

迈向动态野外世界中稳定的测试时自适应

Shuaicheng Niu^{14*}, Jiaxiang Wu^{2*}, Yifan Zhang^{3*}, Zhiqian Wen¹, Yaofo Chen¹,
Peilin Zhao², Mingkui Tan^{15†}

sensc@mail.scut.edu.cn; mingkuitan@scut.edu.cn

South China University of Technology¹ Tencent AI Lab² National University of Singapore³

Key Laboratory of Big Data and Intelligent Robot, Ministry of Education⁴ Pazhou Laboratory⁵

摘要

测试时自适应 (Test-Time Adaptation, TTA) 通过在测试样本上调整给定模型, 已被证明能有效应对训练与测试数据之间的分布偏移。然而, TTA 的在线模型更新可能不稳定, 这往往是阻碍现有 TTA 方法在现实世界中部署的关键障碍。具体而言, 当测试数据具有以下情况时, TTA 可能无法提升甚至损害模型性能: 1) 混合分布偏移, 2) 小批大小, 3) 在线不平衡标签分布偏移, 这些情况在实践中相当常见。本文探究了不稳定的原因, 发现批归一化层是阻碍 TTA 稳定性的关键因素。相反, 使用批无关的归一化层 (即组归一化或层归一化) 时, TTA 可以更稳定地运行。然而, 我们观察到使用组归一化和层归一化的 TTA 并不总能成功, 仍然存在许多失败案例。通过深入分析失败案例, 我们发现某些具有大梯度的噪声测试样本可能干扰模型自适应, 导致退化的平凡解, 即为所有样本分配相同的类别标签。为解决上述坍缩问题, 我们提出了一种锐度感知且可靠的熵最小化方法, 称为 SAR, 从两个方面进一步稳定 TTA: 1) 移除部分具有大梯度的噪声样本, 2) 鼓励模型权重收敛到平坦最小值, 使模型对剩余噪声样本具有鲁棒性。有前景的结果表明, 在上述严苛的测试场景下, SAR 比先前方法表现更稳定, 且计算高效。源代码可在 <https://github.com/mr-eggplant/SAR> 获取。

1 引言

深度神经网络在训练和测试域遵循相同分布时能取得优异性能 (He 等, 2016; Wang 等, 2018; Choi 等, 2018)。然而, 当存在域偏移时, 深度网络往往难以泛化。这种域偏移通常出现在实际应用中, 因为测试数据不可避免地会遇到自然变化或损坏 (Hendrycks & Dietterich, 2019; Koh 等, 2021), 例如天气变化 (如雪、霜、雾)、传感器退化 (如高斯噪声、散焦模糊) 以及许多其他原因。不幸的是, 深度模型可能对上述偏移敏感, 即使偏移轻微也会遭受严重的性能下降 (Recht 等, 2018)。然而, 在存在分布偏移的测试域上部署深度模型仍然是一个迫切需求, 这些情况下需要进行模型自适应。最近, 许多测试时自适应 (TTA) 方法 (Sun 等, 2020; Wang 等, 2021; Iwasawa & Matsuo, 2021; Bartler 等, 2022) 被提出, 通过在线更新测试数据上的模型来克服上述域偏移, 主要包括两大类, 即测试时训练 (TTT) (Sun 等, 2020; Liu 等, 2021) 和完全 TTA (Wang 等, 2021; Niu 等, 2022a)。本文专注于完全 TTA, 因为它在两个方面比 TTT 更通用: i) 它不改变训练过程, 可以在不访问原始训练数据的情况下将任意预训练模型适配到测试数据; ii) 对于每个测试样本, 它可能比 TTT 需要更少的反向传播次数 (仅一次或不到一次) (见表 6 中 TTT、Tent 和 EATA 的效率比较)。* 同等贡献。† 通讯作者。工作完成于 S. Niu 在腾讯 AI 实验室实习期间。




图 1: 实用/野生测试时自适应 (TTA) 场景的示意图, 其中先前的在线 TTA 方法可能会严重退化。Tent (Wang 等, 2021) 的准确率在 ImageNet-C 第 5 级上用 ResNet50-BN 测量 ((a) 中 15 种混合损坏, (b-c) 中高斯噪声)。

测试时自适应 (TTA) 已被证明能显著提升模型对领域偏移的鲁棒性。然而, 其优异性能往往是在一些温和的测试设置下获得的, 例如, 使用具有相同分布偏移类型且标签分布随机打乱的批量测试样本进行自适应 (见图 1 左)。在复杂的现实世界中, 测试数据可能以任意方式出现。如图 1 右所示, 测试场景可能面临: i) 多种分布偏移的混合, ii) 较小的测试批大小 (甚至单个样本), iii) 真实测试标签分布 $Q_t(y)$ 在线偏移且 $Q_t(y)$ 在每个时间步 t 可能不平衡。在这些严苛的测试设置下, 使用现有 TTA 方法在线更新模型可能不稳定, 即无法帮助甚至损害模型的鲁棒性。

为稳定野外的测试时自适应 (TTA), 一种直接的解决方案是在每个样本或小批量自适应后恢复模型权重, 例如 MEMO (Zhang 等, 2022) 和情景式 Tent (Wang 等, 2021)。同时, DDA (Gao 等, 2022) 提供了一个潜在有效的思路: 不是进行模型自适应, 而是将测试样本迁移到源训练分布 (通过训练好的扩散模型 (Dhariwal 和 Nichol, 2021)), 测试期间所有模型权重保持冻结。然而, 这些方法无法累积利用先前测试样本的知识来提升自适应性能, 因此在测试样本较多时结果有限。此外, DDA 中的扩散模型需要具备良好的泛化能力, 能够将任意可能的目标偏移投影到源数据。但就目前而言, 这很难满足, 例如 DDA 在噪声偏移上表现良好, 而在模糊和天气偏移上竞争力较弱 (见表 2)。因此, 如何在野外测试设置下稳定在线 TTA 仍是一个开放问题。本文首先指出批归一化 (BN) 层 (Ioffe 和 Szegedy, 2015) 是一个关键障碍, 因为在上述野外场景下, BN 层中的均值和方差估计会产生偏差。鉴于此, 我们进一步研究了归一化层在 TTA 中的作用 (见第 4 节), 发现具有批无关归一化层 (即组归一化 (GN) (Wu 和 He, 2018) 和层归一化 (LN) (Ba 等, 2016)) 的预训练模型更有利于稳定的 TTA。然而, 在 GN/LN 模型上进行 TTA 并不总能成功, 仍存在许多失败案例。具体而言, 通过在线熵最小化 (Wang 等, 2021) 优化的 GN/LN 模型倾向于发生坍塌, 即把所有样本预测为单一类别 (见图 2), 尤其是在分布偏移严重时。为解决这一问题, 我们提出了一种锐度感知且可靠的熵最小化方法 (简称 SAR)。具体来说, 我们发现确实有一些噪声样本会产生大范数梯度, 损害自适应过程并导致模型坍塌。为避免这种情况, 我们根据熵值过滤掉部分具有大且嘈杂梯度的样本, 使其不参与自适应。对于剩余样本, 我们引入锐度感知学习方案, 确保模型权重被优化到平坦最小值, 从而对大且嘈杂的梯度/更新具有鲁棒性。

主要发现与贡献。 (1) 本文分析并实证验证了批无关的范数层 (即组归一化 (GN) 和层归一化 (LN)) 在混合域偏移、小测试批大小和在线不平衡标签分布偏移等极端测试条件下, 比批归一化 (BN) 更有利于稳定的测试时自适应 (见图 1)。 (2) 本文进一步通过提出一种锐度感知且可靠的 (SAR) 优化方案来解决 GN/LN 模型上测试时熵最小化的模型崩溃问题, 该方案联合最小化那些可靠测试样本的熵和熵的锐度。SAR 简单而有效, 能够在极端测试条件下实现稳定的在线测试时自适应。

2 预备知识

为便于进一步分析, 本节回顾测试时自适应方法的两大主要类别, 由于篇幅限制, 详细的相关工作讨论置于附录 A。

测试时训练 (TTT)。设 $f_{\Theta}(\mathbf{x})$ 表示在 $\mathcal{D}_{train} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ 上训练、参数为 Θ 的模型，其中 $\mathbf{x}_i \in \mathcal{X}_{train}$ (训练数据空间) 和 $y_i \in \mathcal{C}$ (标签空间)。测试时自适应 (Sun 等, 2020; Wang 等, 2021) 的目标是提升 $f_{\Theta}(\mathbf{x})$ 在分布外测试样本上的性能，其中 $\mathbf{x}_i \in \mathcal{X}_{test}$ (测试数据空间) 和 $\mathcal{X}_{test} \neq \mathcal{X}_{train}$ 。Sun 等 (2020) 首先提出了 TTT 流程，在训练阶段，模型在源数据 $\mathcal{D}_{train}$ 上通过交叉熵 $\mathcal{L}_{CE}$ 和自监督旋转预测 (Gidaris 等, 2018) $\mathcal{L}_S$ 进行训练：

$$test = \mathbf{x}_j \quad j=1$$

$$\min_{\Theta_b, \Theta_c, \Theta_s} \mathbb{E}_{\mathbf{x} \in \mathcal{D}_{train}} [\mathcal{L}_{CE}(\mathbf{x}; \Theta_b, \Theta_c) + \mathcal{L}_S(\mathbf{x}; \Theta_b, \Theta_s)], \quad (1)$$

其中 Θ_b 是任务共享参数 (影子层)， Θ_c 和 Θ_s 分别是用于 $\mathcal{L}_{CE}$ 和 $\mathcal{L}_S$ 的任务特定参数 (深层)。在测试阶段，给定测试样本 $\mathbf{x}$ ，TTT 首先通过自监督任务更新模型： $\Theta'_b \leftarrow \arg \min_{\Theta_b} \mathcal{L}_S(\mathbf{x}; \Theta_b, \Theta_s)$ ，然后使用更新后的模型权重 Θ'_b 通过 $f(\mathbf{x}; \Theta'_b, \Theta_c)$ 进行最终预测。

全测试时自适应 (TTA)。TTT 的流程需要改变原始模型训练过程，当训练数据因隐私/存储问题不可用时，这可能不可行。为避免此问题，Wang 等 (2021) 提出了全 TTA，通过对给定测试小批量进行熵最小化 (**Tent**)： $\min - \sum_c \hat{y}_c \log \hat{y}_c$ 来适应任意预训练模型，其中 $\hat{y}_c = f_{\Theta_c}(\mathbf{x})$ 和 c 表示类别 c 。如表 6 所示，该方法比 TTT 更高效。

3 基于测试熵与锐度最小化的稳定自适应

动态野外世界中的测试时自适应 (Test-time Adaptation, TTA) 尽管先前的测试时自适应方法在分布外泛化方面展现出巨大潜力，但其成功可能依赖于一些潜在的测试前提 (如图 1 所示)：

- 1) 测试样本具有相同的分布偏移类型；
- 2) 每次使用一批样本进行自适应；
- 3) 在整个在线自适应过程中测试标签分布是均匀的，然而这些前提在野外世界中很容易被违反。在野外场景 (图 1) 中，先前的方法可能表现不佳甚至失败。在本节中，我们试图从统一的视角 (参见第 3.1 节) 分析 TTA 在图 1 所述野外测试场景下失败的根本原因，然后提出相应的解决方案 (参见第 3.2 节)。

3.1 什么导致了不稳定的测试时自适应？

我们首先通过研究 TTA 中归一化层的影响来分析野外 TTA 失败的原因，然后深入探讨基于熵的方法在使用批无关归一化 (如组归一化) 时的不稳定原因。

批归一化阻碍稳定的测试时自适应。 在测试时自适应 (TTA) 中，以往方法通常对带有批归一化

(BN) 层的预训练模型进行自适应 (Ioffe & Szegedy, 2015)，其中大多数建立在 BN 统计量自适应之上 (Schneider et al., 2020; Nado et al., 2020; Khurana et al., 2021; Wang et al., 2021; Niu et al., 2022a; Hu et al., 2021; Zhang et al., 2022)。具体而言，对于一个具有 d 维输入 $\mathbf{x} = (x^{(1)} \dots x^{(d)})$ 的层，批归一化输出为：

$$\gamma^{(k)} \hat{x}^{(k)} + \beta^{(k)}, \quad \hat{x}^{(k)} = \frac{(x^{(k)} - \mathbb{E}[x^{(k)}])}{\sqrt{\text{Var}[x^{(k)}]}} \quad \text{其中 } \gamma^{(k)} \text{ 和 } \beta^{(k)} \text{ 是可学习的仿射参数。}$$

BN 自适应方法在 (一批) 测试样本上计算均值 $\mathbb{E}[x^{(k)}]$ 和方差 $\text{Var}[x^{(k)}]$ 。然而，在野生 TTA 中，图 1 所示的三种可能导致 TTA 失败的实用自适应设置都会导致均值和方差估计出现问题。首先，BN 统计量实际上代表一种分布，理想情况下每种分布应有其自身的统计量。从小批量测试样本中简单估计多个分布的共享 BN 统计量不可避免地只能获得有限的性能，例如在多任务/多领域学习中 (Wu & Johnson, 2021)。其次，估计统计量的质量依赖于批大小，而使用极少量样本 (即小批大小) 难以准确估计。第三，不平衡的标签偏移也会导致 BN 统计量偏向数据集中某些特定类别。基于上述分析，本文认为与批无关的归一化层，即对样本分组方式不敏感的归一化层，更适合执行 TTA，例如组归一化 (GN) (Wu & He, 2018) 和层归一化 (LN) (Ba et al., 2016)。我们在第 3.2 节基于 GN/LN 模型设计方法。为验证上述观点，我们在第 4 节实证研究了不同归一化层 (包括 BN、GN 和 LN) 在 TTA (包括 TTT 和 Tent) 中的影响。结果表明，配备 GN 和 LN 的模型比配备 BN 的模型更稳定，当




图 2: 在线测试时熵最小化 (Wang et al., 2021) 的失败案例分析 (a-c)。(a) 和 (b) 记录了在线自适应过程中的模型预测。(c) 展示了有无模型崩溃时梯度范数的演变。(d) 研究了样本熵与梯度范数之间的关系。所有实验均在打乱的高斯噪声 ImageNet-C 上使用 ResNet50 (GN) 进行, 严重程度等级越大表示分布偏移越严重。

在三种实用的测试设置下进行在线测试时自适应 (见图 1), 并且失败案例更少。详细的实证研究放在第 4 节以保持表述的连贯性。

在线熵最小化倾向于导致坍塌的平凡解, 即预测所有

样本为同一类别。尽管测试时自适应在组归一化和层归一化模型上表现更稳定, 但它并不总是成功, 仍然面临若干失败案例 (如第 4 节所示)。例如, 在组归一化模型 (ResNet50-GN) 上的熵最小化 (Tent) 倾向于坍塌, 尤其是在分布偏移程度严重时。本文旨在稳定各种实用测试设置下的在线全测试时自适应。为此, 我们首先分析失败原因, 发现模型经常被优化到坍塌的平凡解。我们在下文中说明这一问题。在在线自适应过程中, 我们记录了 ResNet50-GN 在打乱的 ImageNet-C 高斯噪声上的预测类别和梯度范数 (由熵损失产生)。通过比较图 2 (a) 和 (b), 熵最小化被证明是不稳定的, 并且当分布偏移严重时 (即严重程度 5 级) 可能发生坍塌。从图 2 (a) 可以看出, 随着自适应的进行, 模型倾向于将所有输入样本预测为同一类别, 即使这些样本具有不同的真实类别, 这被称为模型坍塌。同时, 我们注意到随着模型开始坍塌, 所有可训练参数的梯度 ℓ_2 -范数突然增加, 然后几乎降为 0 (如图 2 (c) 所示), 而在严重程度 3 级时模型工作良好, 梯度范数始终保持在一个稳定范围内。这表明一些测试样本产生了较大的梯度, 可能损害自适应并导致模型坍塌。

3.2 锐度感知且可靠的测试时熵最小化

基于上述分析, 避免模型坍塌的两个最直接的解决方案是根据样本梯度过滤测试样本或执行梯度裁剪。然而, 这些方法不太可行, 因为不同模型和分布偏移类型的梯度范数具有不同的尺度, 因此很难设计一种通用方法来设置样本过滤或梯度裁剪的阈值 (更多分析见第 5.2 节)。我们提出如下解决方案。

可靠熵最小化。由于直接根据梯度范数筛选样本不可行, 本文首先研究熵损失与梯度范数之间的关系, 并尝试基于样本的熵来移除具有较大梯度的样本。此处, 熵取决于模型的输出类别数 C , 对于不同的模型和数据, 它属于 $(0, \ln C)$ 。从这个意义上说, 用于筛选样本的熵阈值更容易选择。如图 2 (d) 所示, 选择损失值较小的样本可以从自适应过程中移除部分具有较大梯度的样本 (区域@1)。形式上, 令 $E(\mathbf{x}; \Theta)$ 为样本 $\mathbf{x}$ 的熵, 选择性熵最小化定义为:

$$\min_{\Theta} S(\mathbf{x})E(\mathbf{x}; \Theta), \text{ where } S(\mathbf{x}) \triangleq \mathbb{I}_{\{E(\mathbf{x}; \Theta) < E_0\}}(\mathbf{x}). \quad (2)$$

此处, Θ 表示模型参数, $\mathbb{I}_{\{ \cdot \}}(\cdot)$ 是指示函数, E_0 是预定义参数。注意, 上述准则也会移除图 2 (d) 中区域@2 内的样本, 这些样本置信度低, 因此不可靠 (Niu 等人, 2022a)。

锐度感知熵最小化。通过公式 (2), 本文已将图 2 (d) 中区域@1 和@2 的测试样本从自适应过程中移除。理想情况下, 本文期望仅利用区域@3 中的样本来优化模型, 因为区域@4 中的样本仍具有较大梯度, 可能损害自适应过程。然而, 通过筛选方案进一步移除区域@4 中的样本较为困难。作为替代方案,




图 3: 不同模型 (不同归一化层) 下不同测试时自适应方法的批大小效应。实验在 ImageNet-C 的高斯噪声上进行。本文报告了 3 次不同随机种子运行的平均值和标准差。‘na’表示无自适应准确率。注意, 除 ViT-LN 外, 标准差过小, 无法在图中显示。

本文尝试使模型对区域@4 中样本贡献的大梯度不敏感。为此, 本文鼓励模型走向熵损失曲面的平坦区域。原因在于, 平坦极小值具有良好的泛化能力, 并且对噪声或大梯度具有鲁棒性, 即平坦极小值上的噪声或大更新不会显著影响原始模型损失, 而尖锐极小值则会。为此, 本文联合最小化熵及其锐度:

$$\min_{\Theta} E^{SA}(\mathbf{x}; \Theta), \text{ where } E^{SA}(\mathbf{x}; \Theta) \triangleq \max_{\|\epsilon\|_2 \leq \rho} E(\mathbf{x}; \Theta + \epsilon). \quad (3)$$

此处, 内部优化旨在半径为 ρ 的欧几里得球中寻找权重扰动 ϵ , 以最大化熵。锐度由 Θ 与 $\Theta + \epsilon$ 之间熵的最大变化来量化。该双层问题促使优化寻找平坦极小值。为解决式 (3), 我们遵循 SAM (Foret 等, 2021), 首先通过一阶泰勒展开近似求解内部优化, 即

$$\epsilon^*(\Theta) \triangleq \arg \max_{\|\epsilon\|_2 \leq \rho} E(\mathbf{x}; \Theta + \epsilon) \approx \arg \max_{\|\epsilon\|_2 \leq \rho} E(\mathbf{x}; \Theta) + \epsilon^T \nabla_{\Theta} E(\mathbf{x}; \Theta) = \arg \max_{\|\epsilon\|_2 \leq \rho} \epsilon^T \nabla_{\Theta} E(\mathbf{x}; \Theta).$$

那么, 求解该近似的 $\hat{\epsilon}(\Theta)$ 由经典对偶范数问题的解给出:

$$\hat{\epsilon}(\Theta) = \rho \text{sign}(\nabla_{\Theta} E(\mathbf{x}; \Theta)) |\nabla_{\Theta} E(\mathbf{x}; \Theta)| / \|\nabla_{\Theta} E(\mathbf{x}; \Theta)\|_2. \quad (4)$$

将 $\hat{\epsilon}(\Theta)$ 代回式 (3) 并求导, 为加速计算省略二阶项, 最终梯度近似为:

$$\nabla_{\Theta} E^{SA}(\mathbf{x}; \Theta) \approx \nabla_{\Theta} E(\mathbf{x}; \Theta) \Big|_{\Theta + \hat{\epsilon}(\Theta)}. \quad (5)$$

整体优化。总之, 本文提出的锐度感知且可靠的熵最小化方法为:

$$\min_{\Theta} S(\mathbf{x}) E^{SA}(\mathbf{x}; \Theta), \quad (6)$$

其中 $S(\mathbf{x})$ 和 $E^{SA}(\mathbf{x}; \Theta)$ 分别在式 (2) 和式 (3) 中定义, $\tilde{\Theta} \subset \Theta$ 表示测试时自适应期间的可学习参数。此外, 为避免式 (6) 可能失败的少数极端困难情况, 本文进一步引入模型恢复方案。记录熵损失值的移动平均 e_m , 一旦 e_m 小于小阈值 e_0 , 就将 $\tilde{\Theta}$ 重置为原始值, 因为模型发生坍塌后会产生非常小的熵损失。此处额外内存开销可忽略不计, 因为仅优化归一化层中的仿射参数 (详见附录 C.2)。方法细节总结于附录 B 的算法 1。

4 测试时自适应中归一化层效应的实证研究

本节设计实验, 以说明在图 1 所述的多种测试条件下, 测试时自适应 (TTA) 在具有不同归一化层 (包括 BN、GN 和 LN) 的模型上的表现。验证第 2 节介绍的两种代表性方法, 即自监督 TTT (Sun 等, 2020) 和无监督 Tent (一种完全 TTA 方法) (Wang 等, 2021)。考虑到归一化层通常与主流网络架构耦合, 在 ResNet-50-BN (R-50-BN)、ResNet-50-GN (R-50-GN) 和 ViTBase-LN (ViT-LN) 上进行自适应。所有采用的模型权重均公开可用, 来自 torchvision 或 timm 仓库 (Wightman, 2019)。本节实验的实现细节见附录 C.2。




图 4: 在 15 种不同损坏类型混合 (ImageNet-C) 下, TTA 方法在不同模型 (不同范数层) 上的性能。我们报告 3 次独立运行的平均值和标准差。




图 5: 在 ImageNet-C (高斯噪声) 上在线不平衡标签分布偏移下, TTA 方法在不同模型 (不同范数层) 上的性能。我们报告 3 次运行的平均值和标准差结果。注意, 除 ViTBase-LN 外, 标准差太小, 无法在图中显示。

(1) **小测试批大小下 TTA 中的范数层效应。**我们评估了不同批大小 (BS) 下的 TTA 方法 (TTT 和 Tent), BS 选自 $\{1, 2, 4, 8, 16, 32, 64\}$ 。由于 GPU 内存限制, 我们仅报告 TTT 的 BS 最高为 8 或 16 的结果 (原始 TTT 的 BS 为 1), 因为 TTT 需要对每个测试样本进行多次增强 (我们按照 Niu 等人 (2022a) 设置为 20 次)。从图 3 中, 我们得到: i) 对于 Tent, 与 R-50-BN 相比, R-50-GN 和 **Vit-LN** 对小测试批大小不那么敏感。当批大小变小时 (< 8), R-50-BN 的自适应性严重下降, 而 **R-50-GN/Vit-LN** 在各种批大小下表现稳定 (**Vit-LN** 在级别 5 和 3 上, R-50-GN 在级别 3 上, 见子图 (b) 和 (d))。值得注意的是, 使用 R-50-GN 和 **Vit-LN** 的 Tent 并不总是成功, 也存在失败案例, 例如 R-50-GN 在级别 5 上 (Tent 表现比不进行自适应更差), 这在第 3.1 节中进行了分析。ii) 对于 TTT, 所有 R-50-BN/GN 和 **Vit-LN** 在各种批大小下都能表现良好。然而, 使用 **Vit-LN** 的 TTT 非常不稳定, 在不同运行中具有很大的方差, 表明 **TTT+VitBase** 对不同的样本顺序非常敏感。这里, TTT 在批大小为 1 时使用 R-50-BN 表现良好, 主要得益于 TTT 对单个样本应用多次数据增强以形成一个小批量。

(2) **混合分布偏移下 TTA 中的范数层效应。**当测试数据同时来自多个偏移域时, 我们在具有不同范数层的模型上评估测试时自适应方法。我们比较了在包含 15 种损坏类型的 **ImageNet-C** 上的“无自适应”、“平均自适应” (分别对每个域进行自适应的平均准确率) 和“混合自适应” (在混合偏移域上进行自适应) 的准确率。“混合自适应”与“平均自适应”之间的准确率差距越大, 表明对混合分布偏移越敏感。从图 4 中, 我们得到: i) 对于 Tent 和 TTT, R-50-GN 和 **Vit-LN** 在混合域偏移下比 R-50-BN 表现更稳定。具体而言, 在不同严重程度级别 (所有子图 (a-d)) 中, R-50-BN 的混合自适应准确率始终低于平均自适应准确率。相比之下, R-50-GN 和 **Vit-LN** 能够达到与混合和平均自适应相当的准确率, 例如 R-50-GN 上的 TTT (级别 5 和 3) 和 **Vit-LN** 上的 Tent (级别 3)。ii) 对于 R-50-GN 和 **Vit-LN**, TTT 比 Tent 表现更稳定。具体来说, Tent 有 3/4 的失败案例 (R-50-GN 在级别 5 和 3 上, **Vit-LN** 在级别 5 上), 比 TTT 的失败案例更多。iii) 与第 4 节 (1) 相同, **Vit-LN** 上的 TTT 在多次运行中具有较大方差, 表明 **TTT+Vit-LN** 对不同的样本顺序敏感。

(3) **在线不平衡标签偏移下测试时自适应中的范数层效应。**如图 1 (c) 所示, 在在线自适应过程中, 不同时间步 t 的标签分布 $Q_t(y)$ 可能不同 (在线偏移) 且不平衡。为了评估这一点, 我们首先通过调整输入样本 (来自测试集) 的顺序来模拟这种不平衡的标签分布偏移, 如下所示。

在线不平衡标签分布偏移仿真。假设我们总共有 T 个时间步, 且 T 等于类别数 C 。我们设置概率向量 $Q_t(y) = [q_1, q_2, \dots, q_C]$, 其中如果 $c = t$ 则 $q_c = q_{\max}$, 如果 $c \neq t$ 则 $q_c = q_{\min} \triangleq (1 - q_{\max}) / (C - 1)$ 。这里, $q_{\max} / q_{\min}$ 表示不平衡比率。然后, 在每个 $t \in \{1, 2, \dots, T=C\}$ 处, 我们从测试集中采样 M 张图像

根据 $Q_t(y)$ 。基于 **ImageNet-C**（高斯噪声），我们构建了一个新的测试集，该测试集具有在线不平衡标签分布偏移，共包含 $100(M) \times 1000(T)$ 张图像。注意，我们预先打乱了 **ImageNet-C** 中的类别顺序，因为在实际中我们无法预知哪个类别会出现。从图 5 中，我们得到：i) 对于 Tent, R-50-GN 和 **Vit-LN** 对在线不平衡标签分布偏移的敏感度低于 R-50-BN（见子图 (b) 和 (d)）。具体而言，R-50-BN（级别 5 和 3）的自适应准确率随着不平衡比的增加而严重下降。相比之下，R-50-GN 和 **Vit-LN** 在各种不平衡比下具有稳定表现的潜力（例如，级别 3 上的 R-50-GN 和 **Vit-LN**）。ii) 对于 TTT，所有 R-50-BN/GN 和 **Vit-LN** 在标签偏移下表现相对稳定，除了 **TTT+Vit-LN** 具有较大的方差。自适应准确率也会下降，但随着不平衡比的增加，下降并不十分严重。iii) 使用 GN 的 Tent 对分布偏移程度的敏感度高于 BN。具体而言，对于不平衡比为 1（所有 $Q_t(y)$ 都是均匀的）和严重级别 5，Tent+R-50-GN 失败，表现比不进行自适应更差，而 Tent+R-50-BN 表现良好。

(4) 总体观察。基于上述所有结果，我们得到：i) 在野生测试设置下执行 TTA 时，R-50-GN 和 **Vit-LN** 比 R-50-BN 更稳定（见图 1）。然而，它们并不总是成功，仍然存在一些失败案例。ii) R-50-GN 比 **Vit-LN** 更适合自监督 TTT，因为 **TTT+Vit-LN** 对不同的样本顺序敏感，并且在不同的运行中具有较大的方差。iii) **Vit-LN** 比 R-50-GN 更适合无监督 Tent，因为 Tent+R-50-GN 容易崩溃，尤其是在分布偏移严重时。

5 与最先进方法的比较

数据集和方法。

我们在 ImageNet-C (Hendrycks & Dietterich, 2019) 上进行实验，这是一个大规模且广泛使用的分布外泛化基准。它包含 4 大类（噪声、模糊、天气、数字）15 种类型的损坏图像，每种类型有 5 个严重程度级别。我们将我们的 SAR 与以下最先进的方法进行比较。DDA (Gao et al., 2022) 在测试时通过扩散模型执行输入自适应。MEMO (Zhang et al., 2022) 针对给定测试样本的不同增强副本最小化边际熵。Tent (Wang et al., 2021) 和 EATA (Niu et al., 2022a) 是两种基于熵的在线全测试时自适应 (TTA) 方法。

表 1: 在 ResNet50-GN 上使用单个 V100 GPU 处理 50,000 张图像 (ImageNet-C 上的高斯噪声，级别 5) 的效率比较。

Method	GPU time
MEMO (Zhang et al., 2022)	55,980 secs
DDA (Gao et al., 2022)	146,220 secs
TTT (Sun et al., 2020)	3,600 secs
Tent (Wang et al., 2021)	110 secs
EATA (Niu et al., 2022a)	114 secs
SAR (本文方法)	115 秒

模型与实现细节。我们在从 torchvision 或 timm (Wightman, 2019) 获得的 ResNet50-BN/GN 和 VitBase-LN 上进行实验。对于我们的 SAR，我们使用 SGD 作为更新规则，动量为 0.9，批大小为 64（除了批次 size=1），的实验和 ResNet/Vit 模型的学习率 0.00025/0.001。公式 (2) 中的阈值 E_0 按照 EATA (Niu et al., 2022a). ρ 在公式 (3) 中由 Foret et al. (2021) 的默认值 0.05 设置) 设置为 $0.4 \times \ln 1000$ 。对于 TTA 期间 SAR 的可训练参数，遵循 Tent (Wang et al., 2021)，我们自适应 ResNet50-GN/VitBase-LN 中组/层归一化层的仿射参数。比较方法的更多细节和超参数放在附录 C.2 中。

5.1 各种野生测试设置下的损坏鲁棒性

在线不平衡标签分布偏移下的结果。如第 4 节所示，随着不平衡比率 q_{max}/q_{min} 的增加，测试时自适应 (TTA) 的性能退化愈发严重。在此，我们在最困难的情况下进行比较：

$q_{max}/q_{min}=\infty$, i.e., 测试样本按类别顺序出现。为了公平比较，我们通过相同的样本序列在不同损坏类型下评估所有方法。从表 2 可以看出，我们的 SAR 在 ResNet50-GN 和 VitBase-LN 上平均 15 种损坏类型的结果中取得了最佳成绩，这表明了其有效性。值得注意的是，Tent 在 VitBase-LN（例如，散焦和运动模糊）和 ResNet50-GN（例如，像素化）的许多损坏类型上表现良好，但在 ResNet50-BN 上始终失败。这进一步验证了我们在第 4 节中的观察，即在在线不平衡标签分布偏移下，对 LN/GN 模型进行熵最小化有潜力表现良好。同时，Tent 也存在许多失败案例，例如，VitBase-LN 在散粒噪声和雪天条件下。对于这些情况，我们的 SAR 表现良好。此外，EATA 的失败案例比 Tent 少，并且实现了更高的平均准确率，这表明权重正则化在某种程度上能够缓解模型崩溃问题。尽管如此，EATA 的性能仍不如我们的 SAR，例如，在 VitBase-LN 上平均准确率为 49.9% 对比我们的 58.0%。

表 2: 在在线不平衡标签偏移（不平衡比率 = ∞ ）下，与最先进方法在 ImageNet-C（严重程度 5 级）上的准确率（%）比较。“BN”/“GN”/“LN”是批/组/层归一化的缩写。粗体数字表示最佳结果。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (BN)	2.2	2.9	1.8	17.8	9.8	14.5	22.5	16.8	23.4	24.6	59.0	5.5	17.1	20.7	31.6	18.0
• MEMO	7.4	8.6	8.9	19.8	13.2	20.8	27.5	25.6	28.6	32.3	60.8	11.0	23.8	33.2	37.7	24.0
• DDA	32.2	33.1	32.0	14.6	16.4	16.6	24.4	20.0	25.5	17.2	52.2	3.2	35.7	41.8	45.4	27.2
• Tent	1.2	1.4	1.4	1.0	0.9	1.2	2.6	1.7	1.8	3.6	5.0	0.5	2.6	3.2	3.1	2.1
• EATA	0.3	0.3	0.3	0.2	0.2	0.5	0.9	0.8	0.9	1.8	3.5	0.2	0.8	1.2	0.9	0.9
ResNet50 (GN)	17.9	19.9	17.9	19.7	11.3	21.3	24.9	40.4	47.4	33.6	69.2	36.3	18.7	28.4	52.2	30.6
• MEMO	18.4	20.6	18.4	17.1	12.7	21.8	26.9	40.7	46.9	34.8	69.6	36.4	19.2	32.2	53.4	31.3
• DDA	42.5	43.4	42.3	16.5	19.4	21.9	26.1	35.8	40.2	13.7	61.3	25.2	37.3	46.9	54.3	35.1
• Tent	2.6	3.3	2.7	13.9	7.9	19.5	17.0	16.5	21.9	1.8	70.5	42.2	6.6	49.4	53.7	22.0
• EATA	27.0	28.3	28.1	14.9	17.1	24.4	25.3	32.2	32.0	39.8	66.7	33.6	24.5	41.9	38.4	31.6
• SAR (ours)	33.1 $\pm$ 1.0	36.5 $\pm$ 0.4	35.5 $\pm$ 1.1	19.2 $\pm$ 0.4	19.5 $\pm$ 1.2	33.3 $\pm$ 0.5	27.7 $\pm$ 0.0	23.9 $\pm$ 5.1	45.3 $\pm$ 0.4	50.1 $\pm$ 0.1	71.9 $\pm$ 0.1	46.7 $\pm$ 0.2	7.1 $\pm$ 1.8	52.1 $\pm$ 0.5	56.3 $\pm$ 0.1	37.2 $\pm$ 0.6
VitBase (LN)	9.4	6.7	8.3	29.1	23.4	34.0	27.0	15.8	26.3	47.4	54.7	43.9	30.5	44.5	47.6	29.9
• MEMO	21.6	17.4	20.6	37.1	29.6	40.6	34.4	25.0	34.8	55.2	65.0	54.9	37.4	55.5	57.7	39.1
• DDA	41.3	41.3	40.6	24.6	27.4	30.7	26.9	18.2	27.7	34.8	50.0	32.3	42.2	52.5	52.7	36.2
• Tent	32.7	1.4	34.6	54.4	52.3	58.2	52.2	7.7	12.0	69.3	76.1	66.1	56.7	69.4	66.4	47.3
• EATA	35.9	34.6	36.7	45.3	47.2	49.3	47.7	56.5	55.4	62.2	72.2	21.7	56.2	64.7	63.7	49.9
• SAR (ours)	46.5 $\pm$ 3.0	43.1 $\pm$ 7.4	48.9 $\pm$ 0.4	55.3 $\pm$ 0.1	54.3 $\pm$ 0.1	58.9 $\pm$ 0.1	54.8 $\pm$ 0.2	53.6 $\pm$ 7.1	46.2 $\pm$ 3.5	69.7 $\pm$ 0.3	76.2 $\pm$ 0.1	66.2 $\pm$ 0.3	60.9 $\pm$ 0.3	69.6 $\pm$ 0.1	66.6 $\pm$ 0.1	58.0 $\pm$ 0.5

表 4: 在批处理 SIZE=1 下，与最先进方法在 ImageNet-C（严重程度 5 级）上的准确率（%）比较。“BN”/“GN”/“LN”是批/组/层归一化的缩写。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (BN)	2.2	2.9	1.9	17.9	9.8	14.8	22.5	16.9	23.3	24.4	58.9	5.4	17.0	20.6	31.6	18.0
• MEMO	7.5	8.7	8.9	19.7	13.0	20.8	27.6	25.4	28.7	32.2	60.9	11.0	23.8	32.9	37.5	23.9
• DDA	32.1	32.8	31.8	14.7	16.6	16.6	24.2	20.0	25.4	17.2	52.1	3.2	35.7	41.5	45.3	27.3
• Tent	0.1	0.1	0.1	0.1	0.1	0.1	0.2	0.2	0.2	0.2	0.2	0.1	0.1	0.2	0.1	0.1
• EATA	0.1	0.1	0.1	0.1	0.1	0.1	0.2	0.2	0.2	0.1	0.2	0.1	0.1	0.2	0.1	0.1
ResNet50 (GN)	18.0	19.8	17.9	19.8	11.4	21.4	24.9	40.4	47.3	33.6	69.3	36.3	18.6	28.4	52.3	30.6
• MEMO	18.5	20.5	18.4	17.1	12.6	21.8	26.9	40.4	47.0	34.4	69.5	36.5	19.2	32.1	53.3	31.2
• DDA	42.4	43.3	42.3	16.6	19.6	21.9	26.0	35.7	40.1	13.7	61.2	25.2	37.5	46.6	54.1	35.1
• Tent	2.5	2.9	2.5	13.5	3.6	18.6	17.6	15.3	23.0	1.4	70.4	42.2	6.2	49.2	53.8	21.5
• EATA	24.8	28.3	25.7	18.1	17.3	28.5	29.3	44.5	44.3	41.6	70.9	44.6	27.0	46.8	55.7	36.5
• SAR (ours)	23.4 $\pm$ 0.3	26.6 $\pm$ 0.4	23.9 $\pm$ 0.0	18.4 $\pm$ 0.1	15.4 $\pm$ 0.3	28.6 $\pm$ 0.3	30.4 $\pm$ 0.2	44.9 $\pm$ 0.3	44.7 $\pm$ 0.2	25.7 $\pm$ 0.6	72.3 $\pm$ 0.2	44.5 $\pm$ 0.1	14.8 $\pm$ 2.7	47.0 $\pm$ 0.1	56.1 $\pm$ 0.0	34.5 $\pm$ 0.2
VitBase (LN)	9.5	6.7	8.2	29.0	23.4	33.9	27.1	15.9	26.5	47.2	54.7	44.1	30.5	44.5	47.8	29.9
• MEMO	21.6	17.3	20.6	37.1	29.6	40.4	34.4	24.9	34.7	55.1	64.8	54.9	37.4	55.4	57.6	39.1
• DDA	41.3	41.1	40.7	24.4	27.2	30.6	26.9	18.3	27.5	34.6	50.1	32.4	42.3	52.2	52.6	36.1
• Tent	42.2	1.0	43.3	52.4	48.2	55.5	50.5	16.5	16.9	66.4	74.9	64.7	51.6	67.0	64.3	47.7
• EATA	29.7	25.1	34.6	44.7	39.2	48.3	42.4	37.5	45.9	60.0	65.9	61.2	46.4	58.2	59.6	46.6
• SAR (ours)	40.8 $\pm$ 0.4	36.4 $\pm$ 0.7	41.5 $\pm$ 0.3	53.7 $\pm$ 0.2	50.7 $\pm$ 0.1	57.5 $\pm$ 0.1	52.8 $\pm$ 0.3	59.1 $\pm$ 0.4	50.7 $\pm$ 0.6	68.1 $\pm$ 1.4	74.6 $\pm$ 0.7	65.7 $\pm$ 0.0	57.9 $\pm$ 0.1	68.9 $\pm$ 0.1	65.9 $\pm$ 0.0	56.3 $\pm$ 0.1

混合分布偏移下的结果。我们在 15 种损坏类型混合（共 $15 \times 50,000$ 张图像）的不同严重程度（5 和 3）下评估了不同方法。从表 3 可以看出，我们的 SAR 在准确率方面始终表现最佳，这表明了其有效性。

Model + Method	Level 5	Level 3
ResNet50 (BN)	18.0	39.7
• MEMO (Zhang et al., 2022)	23.9	46.2
• DDA (Gao et al., 2022)	27.3	44.2
• Tent (Wang et al., 2021)	2.3	41.1
• EATA (Niu et al., 2022a)	26.8	52.6
ResNet50 (GN)	30.6	54.0
• MEMO (Zhang et al., 2022)	31.2	54.5
• DDA (Gao et al., 2022)	35.1	52.3
• Tent (Wang et al., 2021)	13.4	33.1
• EATA (Niu et al., 2022a)	38.1	56.1
• SAR (ours)	38.3 $\pm$ 0.1	57.4 $\pm$ 0.1
VitBase (LN)	29.9	53.8
• MEMO (Zhang et al., 2022)	39.1	62.1
• DDA (Gao et al., 2022)	36.1	53.2
• Tent (Wang et al., 2021)	16.5	70.2
• EATA (Niu et al., 2022a)	55.7	69.6
• SAR (ours)	57.1 $\pm$ 0.1	70.7 $\pm$ 0.1

批大小=为 1 时的结果。从表 4 可以看出，我们的 SAR 在许多情况下取得了最佳结果。值得注意的是，MEMO 和 DDA 不受小批大小、混合域偏移或在线不平衡标签偏移的影响。它们在这些设置下取得稳定/相同的结果，因为它们在每个样本适应后重置（或固定）模型参数。然而，这两种方法的计算复杂度远高于 SAR（见表 1），并且由于它们无法利用先前看到的图像中的知识，只能获得有限的性能提升。虽然 EATA 在 ResNet50-GN 上比我们的 SAR 表现更好，但它依赖于预先收集 2,000 个额外的分布内样本（而我们不需要）。此外，我们的 SAR 在其他情况下始终优于 EATA，参见 VitBase-LN 上的批大小 1 结果、表 2-3 以及附录中的表 8-9。

表 5: SAR 中组件的影响。我们报告了在线不平衡标签偏移（不平衡比率 $q_{max}/q_{min} = \infty$ ）下 ImageNet-C（严重程度 5）的准确率（%）。“reliable”和“sharpness-aware (sa)”分别表示公式 (2) 和公式 (3)，“recover”表示模型恢复方案。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (GN)+Entropy	3.2	4.1	4.0	17.1	8.5	27.0	24.4	17.9	25.5	2.6	72.1	45.8	8.2	52.2	56.2	24.6
✦ reliable	34.5	36.8	36.2	19.5	3.1	33.6	14.5	20.5	38.3	2.4	71.9	47.0	8.3	52.1	56.4	31.7
✦ reliable+sa	33.8	35.9	36.4	19.2	18.7	33.6	24.5	23.5	45.2	49.3	71.9	46.6	9.2	51.6	56.4	37.0
✦ reliable+sa+recover	33.6	36.1	36.2	19.1	18.6	33.9	24.7	22.5	45.7	49.0	71.9	46.6	9.2	51.5	56.3	37.0
VitBase (LN)+Entropy	21.2	1.9	38.6	54.8	52.7	58.5	54.2	10.1	14.7	69.6	76.3	66.3	59.2	69.7	66.8	47.6
✦ reliable	47.8	35.7	48.4	55.2	54.1	58.6	54.4	13.3	21.4	69.5	76.2	66.1	60.2	69.3	66.7	53.1
✦ reliable+sa	47.9	47.6	48.5	55.4	54.2	58.8	54.6	19.7	22.1	69.4	76.3	66.2	60.9	69.4	66.6	54.5
✦ reliable+sa+recover	47.9	47.6	48.5	55.4	54.2	58.8	54.6	49.1	48.3	69.4	76.3	66.2	60.9	69.4	66.6	58.2

5.2 消融实验

与梯度裁剪的比较。如第 3.2 节所述，梯度裁剪是缓解模型崩溃的一种直接解决方案。此处，本文将所提出的 SAR 方法与两种梯度裁剪变体（按值裁剪与按范数裁剪）进行对比。由图 6 可




图 6: 与梯度裁剪的比较。结果基于 VitBase-LN、ImageNet-C、散粒噪声、严重程度 5、在线不平衡（比率 = ∞ ）标签偏移。准确率是在所有先前测试样本上计算的。

见，对于这两种变体，都难以设定合适的裁剪阈值 δ ，因为不同模型和测试数据的梯度尺度各异，因此 δ 的选择会较为敏感。本文在特定测试集（散粒噪声水平 5）上仔细选取 δ 。随后，选取一个非常小的 δ 以使梯度裁剪生效，即按值裁剪 0.001、按范数裁剪 0.1。

尽管如此，相较于“无自适应”的性能提升十分有限，因为较小的 δ 会限制模型的学习能力，且此时裁剪后的梯度可能指向与真实梯度截然不同的方向。然而，较大的 δ 无法稳定自适应过程，模型崩溃后准确率将下降（例如按值裁剪 0.005、按范数裁剪 1.0）。相比之下，SAR 无需调节此类参数，且相比梯度裁剪取得了显著提升。

合成孔径雷达中各组件的效应。从表 5 可见，与纯熵最小化相比，式 (2) 中的可靠熵显著提升了自适应性能，在 VitBase-LN 上 *i.e.*, 47.6% $\rightarrow$ 53.1%，在 ResNet50-GN 上 24.6% $\rightarrow$ 31.7%，以平在公式 (3) 中的 (sa) 最小化下，准确率进一步提升，*e.g.*, 31.7% $\rightarrow$ 在 ResNet50-GN 上相对于平均准确率提升 37.0%。在 VitBase-LN 上，sa 模块同样有效，并帮助模型避免在散粒噪声上崩溃，*e.g.*, 35.7% $\rightarrow$ 47.6%。结合可靠性和 sa，我们的方法表现稳定，除极少数情况外，即 VitBase-LN

在雪和霜上。对于这种情况，我们的模型恢复方案发挥作用，*i.e.*, 54.5% $\rightarrow$ 58.2% 在 VitBase-LN 上相对于平均准确率。

损失曲面的锐度。

我们通过向模型权重添加扰动来可视化损失曲面，如李等人 (2018b) 所述。我们绘制图 7 展示了在完整测试集上适配后获得的模型权重。通过对比图 7 (a) 与 (b)，本文所提 SAR 方法在最低损失等值线内的区域（最深蓝色部分）大于 Tent 方法，表明本文方案更为平坦，因而对噪声或大幅梯度具有更强的鲁棒性。




图 7: 损失（熵）曲面。模型在 ImageNet-C 高斯噪声（等级 5）上训练得到。

6 结论

本文旨在稳定野生测试环境下的在线测试时自适应 (TTA)，即混合偏移、小批量和标签不平衡偏移。为此，我们首先分析并进行了大量实证研究，以验证野生 TTA 失败的原因。然后，我们指出批归一化是稳定 TTA 的关键障碍。同时，尽管批无关归一化（即组归一化和层归一化）在野生环境下表现更稳定，但它们仍存在许多失败案例。为了解决这些失败，我们提出了一种锐度感知且可靠的熵最小化方法 (SAR)，通过抑制具有大梯度的某些噪声测试样本的影响。大量实验结果表明，我们的 SAR 在野生测试环境下具有稳定性和高效性。

致谢

本工作部分得到广州市重点领域研发计划 202007030007、国家自然科学基金 (NSFC) 62072190、科技部基金项目 2020AAA0106900、广东省引进创新创业团队计划 2017ZT07X183、CCF-腾讯开放基金 RAGR20220108 的支持。

可复现性声明

在本工作中，我们在 ImageNet-C/R 和 VisDA-2021 数据集上，使用不同模型 (ResNet50-BN、ResNet50-GN、VitBase-LN) 实现了所有方法 (所有对比方法和我们的 SAR)。复现本文所有结果依赖于以下三个方面：

1. 数据集。第 5 节第一段和附录 C.1 提供了所采用数据集的详细信息及下载链接。2. 模型。所有用于测试时自适应的模型 (含预训练权重) 均公开可用。具体而言，ResNet50-BN 来自 torchvision，ResNet50-GN 和 VitBase-LN 来自 **timm** 仓库 (**Wightman**, 2019)。附录 C.2 提供了它们的下载链接。3. 各方法的协议。第 5 节第二段和附录 C.2 提供了所有对比方法和我们的 SAR 的实现细节。我们基于各方法官方 GitHub 的代码复现了所有对比方法，其下载链接在附录 C.2 中随各方法介绍提供。SAR 的源代码已公开。

参考文献

- Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- Andrei Barbu, David Mayo, Julian Alverio, William Luo, Christopher Wang, Dan Gutfreund, Josh Tenenbaum, and Boris Katz. Objectnet: A large-scale bias-controlled dataset for pushing the limits of object recognition models. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- Alexander Bartler, Andre Bühler, Felix Wiewel, Mario Döbler, and Bin Yang. MT3: meta test-time training for self-supervised test-time adaption. In *International Conference on Artificial Intelligence and Statistics*, pp. 3080–3090, 2022.
- Dina Bashkirova, Dan Hendrycks, Donghyun Kim, Haojin Liao, Samarth Mishra, Chandramouli Rajagopalan, Kate Saenko, Kuniaki Saito, Burhan Ul Tayyab, Piotr Teterwak, et al. Visda-2021 competition: Universal domain adaptation to improve performance on out-of-distribution data. In *NeurIPS 2021 Competitions and Demonstrations Track*, pp. 66–79, 2022.
- Vasudha Bhatnagar, Sharanjit Kaur, and Sharma Chakravarthy. Clustering data streams using grid-based synopsis. *Knowledge and Information Systems*, 41(1):127–152, 2014.
- Dian Chen, Dequan Wang, Trevor Darrell, and Sayna Ebrahimi. Contrastive test-time adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 295–305, 2022a.
- Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, pp. 1597–1607, 2020.
- Xiangning Chen, Cho-Jui Hsieh, and Boqing Gong. When vision transformers outperform resnets without pre-training or strong data augmentations. In *International Conference on Learning Representations*, 2022b.
- Sungha Choi, Seunghan Yang, Seokeon Choi, and Sunrack Yun. Improving test-time adaptation via shift-agnostic weight regularization and nearest source prototypes. In *European Conference on Computer Vision*, 2022.

- Yunjey Choi, Minje Choi, Munyoung Kim, Jung-Woo Ha, Sunghun Kim, and Jaegul Choo. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 8789–8797, 2018.
- Sayak Ray Chowdhury and Aditya Gopalan. On kernelized multi-armed bandits. In *International Conference on Machine Learning*, pp. 844–853, 2017.
- Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, 2009.
- Prafulla Dhariwal and Alexander Nichol. Diffusion models beat gans on image synthesis. In *Advances in Neural Information Processing Systems*, pp. 8780–8794, 2021.
- Qi Dou, Daniel Coelho de Castro, Konstantinos Kamnitsas, and Ben Glocker. Domain generalization via model-agnostic learning of semantic features. In *Advances in Neural Information Processing Systems*, pp. 6447–6458, 2019.
- Jiawei Du, Hanshu Yan, Jiashi Feng, Joey Tianyi Zhou, Liangli Zhen, Rick Siow Mong Goh, and Vincent Tan. Efficient sharpness-aware minimization for improved training of neural networks. In *International Conference on Learning Representations*, 2022.
- Pierre Foret, Ariel Kleiner, Hossein Mobahi, and Behnam Neyshabur. Sharpness-aware minimization for efficiently improving generalization. In *International Conference on Learning Representations*, 2021.
- Jin Gao, Jialing Zhang, Xihui Liu, Evan Shelhamer, Trevor Darrell, and Dequan Wang. Back to the source: Diffusion-driven test-time adaptation. In *ICML Workshop on Updatable Machine Learning*, 2022.
- Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations. In *International Conference on Learning Representations*, 2018.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations*, 2019.
- Dan Hendrycks, Norman Mu, Ekin D Cubuk, Barret Zoph, Justin Gilmer, and Balaji Lakshminarayanan. Augmix: A simple data processing method to improve robustness and uncertainty. In *International Conference on Learning Representations*, 2020.
- Dan Hendrycks, Steven Basart, Norman Mu, Saurav Kadavath, Frank Wang, Evan Dorundo, Rahul Desai, Tyler Zhu, Samyak Parajuli, Mike Guo, et al. The many faces of robustness: A critical analysis of out-of-distribution generalization. In *IEEE International Conference on Computer Vision*, pp. 8320–8329, 2021.
- Sepp Hochreiter and Jürgen Schmidhuber. Flat minima. *Neural computation*, 9(1):1–42, 1997.
- Steven CH Hoi, Doyen Sahoo, Jing Lu, and Peilin Zhao. Online learning: A comprehensive survey. *Neurocomputing*, 459:249–289, 2021.
- Junyuan Hong, Lingjuan Lyu, Jiayu Zhou, and Michael Spranger. MECTA: Memory-economic continual test-time model adaptation. In *International Conference on Learning Representations*, 2023.
- Xuefeng Hu, Gokhan Uzunbas, Sirius Chen, Rui Wang, Ashish Shah, Ram Nevatia, and Ser-Nam Lim. Mixnorm: Test-time adaptation through online normalization estimation. *arXiv preprint arXiv:2110.11478*, 2021.
- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning*, pp. 448–456, 2015.

- Yusuke Iwasawa and Yutaka Matsuo. Test-time classifier adjustment module for model-agnostic domain generalization. In *Advances in Neural Information Processing Systems*, pp. 2427–2440, 2021.
- Ansh Khurana, Sujoy Paul, Piyush Rai, Soma Biswas, and Gaurav Aggarwal. SITA: single image test-time adaptation. *arXiv preprint arXiv:2112.02355*, 2021.
- Pang Wei Koh, Shiori Sagawa, Henrik Marklund, Sang Michael Xie, Marvin Zhang, Akshay Bal-subramani, Weihua Hu, Michihiro Yasunaga, Richard Lanus Phillips, Irena Gao, et al. WILDS: A benchmark of in-the-wild distribution shifts. In *International Conference on Machine Learning*, pp. 5637–5664, 2021.
- Jogendra Nath Kundu, Naveen Venkat, R Venkatesh Babu, et al. Universal source-free domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4544–4553, 2020.
- Jungmin Kwon, Jeongseop Kim, Hyunseo Park, and In Kwon Choi. ASAM: adaptive sharpness-aware minimization for scale-invariant learning of deep neural networks. In *International Conference on Machine Learning*, pp. 5905–5914, 2021.
- Boyi Li, Felix Wu, Ser-Nam Lim, Serge Belongie, and Kilian Q Weinberger. On feature normalization and data augmentation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 12383–12392, 2021.
- Da Li, Yongxin Yang, Yi-Zhe Song, and Timothy Hospedales. Learning to generalize: Meta-learning for domain generalization. In *AAAI Conference on Artificial Intelligence*, pp. 3490–3497, 2018a.
- Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems*, pp. 6391–6401, 2018b.
- Rui Li, Qianfen Jiao, Wenming Cao, Hau-San Wong, and Si Wu. Model adaptation: Unsupervised domain adaptation without source data. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 9638–9647, 2020.
- Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation. In *International Conference on Machine Learning*, pp. 6028–6039, 2020.
- Hyesu Lim, Byeongeun Kim, Jaegul Choo, and Sungha Choi. TTN: A domain-shift aware batch normalization in test-time adaptation. In *International Conference on Learning Representations*, 2023.
- Sungbin Lim, Ildoo Kim, Taesup Kim, Chiheon Kim, and Sungwoong Kim. Fast autoaugment. In *Advances in Neural Information Processing Systems*, pp. 6665–6675, 2019.
- Hongbin Lin, Yifan Zhang, Zhen Qiu, Shuaicheng Niu, Chuang Gan, Yanxia Liu, and Mingkui Tan. Prototype-guided continual adaptation for class-incremental unsupervised domain adaptation. In *European Conference on Computer Vision*, pp. 351–368, 2022.
- Yuejiang Liu, Parth Kothari, Bastien van Delft, Baptiste Bellot-Gurlet, Taylor Mordan, and Alexandre Alahi. TTT++: when does self-supervised test-time training fail or thrive? In *Advances in Neural Information Processing Systems*, volume 34, pp. 21808–21820, 2021.
- Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A convnet for the 2020s. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 11976–11986, 2022.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2018.
- Chaithanya Kumar Mummadi, Robin Huttmacher, Kilian Rambach, Evgeny Levinkov, Thomas Brox, and Jan Hendrik Metzen. Test-time adaptation to distribution shift by confidence maximization and input transformation. *arXiv preprint arXiv:2106.14999*, 2021.

- Zachary Nado, Shreyas Padhy, D Sculley, Alexander D’Amour, Balaji Lakshminarayanan, and Jasper Snoek. Evaluating prediction-time batch normalization for robustness under covariate shift. *arXiv preprint arXiv:2006.10963*, 2020.
- Shuaicheng Niu, Jiayang Wu, Yifan Zhang, Yaofo Chen, Shijian Zheng, Peilin Zhao, and Mingkui Tan. Efficient test-time model adaptation without forgetting. In *International Conference on Machine Learning*, pp. 16888–16905, 2022a.
- Shuaicheng Niu, Jiayang Wu, Yifan Zhang, Guanghui Xu, Haokun Li, Junzhou Huang, Yaowei Wang, and Mingkui Tan. Boost test-time performance with closed-loop inference. *arXiv preprint arXiv:2203.10853*, 2022b.
- A Emin Orhan. Robustness properties of facebook’s resnext WSL models. *arXiv preprint arXiv:1907.07640*, 2019.
- Zhongyi Pei, Zhangjie Cao, Mingsheng Long, and Jianmin Wang. Multi-adversarial domain adaptation. In *AAAI Conference on Artificial Intelligence*, pp. 3934–3941, 2018.
- Zhen Qiu, Yifan Zhang, Hongbin Lin, Shuaicheng Niu, Yanxia Liu, Qing Du, and Mingkui Tan. Source-free domain adaptation via avatar prototype generation and adaptation. In *International Joint Conference on Artificial Intelligence*, pp. 2921–2927, 2021.
- Alexander Rakhlin, Karthik Sridharan, and Ambuj Tewari. Online learning: Random averages, combinatorial parameters, and learnability. In *Advances in Neural Information Processing Systems*, pp. 1984–1992, 2010.
- Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. Do cifar-10 classifiers generalize to cifar-10? *arXiv preprint arXiv:1806.00451*, 2018.
- Mengye Ren, Tyler R Scott, Michael L Iuzzolino, Michael C Mozer, and Richard Zemel. Online unsupervised learning of visual representations and categories. *arXiv preprint arXiv:2109.05675*, 2021.
- Kuniaki Saito, Kohei Watanabe, Yoshitaka Ushiku, and Tatsuya Harada. Maximum classifier discrepancy for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3723–3732, 2018.
- Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Improving robustness against common corruptions by covariate shift adaptation. In *Advances in Neural Information Processing Systems*, volume 33, pp. 11539–11551, 2020.
- Shai Shalev-Shwartz et al. Online learning and online convex optimization. *Foundations and Trends® in Machine Learning*, 4(2):107–194, 2012.
- Shiv Shankar, Vihari Piratla, Soumen Chakrabarti, Siddhartha Chaudhuri, Preethi Jyothi, and Sunita Sarawagi. Generalizing across domains via cross-gradient training. In *International Conference on Learning Representations*, 2018.
- Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *International Conference on Machine Learning*, pp. 9229–9248, 2020.
- Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *International Conference on Learning Representations*, 2021.
- Qin Wang, Olga Fink, Luc Van Gool, and Dengxin Dai. Continual test-time domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 7201–7211, 2022.
- Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 7794–7803, 2018.
- Ross Wightman. Pytorch image models. <https://github.com/rwightman/pytorch-image-models>, 2019.

- Yuxin Wu and Kaiming He. Group normalization. In *European Conference on Computer Vision*, pp. 3–19, 2018.
- Yuxin Wu and Justin Johnson. Rethinking ”batch” in batchnorm. *arXiv preprint arXiv:2105.07576*, 2021.
- Huaxiu Yao, Yu Wang, Sai Li, Linjun Zhang, Weixin Liang, James Zou, and Chelsea Finn. Improving out-of-distribution robustness via selective augmentation. In *International Conference on Machine Learning*, pp. 25407–25437, 2022.
- Chen Zhang and Steven CH Hoi. Partially observable multi-sensor sequential change detection: A combinatorial multi-armed bandit approach. In *AAAI Conference on Artificial Intelligence*, pp. 5733–5740, 2019.
- Marvin Zhang, Sergey Levine, and Chelsea Finn. Memo: Test time robustness via adaptation and augmentation. In *Advances in Neural Information Processing Systems*, 2022.
- Yifan Zhang, Peilin Zhao, Shuaicheng Niu, Qingyao Wu, Jiezhong Cao, Junzhou Huang, and Mingkui Tan. Online adaptive asymmetric active learning with limited budgets. *IEEE Transactions on Knowledge and Data Engineering*, 33(6):2680–2692, 2019.
- Yifan Zhang, Shuaicheng Niu, Zhen Qiu, Ying Wei, Peilin Zhao, Jianhua Yao, Junzhou Huang, Qingyao Wu, and Mingkui Tan. COVID-DA: Deep domain adaptation from typical pneumonia to covid-19. *arXiv preprint arXiv:2005.01577*, 2020a.
- Yifan Zhang, Ying Wei, Qingyao Wu, Peilin Zhao, Shuaicheng Niu, Junzhou Huang, and Mingkui Tan. Collaborative unsupervised domain adaptation for medical image diagnosis. *IEEE Transactions on Image Processing*, 29:7834–7844, 2020b.
- Bowen Zhao, Chen Chen, and Shu-Tao Xia. DELTA: Degradation-free fully test-time adaptation. In *International Conference on Learning Representations*, 2023.
- Peilin Zhao and Steven CH Hoi. Cost-sensitive online active learning with application to malicious URL detection. In *Proceedings of ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 919–927, 2013.
- Peilin Zhao, Steven CH Hoi, and Rong Jin. Double updating online learning. *Journal of Machine Learning Research*, 12:1587, 2011.
- Yaowei Zheng, Richong Zhang, and Yongyi Mao. Regularizing neural networks via adversarial model perturbation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 8156–8165, 2021.

附录

目录

A 相关工作 16

B SAR 伪代码 18

C 更多实现细节 19	C.1 数据集更多细节	19	C.2 更多实验协议	
.....		19		

D 严重度等级 3 的 ImageNet-C 附加结果	22
D.1 在线不平衡标签偏移下与最先进方法的比较	
D.2 批大小为 1 时与最先进方法的比较	22

E ImageNet-R 和 VisDA-2021 的附加结果 23

F 附加消融结果 24	F.1 SAR 中组件的影响	24	F.2 SAR 学习的损失曲面可视化	25
	F.3			

的敏感性 ρ 在合成孔径雷达中	25
----------------------------	----

G 补充讨论 26	G.1 关于模型崩溃的更多讨论	26	G.2 混合领域偏移下批归一化模型中大批大小的影响	26
	G.3 Tent 与 ConvNeXt-LN 的性能			
	G.4 Tent 与 EATA 的模型恢复方案有效性	26		

A 相关工作

本文将所提出的 SAR 与现有的无目标数据和有目标数据的自适应方法、锐度感知优化、在线学习方法以及 EATA (Niu 等人, 2022a) 进行关联。

无目标数据的自适应。在训练阶段克服分布偏移的问题已在大量工作中得到研究, 包括领域泛化 (Shankar 等人, 2018; Li 等人, 2018a; Dou 等人, 2019)、扩大训练数据集规模 (Orhan, 2019)、各种数据增强技术 (Lim 等人, 2019; Hendrycks 等人, 2020; Li 等人, 2021; Hendrycks 等人, 2021; Yao 等人, 2022) 等, 仅举几例。这些方法旨在训练阶段预先预测或模拟测试数据可能出现的偏移, 从而使训练分布能够覆盖测试数据可能的偏移。然而, 在训练阶段预先预测所有可能的测试偏移可能不可行, 且这些训练策略通常计算开销更大。与在训练阶段提升泛化能力不同, 本文通过直接从测试数据中学习来克服测试偏移。

有目标数据的自适应。我们将利用目标数据的相关方法讨论分为: 1) 无监督领域自适应 (离线自适应) 和 2) 测试时自适应 (在线自适应)。

• **无监督领域自适应 (UDA)。**传统无监督领域自适应联合优化带标签的源数据和未标记的目标数据, 以缓解分布偏移, 例如设计域判别器在特征层面对齐源域和目标域 (Pei 等, 2018; Saito 等, 2018; Zhang 等, 2020b; a), 以及通过对比学习方式对齐源域和目标域的原型 (Lin 等, 2022)。最近, 无源数据的无监督领域自适应方法被提出, 以解决源数据缺失时的自适应问题, 例如基于生成的方法从模型中生成源图像或原型 (Li 等, 2020; Kundu 等, 2020; Qiu 等, 2021), 以及信息最大化方法 (Liang 等, 2020)。这些方法在整个测试集上自适应模型, 其中自适应是离线的, 通常需要多个训练轮次, 因此难以部署在在线测试场景中。

• **测试时自适应 (TTA)。**根据是否改变训练过程, 测试时自适应方法主要可分为两类。i) 测试时训练 (Test-Time Training, TTT) (Sun 等, 2020) 联合优化源模型, 同时使用监督损失和自监督损失, 然后在测试时进行自监督学习。自监督损失可以是 TTT 中的旋转预测 (Gidaris 等, 2018), 或 TTT++ (Liu 等, 2021) 和 MT3 (Bartler 等, 2022) 中的对比目标等。ii) 完全测试时自适应 (Fully Test-Time Adaptation) (Wang 等, 2021; Niu 等, 2022a; Hong 等, 2023) 不改变训练过程, 可应用于任何预训练模型, 包括调整批归一化层中的统计量 (Schneider 等, 2020; Hu 等, 2021; Khurana 等, 2021; Lim 等, 2023; Zhao 等, 2023)、无监督熵最小化 (Wang 等, 2021; Niu 等, 2022a; Zhang 等, 2022)、预测一致性最大化 (Zhang 等, 2022; Wang 等, 2022; Chen 等, 2022a)、top- k 分类提升 (Niu 等, 2022b) 等。尽管这些先前的测试时自适应方法在处理测试分布偏移时有效, 但研究表明它们在线自适应过程中不稳定, 并且对测试数据不足 (小批大小)、来自混合域、标签分布不平衡和在线偏移等情况敏感 (见图 1)。这里值得注意的是, 像 MEMO (Zhang 等, 2022) 和 DDA (Gao 等, 2022) 这样的方法在上述三种场景下不受影响, 因为 MEMO 在每个样本自适应后重置模型参数, 而 DDA 通过扩散进行输入自适应 (测试期间模型权重被冻结)。然而, 这些方法无法利用从先前样本中学到的知识, 因此性能提升有限。此外, MEMO 和 DDA 中的大量数据增强和扩散在测试时计算开销大且效率低 (见表 6)。在这项工作中, 我们分析了在线测试时自适应在上述实际测试设置下可能失败的原因, 并提出了相应的解决方案, 使测试时自适应在各种实际测试设置下保持稳定。

锐度感知最小化 (Sharpness-aware Minimization, SAM)。SAM (Foret 等人, 2021) 同时优化监督目标 (如交叉熵) 和损失曲面的锐度, 旨在找到具有良好泛化能力的平坦最小值 (Hochreiter & Schmidhuber, 1997)。SAM 及其变体 (Kwon 等人, 2021; Zheng 等人, 2021; Du 等人, 2022; Chen 等人, 2022b) 在多个深度学习基准上表现出色。在本工作中, 分析测试时熵最小化失败原因时, 我们发现一些产生大范数梯度的噪声样本会损害自适应过程, 从而导致模型崩溃。为缓解这一问题, 本文提出最小化

测试时熵损失曲面的锐度，使在线模型更新对噪声或大梯度具有鲁棒性。

在线学习 (Online Learning, OL)。OL (Hoi 等人, 2021; Chowdhury & Gopalan, 2017; Zhao 等人, 2011) 一次一个地按顺序从数据样本序列中进行模型学习，这在许多实际应用（如社交网络推荐）中很常见。根据监督类型，OL 可分为三类：i) 监督方法 (Rakhlin 等人, 2010; Shalev-Shwartz 等人, 2012) 在每次在线学习迭代结束时获得监督；ii) 半监督方法 (Zhang & Hoi, 2019) 仅从部分样本获得监督，例如在线主动学习 (Zhao & Hoi, 2013; Zhang 等人, 2019) 选择信息量大的样本来查询真实标签以更新模型；iii) 无监督方法 (Bhatnagar 等人, 2014) 在整个在线学习过程中无法获得任何监督。从这个意义上说，测试时自适应 (TTA) (Sun 等人, 2020; Wang 等人, 2021) 仅使用无标签测试数据在线更新模型，因此属于第三类。然而，与主要旨在学习表示或聚类的无监督 OL (Ren 等人, 2021) 不同，TTA 旨在提升任何预训练模型在分布外测试样本上的性能。

与 EATA 的比较 (牛等人 (Niu et al., 2022a))。尽管 EATA 和我们的 SAR 都包含通过熵移除样本的步骤，但两者在此步骤背后的动机不同。EATA 旨在通过样本熵选择来提高适应效率。在我们的 SAR 中，我们发现一些具有大范数的噪声梯度可能会损害适应，从而在非平稳测试环境下导致模型崩溃。为了移除这些梯度，我们利用了一种替代度量（即熵），这有助于移除部分具有大范数的噪声梯度。然而，这对于实现稳定的测试时适应 (TTA) 仍然不够（见表 5 中的消融结果）。因此，我们进一步引入了锐度感知优化和模型恢复方案。凭借这三种策略，我们的 SAR 在非平稳测试环境下表现稳定。

B SAR 的伪代码

在本附录中，我们提供了 SAR 方法的伪代码。从算法 1 中，对于每个测试样本 $\mathbf{x}_i$ ，我们首先对其应用可靠样本过滤方案（参见第 3-6 行），以确定是否将其用于更新模型。如果 $\mathbf{x}_i$ 是可靠的，我们将通过 $\mathbf{x}_j$ 的锐度感知熵损失来优化模型（参见第 7-10 行）。具体来说，我们首先基于梯度 $\nabla_{\tilde{\Theta}} E(\mathbf{x}_i; \Theta)$ ，计算最优权重扰动 $\hat{\epsilon}(\tilde{\Theta})$ ，然后使用近似梯度 $\mathbf{g} = \nabla_{\tilde{\Theta}} E(\mathbf{x}_j; \Theta)|_{\Theta+\hat{\epsilon}(\tilde{\Theta})}$ 更新模型。最后，我们利用恢复方案使模型即使在少数极端困难的情况下也能良好工作（参见第 11-13 行）。具体来说，当熵损失的移动平均值 e_m 小于 e_0 （表明模型发生崩溃）时，我们将模型参数 $\tilde{\Theta}$ 恢复到其原始/初始值。

Algorithm 1: Sharpness-Aware and Reliable Test-Time Entropy Minimization (SAR)

Input: Test samples $\mathcal{D}_{test} = \{\mathbf{x}_j\}_{j=1}^M$, model $f_{\Theta}(\cdot)$ with trainable parameters $\tilde{\Theta} \subset \Theta$, step size $\eta > 0$, neighborhood size $\rho > 0$, $E_0 > 0$ in Eqn. (2), $e_0 > 0$ for model recovery.

Output: Predictions $\{\hat{y}_j\}_{j=1}^M$.

```

1 Initialize  $\tilde{\Theta}_0 = \tilde{\Theta}$ , moving average of entropy  $e_m = 0$ ;
2 for  $\mathbf{x}_j \in \mathcal{D}_{test}$  do
3   Compute entropy  $E_j = E(\mathbf{x}_j; \Theta)$  and predict  $\hat{y}_j = f_{\Theta}(\mathbf{x}_j)$ ;
4   if  $E_j > E_0$  then
5     continue; // reliable entropy minimization (Eqn. 2)
6   end
7   Compute gradient  $\nabla_{\tilde{\Theta}} E(\mathbf{x}_j; \Theta)$ ;
8   Compute  $\hat{\epsilon}(\tilde{\Theta})$  per Eqn. (4);
9   Compute gradient approximation:  $\mathbf{g} = \nabla_{\tilde{\Theta}} E(\mathbf{x}_j; \Theta)|_{\Theta+\hat{\epsilon}(\tilde{\Theta})}$ ;
10  Update  $\tilde{\Theta} \leftarrow \tilde{\Theta} - \eta \mathbf{g}$ ; // sharpness-aware minimization (Eqn. 3)
11   $e_m = 0.9 \times e_m + 0.1 \times E(\mathbf{x}_j; \Theta + \hat{\epsilon}(\tilde{\Theta}))$  if  $e_m \neq 0$  else  $E(\mathbf{x}_j; \Theta + \hat{\epsilon}(\tilde{\Theta}))$ ; // moving average
12  if  $e_m < e_0$  then
13    Recover model weights:  $\tilde{\Theta} \leftarrow \tilde{\Theta}_0$ ; // model recovery
14  end
15 end
```

C 更多实现细节

C.1 数据集的更多细节

本文主要在一个大规模且广泛使用的基准上评估所有方法的分布外泛化能力，即 **ImageNet-C**¹ (Hendrycks & Dietterich, 2019)。**ImageNet-C** 通过对原始 ImageNet (Deng et al., 2009) 测试集进行损坏来构建。损坏 (如图 8 所示) 包含 15 种不同类型，即高斯噪声、散粒噪声、脉冲噪声、散焦模糊、玻璃模糊、运动模糊、缩放模糊、雪、霜、雾、亮度、对比度、弹性变换、像素化和 JPEG 压缩，其中每种损坏类型有 5 个不同的严重程度级别，严重程度级别越大表示分布偏移越严重。随后，我们进一步在 **ImageNet-R** (Hendrycks et al., 2021) 和 **VisDA-2021** (Bashkirova et al., 2022) 上进行实验，以验证我们方法的有效性。**ImageNet-R** 包含 30,000 张图像，涵盖 200 个 ImageNet 类别的各种艺术渲染，这些图像主要从 Flickr 收集，并由 Amazon MTurk 标注者筛选。**VisDA-2021** 从 ImageNet-O/R/C 和 ObjectNet (Barbu et al., 2019) 收集图像。**VisDA-2021** 中的域偏移包括艺术视觉风格、纹理、视角和损坏的变化。




图 8: ImageNet 损坏基准中不同损坏类型的可视化，取自 ImageNet-C 原始论文 (Hendrycks & Dietterich, 2019)。

C.2 更多实验协议

本文中用于测试时自适应的所有预训练模型均公开可用，包括从 torchvision 库获得的 ResNet50-BN²，以及从 timm 仓库 (Wightman, 2019) 获得的 ResNet-50-GN³、VitBase-LN⁴ 和 ConvNeXt-LN⁵。我们在表 6 中总结了所有涉及方法的详细特征，并在下文介绍其实现细节。

SAR (本文方法)。我们使用 SGD 作为更新规则，动量为 0.9，批大小为 64（批大小 = 1 的实验除外），ResNet/Vit 模型的学习率为 0.00025/0.001。批大小 = 1 的学习率设置为 ResNet 模型 (0.00025/16)，Vit 模型 (0.001/32)。公式 (2) 中的阈值 E_0 按照 EATA (Niu et al., 2022a) 设置为 $0.4 \times \ln 1000$ 。公式 (3) 中的 ρ 设置为 Foret et al. (2021) 中的默认值 0.05。对于模型恢复，我们记录

→ <https://zenodo.org/record/2235448#.YzQpq-xBxcA>²

<https://download.pytorch.org/models/resnet50-19c8e357.pth>³

[https://github.com/rwightman/pytorch-image-models/releases/download/](https://github.com/rwightman/pytorch-image-models/releases/download/v0.1-rsb-weights/resnet50_gn_a1h2-8fe6c4d0.pth)

[v0.1-rsb-weights/resnet50_gn_a1h2-8fe6c4d0.pth](https://github.com/rwightman/pytorch-image-models/releases/download/v0.1-rsb-weights/resnet50_gn_a1h2-8fe6c4d0.pth)

https://storage.googleapis.com/vit_models/augreg/B_16-i21k-300ep-lr_0.001-aug_medium1-wd_0.1-do_0.0-sd_0.0--imagenet2012-steps_20k-lr_0.01-res_224.npz

⁵https://dl.fbaipublicfiles.com/convnext/convnext_base_1k_224_ema.pth

表 6: 最先进方法的特性。我们使用 ResNet-50 (组归一化) 在 ImageNet-C (高斯噪声, 严重程度 5 级) 上评估不同方法的效率, 该数据集共包含 50,000 张图像。实际运行时间在单个 V100 GPU 上测试。DDA (Gao 等人, 2022) 预先训练一个额外的扩散模型, 然后在测试时执行输入自适应/扩散。

Method	Need source data?	Online update?	#Forward	#Backward	Other computation	GPU time (50,000 images)
MEMO (Zhang et al., 2022)	✗	✗	50,000×65	50,000×64	AugMix (Hendrycks et al., 2020)	55,980 seconds
DDA (Gao et al., 2022)	✓	✗	50,000×2	0	50,000 diffusion	146,220 seconds
TTT (Sun et al., 2020)	✓	✓	50,000×21	50,000×20	rotation augmentation	3,600 seconds
Tent (Wang et al., 2021)	✗	✓	50,000	50,000	n/a	110 seconds
EATA (Niu et al., 2022a)	✓	✓	50,000	26,196	regularizer	114 seconds
SAR (ours)	✗	✓	50,000 + 12,710	12,710×2	Eqn. (4)	115 seconds

熵损失值采用移动平均因子 0.9 计算 e_m , 重置阈值 e_0 设为 0.2。对于可学习参数, 我们遵循 Tent (Wang 等人, 2021) 仅更新归一化层中的仿射参数。然而, 由于顶层/深层比浅层对原始模型更敏感且更重要 (Mummadhi 等人, 2021; Choi 等人, 2022), 我们冻结顶层, 并更新剩余浅层中层归一化或组归一化的仿射参数。具体而言, 对于具有 4 个层组 (layer1、2、3、4) 的 ResNet50-GN, 我们冻结 layer4。对于具有 11 个块组 (blocks1-11) 的 ViTBase-LN, 我们冻结 blocks9、blocks10、blocks11。

TTT⁶ (Sun 等人, 2020)。为了公平比较, 我们力求基于相同的模型权重比较所有方法。然而, TTT 改变了模型训练过程, 并要求模型包含用于测试时训练的自监督旋转预测分支。因此, 我们修改 TTT, 使其可应用于任何预训练模型。具体而言, 给定一个预训练模型, 我们在中间层 (ResNet-50-GN 的第 2 层组和 ViTBase-LN 的第 6 块组) 的末端添加一个新分支 (随机初始化), 用于旋转预测任务。我们首先冻结预训练模型的所有原始参数, 并在原始 ImageNet 训练集上训练新添加的分支 10 个训练轮次。这里, 我们应用 SGD 优化器, 动量为 0.9, ResNet50-GN/ViTBase-LN 的初始学习率为 0.1/0.005, 并在第 4 和第 7 个训练轮次以 0.1 的衰减因子降低学习率。然后, 我们将新获得的模型 (具有两个分支) 作为基础模型进行测试时训练。在测试时训练阶段, 我们使用 SGD 作为更新规则, ResNet0-GN 的学习率为 0.001 (遵循 TTT), ViTBase-LN 的学习率为 0.0001, 数据增强大小设为 20 (遵循 Niu 等人 (2022a))。

Tent⁷ (Wang 等人, 2021)。我们遵循 Tent 中设定的所有超参数, 除非其未提供。具体而言, 我们使用 SGD 作为更新规则, 动量为 0.9, 批大小为 64 (除了批大小 = 1 的实验以及小测试批大小的影响实验 (见第 4 节)), ResNet/Vit 模型的学习率为 0.00025/0.001。批大小 = 1 的学习率对于 ResNet 模型设为 (0.00025/32), 对于 Vit 模型设为 (0.001/64)。可训练参数为批归一化层的所有仿射参数。

EATA⁸ (Niu 等人, 2022a)。我们遵循 EATA 中设定的所有超参数, 除非其未提供。具体而言, 熵常数 E_0 (用于可靠样本识别) 设为 $0.1 \times \ln 1000$ 。用于冗余样本识别的 ϵ 设为 0.05。熵损失与正则化损失的权衡参数 β 设为 2,000。用于 Fisher 重要性计算的预收集分布内测试样本数量为 2,000。更新规则为 SGD, 动量为 0.9, 批大小为 64 (除了批大小 = 1 的实验以及小测试批大小的影响实验 (见第 4 节)), ResNet/Vit 模型的学习率为 0.00025/0.001。批大小 = 1 的学习率对于 ResNet 模型设为 (0.00025/32), 对于 Vit 模型设为 (0.001/64)。可训练参数为批归一化层的所有仿射参数。

MEMO⁹ (Zhang 等人, 2022)。我们遵循 MEMO 中设定的所有超参数。具体而言, 我们使用 AugMix (Hendrycks 等人, 2020) 作为数据增强集合, 增强大小设为 64。对于 Vit 模型, 优化器为 AdamW (Loshchilov & Hutter, 2018), 学习

⁶https://github.com/yueatsprograms/ttt_imagenet_release

⁷<https://github.com/DequanWang/tent>

⁸<https://github.com/mr-eggplant/EATA>

⁹<https://github.com/zhangmarvin/memo>

率为 0.00001，权重衰减为 0.01。对于 ResNet 模型，优化器为 SGD，学习率为 0.00025，无权重衰减。可训练参数为整个模型。

DDA¹⁰ (Gao 等人, 2022)。我们根据其官方 GitHub 仓库复现 DDA，并使用默认超参数。

第 4 节实验的更多细节 4：测试时自适应中归一化层的影响。在第 4 节中，我们研究了 TTT 和 Tent 在 { 小测试批大小、混合分布偏移、在线不平衡标签分布偏移 } 下，使用不同归一化层模型的效果。对于每个实验，我们只考虑上述三种测试设置中的一种。具体而言，对于批大小影响的实验（第 4 节（1）），我们只调整批大小，测试集不包含多种类型的分布偏移，且其标签分布始终是均匀的。对于混合域偏移的实验（第 4 节（2）），测试样本来自 15 种损坏类型的混合，而 Tent 的批大小为 64，TTT 的批大小为 1，测试数据的标签分布始终是均匀的。对于在线标签偏移的实验（第 4 节（3）），测试数据的标签分布在线偏移且不平衡，而 Tent 的批大小为 64，TTT 的批大小为 1，测试数据仅包含一种损坏类型。此外，值得注意的是，我们根据批大小重新调整了熵最小化（Tent）的学习率，因为熵最小化对学习率敏感，固定学习率通常效果不佳。具体而言，对于 ResNet 模型，学习率重新调整为 $(0.00025/32) \times BS$ IF $BS < 32$ ELSE 0.00025，对于 Vit 模型，学习率重新调整为 $(0.001/64) \times BS$ 。与 Tent 相比，单样本自适应方法 TTT 对学习率不太敏感，因此我们对各种批大小设置相同的学习率。我们还在表 7 中提供了 TTT 在不同批大小下使用动态重新调整学习率的结果。

表 7: TTT (Sun 等人, 2020 年) 在不同模型（不同归一化层）下的批大小（BS）影响。学习率通过 $0.001 \times BS$ 动态重新调整。我们报告了在 ImageNet-C 上使用高斯噪声和严重级别 5 的准确率（%）。

Model	BS=1	BS=2	BS=4	BS=8	BS=16
ResNet50-BN	21.2	23.4	23.4	24.7	24.6
ResNet50-GN	40.9	40.5	40.8	41.1	40.7

¹⁰<https://github.com/shiyegao/DDA>

D 严重级别 3 的 ImageNet-C 上的附加结果

D.1 在线不平衡标签偏移下与最先进方法的比较

我们在表 8 中提供了所有比较方法在在线不平衡标签分布偏移（不平衡比 $= \infty$ ）下的更多结果。结果与主论文（严重程度 5）一致，我们的 SAR 在 15 种不同损坏类型的平均值上表现最佳。值得注意的是，DDA 在噪声损坏下取得了有竞争力的结果，但在其他损坏类型上表现较差。原因是 DDA 中用于输入自适应的扩散模型是通过噪声扩散训练的，因此其扩散到其他损坏类型的泛化能力仍然有限。

表 8: 在在线不平衡标签分布偏移（不平衡比 $q_{max}/q_{min} = \infty$ ）下，ImageNet-C 严重程度 3 上与最先进方法的准确率（%）比较。“BN”/“GN”/“LN”分别是批归一化/组归一化/层归一化的缩写。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (BN)	27.7	25.2	25.1	37.8	16.7	37.8	35.3	35.2	32.1	46.7	69.5	46.2	55.4	46.2	59.4	39.8
• MEMO	37.6	34.5	36.7	41.4	23.4	44.4	40.9	44.6	37.3	52.4	70.5	56.3	58.7	55.2	60.9	46.3
• DDA	49.9	50.0	49.2	33.2	31.9	38.0	36.7	35.1	34.1	35.01	64.9	33.7	59.3	53.9	59.0	44.3
• Tent	3.4	3.2	3.2	2.3	2.0	2.4	3.4	2.4	2.4	4.6	5.4	3.0	4.8	4.6	4.5	3.4
• EATA	1.3	0.9	1.1	0.6	0.6	1.2	1.4	1.3	1.3	1.9	4.1	1.6	2.7	2.4	3.1	1.7
ResNet50 (GN)	54.5	52.9	53.1	44.4	21.2	49.8	39.3	54.9	54.1	55.8	75.3	69.7	59.6	59.7	66.4	54.1
• MEMO	55.9	54.3	54.1	40.1	23.1	49.5	41.4	54.8	54.1	57.6	75.7	70.2	60.2	61.5	66.7	54.6
• DDA	61.0	61.0	60.5	39.3	37.3	46.4	39.7	47.7	48.1	29.9	69.9	57.8	62.8	60.1	63.8	52.4
• Tent	59.1	58.6	58.3	39.0	27.9	54.7	41.1	51.3	41.4	62.0	75.2	70.1	62.3	63.7	66.4	55.4
• EATA	52.3	52.9	51.7	35.7	30.1	46.4	39.6	43.8	39.8	55.7	72.4	66.6	54.7	56.0	56.2	50.3
• SAR (ours)	60.8 $\pm$ 0.1	60.5 $\pm$ 0.3	60.2 $\pm$ 0.2	47.9 $\pm$ 0.5	36.7 $\pm$ 0.7	58.2 $\pm$ 0.2	49.7 $\pm$ 0.5	57.9 $\pm$ 0.3	53.6 $\pm$ 0.0	65.0 $\pm$ 0.1	76.4 $\pm$ 0.2	71.0 $\pm$ 0.0	67.0 $\pm$ 0.2	65.8 $\pm$ 0.1	67.6 $\pm$ 0.0	59.9 $\pm$ 0.1
VitBase (LN)	51.5	46.8	50.4	48.7	37.1	54.7	41.6	35.1	33.3	68.0	69.3	74.9	65.9	66.0	63.6	53.8
• MEMO	62.1	57.9	61.5	57.2	45.6	62.0	49.9	46.5	43.1	74.1	75.8	79.7	72.6	72.3	70.6	62.1
• DDA	59.7	58.2	59.4	43.5	43.3	50.5	41.0	34.3	34.4	55.4	65.0	64.2	64.1	63.8	62.9	53.3
• Tent	68.7	68.0	68.1	68.2	63.8	70.9	63.8	67.6	41.9	76.3	78.8	79.5	75.9	76.7	73.7	69.5
• EATA	65.3	62.6	63.6	63.0	57.1	66.3	59.3	64.5	61.0	73.3	76.9	75.9	74.2	74.8	73.1	67.4
• SAR (ours)	68.8 $\pm$ 0.1	68.2 $\pm$ 0.1	68.4 $\pm$ 0.2	68.3 $\pm$ 0.2	64.7 $\pm$ 0.0	71.0 $\pm$ 0.2	64.2 $\pm$ 0.3	68.1 $\pm$ 0.1	66.0 $\pm$ 0.1	76.4 $\pm$ 0.1	79.0 $\pm$ 0.1	79.6 $\pm$ 0.1	76.2 $\pm$ 0.3	77.1 $\pm$ 0.1	74.1 $\pm$ 0.2	71.3 $\pm$ 0.1

D.2 批大小为 1 时与最先进方法的比较

我们在表 9 中提供了所有比较方法在批大小=1 下的更多结果。结果与主论文（严重程度 5）一致，我们的 SAR 在 15 种不同损坏类型的平均值上表现最佳。

表 9: 在批大小 SIZE=1 下，ImageNet-C 严重程度 3 上与最先进方法的准确率（%）比较。“BN”/“GN”/“LN”分别是批归一化/组归一化/层归一化的缩写。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (BN)	27.6	25.0	25.1	38.0	16.9	37.7	35.2	35.2	32.1	46.6	69.6	46.0	55.6	46.2	59.3	39.7
• MEMO	37.5	34.3	36.6	41.2	23.3	44.2	41.0	44.5	37.4	52.3	70.5	56.0	58.7	55.0	60.8	46.2
• DDA	49.8	49.9	49.2	33.2	32.0	37.9	36.6	35.2	34.2	34.9	64.9	33.5	59.3	53.9	59.0	44.2
• Tent	0.1	0.2	0.2	0.2	0.1	0.1	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2
• EATA	0.2	0.2	0.1	0.2	0.1	0.2	0.2	0.1	0.2	0.2	0.2	0.2	0.2	0.2	0.2	0.2
ResNet50 (GN)	54.5	52.8	53.1	44.3	21.2	49.7	39.2	54.8	54.0	55.8	75.4	69.8	59.6	59.7	66.3	54.0
• MEMO	55.7	54.2	53.9	40.0	22.8	49.2	41.2	54.8	54.1	57.6	75.5	69.9	60.0	61.3	66.6	54.5
• DDA	61.0	60.9	60.4	39.2	37.2	46.4	39.7	47.7	48.0	29.8	70.0	58.0	62.7	60.2	63.8	52.3
• Tent	58.8	58.5	58.7	38.2	26.8	54.9	42.6	51.6	38.8	61.9	75.3	70.0	62.3	63.6	66.3	55.2
• EATA	59.2	58.7	58.8	45.7	32.6	55.5	45.9	56.4	52.7	63.6	75.9	71.1	64.7	64.5	67.8	58.2
• SAR (ours)	60.3 $\pm$ 0.1	59.6 $\pm$ 0.1	59.5 $\pm$ 0.1	46.6 $\pm$ 1.1	33.0 $\pm$ 0.5	57.5 $\pm$ 0.1	47.8 $\pm$ 0.1	57.8 $\pm$ 0.2	52.8 $\pm$ 0.1	65.1 $\pm$ 0.1	76.7 $\pm$ 0.1	71.4 $\pm$ 0.1	67.3 $\pm$ 0.2	66.0 $\pm$ 0.1	67.8 $\pm$ 0.0	59.3 $\pm$ 0.1
VitBase (LN)	51.6	46.9	50.5	48.7	37.2	54.7	41.6	35.1	33.5	67.8	69.3	74.8	65.8	66.0	63.7	53.8
• MEMO	61.9	57.7	61.4	57.0	45.4	61.8	49.8	46.6	43.1	73.9	75.7	79.6	72.6	72.1	70.5	61.9
• DDA	59.8	58.2	59.5	43.4	43.2	50.4	40.9	34.2	34.3	55.2	64.9	64.0	64.2	63.7	62.8	53.2
• Tent	67.1	66.2	66.3	66.3	60.9	69.1	61.4	65.2	60.4	75.2	78.1	78.8	74.9	75.8	72.4	69.2
• EATA	60.7	58.5	61.6	60.1	51.8	64.2	54.8	53.3	52.6	72.5	73.6	77.9	71.3	71.3	69.7	63.6
• SAR (ours)	68.5 $\pm$ 0.1	67.8 $\pm$ 0.1	68.0 $\pm$ 0.1	67.8 $\pm$ 0.2	63.1 $\pm$ 0.0	70.7 $\pm$ 0.1	63.5 $\pm$ 0.1	66.9 $\pm$ 0.2	62.8 $\pm$ 0.1	75.8 $\pm$ 0.5	77.7 $\pm$ 0.8	78.4 $\pm$ 0.4	74.7 $\pm$ 1.5	75.7 $\pm$ 0.5	72.7 $\pm$ 1.1	70.3 $\pm$ 0.3

E ImageNet-R 和 VisDA-2021 上的额外结果

我们进一步在 ImageNet-R 上进行了两种野生测试设置下的实验：在线不平衡标签分布偏移（表 10）和批大小=1（表 11）。总体结果与 ImageNet-C 上的一致：1) ResNet50-GN 和 VitBase-LN 比 ResNet50-BN 表现更稳定；2) 与 Tent 和 EATA 相比，SAR 在 ResNet50-GN 和 VitBase-LN 上取得了最佳性能。

表 10：在 ImageNet-R 上在线不平衡标签分布偏移的野生设置下的准确率 (%) 比较。

Method	ResNet50-BN	ResNet50-GN	VitBase-LN
No Adapt.	36.2	40.8	43.1
Tent	6.6	41.7	45.2
EATA	5.8	40.9	47.5
SAR (ours)	-	42.9	52.0

表 11：在 ImageNet-R 上，野生设置单样本自适应（批大小=1）下的准确率 (%) 比较。

Method	ResNet50-BN	ResNet50-GN	VitBase-LN
No Adapt.	36.2	40.8	43.1
Tent	0.6	42.2	40.5
EATA	0.6	42.3	52.5
SAR (ours)	-	43.9	53.1

我们还在 VisDA-2021 上将我们的方法与在线测试时自适应方法（Tent 和 EATA）进行了比较。表 12 中的结果与在 ImageNet-C 和 ImageNet-R 上的结果一致。具体而言，在在线不平衡标签偏移下，Tent 和 EATA 在 BN 模型（ResNet50-BN）上失败，而在 GN/LN 模型（ResNet50-GN/VitBase-LN）上表现稳定。此外，我们的 SAR 进一步提升了 Tent 和 EATA 在 ResNet50-GN/VitBase-LN 上的自适应性能。

表 12：在在线不平衡标签分布偏移和混合域偏移下，VisDA-2021 上的分类准确率 (%)。

Model	No adapt	Tent	EATA	SAR (ours)
ResNet50-BN	36.0	9.0	7.4	-
ResNet50-GN	43.7	42.8	40.9	44.1
VitBase-LN	44.3	49.1	49.0	52.0

F 附加消融结果

F.1 SAR 中组件的影响

我们通过绘制不同组件下我们方法的梯度范数变化，在图 9 中进一步消融了 SAR 中组件的影响。结果表明，可靠模块（公式 2）和锐度感知模块（公式 3）共同确保模型在整个在线自适应过程中梯度保持在正常范围内，这与我们在第 5.2 节中的先前结果一致。




图 9：在线测试时自适应过程中梯度范数的演变。结果基于 ViTBase、ImageNet-C、散粒噪声、严重程度 5、在线不平衡标签偏移（不平衡比率 = ∞ ）。“可靠”和“锐度感知”分别简称为公式 (2) 和公式 (3)。

我们还在“批大小 (BS)=1”（表 13）和“混合域偏移”（表 14）的野生测试设置下进行了更多消融实验。结果与表 5 中的结果基本一致。可靠熵和锐度感知优化共同作用以稳定在线测试时自适应。值得注意的是，仅在 BS=1 下的 ViTBase-LN 中，模型恢复方案被激活，并将平均准确率从 55.7% 提高到 56.4%。

表 13: SAR 中各组件的效果。我们报告了在 **BATCH SIZE=1** 设置下，ImageNet-C（严重程度 5 级）上的准确率（%）。“reliable”和“sharpness-aware (sa)”分别表示公式 (2) 和公式 (3)，“recover”表示模型恢复方案。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (GN)+Entropy	3.4	4.5	4.0	16.7	5.9	27.0	29.7	16.3	26.6	2.1	72.1	46.4	7.5	52.5	56.2	24.7
+ reliable	22.8	25.5	23.0	18.4	14.8	27.0	28.6	40.0	43.3	18.4	71.5	43.1	15.2	45.6	55.4	32.8
+ reliable+sa	23.8	26.4	24.0	18.6	15.4	28.3	30.5	44.8	44.8	26.7	72.4	44.5	12.2	46.9	65.1	34.4
+ reliable+sa+recover	23.8	26.4	23.9	18.5	15.4	28.3	30.6	44.6	44.9	24.7	72.4	44.4	12.3	47.0	56.1	34.2
ViTBase (LN)+Entropy	42.9	1.4	43.9	52.6	48.8	55.8	51.4	22.2	20.1	67.0	75.1	64.7	53.7	67.2	64.5	48.8
+ reliable	34.8	4.2	35.5	50.5	45.9	54.0	48.6	52.5	47.8	65.5	74.5	63.4	51.4	65.6	63.0	50.5
+ reliable+sa	40.4	37.3	41.2	53.6	50.6	57.3	53.0	58.7	40.9	68.8	75.9	65.7	57.9	69.0	66.0	55.7
+ reliable+sa+recover	40.4	37.3	41.2	53.6	50.6	57.3	53.0	58.7	50.7	68.8	75.4	65.7	57.9	69.0	66.0	56.4

表 14: SAR 中各组件的效果。我们报告了在混合分布偏移（即 ImageNet-C 中 15 种损坏类型、严重程度 5 级的混合）下的准确率（%）。“reliable”和“sharpness-aware (sa)”分别表示公式 (2) 和公式 (3)，“recover”表示模型恢复方案。

Model + Method	Accuracy (%)
ResNet50 (GN)+Entropy	33.5
+ reliable	38.1
+ reliable+sa	38.2
+ reliable+sa+recover	38.2
ResNet50 (GN)+Entropy	18.5
+ reliable	55.2
+ reliable+sa	57.2
+ reliable+sa+recover	57.2

F.2 SAR 学习到的损失曲面可视化

在正文图 7 中，我们可视化了 Tent 和我们的 SAR 在 VitBase-LN 上的损失曲面。在本节中，我们进一步提供 ResNet50-GN 的可视化。我们选择批次 120 处的检查点来绘制 Tent 的损失曲面，因为在该批次之后此模型开始崩溃。在这种情况下，损失（熵）难以降低，无法找到合适的最小值。对于我们的 SAR，用于绘图的模型权重是在整个测试集上自适应后获得的。通过比较图 10(a)-(b)，SAR 有助于稳定熵最小化过程并找到合适的最小值。




图 10: 损失（熵）曲面的可视化。模型在严重程度 5 级的高斯噪声 ImageNet-C 上学习。

F.3 SAR 对 ρ IN 的敏感性

在我们的在线测试时自适应中，锐度感知优化中的超参数 ρ （公式 (3) 中）并不难调整。遵循 Foret 等人 (2021) 的做法，我们在所有实验中设置 $\rho = 0.05$ ，它在不同模型架构（ResNet50-BN、ResNet50-GN、VitBase-LN）和不同数据集（ImageNet-C、ImageNet-R）上均表现良好。此外，我们在表 15 中对 ρ 进行了敏感性分析，结果表明 SAR 在 $[0.03, 0.1]$ 范围内均表现良好。

表 15: SAR 中 ρ 的敏感性。我们报告了在线不平衡标签分布偏移下 ImageNet-C（散粒噪声，严重程度 5 级）上的准确率（%），其中不平衡比率为 ∞ 。

Method	No adapt	Tent	SAR ($\rho=0.01$)	SAR ($\rho=0.03$)	SAR ($\rho=0.05$)	SAR ($\rho=0.07$)	SAR ($\rho=0.1$)
Accuracy (%)	6.7	1.4	40.3	47.7	47.6	47.2	47.2

G 补充讨论

G.1 关于模型崩溃的更多讨论

如第 3.1 节所述，在复杂测试场景下，通过熵在线优化的模型（Wang 等，2021；Niu 等，2022a）容易发生崩溃，即无论输入如何，将所有样本预测为单一类别。为缓解此问题，先前方法（Liang 等，2020；Mummadhi 等，2021）利用多样性正则化强制样本输出分布均匀。然而，该假设在测试时并不合理，例如当测试数据在一段时间内不平衡时（如图 1(c) 所示），且该方法依赖于一批样本（与图 1(b) 相反）。因此，该策略不适用于我们的问题。本文从优化角度解决测试时自适应的崩溃问题，使在线自适应过程保持稳定。

G.2 混合分布偏移下 BN 模型中使用大批量的影响

在第 3.1 节中，我们提到当仅存在一种分布偏移时，标准批量大小（例如 ImageNet 上的 64）效果良好。然而，当测试数据包含多种偏移时，该批量大小无法在批归一化层中准确计算均值和方差估计。在此，我们研究该设置下超大批量的影响。从表 16 可以看出，自适应性能随批量增大而提升，表明更大的批量有助于更准确地估计统计量。值得注意的是，当批量大小超过 1024 时，严重程度级别 3 的性能下降。这是因为我们为不同批量大小固定了学习率，在此情况下，BS=1024 可能导致模型更新不足。此外，尽管增大批量能够提升性能，但自适应性能仍低于分别对每种损坏类型进行自适应的平均准确率（即平均自适应）。这进一步强调了利用具有组归一化或层归一化层的模型进行测试时熵最小化的必要性。

表 16: 在 ImageNet-C 上混合 15 种不同损坏类型下，Tent（Wang 等，2021）使用 ResNet-50-BN 时大批量大小（BS）的影响。报告准确率（%）。

Severity	Base	avg. adapt		mix adapt					
		BS=64	BS=32	BS=64	BS=128	BS=256	BS=512	BS=1,024	
Level = 5	18.0	42.6	0.9	2.3	4.0	8.3	12.4	16.4	
Level = 3	39.8	59.0	20.1	40.7	46.7	49.1	49.0	47.8	

G.3 Tent 在 ConvNeXt-LN 上的性能

对于主流神经网络模型，归一化层通常与网络架构耦合。具体而言，组归一化（Group Norm，GN）和批归一化（Batch Norm，BN）常与常规网络结合，而层归一化（Layer Norm，LN）更适合变换器（Transformer）网络。因此，我们在第 4 节通过 VitBase-LN 研究测试时自适应（TTA）中的层归一化效应。在此，我们进行更多实验，比较在线熵最小化（Wang 等，2021）在 ResNet50-BN 和 ConvNeXt-LN（Liu 等，2022）上的性能。ConvNeXt 是一种配备 LN 的卷积网络。作者对 ResNet 进行了重大修改，使这种基于 LN 的卷积网络表现良好，例如修改架构（ResNet 块改为 ConvNeXt 块、激活函数等）、各种训练策略（随机深度、随机擦除、指数移动平均等）。从表 17 可以看出，Tent+ConvNeXt-LN 比 Tent+ResNet50-BN 表现更稳定，但仍存在若干失败案例。这些结果与 ResNet50-BN 对比 VitBase-LN 的结果一致。

G.4 模型恢复方案与 Tent 和 EATA 结合的有效性

在本小节中，我们将模型恢复方案应用于 Tent（Wang 等，2021）和 EATA（Niu 等，2022a）。从表 18 可以看出，模型恢复确实对 Tent 有很大帮助（例如，在 ResNet50-GN 上平均准确率从 22.0% 提高到 26.1%），而在 EATA 上的性能提升则较为有限。与 Tent+恢复和 EATA+恢复相比，我们的 SAR 显著提升了自适应性能。

表 17: Tent 在 ResNet50-BN 和 ConvNeXt-LN 上的结果。我们报告在在线不平衡标签分布偏移下 ImageNet-C 上的准确率（%），不平衡比为 ∞ 。

Severity level 5	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50-BN	2.2	2.9	1.8	17.8	9.8	14.5	22.5	16.8	23.4	24.6	59.0	5.5	17.1	20.7	31.6	18.0
• Tent (Wang et al., 2021)	1.2	1.4	1.4	1.0	0.9	1.2	2.6	1.7	1.8	3.6	5.0	0.5	2.6	3.2	3.1	2.1
ConvNeXt-LN	52.3	52.7	52.3	31.7	18.7	42.5	38.1	54.2	58.3	50.6	75.6	56.8	32.2	39.2	60.4	47.7
• Tent (Wang et al., 2021)	26.3	11.9	36.9	31.1	12.7	14.6	5.1	7.8	5.3	6.6	79.0	67.6	1.5	68.4	65.8	29.4
Severity level 3	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	Avg.
ResNet50-BN	27.7	25.2	25.1	37.8	16.7	37.8	35.3	35.2	32.1	46.7	69.5	46.2	55.4	46.2	59.4	39.8
• Tent (Wang et al., 2021)	3.4	3.2	3.2	2.3	2.0	2.4	3.4	2.4	2.4	4.6	5.4	3.0	4.8	4.6	4.5	3.4
ConvNeXt-LN	71.1	69.8	72.4	55.2	36.6	64.3	52.8	63.2	64.0	66.0	79.4	75.8	69.1	68.5	71.9	65.4
• Tent (Wang et al., 2021)	73.4	73.5	74.4	66.8	61.6	71.4	64.2	22.6	39.5	76.8	81.2	78.9	76.8	75.6	75.8	67.5

e.g., the average accuracy 26.1% (Tent+recovery) vs. 37.2% (SAR) on ResNet50-GN, suggesting the effectiveness of our proposed SAR.

表 18: 模型恢复方案与 Tent 和 EATA 结合的结果。我们报告在在线不平衡标签分布偏移下 ImageNet-C 严重程度 5 级的准确率（%），不平衡比为 ∞ 。

Model+Method	Noise			Blur				Weather				Digital				Avg.
	Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
ResNet50 (GN)	18.0	19.8	17.9	19.8	11.4	21.4	24.9	40.4	47.3	33.6	69.3	36.3	18.6	28.4	52.3	30.6
• Tent	2.6	3.3	2.7	13.9	7.9	19.5	17.0	16.5	21.9	1.8	70.5	42.2	6.6	49.4	53.7	22.0
• Tent+recover	10.1	12.2	10.6	13.9	8.5	19.5	20.6	24.3	33.5	8.9	70.5	42.2	13.5	49.4	53.7	26.1
• EATA	27.0	28.3	28.1	14.9	17.1	24.4	25.3	32.2	32.0	39.8	66.7	33.6	24.5	41.9	38.4	31.6
• EATA+recover	26.1	31.0	27.2	19.9	18.5	25.7	25.7	35.9	28.6	40.4	68.2	35.3	27.6	42.9	40.9	32.9
• SAR (ours)	33.1	36.5	35.5	19.2	19.5	33.3	27.7	23.9	45.3	50.1	71.9	46.7	7.1	52.1	56.3	37.2
VitBase (LN)	9.4	6.7	8.3	29.1	23.4	34.0	27.0	15.8	26.3	47.4	54.7	43.9	30.5	44.5	47.6	29.9
• Tent	32.7	1.4	34.6	54.4	52.3	58.2	52.2	7.7	12.0	69.3	76.1	66.1	56.7	69.4	66.4	47.3
• Tent+recover	40.3	10.1	42.4	54.4	52.3	58.1	52.2	31.6	39.2	69.3	76.1	66.1	56.7	69.4	66.4	52.3
• EATA	35.9	34.6	36.7	45.3	47.2	49.3	47.7	56.5	55.4	62.2	72.2	21.7	56.2	64.7	63.7	50.0
• EATA+recover	35.9	34.6	36.7	45.3	47.2	49.3	47.7	56.5	55.4	62.2	72.2	21.7	56.2	64.7	63.7	49.9
• SAR (ours)	46.5	43.1	48.9	55.3	54.3	58.9	54.8	53.6	46.2	69.7	76.2	66.2	60.9	69.6	66.6	58.1