


# 解析生成式策略的失效模式： 一致性与进展的运行时监控

Christopher Agia<sup>1</sup>, Rohan Sinha<sup>1</sup>, Jingyun Yang<sup>1</sup>, Zi-ang Cao<sup>1</sup>,  
Rika Antonova<sup>1</sup>, Marco Pavone<sup>1,2</sup>, Jeannette Bohg<sup>1</sup>

<sup>1</sup>Stanford University, <sup>2</sup>NVIDIA Research



**图 1:** 本文提出哨兵（Sentinel），一种运行时监控器，用于在部署时检测生成式机器人策略的未知失效。构建哨兵仅需一组成功的策略执行轨迹和任务描述，通过监控（a）策略生成的动作块分布的时序一致性，以及（b）借助视觉语言模型进行视频问答来评估机器人的任务进展，从而检测多种失效。

**摘要：**通过模仿学习训练的机器人行为策略在与训练数据偏离的条件下容易失效。因此，需要在测试时监控学习策略并提供失效早期预警的算法，以促进可扩展部署。本文提出哨兵（Sentinel），一种运行时监控框架，将失效检测分为两个互补类别：1）不稳定失效，利用时序动作一致性的统计测度进行检测；以及

2）任务进展失效，利用视觉语言模型（VLM）检测策略何时自信且持续地采取无法解决任务的动作。

本文方法具有两个关键优势。首先，由于学习策略表现出多样的失效模式，结合互补检测器可显著提高失效检测准确率。其次，利用统计时序动作一致性测度，可在计算成本可忽略的情况下快速检测多模态生成式策略的不稳定行为。相比之下，仅使用视觉语言模型检测对时间不敏感的失效模式。本文在仿真和真实世界的机器人移动操作领域中，针对扩散策略验证了所提方法。通过统一时序一致性检测和视觉语言模型运行时监控，哨兵比单独使用任一检测器多检测出 18% 的失效，并显著优于基线方法，从而凸显了为互补失效类别分配专用检测器的重要性。定性结果见 [sites.google.com/stanford.edu/sentinel](https://sites.google.com/stanford.edu/sentinel)。

**关键词：**失效检测，生成式策略，视觉语言模型 通讯作者：Christopher Agia <  
[cagia@cs.stanford.edu](mailto:cagia@cs.stanford.edu)>

# 1 引言

模仿学习是从数据中学习机器人控制行为最简单且最有效的方法之一。其中，生成式建模技术使机器人策略能够从人类收集的高度异构、多模态演示数据中学习 [1, 2, 3]，并初步展现出对新环境 [4] 和新本体 [5] 的泛化能力。然而，当机器人部署到受控实验室环境之外时，即使是最强大的生成式策略最终也会遇到分布外（OOD）测试案例——即与训练数据不同的场景——在这些场景下，其行为变得不可预测 [6]。为此，我们需要在部署时监控所学生成式策略行为的方法，以检测其是否因分布偏移而失效。

识别学习模型何时表现不可靠通常被表述为分布外检测问题，对此已存在一系列方法 [7, 8]。虽然这些方法能够指示分布偏移 [9, 10] 或量化单个输入输出样本的不确定性 [11,12]，但它们并未完全刻画由轨迹展开过程中多个时间相关的预测误差所导致的闭环策略失效。动作多模态性进一步加剧了失效检测的复杂性：即从多模态生成式策略中采样的动作在不同时间步之间可能存在巨大差异，导致复杂的运行时行为，并因此产生与以往无模型策略相比更加多样的失效模式 [13, 14]。因此，生成式机器人策略的特殊情况要求设计新的失效检测器，以适应其多模态特性和部署中的闭环运行本质。

本文提出了哨兵（**Sentinel**），一个运行时监控框架，将生成式策略的故障检测任务划分为两个互补类别。第一类是检测策略因时序不一致而表现异常行为的故障。例如，如果策略的动作分布在时间上包含冲突的动作模式，机器人可能会与周围环境发生碰撞。为了检测异常故障，本文提出使用时序动作一致性（STAC）的统计测度来评估生成式策略的动作分布在时间上的变化程度。第二类是检测策略时序一致但难以推进任务的故障。例如，如果策略输出恒定，机器人可能会原地停滞或偏离航向。本文提出利用视觉语言模型（VLM）以零样本方式检测任务进展故障（STAC 无法检测），在视频问答设置中提示模型推理机器人的进展，从而区分非标称行为。值得注意的是，异常故障（第一类）需要快速捕获，而任务进展故障（第二类）不需要立即干预。

本文的贡献有三方面：1) 提出一种针对生成式策略的故障检测形式化方法，将故障划分为两个互补类别，从而允许使用专用检测器以提升系统级性能（即分而治之策略）；2) 提出 STAC，一种新颖的时序一致性检测器，通过跟踪生成式策略动作分布的统计一致性来检测异常故障；3) 提出使用 VLM 在策略执行期间监控任务进展，并为其作为故障检测器的使用提供了实用洞见。仅提供一组成功的策略执行记录和任务的自然语言描述，哨兵（并行运行 STAC 和 VLM 监控器）在仿真和真实机器人移动操作领域中检测到扩散策略 [1] 表现出的未知故障超过 97%。

## 2 相关工作

机器人模仿学习的进展包括新的策略架构 [1, 15, 16, 17]、用于数据收集的硬件创新 [18, 19, 20]、社区范围内扩展机器人学习数据集的努力 [3, 5, 21]，以及在这些数据集上训练高容量行为策略 [2, 4, 22, 23]。近期关注的是使用生成模型 [24, 25, 26, 27] 从异构和多模态的人类演示数据集中有效学习 [1, 5, 2, 23]。因此，生成式策略能够学习表示高度多模态的分布，从中可以采样出多样的机器人动作。虽然最先进的生成式策略表现出卓越的性能，但其固有的多模态性导致运行时行为比之前的无模型策略更具随机性 [13, 14, 28, 29, 30, 31]。在这项工作中，我们专注于刻画生成式机器人策略的行为以进行故障检测。

尽管近期取得了进展，但众所周知，学习到的策略可能会在其训练分布之外失败 [6, 7, 8]，部分原因是策略诱导的状态上的复合预测误差 [32, 33]。因此，最近的一项工作提出在部署前对模仿学习策略的性能进行界定 [34]。其他工作提出使用来自人类的纠正性监督在分布外状态上重新训练策略 [35, 36, 37, 38, 39]。值得注意的是，这些方法在故障发生后应用，仍然需要运行时监视器来检测策略故障并防止其下游后果。因此，我们的关注点可以被视为与从纠正反馈中事后学习的方法互补。

关于分布外检测器和学习模型运行时监控的现有文献高度多样化，涵盖多种方法类别。基于模型的方法（例如，[40, 41]）不直接适用于我们所考虑的无模型策略。一些方法仅追求先验已知的失败模式 [42, 43, 44, 45]，而我们则力求在部署时检测未知失败。许多分布外检测工作通过重构 [9, 46] 或嵌入相似性 [47, 10] 来检测与训练数据的差异，然而观测差异并不总是导致策略失败。其他方法直接量化认知不确定性 [11, 12, 48, 49]，但伴随相当大的计算开销，或可能不适合自回归、生成式策略架构，例如扩散策略 [1]。若干工作监控符号状态以检测操作失败 [50, 51]，但假设能够访问多种传感器模态（例如视觉、触觉、本体感觉）以进行符号状态估计。与我们的方法最相关的是跨传感器模态 [52] 和时间 [53] 执行一致性检查的算法。与这些方法不同，我们直接监控学习策略的动作分布一致性及其任务进展，以检测闭环失败。

人们对使用基础模型（Foundation Models）[54] 来提高机器人系统鲁棒性的兴趣日益增长。大语言模型被用于检测异常 [55, 56] 并在执行失败时重新规划 [56, 57, 58, 59]。以视觉表示 [60, 61] 或视觉语言模型 [62] 形式存在的奖励模型，可以通过对预测奖励进行阈值化来重新用于失败检测。然而，[62] 表明，需要额外的微调才能获得可靠的奖励估计。Du 等人 [63] 使用规模约为  $10^5$  条轨迹的人工标注数据集，对视觉语言模型进行微调，用于回合级成功分类。与这项工作相比，我们：1) 专注于使用视觉语言模型进行零样本评估；2) 力求在任务执行过程中检测策略失败；3) 考虑视觉语言模型在系统层面与策略级失败检测器协同工作的角色，因此将每个检测器分配给指定的失败类别。

### 3 问题设定

**失败检测** 本工作的目标是检测生成式机器人策略  $\pi(a|s)$  何时未能完成任务。该策略在有限时域  $H$ ，的马尔可夫决策过程（Markov Decision Process, MDP）中运行，但可能在较早的时间步完成任务时终止。给定代表新测试场景的初始状态  $s_0$ ，执行策略  $t$  个时间步会产生一条轨迹  $\tau_t = (s_0, a_0, \dots, s_t)$ 。本文将失败检测定义为检测轨迹展开  $\tau_H$  是否构成失败的任务，并尽可能在最早的时间步  $t$  完成。为此，本文旨在构建一个失败检测器  $f(\tau_t) \rightarrow \{\text{ok}, \text{failure}\}$ ，使其在每个时间步  $t$  能够给出分类，判断策略若继续执行 MDP 剩余  $H-t$  个时间步是否会失败。注意，失败检测器仅基于截至当前时间步  $t$  的已观测状态和采样动作历史进行评估。

失败检测器可能包含需要校准的参数，例如检测阈值（如 § 4.1 所述）。因此，本文假设一种场景：策略  $\pi$  首先被训练，然后在预期可靠执行的测试用例上进行验证。该验证过程产生一个包含  $M$  条成功轨迹  $\mathcal{D}_\tau = \{\tau^i\}_{i=1}^M$  的小型数据集，可用于校准失败检测器  $f$ （若其包含参数）。直观上，数据集  $\mathcal{D}_\tau$  刻画了策略在其训练状态分布内或附近的标称行为，这有助于在测试时对可能分布外（OOD）的轨迹进行评估。

本文以真阳性率（True Positive Rate, TPR）、真阴性率（True Negative Rate, TNR）和检测时间（Detection Time, DT）来衡量失败检测性能。若失败检测器在策略失败的轨迹中的任一时间步发出警告，则计为一次真阳性，其中最早的时间步计为检测时间。若失败检测器在策略成功的轨迹中从未发出警告，则计为一次真阴性。关于策略失败和关键性能指标的支持性定义参见 § B.4。




图 3: 哨兵系统概览。图像展示了时间步  $t = 1, \dots, T$  的策略执行过程。时序一致性检测器：在每个时间步  $t$ ，状态  $s_t$  被输入生成式策略，得到动作分布  $\pi_t$ ，计算它们之间的统计距离  $\hat{D}_t$  以衡量时序一致性。统计距离累加至当前时间步  $T$  (as in Eq. 1)，并通过阈值  $\gamma$  判断策略是否失效。视觉语言模型检测器：给定截至时间步  $T$  的视频和任务描述，视觉语言模型判断策略是否未能推进任务。任一检测器发出警告即停止执行。

### 策略形式化

其中策略  $\pi$

是随机的，并为接下来的  $h$  个时间步预测动作序列（也称为动作块 [18]）。也就是说，在第  $t$  个时间步采样的动作序列  $a_t \sim \pi(\cdot|s_t)$  由  $h$  个动作  $a_t := (a_{t|t}, a_{t+1|t}, \dots, a_{t+h-1|t})$  组成，其中记号  $a_{t+i|t}$  表示在时间步  $t$  生成的针对时间  $t+i$  的动作预测（如 [64] 所述）。动作  $a_{i|t} \in \mathcal{A}$  可以对应例如末端执行器位姿或速度。为控制机器人，我们采样动作序列并执行前  $k < h$  个动作  $a_{t:t+k|t}$ ，之后在时间步  $t+k$  重新评估策略。我们在图 2 中展示了  $k=1$  的滚动时域执行过程。值得注意的是， $a_t$  和  $a_{t+k}$  包含在  $h-k$  个时间步上时间重叠的动作（即在  $a_{t+k:t+h-1|t}$  和  $a_{t+k:t+h-1|t+k}$  处）。




图 2: 策略执行过程中动作序列预测的重叠。

最近提出的几种策略架构通过使用生成模型 [1, 18, 2] 采样动作序列达到了最先进的性能，我们的方法可普遍适用于这些架构。然而，在本文中，我们针对扩散策略（DP）[1] 定义故障检测问题，因为扩散策略（a）训练稳定，（b）通过用去噪扩散概率模型（DDPM）[26] 表示策略分布来解决动作多模态问题。我们注意到，去噪过程计算密集且具有迭代性质，这使得直接将现有的分布外检测方法（例如 [65]）应用于扩散策略进行故障检测具有挑战性，因此促成了我们若干设计决策。关于这些模型的训练和性质的更多细节见 § B.2。

## 4 提出的方法：哨兵系统

生成式策略在分布外条件下的失效行为可能高度多样，因此本文认为失效检测器的需求可能因失效的定性类型而异。本文提出将失效检测任务拆分为两个互补的失效类别。

第一类是检测由策略行为不稳定导致的失效，这类失效可能使机器人陷入难以或代价高昂地重置的状态、撞倒物体或引发安全隐患。因此，尽快检测不稳定行为至关重要（§ 4.1）。第二类是检测策略在任务推进上挣扎但以时序一致方式表现的失效（下文称为任务推进失效）。例如，策略可能自信地将物体放置在错误位置。此时，必须较长时间观察机器人，以识别策略未朝任务完成方向推进（§ 4.2）。

本文方法的核心洞见在于：将一个失效类别定义为另一个类别的补集，即可轻松组合失效检测器，形成准确的总体检测流程，同时满足每个失效类别的需求。本文完整流程 **Sentinel** 如图 3 所示。

#### 4.1 STAC: 利用时序一致性检测不稳定失效

当策略在标称的分布内设置下运行时，应以时序一致的方式完成任务。例如，策略可能计划从右侧或左侧避开障碍物，但不应在两个选项之间抖动。此外，如 [1] 所述，训练预测动作序列而非单个动作的扩散策略可促进动作预测之间的时序一致性。

因此，本文提出构建时序动作一致性的可量化测度，以检测策略是否行为不稳定，从而可能任务失败。然而，扩散策略的多模态分布特性使得直接比较两个采样动作  $a_t \sim \pi(a_t|s_t)$  和  $a_{t+k} \sim \pi(a_{t+k}|s_{t+k})$ （例如在整个执行过程中）变得困难。这是因为当策略承诺或切换不同动作模式时，或仅因采样随机性，动作在其预测时域上可能差异显著。相反，本文用时序动作一致性的统计测度（STAC，即本文方法）来量化不稳定策略行为。

设  $\tilde{\pi}_t := \pi(a_{t+k:t+h-1}|t|s_t)$  和  $\tilde{\pi}_{t+k} := \pi(a_{t+k:t+h-1}|t+k|s_{t+k})$  为时间步  $t$  与  $t+k$  之间时间重叠动作的边缘动作分布。我们计算两个相邻时间步  $t$  与  $t+k$  之间的时序一致性为  $\hat{D}(\tilde{\pi}_t, \tilde{\pi}_{t+k}) \geq 0$ ，其中  $\hat{D}$  表示所选的统计距离函数（例如最大均值差异、KL 散度）<sup>1</sup>。此外，我们提出沿轨迹取统计距离的累积和，作为策略展开中整体时序一致性的度量。在每个策略推理时间步  $t = jk$  且  $j \in \{0, 1, \dots\}$  时，我们计算时序一致性得分为

$$\eta_t := \sum_{i=0}^{j-1} \hat{D}(\tilde{\pi}_{ik}, \tilde{\pi}_{(i+1)k}). \quad (1)$$

以累积方式计算一致性得分相比在每个时间步单独对距离进行阈值化有两个优势。首先，它使我们能够检测整个回合中时序一致性度量  $\hat{D}$  略高于通常水平的情况（例如抖动）。其次，它使我们能够检测策略在时序上不一致的频率高于标称场景的情况。

在运行时，当  $\eta_t$  超过失败检测阈值  $\gamma$  时，我们立即发出失败警告，该阈值使用成功轨迹的验证数据集  $\mathcal{D}_\tau$  离线校准。这里，我们首先计算  $\mathcal{D}_\tau$  中轨迹整个长度  $H_i \leq H$  上的累积时序一致性得分，得到  $\{\eta_{H_i}^i\}_{i=1}^M$ 。然后，我们将阈值  $\gamma$  设为  $\{\eta_{H_i}^i\}_{i=1}^M$  的  $1-\delta$  分位数，其中  $\delta \in (0, 1)$  是一个超参数。直观上，这确保了假阳性率（FPR）——即对于任何与  $\mathcal{D}_\tau$  独立同分布的轨迹，我们发出错误警报并终止的概率——保持较低，因此任何警告都可能是真正的失败。我们可以利用近期共形预测的结果 [66, 67] 将这一直觉形式化：

**命题 1 (STAC 具有低 FPR)**。设  $P_\tau$  表示验证数据集  $\mathcal{D}_\tau = \{\tau^i\}_{i=1}^M \stackrel{\text{iid}}{\sim} P_\tau$  中成功轨迹的分布。那么，FPR——在长度为  $H' \leq H$  的独立同分布测试轨迹  $\tau \sim P_\tau$  上任意时刻发出错误警报的概率——至多为  $\delta$ ：

$$\text{FPR} := \mathbb{P}_{P_\tau}(\exists 0 \leq t \leq H' \text{ s.t. } \eta_t > \gamma) \leq \delta.$$

关于 STAC 的更多细节参见 § A.1，命题 1 的完整陈述与证明参见 § D。

#### 4.2 利用视觉语言模型检测任务进展失败

在分布外环境中运行的策略并不总是通过表现出我们能 STAC (§ 4.1) 检测到的异常行为而失败。例如，假设策略自信地做出了错误的 1 由于扩散策略的迭代去噪过程，解析地计算距离  $D(\tilde{\pi}_t, \tilde{\pi}_{t+k})$  具有挑战性，因为评估  $\tilde{\pi}_t$  和  $\tilde{\pi}_{t+k}$  的密度需要对中间扩散步骤和非重叠动作进行边缘化。相反，我们在每个时间步  $t$  和  $t+k$  采样一批动作序列（在 GPU 上并行化），而不是单个动作序列，用其经验对应物  $\hat{D}$  来近似  $D$ 。




图 4：当策略失败时，时序一致性得分增长更快。误差线表示第 5 和第 95 百分位得分分位数。



计划或产生近似恒定的输出。检测此类失败需要理解策略是否在其任务上取得进展，这需要在任务规范的背景下对机器人的行为进行更全面的分析。因此，我们提出使用视觉语言模型（VLM）来监控策略的任务进展，方法是将机器人截至当前时间步的图像观测作为视频提供给它们。我们这样做是因为最近的工作表明，大容量视觉语言模型具备机器人相关的知识和上下文推理能力 [68, 69, 63, 70, 62]。

我们将任务进展失败的检测形式化为思维链（CoT）[71]、视频问答（QA）任务 [72, 73]，反映了当前提示的最佳实践。为了捕捉任务进展的概念，视觉语言模型必须跨时间并在策略任务的背景下进行推理。因此，我们构建了一个提示，其中包含任务描述和视觉语言模型作为运行时监控器的角色。我们使用文本提示和截至当前时间步  $t$  的观测图像历史（即视频） $I_{0:t} := (I_0, I_{\nu k}, I_{2\nu k}, \dots, I_t)$  在线查询视觉语言模型，其中  $\nu$  决定了图像相对于扩散策略（§ 3）执行范围  $k$  的频率。对于移动缓慢的机器人，区分部分进展和任务失败可能含糊不清，因此我们还指定了当前经过的时间  $t$  和任务的时间限制  $H$ 。这使视觉语言模型能够判断机器人的执行速率是否会导致及时完成任务。在执行思维链分析后，视觉语言模型以 {ok, 失败} 的分类作为结论。有关视觉语言模型和提示的更多细节，请参见 § A.2。

在撰写本文时，通过云端查询最先进的视频问答视觉语言模型（VLM）会产生显著的延迟（例如，GPT-4o 的平均响应时间为 14.0s）。然而，我们强调，VLM 推理延迟对于检测任务进展失败而言并非主要问题，因为这类失败可能发生在更长的时间尺度上，且不需要紧急干预。相比之下，我们将快速检测不稳定失败的任务分配给 STAC（§ 4.1）。值得注意的是，我们互补的失败类别对快速和慢速检测的不同要求意味着 STAC 和 VLM 可以在不同的时间尺度上运行，从而在并行运行时提供潜在的优势，例如降低成本并降低假阳性的可能性（图 3）。

## 5 实验

我们进行了一系列实验来测试我们的失败检测框架。这些实验在仿真和现实世界中同时进行（图 1），并包含了大量的基线方法。关于环境、硬件设置、基线和评估协议的详细描述，请参见 § B。

**环境。**我们引入了来自 [1] 的 PushT 领域，以评估在动作多模态情况下的失败检测。Close Box 和 Cover Object 领域涉及两个移动机械臂，因此带来了高维、14 自由度动作空间的挑战。此外，我们还使用移动机械臂进行了非抓取式 Push Chair 任务的硬件实验。该任务比仿真领域 [74] 具有更大的动态复杂度。在测试时，我们通过随机化以下因素来生成分布外（OOD）场景：a) PushT 和 Close Box 中物体的尺度和尺寸；b) Cover Object 和 Push Chair 中物体的位姿，使其超出策略的演示数据范围。

**基线。**我们将哨兵（Sentinel，即同时包含时序动作一致性（STAC）和视觉语言模型（VLM））与代表分布外检测文献中多个方法类别的基线进行比较 [7]。直观上，这些类别代表了故障检测器评分函数的不同表述，该函数负责计算每个时间步的分数，然后按公式 1 求和得到轨迹分数。我们考虑的评分函数基于观测状态的嵌入相似度 *w.r.t.*  $\mathcal{D}_\tau$  [47]、从扩散策略（DP）采样的动作的重建误差 [75] 以及扩散策略的输出方差。为加强比较，我们引入一个新基线，该基线使用对从扩散策略采样的动作重新加噪后的去噪扩散概率模型（DDPM）损失（公式 2）作为故障检测器的评分函数。在适用的情况下，我们实现这些基线的时序一致性变体，以消融时序动作一致性的设计。关于这些基线的更多细节见 § B.3。

**评估协议。**我们为每个环境训练一个扩散策略（Diffusion Policy，DP），并使用标准设置来设定 DP 的预测与执行时域 [1]。我们在所有故障检测方法中采用相同的校准与评估协议。也就是说，我

们将检测阈值校准到分数的第 95 个分位数。在一个数据集  $i=1$  中，包含每个模拟任务的  $M=50$  个分布内轨迹，以及真实世界任务的  $M=10$


个分布内轨迹。最后，我们报告标准检测度量，包括真阳性率、真阴性率、平均检测时间、准确率和平衡准确率，遵循第 3 节中的定义。

| Category 1: Erratic Failures            |                           |  | Close Box: In-Distribution<br>(Policy Success Rate: 91%) |       |                 | Close Box: Out-of-Distribution<br>(Policy Success Rate: 41%) |       |                 | Close Box: Combined<br>(Policy Success Rate: 67%) |       |            |
|-----------------------------------------|---------------------------|--|----------------------------------------------------------|-------|-----------------|--------------------------------------------------------------|-------|-----------------|---------------------------------------------------|-------|------------|
| Failure Detector                        |                           |  | TPR ↑                                                    | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                                        | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                             | TNR ↑ | Accuracy ↑ |
| Diffusion                               | Temporal Non-Distr. Min.  |  | 1.00                                                     | 0.97  | 5.00            | 1.00                                                         | 0.27  | 12.35           | 1.00                                              | 0.77  | 0.85       |
|                                         | Diffusion Recon. [75]     |  | 0.33                                                     | 0.95  | 13.60           | 0.40                                                         | 1.00  | 17.08           | 0.37                                              | 0.96  | 0.76       |
|                                         | Temporal Diffusion Recon. |  | 1.00                                                     | 0.96  | 8.47            | 0.92                                                         | 1.00  | 15.75           | 0.92                                              | 0.97  | 0.95       |
|                                         | DDPM Loss (Eq. 2)         |  | 1.00                                                     | 0.90  | 8.27            | 1.00                                                         | 0.94  | 14.54           | 1.00                                              | 0.91  | 0.94       |
|                                         | Temporal DDPM Loss        |  | 1.00                                                     | 0.95  | 7.53            | 1.00                                                         | 0.37  | 13.66           | 1.00                                              | 0.79  | 0.86       |
| Diffusion Output Variance               |                           |  | 0.33                                                     | 0.94  | 14.00           | 0.28                                                         | 1.00  | 17.27           | 0.26                                              | 0.96  | 0.72       |
| Embed.                                  | Policy Encoder            |  | 0.25                                                     | 0.98  | 16.27           | 1.00                                                         | 0.00  | 1.59            | 0.94                                              | 0.70  | 0.78       |
|                                         | CLIP Pretrained           |  | 1.00                                                     | 0.95  | 15.73           | 1.00                                                         | 0.00  | 8.20            | 1.00                                              | 0.68  | 0.79       |
|                                         | ResNet Pretrained         |  | 1.00                                                     | 0.95  | 17.87           | 1.00                                                         | 0.00  | 15.51           | 1.00                                              | 0.68  | 0.79       |
| STAC                                    | STAC For. KL (Ours)       |  | 1.00                                                     | 0.90  | 6.60            | 0.99                                                         | 0.85  | 14.04           | 0.99                                              | 0.89  | 0.92       |
|                                         | STAC Rev. KL (Ours)       |  | 1.00                                                     | 0.95  | 7.60            | 0.93                                                         | 0.97  | 15.12           | 0.93                                              | 0.96  | 0.95       |
|                                         | STAC MMD* (Ours)          |  | 1.00                                                     | 0.94  | 7.20            | 0.99                                                         | 0.93  | 14.72           | 0.99                                              | 0.94  | 0.96       |
| VLM                                     | GPT-4o Image QA           |  | 1.00                                                     | 0.00  | 23.20           | 1.00                                                         | 0.00  | 23.20           | 1.00                                              | 0.00  | 0.29       |
|                                         | GPT-4o Video QA* (Ours)   |  | 1.00                                                     | 0.89  | 21.20           | 0.69                                                         | 0.95  | 21.02           | 0.77                                              | 0.91  | 0.87       |
| Sentinel (STAC MMD* + GPT-4o Video QA*) |                           |  | 1.00                                                     | 0.86  | 5.47            | 1.00                                                         | 0.90  | 14.25           | 1.00                                              | 0.87  | 0.91       |

**表 1：在封闭盒子领域中检测不稳定策略失败。**结果基于 3 个随机种子取平均。我们的时序一致性检测器 STAC 能够识别策略何时失败（高真阳性率）以及何时泛化到分布外测试案例（高真阴性率），这与将状态非典型性与策略失败相关联的基于嵌入的方法（低真阴性率）形成对比。在该领域中准确检测不稳定策略失败的选定基线在多模态条件下性能下降（即 PushT，如图 5 所示），而 STAC 在多个领域中持续表现出强大性能。视觉语言模型必须对视频进行推理才能获得高真阴性率，这是将其与 STAC 结合所必需的（见图 6）。Sentinel 并行运行 STAC 和视觉语言模型监视器，在该领域中检测到 100% 的不稳定策略失败。

## 6 结果

**STAC 在多模态领域中检测扩散策略失败。**图 5（左）将 STAC 与 PushT 领域中各类基线的最佳方法进行比较。在此，STAC 是唯一达到超过 90% 平衡准确率的方法，表明时序一致性（或缺乏一致性）与成功（或失败）强相关。替代输出度量（如 DP 的输出方差）表现不佳，因为在多模态领域中成功和失败都可能呈现高方差输出。有趣的是，嵌入相似性方法表现强劲，表明相对于校准数据集的状态不相似性恰好与该领域中的失败相关。



**图 5：检测 PushT 中的失败。**左：我们的失败检测器（STAC）通过测量生成式策略的时序一致性，优于多个类别的分布外检测器。右：最佳性能来自使用统计距离函数测量时序一致性；为基线增加时序一致性并不总能提升其性能。

**动作相似性的统计度量实现了时序一致性检测。**图 5（右）对 STAC 的设计决策进行了消融。首先，我们观察到为基线增加时序一致性至多只能略微提升其性能。其次，使用非统计距离函数（例如最小距离）测量时序动作一致性表现不如基线，因为它忽略了动作多模态性。因此，统计距离函数与时序一致性的结合才能产生最佳结果。关于 STAC 的扩展消融请参见 § C.1。

**STAC 考虑了分布外失败和泛化。**Close Box 领域的结果见表 1。STAC 在总体上达到了最高准确率（96%）。然而，我们新提出的两个基线——使用 DDPM 损失（公式 2）和 [75] 的时序重建变体——也表现良好，可能是由于相对于 PushT 动作多模态性降低。值得注意的是，我们发现嵌入相似性方法将分布外状态与策略失败混为一谈，导致策略在分布外成功时产生假阳性。相比之下，STAC 有效地区分了分布外成功与失败。

**视觉语言模型必须跨时间推理。**在表 1 中，我们发现最先进的视觉语言模型（GPT-4o）在仅给定单张图像时难以识别任务成功。相反，它必须在策略执行的整个过程中观察机器人，才能更准确地推理任务进展和状态变化（得到

91% 的真阴性率)。虽然突发性失败具有时间敏感性，但它们在视觉上更为细微，因此视觉语言模型难以检测 (77% 的真阳性率)。在任务进展失败中，机器人采取了更明显的错误动作 (例如停滞、偏离方向) (图 6)。正如预期，视觉语言模型的检测时间显著慢于 STAC，进一步凸显了 STAC 在快速检测异常行为方面的价值。

#### 哨兵：结合 STAC 与视觉语言模型用于系统级

**性能提升。**我们在分布偏移上评估了失败检测器，这些偏移主要导致覆盖物体和关闭盒子领域中的任务进展失败。结果如图 6 所示。当策略以时间一致的方式失败时，STAC 实现了较低的真阳性率 (44%)，而视觉语言模型 (VLM) 对于关闭盒子为 GPT-4o，对于覆盖物体为 Claude)

**封面对象)** 准确检测任务进展失败。因此，它们的组合 (哨兵) 实现了 93% 的真阳性率，同时仅导致假阳性率增加 7%。检测时间的上升表明，快速时空异常检测与慢速视觉语言模型均对失败检测有所贡献。

**哨兵系统检测现实世界中生成式策略的失效情况。**我们在推椅子任务上对哨兵 (Sentinel) 进行了评估，涵盖 10 次成功和 10 次失败的政策执行。结果如表 2 所示。仅使用 10 次成功的分布内执行进行校准后，时空异常检测 (STAC) 检测出 80% 的政策失败，且仅产生一次误报 (90% 真阴性率)。视觉语言模型 (VLM) 在真实世界中表现出更强的性能 (90% 真阳性率，100%

TNR) 比在仿真领域中更高，这可能是因为真实世界图像相较于仿真渲染图像，对视觉推理而言领域差距更小。总体而言，哨兵 (Sentinel) 达到了 95% 的检测准确率，突显了其在真实世界机器人环境中检测故障的有效性。

**讨论。**对表 1、图 6 和表 2 的整体分析表明，我们可以轻松地将 STAC 与视觉语言模型 (VLM) 结合，构建一个性能良好的整体检测器，用于检测异常行为和任务进展失败，特别是因为两种检测器都实现了较高的整体真阴性率 (TNR)。由于所有基线方法可能 1) 在任一异常失败领域 (即多模态 PushT 和 Close Box 领域) 上表现出较低的准确率，或 2) 产生较低的真阴性率，因此尚不清楚如何将它们与其他检测器结合以超越 Sentinel。




图 6: 检测任务进展失败。将视觉语言模型与 STAC 结合，可得到针对任务进展失败和突发性失败的准确整体检测器 (哨兵) (表 1)。扩展结果与分析见 § C.2。

| Failure Detector                | TPR ↑       | TNR ↑       | Det. Time (s) ↓ |
|---------------------------------|-------------|-------------|-----------------|
| Diffusion Output Variance       | 0.60        | 0.90        | 10.67           |
| Temporal Non-Distr. Min.        | 0.70        | 0.80        | 9.52            |
| STAC Rev. KL (Ours)             | 0.80        | 0.90        | 9.83            |
| GPT-4o Video QA (Ours)          | 0.90        | 1.00        | 12.89           |
| <b>Sentinel (STAC + GPT-4o)</b> | <b>1.00</b> | <b>0.90</b> | <b>9.60</b>     |

表 2: 检测现实世界中的失败。哨兵 (Sentinel) 在现实世界的推椅任务中展现出强大的失败检测性能，总体准确率达到了 95%。

## 7 结论

本文研究了生成式机器人策略的失败检测问题。我们提出了 Sentinel，一种运行时监控器，将失败检测任务分为两类：1) 异常失败，通过测量策略动作分布随时间的统计变化来检测；2) 任务进展失败，使用视觉语言模型评估策略是否持续采取无法解决任务的动作。我们的结果强调了针对互补失败类别使用专用检测器的重要性。未来工作包括使用 Sentinel 监控高容量策略 [2, 23]、指导数据收集并加速策略学习。

**局限性。**虽然将异常失败和任务进展失败分类可以在我们考虑的领域内实现准确的失败检测，但这两类失败可能并不全面。未来，引入更多类别或进一步划分现有类别可能提供更广泛的失败覆盖，实现更高效的失败检测，并为缓解策略提供信息。此外，我们的方法不提供检测失败的形式化保证。然而，提供此类保证需要成功和不成功策略执行的数据来校准检测器 [67]。尽管我们的检测器在总体上实现了较低的假阳性率，但在最坏情况下，合并它们的预测可能会增加误报风险。因此，探索更复杂的方法来组合互补的失败检测器是一个可能的扩展方向。最后，我们的方法并非旨在预测失败发生之前，而是专注于在失败发生时进行检测。



## 致谢

作者谨向 Rachel Luo 和 Apoorva Sharma 对项目早期阶段提供的反馈表示感谢。丰田研究所、东芝以及斯坦福以人为本人工智能研究院为本工作提供了资金支持。本工作还得到了蓝色起源和美国国家航空航天局在大学领导力倡议计划下的资助。

## 参考文献

- [1] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. C. Burchfiel, and S. Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi:10.15607/RSS.2023.XIX.026.
- [2] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, T. Kreiman, Y. Tan, L. Y. Chen, P. Sanketi, Q. Vuong, T. Xiao, D. Sadigh, C. Finn, and S. Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [3] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, P. D. Fagan, J. Hejna, M. Itkina, M. Lepert, Y. J. Ma, P. T. Miller, J. Wu, S. Belkhale, S. Dass, H. Ha, A. Jain, A. Lee, Y. Lee, M. Memmel, S. Park, I. Radosavovic, K. Wang, A. Zhan, K. Black, C. Chi, K. B. Hatch, S. Lin, J. Lu, J. Mercat, A. Rehman, P. R. Sanketi, A. Sharma, C. Simpson, Q. Vuong, H. R. Walke, B. Wulfe, T. Xiao, J. H. Yang, A. Yavary, T. Z. Zhao, C. Agia, R. Baijal, M. G. Castro, D. Chen, Q. Chen, T. Chung, J. Drake, E. P. Foster, J. Gao, D. A. Herrera, M. Heo, K. Hsu, J. Hu, D. Jackson, C. Le, Y. Li, K. Lin, R. Lin, Z. Ma, A. Maddukuri, S. Mirchandani, D. Morton, T. Nguyen, A. O’Neill, R. Scalise, D. Seale, V. Son, S. Tian, E. Tran, A. E. Wang, Y. Wu, A. Xie, J. Yang, P. Yin, Y. Zhang, O. Bastani, G. Berseth, J. Bohg, K. Goldberg, A. Gupta, A. Gupta, D. Jayaraman, J. J. Lim, J. Malik, R. Martín-Martín, S. Ramamoorthy, D. Sadigh, S. Song, J. Wu, M. C. Yip, Y. Zhu, T. Kollar, S. Levine, and C. Finn. Droid: A large-scale in-the-wild robot manipulation dataset. 2024.
- [4] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid, Q. Vuong, V. Vanhoucke, H. Tran, R. Soricut, A. Singh, J. Singh, P. Sermanet, P. R. Sanketi, G. Salazar, M. S. Ryoo, K. Reymann, K. Rao, K. Pertsch, I. Mordatch, H. Michalewski, Y. Lu, S. Levine, L. Lee, T.-W. E. Lee, I. Leal, Y. Kuang, D. Kalashnikov, R. Julian, N. J. Joshi, A. Irpan, B. Ichter, J. Hsu, A. Herzog, K. Hausman, K. Gopalakrishnan, C. Fu, P. Florence, C. Finn, K. A. Dubey, D. Driess, T. Ding, K. M. Choromanski, X. Chen, Y. Chebotar, J. Carbajal, N. Brown, A. Brohan, M. G. Arenas, and K. Han. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In J. Tan, M. Toussaint, and K. Darvish, editors, *Proceedings of The 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, pages 2165–2183. PMLR, 06–09 Nov 2023. URL <https://proceedings.mlr.press/v229/zitkovich23a.html>.
- [5] O. X.-E. Collaboration, A. O’Neill, A. Rehman, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, A. Jain, A. Tung, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Gupta, A. Wang, A. Kolobov, A. Singh, A. Garg, A. Kembhavi, A. Xie, A. Brohan, A. Raffin, A. Sharma, A. Yavary, A. Jain, A. Balakrishna, A. Wahid, B. Burgess-Limerick, B. Kim, B. Schölkopf, B. Wulfe, B. Ichter, C. Lu, C. Xu, C. Le, C. Finn, C. Wang, C. Xu, C. Chi, C. Huang, C. Chan, C. Agia, C. Pan, C. Fu, C. Devin, D. Xu, D. Morton, D. Driess, D. Chen, D. Pathak, D. Shah, D. Büchler, D. Jayaraman, D. Kalashnikov, D. Sadigh, E. Johns, E. Foster, F. Liu, F. Ceola, F. Xia, F. Zhao, F. V. Frujeri, F. Stulp, G. Zhou, G. S. Sukhatme, G. Salhotra, G. Yan, G. Feng, G. Schiavi, G. Berseth, G. Kahn, G. Yang, G. Wang, H. Su, H.-S. Fang, H. Shi, H. Bao, H. B. Amor, H. I. Christensen, H. Furuta, H. Walke, H. Fang, H. Ha, I. Mordatch, I. Radosavovic, I. Leal, J. Liang, J. Abou-Chakra, J. Kim, J. Drake, J. Peters, J. Schneider, J. Hsu, J. Bohg, J. Bingham, J. Wu, J. Gao, J. Hu, J. Wu, J. Wu, J. Sun, J. Luo, J. Gu, J. Tan, J. Oh, J. Wu, J. Lu, J. Yang, J. Malik, J. Silvério, J. Hejna, J. Booher, J. Tompson, J. Yang, J. Salvador, J. J. Lim, J. Han,

- K. Wang, K. Rao, K. Pertsch, K. Hausman, K. Go, K. Gopalakrishnan, K. Goldberg, K. Byrne, K. Oslund, K. Kawaharazuka, K. Black, K. Lin, K. Zhang, K. Ehsani, K. Lekkala, K. Ellis, K. Rana, K. Srinivasan, K. Fang, K. P. Singh, K.-H. Zeng, K. Hatch, K. Hsu, L. Itti, L. Y. Chen, L. Pinto, L. Fei-Fei, L. Tan, L. J. Fan, L. Ott, L. Lee, L. Weihs, M. Chen, M. Lepert, M. Memmel, M. Tomizuka, M. Itkina, M. G. Castro, M. Spero, M. Du, M. Ahn, M. C. Yip, M. Zhang, M. Ding, M. Heo, M. K. Srirama, M. Sharma, M. J. Kim, N. Kanazawa, N. Hansen, N. Heess, N. J. Joshi, N. Suenderhauf, N. Liu, N. D. Palo, N. M. M. Shafiullah, O. Mees, O. Kroemer, O. Bastani, P. R. Sanketi, P. T. Miller, P. Yin, P. Wohlhart, P. Xu, P. D. Fagan, P. Mitrano, P. Sermanet, P. Abbeel, P. Sundaresan, Q. Chen, Q. Vuong, R. Rafailov, R. Tian, R. Doshi, R. Mart'in-Mart'in, R. Baijal, R. Scalise, R. Hendrix, R. Lin, R. Qian, R. Zhang, R. Mendonca, R. Shah, R. Hoque, R. Julian, S. Bustamante, S. Kirmani, S. Levine, S. Lin, S. Moore, S. Bahl, S. Dass, S. Sonawani, S. Song, S. Xu, S. Haldar, S. Karamcheti, S. Adebola, S. Guist, S. Nasiriany, S. Schaal, S. Welker, S. Tian, S. Ramamoorthy, S. Dasari, S. Belkhale, S. Park, S. Nair, S. Mirchandani, T. Osa, T. Gupta, T. Harada, T. Matsushima, T. Xiao, T. Kollar, T. Yu, T. Ding, T. Davchev, T. Z. Zhao, T. Armstrong, T. Darrell, T. Chung, V. Jain, V. Vanhoucke, W. Zhan, W. Zhou, W. Burgard, X. Chen, X. Chen, X. Wang, X. Zhu, X. Geng, X. Liu, X. Liangwei, X. Li, Y. Pang, Y. Lu, Y. J. Ma, Y. Kim, Y. Chebotar, Y. Zhou, Y. Zhu, Y. Wu, Y. Xu, Y. Wang, Y. Bisk, Y. Dou, Y. Cho, Y. Lee, Y. Cui, Y. Cao, Y.-H. Wu, Y. Tang, Y. Zhu, Y. Zhang, Y. Jiang, Y. Li, Y. Li, Y. Iwasawa, Y. Matsuo, Z. Ma, Z. Xu, Z. J. Cui, Z. Zhang, Z. Fu, and Z. Lin. Open X-Embodiment: Robotic learning datasets and RT-X models. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [6] B. D. Argall, S. Chernova, M. Veloso, and B. Browning. A survey of robot learning from demonstration. *Robotics and autonomous systems*, 57(5):469–483, 2009.
- [7] R. Sinha, A. Sharma, S. Banerjee, T. Lew, R. Luo, S. M. Richards, Y. Sun, E. Schmerling, and M. Pavone. A system-level view on out-of-distribution data in robotics. *arXiv preprint arXiv:2212.14020*, 2022. Available at <https://arxiv.org/abs/2212.14020>.
- [8] J. Yang, K. Zhou, Y. Li, and Z. Liu. Generalized out-of-distribution detection: A survey. *CoRR*, abs/2110.11334, 2021. URL <https://arxiv.org/abs/2110.11334>.
- [9] C. Richter and N. Roy. Safe visual navigation via deep learning and novelty detection. 2017.
- [10] L. Ruff, R. Vandermeulen, N. Goernitz, L. Deecke, S. A. Siddiqui, A. Binder, E. Müller, and M. Kloft. Deep one-class classification. In J. Dy and A. Krause, editors, *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 4393–4402. PMLR, 10–15 Jul 2018. URL <https://proceedings.mlr.press/v80/ruff18a.html>.
- [11] Y. Gal and Z. Ghahramani. Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In M. F. Balcan and K. Q. Weinberger, editors, *Proceedings of The 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pages 1050–1059, New York, New York, USA, 20–22 Jun 2016. PMLR. URL <https://proceedings.mlr.press/v48/gal16.html>.
- [12] B. Lakshminarayanan, A. Pritzel, and C. Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL <https://proceedings.neurips.cc/paper/2017/file/9ef2ed4b7fd2c810847ffa5fa85bce38-Paper.pdf>.
- [13] A. Mandlekar, D. Xu, J. Wong, S. Nasiriany, C. Wang, R. Kulkarni, L. Fei-Fei, S. Savarese, Y. Zhu, and R. Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In A. Faust, D. Hsu, and G. Neumann, editors, *Proceedings of the 5th Conference on Robot Learning*, volume 164 of *Proceedings of Machine Learning Research*, pages 1678–1690. PMLR, 08–11 Nov 2022.

- [14] T. Zhang, Z. McCarthy, O. Jow, D. Lee, X. Chen, K. Goldberg, and P. Abbeel. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 5628–5635. IEEE, 2018.
- [15] J. Yang, C. Deng, J. Wu, R. Antonova, L. Guibas, and J. Bohg. Equivact: Sim(3)-equivariant visuomotor policies beyond rigid object manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [16] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking, 2023.
- [17] A. Goyal, J. Xu, Y. Guo, V. Blukis, Y.-W. Chao, and D. Fox. Rvt: Robotic view transformer for 3d object manipulation. In *Conference on Robot Learning*, pages 694–710. PMLR, 2023.
- [18] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi:10.15607/RSS.2023.XIX.016.
- [19] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [20] Z. Fu, T. Z. Zhao, and C. Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. In *arXiv*, 2024.
- [21] H. Walke, K. Black, A. Lee, M. J. Kim, M. Du, C. Zheng, T. Zhao, P. Hansen-Estruch, Q. Vuong, A. He, V. Myers, K. Fang, C. Finn, and S. Levine. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023.
- [22] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. S. Ryoo, G. Salazar, P. R. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. H. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich. RT-1: Robotics Transformer for Real-World Control at Scale. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi:10.15607/RSS.2023.XIX.025.
- [23] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [24] Y. LeCun, S. Chopra, R. Hadsell, M. Ranzato, and F. Huang. A tutorial on energy-based learning. *Predicting structured data*, 1(0), 2006.
- [25] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [26] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [27] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=PXTIG12RRHS>.
- [28] R. Rahmatizadeh, P. Abolghasemi, L. Bölöni, and S. Levine. Vision-based multi-task manipulation for inexpensive robots using end-to-end learning from demonstration. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 3758–3765. IEEE, 2018.

- [29] P. Florence, L. Manuelli, and R. Tedrake. Self-supervised correspondence in visuomotor policy learning. *IEEE Robotics and Automation Letters*, 5(2):492–499, 2019.
- [30] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018.
- [31] A. Nair, A. Gupta, M. Dalal, and S. Levine. Awac: Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020.
- [32] S. Ross and D. Bagnell. Efficient reductions for imitation learning. In *Proceedings of the thirteenth international conference on artificial intelligence and statistics*, pages 661–668. JMLR Workshop and Conference Proceedings, 2010.
- [33] S. Ross, G. Gordon, and D. Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, pages 627–635. JMLR Workshop and Conference Proceedings, 2011.
- [34] J. A. Vincent, H. Nishimura, M. Itkina, P. Shah, M. Schwager, and T. Kollar. How generalizable is my behavior cloning policy? a statistical approach to trustworthy performance evaluation, 2024.
- [35] A. Bajcsy, D. P. Losey, M. K. O’Malley, and A. D. Dragan. Learning from physical human corrections, one feature at a time. In *Proceedings of the 2018 ACM/IEEE International Conference on Human-Robot Interaction*, pages 141–149, 2018.
- [36] M. Kelly, C. Sidrane, K. Driggs-Campbell, and M. J. Kochenderfer. Hg-dagger: Interactive imitation learning with human experts. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 8077–8083. IEEE, 2019.
- [37] A. Mandlekar, D. Xu, R. Martín-Martín, Y. Zhu, L. Fei-Fei, and S. Savarese. Human-in-the-loop imitation learning using remote teleoperation. *CoRR*, abs/2012.06733, 2020. URL <https://arxiv.org/abs/2012.06733>.
- [38] R. Hoque, A. Balakrishna, E. Novoseller, A. Wilcox, D. S. Brown, and K. Goldberg. Thriftydagger: Budget-aware novelty and risk gating for interactive imitation learning. In A. Faust, D. Hsu, and G. Neumann, editors, *Proceedings of the 5th Conference on Robot Learning*, volume 164 of *Proceedings of Machine Learning Research*, pages 598–608. PMLR, 08–11 Nov 2022. URL <https://proceedings.mlr.press/v164/hoque22a.html>.
- [39] Y. Cui, S. Karamcheti, R. Palleti, N. Shivakumar, P. Liang, and D. Sadigh. No, to the right: Online language corrections for robotic manipulation via shared autonomy. In *Proceedings of the 2023 ACM/IEEE International Conference on Human-Robot Interaction*, pages 93–101, 2023.
- [40] A. Marco, E. Morley, and C. J. Tomlin. Out of distribution detection via domain-informed gaussian process state space models. In *2023 62nd IEEE Conference on Decision and Control (CDC)*, pages 5487–5493, 2023. doi:10.1109/CDC49753.2023.10383566.
- [41] H. Liu, S. Dass, R. Martín-Martín, and Y. Zhu. Model-based runtime monitoring with interactive imitation learning. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [42] A. Farid, D. Snyder, A. Ren, and A. Majumdar. Failure Prediction with Statistical Guarantees for Vision-Based Robot Control. In *Proceedings of Robotics: Science and Systems*, New York City, NY, USA, June 2022. doi:10.15607/RSS.2022.XVIII.042.
- [43] S. Daftry, S. Zeng, J. A. Bagnell, and M. Hebert. Introspective perception: Learning to predict failures in vision systems. *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1743–1750, 2016. URL <https://api.semanticscholar.org/CorpusID:15394788>.

- [44] S. Rabiee and J. Biswas. Ivoa: Introspective vision for obstacle avoidance. *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1230–1235, 2019. URL <https://api.semanticscholar.org/CorpusID:67855498>.
- [45] A. Inceoglu, E. E. Aksoy, A. Cihan Ak, and S. Sariel. Fino-net: A deep multimodal sensor fusion framework for manipulation failure detection. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 6841–6847, 2021. doi:10.1109/IROS51168.2021.9636455.
- [46] L. Ruff, J. R. Kauffmann, R. A. Vandermeulen, G. Montavon, W. Samek, M. Kloft, T. G. Dietterich, and K.-R. Müller. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109(5):756–795, 2021. doi:10.1109/JPROC.2021.3052449.
- [47] K. Lee, K. Lee, H. Lee, and J. Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018. URL [https://proceedings.neurips.cc/paper\\_files/paper/2018/file/abdeb6f575ac5c6676b747bca8d09cc2-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2018/file/abdeb6f575ac5c6676b747bca8d09cc2-Paper.pdf).
- [48] J. Z. Liu, Z. Lin, S. Padhy, D. Tran, T. Bedrax-Weiss, and B. Lakshminarayanan. Simple and principled uncertainty estimation with deterministic deep learning via distance awareness, 2020.
- [49] A. Sharma, N. Azizan, and M. Pavone. Sketching curvature for efficient out-of-distribution detection for deep neural networks. In C. de Campos and M. H. Maathuis, editors, *Proceedings of the Thirty-Seventh Conference on Uncertainty in Artificial Intelligence*, volume 161 of *Proceedings of Machine Learning Research*, pages 1958–1967. PMLR, 27–30 Jul 2021. URL <https://proceedings.mlr.press/v161/sharma21a.html>.
- [50] T. Migimatsu, W. Lian, J. Bohg, and S. Schaal. Symbolic state estimation with predicates for contact-rich manipulation tasks. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 1702–1709. IEEE, 2022.
- [51] P. Hegemann, T. Zechmeister, M. Grotz, K. Hitzler, and T. Asfour. Learning symbolic failure detection for grasping and mobile manipulation tasks. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4302–4309. IEEE, 2022.
- [52] M. A. Lee, M. Tan, Y. Zhu, and J. Bohg. Detect, reject, correct: Crossmodal compensation of corrupted sensors. In *2021 IEEE international conference on robotics and automation (ICRA)*, pages 909–916. IEEE, 2021.
- [53] P. Antonante, D. I. Spivak, and L. Carlone. Monitoring and diagnosability of perception systems. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 168–175, 2021. doi:10.1109/IROS51168.2021.9636497.
- [54] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. von Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill, et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*, 2021.
- [55] A. Elhafsi, R. Sinha, C. Agia, E. Schmerling, I. A. Nesnas, and M. Pavone. Semantic anomaly detection with large language models. *Autonomous Robots*, 47(8):1035–1055, 2023.
- [56] R. Sinha, A. Elhafsi, C. Agia, M. Foutter, E. Schmerling, and M. Pavone. Real-time anomaly detection and reactive planning with large language models. In *Robotics: Science and Systems*, 2024.
- [57] W. Huang, F. Xia, T. Xiao, H. Chan, J. Liang, P. Florence, A. Zeng, J. Tompson, I. Mordatch, Y. Chebotar, P. Sermanet, T. Jackson, N. Brown, L. Luu, S. Levine, K. Hausman, and b. ichter. Inner monologue: Embodied reasoning through planning with language models. In K. Liu, D. Kulic, and J. Ichnowski, editors, *Proceedings of The 6th Conference on Robot Learning*,



- volume 205 of *Proceedings of Machine Learning Research*, pages 1769–1782. PMLR, 14–18 Dec 2023. URL <https://proceedings.mlr.press/v205/huang23c.html>.
- [58] Z. Liu, A. Bahety, and S. Song. Reflect: Summarizing robot experiences for failure explanation and correction. In J. Tan, M. Toussaint, and K. Darvish, editors, *Proceedings of The 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, pages 3468–3484. PMLR, 06–09 Nov 2023. URL <https://proceedings.mlr.press/v229/liu23g.html>.
  - [59] M. Skreta, Z. Zhou, J. L. Yuan, K. Darvish, A. Aspuru-Guzik, and A. Garg. Replan: Robotic replanning with perception and language models. *arXiv preprint arXiv:2401.04157*, 2024.
  - [60] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. VIP: Towards universal visual reward and representation via value-implicit pre-training. In *The Eleventh International Conference on Learning Representations*, 2023. URL <https://openreview.net/forum?id=YJ7o2wetJ2>.
  - [61] Y. Cui, S. Niekum, A. Gupta, V. Kumar, and A. Rajeswaran. Can foundation models perform zero-shot task specification for robot manipulation? In *Learning for dynamics and control conference*, pages 893–905. PMLR, 2022.
  - [62] J. Yang, M. S. Mark, B. Vu, A. Sharma, J. Bohg, and C. Finn. Robot fine-tuning made easy: Pre-training rewards and policies for autonomous real-world reinforcement learning, 2023.
  - [63] Y. Du, K. Konyushkova, M. Denil, A. Raju, J. Landon, F. Hill, N. de Freitas, and S. Cabi. Vision-language models as success detectors. In S. Chandar, R. Pascanu, H. Sedghi, and D. Precup, editors, *Proceedings of The 2nd Conference on Lifelong Learning Agents*, volume 232 of *Proceedings of Machine Learning Research*, pages 120–136. PMLR, 22–25 Aug 2023. URL <https://proceedings.mlr.press/v232/du23b.html>.
  - [64] F. Borrelli, A. Bemporad, and M. Morari. *Predictive Control for Linear and Hybrid Systems*. Cambridge University Press, 2017.
  - [65] A. Sharma, N. Azizan, and M. Pavone. Sketching curvature for efficient out-of-distribution detection for deep neural networks. In *Uncertainty in artificial intelligence*, pages 1958–1967. PMLR, 2021.
  - [66] A. N. Angelopoulos and S. Bates. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*, 2021.
  - [67] R. Luo, S. Zhao, J. Kuck, B. Ivanovic, S. Savarese, E. Schmerling, and M. Pavone. Sample-efficient safety assurances using conformal prediction. In S. M. LaValle, J. M. O’Kane, M. Otte, D. Sadigh, and P. Tokekar, editors, *Algorithmic Foundations of Robotics XV*, pages 149–169, Cham, 2023. Springer International Publishing. ISBN 978-3-031-21090-7.
  - [68] S. Nasiriany, F. Xia, W. Yu, T. Xiao, J. Liang, I. Dasgupta, A. Xie, D. Driess, A. Wahid, Z. Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. *arXiv preprint arXiv:2402.07872*, 2024.
  - [69] J. Gao, B. Sarkar, F. Xia, T. Xiao, J. Wu, B. Ichter, A. Majumdar, and D. Sadigh. Physically grounded vision-language models for robotic manipulation. 2024.
  - [70] X. Li, M. Liu, H. Zhang, C. Yu, J. Xu, H. Wu, C. Cheang, Y. Jing, W. Zhang, H. Liu, H. Li, and T. Kong. Vision-language foundation models as effective robot imitators. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=lFYj0oibGR>.
  - [71] J. Wei, X. Wang, D. Schuurmans, M. Bosma, brian ichter, F. Xia, E. H. Chi, Q. V. Le, and D. Zhou. Chain of thought prompting elicits reasoning in large language models. In A. H. Oh, A. Agarwal, D. Belgrave, and K. Cho, editors, *Advances in Neural Information Processing Systems*, 2022. URL [https://openreview.net/forum?id=\\_VjQlMeSB\\_J](https://openreview.net/forum?id=_VjQlMeSB_J).

- [72] S. Antol, A. Agrawal, J. Lu, M. Mitchell, D. Batra, C. L. Zitnick, and D. Parikh. Vqa: Visual question answering. In *Proceedings of the IEEE international conference on computer vision*, pages 2425–2433, 2015.
- [73] J. Xu, T. Mei, T. Yao, and Y. Rui. Msr-vtt: A large video description dataset for bridging video and language. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 5288–5296, 2016.
- [74] F. Ruggiero, V. Lippiello, and B. Siciliano. Nonprehensile dynamic manipulation: A survey. *IEEE Robotics and Automation Letters*, 3(3):1711–1718, 2018.
- [75] M. S. Graham, W. H. Pinaya, P.-D. Tudosiu, P. Nachev, S. Ourselin, and J. Cardoso. Denoising diffusion models for out-of-distribution detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2947–2956, 2023.
- [76] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International conference on machine learning*, pages 2256–2265. PMLR, 2015.
- [77] A. Gretton, R. Herbrich, A. Smola, O. Bousquet, B. Schölkopf, et al. Kernel methods for measuring independence. 2005.
- [78] K. Muandet, K. Fukumizu, B. Sriperumbudur, B. Schölkopf, et al. Kernel mean embedding of distributions: A review and beyond. *Foundations and Trends® in Machine Learning*, 10(1-2): 1–141, 2017.
- [79] M. Reid, N. Savinov, D. Teplyashin, D. Lepikhin, T. Lillicrap, J.-b. Alayrac, R. Soricut, A. Lazaridou, O. Firat, J. Schrittwieser, et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *arXiv preprint arXiv:2403.05530*, 2024.
- [80] S. Pitis, M. R. Zhang, A. Wang, and J. Ba. Boosted prompt ensembles for large language models. *arXiv preprint arXiv:2304.05970*, 2023.
- [81] T. Ren, S. Liu, A. Zeng, J. Lin, K. Li, H. Cao, J. Chen, X. Huang, Y. Chen, F. Yan, et al. Grounded sam: Assembling open-world models for diverse visual tasks. *arXiv preprint arXiv:2401.14159*, 2024.
- [82] G. Pavlakos, D. Shan, I. Radosavovic, A. Kanazawa, D. Fouhey, and J. Malik. Reconstructing hands in 3d with transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9826–9836, 2024.
- [83] H. K. Cheng, S. W. Oh, B. Price, A. Schwing, and J.-Y. Lee. Tracking anything with decoupled video segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 1316–1326, 2023.
- [84] C. R. Qi, L. Yi, H. Su, and L. J. Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. *Advances in neural information processing systems*, 30, 2017.
- [85] J. Yang, Z. ang Cao, C. Deng, R. Antonova, S. Song, and J. Bohg. Equibot: Sim(3)-equivariant diffusion policy for generalizable and data efficient learning, 2024.
- [86] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [87] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.

- [88] Z. Zhao, E. Wallace, S. Feng, D. Klein, and S. Singh. Calibrate before use: Improving few-shot performance of language models. In *International conference on machine learning*, pages 12697–12706. PMLR, 2021.
- [89] B. Chen, Z. Xu, S. Kirmani, B. Ichter, D. Sadigh, L. Guibas, and F. Xia. Spatialvlm: Endowing vision-language models with spatial reasoning capabilities. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14455–14465, 2024.
- [90] A. Z. Ren, A. Dixit, A. Bodrova, S. Singh, S. Tu, N. Brown, P. Xu, L. Takayama, F. Xia, J. Varley, Z. Xu, D. Sadigh, A. Zeng, and A. Majumdar. Robots that ask for help: Uncertainty alignment for large language model planners. In *Proceedings of the Conference on Robot Learning (CoRL)*, 2023.
- [91] R. Luo, R. Sinha, Y. Sun, A. Hindy, S. Zhao, S. Savarese, E. Schmerling, and M. Pavone. Online distribution shift detection via recency prediction. In *Proceedings of the 2024 IEEE International Conference on Robotics and Automation (ICRA)*, Yokohama, Japan, 2024. IEEE.

## 附录概览：解析生成式策略的失效模式

附录提供了关于我们失效检测框架实现的更多细节（§ A）、所进行的实验（§ B）、扩展结果与分析（§ C），以及为我们提出的失效检测器提供支持的推导（§ D）。定性结果和视频摘要可在 [sites.google.com/stanford.edu/sentinel](https://sites.google.com/stanford.edu/sentinel) 获取。

### 附录 A 方法细节：Sentinel 18

|                            |    |
|----------------------------|----|
| A.1 基于 STAC 的时序一致性检测 ..... | 18 |
| A.2 利用视觉语言模型进行运行时监控 .....  | 19 |
| A.2.1 提示集成 .....           | 21 |

### 附录 B 实验细节 22

|                             |    |
|-----------------------------|----|
| B.1 环境 .....                | 22 |
| B.1.1 仿真域 .....             | 23 |
| B.1.2 真实世界域 .....           | 23 |
| B.2 扩散策略 .....              | 24 |
| B.3 基线 .....                | 24 |
| B.3.1 STAC 基线（策略级监视器） ..... | 25 |
| B.3.2 VLM 基线（任务级监视器） .....  | 27 |
| B.4 评估协议 .....              | 28 |
| B.4.1 定义：策略失败 .....         | 28 |
| B.4.2 构建校准数据集 .....         | 28 |
| B.4.3 测试与评估 .....           | 29 |
| B.4.4 报告的度量 .....           | 29 |

### 附录 C 附加结果 29

|                           |    |
|---------------------------|----|
| C.1 STAC 上的消融实验 .....     | 29 |
| C.2 扩展结果：VLM 运行时监视器 ..... | 30 |

### 附录 D 推导 33

## A 方法细节：哨兵

如图 3 所示，哨兵运行时监控框架由两个互补的故障检测器并行运行组成，每个检测器负责检测生成策略的特定故障类别。第一个是时序一致性检测器，通过统计时序动作一致性（STAC）测度监控策略的异常行为。第二个是视觉语言模型

（VLM），用于监控策略在任务上未能取得进展的故障。在本节中，我们提供关于 STAC 实现（§ A.1）和 VLM 运行时监控器（§ A.2）的额外细节。

### A.1 使用 STAC 进行时序一致性检测

**背景** 总结 § 3，STAC 假设使用随机策略  $\pi$ ，在每个策略推理时间步  $t$ ，预测接下来  $h$  个时间步的动作序列，同时  $a_{t:t+h-1|t} \sim \pi(\cdot|s_t)$ ，执行前  $k$  个动作  $a_{t:t+k|t}$ ，然后在时间步  $t+k$  重新评估策略。在两个连续的推理时间步  $t$  和  $t+k$  之间，采样的动作序列  $a_{t+k:t+h-1|t}$  和  $a_{t+k:t+h-1|t+k}$  和（两者均在  $\mathbb{R}^{(h-k) \times |\mathcal{A}|}$  中）重叠  $h-k$  个时间步。从高层来看，STAC 旨在量化生成式策略的动作分布随时间变化的程度。它通过计算重叠动作分布之间的统计距离来实现这一点，即给定  $\tilde{\pi}_t := \pi(a_{t+k:t+h-1|t}|s_t)$  和  $\tilde{\pi}_{t+k} := \pi(a_{t+k:t+h-1|t+k}|s_{t+k})$ ，我们计算  $D(\tilde{\pi}_t, \tilde{\pi}_{t+k})$ 。

**假设** 我们的核心假设是，较大的统计距离与下游策略失效相关。直观上，预测性策略可类比为拥有一个内部世界模型，该模型模拟机器人动作如何影响环境状态。当策略处于分布内时，我们期望这个世界模型是准确的，从而产生较小的统计距离。更具体地说，如果策略在时间步  $t$  对状态  $s_{t+k}$  的内部模型与实际观察到的时间步  $t+k$  的状态  $s_{t+k}$  一致，那么动作  $\tilde{\pi}_{t+k}$  的分布应能很好地由分布  $\tilde{\pi}_t$  表示，因此距离  $D(\tilde{\pi}_t, \tilde{\pi}_{t+k})$  将很小（对于合适的统计距离函数  $D$  的选择）。相反，当策略处于分布外（OOD）时，其在时间步  $t$  对状态  $s_{t+k}$  的内部模型可能不准确，导致  $\tilde{\pi}_t$  与  $\tilde{\pi}_{t+k}$  之间出现发散，从而产生更大的统计距离。

**实现细节** 如第 4.1 节所述，我们提出用经验距离函数  $\hat{D}$  来近似  $D(\tilde{\pi}_t, \tilde{\pi}_{t+k})$ ，而不是解析计算，因为这样做面临将非重叠动作（时间步  $t$  与  $t+k$  之间）和扩散过程的中间步骤 [76] 边缘化的挑战。我们发现以下近似方法在实践中效果良好：

- 使用径向基函数（RBF）核的最大均值差异（MMD）。我们计算

$$\begin{aligned} \hat{D}(\tilde{\pi}_t, \tilde{\pi}_{t+k}) = & \mathbb{E}_{a_t, a'_t \sim \tilde{\pi}_t} [k(a_t, a'_t)] + \mathbb{E}_{a_{t+k}, a'_{t+k} \sim \tilde{\pi}_{t+k}} [k(a_{t+k}, a'_{t+k})] \\ & - 2\mathbb{E}_{a_t \sim \tilde{\pi}_t, a_{t+k} \sim \tilde{\pi}_{t+k}} [k(a_t, a_{t+k})], \quad \text{其中} \quad k(x, y; \beta_1) = \exp\left(-\frac{\|x-y\|^2}{\beta_1}\right). \end{aligned}$$

此处， $k: \mathbb{R}^{(h-k) \times |\mathcal{A}|} \times \mathbb{R}^{(h-k) \times |\mathcal{A}|} \rightarrow \mathbb{R}$  计算两个重叠动作序列之间的相似度， $\beta_1$  表示径向基核函数的带宽。期望是在从生成策略中采样的一批  $B$  个动作序列上取得的。

- 通过策略分布的核密度估计（KDE）计算前向 KL 散度：

$$\hat{D}(\tilde{\pi}_t, \tilde{\pi}_{t+k}) = \mathbb{E}_{a_{t+k} \sim \tilde{\pi}_{t+k}} \left[ \log \frac{p(a_{t+k})}{q(a_{t+k})} \right],$$

其中  $p$  和  $q$  分别是  $\tilde{\pi}_{t+k}$  和  $\tilde{\pi}_t$  的核密度估计，它们是在从每个策略分布中采样的一批  $B$  个动作序列上拟合的。如前所述，我们使用形式为  $k(x, y; \beta_2)$  的高斯径向基核函数，其中  $\beta_2$  表示用于核密度估计的径向基核函数的带宽。



- 通过策略分布的核密度估计计算反向 KL 散度：

$$\hat{D}(\tilde{\pi}_t, \tilde{\pi}_{t+k}) = \mathbb{E}_{a_t \sim \tilde{\pi}_t} \left[ \log \frac{p(a_t)}{q(a_t)} \right],$$

其中  $p$  和  $q$  分别是  $\tilde{\pi}_t$  和  $\tilde{\pi}_{t+k}$  的核密度估计，它们是在从每个分布中采样的一批  $B$  个动作序列上拟合的，所有其他参数遵循前向 KL 散度的定义。

**超参数** 批大小  $B$ 、最大均值差异带宽  $\beta_1$  和核密度估计带宽  $\beta_2$  是我们为给定环境选择的超参数。正如预期的那样，我们发现在具有更高多模态程度的领域中（例如，PushT 和 Push Chair 的  $B=256$  个动作序列），需要更大的批大小才能获得准确的均值嵌入和密度估计。我们还发现，使用默认设置或动态校准技术足以分别获得合适的最大均值差异和核密度估计带宽参数  $\beta_1$  和  $\beta_2$ 。例如，在多模态领域中，将  $\beta_2$  设置为与从  $\tilde{\pi}_t$  和  $\tilde{\pi}_{t+k}$  采样的重叠动作  $a_{t+k:t+h-1}$  的协方差的最大特征值成比例，效果良好。有关超参数的更多详细信息见表 3。

| Hyperparameters                   | PushT (↑ Multimodality)                            | Close Box & Cover Object (↓ Multimodality) | Push Chair (↑ Multimodality)                       |
|-----------------------------------|----------------------------------------------------|--------------------------------------------|----------------------------------------------------|
| MMD + KDE batch size ( $B$ )      | 256                                                | 32                                         | 256                                                |
| MMD bandwidth ( $\beta_1$ )       | Median Heuristic [77, 78]                          | $1.0/ A $                                  | Median Heuristic                                   |
| KDE bandwidth ( $\beta_2$ )       | $\sqrt{\lambda_{\max}(\text{Cov}(a_{t+k:t+h-1}))}$ | 1.0                                        | $\sqrt{\lambda_{\max}(\text{Cov}(a_{t+k:t+h-1}))}$ |
| Policy action space ( $A$ )       | Linear Velocity                                    | 2 x (Linear + Angular Velocity)            | 1 x (Linear + Angular Velocity)                    |
| Policy prediction horizon ( $h$ ) | 16                                                 | 16                                         | 16                                                 |
| Policy execution horizon ( $k$ )  | 8                                                  | 4                                          | 4                                                  |

表 3：使用 STAC 进行时序一致性检测的超参数设置。

**额外的设计选择** 有若干额外设置可调整，以提升 STAC 在特定任务上的检测性能。首先，过滤策略动作空间中噪声较大或离散的分量，可提高统计距离评分函数的质量。例如，在我们的机器人操作器领域中，策略的动作空间包含末端执行器的线速度和角速度，以及一个二值夹爪指令。然而，在计算统计距离时，我们省略所有二值夹爪指令。其次，缩短生成策略的执行时域  $k$ ，以比较时间上更接近的动作分布，可缓解高动态或随机环境中过大的统计距离。同样，若预测动作序列的尾部（例如）表现出高方差，则采用更短的预测时域  $h$  来比较动作分布可能更为合适。

## A.2 基于视觉语言模型的运行时监控

如第 4.2 节所述，我们将任务进展失败的检测表述为一种思维链

（思维链）[71]，视频问答（Video QA）[73] 任务与视觉语言模型。下文将详细介绍视觉语言模型运行时监控器的实现细节，以及实验中使用的提示模板。

**视觉语言模型** 在扩展实验（§ C.2）中，我们纳入了基于多种模型的视觉语言模型（VLM）运行时监控器的变体：OpenAI 的 GPT-4o、Anthropic 的 Claude 3.5 Sonnet 以及 Google 的 Gemini 1.5 Pro [79]。在撰写本文时，这些模型代表了当前用于复杂多模态推理任务的最先进的视觉语言模型。我们对所有模型使用一致的提示，然而，我们略微调整了监控器的实现，以反映每个视觉语言模型建议的最佳实践。

**实现细节** 本文提出在线查询视觉语言模型（VLM），使用解析后的文本提示描述运行时监控任务以及机器人摄像系统截至当前时间步所捕获的图像历史（即视频） $I_{0:t} := (I_0, I_{\nu k}, I_{2\nu k}, \dots, I_t)$   $t$ 。其中，超参数  $\nu$  指定图像相对于生成式策略（§ 3）执行范围  $k$  的频率，以保证通用性，因为视频的捕获帧率可能远高于策略的执行速率。在实验中，仅设置  $\nu \in \{1, 2\}$  即可为 VLM 识别机器人运动提供足够的粒度。

通过进行非阻塞应用程序编程接口（API）调用，VLM 运行时监控器能够以相对较高的频率运行。例如，可以在每个策略推理时间步  $t = jk$  查询 VLM，以  $j \in \{0, 1, \dots\}$  (i.e., (在 STAC 的检测频率下) 提供故障分类。然而，根据任务的不同，这样做可能既不必要也不可取，原因有二。首先，由于任务进展故障可能发生在比异常故障更长的时间尺度上，以降低的频率查询 VLM 可能为状态发生有意义的变化留出时间。反过来，这将减少 VLM 预测中的冗余，例如，如果自上次查询以来没有发生有意义的状态变化。其次，虽然 STAC——一种统计输出监控器——可以以可忽略的成本（计算上和金钱上）进行评估，但查询最先进的闭源 VLM 可能带来相当大的开销。由于任务进展故障不太可能需要立即干预（与异常故障相比），以低于 STAC 的频率查询 VLM 可能更为可取。在实验中，我们每个回合查询 VLM 两次以检测任务进展故障。

提示模板由三部分组成：1) 简要描述 VLM 作为机器人操作臂系统运行时监控器的角色，它必须通过分析所附视频来执行该角色；2) 描述机器人的任务、已经过去的总时间  $\tau$  以及任务的时间限制（对应于 § 3 中的马尔可夫决策过程（MDP）范围  $H$ ）；3) 指示引出思维链（CoT）响应，确保 VLM 描述并分析机器人及所有与任务相关的物体的运动，并输出一个易于解析的分类。为了消除对机器人预期行为以及什么构成任务完成的歧义，我们确保任务描述足够详细：

```
task_descriptions:
  cover: "hide the white box by covering it with the black blanket. The white box
    位于两个机械臂前方的某个位置且不移动。黑色毯子起始于两个机械臂正中间" 关闭: "通过折入两
    个较小的白色侧盖来关闭白色盒子，并且

    更大的白色后盖。白色盒子位于两个机械臂之间且不移动。机械臂应同时靠近侧盖并将两个侧盖向
    上推，随后靠近后盖并用双臂折叠后盖，且不通过夹爪抓取盖子" push_chair: "将黑色椅子推入圆
    形桌子。黑色椅子

    starts directly in front of the robot. The robot should push black chair in

    一条相对笔直的线，椅子不向左或向右旋转，使椅座恰好收在圆桌下方"
```

我们从视觉语言模型（VLM）中引出四步思维链响应：1) 生成一组与任务相关的问题，这些问题的正确答案将充分刻画视频中机器人及所有任务相关物体的运动；2) 回答这些任务相关问题，同时提供细粒度的视觉细节；3) 分析问题、答案和已用时间，以判断机器人在回合时间限制内是否正朝着任务完成取得进展；4) 最终给出整体分类，结果为 {ok, 失败}。有趣的是，我们发现提示视觉语言模型自行生成问题，而非人工指定问题，能够获得对视频更准确的描述以及后续预测。

### Prompt Template (Video QA)

```
You are the runtime monitor for an autonomous mobile manipulator robot capable
    解决常见家务任务。摄像系统在线捕捉机器人执行当前任务时的一系列图像帧（即视频）。

    图像帧以约 1Hz 的频率捕获。作为运行时监视器，你的任务是分析视频并判断机器人是否 a) 处于
```

2 在线运行时监控要求视觉语言模型（VLM）区分以下两种情况：a) 机器人仍在正确执行任务的过程中（即部分进展），还是 b) 机器人将无法完成任务（例如，停滞在部分完成状态）。对于移动缓慢的机器人，区分部分进展与任务失败可能具有模糊性，因此，向视觉语言模型提供当前已用时间可作为参考，以判断机器人执行任务的速率是否会导致任务及时完成。

执行任务的进展，或 b) 未能执行任务，例如行为不当或不安全。

The robot's current task is to {DESCRIPTION}. The robot may take up to {  
TIME\_LIMIT} 秒完成此任务。当前已用时间为 {TIME} 秒。

Format your output in the following form:  
[start of output]

Questions: First, generate a set of task-relevant questions that will enable you  
理解机器人及所有任务相关物体在伴随视频中从始至终的完整、详细运动。答案：其次，精确回答  
生成的问题，提供精细的

细粒度的视觉细节，有助于准确评估任务当前进展状态。分析：判断机器人是否明显未能完成  
任务。由于

video only represents the robot's progress up to the current timestep and  
the robot moves slowly, refrain from making a failure classification unless  
the robot is unlikely to complete the task in the allotted time. Explicitly  
note the amount of time that has passed in seconds and compare it with the  
time limit (e.g., x out of {TIME\_LIMIT} seconds). Finally, based on the  
questions, answers, analysis, and elapsed time, decide whether the robot is  
in progress, or whether the robot will fail to complete its task in the  
remaining time (if any).

Overall assessment: {CHOICE: [ok, failure]}  
[end of output]

Rules:

1. If you see phrases like {CHOICE: [choice1, choice2]}, it means you should

将整个短语替换为所列选项之一。例如，当选择选项 B 时，将整个短语“{CHOICE: [A, B]}”替换为“B”。

请勿将您的选择置于“{”“}”括号内。若您对数值不确定，请依据最佳判断。2. 请勿忘记在分析结尾  
给出总体评估。如

indicated above with '{CHOICE: [ok, failure]}', your only options for the  
overall assessment are 'ok' or 'failure'.

3. Always start the output with [start of output] and end the output with [end of  
output].

## A.2.1 提示集成

视频问答失败检测任务需要对可能很长的图像序列进行全面而细致的推理，这在撰写本文时，即使  
对最强大的视觉语言模型（VLM）来说也是一个挑战。因此，当视觉语言模型运行时监控器部署在  
相对于其训练数据视觉上分布外（OOD）的领域（例如，仿真渲染的图像或从异常相机姿态捕获  
的图像）时，其性能预计会下降。在这些场景下，视觉语言模型运行时监控器可能对任务进展失败  
提供合理但不完美的信号，从而导致误分类。

为增强视觉语言模型运行时监控器的可靠性，本文提出一种简单的提示集成策略 [80]，即构建多个  
视频问答提示，逐一查询视觉语言模型，并将所有提示预测结果的多数投票作为整体故障分类。直  
观上，若各提示对应的故障检测器初始准确度较高，则多数投票检测器的正确概率将进一步提升。

在实验中，我们发现仅在覆盖物体（Cover Object）领域需要使用提示集成。我们构建了视频问答  
提示的两种变体（共 3 个提示），每种变体都遵循类似的思维链结构，同时包含额外信息以多样  
化视觉语言模型的推理。第一种提示变体，视频问答 + 成功视频，包含当前任务成功策略执行的  
视频。这使得视觉语言模型能够在测试时区分异常策略行为与示例视频中展示的正常策略行为。  
第二种提示变体，视频问答 + 目标图像，

包含成功策略执行结束时场景的示例图像，作为任务完成的视觉参考。根据我们框架的假设，这些提示变体仅需要与策略成功相关的数据，即可在测试时检测未知失败。

### Prompt Template (Video QA + Success Video)

You are the runtime monitor... # Same as Video QA

To inform your analysis, you will be provided with an example video that shows  
当任务成功执行时，机器人及所有任务相关物体的完整运动。例如，示例视频中的最后一帧图像将展示成功执行任务结束时场景应有的样子。

通过将当前视频与示例视频进行比较，您可能能够从视觉上区分机器人是在任务中失败，还是在稳步推进或已经完成。

The robot's current task is... # Same as Video QA

Questions: First, generate a set of task-relevant questions that will enable you  
理解伴随视频中机器人及所有任务相关物体从开始到结束的完整、详细运动。此外，  
生成问题，使您能够识别当前视频与示例成功视频之间的任何关键相似之处或差异。答案：其次，精确回答…… # 与视频问答相同

### Prompt Template (Video QA + Goal Images)

You are the runtime monitor... # Same as Video QA

To inform your analysis, you will be provided with several example images that  
展示成功执行任务结束时场景（即机器人及所有任务相关物体）应有的样子。通过将当前视频的最后几帧图像与这些示例图像进行比较，您可能能够从视觉上区分机器人是在任务中失败，还是在稳步推进或已经完成。


The robot's current task is... # Same as Video QA

Questions: First, generate a set of task-relevant questions that will enable you  
理解伴随视频中机器人及所有任务相关物体从开始到结束的完整、详细运动。此外，  
生成问题，使您能够识别当前视频与成功完成任务示例图像之间的任何关键相似之处或差异。答案：其次，精确回答…… # 与视频问答相同

## B 实验细节

### B.1 环境

我们提供了用于评估哨兵（Sentinel）的环境的额外细节。这些环境在数据分布（例如，多模态或高维动作）方面有所不同，并支持不同类型的分布偏移（例如，物体尺度、姿态、动力学），在这些条件下可以系统地研究生成式扩散策略的行为。这些环境在图 7 中可视化。



**图 7：评估领域。**我们在三个仿真领域和一个真实世界领域中评估我们的失败检测框架。这些领域覆盖了不同的数据分布（例如，动作多模态、高维动作）和生成式策略失败的模式。例如，生成式策略在“关闭盒子”领域中倾向于无规律地失败，而在“覆盖物体”领域中则平滑地失败。有效的失败检测器应在多个领域中表现良好，这需要覆盖异构的失败模式。

### B.1.1 仿真领域

**推动 T 形物体领域** 策略的任务是将一个平面“T”形物体推入目标构型。如果在 300 个环境步骤内，“T”形物体与其目标的重叠超过 90%，则轨迹被视为成功。动作空间是末端执行器的 2 自由度线速度。我们通过对“T”形物体的尺度和尺寸进行非均匀随机化，超出策略演示数据中包含的随机化范围，来生成分布外测试场景。策略倾向于收敛到局部最优构型而失败，此时“T”与目标重叠但方向不正确。由于该任务可以通过多种方式解决，我们包含此领域以评估各种评分函数在动作多模态存在时的性能。关于该领域演示数据的生成过程，我们参考 [1]。

**关闭盒子领域** 该策略的任务是关闭一个有三个盖子的箱子。若在 120 个环境步（24 秒）内三个盖子全部关闭，则轨迹视为成功。动作空间为两台移动机械臂末端执行器的 14 自由度线速度、角速度及夹爪指令。演示数据由一种基于初始状态为末端执行器设置一系列路径点的专家策略生成。我们通过对箱子尺寸进行非均匀随机化（超出策略演示数据中包含的随机化范围）来生成分布外测试场景。当机器人例如与箱子或其盖子发生碰撞时，策略往往会出现无规律失败，但也可能发生任务进展失败。该领域主要用于评估在高维动作空间的双机械臂机器人系统上对无规律策略失败的检测。

**覆盖物体领域** 该策略的任务是用布覆盖一个刚性物体。若在 64 个环境步（13 秒）内物体被布覆盖的比例超过 75%，则轨迹视为成功。动作空间和演示数据生成过程与

**关闭箱子** 相同。我们通过对物体位置进行非均匀随机化（超出策略演示数据中包含的随机化范围）来生成分布外测试场景。策略往往在到达物体之前就释放覆盖物而导致失败。因此，该领域用于评估任务进展失败的检测，其中需要更长时间的推理来评估任务进展。

### B.1.2 真实世界领域

**移动机器人设置** 我们使用配备 Kinova Gen3 7 自由度机械臂的全向移动底座。工作空间中固定一台 ZED 2 相机，用于为生成式策略捕获视觉观测。ZED 2 相机首先生成环境的局部视图点云，然后我们使用基于自然语言的 Grounded Segment Anything Model [81] 从中分割出与任务相关的物体。

与任务相关的语言描述。分割后的点云作为策略的视觉输入。此外，我们使用运动捕捉系统跟踪移动基座的位姿。在评估过程中，策略处理点云，预测 16 个动作的序列，其中前 4 个在机器人上执行。然后，移动操作机器人根据这些命令操纵其手臂，如果末端执行器移出预定义的工作空间，则调整基座的位姿。

**推椅子领域** 策略的任务是使用单臂移动操作平台将椅子推入桌下。如果在策略执行结束时，椅子的座位被正确地推到桌子下面，则轨迹被视为成功。动作空间是移动操作机器人末端执行器的 7 自由度线速度和角速度以及夹爪命令。演示数据从人类视频中提取：我们使用现成的手部检测模型 [82]、物体分割模型 [83, 81] 和立体到深度模型，从 15 个人类演示视频中的每个视频的子采样帧中提取人手位姿和物体点云。我们通过随机化椅子的初始位姿（超出演示数据中包含的随机化范围）来生成分布外测试场景。如果椅子在推动时向任一方向旋转离开，策略往往会不稳定地失败，但这种失败在视觉上也很明显。因此，该任务用于在动态复杂 [74] 的真实世界环境中测试 STAC 和视觉语言模型运行时监视器的有效性。

## B.2 扩散策略

我们为每个环境训练一个扩散策略（DP），在 PushT 领域使用 200 个演示，在 Close Box 和 Cover Object 领域各使用 50 个演示，在真实世界的 Push Chair 领域使用 15 个演示。在 DP 中，动作是通过在  $N$  步上去噪初始随机动作  $a_t^N \sim \mathcal{N}(0,1)$  生成的，如  $a_t^N, \dots, a_t^0$  所示，其中带有上标  $i$  的  $a_t^i$  表示在第  $i$  次去噪迭代时生成的动作序列。在模仿学习设置中，DP 的噪声预测网络  $\epsilon_\theta$  被训练来预测添加到从专家演示数据集  $\mathcal{D}_{\text{train}}$  中抽取的动作上的随机噪声  $\epsilon^i$ ，通过最小化

$$\mathcal{L}_{\text{ddpm}} := \mathbb{E}_{(s,a^0) \sim \mathcal{D}_{\text{train}}, \epsilon^i, i} [\|\epsilon^i - \epsilon_\theta(\sqrt{\bar{\alpha}_i}a^0 + \sqrt{1-\bar{\alpha}_i}\epsilon^i, s, i)\|^2], \quad (2)$$

其中常数  $\bar{\alpha}_i$  取决于所选择的扩散过程噪声调度。

为了提高分布偏移相对于物体位置和尺度的显著性，我们使用点云而非 RGB 图像作为策略的输入（例如，物体尺度增加 5% 在图像中可能不显著）。在仿真实验中，我们采用与原文 [1] 相同的扩散策略架构，但视觉编码器不同：将基于 ResNet 的编码器替换为基于 PointNet 的编码器——一个 4 层 PointNet++ 编码器 [84]，隐藏维度为 128。该编码器的输出与本体感受输入拼接后输入噪声预测网络。在真实世界实验中，我们使用最近提出的 EquiBot 扩散策略架构 [85]，该架构额外将 SIM(3) 等变性融入扩散过程。我们使用 EquiBot 在当前最先进的真实世界生成策略学习方法上评估我们的失败检测器。所有扩散策略在  $N=100$  次去噪迭代中生成动作。除非另有说明，我们使用扩散策略预测  $h$  和执行时域  $k$  的标准设置。

## B.3 基线

我们概述第 5 节中引入的基线的实现细节。首先，除 VLM 运行时监视器外，所有评估的失败检测方法都包括：在每次策略推理时间步计算得分  $S(\cdot)$ ，对截至当前时间步的得分求累积和  $t$ ，然后检查累积和是否超过校准阈值以检测策略失败。因此，基线的区别在于其得分函数，即如何计算逐时间步得分，然后求和并阈值化。直观上，好的得分函数应与策略失败高度相关，即在策略成功时输出小值，失败时输出大值。例如，图 4 展示了 STAC 具有这一性质。我们



与一系列广泛的得分函数进行基线对比，其中一些是我们针对生成式扩散策略新引入的，另一些是 OOD 检测文献中常见的 [7]。

### B.3.1 STAC 基线（策略级监视器）

- 策略编码器嵌入量化了当前点云观测  $o_t$  w.r.t. 与  $M$  次成功策略执行的校准数据集中点云的差异  $\mathcal{D}_\tau = \{o_{\tau^i}\}_{i=1}^M$ （如 §3 所述），在策略编码器的嵌入空间内（此处  $o_t$  表示输入策略的点云，包括当前时刻和前一时刻的点云）。更具体地，设  $E$  为策略的编码器， $z_t = E(o_t)$  为当前点云嵌入， $\mathcal{D}_z = E(\mathcal{D}_\tau)$  为校准数据集中所有点云的嵌入。我们计算每个时间步的分数为马氏距离

$$S(z_t; \mathcal{D}_z) = \sqrt{(z_t - \mu_z)^T \Sigma_{zz}^{-1} (z_t - \mu_z)}, \quad (3)$$

其中  $\mu_z$  是  $\mathcal{D}_z$  中嵌入的均值， $\Sigma_{zz}$  是协方差。在测试时，如果累积分数  $\eta_t$  超过校准的检测阈值  $\gamma$ ，我们发出故障警告

$$\eta_t > \gamma, \quad \text{其中} \quad \eta_t = \sum_{i=0}^{j-1} S(z_i; \mathcal{D}_z), \quad t = jk.$$

此处， $\gamma$  设为校准轨迹  $\{o_{\tau^i}\}_{i=1}^M$  上累积分数的  $1 - \delta$  分位数，其中  $\tau^i \in \mathcal{D}_\tau$ 。重要的是，在计算校准分数时  $\eta^i$ ，我们采用留一轨迹法：即对于点云  $o_t \in \tau^i$ ，其中  $\tau^i \in \mathcal{D}_\tau$ ，我们计算每个时间步的分数为  $S(E(o_t); E(\mathcal{D}_\tau \setminus \tau^i))$ 。这确保了观测  $o_t$  的差异是相对于除自身轨迹之外的其他轨迹计算的，这 a) 与测试时计算分数的方式一致，b) 确保校准分数不会过低。我们尝试了公式 3 中马氏距离的替代方案，将其替换为基于余弦相似度和 L2 距离度量的前  $k$  个分数，其中  $k \in \{1, 5, 10\}$ 。然而，我们发现马氏距离最为稳定。我们还评估了该基线的变体，计算完整策略状态  $s_t$ （包括点云嵌入和机器人末端执行器位姿）的差异，但发现性能相当。

- CLIP 预训练嵌入** 量化当前图像观测

$I_t$  w.r.t. 与校准数据集中图像在预训练 CLIP 编码器 [86] 嵌入空间内的差异。分数函数（公式 3）和校准过程与策略编码器嵌入相同。重要的是，此处使用的编码器采用表示学习目标训练，从而产生结构化的嵌入空间和更具可解释性的嵌入相似度分数。在我们的实验中，我们使用开源 clip-vit-base-patch32 版本的 CLIP，未进行任何微调。

- ResNet 预训练嵌入** 与 CLIP 预训练嵌入相同，不同之处在于它使用 ResNet18 预训练模型的嵌入来量化图像空间的不相似性 [87]。

- 时序非分布最小值** 与 STAC（§ A.1）类似，它旨在计算重叠动作  $a_{t+k:t+h-1|t}$  和  $a_{t+k:t+h-1|t+k}$  之间的一致性得分，这些动作分别从生成策略在连续策略推理时间步  $t$  和  $t+k$ ，采样得到。然而，它通过使用非统计距离函数来实现。具体而言，该基线在时间步  $t+k$  计算逐时间步的时序一致性得分

$$S(s_{t+k}) = \min_{b \in \{1 \dots B\}} \left\| a_{t+k:t+h-1|t} - a_{t+k:t+h-1|t+k}^b \right\|,$$

其中  $a_{t+k:t+h-1|t+k}^b \sim \tilde{\pi}_{t+k}(\cdot | s_{t+k})$ 。也就是说，我们在时间步  $t+k$  采样一批  $B$  个动作序列，计算它们与先前执行的动作序列  $a_{t+k:t+h-1|t}$  的重叠动作之间的 L2 距离，并返回与最相似动作序列对应的 L2 距离。直观上，该基线试图在时间步  $t+k$  找到与先前执行的动作序列最接近的动作序列，而 STAC 则试图量化

时间步  $t+k$  的动作分布  $\tilde{\pi}_{t+k}$  在时间步  $t$  的分布  $\tilde{\pi}_t$  中的表示程度。 $\beta$  的值见表 3。该基线的校准和运行时过程与 STAC (§ 4.1) 相同。

- **扩散重建** 将 Graham 等人 [75] 的基于扩散的 OOD 检测方法适配到扩散策略场景。具体而言，该基线计算从扩散策略采样的重新加噪动作序列上的重建误差为

$$S(s_t) = \mathbb{E}_{a^0 \sim \pi(\cdot|s_t), \epsilon^i, i} \left[ \left\| a^0 - \epsilon_{\theta}^{i:0} (\sqrt{\bar{\alpha}_i} a^0 + \sqrt{1 - \bar{\alpha}_i} \epsilon^i, s_t) \right\|^2 \right], \quad (4)$$

其中  $\epsilon_{\theta}^{i:0}$  表示从第  $i$  个去噪迭代到第 0-th 个迭代的反向扩散过程，从而得到重建动作。我们通过从扩散策略采样的一批  $\beta = 256$  个动作序列来近似式 4 中的期望，每个序列重新加噪  $i \in \{5, 10, 25, 50\}$  个前向扩散步骤（也称为重建深度）。我们尝试了多组重建深度，发现性能相当。我们注意到该基线计算开销显著，因为它需要多次执行去噪过程：即，如果我们想计算  $R$  个重建，该基线大约比单次反向扩散过程昂贵  $R$  倍。该基线的校准和运行时过程与 STAC (§ 4.1) 相同。

- **时序扩散重建** 是扩散重建的一种时序变体，同样在从扩散策略采样的重新加噪动作序列上计算重建误差，但以先前状态  $s_t$  为条件重建动作序列，即

$$S(s_t, s_{t+k}) = \mathbb{E}_{a_{t+k:t+h-1|t+k}^0 \sim \tilde{\pi}_{t+k}, \epsilon^i, i} \left[ \left\| \hat{a}^0 - \epsilon_{\theta}^{i:0} (\sqrt{\bar{\alpha}_i} \hat{a}^0 + \sqrt{1 - \bar{\alpha}_i} \epsilon^i, s_t) \right\|^2 \right].$$

此处， $\hat{a}^0$  表示计算重建所依据的动作序列，将时间步  $t$  采样的前  $k$  个（已执行）动作与时间步  $t+k$  采样的后续  $h-k$  个（预测）动作拼接：即  $\hat{a}^0 = a_{t:t+k|t} \oplus a_{t+k:t+h-1|t+k}^0$ 。此步骤是必要的，以确保以  $s_t$  为条件的去噪过程仅考虑策略预测范围内的动作。该基线代表了时序一致性的另一种形式。直观上，它询问在时间步  $t+k$  采样的动作序列是否也会在时间步  $t$  被采样，若策略处于分布内则答案很可能为是，若策略处于分布外则很可能为否——因为以  $s_t$  与  $s_{t+k}$  为条件的边缘分布可能不同。该基线的超参数遵循扩散重建的设置。

- **去噪扩散概率模型损失** 在从扩散策略采样的重新加噪动作序列上计算经验去噪扩散概率模型损失，即

$$S(s_t) = \mathbb{E}_{a^0 \sim \pi(\cdot|s_t), \epsilon^i, i} \left[ \left\| \epsilon^i - \epsilon_{\theta} (\sqrt{\bar{\alpha}_i} a^0 + \sqrt{1 - \bar{\alpha}_i} \epsilon^i, s_t, i) \right\|^2 \right].$$

此处，期望取自一批  $\beta = 256$  个采样动作序列和 10 个采样去噪迭代  $i \sim \mathcal{U}[0, N]$ ，其中  $N$  为去噪迭代总数 (§ B.2)。可将该基线视为扩散重建的更高效版本，因为它直接量化扩散策略在其训练任务上的性能，而无需在大量去噪迭代中重建动作。该基线的校准与运行时程序与 STAC (§ 4.1) 相同。

- **时序去噪扩散概率模型损失** 是去噪扩散概率模型损失的一种时序变体，同样在从扩散策略采样的重新加噪动作序列上计算经验去噪扩散概率模型损失，但以先前状态  $s_t$  为条件，即

$$S(s_t, s_{t+k}) = \mathbb{E}_{a_{t+k:t+h-1|t+k}^0 \sim \tilde{\pi}_{t+k}, \epsilon^i, i} \left[ \left\| \epsilon^i - \epsilon_{\theta} (\sqrt{\bar{\alpha}_i} \hat{a}^0 + \sqrt{1 - \bar{\alpha}_i} \epsilon^i, s_t, i) \right\|^2 \right],$$

其中  $\hat{a}^0 = a_{t:t+k|t} \oplus a_{t+k:t+h-1|t+k}^0$  (如时序扩散重建中所定义) ).

该基线的超参数遵循去噪扩散概率模型损失 (DDPM Loss) 的超参数，预期通过时序一致性提供优势。

- **扩散输出方差** 计算从扩散策略采样的  $B$  动作序列的方差，并依据校准数据集  $\mathcal{D}_\tau$  上样本方差的  $1-\delta$  分位数进行阈值判定。该基线反映了时序一致性之外的另一种输出度量，可用于监测策略失效。虽然计算输出方差可能与集成方法 [12] 相似，但需注意该方法并未量化认知模型不确定性。要做到这一点，需要训练多个扩散策略并在测试时逐一推理，由于计算开销较大，本文未采用。该基线的超参数与时空异常检测 (STAC) 相同 (见表 3)。

**基线讨论** 首先，本文强调基于嵌入的方法仅根据当前状态的差异性或不典型性来预测失效。因此，这些基线不具备策略感知能力：它们可能对与校准数据集  $\mathcal{D}_\tau$  中状态不同的状态发出失效警告，却不了解策略在这些状态下的行为。在某些情况下，策略仍可能成功或泛化到状态的轻微分布偏移，导致这些基线的检测性能显著下降。基于重建的方法可能考虑策略的泛化特性，但计算开销较大，可能无法用于实时场景。去噪扩散概率模型损失方法作为时空异常检测的次优替代方案，其评分函数与扩散策略的训练任务一致，且计算开销可忽略不计。然而，本文指出去噪扩散概率模型损失基线仅适用于扩散策略，而时空异常检测与生成式策略的具体形式无关。

### B.3.2 视觉语言模型基线（任务级监测器）

如第 4.2 节所述，本文提出通过零样本提示视觉语言模型 (VLM) 分析机器人执行至当前时间步的视频，以监控生成式策略的任务进展。我们将视频问答 (Video QA) 方法的性能与一种变体——图像问答 (Image QA) 进行对比，后者仅使用  $I_t$ ，即当前时间步记录的图像  $t$ ，而非完整视频  $I_{0:t}$  来查询视觉语言模型。该基线用于评估基于视频的推理相较于单张图像的重要性。我们通过如下所示对视频问答提示 (§ A.2) 进行最小修改来构建图像问答提示：

#### Prompt Template (Image QA)

You are the runtime monitor for an autonomous mobile manipulator robot capable of solving common household tasks. A camera system captures image frames (at approximately 1Hz) of the robot executing its current task online. As a runtime monitor, your job is to analyze the most recent image frame and identify whether the robot is a) in progress of executing the task or b) failing to execute the task, for example, by acting incorrectly or unsafely.

The robot's current task is to {DESCRIPTION}. The robot may take up to {TIME\_LIMIT} 秒完成此任务。当前已用时间为 {TIME} 秒。

Format your output in the following form:

[start of output]

Questions: First, generate a set of task-relevant questions that will enable you

彻底分析图像帧，识别机器人迄今已采取的动作。答案：其次，精确回答生成的问题，提供细粒度

细粒度的视觉细节，有助于准确评估任务当前进展状态。分析：判断机器人是否明显未能完成任务。由于

图像帧仅代表机器人截至当前时间步的进展，且机器人移动缓慢，除非机器人采取不安全动作或不太可能在规定时间内完成任务，否则不要做出失败分类。明确注明已过去的时间（以秒为单位），并将其与时间限制进行比较（例如，{TIME\_LIMIT} 中的  $x$ ）

```

seconds). Finally, based on the questions, answers, analysis, and elapsed
time, decide whether the robot is in progress, or whether the robot will
fail to complete its task in the remaining time (if any).
Overall assessment: {CHOICE: [ok, failure]}
[end of output]

Rules:
1. If you see phrases like {CHOICE: [choice1, choice2]}, it means you should
    将整个短语替换为所列选项之一。例如，当选择选项 B 时，将整个短语“{CHOICE: [A, B]}”替换为“B”。
    请勿将您的选择置于“{” “}”括号内。若您对数值不确定，请依据最佳判断。2. 请勿忘记在分析结尾
    给出总体评估。如
    indicated above with '{CHOICE: [ok, failure]}', your only options for the
    overall assessment are 'ok' or 'failure'.
3. Always start the output with [start of output] and end the output with [end of
    output].

```

## B.4 评估协议

### B.4.1 定义：策略失效

考虑一个策略  $\pi(a|s)$ ，它在有限时域马尔可夫决策过程（Markov Decision Process, MDP）中运行：一个五元组  $\langle \mathcal{S}, \mathcal{A}, T, R, H \rangle$ ，其中  $\mathcal{S}$  和  $\mathcal{A}$  分别是状态空间和动作空间， $T(s'|s, a)$  是转移模型， $R(s, a, s')$  是奖励模型， $H$  是 MDP 的时域。给定一个代表新测试场景的初始状态  $s_0$ ，执行该策略  $t$  个时间步会产生一条轨迹  $\tau_t = (s_0, a_0, \dots, s_t)$ 。轨迹的回报定义为奖励的累积和：

$$R(\tau_t) = \sum_{t'=0}^{t-1} R(s_{t'}, a_{t'}, s_{t'+1})。$$

本文仅依据任务完成情况来定义策略失败。更正式地，给定一个定义的成功阈值  $R_\tau$ ，若策略在其轨迹  $\tau_t$  上的回报未能在马尔可夫决策过程（MDP）的时域内超过该成功阈值，则策略失败：

$R(\tau_t) < R_\tau$  其中  $t \geq H$ 。在最简单的情形下，成功阈值  $R_\tau$  等于 1，且奖励模型  $R(s, a, s')$  当且仅当任务在状态  $s'$  处完成时等于 1。例如，若机器人的任务是拿起一个杯子，则仅在杯子被牢牢抓住时才获得 1 的奖励。在实验中，我们遵循这一策略失败的定义，并将轨迹回报按  $R(\tau_H) < R_\tau$  进行阈值化，以计算轨迹  $\tau_H$  中策略是否失败的真实标签。

**与故障检测的关系：** 在第 3 节中，我们给出了失败检测任务的定义——在尽可能早的时间步  $t$  检测一条轨迹  $\tau_H$  是否构成策略失败——这与检测策略“失败”的具体时间步（或之前）不同。这样做消除了手动指定任务特定失败标准的需要，例如为轨迹中的每个时间步打标签。虽然我们的失败检测器的目标是标记失败回合，但在尽可能早的时间步捕获失败仍然是有益的，这就是为什么 a) 我们上述策略失败的定义是基于马尔可夫决策过程（MDP）截至当前时间步  $t \leq H$  的部分轨迹  $\tau_t$  来表述的，b) 我们提出了一种在线检测方案，在每个时间步  $t$  基于截至当前时间步的轨迹（即  $f(\tau_t) \rightarrow \{\text{ok}, \text{失败}\}$ ）监测失败，以及 c) 我们将检测时间报告为性能度量。

### B.4.2 构建校准数据集

校准 STAC 及其基线需要一个成功策略执行的小数据集  $\mathcal{D}_\tau = \{\tau^i\}_{i=1}^M$ ，这些数据为策略的名义分布内行为提供了依据。这使我们能够评估可能失败的策略在测试时的行为与其已知名义行为的关系。

**校准数据质量** 我们发现确保轨迹质量很重要  $\tau^i \in \mathcal{D}_\tau$ 。具体来说，策略成功但方式不理想或不可接受的轨迹不应用于校准。例如，策略可能解决了关闭盒子任务（图 7），但

在此过程中损坏了盒子的盖子。将这样的轨迹包含在校准数据集中会将这种行为定义为名义行为，并降低检测器在测试时的敏感性。回到我们的例子，如果策略在测试时损坏了盒子，检测器可能不会发出失败警告。

**收集校准数据集** 在实践中，此类校准数据集可在部署前的策略验证阶段收集。例如，我们为每个仿真域收集  $M=50$  次成功的策略展开，并手动过滤掉策略成功但行为不可接受（如抖动）的回合。我们假设检测器性能与展开次数  $M$  的关系是任务特定的。例如，对于变异性较低的任务（即单一、结构化环境），较小的校准数据集可能足够；而若策略需大规模部署，则可能需要更大的数据集。然而，我们注意到，增大校准数据集规模可能有助于为检测器的假阳性率（FPR）提供更强的共形保证（如 § D 中推导）。

**基于演示数据校准** 最后，为消除收集额外成功策略展开校准数据集的需求，我们尝试了直接基于策略演示数据集中轨迹进行校准的 STAC 变体。然而，这样做导致检测器的假阳性率显著上升。我们将此归因于模仿学习策略中众所周知的协变量偏移问题 [32, 33]。即，其预测误差在策略诱导的状态下呈二次方增长，导致检测器将成功的测试时展开误判为失败。

### B.4.3 测试与评估

我们并非在线（即在策略展开过程中）评估失败检测器，而是收集多个包含成功与失败策略展开的测试数据集。每条轨迹通过设定回合最终状态的回报阈值标记为成功或失败（详见 § B.4.1）。随后，我们在轨迹的每个时间步调用失败检测器进行离线评估，从而确定检测器首次发出警告的时间步。

### B.4.4 报告的度量指标

我们扩展了第 3 节中概述的度量。首先，将正例定义为策略失败的轨迹，将负例定义为策略成功的轨迹。若在策略失败的轨迹中，失败检测器在任意时间步发出警告，则计为真阳性。若在策略成功的轨迹中，失败检测器从未发出警告，则计为真阴性。假阳性和假阴性的定义相应类推。检测时间定义为在策略失败的轨迹中，失败检测器最早发出警告的时间步。

在实验中，我们报告真阳性率（TPR）、真阴性率（TNR）、假阳性率（FPR）、检测时间（DT）、准确率和平衡准确率。TPR 衡量真阳性（检测到的失败）数量占正例（失败）总数的比例。TNR 衡量真阴性（检测到的成功）数量占负例（成功）总数的比例。FPR 衡量假阳性（误报）数量占负例（成功）总数的比例。准确率和平衡准确率同时考虑了检测器的 TPR 和 TNR。然而，当测试集中正负轨迹存在不可忽略的不平衡时，我们报告平衡准确率。

## C 附加结果

### C.1 STAC 的消融实验

**STAC 的性能是否依赖于策略的预测和执行时域？**

我们在 PushT 领域进行了消融实验，以测试 STAC 的性能如何随扩散策略的预测时域  $h$  和执行时域  $k$  变化。预测时域和执行时域共同决定了 STAC 进行统计比较的时间重叠动作分量的数量（即介于  $a_{t+k:t+h-1|t}$  和  $a_{t+k:t+h-1|t+k}$  之间），而执行时域则决定了动作分布  $\pi_t$  和  $\pi_{t+k}$  在时间上生成的距离。

结果如图 8 所示。我们发现，STAC (MMD) 在执行时域为  $k=4$  和  $k=8$  时表现相当，但在标准扩散策略设置  $k=8$  和  $h=16$ （用于图 5 的主要结果）下表现最佳。当使用最小执行时域  $k=2$  时，检测器性能下降。我们将此归因于两个执行步骤内环境变化相对较小，导致  $\pi_t$  和  $\pi_{t+k}$  分布相似，从而产生过于保守的统计距离。这反映在我们的结果中：检测器在各种执行时域下达到  $> 95\%$  的真阴性率，但使用  $k=2$  导致真阳性率显著下降至  $61\%$ ，而  $k=4$  和  $k=8$  分别达到  $78\%$  和  $95\%$  的真阳性率。




图 8: 在 PushT 中，STAC 性能随不同策略预测和执行时域的变化。

为进一步消融策略预测时域的选择，我们在模拟的 Close Box 和真实世界的 Push Chair 领域进行了类似研究。结果如表 4 所示，我们发现 STAC 对预测时域的选择相当稳健，而使用标准设置  $h=16$  可获得最佳结果。

|      | Domain     | Pred. Horizon ( $h$ ) | TPR $\uparrow$ | TNR $\uparrow$ | Accuracy $\uparrow$ |
|------|------------|-----------------------|----------------|----------------|---------------------|
| Sim. | Close Box  | 8                     | 0.92           | 0.94           | 0.93                |
|      | Close Box  | 12                    | 0.88           | 1.00           | 0.93                |
|      | Close Box  | 16                    | 0.96           | 1.00           | 0.98                |
|      | Close Box  | 16                    | 0.96           | 1.00           | 0.98                |
| Real | Push Chair | 8                     | 1.00           | 0.80           | 0.90                |
|      | Push Chair | 12                    | 0.80           | 0.80           | 0.80                |
|      | Push Chair | 16                    | 0.80           | 0.90           | 0.85                |

表 4: 策略预测时域  $h$  上的 STAC 消融。

总体而言，STAC 的性能可能随策略执行时域而变化，但在策略预测时域的不同选择下相对稳定。我们在校准时和部署时使用相同的预测时域，这一事实可能在测试时归一化了该参数的影响。

### How does STAC’s performance vary with the choice of statistical distance function?

#### 图 9 消融了在推块任务领域中不同统计距离函数选择下时序动作

一致性检测器的性能。我们发现，时序动作一致性检测器在常见选择下表现相当，例如使用径向基核函数的最大均值差异和通过核密度估计的 KL 散度（详见附录 A.4）。这一发现在表 5 中得到印证，其中时序动作一致性检测器的所有变体在关箱任务领域中均达到超过  $90\%$  的检测准确率。相比之下，当使用非统计距离函数（“时序非分布最小值”；附录 B.3.4）来衡量时序动作一致性时，我们观察到性能大幅下降。这种性能下降可归因于生成式策略的随机多模态性，这使得在策略执行过程中难以采样到与先前时间步相似的单步动作。由于非统计距离函数对动作采样中的随机性比统计距离函数更敏感，我们观察到误报率增加。




图 9: PushT 中基于统计距离函数选择的 STAC 性能变化。

## C.2 扩展结果：视觉语言模型运行时监控器

为补充第 6 节提供的分析，本文重点研究视觉语言模型运行时监控器的性能及其对时序动作一致性检测器在检测异常和任务进展失败方面的补充作用。



**Erratic Failure Analysis** Table 5 presents the extended results of our experiments on the **Close Box** domain, where we aim to detect erratic policy failures that result from OOD scaling of the box. We run several evaluations of our VLM runtime monitor, varying the choice of VLM (GPT-4o, Claude 3.5 Sonnet, Gemini 1.5 Pro [79]) and prompt template (Video QA, Image QA). Since erratic failures in this domain are assigned to STAC—which detects 99% of them—we would like the VLM to avoid raising false alarms so as to keep the overall FPR of Sentinel low when the two detectors are combined.

| Category 1: Erratic Failures            |                            |  | Close Box: In-Distribution<br>(Policy Success Rate: 91%) |       |                 | Close Box: Out-of-Distribution<br>(Policy Success Rate: 41%) |       |                 | Close Box: Combined<br>(Policy Success Rate: 67%) |       |            |
|-----------------------------------------|----------------------------|--|----------------------------------------------------------|-------|-----------------|--------------------------------------------------------------|-------|-----------------|---------------------------------------------------|-------|------------|
| Failure Detector                        |                            |  | TPR ↑                                                    | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                                        | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                             | TNR ↑ | Accuracy ↑ |
| Diffusion                               | Temporal Non-Distr. Min.   |  | 1.00                                                     | 0.97  | 5.00            | 1.00                                                         | 0.27  | 12.35           | 1.00                                              | 0.77  | 0.85       |
|                                         | Diffusion Recon. [75]      |  | 0.33                                                     | 0.95  | 13.60           | 0.40                                                         | 1.00  | 17.08           | 0.37                                              | 0.96  | 0.76       |
|                                         | Temporal Diffusion Recon.  |  | 1.00                                                     | 0.96  | 8.47            | 0.92                                                         | 1.00  | 15.75           | 0.92                                              | 0.97  | 0.95       |
|                                         | DDPM Loss (Eq. 2)          |  | 1.00                                                     | 0.90  | 8.27            | 1.00                                                         | 0.94  | 14.54           | 1.00                                              | 0.91  | 0.94       |
|                                         | Temporal DDPM Loss         |  | 1.00                                                     | 0.95  | 7.53            | 1.00                                                         | 0.37  | 13.66           | 1.00                                              | 0.79  | 0.86       |
|                                         | Diffusion Output Variance  |  | 0.33                                                     | 0.94  | 14.00           | 0.28                                                         | 1.00  | 17.27           | 0.26                                              | 0.96  | 0.72       |
| Embed.                                  | Policy Encoder             |  | 0.25                                                     | 0.98  | 16.27           | 1.00                                                         | 0.00  | 1.59            | 0.94                                              | 0.70  | 0.78       |
|                                         | CLIP Pretrained            |  | 1.00                                                     | 0.95  | 15.73           | 1.00                                                         | 0.00  | 8.20            | 1.00                                              | 0.68  | 0.79       |
|                                         | ResNet Pretrained          |  | 1.00                                                     | 0.95  | 17.87           | 1.00                                                         | 0.00  | 15.51           | 1.00                                              | 0.68  | 0.79       |
| STAC                                    | STAC For. KL               |  | 1.00                                                     | 0.90  | 6.60            | 0.99                                                         | 0.85  | 14.04           | 0.99                                              | 0.89  | 0.92       |
|                                         | STAC Rev. KL               |  | 1.00                                                     | 0.95  | 7.60            | 0.93                                                         | 0.97  | 15.12           | 0.93                                              | 0.96  | 0.95       |
|                                         | STAC MMD*                  |  | 1.00                                                     | 0.94  | 7.20            | 0.99                                                         | 0.93  | 14.72           | 0.99                                              | 0.94  | 0.96       |
| VLM                                     | GPT-4o Image QA            |  | 1.00                                                     | 0.00  | 23.20           | 1.00                                                         | 0.00  | 23.20           | 1.00                                              | 0.00  | 0.29       |
|                                         | GPT-4o Video QA*           |  | 1.00                                                     | 0.89  | 21.20           | 0.69                                                         | 0.95  | 21.02           | 0.77                                              | 0.91  | 0.87       |
|                                         | Gemini 1.5 Pro Image QA    |  | 1.00                                                     | 0.00  | 21.20           | 1.00                                                         | 0.00  | 23.20           | 1.00                                              | 0.00  | 0.29       |
|                                         | Gemini 1.5 Pro Video QA    |  | 1.00                                                     | 0.57  | 17.20           | 1.00                                                         | 0.50  | 20.20           | 1.00                                              | 0.55  | 0.68       |
|                                         | Claude 3.5 Sonnet Image QA |  | 1.00                                                     | 0.06  | 23.20           | 0.69                                                         | 0.10  | 23.20           | 0.77                                              | 0.07  | 0.27       |
|                                         | Claude 3.5 Sonnet Video QA |  | 0.83                                                     | 0.31  | 23.20           | 0.44                                                         | 0.40  | 23.20           | 0.55                                              | 0.35  | 0.40       |
| Sentinel (STAC MMD* + GPT-4o Video QA*) |                            |  | 1.00                                                     | 0.86  | 5.47            | 1.00                                                         | 0.90  | 14.25           | 1.00                                              | 0.87  | 0.91       |

**表 5：关箱任务领域中检测异常失败的扩展结果。**我们的时序一致性检测器时序动作一致性检测器检测到扩散策略表现出的 99% 的异常失败。当仅以单张图像提示时，视觉语言模型会产生大量误报（图像问答），而执行视频问答（本文方法）则使所有模型的真负率显著提高。性能也因视觉语言模型的选择而异；GPT-4o 在该领域最为可靠，相比之下，其他视觉语言模型难以准确描述视频中机器人的任务进展。总体而言，哨兵系统检测到 100% 的失败，而将时序动作一致性检测器与视觉语言模型结合会使误报率增加到 13%。

我们首先讨论图像问答基线的性能不佳问题。当仅提供单张图像时，我们发现所有视觉语言模型都难以区分策略的成功与失败，因此真阴性率不超过 7%。由于未观察到初始状态（即盖子打开的盒子）和机器人的动作，视觉语言模型无法识别盒子的盖子以及它们是否已被关闭。因此，一旦任务的时间限制被超过，视觉语言模型便直接判定失败。我们迭代了多个包含详细问题的提示，试图引导视觉语言模型推理盒子的位置及其盖子，但这带来的性能变化微乎其微。结果，图像问答基线的所有输出都类似于以下假阳性示例：

**Analysis:** The current observation shows the manipulator’s arms positioned near 白色盒子，夹爪张开且未抓取盖子。盒子的两个较小的白色侧盖和较大的白色后盖不可见，表明它们尚未折叠。已用时间为 30 秒中的 30 秒

，这意味着机器人已达到完成任务的时间限制。鉴于盖子未折叠且任务未完成，机器人显然处于失败状态。

**Overall assessment:** failure

在视频问答设置（§ A.2）中提示视觉语言模型，所有模型的真阴性率均严格提高。尽管根据领域不同，我们清楚地观察到某些视觉语言模型表现出比其他模型更好的视觉推理性能。在关闭盒子领域，GPT-4o 生成相对连贯的视频描述，而 Claude 3.5 Sonnet 和 Gemini 1.5 Pro 经常例如将关闭的盖子误认为打开的盖子，或未能识别机器人已取得任何显著进展。虽然这种性能差异难以解释，但两个潜在原因是：a) 关闭盒子任务可能需要推理长视频（即 20-30 个图像帧），并且尽管视觉语言模型的大上下文窗口具有容纳性，

视觉语言模型仍可能容易受到近因偏差的影响 [88]；b) 该领域中渲染的图像可能在一个视觉语言模型（本例中为 GPT-4o）的训练数据中比其他模型有更好的表示。

**Task Progression Failure Analysis** In the context of VLM runtime monitoring, task progression failures differ from erratic failures in that they are more visually apparent and hence simpler for the VLM to interpret. For example, the policy takes more obviously incorrect actions, e.g., clearly misplacing the cover in the **Cover Object** domain (see Fig. 7), but it does so in a temporally consistent manner that goes unnoticed by STAC. Therefore, under task progression failures, we require the VLM to attain both a high TPR and TNR, whereas we are mainly concerned with TNR under erratic failures. The extended results of our task progression failure experiments are shown in Table 6 for the **Cover Object** domain and Table 7 for the **Close Box** domain, the two of which are aggregated in Fig. 6.

| Category 2: Task Progression Failures                     |                                                   |  | Cover Object: In-Distribution<br>(Policy Success Rate: 98%) |       |                 | Cover Object: Out-of-Distribution<br>(Policy Success Rate: 3%) |       |                 | Cover Object: Combined<br>(Policy Success Rate: 56%) |       |            |
|-----------------------------------------------------------|---------------------------------------------------|--|-------------------------------------------------------------|-------|-----------------|----------------------------------------------------------------|-------|-----------------|------------------------------------------------------|-------|------------|
| Failure Detector                                          |                                                   |  | TPR ↑                                                       | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                                          | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                                | TNR ↑ | Accuracy ↑ |
| Diff.                                                     | Temporal Non-Distr. Min.                          |  | 1.00                                                        | 0.93  | 2.40            | 0.06                                                           | 1.00  | 7.60            | 0.09                                                 | 0.93  | 0.56       |
|                                                           | Diffusion Output Variance                         |  | 0.00                                                        | 0.77  | -               | 0.00                                                           | 1.00  | -               | 0.00                                                 | 0.77  | 0.44       |
| STAC                                                      | STAC For. KL                                      |  | 1.00                                                        | 0.95  | 2.40            | 0.03                                                           | 1.00  | 6.40            | 0.06                                                 | 0.95  | 0.56       |
|                                                           | STAC Rev. KL                                      |  | 1.00                                                        | 0.93  | 2.40            | 0.03                                                           | 1.00  | 6.40            | 0.06                                                 | 0.93  | 0.55       |
|                                                           | STAC MMD*                                         |  | 1.00                                                        | 0.93  | 2.40            | 0.09                                                           | 1.00  | 7.73            | 0.12                                                 | 0.93  | 0.58       |
| VLM                                                       | GPT-4o Image QA                                   |  | 1.00                                                        | 0.07  | 12.00           | 1.00                                                           | 0.00  | 11.03           | 1.00                                                 | 0.07  | 0.47       |
|                                                           | GPT-4o Video QA                                   |  | 1.00                                                        | 0.05  | 5.60            | 1.00                                                           | 0.00  | 10.06           | 1.00                                                 | 0.05  | 0.46       |
|                                                           | Gemini 1.5 Pro Image QA                           |  | 1.00                                                        | 0.05  | 12.00           | 0.91                                                           | 0.00  | 11.15           | 0.91                                                 | 0.05  | 0.42       |
|                                                           | Gemini 1.5 Pro Video QA                           |  | 1.00                                                        | 0.00  | 5.60            | 1.00                                                           | 0.00  | 7.54            | 1.00                                                 | 0.00  | 0.44       |
|                                                           | Claude 3.5 Sonnet Image QA                        |  | 1.00                                                        | 0.81  | 12.00           | 0.70                                                           | 1.00  | 12.00           | 0.71                                                 | 0.82  | 0.77       |
|                                                           | Claude 3.5 Sonnet Video QA                        |  | 1.00                                                        | 0.84  | 12.00           | 0.79                                                           | 1.00  | 12.00           | 0.79                                                 | 0.84  | 0.82       |
|                                                           | Claude 3.5 Sonnet Video QA + Success Video        |  | 1.00                                                        | 0.77  | 12.00           | 0.94                                                           | 1.00  | 11.59           | 0.94                                                 | 0.77  | 0.85       |
|                                                           | Claude 3.5 Sonnet Video QA + Goal Images          |  | 1.00                                                        | 0.93  | 5.60            | 0.76                                                           | 1.00  | 11.74           | 0.76                                                 | 0.93  | 0.86       |
|                                                           | Claude 3.5 Sonnet Prompt Ensemble* (see §A.2.1)   |  | 1.00                                                        | 0.93  | 12.00           | 0.85                                                           | 1.00  | 12.00           | 0.85                                                 | 0.93  | 0.90       |
|                                                           | Sentinel (STAC MMD* + Claude 3.5 Sonnet Video QA) |  | 1.00                                                        | 0.79  | 2.40            | 0.82                                                           | 1.00  | 8.68            | 0.82                                                 | 0.80  | 0.81       |
| Sentinel (STAC MMD* + Claude 3.5 Sonnet Prompt Ensemble*) |                                                   |  | 1.00                                                        | 0.88  | 2.40            | 0.88                                                           | 1.00  | 8.69            | 0.88                                                 | 0.89  | 0.88       |

表 6：在遮盖物体领域中检测任务进展失败情况的扩展结果。STAC 仅检测到 12% 的任务进展失败（即策略以时间一致的方式失败的情况），这凸显了采用视觉语言模型运行时监控的必要性。Claude 3.5 Sonnet 在该领域展现出最可靠的检测性能，然而，我们采用提示集成技术（详见 § A.2.1）以减少假阳性数量。总体而言，Sentinel 检测到 88% 的失败，同时产生 11% 的误报。

在所考虑的视觉语言模型中，我们发现 Claude 3.5 Sonnet 在

**封面对象** 领域（表 6）中表现最佳，在视频问答设置下达到 79% 的真阳性率和 84% 的真阴性率。对 GPT-4o 和 Gemini 1.5 Pro 响应的定性分析表明，它们误解了视频，从而产生了过多的误报。正如预期，STAC 达到了可观的 93% 真阴性率，但仅检测到 12% 的任务进展失败。STAC 与 Claude 3.5 Sonnet 视频问答的组合表现良好（82% 真阳性率，80% 真阴性率），但在减少假阳性数量方面仍有改进空间，其中大部分假阳性由视觉语言模型产生。在此，我们表明 § A.2.1 中讨论的提示集成策略增强了我们视觉语言模型运行时监控器的可靠性（“Claude 3.5 Sonnet 提示集成”），将真阴性率提高到 93%。最后，将这一改进的视觉语言模型运行时监控器与 STAC 结合，得到 Sentinel 的一个版本，该版本检测到 88% 的失败，同时产生更可接受的误报数量（11%）。

表 7 中的结果再次证实了以下关键点：a) 基于图像的视觉语言模型推理不足以理解机器人的任务进展，从而导致较低的真阴性率；b) 视觉语言模型的性能因领域而异，GPT-4o 和 Claude 3.5 Sonnet 分别在

**关闭箱子** 和遮盖物体领域中表现最佳；c) STAC 和视觉语言模型运行时监控器在跨领域实现高性能整体失败检测方面发挥互补作用。我们预期，随着未来更强大的视觉语言模型 [89] 的发布，我们的视觉语言模型运行时监控器（以及 Sentinel）的性能将得到提升，这也可能消除上述视觉语言模型之间的差异。

#### 讨论：为什么通过取预测结果的并集来组合失败检测器？

我们的完整故障检测器“哨兵”（Sentinel）将 STAC 与视觉语言模型（VLM）相结合，取二者预测的并集（即图 3 中的“逻辑或”），在最坏情况下，这会通过应用并集来叠加它们的假阳性率。然而，这样做源于以下几个设计考量：

| Category 2: Task Progression Failures   |                            |  | Close Box: In-Distribution<br>(Policy Success Rate: 85%) |       |                 | Close Box: Out-of-Distribution<br>(Policy Success Rate: 0%) |       |                 | Close Box: Combined<br>(Policy Success Rate: 40%) |       |            |
|-----------------------------------------|----------------------------|--|----------------------------------------------------------|-------|-----------------|-------------------------------------------------------------|-------|-----------------|---------------------------------------------------|-------|------------|
| Failure Detector                        |                            |  | TPR ↑                                                    | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                                       | TNR ↑ | Det. Time (s) ↓ | TPR ↑                                             | TNR ↑ | Accuracy ↑ |
| Diff.                                   | Temporal Non-Distr. Min.   |  | 1.00                                                     | 0.97  | 4.67            | 0.67                                                        | -     | 7.46            | 0.71                                              | 0.97  | 0.82       |
|                                         | Diffusion Output Variance  |  | 0.00                                                     | 1.00  | -               | 0.28                                                        | -     | 11.57           | 0.25                                              | 1.00  | 0.55       |
| STAC                                    | STAC For. KL               |  | 1.00                                                     | 0.97  | 5.07            | 0.61                                                        | -     | 8.14            | 0.65                                              | 0.97  | 0.78       |
|                                         | STAC Rev. KL               |  | 1.00                                                     | 0.97  | 6.13            | 0.61                                                        | -     | 10.11           | 0.65                                              | 0.97  | 0.78       |
|                                         | STAC MMD*                  |  | 1.00                                                     | 0.97  | 5.47            | 0.61                                                        | -     | 9.06            | 0.65                                              | 0.97  | 0.78       |
|                                         |                            |  |                                                          |       |                 |                                                             |       |                 |                                                   |       |            |
| VLM                                     | GPT-4o Image QA            |  | 1.00                                                     | 0.00  | 23.20           | 1.00                                                        | -     | 22.68           | 1.00                                              | 0.00  | 0.60       |
|                                         | GPT-4o Video QA*           |  | 1.00                                                     | 0.89  | 21.20           | 0.87                                                        | -     | 22.00           | 0.88                                              | 0.89  | 0.89       |
|                                         | Gemini 1.5 Pro Image QA    |  | 1.00                                                     | 0.00  | 21.20           | 0.96                                                        | -     | 23.20           | 0.96                                              | 0.00  | 0.57       |
|                                         | Gemini 1.5 Pro Video QA    |  | 1.00                                                     | 0.57  | 17.20           | 0.98                                                        | -     | 15.47           | 0.98                                              | 0.57  | 0.82       |
|                                         | Claude 3.5 Sonnet Image QA |  | 1.00                                                     | 0.06  | 23.20           | 0.78                                                        | -     | 23.20           | 0.81                                              | 0.06  | 0.51       |
|                                         | Claude 3.5 Sonnet Video QA |  | 0.83                                                     | 0.31  | 23.20           | 0.80                                                        | -     | 23.20           | 0.81                                              | 0.31  | 0.61       |
|                                         |                            |  |                                                          |       |                 |                                                             |       |                 |                                                   |       |            |
| Sentinel (STAC MMD* + GPT-4o Video QA*) |                            |  | 1.00                                                     | 0.86  | 5.47            | 0.96                                                        | -     | 12.20           | 0.96                                              | 0.86  | 0.92       |

**表 7：在“关闭盒子”领域中检测任务进展故障的扩展结果。**在此，STAC 检测到的任务进展故障比在“覆盖物体”领域中多得多，但仍有 35% 的故障未被检测到。与表 5 一样，我们发现基于视频的推理对于视觉语言模型获得高真阴性率（TNR）是必要的，其中 GPT-4o 表现最佳。总体而言，哨兵检测到 96% 的故障，同时产生 14% 的误报。

- **重要性加权：**我们明确将一种故障类别定义为另一种的补集，并为每种故障类别分配专门的检测器，因为设计一个能够捕捉高度异质故障模式的单一检测器极其困难。因此，通过使用“或”运算，我们对所提出的两种故障类别赋予同等重要性。我们注意到，我们的故障检测器的主要目的是在部署时检测未见过的故障：即我们不假设有任何机器人故障数据来校准检测器，而这对于调整不同检测器的重要性权重可能是必要的。此外，在一个数据集上最优的重要性权重可能在未包含于该数据中的故障模式上表现不佳。

- **性能可解释性：**使用简单的方案来组合检测器，可以轻松解释（a）组合检测器的运行时行为，以及（b）哪些单个检测器在何时对性能有所贡献。例如，使用逻辑“或”意味着，如果 STAC 和视觉语言模型运行时监控器都具有较低的假阳性率（FPR），那么哨兵的整体假阳性率仍可保持在可接受的低水平。STAC 实现了可证明的低假阳性率（§ D），同时存在通过例如提示集成（§ A.2.1）或共形校准 [90] 来降低视觉语言模型假阳性率的策略。因此，当检测器组合时，我们可以预期较低的假阳性率。同样，我们可以解释哨兵的真阳性率（TPR）性能，正如我们的实验分析所例证的那样。对于更复杂的检测器组合方案，性能解释的简易性可能不再成立。

- **运行时约束：**在实践中，STAC（快速）与视觉语言模型运行时监控器（慢速）具有不同的推理时延，可能需要在不同的时间尺度上运行。因此，我们的逻辑“或”组合仅在重叠的时间步上生效，否则允许每个故障检测器独立发出警报，即无需同步它们的检测速率。这种灵活性至关重要，因为更复杂的组合方案可能会遇到问题，例如，意外的网络延迟导致云端托管的视觉语言模型响应延迟。

尽管如此，我们注意到更复杂的组合方案可能带来优势，例如在集成额外检测器时提升检测性能或可扩展性。探索符合上述设计考虑的此类方案，是未来工作的一个有价值方向。

## D 推导

为验证我们的设计选择，我们证明第 4.1 节中 STAC 的评分函数与校准程序可证明地实现低误报率。为此，我们采用近期流行的共形预测工具，因为它们样本高效且分布无关，即无需对轨迹展开做分布假设。我们的保证是分裂共形预测标准结果的直接应用 [66]，但为确保本文自包含性，我们首先使用本文符号简要重述共形预测的核心概念（取自 [66]）。

**共形推断背景** 在最基本形式中，共形预测旨在构建一个预测集  $\mathcal{C}$ ，使其以用户定义的概率至少  $1-\delta$  包含新测试点  $X_{\text{test}}$  的真实值 [66]。为此，共形算法需要 1) 一系列校准样本  $\{X^i\}_{i=1}^M$ ，其中所有样本  $X^1, \dots, X^M, X_{\text{test}}$  独立同分布，以及 2) 一个一致性评分函数  $\eta(X) \in \mathbb{R}$ 。直观上，共形方法利用  $\{\eta(X^i)\}_{i=1}^M$  来识别  $\eta(X_{\text{test}})$  有多大可能位于校准样本的  $1-\delta$  分位数范围内（即  $X_{\text{test}}$  与校准数据的符合程度）。我们强调，无论一致性评分如何选择，也无需了解数据生成分布的任何性质，该方法都能确保构建有效的预测集  $\mathcal{C}$ ：

**定理 1 (改编自 [66] 中的定理 D.1)**。设  $\mathcal{D}_{\text{calib}} = \{X^1, \dots, X^M\}$  为校准数据集， $X_{\text{test}}$  为测试样本。假设  $\mathcal{D}_{\text{calib}}$  与  $X_{\text{test}}$  中的样本独立同分布。则定义

$$\gamma := \inf \left\{ \xi \in \mathbb{R} : \frac{|\{i : \eta(X^i) \leq \xi\}|}{M} \geq \frac{\lceil (M+1)(1-\delta) \rceil}{M} \right\}$$

$\frac{\lceil (M+1)(1-\delta) \rceil}{M}$  作为校准数据的经验分位数可确保

$$\mathbb{P}(\eta(X_{\text{test}}) \leq \gamma) \geq 1-\delta.$$

此处， $\lceil \cdot \rceil$  表示向上取整函数。

**STAC 的共形保证** 定理 1 所概述的基础分裂共形程序要求用于校准和测试的样本是独立同分布的。然而，在轨迹内顺序观察到的状态和动作并不满足这一条件，这使得在轨迹内每个时间步应用 STAC 的分析变得复杂。因此，为解决这一问题，并在轨迹内相关状态-动作对上顺序应用 STAC 时提供保证，我们在第 4.1 节中使用跨完整轨迹生成的一致性分数来校准检测器。这使我们能够利用定理 1 严格界定误报率。

**命题 2 (STAC 具有低假阳性率)**。设  $\mathcal{D}_\tau = \{\tau^i\}_{i=1}^M \stackrel{\text{iid}}{\sim} P_\tau$  为成功轨迹的验证数据集，每条轨迹包含  $H_i \leq H$  个时间步，且独立同分布地采样自闭环标称分布  $P_\tau$ 。为记号简便，假设任意轨迹的长度可被  $k$  (i.e.,  $H_i \bmod k = 0$ ) 整除。此外，设  $\eta_t$  为式 1 中某时间步  $0 \leq t \leq H$  处的 STAC 时序一致性得分，并令  $\gamma$  等于  $\mathcal{D}_\tau$  中轨迹的终端 STAC 得分  $\{\eta_{H_i}^i\}_{i=1}^M$  的经验  $\frac{\lceil (M+1)(1-\delta) \rceil}{M}$  分位数。那么，假阳性率——即我们在一条新的长度为  $H' \leq H$  的成功测试轨迹  $\tau \sim P_\tau$  期间任意时刻发出错误警报的概率——至多为  $\delta$ ：

$$\text{FPR} := \mathbb{P}_{P_\tau}(\exists 0 \leq t \leq H' \text{ s.t. } \eta_t > \gamma) \leq \delta. \quad (5)$$

证明。设  $H' \leq H$  为测试轨迹  $\tau$  的长度。若不存在分布偏移，即当测试轨迹  $\tau$  关于  $\mathcal{D}_\tau \stackrel{\text{iid}}{\sim} P_\tau$  独立同分布时，有  $\eta_{H'}$  且  $\{\eta_{H_i}^i\}_{i=1}^M$  独立同分布。因此，由定理 1 可得

$$\mathbb{P}_{P_\tau}(\eta_{H'} > \gamma) \leq \delta.$$

此外，由于我们在式 1 中为  $t = jk$  定义了  $\eta_t = \sum_{i=0}^{j-1} \hat{D}(\bar{\pi}_{ik}, \bar{\pi}_{(i+1)k})$ ，并且  $\hat{D}(\cdot, \cdot) \geq 0$  因为它是统计距离，所以  $\eta_t$  是递增的。也就是说， $\eta_0 \leq \eta_k \leq \eta_{2k} \leq \dots \leq \eta_{H'}$ 。因此，如果  $\eta_t$  在任何时刻越过阈值  $\gamma$ ，那么  $\eta_{H'} > \gamma$  也成立。这立即蕴含该命题，因为此时我们有

$$\mathbb{P}_{P_\tau}(\exists 0 \leq t \leq H' \text{ s.t. } \eta_t > \gamma) = \mathbb{P}_{P_\tau}(\eta_{H'} > \gamma) \leq \delta.$$

□

本节以三点说明作结：

1. 本文仅约束误报率 (FPR)，这确保了算法以高概率不发出虚假警报，因此任何警告都极有可能对应分布外 (OOD) 场景。之所以如此，是因为

频繁产生误报的系统在实际中难以使用。本文的校准方法既不保证检测到所有失败，也不保证在分布外成功案例上不产生误报，因为在不对分布外场景做任何分布假设、或不使用失败数据进行校准的情况下，这是不可能实现的 [91]。相反，本文通过实验发现，所提出的时序一致性分数在检测失败方面表现良好。

2. 命题 2 仅证明 STAC 的假阳性率较低。本文不对 STAC 与视觉语言模型 (VLM) 的组合性能作任何声明，因为 VLM 是一个黑盒分类器。未来工作可以研究联合校准多个失败检测器的方法。

3. 定理 1 和命题 2 中的共形保证是关于校准数据的边际保证。也就是说，对于某个特定的校准数据集，这些保证可能并不精确成立；但如果采样数千个校准数据集，这些保证将在平均意义上成立。因此，正如预期的那样，STAC 在本文结果中并未精确满足公式 5，因为计算预算限制了实验只能在有限数量的随机种子上重复进行。