

我们真的需要访问源数据吗？用于无监督领域自适应的源假设迁移

Jian Liang¹ Dapeng Hu¹ Jiashi Feng¹

摘要

无监督领域自适应（Unsupervised Domain Adaptation, UDA）旨在利用从带标签源数据集学到的知识，在新的无标签领域中解决相似任务。现有 UDA 方法通常需要在模型学习时访问源数据，这使得它们在处理分散的私有数据时存在风险且效率低下。本文研究一种实用场景：仅有一个训练好的源模型可用，并探讨如何在没有源数据的情况下有效利用该模型解决 UDA 问题。我们提出一个简单而通用的表示学习框架，称为源假设迁移（Source Hypothesis Transfer, SHOT）。SHOT 冻结源模型分类器模块（假设），并通过信息最大化和自监督伪标签来学习目标特定的特征提取模块，从而隐式地将目标域表示对齐到源假设。为验证其通用性，我们在多种自适应场景下评估 SHOT，包括闭集、部分集和开集领域自适应。实验表明，SHOT 在多个领域自适应基准上取得了最先进的结果。

到深度领域自适应，尤其是在普通的无监督闭集设定下（Panareda Busto & Gall, 2017），其中两个领域共享相同的标签空间，但目标数据没有标签。一种主流范式是通过匹配不同阶的分布统计矩来减小领域间的分布发散（Sun et al., 2016; Zellinger et al., 2017; Peng et al., 2019a）。例如，最受青睐的最大均值差异（Maximum Mean Discrepancy, MMD）（Gretton et al., 2007）测度最小化所有原始矩的加权和之间的某种距离。另一种流行的范式利用对抗学习（Goodfellow et al., 2014）的思想，引入一个额外的领域分类器来最小化跨领域的代理 $\mathcal{A}$ -距离（Ben-David et al., 2010）。

如今，数据分布在不同的设备上，通常包含隐私信息，例如个人手机上的数据或监控摄像头的的数据。现有的领域自适应方法在学习适应过程中需要访问源数据，这不仅数据传输效率低下，还可能违反数据隐私政策。本文研究一种有趣但具有挑战性的无监督领域自适应设定，仅提供一个训练好的源模型作为监督。它与普通无监督领域自适应的不同之处在于，提供给未标记目标领域的是源模型而非源数据。这种设定有助于保护源领域的隐私（例如，个体医院档案），并且传输轻量级训练模型比传输大量数据高效得多。例如，如表 1 所示，训练模型的存储大小远小于压缩数据集的存储大小。

1. 引言

深度神经网络在众多领域的各种应用中取得了显著成功，但代价是繁重的大规模训练数据标注。为避免昂贵的数据标注，领域自适应（Domain Adaptation, DA）方法被开发出来，以直推式方式充分利用已有的带标签数据集和手头的无标签数据，在物体识别（Long 等, 2015; Tzeng 等, 2017）、语义分割（Zhang 等, 2017; Hoffman 等, 2018）等任务中取得了有前景的结果。过去十年间，越来越多的努力投入到 1 新加坡国立大学电子与计算机工程系。通讯作者：Jian Liang <liangjian92@gmail.com>。

表 1. 存储大小。源模型的骨干网络分别是 LeNet（LeCun et al., 1998）和 ResNet-101（He et al., 2016）。[†]（Hoffman et al., 2018）, [‡]（Peng et al., 2017）。

Storage size (MB)	Digits [†]	VisDA-C [‡]
Source Dataset	33.2	7884.8
Source Model	0.9	172.6

在隐私保护方面，这种设定似乎与最近在假设迁移学习（Hypothesis Transfer Learning, HTL）（Kuzborskij & Orabona, 2013）中提出的迁移学习设定有些相似，其中学习者无法直接访问源领域数据，只能操作假设

从源数据中归纳得出。然而，本文方法与该项工作存在显著差异。传统的异构迁移学习通常要求目标域具备带标签的数据（Tommasi 等人，2013 年）或来自不同源域的多个假设（Mansour 等人，2009 年），这些条件无法应用于无监督领域自适应。

为应对这一具有挑战性的无监督领域自适应场景，本文提出一种简单而通用的解决方案，称为源假设迁移（Source Hypothesis Transfer, SHOT）。受先前工作（Tzeng 等人，2017 年）的启发，SHOT 假设相同的深度神经网络模型由特征编码模块和分类器模块（即假设）组成，且跨域共享。其目标是在不访问源数据和目标标签的前提下，学习一个目标域特定的特征编码模块，以生成与源数据表示良好对齐的目标数据表示。SHOT 的设计基于以下观察：若能为目标数据学习到类似源域的表示，则源分类器（假设）对目标数据的分类输出应与源数据的输出相似，即接近独热编码。因此，SHOT 冻结源假设，并通过最大化中间特征表示与分类器输出之间的互信息来微调源编码模块，因为信息最大化（Hu 等人，2017 年）会促使网络为目标特征表示分配不同的独热编码。

尽管信息最大化迫使特征表示与假设良好匹配，但它仍可能将目标特征表示对齐到错误的源假设上。为避免这一问题，本文提出一种新颖的自监督伪标签方法，以增强目标表示学习。考虑到源分类器生成的目标数据伪标签可能不准确且含有噪声，本文提出为目标域自身获取中间类级原型，并通过这些原型的监督进一步获得更干净的伪标签，以指导映射模块的学习。这种自监督标签方法充分利用了目标域的全局结构，能够学习到正确匹配源假设的特征表示。此外，本文在源模型的网络架构中研究了标签平滑（Label Smoothing）、权重归一化（Weight Normalization）和批归一化（Batch Normalization），以提升自适应性能。实验证据表明，SHOT 及其基线方法（仅源域）均受益于这些技术。

我们将 SHOT 应用于标准的闭集（Saenko 等人，2010）领域自适应场景，以及多种其他无监督领域自适应任务，如部分集（Cao 等人，2018）和开集（Panareda Busto & Gall, 2017）情形。实验表明，SHOT 在多个不同的领域自适应任务中均达到了最先进的结果。例如，在 Office-

在家庭数据集上，SHOT 将闭集场景下的最佳平均准确率从 67.6%（Wang 等人，2019）提升至 **71.8%**，将部分迁移场景下的最佳平均准确率从 **71.8%**（Xu 等人，2019）提升至 **79.3%**，并将开放集场景下的最佳平均准确率从 69.5%（Liu 等人，2019）提升至 **72.8%**。

2. 相关工作

无监督领域自适应。大量无监督域自适应方法已被开发并成功应用于跨域任务，如目标识别（Liang et al., 2018; ?）、目标检测（Chen et al., 2018）、语义分割（Tsai et al., 2018）和情感分类（Glorot et al., 2011）。除了前述的两种主流范式——矩匹配和对抗对齐——还有若干基于样本的域自适应方法，它们估计源样本的重要性权重（Jiang & Zhai, 2007; Huang et al., 2007）或通过最优传输估计样本间相似度（Bhushan Damodaran et al., 2018）。此外，一些工作（Bousmalis et al., 2016; Ghifary et al., 2016）将数据重构作为辅助任务以确保特征不变性，还有一些研究在网络架构中考虑批归一化（Cariucci et al., 2017; Wang et al., 2019）和对抗性随机失活（Saito et al., 2018a; Lee et al., 2019b）。然而，所有这些方法都假设目标用户能够访问源域数据，这既不安全，有时也不切实际，因为源数据可能是私有的、分散存储的（存储在其他设备上）。此外，据我们所知，我们的工作为首个几乎覆盖所有无监督域自适应场景的域自适应框架，包括多源（Peng et al., 2019a）和多目标（Peng et al., 2019b）、开放集域自适应（Panareda Busto & Gall, 2017）以及部分集域自适应（Cao et al., 2018）。

假设迁移学习（Hypothesis Transfer Learning, HTL）。假设迁移学习（Kuzborskij & Orabona, 2013）可视为参数自适应（Csurka, 2017）的一种泛化，它假设最优目标假设与源假设密切相关。与著名的微调策略（Yosinski et al., 2014）类似，假设迁移学习通常需要每类至少一小部分带标签的目标样本，这限制了其在半监督域自适应场景中的适用性（Yang et al., 2007; Nelakurthi et al., 2018）。此外，一项开创性工作（Mansour et al., 2009）为每个无标签目标样本推断不同源假设的权重，并利用源假设的凸组合。然而，它仅适用于多源场景，且需要对每个源域进行加性分布估计。据我们所知，（Chidlovskii et al., 2016; Liang et al., 2019）在无监督域自适应问题中引入了与我们类似的设置，但由于它们未在内部整合端到端特征学习模块，可能效果不够理想。

伪标签（Pseudo Labeling, PL）。伪标签（Pseudo Labeling）（Lee, 2013）最初为半监督学习而提出，并获得了广泛关注。

在其他直推式学习问题（如领域自适应）中，伪标签也展现出相似的有效性。其核心思想是：为无标签数据赋予最大预测概率对应的标签，并与有标签数据一同进行微调，这一过程相当高效。对于领域自适应方法，（Zhang et al., 2018b; Choi et al., 2019）直接将伪标签作为正则化手段，而（Long et al., 2017; 2018）则在自适应模块中利用伪标签来追求判别性的（条件）分布对齐。（Zou et al., 2018）进一步设计了一个集成框架，交替求解目标伪标签并进行模型训练。在缺乏标签数据的情况下，DeepCluster（Caron et al., 2018）作为最优秀的自监督学习方法之一，通过 k 均值聚类生成伪标签，并利用它们重新训练当前模型。考虑到数据集偏移问题，本文框架结合了上述两种方法的优势，并开发了一种自监督伪标签策略，以减轻噪声伪标签带来的危害。

联邦学习（Federated Learning, FL）。联邦学习（Federated Learning, FL）（Bonawitz et al., 2019）是一种分布式机器学习方法，它在多个分散的边缘设备上训练模型，而无需交换它们的数据样本。联邦学习的一种常见用法是在服务器端的学习算法中简单地聚合来自多个本地用户的更新（Bonawitz et al., 2017; McMahan et al., 2018），从而提供一种隐私保护机制。最近，（Peng et al., 2020）引入了首个联邦域适应（Federated DA）设置，其中知识从分散的节点转移到新节点，而新节点本身没有任何监督，并提出了一种基于对抗的解决方案。具体来说，它为每个源节点训练一个模型，并通过聚合源梯度来更新目标模型，以减少域偏移。然而，它可能无法解决只有一个源域可用的普通域适应（vanilla DA）设置。

3. 方法

我们处理无监督领域自适应任务，仅使用预训练的源模型，且不访问源数据。具体而言，我们考虑 K 类分类。对于标准的无监督领域自适应任务，给定来自源域 $\mathcal{D}_s$ 的 n_s 个带标签样本 $\{x_s^i, y_s^i\}_{i=1}^{n_s}$ ，其中 $x_s^i \in \mathcal{X}_s, y_s^i \in \mathcal{Y}_s$ ，以及来自目标域 $\mathcal{D}_t$ 的 n_t 个无标签样本 $\{x_t^i\}_{i=1}^{n_t}$ ，其中 $x_t^i \in \mathcal{X}_t$ 。领域自适应的目标是预测目标域中的标签 $\{y_t^i\}_{i=1}^{n_t}$ ，其中 $y_t^i \in \mathcal{Y}_t$ ，并假设源任务 $\mathcal{X}_s \rightarrow \mathcal{Y}_s$ 与目标任务 $\mathcal{X}_t \rightarrow \mathcal{Y}_t$ 相同。在此，SHOT 旨在学习目标函数 $f_t: \mathcal{X}_t \rightarrow \mathcal{Y}_t$ 并推断 $\{y_t^i\}_{i=1}^{n_t}$ ，仅使用 $\{x_t^i\}_{i=1}^{n_t}$ 和源函数 $f_s: \mathcal{X}_s \rightarrow \mathcal{Y}_s$ 。

我们通过三个步骤解决上述无监督领域自适应的源模型迁移任务。首先，从源数据生成源模型。其次，丢弃源数据，在不访问源数据的情况下将模型（包括源假设）迁移到目标域。第三，进一步研究如何为两个模型设计更好的网络架构以提高自适应性能。

模型以提高自适应性能。

3.1. 源模型生成

我们考虑开发一个深度神经网络，并通过最小化以下标准交叉熵损失来学习源模型 $f_s: \mathcal{X}_s \rightarrow \mathcal{Y}_s$ ：

$$\mathcal{L}_{src}(f_s; \mathcal{X}_s, \mathcal{Y}_s) = -\mathbb{E}_{(x_s, y_s) \in \mathcal{X}_s \times \mathcal{Y}_s} \sum_{k=1}^K q_k \log \delta_k(f_s(x_s)), \quad (1)$$

$\delta_k(a) = \frac{\exp(a_k)}{\sum_i \exp(a_i)}$ 其中 $\sum_i \exp(a_i)$ 表示 K 维向量 a 的 softmax 输出中的第 k 个元素， q 是 y_s 的 one-of- K 编码，其中 q_k 对于正确类别为‘1’，其余为‘0’。为了进一步增强源模型的判别能力并促进后续的目标数据对齐，我们提出采用标签平滑技术，因为它鼓励样本形成紧密且均匀分离的簇（Müller 等人，2019）。使用标签平滑后，目标函数变为

$$\mathcal{L}_{src}^{ls}(f_s; \mathcal{X}_s, \mathcal{Y}_s) = -\mathbb{E}_{(x_s, y_s) \in \mathcal{X}_s \times \mathcal{Y}_s} \sum_{k=1}^K q_k^{ls} \log \delta_k(f_s(x_s)), \quad (2)$$

其中 $q_k^{ls} = (1 - \alpha)q_k + \alpha/K$ 是平滑后的标签， α 是平滑参数，经验上设置为 0.1。

3.2. 基于信息的源假设迁移 Maximization (SHOT-IM)

图 2 中由深度神经网络（DNN）参数化的源模型包含两个模块：特征编码模块 $g_s: \mathcal{X}_s \rightarrow \mathbb{R}^d$ 和分类器模块 $h_s: \mathbb{R}^d \rightarrow \mathbb{R}^K$ ，i.e., $f_s(x) = h_s(g_s(x))$ 。此处 d 为输入特征的维度。以往的域适应（DA）方法通过在特征空间 $\mathbb{R}^d$ 中匹配数据分布来对齐不同域。使用最大均值差异（Maximum Mean Discrepancy, MMD）（Long 等，2015）或域对抗对齐（Ganin 和 Lempitsky，2015）。然而，这两种策略都假设源域和目标域共享相同的特征编码器，并且在适应过程中需要访问源数据。这在所提出的域适应设置中并不适用。相比之下，ADDA（Tzeng 等，2017）放宽了参数共享约束，并提出了一种新的对抗性域适应框架，为每个域学习不同的映射函数。此外，DIRT-T（Shu 等，2018）首先训练一个参数共享的域适应框架作为初始化，然后通过最小化聚类假设违反来微调整个网络。这两种方法都表明，学习特定域的特征编码模块是可行的，甚至比参数共享机制效果更好。

我们遵循这一策略，通过固定源模型并学习领域特定的特征编码模块，开发了一种源假设迁移（Source Hypothesis Transfer, SHOT）框架

分类器模块（假设），因为源假设编码了未见源数据的分布信息。具体而言，SHOT 对不同的领域特定特征学习模块使用相同的分类器模块，即。其目标是学习最优的目标特征学习模块 $g_t: \mathcal{X}_t \rightarrow \mathbb{R}^d$ ，使得输出的目标特征能够很好地匹配源特征分布，并能直接由源假设准确分类。值得注意的是，SHOT 仅利用源数据一次来生成源假设，而 ADDA 和 DIRT-T 在学习模型时需要同时访问源域和目标域的数据。

本质上，我们期望学习最优的目标编码器 g_t ，使得目标数据分布 $p(g_t(x_t))$ 与源数据分布 $p(g_s(x_s))$ 良好匹配。然而，特征级对齐完全不可行，因为在无法访问源数据的情况下，估计 $p(g_s(x_s))$ 的分布是不可能的。我们从另一个角度看待这一具有挑战性的问题：如果领域差距得到缓解，未标注的目标数据应具有何种输出？我们认为理想的目标输出应类似于独热编码，但彼此之间又有所不同。为此，我们采用信息最大化（IM）损失（Krause 等, 2010; Shi 和 Sha, 2012; Hu 等, 2017），使目标输出在个体上确定、在全局上多样。在实践中，我们最小化以下 $\mathcal{L}_{ent}$ 和 $\mathcal{L}_{div}$ ，它们共同构成 IM 损失：

$$\begin{aligned}\mathcal{L}_{ent}(f_t; \mathcal{X}_t) &= -\mathbb{E}_{x_t \in \mathcal{X}_t} \sum_{k=1}^K \delta_k(f_t(x_t)) \log \delta_k(f_t(x_t)), \\ \mathcal{L}_{div}(f_t; \mathcal{X}_t) &= \sum_{k=1}^K \hat{p}_k \log \hat{p}_k \\ &= D_{KL}(\hat{p}, \frac{1}{K} \mathbf{1}_K) - \log K,\end{aligned}\quad (3)$$

其中 $f_t(x) = h_t(g_t(x))$ 是每个目标样本的 K 维输出， $\mathbf{1}_K$ is a K 维全一向量， $\hat{p} = \mathbb{E}_{x_t \in \mathcal{X}_t} [\delta(f_t(x_t))]$ 是整个目标域的平均输出嵌入。IM 会比先前领域自适应工作中广泛使用的条件熵最小化（Grandvalet 和 Bengio, 2005; Vu 等, 2019; Saito 等, 2019）表现更好，因为 IM 可以通过公平的多样性促进目标 $\mathcal{L}_{div}$ 来规避所有未标注数据具有相同独热编码的平凡解。

3.3. 源假设迁移增强与自监督伪标签

如图 1 所示，我们展示了由 SHOT-IM 和仅源模型学习到的特征的 t -分布随机邻域嵌入可视化。直观上，仅源模型的目标特征表示分布混乱，而使用 IM 损失有助于将目标数据与不可见的源数据良好对齐。然而，在图 1(b) 中，目标数据可能在某种程度上被匹配到错误的源假设。




图 1. 五路分类任务的 t -分布随机邻域嵌入可视化。深色圆圈表示不可见的源数据，浅色星形表示目标数据。不同颜色代表不同类别。

我们认为，有害影响源于网络输出的不准确。例如，一个来自第 2 类的目标样本，其归一化网络输出为 $[0.4, 0.3, 0.1, 0.1, 0.1]$ ，可能被强制要求具有期望输出 $[1.0, 0.0, 0.0, 0.0, 0.0]$ 。为缓解此类影响，我们进一步对每个无标签数据应用伪标签（Pseudo-Labeling）（Lee, 2013），以更好地监督目标数据编码训练。然而，传统上由源假设生成的伪标签仍因领域偏移而存在噪声。受深度聚类（DeepCluster）（Caron et al., 2018）启发，我们提出一种新颖的自监督伪标签策略。首先，我们获得目标域中每个类别的质心，类似于加权 k 均值聚类，

$$c_k^{(0)} = \frac{\sum_{x_t \in \mathcal{X}_t} \delta_k(\hat{f}_t(x_t)) \hat{g}_t(x_t)}{\sum_{x_t \in \mathcal{X}_t} \delta_k(\hat{f}_t(x_t))}, \quad (4)$$

其中 $\hat{f}_t = \hat{g}_t \circ h_t$ 表示先前学习到的目标假设。这些质心能够稳健且更可靠地刻画目标域内不同类别的分布。然后，我们通过最近质心分类器获得伪标签：

$$\hat{y}_t = \arg \min_k D_f(\hat{g}_t(x_t), c_k^{(0)}), \quad (5)$$

其中 $D_f(a, b)$ 度量 a 与之间的余弦距离。最后，我们基于新的伪标签计算目标质心：

$$\begin{aligned}c_k^{(1)} &= \frac{\sum_{x_t \in \mathcal{X}_t} \mathbf{1}(\hat{y}_t = k) \hat{g}_t(x_t)}{\sum_{x_t \in \mathcal{X}_t} \mathbf{1}(\hat{y}_t = k)}, \\ \hat{y}_t &= \arg \min_k D_f(\hat{g}_t(x_t), c_k^{(1)}).\end{aligned}\quad (6)$$

我们将 $\hat{y}_t$ 称为自监督伪标签，因为它们是由以无监督方式获得的质心生成的。在实践中，我们按式 (6) 对质心和标签进行多轮更新。然而，实验验证表明，仅更新一次即可获得足够好的伪标签。

综上所述，给定源模型 $f_s = g_s \circ h_s$ 和如上生成的伪标签，SHOT 冻结来自源域的假设 $h_t = h_s$ ，并学习特征编码器 g_t




图 2. 我们的 SHOT 框架流程。源模型由特征学习模块和分类器模块（假设）组成。SHOT 保持假设冻结，并利用特征学习模块作为目标域学习的初始化。

完整目标函数为

$$\mathcal{L}(g_t) = \mathcal{L}_{ent}(h_t \circ g_t; \mathcal{X}_t) + \mathcal{L}_{div}(h_t \circ g_t; \mathcal{X}_t) - \beta \mathbb{E}_{(x_t, \hat{y}_t) \in \mathcal{X}_t \times \hat{\mathcal{Y}}_t} \sum_{k=1}^K \mathbb{1}_{[k=\hat{y}_t]} \log \delta_k(h_t(g_t(x_t))), \quad (7)$$

其中 $\beta > 0$ 是平衡超参数。

备注。所提出的 SHOT 框架也可轻松扩展至其他无监督域自适应任务，如部分集域自适应（Partial-set DA）（Cao 等，2018）和开放集域自适应（Open-set DA）（Panareda Busto & Gall, 2017）。更多细节见附录。

3.4. 源模型的网络架构

现在研究如何为自身问题训练更优的源假设。讨论神经网络模型在参数化特征编码模块和假设时的一些架构选择。首先，需要回顾式 (1) 中交叉熵损失的期望网络输出。若 $y_s = k$ ，则最大化 $f_s^{(k)}(x_s) = \frac{\exp(w_k^\top g_s(x_s))}{\sum_i \exp(w_i^\top g_s(x_s))}$ 意味着最小化 $g_s(x_s)$ 与 w_k 之间的距离，其中 w_k 是最后一个全连接层中的第 k 个权重向量。理想情况下，来自第 k 类的所有样本的特征嵌入应接近 w_k 。若未标记的目标样本被赋予正确的伪标签，则通过伪标签项，源特征嵌入与目标特征嵌入相似是容易理解的。其背后的直觉与先前研究（Long 等，2013；Xie 等，2018）非常相似，这些研究利用简化的最大均值差异（MMD）进行判别性域混淆。

由于权重范数在 softmax 输出的内距离中很重要，采用权重归一化（Weight Normalization, WN）（Salimans & Kingma, 2016）以保持全连接分类器层中每个权重向量 w_i 的范数相同。此外，如先前研究所指出的，批归一化（Batch Normalization, BN）（Ioffe & Szegedy, 2015）可以减少内部数据集偏移，因为不同域共享相同的均值（零）和方差，这可以被视为一阶和二阶矩。

基于这些考虑，形成了如图 2 所示的 SHOT 完整框架。在实验中，广泛研究了图 3 中上述每种架构设计的效果。

4. 实验

4.1. 设置

为验证其通用性，本文在多种无监督领域自适应场景下评估了 SHOT，涵盖以下多个流行的视觉基准。完整代码可在 <https://github.com/tim-learn/SHOT> 获取。

办公室（萨恩科等人，2010）是一个标准的领域自适应基准，包含三个领域（亚马逊（**A**）、数码单反相机（**D**）和网络摄像头（**W**）），每个领域在办公环境下包含 31 个物体类别。（龚等人，2012）进一步提取了办公室与加州理工学院-256（**C**）之间共有的 10 个类别，形成了一个名为办公室-加州理工学院的新基准。这两个基准规模均较小。

办公室-家庭（文卡泰斯瓦拉等人，2017 年）是一个具有挑战性的中等规模基准，包含四个不同的领域（艺术图像（**Ar**）、剪贴画（**Cl**）、产品图像（**Pr**）和真实世界图像（**Rw**））。每个领域共有 65 个日常物体类别。

VisDA-C（Peng 等人，2017）是一个具有挑战性的大规模基准，主要关注 12 类合成到真实物体识别任务。源域包含 15.2 万张通过渲染三维模型生成的合成图像，而目标域包含 5.5 万张从微软 COCO 中采样的真实物体图像。

数字 是一个标准的领域自适应基准，专注于数字识别。我们遵循（Hoffman 等人，2018）的协议，并利用三个子集：**SVHN**（**S**）、**MNIST**（**M**）和 **USPS**（**U**）。与（Long 等人，2018）类似，我们使用每个领域的训练集训练模型，并在目标领域的标准测试集上报告识别结果。

基线方法。对于数字识别中的普通无监督领域自适应，我们将 SHOT 与 ADDA（Tzeng 等人，2017）、ADR（Saito 等人，2018a）、CDAN（Long 等人，2018）、CyCADA（Hoffman 等人，2018）、CAT（Deng 等人，2019）和 SWD（Lee 等人，2019a）进行比较。对于物体识别，我们与 DANN（Ganin 和 Lempitsky, 2015）、DAN（Long 等人，2015）、ADR、CDAN、CAT、SAFN（Xu 等人，2019）、BSP（Chen 等人，2019）、TransNorm（Wang 等人，2019）和 SWD 进行比较。对于特定的部分集和开放集领域自适应任务，我们分别与 IWAN（Zhang 等人，2018a）、SAN（Cao 等人，2018）、ETN（Cao 等人，2019）、SAFN、ATI- λ （Panareda Busto 和 Gall, 2017）、OSBP（Saito 等人，2018c）、OpenMax（Bendale 和 Boulton, 2016）、STA（Liu 等人，2019）进行比较。对于多源和多目标领域自适应，我们与 DCTN（Xu 等人，2018）、MCD（Saito 等人，

表 2. 在 **Digits** 数据集上普通闭集领域自适应的分类准确率（%）。S: SVHN, M: MNIST, U: USPS。

Method (Source→Target)	S→M	U→M	M→U	Avg.
Source only (Hoffman et al., 2018)	67.1±0.6	69.6±3.8	82.2±0.8	73.0
ADDA (Tzeng et al., 2017)	76.0±1.8	90.1±0.8	89.4±0.2	85.2
ADR (Saito et al., 2018a)	95.0±1.9	93.1±1.3	93.2±2.5	93.8
CDAN+E (Long et al., 2018)	89.2	98.0	95.6	94.3
CyCADA (Hoffman et al., 2018)	90.4±0.4	96.5±0.1	95.6±0.4	94.2
rRevGrad+CAT (Deng et al., 2019)	98.8±0.0	96.0±0.9	94.0±0.7	96.3
SWD (Lee et al., 2019a)	98.9±0.1	97.1±0.1	98.1±0.1	98.0
Source model only	70.2±1.2	88.0±2.2	79.7±2.5	79.3
SHOT-IM (ours)	99.0±0.1	97.6±0.5	97.7±0.1	98.2
SHOT (full, ours)	98.9±0.1	98.0±0.6	97.9±0.2	98.3
Target-supervised (Oracle)	99.4±0.1	99.4±0.1	98.0±0.1	98.8

2018b), M^3 SDA- β (Peng 等人, 2019a)、FADA (Peng 等人, 2020)、DANN 和 DADA (Peng 等人, 2019b) 分别进行比较。注意, 如果我们遵循相同的设置, 结果直接从已发表的论文中引用。仅源模型表示使用来自源的整个模型进行目标标签预测。SHOT-IM 是 SHOT 的一个特例, 其中通过令 $\beta = 0$ 忽略了自监督伪标签。

4.2. 实现细节

网络架构。 对于数字识别任务, 我们使用与 CDAN (Long 等人, 2018) 相同的架构, 即经典的 LeNet-5 (LeCun 等人, 1998) 网络用于 USPS $\leftrightarrow$ MNIST, LeNet 的一个变体用于 SVHN $\rightarrow$ MNIST。详细的网络在附录 A 中提供。对于物体识别任务, 我们采用预训练的 ResNet-50 或 ResNet-101 (He 等人, 2016) 模型作为骨干模块, 类似于 (Long 等人, 2018; Deng 等人, 2019; Xu 等人, 2019; Peng 等人, 2019a)。遵循 (Ganin 和 Lempitsky, 2015), 我们将原始全连接层替换为图 2 中的瓶颈层 (256 个单元) 和任务特定的全连接分类器层。在瓶颈层内的全连接层之后放置一个批归一化层, 并在最后一个全连接层中使用权重归一化层。

网络超参数。 本文通过反向传播训练整个网络, 新添加的层以预训练层 (图 2 中的骨干网络) 10 倍的学习率进行训练。具体而言, 除 **VisDA-C** 使用 $\eta_0 = 1e^{-3}$ 外, 所有实验均采用动量 0.9、权重衰减 $1e^{-3}$ 的迷你批随机梯度下降, 新层和从头学习的层学习率为 $\eta_0 = 1e^{-2}$ 。此外, 本文采用与 (Ganin & Lempitsky, 2015; Long et al., 2018) 相同的学习率调度器 $\eta = \eta_0 \cdot (1 + 10 \cdot p)^{-0.75}$, 其中 p 为从 0 变化到 1 的训练进度。另外, 所有任务的批大小均设为 64。除 **Digits** 使用 $\beta = 0.1$ 外, 所有实验均利用 $\beta = 0.3$ 。

对于 **Digits** 数据集, 本文使用源数据集的测试集作为验证集来训练最优源假设。对于其他

没有训练-验证划分的数据集, 本文在源数据集中随机指定 0.9/0.1 的划分, 并基于验证划分生成最优源假设。

Digits、Office、Office-Home、VisDA-C 和 Office-Caltech 的最大训练轮次分别经验性地设为 30、100、50、10 和 100。对于目标域的学习, 本文逐轮更新伪标签, 最大训练轮次经验性地设为 15。本文使用 **PyTorch** 以不同的随机种子 {2019, 2020, 2021} 随机运行方法三次, 并报告平均准确率。注意, 本文在评估时未利用任何目标增强, 如十裁剪集成 (Long et al., 2018)。

4.3. 数字识别结果

对于数字识别, 本文在三个闭集自适应任务上评估 SHOT: SVHN $\rightarrow$ MNIST、USPS $\rightarrow$ MNIST 和 MNIST $\rightarrow$ USPS。SHOT 和先前工作的分类准确率报告于表 2。显然, SHOT 在每个任务上均获得最佳或次佳的平均准确率, 并在平均准确率方面优于先前工作。与仅使用源模型相比, SHOT-IM 始终取得更好的结果, 而 SHOT 由于自监督伪标签的贡献略优于 SHOT-IM。值得注意的是, SHOT 在 M $\rightarrow$ U 上与目标监督结果相当。这可能是因为 MNIST 远大于 USPS, 从而很好地缓解了域偏移。

表 3. 小型 Office 数据集上普通闭集领域自适应的分类准确率（%）(ResNet-50)。

Method (Source→Target)	A→D	A→W	D→A	D→W	W→A	W→D	Avg.
ResNet-50 (He et al., 2016)	68.9	68.4	62.5	96.7	60.7	99.3	76.1
DANN (Ganin & Lempitsky, 2015)	79.7	82.0	68.2	96.9	67.4	99.1	82.2
DAN (Long et al., 2015)	78.6	80.5	63.6	97.1	62.8	99.6	80.4
CDAN+E (Long et al., 2018)	92.9	94.1	71.0	98.6	69.3	100.	87.7
rRevGrad+CAT (Deng et al., 2019)	90.8	94.4	72.2	98.0	70.2	100.	87.6
SAFN+ENT (Xu et al., 2019)	90.7	90.1	73.0	98.6	70.2	99.8	87.1
CDAN+BSP (Chen et al., 2019)	93.0	93.3	73.6	98.2	72.6	100.	88.5
CDAN+TransNorm (Wang et al., 2019)	94.0	95.7	73.4	98.7	74.2	100.	89.3
Source model only	80.8	76.9	60.3	95.3	63.6	98.7	79.3
SHOT-IM (ours)	90.6	91.2	72.5	98.3	71.4	99.9	87.3
SHOT (full, ours)	94.0	90.1	74.7	98.4	74.3	99.9	88.6

4.4. 目标识别结果 (普通闭集)

接下来, 我们在多种目标识别基准上评估 SHOT, 包括 Office、Office-Home 和 **VisDA-C**, 在标准闭集域适应设置下。如表 3 所示, SHOT 在两个具有挑战性的任务 D $\rightarrow$ A 和 W $\rightarrow$ A 上表现最佳, 而在其他任务上表现不如先前最先进的方法 (Wang 等人, 2019)。这可能是因为 SHOT 需要相对较大的目标域来学习假设 f_t , 而 D 和 W 作为目标域较小。总体而言, 即使无法直接访问源域数据, SHOT 也获得了具有竞争力的性能。

正如预期, 在中等规模的 Office-Home 数据集上,

表 4. 中等规模 Office-Home 数据集上标准闭集域适应的分类准确率 (%) (ResNet-50)。

Method (Source→Target)	Ar→Cl	Ar→Pr	Ar→Re	Cl→Ar	Cl→Pr	Cl→Re	Pr→Ar	Pr→Cl	Pr→Re	Re→Ar	Re→Cl	Re→Pr	Avg.
ResNet-50 (He et al., 2016)	34.9	50.0	58.0	37.4	41.9	46.2	38.5	31.2	60.4	53.9	41.2	59.9	46.1
DANN (Ganin & Lempitsky, 2015)	45.6	59.3	70.1	47.0	58.5	60.9	46.1	43.7	68.5	63.2	51.8	76.8	57.6
DAN (Long et al., 2015)	43.6	57.0	67.9	45.8	56.5	60.4	44.0	43.6	67.7	63.1	51.5	74.3	56.3
CDAN+E (Long et al., 2018)	50.7	70.6	76.0	57.6	70.0	70.0	57.4	50.9	77.3	70.9	56.7	81.6	65.8
CDAN+BSP (Chen et al., 2019)	52.0	68.6	76.1	58.0	70.3	70.2	58.6	50.2	77.6	72.2	59.3	81.9	66.3
SAFN (Xu et al., 2019)	52.0	71.7	76.3	64.2	69.9	71.9	63.7	51.4	77.1	70.9	57.1	81.5	67.3
CDAN+TransNorm (Wang et al., 2019)	50.2	71.4	77.4	59.3	72.7	73.1	61.0	53.1	79.5	71.9	59.0	82.9	67.6
Source model only	44.6	67.3	74.8	52.7	62.7	64.8	53.0	40.6	73.2	65.3	45.4	78.0	60.2
SHOT-IM (ours)	55.4	76.6	80.4	66.9	74.3	75.4	65.6	54.8	80.7	73.7	58.4	83.4	70.5
SHOT (full, ours)	57.1	78.1	81.5	68.0	78.2	78.1	67.4	54.9	82.2	73.3	58.8	84.3	71.8

表 5. 大规模 VisDA-C 数据集上标准闭集域适应的分类准确率 (%) (ResNet-101)。

Method (Synthesis → Real)	plane	bcycl	bus	car	horse	knife	mcycl	person	plant	sktbrd	train	truck	Per-class
ResNet-101 (He et al., 2016)	55.1	53.3	61.9	59.1	80.6	17.9	79.7	31.2	81.0	26.5	73.5	8.5	52.4
DANN (Ganin & Lempitsky, 2015)	81.9	77.7	82.8	44.3	81.2	29.5	65.1	28.6	51.9	54.6	82.8	7.8	57.4
DAN (Long et al., 2015)	87.1	63.0	76.5	42.0	90.3	42.9	85.9	53.1	49.7	36.3	85.8	20.7	61.1
ADR (Saito et al., 2018a)	94.2	48.5	84.0	72.9	90.1	74.2	92.6	72.5	80.8	61.8	82.2	28.8	73.5
CDAN (Long et al., 2018)	85.2	66.9	83.0	50.8	84.2	74.9	88.1	74.5	83.4	76.0	81.9	38.0	73.9
CDAN+BSP (Chen et al., 2019)	92.4	61.0	81.0	57.5	89.0	80.6	90.1	77.0	84.2	77.9	82.1	38.4	75.9
SAFN (Xu et al., 2019)	93.6	61.3	84.1	70.6	94.1	79.0	91.8	79.6	89.9	55.6	89.0	24.4	76.1
SWD (Lee et al., 2019a)	90.8	82.5	81.7	70.5	91.7	69.5	86.3	77.5	87.4	63.6	85.6	29.2	76.4
Source model only	60.9	21.6	50.9	67.6	65.8	6.3	82.2	23.2	57.3	30.6	84.6	8.0	46.6
SHOT-IM (ours)	93.7	86.4	78.7	50.7	91.0	93.5	79.0	78.3	89.2	85.4	87.9	51.1	80.4
SHOT (full, ours)	94.3	88.5	80.1	57.3	93.1	94.9	80.7	80.3	91.5	89.1	86.3	58.2	82.9

SHOT 显著优于先前发表的最先进方法，在表 4 中将平均准确率从 67.6% (Wang 等人, 2019) 提升至 71.8%。此外，SHOT 在 12 个独立任务中的 10 个上表现最佳。对于表 5 中的大规模合成到真实 VisDA-C 数据集，SHOT 仍然取得了最佳的每类准确率，并在 12 个任务中的 7 个上表现最佳。仔细比较 SHOT 与先前工作，我们发现 SHOT 在最具挑战性的类别“卡车”上表现良好。同样，所提出的自监督伪标签策略效果良好，因为 SHOT 始终优于 SHOT-IM。

表 6. 三个闭集无监督域适应数据集上的平均准确率。

Methods / Datasets	Office	Office-Home	VisDA-C
Source model only	79.3	60.2	46.6
naive pseudo-labeling (PL) (Lee, 2013)	83.0	64.1	76.6
Self-supervised PL (ours)	87.6	68.9	80.7
$\mathcal{L}_{ent}$	83.5	55.5	63.3
$\mathcal{L}_{ent} + \mathcal{L}_{div}$	87.3	70.5	80.4
$\mathcal{L}_{ent} + \mathcal{L}_{div} + \text{naive PL}$ (Lee, 2013)	87.5	70.3	82.9
$\mathcal{L}_{ent} + \mathcal{L}_{div} + \text{Self-supervised PL}$	88.6	71.8	82.9

消融实验。我们在表 6 中研究了自监督伪标签 (PL) 策略相对于朴素策略 (Lee, 2013) 的优势。结果清楚地表明，两种 PL 策略都有效，而我们的自监督 PL 始终远优于朴素策略。令人惊讶的是，仅使用 $\mathcal{L}_{ent}$ 与自监督 PL 结合甚至产生更低的结果。但同时使用 $\mathcal{L}_{ent}$ 和 $\mathcal{L}_{div}$ 时，结果优于自监督 PL 基线，这表明了多样性促进目标 $\mathcal{L}_{div}$ 的重要性。




图 3. 在 $Ar \rightarrow Cl$ 任务上闭集无监督域适应的准确率 (%)。[权重归一化/批归一化/标签平滑] 随后，本文评估了网络架构中每个组件的贡献，结果如图 3 所示。似乎 SHOT-IM 的准确率部分仅依赖于源模型的质量。仅使用源模型的结果在批归一化的帮助下尤其得到提升，批归一化在先前研究中也已被采用 (Xu 等, 2019; Wang 等, 2019)。使用权重归一化和标签平滑可能会降低仅源模型的准确率，但通过 SHOT-IM 仍能获得更好的结果。所有这些组件相互补充，任意两者结合使用有助于仅源模型和 SHOT-IM 达到最佳性能。最终，当网络中同时使用所有这些组件时，SHOT-IM 取得了最佳性能。

4.5. 目标识别结果 (超越基础模型) 闭集)

我们进一步将 SHOT 扩展到另外两种领域自适应场景：多源 (Peng 等人, 2019a) 和多目标 (Peng 等人,

表 7. (OS) 在办公室-家庭数据集上部分集和开放集域适应的分类准确率 (%) (残差网络-50)。

Partial-set DA (Source→Target)	Ar→Cl	Ar→Pr	Ar→Re	Cl→Ar	Cl→Pr	Cl→Re	Pr→Ar	Pr→Cl	Pr→Re	Re→Ar	Re→Cl	Re→Pr	Avg.
ResNet-50 (He et al., 2016)	46.3	67.5	75.9	59.1	59.9	62.7	58.2	41.8	74.9	67.4	48.2	74.2	61.3
IWAN (Zhang et al., 2018a)	53.9	54.5	78.1	61.3	48.0	63.3	54.2	52.0	81.3	76.5	56.8	82.9	63.6
SAN (Cao et al., 2018)	44.4	68.7	74.6	67.5	65.0	77.8	59.8	44.7	80.1	72.2	50.2	78.7	65.3
ETN (Cao et al., 2019)	59.2	77.0	79.5	62.9	65.7	75.0	68.3	55.4	84.4	75.7	57.7	84.5	70.5
SAFN (Xu et al., 2019)	58.9	76.3	81.4	70.4	73.0	77.8	72.4	55.3	80.4	75.8	60.4	79.9	71.8
Source model only	45.2	70.4	81.0	56.2	60.8	66.2	60.9	40.1	76.2	70.8	48.5	77.3	62.8
SHOT-IM (ours)	57.9	83.6	88.8	72.4	74.0	79.0	76.1	60.6	90.1	81.9	68.3	88.5	76.8
SHOT (full, ours)	64.8	85.2	92.7	76.3	77.6	88.8	79.7	64.3	89.5	80.6	66.4	85.8	79.3
Open-set DA (Source→Target)	Ar→Cl	Ar→Pr	Ar→Re	Cl→Ar	Cl→Pr	Cl→Re	Pr→Ar	Pr→Cl	Pr→Re	Re→Ar	Re→Cl	Re→Pr	Avg.
ResNet (He et al., 2016)	53.4	52.7	51.9	69.3	61.8	74.1	61.4	64.0	70.0	78.7	71.0	74.9	65.3
ATI- λ (Panareda Busto & Gall, 2017)	55.2	52.6	53.5	69.1	63.5	74.1	61.7	64.5	70.7	79.2	72.9	75.8	66.1
OSBP (Saito et al., 2018c)	56.7	51.5	49.2	67.5	65.5	74.0	62.5	64.8	69.3	80.6	74.7	71.5	65.7
OpenMax (Bendale & Boulton, 2016)	56.5	52.9	53.7	69.1	64.8	74.5	64.1	64.0	71.2	80.3	73.0	76.9	66.7
STA (Liu et al., 2019)	58.1	53.1	54.4	71.6	69.3	81.9	63.4	65.2	74.9	85.0	75.8	80.8	69.5
Source model only	36.3	54.8	69.1	33.8	44.4	49.2	36.8	29.2	56.8	51.4	35.1	62.3	46.6
SHOT-IM (ours)	62.5	77.8	83.9	60.9	73.4	79.4	64.7	58.7	83.1	69.1	62.0	82.1	71.5
SHOT (full, ours)	64.5	80.4	84.7	63.1	75.4	81.2	65.3	59.3	83.3	69.6	64.6	82.3	72.8

2019b)。对于多源设置，本文首先从不同源域学习多个源假设，并将其逐一直接迁移至目标域。随后，将通过 SHOT 优化的不同目标假设的预测分数相加，以确定具有最大值的标签。对于多目标设置，本文简单地将这些目标域合并，并将其视为 SHOT 的新目标域。SHOT 及先前发表的最先进方法的结果如表 8 所示。显而易见，SHOT 在两种设置下均取得了最佳结果。值得注意的是，FADA (Peng 等人, 2020 年) 不访问源域，而是利用类似联邦学习的梯度更新信息，但在多源设置下其性能远逊于本文的 SHOT。

表 8. 在 Office-Caltech 数据集上多源与多目标域适应的分类准确率 (%) (ResNet-101)。[* $\mathfrak{R}$ 表示除单一源域/目标域外的其余三个域。]

Multi-source ($\mathfrak{R} \rightarrow$)	$\mathfrak{R} \rightarrow A$	$\mathfrak{R} \rightarrow C$	$\mathfrak{R} \rightarrow D$	$\mathfrak{R} \rightarrow W$	Avg.
ResNet-101 (He et al., 2016)	88.7	85.4	98.2	99.1	92.9
DAN (Long et al., 2015)	91.6	89.2	99.1	99.5	94.8
DCTN (Xu et al., 2018)	92.7	90.2	99.0	99.4	95.3
MCD (Saito et al., 2018b)	92.1	91.5	99.1	99.5	95.6
M ³ SDA- β (Peng et al., 2019a)	94.5	92.2	99.2	99.5	96.4
FADA (Peng et al., 2020)	84.2	88.7	87.1	88.1	87.1
Source model only	95.4	93.7	98.9	98.3	96.6
SHOT-IM (ours)	96.2	96.1	98.5	99.7	97.6
SHOT (full, ours)	96.4	96.2	98.5	99.7	97.7
Multi-target ($\rightarrow \mathfrak{R}$)	A $\rightarrow \mathfrak{R}$	C $\rightarrow \mathfrak{R}$	D $\rightarrow \mathfrak{R}$	W $\rightarrow \mathfrak{R}$	Avg.
ResNet-101 (He et al., 2016)	90.5	94.3	88.7	82.5	89.0
SE (French et al., 2018)	90.3	94.7	88.5	85.3	89.7
MCD (Saito et al., 2018b)	91.7	95.3	89.5	84.3	90.2
DANN (Ganin & Lempitsky, 2015)	91.5	94.3	90.5	86.3	90.7
DADA (Peng et al., 2019b)	92.0	95.1	91.3	93.1	92.9
Source model only	90.7	96.1	90.2	90.9	92.0
SHOT-IM (ours)	95.7	97.2	96.3	96.1	96.3
SHOT (full, ours)	96.2	97.3	96.3	96.2	96.5

最后，本文通过将 SHOT 扩展到两个具有挑战性的领域自适应任务——部分领域自适应 (PDA) 和开放集领域自适应 (ODA)，并遵循 (Cao 等人, 2019) 在 Office-Home 数据集上的协议，来评估其泛化能力。

以及 (Liu 等人, 2019) 分别。对于部分域自适应 (PDA)，目标域共有 25 个类别 (按字母顺序的前 25 个)，源域有 65 个类别；而对于开放集域自适应 (ODA)，源域包含相同的 25 个类别，但目标域包含 65 个类别，其中包括未知样本。关于 SHOT 在这两种场景下的工作原理的更多细节分别见附录 B 和 C。表 7 中的结果验证了 SHOT 在这两个具有挑战性的非对称域自适应任务中的有效性。

特殊情况。有人可能会问，如果我们无法自行训练源模型，SHOT 是否仍然有效。为了找到答案，我们利用最流行的现成预训练 ImageNet 模型 ResNet-50 (He 等人, 2016)，并考虑一个部分域自适应任务 (ImageNet $\rightarrow$ Caltech)，在与 (Cao 等人, 2019) 相同的基本设置下评估 SHOT 的有效性。显然，在表 9 中，即使不访问源数据，SHOT 仍然比最先进的 ETN (Cao 等人, 2019) 取得了略高的准确率。

表 9. 部分域自适应任务 (ImageNet $\rightarrow$ Caltech)。† 利用了 ImageNet 的训练集以及预训练的 ResNet-50 模型) 的结果。

Methods	ResNet-50	ETN [†]	SHOT-IM (ours)	SHOT (full, ours)
Accuracy	69.7 $\pm$ 0.0	83.2 $\pm$ 0.2	81.7 $\pm$ 0.5	83.3$\pm$0.1

5. 结论

在本文中，我们通过一个简单而通用的表示学习框架 SHOT 来解决一个实用的无监督域自适应设置。SHOT 仅需要训练良好的源模型，并且提供了在无法访问可能私有且分散的源数据的情况下进行无监督域自适应的可行性。具体来说，SHOT 通过利用信息最大化和自监督伪标签来学习最优的目标特定特征学习模块，以拟合源假设。针对数字识别和物体识别的实验验证了 SHOT 达到了具有竞争力甚至最先进的性能。

致谢： Jiashi Feng 部分得到了 AISG-100E-2019-035 和 MOE2017-T2-2-151 的支持。作者感谢南京信息工程大学江苏省大数据分析技术重点实验室开放项目（编号 KBDat1505）的（部分）支持。作者还感谢 Quanhong Fu 和 Weihao Yu 在改进本文技术写作方面提供的帮助。

Algorithm 1 SHOT algorithm for closed-set UDA task.

Input: source model $f_s = g_s \circ h_s$, target data $\{x_t^i\}_{i=1}^{n_t}$, maximum number of epochs T_m , trade-off parameter β .
Initialization: Freeze the final classifier layer $h_t = h_s$, and copy the parameters from g_s to g_t as initialization.
for $epoch = 1$ **to** T_m **do**
 Obtain self-supervised pseudo labels via Eq. (6)
 for $iter = 1$ **to** n_b **do**
 # min-batch optimization
 Sample a batch from target data and get the corresponding pseudo labels.
 Update the parameters in g_t via $\mathcal{L}(g_t)$ in Eq. (7).
 end for
end for

6. 附录

A. 无监督域自适应场景与网络架构

关于域自适应场景，闭集设定 (Saenko et al., 2010) 最受青睐，其中源域和目标域共享相同的标签空间。随后，原始的一对一自适应被分别扩展到多源 (Peng et al., 2019a) 和多目标 (Peng et al., 2019b) 设定。为了更贴近现实，开集域自适应 (Panareda Busto & Gall, 2017) 假设目标域包含一些未见过的类别，而部分集域自适应 (Cao et al., 2018) 则考虑源域标签空间包含目标域标签空间的设定。

对于数字实验，我们遵循 (Long et al., 2018) 的方法，并在图 4 中展示了详细的网络结构。




图 4. 数字实验所用的网络架构。(a) 用于 MNIST $\leftrightarrow$ USPS, (b) 用于 SVHN $\rightarrow$ MNIST。

B. SHOT 用于部分集域自适应 (PDA) 的细节

考察式 (3) 中的多样性促进项 $\mathcal{L}_{div}$ ，它鼓励目标域具有均匀的目标标签分布。这对于闭集域自适应而言是合理的，但对于部分集域自适应则不然。

在现实中，目标域仅包含源域全部类别中的部分类别，导致标签分布稀疏。因此，对于 PDA，我们舍弃第二项 $\mathcal{L}_{div}$ 。

此外，在自监督伪标签策略中，我们通常需要获取 K 个质心。然而，对于部分域自适应任务，存在一些微小质心，应像 k 均值聚类那样将其视为空。特别地，SHOT 在式 (6) 中丢弃尺寸小于 T_c 的微小质心以用于部分域自适应。接下来，我们在图 5 中展示在 Office-Home 数据集上关于 T_c 选择的平均准确率。




图 5. SHOT-IM 和 SHOT 在 Office-Home 上所有部分集域自适应任务的平均准确率 (%)。 (ResNet-50) C. SHOT 用于开放集域自适应的细节 相反，开放集域自适应问题中的目标域除了源域中出现的类别外，还包含一些未知类别。然而，很难为 SHOT 改变最终分类器层并在目标域中完全学习它。因此，我们采用置信度阈值策略，在 SHOT 学习过程中拒绝目标域中的未知样本。实际上，我们利用网络输出的熵来计算不确定性，并通过除以 $\log K$ 将其归一化到 $[0,1]$ 范围内。对于每个训练轮次，我们首先计算所有不确定性值，并执行二类 k 均值聚类。具有较大平均不确定性的簇将被视为未知类，不用于更新目标质心，也不参与 $\mathcal{L}_{ent}$ 中的目标计算。接下来，我们在图 6 中展示 SHOT 过程中 OS 分数、OS*分数和未知准确率的变化的。具体而言，OS 分数包含未知类并衡量每类准确率，即 $OS = \frac{1}{K+1} \sum_{k=1}^{K+1} Acc_k$ ，其中 K 表示已知类别数， $(K+1)$ -th 类为未知类。OS*分数仅衡量已知类别的每类准确率，即 $OS^* = \frac{1}{K}$ 。




图 6. SHOT 在开放集域自适应任务 $Ar \rightarrow Cl$ on Office-Home 上随训练轮次变化的不同分数。(ResNet-50)

参考文献

- Ben-David, S., Blitzer, J., Crammer, K., Kulesza, A., Pereira, F., and Vaughan, J. W. A theory of learning from different domains. *Springer MLJ*, 79(1-2):151–175, 2010.
- Bendale, A. and Boulton, T. E. Towards open set deep networks. In *CVPR*, 2016.
- Bhushan Damodaran, B., Kellenberger, B., Flamary, R., Tuia, D., and Courty, N. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation. In *ECCV*, 2018.
- Bonawitz, K., Ivanov, V., Kreuter, B., Marcedone, A., McMahan, H. B., Patel, S., Ramage, D., Segal, A., and Seth, K. Practical secure aggregation for privacy-preserving machine learning. In *ACM CCS*, 2017.
- Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., Kiddon, C., Konecny, J., Mazzocchi, S., McMahan, H. B., et al. Towards federated learning at scale: System design. *arXiv preprint arXiv:1902.01046*, 2019.
- Bousmalis, K., Trigeorgis, G., Silberman, N., Krishnan, D., and Erhan, D. Domain separation networks. In *NeurIPS*, 2016.
- Cao, Z., Long, M., Wang, J., and Jordan, M. I. Partial transfer learning with selective adversarial networks. In *CVPR*, 2018.
- Cao, Z., You, K., Long, M., Wang, J., and Yang, Q. Learning to transfer examples for partial domain adaptation. In *CVPR*, 2019.
- Cariucci, F. M., Porzi, L., Caputo, B., Ricci, E., and Bulò, S. R. Autodial: Automatic domain alignment layers. In *ICCV*, 2017.
- Caron, M., Bojanowski, P., Joulin, A., and Douze, M. Deep clustering for unsupervised learning of visual features. In *ECCV*, 2018.
- Chen, X., Wang, S., Long, M., and Wang, J. Transferability vs. discriminability: Batch spectral penalization for adversarial domain adaptation. In *ICML*, 2019.
- Chen, Y., Li, W., Sakaridis, C., Dai, D., and Van Gool, L. Domain adaptive faster r-cnn for object detection in the wild. In *CVPR*, 2018.
- Chidlovskii, B., Clinchant, S., and Csurka, G. Domain adaptation in the absence of source domain data. In *KDD*, 2016.
- Choi, J., Jeong, M., Kim, T., and Kim, C. Pseudo-labeling curriculum for unsupervised domain adaptation. In *BMVC*, 2019.
- Csurka, G. A comprehensive survey on domain adaptation for visual applications. In *Domain Adaptation in Computer Vision Applications*, pp. 1–35. Springer, 2017.
- Deng, Z., Luo, Y., and Zhu, J. Cluster alignment with a teacher for unsupervised domain adaptation. In *ICCV*, 2019.
- French, G., Mackiewicz, M., and Fisher, M. Self-ensembling for visual domain adaptation. In *ICLR*, 2018.
- Ganin, Y. and Lempitsky, V. Unsupervised domain adaptation by backpropagation. In *ICML*, 2015.
- Ghifary, M., Kleijn, W. B., Zhang, M., Balduzzi, D., and Li, W. Deep reconstruction-classification networks for unsupervised domain adaptation. In *ECCV*, 2016.
- Glorot, X., Bordes, A., and Bengio, Y. Domain adaptation for large-scale sentiment classification: a deep learning approach. In *ICML*, 2011.
- Gong, B., Shi, Y., Sha, F., and Grauman, K. Geodesic flow kernel for unsupervised domain adaptation. In *CVPR*, 2012.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., and Bengio, Y. Generative adversarial nets. In *NeurIPS*, 2014.
- Grandvalet, Y. and Bengio, Y. Semi-supervised learning by entropy minimization. In *NeurIPS*, 2005.
- Gretton, A., Borgwardt, K., Rasch, M., Schölkopf, B., and Smola, A. J. A kernel method for the two-sample problem. In *NeurIPS*, 2007.
- He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. In *CVPR*, 2016.
- Hoffman, J., Tzeng, E., Park, T., Zhu, J.-Y., Isola, P., Saenko, K., Efros, A., and Darrell, T. Cycada: Cycle-consistent adversarial domain adaptation. In *ICML*, 2018.
- Hu, W., Miyato, T., Tokui, S., Matsumoto, E., and Sugiyama, M. Learning discrete representations via information maximizing self-augmented training. In *ICML*, 2017.
- Huang, J., Gretton, A., Borgwardt, K., Schölkopf, B., and Smola, A. J. Correcting sample selection bias by unlabeled data. In *NeurIPS*, 2007.
- Ioffe, S. and Szegedy, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *ICML*, 2015.

- Jiang, J. and Zhai, C. Instance weighting for domain adaptation in nlp. In *ACL*, 2007.
- Krause, A., Perona, P., and Gomes, R. G. Discriminative clustering by regularized information maximization. In *NeurIPS*, 2010.
- Kuzborskij, I. and Orabona, F. Stability and hypothesis transfer learning. In *ICML*, 2013.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- Lee, C.-Y., Batra, T., Baig, M. H., and Ulbricht, D. Sliced wasserstein discrepancy for unsupervised domain adaptation. In *CVPR*, 2019a.
- Lee, D.-H. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *Workshop on challenges in representation learning, ICML*, 2013.
- Lee, S., Kim, D., Kim, N., and Jeong, S.-G. Drop to adapt: Learning discriminative features for unsupervised domain adaptation. In *ICCV*, 2019b.
- Liang, J., He, R., Sun, Z., and Tan, T. Aggregating randomized clustering-promoting invariant projections for domain adaptation. *IEEE TPAMI*, 41(5):1027–1042, 2018.
- Liang, J., He, R., Sun, Z., and Tan, T. Distant supervised centroid shift: A simple and efficient approach to visual domain adaptation. In *CVPR*, 2019.
- Liu, H., Cao, Z., Long, M., Wang, J., and Yang, Q. Separate to adapt: Open set domain adaptation via progressive separation. In *CVPR*, 2019.
- Long, M., Wang, J., Ding, G., Sun, J., and Yu, P. S. Transfer feature learning with joint distribution adaptation. In *ICCV*, 2013.
- Long, M., Cao, Y., Wang, J., and Jordan, M. Learning transferable features with deep adaptation networks. In *ICML*, 2015.
- Long, M., Zhu, H., Wang, J., and Jordan, M. I. Deep transfer learning with joint adaptation networks. In *ICML*, 2017.
- Long, M., Cao, Z., Wang, J., and Jordan, M. I. Conditional adversarial domain adaptation. In *NeurIPS*, 2018.
- Mansour, Y., Mohri, M., and Rostamizadeh, A. Domain adaptation with multiple sources. In *NeurIPS*, 2009.
- McMahan, H. B., Ramage, D., Talwar, K., and Zhang, L. Learning differentially private recurrent language models. In *ICLR*, 2018.
- Müller, R., Kornblith, S., and Hinton, G. E. When does label smoothing help? In *NeurIPS*, 2019.
- Nelakurthi, A. R., Maciejewski, R., and He, J. Source free domain adaptation using an off-the-shelf classifier. In *IEEE BigData*, 2018.
- Panareda Busto, P. and Gall, J. Open set domain adaptation. In *ICCV*, 2017.
- Peng, X., Usman, B., Kaushik, N., Hoffman, J., Wang, D., and Saenko, K. Visda: The visual domain adaptation challenge. *arXiv preprint arXiv:1710.06924*, 2017.
- Peng, X., Bai, Q., Xia, X., Huang, Z., Saenko, K., and Wang, B. Moment matching for multi-source domain adaptation. In *ICCV*, 2019a.
- Peng, X., Huang, Z., Sun, X., and Saenko, K. Domain agnostic learning with disentangled representations. In *ICML*, 2019b.
- Peng, X., Huang, Z., Zhu, Y., and Saenko, K. Federated adversarial domain adaptation. In *ICLR*, 2020.
- Saenko, K., Kulis, B., Fritz, M., and Darrell, T. Adapting visual category models to new domains. In *ECCV*, 2010.
- Saito, K., Ushiku, Y., Harada, T., and Saenko, K. Adversarial dropout regularization. In *ICLR*, 2018a.
- Saito, K., Watanabe, K., Ushiku, Y., and Harada, T. Maximum classifier discrepancy for unsupervised domain adaptation. In *CVPR*, 2018b.
- Saito, K., Yamamoto, S., Ushiku, Y., and Harada, T. Open set domain adaptation by backpropagation. In *ECCV*, 2018c.
- Saito, K., Kim, D., Sclaroff, S., Darrell, T., and Saenko, K. Semi-supervised domain adaptation via minimax entropy. In *ICCV*, 2019.
- Salimans, T. and Kingma, D. P. Weight normalization: A simple reparameterization to accelerate training of deep neural networks. In *NeurIPS*, 2016.
- Shi, Y. and Sha, F. Information-theoretical learning of discriminative clusters for unsupervised domain adaptation. In *ICML*, 2012.
- Shu, R., Bui, H. H., Narui, H., and Ermon, S. A dirt-t approach to unsupervised domain adaptation. In *ICLR*, 2018.
- Sun, B., Feng, J., and Saenko, K. Return of frustratingly easy domain adaptation. In *AAAI*, 2016.

- Tommasi, T., Orabona, F., and Caputo, B. Learning categories from few examples with multi model knowledge transfer. *IEEE TPAMI*, 36(5):928–941, 2013.
- Tsai, Y.-H., Hung, W.-C., Schuster, S., Sohn, K., Yang, M.-H., and Chandraker, M. Learning to adapt structured output space for semantic segmentation. In *CVPR*, 2018.
- Tzeng, E., Hoffman, J., Saenko, K., and Darrell, T. Adversarial discriminative domain adaptation. In *CVPR*, 2017.
- Venkateswara, H., Eusebio, J., Chakraborty, S., and Panchanathan, S. Deep hashing network for unsupervised domain adaptation. In *CVPR*, 2017.
- Vu, T.-H., Jain, H., Bucher, M., Cord, M., and Pérez, P. Advent: Adversarial entropy minimization for domain adaptation in semantic segmentation. In *CVPR*, 2019.
- Wang, X., Jin, Y., Long, M., Wang, J., and Jordan, M. I. Transferable normalization: Towards improving transferability of deep neural networks. In *NeurIPS*, 2019.
- Xie, S., Zheng, Z., Chen, L., and Chen, C. Learning semantic representations for unsupervised domain adaptation. In *ICML*, 2018.
- Xu, R., Chen, Z., Zuo, W., Yan, J., and Lin, L. Deep cocktail network: Multi-source unsupervised domain adaptation with category shift. In *CVPR*, 2018.
- Xu, R., Li, G., Yang, J., and Lin, L. Larger norm more transferable: An adaptive feature norm approach for unsupervised domain adaptation. In *ICCV*, 2019.
- Yang, J., Yan, R., and Hauptmann, A. G. Cross-domain video concept detection using adaptive svms. In *ACM-MM*, 2007.
- Yosinski, J., Clune, J., Bengio, Y., and Lipson, H. How transferable are features in deep neural networks? In *NeurIPS*, 2014.
- Zellinger, W., Grubinger, T., Lughofer, E., Natschläger, T., and Saminger-Platz, S. Central moment discrepancy (cmd) for domain-invariant representation learning. In *ICLR*, 2017.
- Zhang, J., Ding, Z., Li, W., and Ogunbona, P. Importance weighted adversarial nets for partial domain adaptation. In *CVPR*, 2018a.
- Zhang, W., Ouyang, W., Li, W., and Xu, D. Collaborative and adversarial network for unsupervised domain adaptation. In *CVPR*, 2018b.
- Zhang, Y., David, P., and Gong, B. Curriculum domain adaptation for semantic segmentation of urban scenes. In *ICCV*, 2017.
- Zou, Y., Yu, Z., Vijaya Kumar, B., and Wang, J. Unsupervised domain adaptation for semantic segmentation via class-balanced self-training. In *ECCV*, 2018.