

TENT: 通过熵最小化实现完全测试时自适应

Dequan Wang^{1*}, Evan Shelhamer^{2*†}, Shaoteng Liu¹, Bruno Olshausen¹, Trevor Darrell¹
 dqwang@cs.berkeley.edu, shelhamer@google.com
 UC Berkeley¹ Adobe Research²

摘要

模型必须在测试期间自适应以泛化到新的、不同的数据。在这种完全测试时自适应的设定下，模型仅拥有测试数据和自身参数。我们提出通过测试熵最小化（tent）进行自适应：以预测的熵来衡量置信度，并据此优化模型。我们的方法估计归一化统计量并优化通道级仿射变换，在每个批次上在线更新。Tent 在损坏的 ImageNet 和 CIFAR-10/100 上降低了图像分类的泛化误差，并在 ImageNet-C 上达到了新的最先进误差水平。Tent 在从 SVHN 到 MNIST/MNIST-M/USPS 的数字识别、从 GTA 到 Cityscapes 的语义分割以及 VisDA-C 基准上处理了无源领域自适应。这些结果是在一个训练轮次的测试时优化中实现的，且无需改变训练过程。

1 引言

深度网络可以在来自相同分布的训练和测试数据上达到高准确率，这一点已被大量基准进展所证明（Krizhevsky et al., 2012; Simonyan & Zisserman, 2015; He et al., 2016）。然而，对新的、不同数据的泛化能力有限（Hendrycks & Dietterich, 2019; Recht et al., 2019; Geirhos et al., 2018）。当训练（源）数据与测试（目标）数据不同时，准确率会下降，这种情况被称为数据集偏移（Quionero-Candela et al., 2009）。模型可能对测试期间出现的、训练时未知的偏移敏感，无论是自然变化还是损坏，例如意外的天气或传感器退化。尽管如此，可能有必要将模型部署到不同的数据分布上，因此需要自适应。

在测试期间，模型必须仅根据自身参数和目标数据进行自适应。这种完全测试时自适应的设定不能依赖源数据或监督。当模型首次遇到新的测试数据时，在数据被收集和标注之前，这两者都不实用，因为推理必须继续进行。现实世界的使用从数据、计算和任务需求三个方面推动了完全测试时自适应：

1. 可用性。模型可能因带宽、隐私或利润原因而在分发时不包含源数据。
2. 效率。在测试期间（重新）处理源数据可能在计算上不实用。
3. 准确率。如果不进行自适应，模型可能因准确率过低而无法达到其目的。

为了在测试过程中进行自适应，我们最小化模型预测的熵。我们将这一目标称为测试熵，并据此将我们的方法命名为 tent。我们选择熵是因为它与误差和分布偏移存在关联。熵与误差相关，因为更自信的预测总体上更正确（图 1）。熵与由损坏引起的偏移相关，因为损坏程度越高，熵越大，并且随着损坏程度的增加，熵与图像分类损失之间存在很强的秩相关性（图 2）。

为了最小化熵，tent 通过逐批估计统计量和优化仿射参数，对目标数据进行归一化和变换推理。这种低维、逐通道的特征调制方式在测试期间能够高效地进行自适应，即使是在线更新也是如此。tent 不限制或改变模型训练：在给定模型参数的情况下，它与源数据无关。只要模型能够运行，就可以进行自适应。最重要的是，tent 不仅有效降低了熵，还降低了误差。* 同等贡献。† 工作完成于 Adobe Research；作者现就职于 DeepMind。1 请访问项目页面 <https://github.com/DequanWang/tent> 获取代码和更多信息。




图 1：在损坏的 CIFAR-100-C 上，熵较低的预测具有较低的误差率。确定性可以在测试期间作为监督信号。




图 2：在 CIFAR-100-C 上，更多的损坏会导致更大的损失和更高的熵。熵可以在没有训练数据或标签的情况下估计偏移程度。

我们的结果评估了图像分类对损坏的泛化能力、数字识别对领域偏移的泛化能力，以及语义分割对仿真到真实偏移的泛化能力。为了与更多数据和优化方法进行对比，我们在给定带标签源数据的情况下，评估了鲁棒训练、领域自适应和自监督学习方法。仅使用目标数据，tent 就能实现更低的误差，并且在 ImageNet-C 基准上超越了最先进的方法。分析实验支持我们的熵目标，检验了对数据量和自适应参数选择的敏感性，并验证了 tent 在不同架构上的通用性。

我们的贡献

- 本文强调完全测试时自适应（Fully Test-Time Adaptation）的设置，仅使用目标数据而无源数据。为强调推理过程中的实用自适应，本文采用离线与在线更新进行基准测试。
- 本文考察熵作为自适应目标，并提出帐篷（Tent）：一种测试时熵最小化方案，通过降低模型在测试数据上预测的熵来减少泛化误差。
- 针对腐蚀的鲁棒性，帐篷在 ImageNet-C 上达到 44.0% 错误率，优于最先进的鲁棒训练方法（50.2%）以及测试时归一化的强基线（49.9%）。
- 针对领域自适应，帐篷能够对数字分类和语义分割进行在线且无源的自适应，甚至可与使用源数据和更多优化的方法相媲美。

2 设置：完全测试时自适应

自适应解决从源到目标的泛化问题。一个在源数据和标签 x^s, y^s 上训练的模型 $f_\theta(x)$ ，其参数为 θ ，在偏移的目标数据 x^t 上测试时可能无法泛化。表 1 总结了自适应设置、所需数据及损失类型。本文的完全测试时自适应设置独特地仅需要模型 f_θ 和无标签目标数据 x^t 用于推理过程中的自适应。

现有自适应设置通过更多数据和监督来扩展训练。迁移学习中的微调（Donahue 等，2014；Yosinski 等，2014）需要目标标签以使用监督损失 $L(x^t, y^t)$ 进行（重新）训练。在没有目标标签的情况下，本文的设置不允许这种监督训练。领域自适应（DA）（Quionero-Candela 等，2009；Saenko 等，2010；Ganin 和 Lempitsky，2015；Tzeng 等，2015）需要源数据和目标数据，以使用跨域损失 $L(x^s, x^t)$ 进行训练。测试时训练（TTT）（Sun 等，2019b）在测试期间进行自适应，但首先改变训练方式，以联合优化其监督损失 $L(x^s, y^s)$ 和自监督损失 $L(x^s)$ 。在没有源数据的情况下，本文的设置不允许跨域（DA）或跨损失（TTT）的联合训练。现有设置各有其用途，但并未涵盖源数据、目标数据或监督无法同时获得的所有实用情况。

测试期间出现意外的目标数据时，需要进行测试时自适应。测试时训练（TTT）和我们的设定通过在测试期间优化无监督损失来调整模型 $L(x^t)$ 。在训练期间，TTT 在源数据上联合优化同一损失 $L(x^s)$ 和监督损失 $L(x^s, y^s)$ ，以确保参数 θ 在损失之间共享，从而与通过 $L(x^t)$ 进行的自适应兼容。完全测试时自适应在给定参数 θ 的情况下独立于训练数据和训练损失。由于不改变训练，我们的设定有可能需要更少的数据和计算来进行自适应。

表 1: 自适应设定因数据不同而不同, 因此在训练和测试期间的损失也不同。在源 s 和目标 t 数据 x 及标签 y 中, 我们的完全测试时设定只需要目标数据 x^t 。

setting	source data	target data	train loss	test loss
fine-tuning	-	x^t, y^t	$L(x^t, y^t)$	-
domain adaptation	x^s, y^s	x^t	$L(x^s, y^s) + L(x^s, x^t)$	-
test-time training	x^s, y^s	x^t	$L(x^s, y^s) + L(x^s)$	$L(x^t)$
fully test-time adaptation	-	x^t	-	$L(x^t)$




图 3: 方法概述。Tent 不改变训练 (a), 但在测试期间 (b) 通过约束调制 Δ 最小化预测的熵, 给定参数 θ 和目标数据 x^t 。

3 方法: 通过特征调制的测试熵最小化

我们在测试期间通过调制模型的特征来优化模型, 以最小化其预测的熵。我们将此方法称为 tent (测试熵)。Tent 需要一个兼容的模型、一个要最小化的目标 (第 3.1 节) 以及要优化的参数 (第 3.2 节), 以完全定义算法 (第 3.3 节)。图 3 概述了我们的完全测试时自适应方法。

要调整的模型必须是为监督任务训练的、概率性的且可微分的。测试期间不提供监督, 因此模型必须已经训练好。测量预测的熵需要预测上的分布, 因此模型必须是概率性的。快速迭代优化需要梯度, 因此模型必须是可微分的。用于监督学习的典型深度网络满足这些模型要求。

3.1 熵目标

我们的测试时目标 $L(x_t)$ 是最小化模型预测 $\hat{y} = f_\theta(x^t)$ 的熵 $H(\hat{y})$ 。具体来说, 我们测量香农熵 (Shannon, 1948), $H(\hat{y}) = -\sum_c p(\hat{y}_c) \log p(\hat{y}_c)$, 其中 $\hat{y}_c$ 是类别 c 的概率。注意, 优化单个预测有一个平凡解: 将所有概率分配给最可能的类别。我们通过在批次内共享的参数上联合优化批量预测来防止这种情况。

熵是一种无监督目标, 因为它仅依赖于预测而非标注。然而, 作为预测的一种测度, 它与监督任务及模型直接相关。

相比之下, 自监督学习的代理任务与监督任务并不直接相关。代理任务从输入 x_t 中推导出自监督标签 y' , 而不使用任务标签 y 。这些代理任务的例子包括旋转预测 (Gidaris 等人, 2018)、上下文预测 (Doersch 等人, 2015) 以及跨通道自动编码 (Zhang 等人, 2017)。在代理任务上取得过多进展可能会干扰监督任务上的性能, 因此自监督适应方法必须相应地限制或混合更新 (Sun 等人, 2019b; a)。因此, 需要谨慎选择与领域和任务兼容的代理任务, 为代理模型设计架构, 并平衡任务目标与代理目标之间的优化。我们的熵目标不需要这些努力。

3.2 调制参数

模型参数 θ 是测试时优化的自然选择, 也是先前工作在训练时熵最小化中的选择 (Grandvalet 与 Bengio, 2005; Dhillon 等人, 2020; Carlucci 等人, 2017)。然而, θ 是我们设置中训练/源数据的唯一表示, 改变 θ 可能导致模型偏离其训练状态。此外, f 可能是非线性的, 且 θ 可能是高维的, 这使得优化过于敏感且对测试时使用而言效率低下。




图 4: Tent 在测试期间通过估计归一化统计量 μ, σ 并优化变换参数 γ, β 来调制特征。归一化和变换对特征应用逐通道的缩放和平移。统计量和参数在目标数据上更新，不使用源数据。实际上，适应 γ, β 是高效的，因为它们占模型参数的比例不到 1%。

为了稳定性和效率，我们仅更新线性的（缩放和平移）且低维的（逐通道）特征调制。图 4 展示了我们调制的两个步骤：通过统计量进行归一化和通过参数进行变换。归一化通过其均值 μ 和标准差 σ 将输入 x 中心化并标准化为 $\bar{x} = (x - \mu)/\sigma$ 。变换通过仿射参数（缩放 γ 和平移 β ）将 $\bar{x}$ 转换为输出 $x' = \gamma\bar{x} + \beta$ 。注意，统计量 μ, σ 是从数据中估计的，而参数 γ, β 是通过损失优化的。

在实现上，我们直接复用源模型的归一化层。在测试期间，我们更新所有层和通道的归一化统计量与仿射参数。

3.3 算法

初始化 优化器收集源模型中每个归一化层 l 和通道 k 的仿射变换参数 $\{\gamma_{l,k}, \beta_{l,k}\}$ 。其余参数 $\theta \setminus \{\gamma_{l,k}, \beta_{l,k}\}$ 保持固定。来自源数据的归一化统计量 $\{\mu_{l,k}, \sigma_{l,k}\}$ 被丢弃。

迭代 每一步在一批数据上更新归一化统计量和变换参数。在前向传播过程中，逐层估计归一化统计量。变换参数 γ, β 通过预测熵 $\nabla H(\hat{y})$ 的梯度在后向传播过程中更新。注意，变换更新跟随当前批次的预测，因此它只影响下一批次（除非重复前向传播）。这仅需每个数据点额外计算一个梯度，因此我们默认采用此方案以提高效率。

终止 对于在线自适应，无需终止，只要有测试数据，迭代就会持续进行。对于离线自适应，模型先进行更新，然后重复推理。当然，可以通过多个训练轮次的更新继续自适应。

4 实验

我们在 CIFAR-10/CIFAR-100 和 ImageNet 上评估了 tent 对损坏鲁棒性的表现，并在从 SVHN 到 MNIST/MNIST-M/USPS 的数字自适应任务上评估了领域自适应性能。我们的实现基于 PyTorch (Paszke 等, 2019) 和 pycls 库 (Radosavovic 等, 2019)。

数据集 我们在图像分类数据集上进行了损坏和领域自适应条件下的实验。对于大规模实验，我们选择了 ImageNet (Russakovsky 等, 2015)，包含 1,000 个类别、120 万张训练集和 5 万张验证集。对于规模适中的实验，我们选择了 CIFAR-10/CIFAR-100 (Krizhevsky, 2009)，分别包含 10/100 个类别、5 万张训练集和 1 万张测试集。对于领域自适应，我们选择 SVHN (Netzer 等, 2011) 作为源域，MNIST (LeCun 等, 1998) /MNIST-M (Ganin 和 Lempitsky, 2015) /USPS (Hull, 1994) 作为目标域，均包含数字 0-9 的十个类别。SVHN 包含来自街景的彩色门牌号图像，训练集为 73,257 张，测试集为 26,032 张。MNIST/MNIST-M/USPS 包含手写数字，训练集分别为 60,000/60,000/7,291 张，测试集分别为 10,000/10,000/2,007 张。

模型 对于损坏实验，我们使用残差网络 (He 等, 2016)，在 CIFAR-10/100 上采用 26 层 (R-26)，在 ImageNet 上采用 50 层 (R-50)。对于领域自适应，我们使用 R-26 架构。为了公平比较，每种实验条件下的所有方法共享相同的架构。

我们的网络配备了批归一化 (Ioffe 和 Szegedy, 2015)。对于未进行自适应的源模型，归一化统计量在源数据训练期间估计。对于所有测试时自适应方法，我们在目标数据测试期间估计这些统计量，这与同期基于归一化的自适应工作 (Schneider 等, 2020; Nado 等, 2020) 一致。

表 2: CIFAR-10-C 和 CIFAR-100-C 上最高严重程度损坏基准。Tent 误差最小，优化量少于领域自适应（RG、UDA-SS）和测试时训练（TTT），并优于测试时归一化（BN）。

Method	Source	Target	Error (%)	
			C10-C	C100-C
Source	train		40.8	67.2
RG	train	train	18.3	38.9
UDA-SS	train	train	16.7	47.0
TTT	train	test	17.5	45.0
BN		test	17.3	42.6
PL		test	15.7	41.2
Tent (ours)		test	14.3	37.3




图 5: ImageNet-C 上的损坏基准：每种损坏类型的误差在严重程度级别上取平均。Tent 通过完全测试时自适应而不改变训练，改进了先前最先进的对抗噪声训练方法（Rusak 等人，2020）。

优化 我们按照源模型的训练超参数优化调制参数 γ, β ，仅做少量更改。在 ImageNet 上，我们使用带动量的随机梯度下降进行优化；在其他数据集上，我们使用 Adam 优化器（Kingma & Ba, 2015）。我们降低批大小（BS）以减少推理时的内存使用，然后按相同比例降低学习率（LR）以进行补偿（Goyal 等人，2017）。在 ImageNet 上，我们设置 BS 为= 64，LR 为= 0.00025；在其他数据集上，我们设置 BS 为= 128，LR 为= 0.001。我们通过打乱顺序并在各方法间共享该顺序来控制顺序效应。

基线 我们与领域自适应、自监督、归一化和伪标签方法进行比较：

- source：将训练好的分类器直接应用于测试数据，不进行自适应。
- 对抗领域自适应（RG）：反转源域和目标域上领域分类器的梯度，以优化领域不变表示（Ganin & Lempitsky, 2015）。
- 自监督领域自适应（UDA-SS）：在源域和目标域上联合训练自监督旋转和位置任务，以优化共享表示（Sun 等人，2019a）。
- 测试时训练（Test-Time Training, TTT）在源数据上联合训练监督与自监督任务，然后在测试期间继续在目标数据上训练自监督任务（Sun 等，2019b），
- 测试时归一化（Test-Time Normalization, BN）在测试期间更新目标数据上的批归一化统计量（Ioffe & Szegedy, 2015）（Schneider 等，2020；Nado 等，2020），
- 伪标签（Pseudo-Labeling, PL）调整置信度阈值，将超过阈值的预测作为标签，然后在测试前针对这些伪标签优化模型（Lee, 2013）。

只有测试时归一化（BN）、伪标签（PL）和 tent（本文方法）是完全的测试时自适应方法。关于与领域自适应和测试时训练的解释与对比，请参见第 2 节。

4.1 对损坏的鲁棒性

为评估对损坏的鲁棒性，我们使用常见的图像损坏（示例见附录 A）。通过复制测试/验证集并施加 15 种损坏类型、5 个严重程度级别，将 CIFAR-10/100 和 ImageNet 数据集转换为 CIFAR-10/100-C 和 ImageNet-C 损坏基准（Hendrycks & Dietterich, 2019）。

Tent 以更少的数据和计算获得更大提升。表 2 报告了在最严重损坏级别下按损坏类型平均的错误率。在 CIFAR-10/100-C 上，考虑到这些数据集的规模适中，我们比较了所有方法，包括那些需要跨领域或跨损失联合训练的方法。为与离线基线公平比较，自适应采用离线方式。Tent 不仅优于完全测试时自适应基线（BN、PL），还优于领域自适应（RG、UDA-SS）和测试时训练方法。

（TTT）方法需要在源域和目标域上进行多个训练轮次的优化。

Tent 在各种损坏类型上均能持续提升性能。图 5 绘制了在 ImageNet-C 上按损坏类型平均、跨损坏级别统计的错误率。考虑到其他方法所需源数据规模庞大（超过 100 万张图像）以及 75 种损坏类型与级别的目标组合，我们比较了最高效的方法——源模型、归一化和 Tent。Tent 和 BN 在线自适应，其效率可与无自适应的推理相媲美。Tent 在大多数损坏类型上达到最低错误率，且不会增加原始数据上的错误率。

表 3: 从 SVHN 到 MNIST/MNIST-M/USPS 的数字领域自适应。无源自适应不仅可行, 而且更高效。Tent 始终优于归一化 (BN), 并且在 3 个案例中有 2 个案例的错误率低于领域自适应 (RG、UDA-SS), 且无需在源域和目标域上进行联合训练。

Method	Source	Target	Epochs	Error (%)		
			Source + Target	MNIST	MNIST-M	USPS
Source	train		-	18.2	39.7	19.3
RG	train	train	10 + 10	15.0	33.4	18.9
UDA-SS	train	train	10 + 10	11.1	22.2	18.4
BN		test	0 + 1	15.7	39.7	18.0
Tent (ours)		test	0 + 1	10.0	37.0	16.3
Tent (ours)		test	0 + 10	8.2	36.8	14.4

Tent 在不改变训练过程的情况下达到了新的最先进水平。 最先进的鲁棒性方法通过对抗噪声 (ANT) (Rusak 等人, 2020) 扩展训练, 达到 50.2% 错误率, 或通过数据增强混合 (AugMix) (Hendrycks 等人, 2020) 达到 51.7% 错误率。结合外部图像的风格化 (SIN) (Geirhos 等人, 2019), ANT+SIN 达到 47.4%。Tent 通过在线自适应达到新的最先进水平 44.0%, 通过离线自适应达到 42.3%。除噪声类型 (ANT 在其上训练) 外, Tent 在所有类型上均优于 ANT。这仅需每个测试点一次梯度计算, 无需在训练集上进行更多优化 (ANT、AugMix) 或使用外部图像 (SIN)。在完全测试时自适应方法中, Tent 将错误率降低到测试时归一化以下, 相对改进 18%。在同期工作中, Schneider 等人 (2020) 报告测试时归一化的错误率为 49.3%, Tent 仍相对改进 14%。

4.2 无源领域自适应

我们针对从 SVHN 到 MNIST/MNIST-M/USPS 的偏移, 对数字自适应 (Ganin 和 Lempitsky, 2015; Tzeng 等人, 2015; 2017; Shu 等人, 2018) 进行基准测试。回顾一下, 无监督领域自适应利用带标签的源数据和未带标签的目标数据, 而我们的完全测试时自适应设置禁止使用源数据。为了与离线基线进行公平比较, 自适应采用离线方式。

Tent 在无源数据的情况下适应目标。 表 3 报告了领域自适应和全测试时自适应方法的目标误差。测试时归一化 (BN) 略有改善, 而对抗性领域自适应 (RG) 和自监督领域自适应 (UDA-SS) 通过在源数据和目标数据上联合训练改善更多。Tent 始终比源模型和 BN 具有更低的误差, 并且在三分之二的情况下达到最低误差, 即使仅在一个训练轮次内且不使用源数据。

虽然全测试时自适应令人鼓舞, 但无监督领域自适应对于最高准确率和更困难的偏移仍然是必要的。对于 SVHN 到 MNIST 的迁移, DIRT-T (Shu 等人, 2018) 实现了显著的 0.6% 误差²。对于 MNIST 到 SVHN 的迁移, 这是一个困难的偏移, 仅源数据的误差为 71.3%, DIRT-T 达到 45.5%, UDA-SS 达到 38.7%。Tent 在此偏移上失败, 并将误差增加到 79.8%。在这种情况下, 成功目前需要在源数据和目标数据上进行联合优化。

Tent 需要更少的计算, 但通过更多计算仍能进一步改善。 Tent 仅使用目标数据, 每个点仅需一次梯度即可高效适应。RG 和 UDA-SS 还使用源数据 (SVHN 训练集), 其规模是目标数据 (MNIST 测试集) 的 $\sim 7\times$ 倍, 并优化 10 个训练轮次。Tent 以 $\sim 80\times$ 更少的计算进行适应。通过更多更新, Tent 在 10 个训练轮次内达到 8.2% 误差, 在 100 个训练轮次内达到 6.5% 误差。通过在线更新, Tent 在一个训练轮次内达到 12.5% 误差, 在 10 个训练轮次内达到 8.4% 误差。

Tent 可扩展到语义分割。 为了展示对大型模型和输入的可扩展性, 我们在从模拟源到真实目标的领域偏移上评估语义分割 (像素级分类)。源数据是 GTA (Richter 等人, 2017), 一个城市环境中的视频游戏, 目标数据是 Cityscapes (Cordts 等人, 2016), 一个城市自动驾驶数据集。模型是 HRNet-W18, 一个具有高分辨率架构的全卷积网络 (Shelhamer 等人, 2017; Wang 等人, 2020)。目标交并比得分 (越高越好) 为源 28.8%, BN 31.4%, Tent 通过 Adam 离线优化达到 35.8%。对于单张图像的适应, Tent 通过情景优化在 10 次迭代内达到 36.4%。定性示例见附录 (附录 B)。

² 我们因架构和模型选择上不可比的差异而将 DIRT-T 排除在我们的实验之外。DIRT-T 使用带标签的目标数据进行微调, 而我们不使用。更多细节请参考 Shu 等人 (2018)。




图 6: Tent 降低了熵和损失。我们绘制了 CIFAR-100-C 上所有数据在熵变化 ΔH 和损失变化 ΔL 方面的变化。熵的变化与损失的变化在秩上相关: 注意深色对角线以及秩相关系数 0.22。




图 7: CIFAR-100-C 上带有高斯噪声的自适应特征 (前) 与无损坏的参考特征 (后)。损坏使特征偏离参考, 但批量归一化 (BN) 减少了偏移。Tent 则使特征偏移更多, 并且更接近在目标标签上优化的理想情况。

Tent 可扩展至 VisDA-C 挑战。 为了在更困难的基准上展示自适应能力, 我们在 VisDA-C 挑战 (Peng 等人, 2017) 上进行了评估。该任务是针对 12 个类别的物体识别, 其中源数据通过渲染三维模型合成, 目标数据从真实场景中收集。我们的源模型 (ResNet-50, 在 ImageNet 上预训练) 的验证误差为 56.1%, 而 Tent 达到 45.6%, 并且通过更新除最终分类器之外的所有层 (如 Liang 等人 (2020) 所做), 可进一步改进至 39.6%。尽管离线无源自适应方法如模型自适应 (Li 等人, 2020) 或 SHOT (Liang 等人, 2020) 可以通过更多计算和调优达到更低的误差, 但 Tent 可以在测试期间在线自适应。

4.3 分析

Tent 降低了熵和误差。 图 6 验证了 Tent 确实降低了熵和任务损失 (Softmax 交叉熵)。我们绘制了 CIFAR-100-C 上所有 75 种损坏类型/级别组合的熵和损失变化。两个轴均按预测的最大熵 ($\log 100$) 归一化, 并裁剪至 ± 1 。大多数点在自适应后具有更低的熵和误差。

Tent 需要特征调制。 我们消融了特征调制中的归一化和变换步骤。不更新归一化会增加误差, 并且可能无法优于批归一化 (BN) 和预测对数 (PL)。不更新变换参数会将方法退化为测试时归一化。仅更新模型的最后一层可以带来改进, 但随后会随着进一步优化而退化。更新完整模型参数 θ 从未优于未适应的源模型。

Tent 在目标数据上具有泛化性。 适应可能仅限于用于更新的数据点。我们通过在目标训练集上适应而不在目标测试集上适应来检查适应是否跨数据点泛化。测试误差下降: CIFAR-100-C 误差从 37.3% 降至 34.2%, SVHN 到 MNIST 误差从 8.2% 降至 6.5%。(训练集比测试集大; 当子采样到相同大小时, 误差差异小于 0.1%。) 因此适应后的调制不是点特定的, 而是具有泛化性的。

Tent 调制不同于归一化。 调制对特征进行归一化和变换。我们考察了组合效应。图 7 将损坏数据上的适应特征与未损坏数据上的参考特征进行对比。我们绘制了来自源模型、归一化、tent 以及在目标标签上优化的预言机的特征。归一化使特征更接近参考特征, 但 tent 并非如此。相反, tent 使特征更接近预言机。这表明存在一种不同的、任务特定的效应。更多层的可视化见附录 (附录 C)。

Tent 适应替代架构。Tent 原则上与架构无关。为了评估其在实践中的通用性，我们评估了基于自注意力（SAN）（Zhao 等人，2020）和均衡求解（MDEQ）（Bai 等人，2020）的新架构在 CIFAR-100-C 上的损坏鲁棒性。表 4 显示，在与卷积残差网络相同的设置下，tent 降低了误差。

表 4: Tent 在 CIFAR-100-C 上无需调参即可适应替代架构。结果为误差（%）。

SAN-10 (pair)			SAN-10 (patch)			MDEQ (large)		
Source	BN	Tent	Source	BN	Tent	Source	BN	Tent
55.3	39.7	36.7	48.0	31.8	29.2	53.3	44.9	41.7

5 相关工作

本文将帐篷（tent）与现有的自适应、熵最小化和特征调制方法进行关联。

训练时自适应 领域自适应通过跨域损失 $L(x^s, x^t)$ 在源域和目标域上联合优化，以缓解分布偏移。这些损失优化特征对齐（Gretton 等人，2009；Sun 等人，2017）、对抗不变性（Ganin & Lempitsky，2015；Tzeng 等人，2017）或共享代理任务（Sun 等人，2019a）。直推式学习（Gammerman 等人，1998；Joachims，1999；Zhou 等人，2004）在训练集和测试集上联合优化，以更好地拟合特定测试实例。尽管这些方法在其设定中有效，但当不允许联合使用源域/训练集和目标域/测试集时，两者均不适用。帐篷仅在目标域上自适应。

近期“无源”方法（Li 等人，2020；Kundu 等人，2020；Liang 等人，2020）同样无需源数据即可自适应。Li 等人（2020）；Kundu 等人（2020）依赖生成建模，并使用多个损失优化多个模型。Kundu 等人（2020）；Liang 等人（2020）还改变了训练过程。帐篷无需生成建模，也不改变训练，因此可以更广泛地部署，以更高的计算效率在线自适应。SHOT（Liang 等人，2020）通过信息最大化（熵最小化和多样性正则化）进行自适应，但其其他损失和参数化方式有所不同。这些无源方法以离线方式、使用多个损失进行多个训练轮次的优化，相比帐篷需要更多调参和计算，但可能以更多计算换取更高准确率。帐篷仅使用一个损失和高效的调制参数化进行在线优化，以强调推理过程中的完全测试时自适应。我们鼓励对无源数据自适应前沿的每一项工作进行考察。

Chidlovskii et al. (2016) are the first to motivate adaptation without source data for legal, commercial, or technical concerns. They adapt predictions by applying denoising auto-encoders while we adapt models by entropy minimization. We share their motivations, but the methods and experiments differ.

测试时自适应 帐篷通过测试时优化和归一化来更新模型。测试时预测自适应——即根据较容易和较确定的案例调整较困难和不确定的案例（Jain & Learned-Miller，2011）——为类似本文的基于确定性的模型自适应方案提供了启发。

测试时训练（Test-time Training, TTT）（Sun et al., 2019b）也在测试期间进行优化，但其损失函数不同，且必须改变训练方式。TTT 依赖于一个代理任务，例如识别图像的旋转，因此其损失取决于代理任务的选择。（事实上，其作者警告代理任务必须“在新领域中既定义明确又非平凡”）。TTT 改变训练方式，在适应目标域之前先在源域上优化该代理损失。Tent 无需代理任务且不改变训练方式即可进行适应。

归一化特征统计量在领域自适应中很常见（Gretton et al., 2009; Sun et al., 2017）。对于批归一化，Li et al. (2017); Carlucci et al. (2017) 在训练期间分离源域和目标域的统计量。Schneider et al. (2020); Nado et al. (2020) 在测试期间估计目标域统计量以提高泛化能力。Tent 基于测试时归一化进一步降低泛化误差。

熵最小化 熵最小化是领域自适应（Carlucci et al., 2017; Shu et al., 2018; Saito et al., 2019; Roy et al., 2019）、半监督学习（Grandvalet & Bengio, 2005; Lee, 2013; Berthelot et al., 2019）和小样本学习（Dhillon et al., 2020）中的关键正则化方法。正则化熵惩罚数据分布中高密度区域的决策，以提高不同类别的准确率（Grandvalet & Bengio, 2005）。这些方法在训练期间与其他监督和无监督损失一起在额外数据上正则化熵。Tent 是第一个在测试期间最小化

熵的方法，用于适应数据集偏移，无需其他损失或数据。熵损失很常见；我们的贡献在于展示熵作为完全测试时自适应的唯一损失。

特征调制 调制使模型随输入而变化。我们优化比完整模型更简单的调制，以实现稳定高效的适应。我们调制通道级仿射变换，因为它们在归一化（Ioffe & Szegedy, 2015; Wu & He, 2018）中有效，并且在为不同任务进行条件化时具有灵活性（Perez et al., 2018）。这些归一化和条件化方法在训练期间通过监督损失优化调制，但在测试期间保持固定。我们在测试期间通过无监督损失优化调制，使其能够适应不同的目标数据。

6 讨论

Tent 通过测试时熵最小化降低偏移数据上的泛化误差。在最小化熵的过程中，模型根据自身预测的反馈进行自适应。这真正实现了自监督的自我改进。与旨在从数据中提取更多监督信息的代理任务不同，此类自监督完全由监督任务定义，然而它仍能显著降低误差。尽管如此，由损坏和其他偏移引起的误差依然存在，因此需要更多的自适应。后续工作应致力于在更多且更困难的偏移类型上、针对更通用的参数、采用更有效且高效的目标函数进行测试时自适应。

偏移 Tent 能够降低多种偏移下的误差，包括图像损坏、数字外观的简单变化以及仿真到现实的差异。这些偏移作为标准化基准被广泛使用，但还存在其他现实世界的偏移。例如，CIFAR 10.1 和 ImageNetV2 测试集（Recht 等人，2018；2019）通过复现数据集收集流程制作，包含自然但未知的偏移。尽管两个测试集上的误差均较高，表明存在偏移，但 Tent 并未提升泛化能力。对抗性偏移（Szegedy 等人，2014）同样威胁实际应用，且攻击者不断适应防御措施。虽然对抗训练（Madry 等人，2018）有所助益，但测试时自适应有助于应对此类测试时攻击。

参数 Tent 通过归一化和变换调节模型，但模型的大部分参数保持固定。测试时自适应可以更新更多模型参数，但关键在于识别既具表达力又可靠的参数，这可能与目标函数的选择相互影响。TTT 自适应监督与自监督模型共享的多层特征，SHOT 则自适应除最后一层（或几层）外的所有模型参数。这些选择取决于模型架构、目标函数和调参。对于 Tent 而言，调节是可靠的，但 VisDA 上更大的偏移更适合采用 SHOT 的参数化方式。联合自适应输入可能是一种更通用的替代方案。如果模型能够在目标域上自适应，那么其输入梯度或许可以优化空间变换或图像平移，从而在无源数据的情况下减少偏移。

目标函数 Tent 最小化熵。为了更强的适应性，是否存在一种有效的损失函数，用于通用但偶发性的测试时优化？熵在任务间具有通用性，但作用范围有限。它需要批量数据进行优化，无法逐点进行偶发性更新。TTT 可以做到这一点，但前提是使用合适的代理任务。为了减少计算量，是否存在一种高效的损失函数，用于更局部的优化？Tent 和 TTT 都要求对模型进行完整（重新）计算以进行更新，因为它们依赖于模型的预测。如果损失函数改为定义在表示上，那么更新所需的向前和向后计算就会减少。具体回到熵，该损失可能与校准（Guo et al., 2017）相互作用，因为更好的不确定性估计可能推动更好的适应性。

我们希望完全测试时自适应设置能够促进新方法的提出，使模型能够自我调整，正如 tent 每次更新都会产生一个新模型。

致谢

我们感谢 Eric Tzeng 在领域自适应方面的讨论，Bill Freeman 对实验的评论，Yu Sun 在测试时训练方面的咨询，以及 Kelsey Allen 对表述的反馈。我们感谢 ICLR 2021 的匿名审稿人提出的反馈，这些反馈无疑改进了本文的最新版本。

参考文献

- Shaojie Bai, Vladlen Koltun, and J Zico Kolter. Multiscale deep equilibrium models. *arXiv preprint arXiv:2006.08656*, 2020.
- David Berthelot, Nicholas Carlini, Ian Goodfellow, Nicolas Papernot, Avital Oliver, and Colin A Raffel. Mixmatch: A holistic approach to semi-supervised learning. In *NeurIPS*, 2019.
- Fabio Maria Carlucci, Lorenzo Porzi, Barbara Caputo, Elisa Ricci, and Samuel Rota Buló. Autodial: Automatic domain alignment layers. In *2017 IEEE International Conference on Computer Vision (ICCV)*, pp. 5077–5085. IEEE, 2017.
- Boris Chidlovskii, Stephane Clinchant, and Gabriela Csurka. Domain adaptation in the absence of source domain data. In *SIGKDD*, pp. 451–460, 2016.
- Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The cityscapes dataset for semantic urban scene understanding. In *CVPR*, 2016.
- Guneet Singh Dhillon, Pratik Chaudhari, Avinash Ravichandran, and Stefano Soatto. A baseline for few-shot image classification. In *ICLR*, 2020.
- Carl Doersch, Abhinav Gupta, and Alexei A Efros. Unsupervised visual representation learning by context prediction. In *ICCV*, 2015.
- J. Donahue, Y. Jia, O. Vinyals, J. Hoffman, N. Zhang, E. Tzeng, and T. Darrell. Decaf: A deep convolutional activation feature for generic visual recognition. In *ICML*, 2014.
- A Gammerman, V Vovk, and V Vapnik. Learning by transduction. In *UAI*, 1998.
- Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation. In *ICML*, 2015.
- Robert Geirhos, Carlos RM Temme, Jonas Rauber, Heiko H Schütt, Matthias Bethge, and Felix A Wichmann. Generalisation in humans and deep neural networks. In *NeurIPS*, 2018.
- Robert Geirhos, Patricia Rubisch, Claudio Michaelis, Matthias Bethge, Felix A. Wichmann, and Wieland Brendel. Imagenet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness. In *International Conference on Learning Representations*, 2019.
- Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations. In *ICLR*, 2018.
- Priya Goyal, Piotr Dollár, Ross Girshick, Pieter Noordhuis, Lukasz Wesolowski, Aapo Kyrola, Andrew Tulloch, Yangqing Jia, and Kaiming He. Accurate, large minibatch sgd: training imagenet in 1 hour. *arXiv preprint arXiv:1706.02677*, 2017.
- Yves Grandvalet and Yoshua Bengio. Semi-supervised learning by entropy minimization. In *NeurIPS*, 2005.
- A. Gretton, AJ. Smola, J. Huang, M. Schmittfull, KM. Borgwardt, and B. Schölkopf. Covariate shift and local learning by distribution matching. In *Dataset Shift in Machine Learning*, pp. 131–160. MIT Press, Cambridge, MA, USA, 2009.
- Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q Weinberger. On calibration of modern neural networks. In *ICML*, 2017.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, June 2016.
- Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *ICLR*, 2019.
- Dan Hendrycks, Norman Mu, Ekin D Cubuk, Barret Zoph, Justin Gilmer, and Balaji Lakshminarayanan. Augmix: A simple data processing method to improve robustness and uncertainty. In *ICLR*, 2020.
- Jonathan J. Hull. A database for handwritten text recognition research. *TPAMI*, 1994.
- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *ICML*, 2015.

- Vidit Jain and Erik Learned-Miller. Online domain adaptation of a pre-trained cascade of classifiers. In *CVPR*, 2011.
- Thorsten Joachims. Transductive inference for text classification using support vector machines. In *ICML*, 1999.
- Diederik Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *ICLR*, 2015.
- A. Krizhevsky, I. Sutskever, and G. Hinton. Imagenet classification with deep convolutional neural networks. *NeurIPS*, 25, 2012.
- Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, University of Toronto, 2009.
- Jogendra Nath Kundu, Naveen Venkat, R Venkatesh Babu, et al. Universal source-free domain adaptation. In *CVPR*, pp. 4544–4553, 2020.
- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- Dong-Hyun Lee. Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks. In *ICML Workshop on challenges in representation learning*, 2013.
- Rui Li, Qianfen Jiao, Wenming Cao, Hau-San Wong, and Si Wu. Model adaptation: Unsupervised domain adaptation without source data. In *CVPR*, June 2020.
- Yanghao Li, Naiyan Wang, Jianping Shi, Jiaying Liu, and Xiaodi Hou. Revisiting batch normalization for practical domain adaptation. In *ICLRW*, 2017.
- Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation. In *ICML*, 2020.
- Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks. In *International Conference on Learning Representations*, 2018.
- Zachary Nado, Shreyas Padhy, D Sculley, Alexander D’Amour, Balaji Lakshminarayanan, and Jasper Snoek. Evaluating prediction-time batch normalization for robustness under covariate shift. *arXiv preprint arXiv:2006.10963*, 2020.
- Yuval Netzer, Tao Wang, Adam Coates, Alessandro Bissacco, Bo Wu, and Andrew Y Ng. Reading digits in natural images with unsupervised feature learning. *NeurIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. In *NeurIPS*, 2019.
- Xingchao Peng, Ben Usman, Neela Kaushik, Judy Hoffman, Dequan Wang, and Kate Saenko. VisDA: The visual domain adaptation challenge. *arXiv preprint arXiv:1710.06924*, 2017.
- Ethan Perez, Florian Strub, Harm De Vries, Vincent Dumoulin, and Aaron Courville. Film: Visual reasoning with a general conditioning layer. In *AAAI*, 2018.
- Joaquin Quionero-Candela, Masashi Sugiyama, Anton Schwaighofer, and Neil D Lawrence. *Dataset shift in machine learning*. MIT Press, Cambridge, MA, USA, 2009.
- Ilija Radosavovic, Justin Johnson, Saining Xie, Wan-Yen Lo, and Piotr Dollár. On network design spaces for visual recognition. In *ICCV*, 2019.
- Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. Do cifar-10 classifiers generalize to cifar-10? *arXiv preprint arXiv:1806.00451*, 2018.
- Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. Do ImageNet classifiers generalize to ImageNet? In *ICML*, 2019.
- Stephan R Richter, Zeeshan Hayder, and Vladlen Koltun. Playing for benchmarks. In *ICCV*, 2017.
- Subhankar Roy, Aliaksandr Siarohin, Enver Sangineto, Samuel Rota Buló, Nicu Sebe, and Elisa Ricci. Unsupervised domain adaptation using feature-whitening and consensus loss. In *CVPR*, 2019.

- Evgenia Rusak, Lukas Schott, Roland S Zimmermann, Julian Bitterwolf, Oliver Bringmann, Matthias Bethge, and Wieland Brendel. A simple way to make neural networks robust against diverse image corruptions. In *ECCV*, 2020.
- Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. ImageNet large scale visual recognition challenge. *IJCV*, 2015.
- Kate Saenko, Brian Kulis, Mario Fritz, and Trevor Darrell. Adapting visual category models to new domains. In *European conference on computer vision*, pp. 213–226. Springer, 2010.
- Kuniaki Saito, Donghyun Kim, Stan Sclaroff, Trevor Darrell, and Kate Saenko. Semi-supervised domain adaptation via minimax entropy. In *ICCV*, 2019.
- Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Improving robustness against common corruptions by covariate shift adaptation. *arXiv preprint arXiv:2006.16971*, 2020.
- C.E. Shannon. A mathematical theory of communication. *Bell system technical journal*, 27, 1948.
- Evan Shelhamer, Jonathan Long, and Trevor Darrell. Fully convolutional networks for semantic segmentation. *PAMI*, 2017.
- Rui Shu, Hung H Bui, Hirokazu Narui, and Stefano Ermon. A dirt-t approach to unsupervised domain adaptation. In *ICLR*, 2018.
- Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015.
- Baochen Sun, Jiashi Feng, and Kate Saenko. Correlation alignment for unsupervised domain adaptation. In *Domain Adaptation in Computer Vision Applications*, pp. 153–171. Springer, 2017.
- Yu Sun, Eric Tzeng, Trevor Darrell, and Alexei A Efros. Unsupervised domain adaptation through self-supervision. *arXiv preprint arXiv:1909.11825*, 2019a.
- Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A Efros, and Moritz Hardt. Test-time training for out-of-distribution generalization. *arXiv preprint arXiv:1909.13231*, 2019b.
- Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian Goodfellow, and Rob Fergus. Intriguing properties of neural networks. 2014.
- Eric Tzeng, Judy Hoffman, Trevor Darrell, and Kate Saenko. Simultaneous deep transfer across domains and tasks. In *ICCV*, 2015.
- Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial discriminative domain adaptation. In *CVPR*, 2017.
- Jingdong Wang, Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, Yadong Mu, Minghui Tan, Xinggang Wang, et al. Deep high-resolution representation learning for visual recognition. *PAMI*, 2020.
- Yuxin Wu and Kaiming He. Group normalization. In *ECCV*, 2018.
- Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *NeurIPS*, 2014.
- Richard Zhang, Phillip Isola, and Alexei A Efros. Split-brain autoencoders: Unsupervised learning by cross-channel prediction. In *CVPR*, 2017.
- Hengshuang Zhao, Jiaya Jia, and Vladlen Koltun. Exploring self-attention for image recognition. In *CVPR*, 2020.
- Dengyong Zhou, Olivier Bousquet, Thomas Navin Lal, Jason Weston, and Bernhard Schölkopf. Learning with local and global consistency. *NeurIPS*, 2004.

附录

本补充材料总结了实验中使用的图像损坏类型，展示了语义分割中实例级自适应的定性示例，并可视化了更多层的特征偏移。

A 对损坏的鲁棒性

在第 4.1 节中，我们在一个常见的图像损坏基准上评估了各方法。表 2 报告了最严重损坏级别（第 5 级）下的误差，图 5 报告了每种损坏类型在 1 至 5 级平均后的误差。我们在图 8 中以示例形式总结了这些损坏类型。




图 8: 图像损坏基准中每种损坏类型的示例。尽管是合成的，这组损坏旨在代表自然的变异因素，如噪声、模糊、天气和数字成像效果。此图转载自 Hendrycks & Dietterich (2019)。

B 面向语义分割的无源适应

图 9 展示了在仿真到真实（sim-to-real）偏移下，面向语义分割（逐像素分类）的无源适应的定性结果。

在这种仿真到真实条件下，源数据是仿真的，而目标数据是真实的。我们的源数据是 GTA Richter 等人（2017），这是一款视觉上精细的、以城市环境为背景的视频游戏；我们的目标数据是 Cityscapes Cordts 等人（2016），这是一个城市自动驾驶数据集。监督模型是 HRnet-W18，一种高分辨率网络家族 Wang 等人（2020）中的全卷积网络 Shelhamer 等人（2017）。对于这个定性示例，我们对单张图像运行 tent 进行多次迭代，因为一张图像实际上是一批像素。这展示了对目标实例的适应，而无需通过使用来自目标分布的多张图像进一步访问目标域。




图 9: 从 GTA Richter 等人 (2017) 到 Cityscapes Cordts 等人 (2016) 的仿真到真实偏移下的语义分割适应。Tent 仅使用目标数据, 并将单张图像作为逐像素预测的数据集进行优化。这种情景式优化实际上为目标域的每张图像拟合了一个定制模型。仅经过 10 次迭代, 我们的方法就抑制了噪声 (见街道分割的完成, 紫色部分) 并恢复了缺失的类别 (见摩托车和骑手, 中央)。

C 跨层和方法的特征偏移




图 10: 在带有高斯噪声的 CIFAR-100-C 上适应的特征（前部）和无损坏的参考特征（后部）。损坏使源特征偏离参考。BN 将特征移回，使其更接近参考。Tent 将特征移得离参考更远，而更接近在目标标签上优化的预言机。