

泰坦：在测试时学习记忆

Ali Behrouz[†], Peilin Zhong[†], and Vahab Mirrokni[†]

[†] Google Research

{alibehrouz, peilinz, mirrokni}@google.com

摘要

十多年来，如何有效利用循环模型与注意力机制一直是广泛研究的课题。循环模型旨在将数据压缩为固定大小的记忆（称为隐藏状态），而注意力机制则允许关注整个上下文窗口，捕捉所有标记之间的直接依赖关系。然而，这种更精确的依赖建模带来了二次方成本，将模型限制在固定长度的上下文中。本文提出一种新颖的神经长期记忆模块，该模块学习记忆历史上下文，并帮助注意力机制在利用长期过去信息的同时关注当前上下文。我们证明这种神经记忆具有快速可并行化训练的优势，同时保持快速推理。从记忆的角度来看，我们认为注意力机制由于其有限的上下文但精确的依赖建模，充当短期记忆；而神经记忆由于其记忆数据的能力，充当长期、更持久的记忆。基于这两个模块，我们引入了一个新的架构家族，称为泰坦（Titans），并提出三种变体来解决如何有效地将记忆融入该架构的问题。我们在语言建模、常识推理、基因组学和时间序列任务上的实验结果表明，泰坦比变换器（Transformers）及近期现代线性循环模型更有效。此外，它们能够有效扩展到超过 200 万上下文窗口大小，并在大海捞针任务中相比基线具有更高的准确率。

1 引言

“记忆的真正艺术是注意力的艺术！”

变换器（Transformers，即纯注意力架构）[Vaswani et al. 2017] 已被牢固确立为序列建模中最先进的模型，主要归功于其上下文学习能力以及大规模学习的能力 [Kaplan et al. 2020]。变换器的主要构建模块——注意力模块——充当联想记忆块 [Bietti et al. 2024]，它们学习存储键值关联，并通过计算查询（即搜索信号）与键（即上下文）之间的成对相似度来检索这些关联。因此，从设计上讲，变换器的输出仅依赖于当前上下文窗口中标记的直接依赖关系。然而，这种对依赖关系的精确建模带来了与上下文长度相关的二次时间和内存复杂度。在复杂的现实世界任务中（例如语言建模 [N. F. Liu et al. 2024]、视频理解 [C.-Y. Wu et al. 2019]、长时间序列预测 [H. Zhou et al. 2021]），上下文窗口可能变得极其庞大，这使得变换器在这些下游任务中的适用性面临挑战。为了克服变换器的可扩展性问题，近期研究致力于设计不同的线性变换器变体 [Kacham, Mirrokni, and P. Zhong 2024; Katharopoulos et al. 2020; S. Yang, B. Wang, Shen, et al. 2024]，其中注意力中的 Softmax 函数被核函数替代（详见 § 2.1），从而显著降低内存消耗。尽管线性变换器具有效率优势并能扩展到更长的上下文，但与变换器相比，它们并未表现出有竞争力的性能，因为核技巧使模型成为线性循环网络，其中数据被压缩为矩阵值状态 [Katharopoulos et al. 2020]。然而，这带来了关于线性循环（或线性变换器）模型的一个矛盾事实：一方面，我们使用这些线性模型来增强可扩展性和效率（线性与二次复杂度），其优势在非常长的上下文中得以体现；另一方面，非常长的上下文无法被恰当地压缩到小型向量值或矩阵值状态中 [S. Wang 2024]。

此外，除效率之外，大多数现有架构——从霍普菲尔德网络（Hopfield Networks）（Hopfield 1982）到长短期记忆网络（LSTMs）（Jürgen Schmidhuber and Hochreiter 1997）和变换器（Transformers）（Vaswani et al. 2017）——在处理泛化、长度外推和/或推理时面临挑战（Anil et al. 2022; Qin, Y. Zhong, and Deng 2024），而这些都是许多困难现实世界任务中不可分割的部分。尽管这些架构从人脑中获得启发，但每一个都缺少：（1）学习过程的关键组成部分——如短期记忆、长期记忆、元记忆、关注当前上下文等（Cowan 2008）；（2）这些组成部分如何作为可独立运行的互联系统；和/或（3）主动从数据中学习并记忆过去历史抽象的能力。本文认为，在一个有效的学习范式中，类似于人脑，存在不同但相互连接的模块，每个模块负责学习过程中至关重要的一个组成部分。

记忆视角

记忆是一种基本的心理过程，是人类学习不可分割的组成部分（Terry 2017）。如果没有正常运作的记忆系统，人类和动物将仅限于基本反射和刻板行为。因此，记忆一直是机器学习文献中许多开创性研究的灵感来源；例如，霍普菲尔德网络（Hopfield Networks）（Hopfield 1982）、长短期记忆网络（LSTMs）（Jürgen Schmidhuber and Hochreiter 1997）和变换器（Transformers）（Vaswani et al. 2017）。

受神经心理学文献中记忆与学习的常见定义启发（Okano、Hirano 和 Balaban 2000），大多数现有架构将记忆视为由输入引起的神经更新，并将学习定义为在给定目标下获取有效且有用记忆的过程。从这一视角出发，循环神经网络（Recurrent Neural Networks, RNNs）（Williams 和 Zipser 1989）可被定义为具有向量值记忆模块 M （也称为隐藏状态）的模型，包含两个主要步骤：给定时间 t 的新输入 x_t ，模型（1）使用函数 $f(M_{t-1}, x_t)$ 更新记忆（带压缩）；（2）使用函数 $q(M_t, x_t)$ （检索输入对应的记忆（详见第 2.1 节）。类似地，变换器（Transformers）可被视为具有增长记忆和两个相似步骤的架构。即，键和值矩阵对充当模型的记忆，模型：（1）通过将键和值追加到记忆中（无压缩）来更新记忆；（2）通过寻找查询向量与键向量的相似性来检索查询向量对应的记忆，该相似性随后用于对值向量加权以生成输出。

这一视角有助于我们更好地理解现有范式及其关键差异，并设计更有效的架构。例如，变换器（Transformer）（Vaswani 等人，2017）与线性变换器（Linear Transformer）（Katharopoulos 等人，2020）的主要区别在于记忆结构及记忆更新步骤：线性变换器将历史数据压缩为固定大小的矩阵值记忆，而变换器在上下文长度内保留所有历史数据而不进行压缩。虽然线性变换器和线性循环神经网络（包括状态空间模型）都在记忆更新步骤中压缩信息，但关键差异在于记忆的结构：线性循环神经网络（相对于线性变换器）使用向量值记忆（相对于矩阵值记忆）。因此，这一视角促使我们提出以下问题：

（问题 1）什么构成了良好的记忆结构？（问题 2）什么是合适的记忆更新机制？（问题 3）什么是良好的记忆检索过程？重新审视我们对人类记忆的理解，它既不是单一过程，也不只服务于单一功能（Cowan 2008）。事实上，记忆是多个系统的联合体——例如短期记忆、工作记忆和长期记忆——每个系统服务于不同的功能，具有不同的神经结构，并且能够独立运作（Willingham 1997）。这一事实促使我们提出：（问题 4）如何设计一种高效架构，将不同的相互连接的记忆模块整合在一起。最后，存储记忆是一个神经过程，需要对过去的抽象进行编码和存储。假设单个向量或矩阵（其参数以线性方式编码数据）足以存储长期历史，可能过于简化。（问题 5）是否需要深度记忆模块来有效存储/记住久远的过去？

文献与路线图

在本文中，我们旨在通过设计一个长期神经记忆模块来回答上述五个问题，该模块能够在测试时高效且有效地学习记忆。基于其设计，我们讨论如何将其整合到架构中。

神经记忆（§ 3）。我们提出一种（深度）神经长期记忆，它（作为元上下文模型）在测试时学习如何将数据记忆/存储到其参数中。受人类长期记忆系统（Mandler 2014）的启发，

我们设计该记忆模块，使违反期望（即令人惊讶）的事件更易被记住。为此，我们利用神经网络在联想记忆损失下对输入的梯度来衡量输入的惊讶程度（详见 § 3.1）。为更好地应对有限记忆，我们提出一种衰减机制，该机制考虑记忆大小的比例与数据惊讶程度，从而实现更优的记忆管理。我们证明该衰减机制实际上是现代循环模型中遗忘机制的推广（Dao 和 Gu 2024；Gu 和 Dao 2024；S. Yang、Kautz 和 Hatamizadeh 2024）。有趣的是，我们发现该机制等价于使用小批量梯度下降、动量和权重衰减来优化一个元神经网络。基于将小批量梯度下降张量化以使用更多矩阵乘法运算（Yu Sun 等 2024），我们提出一种快速且可并行化的算法来训练我们的深度神经长期记忆。

泰坦架构（§ 4）。在设计出长期神经记忆之后，一个重要的遗留问题是如何有效且高效地将记忆融入深度学习架构。我们提出泰坦（Titans），这是一个由三个超头组成的深度模型家族：（1）核心：该模块包含短期记忆，负责数据处理的主要流程（我们使用窗口大小有限的注意力机制）；（2）长期记忆：该分支是我们的神经长期记忆模块，负责存储/记住久远的过去；（3）持久记忆：这是一组可学习但与数据无关的参数，编码了关于任务的知识。最后，作为概念验证，我们提出泰坦的三种变体，其中我们将记忆融入为：（i）上下文，（ii）层，以及（iii）门控分支。

实验结果（§ 5）。我们在语言建模、常识推理、密集回忆、大海捞针、时间序列预测和 DNA 建模任务上进行了实验评估。我们观察到，在一系列全面的基准测试中，我们的泰坦架构优于所有现代循环模型及其混合变体（与滑动窗口注意力结合）。此外，泰坦在相同上下文窗口下优于变换器，并且与使用完整上下文的变换器相比表现出具有竞争力的性能。这些结果是在泰坦能够扩展到超过 200 万上下文窗口大小的情况下取得的，这与变换器不同。

2 预备知识

本节讨论全文使用的符号表示及背景概念。令 $x \in \mathbb{R}^{N \times d_{\text{in}}}$ 为输入， M 为神经网络（神经记忆模块）， O, K, V 为注意力机制的查询、键和值， M 为注意力掩码。对序列进行分段时，使用 $S^{(i)}$ 表示第 i 个分段。全文沿用符号约定，使用下标表示矩阵、向量或分段的特定元素。例如，令 $S^{(i)}$ 为第 i 个分段中的第 j 个词元。唯一例外是带 t 的下标，保留用于索引时间上的循环，或神经网络在时间 t 的状态。给定神经网络 N 和数据样本 x ，使用 $N(x)$ （相应地 $N^*(x)$ ）表示带（相应地不带）权重调整的前向传播。同样沿用符号约定，使用 $N^{(k)}$ 表示神经网络的第 k 层。下文首先讨论注意力及其高效变体的背景，随后回顾现代线性循环神经网络。最后，从记忆视角讨论这些架构，以引出 Titans 的设计动机。

2.1 背景

注意力。变换器（Transformer）（Vaswani et al. 2017）作为众多深度学习模型事实上的骨干架构，基于注意力机制。给定输入 $x \in \mathbb{R}^{N \times d_{\text{in}}}$ ，因果注意力基于输入相关的键、值和查询矩阵，通过 Softmax 函数计算输出 $y \in \mathbb{R}^{N \times d_{\text{in}}}$ ：

$$Q = xW_Q, \quad K = xW_K, \quad V = xW_V, \quad (1)$$

$$y_i = \sum_{j=1}^i \frac{\exp\left(Q_i^\top K_j / \sqrt{d_{\text{in}}}\right) V_j}{\sum_{\ell=1}^i \exp\left(Q_i^\top K_\ell / \sqrt{d_{\text{in}}}\right)}, \quad (2)$$

其中 W_Q, W_K 和 $W_V \in \mathbb{R}^{d_{\text{in}} \times d_{\text{in}}}$ 为可学习参数。尽管变换器在召回率方面具有强大能力和有效性，但计算输出至少需要 $N \times d$ 次运算，导致较长序列的内存消耗更大、吞吐量更低。

高效注意力。为改善较长序列下 Softmax 注意力的内存消耗和吞吐量，多项研究聚焦于注意力的输入输出感知实现（Dao 2024；Dao, D. Fu, et al. 2022），设计更

通过稀疏化注意力矩阵 (B. Chen et al. 2021; Choromanski et al. 2021; Dai et al. 2019)、近似 Softmax 函数 (Arora et al. 2024) 或开发基于核函数的 (线性) 注意力机制 (Aksenov et al. 2024; Kacham, Mirrokni, and P. Zhong 2024; Schlag, Irie, and Jürgen Schmidhuber 2021; S. Yang, B. Wang, Shen, et al. 2024), 可以实现高效的注意力机制。在本部分中, 我们关注后者, 即线性注意力机制, 其中标准注意力中的 Softmax 函数被替换为替代核函数 $\phi(\dots)$, 使得 $\phi(x, u) = \phi(x)\phi(u)$ 。相应地, 注意力可以写为:

$$\mathbf{y}_i = \sum_{j=1}^i \frac{\phi(Q_i^\top K_j)}{\sum_{t=1}^i \phi(Q_i^\top K_t)} V_j = \sum_{j=1}^i \frac{\phi(Q_i)^\top \phi(K_j)}{\sum_{t=1}^i \phi(Q_i)^\top \phi(K_t)} V_j = \frac{\phi(Q_i)^\top \sum_{j=1}^i \phi(K_j) V_j}{\phi(Q_i)^\top \sum_{t=1}^i \phi(K_t)}, \quad (3)$$

并且 $\phi(K_t)$ 在每一步中重复使用。当选择 $\sum_{j=1}^i \phi(K_j)$ 择核函数为单位矩阵时 (Yutao Sun et al. 2023), 上述公式也可以写成循环形式:

$$\mathbf{M}_t = \mathbf{M}_{t-1} + K_t^\top V_t, \quad (4)$$

$$\mathbf{y}_t = Q_t \mathbf{M}_t, \quad (5)$$

这使得线性注意力机制能够高效推理。

现代线性模型及其记忆视角。 如前所述, 可以将学习定义为获取有效且有用记忆的过程。基于此, 可以将循环神经网络 (RNN) 的隐藏状态视为一个记忆单元, 模型旨在将信息压缩到其中。相应地, 在循环神经网络的一般形式中, 隐藏状态可以被视为记忆单元, 循环过程可以分解为记忆单元中的读取和写入操作。也就是说, 令 $\mathbf{x} \in \mathbb{R}^{N \times d_{in}}$ 为输入, $\mathbf{M} \in \mathbb{R}^d$ 为记忆单元, $\mathbf{y} \in \mathbb{R}^{d_{in}}$ 为输出, 则循环神经网络的一般形式定义为:

$$\mathbf{M}_t = f(\mathbf{M}_{t-1}, \mathbf{x}_t), \quad \text{Write Operation} \quad (6)$$

$$\mathbf{y}_t = g(\mathbf{M}_t, \mathbf{x}_t), \quad \text{Read Operation} \quad (7)$$

其中 $f(\dots)$ 是读取函数, $g(\dots)$ 是对应的写入函数。注意, 此处 $\mathbf{M}_t$ 的下标表示记忆在时刻 t 的状态。从这一视角看, 线性变换器 (Linear Transformer) 的递推公式 (见方程 4) 等价于将键和值 (K_t, V_t) 加性地压缩并写入矩阵值记忆单元 $\mathbf{M}_t$ 。因此, 在处理长上下文数据时, 这种加性过程会导致记忆溢出, 显著损害模型性能。为解决这一问题, 研究聚焦于两个有前景的方向: (1) 添加遗忘机制: 多项研究为线性模型提出了自适应 (数据依赖) 的遗忘门机制, 可在需要时擦除记忆。此类模型的例子包括 GLA (S. Yang, B. Wang, Shen, et al. 2024)、LRU (Orvieto et al. 2023)、Griffin (De et al. 2024)、xLSTM (Beck et al. 2024) 和 Mamba2 (Dao and Gu 2024), 后者还与传统状态空间模型 (State Space Model) 的离散化版本相关 (Gu and Dao 2024)。(2) 改进写入操作: 为克服传统循环模型中记忆写入操作的加性本质, Widrow 和 Hoff (1988) 提出了 Delta 规则, 即在添加记忆 (即键值对) 之前, 模型首先移除其过去的值。为增强可并行化训练和扩展性, S. Yang, B. Wang, Yu Zhang, et al. (2024) 提出了一种快速可并行化算法。最后, 最近 S. Yang, Kautz 和 Hatamizadeh (2024) 通过添加遗忘门改进了 DeltaNet。

记忆模块。 记忆一直是神经网络设计中的核心部分之一 (Graves, Wayne, and Danihelka 2014; JH Schmidhuber 1992; Jürgen Schmidhuber and Hochreiter 1997; J. Zhang et al. 2024)。将线性层视为键值 (关联) 记忆系统的思想可追溯至快速权重程序, 其中动态快速程序被整合到循环神经网络中, 充当可写记忆 (JH Schmidhuber 1992)。赫布学习规则 (Hebb 2005) 和德尔塔学习规则 (Prados and Kak 1989) 是快速权重程序中最流行的两种学习规则, 已在多项研究中得到广泛探索 (Irie, Schlag, et al. 2021; Munkhdalai, Sordoni, et al. 2019; Munkhdalai and H. Yu 2017; Schlag, Irie, and Jürgen Schmidhuber 2021; JH Schmidhuber 1992; S. Yang, Kautz, and Hatamizadeh 2024; S. Yang, B. Wang, Yu Zhang, et al. 2024)。然而, 所有这些模型都基于瞬时惊讶, 忽略了序列中的令牌流 (见第 3.1 节), 且大多数缺乏遗忘门, 导致记忆管理不佳。我们在附录 C 中进一步讨论了我们的架构与近期模型的联系。其他相关工作在附录 A 中讨论。

3 在测试时学习记忆

为了克服长期记忆的缺乏，并使模型能够学习、遗忘和检索信息，在本节中，我们提出一个神经长期记忆模块，它是一个元模型，在测试时学习记忆。在第 3.1 节中，我们首先讨论神经记忆的动机和设计。在第 3.2 节中，我们讨论我们的架构设计如何受益于快速且可并行化的训练。最后，在第 3.3 节中，我们使用持久记忆模块增强我们的架构，其中我们使用可学习但与数据无关的参数来学习任务的元信息。

3.1 长期记忆

为了设计一个神经长期记忆模块，我们需要一个能够将过去历史的抽象编码到其参数中的模型。一个例子是大语言模型（LLMs），它们已被证明能够记忆其训练数据（Leybzon 和 Kervadec 2024; Schwarzschild 等人 2024; Staab 等人 2024）。因此，一个简单的想法是训练一个神经网络并期望它记忆其训练数据。然而，记忆在神经网络中几乎总是被认为是一种不良现象，因为它限制了模型的泛化能力（Bayat 等人 2024），引发隐私问题（Staab 等人 2024），从而导致测试时性能不佳。此外，训练数据的记忆在测试时可能没有帮助，因为数据可能超出分布。我们认为，我们需要一个在线元模型，在测试时学习如何记忆/遗忘数据。在这种设置下，模型学习的是一个能够进行记忆的函数，但它不会对训练数据过拟合，从而在测试时获得更好的泛化性能。

学习过程与意外度量。 训练长期记忆的关键思想是将其训练视为一个在线学习问题，其中我们旨在将过去的信息 $x_1, \dots, x_{t-1}$ 压缩到我们的长期神经记忆模块的参数 $\mathcal{M}_t$ 中。如前所述，违反预期（即令人意外）的事件对人类来说更难忘记（Mandler 2014）。受此启发，模型意外的一个简单定义可以是其相对于输入的梯度。梯度越大，输入数据与过去数据的差异就越大。因此，利用这个意外分数，我们可以按如下方式更新记忆：

$$\mathcal{M}_t = \mathcal{M}_{t-1} - \theta_t \underbrace{\nabla \ell(\mathcal{M}_{t-1}; x_t)}_{\text{Surprise}}. \quad (8)$$

然而，这种意外度量可能导致在重大意外时刻之后遗漏重要信息。也就是说，经过若干意外步骤后，梯度可能变得极小，导致陷入平坦区域（即局部极小值），从而遗漏序列某些部分的信息。从人类记忆的角度来看，一个事件虽然令人难忘，但未必能在长时间内持续让我们感到意外。原因在于，初始时刻的意外程度足以在长时间内吸引我们的注意力，从而记住整个时间段。为了改进上述意外度量（方程 8），我们将意外度量分解为：（1）过去意外，衡量最近过去的意外程度；（2）瞬时意外，衡量新输入数据的意外程度：

$$\mathcal{M}_t = \mathcal{M}_{t-1} + S_t, \quad (9)$$

$$S_t = \eta_t \underbrace{S_{t-1}}_{\text{Past Surprise}} - \theta_t \underbrace{\nabla \ell(\mathcal{M}_{t-1}; x_t)}_{\text{Momentary Surprise}}. \quad (10)$$

有趣的是，这种表述类似于带动量的梯度下降，其中 S_t 是动量项。因此，这里的动量充当了跨时间（序列长度）的意外记忆。在该表述中，项 η_t 是数据依赖的意外衰减（ x_t 的函数），控制意外随时间衰减的方式；项 θ_t 则以数据依赖的方式控制瞬时意外应多大程度地纳入最终意外度量。这种数据依赖性在此设计中尤为重要：虽然前一个词元的意外可能需要影响下一个词元的意外，但这主要在所有词元相关且处于同一上下文时才成立。因此，数据依赖的 η 可以控制记忆是否需要：（1）通过设置 $\eta_t \rightarrow 0$ 来忽略上一次意外（可能由于上下文变化），或（2）通过设置 $\eta_t \rightarrow 1$ 来完全纳入上一次意外（可能因为该词元与其最近的过去词元高度相关）。

目标。 上述意外度量基于损失函数 $\ell(\cdot; \cdot)$ ，该损失函数是记忆在测试时学习执行的目标。也就是说，我们的记忆模块是一个元模型，它基于损失函数 $\ell(\cdot; \cdot)$ 学习一个函数。

在本工作中，我们专注于联想记忆，旨在将过去的数据存储为键值对。给定 x_t ，与变换器 (Vaswani et al. 2017) 类似，我们使用两个线性层将 x_t 投影为键和值：

$$\mathbf{k}_t = x_t W_K, \quad \mathbf{v}_t = x_t W_V, \quad (11)$$

其中 W_K 和 $W_V \in \mathbb{R}^{d_{in} \times d_{in}}$ 。接下来，我们期望记忆模块学习键与值之间的关联。为此，我们定义损失如下：

$$\ell(\mathcal{M}_{t-1}; x_t) = \|\mathcal{M}_{t-1}(\mathbf{k}_t) - \mathbf{v}_t\|_2^2 \quad (12)$$

通过在元模型（记忆）的内循环中优化上述损失函数，模型学会了在测试时记忆键与值之间的映射。注意，与元学习模型 (Nichol 2018; Zintgraf 等人 2019) 类似，记忆的训练在内循环中进行，因此参数 W_K 和 W_V 是上述损失函数中的超参数。相应地，在内循环中，我们优化 $\mathcal{M}$ 的权重，而在外循环中，我们优化整个架构的其他参数。

遗忘机制。当处理非常长的序列（例如，数百万个标记）时，即使使用深度或非常大的矩阵值记忆，管理哪些过去的信息应该被遗忘也至关重要。为此，我们使用一种自适应遗忘机制，允许记忆遗忘不再需要的信息，从而更好地管理记忆的有限容量。也就是说，给定下一个标记 x_t ，我们将更新规则修改为：

$$\mathcal{M}_t = (1 - \alpha_t) \mathcal{M}_{t-1} + S_t, \quad (13)$$

$$S_t = \eta_t S_{t-1} - \theta_t \nabla \ell(\mathcal{M}_{t-1}; x_t), \quad (14)$$

其中 $\alpha_t \in [0, 1]$ 是灵活控制记忆的门控机制；即决定多少信息应该被遗忘。例如，它可以通过令 $\alpha_t \rightarrow 0$ 来更新记忆而不影响过去的抽象，并且可以通过令 $\alpha_t \rightarrow 1$ 来清除整个记忆。本节稍后，我们将展示这种权重衰减机制与现代循环神经网络中的门控机制密切相关 (Dao 和 Gu 2024; Orvieto 等人 2023)。

记忆架构。本文聚焦于以 $L_M \geq 1$ 层简单多层感知机作为长期记忆的架构。这一选择的主要原因在于，我们希望更充分地论证长期记忆的设计动机，以及将其融入整体架构的多种方式。然而，本文的公式化表述与架构设计开辟了一个新的研究方向，即设计在数据记忆方面更有效、更高效的神经架构。近期，已有若干有前景的工作致力于设计此类架构 (Berges 等, 2024; Cetin 等, 2024; J. Zhang 等, 2024)，将其纳入本文框架（即用此类架构替换简单多层感知机）可成为有趣的未来工作。当采用向量值或矩阵值记忆时 (De 等, 2024; Orvieto 等, 2023; S. Yang、B. Wang、Shen 等, 2024)，记忆模块对过去数据进行压缩并拟合为一条直线。也就是说，从元学习或在线学习的视角来看 (Yu Sun 等, 2024)，使用矩阵值记忆 $\mathcal{M} = W \in \mathbb{R}^{d_{in} \times d_{in}}$ 等价于优化 $\ell(W_{t-1}; x_t) = \|W_{t-1} \mathbf{k}_t - \mathbf{v}_t\|_2^2$ ，这是一个在线线性回归目标，因此最优解假设历史数据的潜在依赖关系是线性的。另一方面，本文认为深层记忆模块（即 $L_M \geq 2$ ）。与至少两层多层感知机严格比线性模型更具表达力的理论结果一致 (Hornik、Stinchcombe 和 White, 1989)，在第 5.5 节中，本文展示了深层记忆模块在实践中更为有效。

检索记忆。上文讨论了如何设计并训练一个在测试时学习记忆的长期记忆模块。一个关键问题是：如何从记忆中检索信息？本文仅使用不更新权重的前向传播（即推理）来检索与查询对应的记忆。形式上，给定输入 x_t ，使用线性层 W_O 对输入进行投影，即 $\mathbf{q}_t = x_t W_O$ ，并通过以下方式从记忆 u_t 中检索相应（或有用）的信息：

$$y_t = \mathcal{M}^*(\mathbf{q}_t). \quad (15)$$




图 1: 神经记忆训练如何并行化并使用矩阵乘法的示意图。

3.2 如何并行化长期记忆训练

如上文所述，我们设计的长期记忆模块等价于通过优化联想记忆损失函数 $\ell(\mathcal{M}_{t-1}; x_t) = \|\mathcal{M}_{t-1}(\mathbf{k}_t) - \mathbf{v}_t\|_2^2$ ，使用带动量和权重衰减的梯度下降来训练元模型。因此，理论上，长期记忆模块的训练需要 $\mathcal{O}(N)$ FLOPs，其中 N 是序列长度。然而，在实践中，我们需要并行化训练过程，并充分利用硬件加速器（如 TPU、GPU），因此需要将过程张量化并使用更多矩阵乘法。接下来，我们展示内循环中使用权重的计算，采用小批量梯度下降、数据依赖的学习率和权重衰减，可以重新表述为仅使用矩阵乘法和求和。我们基于 Yu Sun 等人（2024）的工作，该工作表明使用小批量梯度下降（恒定学习率）优化的模型前向传播可以通过矩阵乘法计算。我们可以将序列分割为大小为 $b \geq 1$ 的块，并将小批量梯度下降写为：

$$\mathcal{M}_t = (1 - \alpha_t) \mathcal{M}_{t-1} - \theta_t \nabla \ell(\mathcal{M}_{t-1}; x_t) = \beta_t \mathcal{M}_0 - \sum_{i=1}^t \theta_i \frac{\beta_t}{\beta_i} \nabla \ell(\mathcal{M}_{t'}; x_i), \quad (16)$$

其中 $t' = t - \text{mod}(t, b)$ ，且 $\beta_i = \prod_{i'=i}^{t-1} (1 - \alpha_{i'})$ 。为简单起见，我们关注第一个块，即 $t = b$ ，因此 $t' = 0$ 。此外，我们针对 $\mathcal{M}_t = W_t$ 为线性的情况解释该过程。对于具有 $N_b \geq 2$ 的多层感知机（MLP）的过程类似。使用我们的损失函数，我们有：

$$\nabla \ell(W_0; x_t) = (W_0 x_t - x_t) x_t^\top \Rightarrow \sum_{i=1}^b \theta_i \frac{\beta_b}{\beta_i} \nabla \ell(W_0; x_i) = \Theta_b \mathbf{B}_b (W_0 X - X) X^\top, \quad (17)$$

其中 $\Theta_b = \text{diag}([\theta_1 \ \theta_2 \ \dots \ \theta_b])$ ，且 $\mathbf{B}_b$ 在 $\frac{\beta_b}{\beta_i}$ s 上类似定义。注意，我们不需要存储所有 Θ_{kb} 和 $\mathbf{B}_{kb}$ 对于 $k = 1, \dots, \tilde{N}/b$ ，而是为每个块存储这些矩阵，从而使用更少的内存。接下来，我们扩展此表示以纳入动量项。在分块带动量的梯度下降中，观察动量项，我们有：

$$S_t = \eta_t S_{t-1} - \theta_t u_t, \quad (18)$$

其中 $u_t = \nabla \ell(\mathcal{M}_{t'}; x_t)$ 。注意，我们可以同时计算所有 u_t ，因此方程 18 是一个线性递推，以 u_t 为输入， S_t 为隐藏状态， η_t 为输入依赖的转移值。因此，我们可以使用并行关联扫描（J. T. Smith, Warrington, and Linderman 2023）来计算该块中的 S_t 。

参数作为块的函数。 与其使参数如 α_t, θ_t 和 η_t 依赖于输入（即作为词元 x_t 的函数），我们可以使它们成为其所在块的函数。尽管会损失表达能力，但这种形式化有助于进一步加快训练速度。在这种情况下，我们在每个块中对 α, θ 和 η 使用相同的值。相应地，在方程 17 中，我们可以用单个标量存储 Θ 。类似地，我们可以使方程 18 更快。也就是说，当 η 和 θ 可学习但在每个块内时不变时，该方程变为线性时不变系统（LTI），可以通过全局卷积计算（Gu, Goel, and Re 2022）。在我们的实验中，我们将这些参数设为词元的函数。然而，这种简化（即作为块的函数）可能成为未来工作以更高效方式训练更大模型的兴趣点。




图 2：记忆作为上下文 (MAC) 架构。该架构包含三个分支：(1) 核心分支，(2) 上下文（长期）记忆分支，以及 (3) 持久记忆分支。核心分支将相应的长期记忆和持久记忆与输入序列拼接。随后，对序列执行注意力机制，并决定哪部分信息应存储到长期记忆中。在测试时，对应于上下文记忆的参数仍在学习，对应于核心分支的参数负责上下文学习，而持久记忆的参数负责存储关于任务的知识，因此是固定的。

3.3 持久记忆

我们的长期记忆也可以被视为一种上下文记忆，意味着输出完全依赖于上下文。因此，除了长期记忆之外，我们还使用一组可学习但与输入无关的参数来充当任务相关记忆。这种类型的记忆在文献中被称为持久记忆或元记忆 (X. Dong et al. 2024; Sukhbaatar, Grave, et al. 2019)。给定 $N_p \geq 1$ ，我们使用可学习参数 $P =$ 并将其附加到序列的开头：即，给定上下文窗口大小为 N ，我们将输入修改为：

$$x_{\text{new}} = [p_1 \ p_2 \ \dots \ p_{N_p}] \parallel x, \quad (19)$$

其中 $\parallel$ 表示拼接。接下来，我们从三个角度讨论持久记忆的动机：


记忆视角。如前所述，我们的神经长期记忆是一种上下文记忆，其中所有参数都依赖于输入。然而，一个有效的记忆系统还需要与输入无关的参数来存储任务知识的抽象。也就是说，掌握一项任务需要记住如何完成该任务的知识，而这些参数负责存储此类知识。

前馈网络视角。在变换器 (Transformer) 架构中，注意力模块之后存在全连接层，这些层被证明与注意力权重相似，但具有与数据无关的参数。也就是说，Sukhbaatar、Grave 等人 (2019) 表明，将全连接层中的修正线性单元 (ReLU) 替换为 Softmax 函数可以产生类似注意力的权重，其中权重与数据无关：

$$FFN(x) = W_V \text{Softmax}(W_K x). \quad (20)$$

事实上，当 W_K 和 W_V 与输入无关时，它们的作用类似于注意力模块中的 K 和 V 矩阵。持久记忆权重预期具有相同的功能，这意味着在序列的第一部分使用它们会产生与输入无关的注意力权重 (Sukhbaatar、Grave 等人, 2019)。

技术视角。带有因果掩码的注意力对序列中的初始标记存在隐式偏置，因此注意力权重几乎总是对初始标记高度活跃，导致性能受损。从技术角度来看，序列开头的这些可学习参数可以通过更有效地重新分配注意力权重来缓解这种影响 (Han 等人, 2024; Xiao 等人, 2024)。



(a) 记忆作为上下文 (MAC)。我们对序列进行分段，并在每个窗口中使用全因果注意力。同样，前 N_o 个标记是持久记忆，接下来的 N_l 个是长期记忆标记。

(b) 记忆作为门控 (MAG)。We use sliding window attention (SWA) 作为短期记忆，而我们的神经记忆模块作为长期记忆，通过门控机制进行结合。

图 3: 不同 Titans 变体的注意力掩码。

一个尚未解决的重要问题是：如何有效且高效地将所设计的神经记忆融入深度学习架构中？如前所述，从记忆的角度来看，变换器中的 K 和 V 矩阵对可以被解释为联想记忆块。由于它们对依赖关系的精确建模以及因此受限的上下文窗口，我们将其解释为短期记忆模块，关注当前上下文窗口大小。另一方面，我们的神经记忆具有从数据中持续学习并将其存储在权重中的能力，可以扮演长期记忆的角色。在本节中，我们旨在通过提出三种不同的 Titans 变体来回答上述问题。在后续实验中，我们表明每种变体都有其自身的优势与劣势，并且可以在超长上下文中展示效率与有效性之间的权衡。

4.1 记忆作为上下文

在第一种架构设计中（见图 2），我们将记忆视为当前信息的上下文。也就是说，给定一个长序列 $x \in \mathbb{R}^{N \times d_m}$ ，我们首先将序列分块为固定大小的片段 $S^{(i)}$ ，其中 $i = 1, \dots, N/C$ 。给定传入片段 $S^{(t)}$ ，我们将其视为当前上下文，并将其过去的片段视为历史信息。因此，设 M_{t-1} 为片段 $S^{(t)}$ 之前的长期记忆状态，我们使用输入上下文作为对记忆 M_{t-1} 的查询，以从长期记忆中检索相应的信息。也就是说，我们检索与 $S^{(t)}$ 对应的过去信息，如下所示：

$$h_t = M_{t-1}^*(q_t), \quad (21)$$

其中 $q_t = S^{(t)} W_Q$ 。接下来，我们将这些历史信息与我们的持久记忆参数一起作为注意力模块的输入序列：

$$\tilde{S}^{(t)} = [p_1 \ p_2 \ \dots \ p_{N_p}] \parallel h_t \parallel S^{(t)}, \quad (22)$$

$$y_t = \text{Attn}(\tilde{S}^{(t)}). \quad (23)$$

整个序列上的注意力图结构如图 3a 所示。然后我们使用 u_t 来更新下一片段的长期记忆模块和最终输出：

$$M_t = M_{t-1}(y_t), \quad (24)$$

$$o_t = y_t \otimes M_t^*(y_t). \quad (25)$$

请注意，在上述过程中，我们通过前向传播更新 M_{t-1} 的权重。该架构具有两个关键优势：（1）注意力机制同时拥有历史和当前上下文，能够判断在当前数据下是否需要长期记忆信息。（2）注意力模块有助于




图 4：记忆作为门控（MAG）架构。该架构同样具有三个分支：（1）核心、（2）上下文记忆和（3）持久记忆。然而，它仅将持久记忆纳入上下文，并通过门控机制将记忆与核心分支结合。在测试时，其行为与图 2 相同。

长期记忆仅存储当前上下文中有用的信息。也就是说，并非每个片段中的所有标记都有用，记忆所有标记可能导致记忆溢出。因此，注意力机制帮助记忆理解哪些信息有用，从而更好地管理记忆容量。（3）在测试时：（i）持久记忆参数固定，因为它们编码了关于任务的知识，不应改变；（ii）注意力模块权重是上下文学习者；（iii）长期记忆模块在测试时仍在学习（记忆）信息。也就是说，即使在测试时，我们也会更新神经记忆的权重，因为权重编码了长期过去的抽象。

4.2 门控记忆

在下一个变体中（见图 4），在一个分支中，我们直接使用输入数据更新长期记忆，在第二个分支中，我们使用滑动窗口注意力（SWA）：

$$\tilde{x} = [p_1 \ p_2 \ \dots \ p_{N_p}] \parallel x, \quad (26)$$

$$y = \text{SW-Attn}^*(\tilde{x}), \quad (27)$$

$$o = y \otimes \mathcal{M}(\tilde{x}), \quad (28)$$

其中 SW-Attn^* 是带前缀的滑动窗口注意力（见图 3b）。请注意，与之前的设计相反，我们不对输入数据进行分段。此外，我们滥用符号，使用 $\mathcal{M}(x)$ 来表示在序列所有标记上递归后记忆的最终输出。在上述方程中， $\otimes_{\text{can}}$ 可以是任何非线性门控。在我们的实验中，我们使用可学习的向量值权重对输出 y 和 $\mathcal{M}(\tilde{x})$ 进行归一化，然后应用非线性 $\sigma(\cdot)$ 。

该设计的整体注意力掩码如图 3b 所示。在此设计中，滑动窗口注意力充当精确的短期记忆，而神经记忆模块则充当模型的衰减记忆。这种架构设计也可以看作是一种多头架构，其中头的结构不同（X. Dong 等人，2024）。

4.3 记忆作为层

最后一种变体将神经记忆作为深度神经网络的一层（MAL）（见图 5）。这种架构设计在文献中更为常见，其中混合模型将循环模型与全注意力或滑动窗口注意力堆叠在一起。给定输入 x ，我们有：

$$\tilde{x} = [p_1 \ p_2 \ \dots \ p_{N_p}] \parallel x, \quad (29)$$

$$y = \mathcal{M}(\tilde{x}), \quad (30)$$

$$o = \text{SW-Attn}(y), \quad (31)$$




图 5：记忆作为一层（MAL）架构。在该架构中，记忆层负责在注意力模块之前压缩过去和当前的上下文。

其中 SW-Attn 是滑动窗口注意力。这种设计的主要缺点是模型的性能受限于每一层，因此无法利用注意力和神经记忆模块的互补数据处理能力。在我们的实验中，为了评估这种设计中的记忆，我们采用了与 H3 (D. Y. Fu 等人, 2023) 类似的架构，其中我们将序列模型替换为我们的神经记忆模块 (LMM)。

无注意力的记忆。尽管上文我们将 MAL 讨论为 LMM 与注意力以顺序方式的组合，但 MAL 的一个简单变体是将 LMM 视为没有任何注意力的序列模型。从记忆的角度来看，如第 1 节所讨论的，我们期望记忆系统的每个部分都能独立工作，即使其他组件受到干扰。因此，即使没有短期记忆（即注意力），长期记忆模块仍应是一个强大的模型。我们在实验中称这种变体为 LMM 或 Titans (LMM)。我们在附录 C 中提供了关于 Titans 与其他现代循环模型联系的额外讨论。

4.4 架构细节

为了简单和表述清晰，我们避免讨论实现细节，如使用残差连接、线性层门控和归一化。在所有块中，我们使用残差连接。在我们的实现中，我们使用 SiLU(.) 激活函数 (Elfwing, Uchibe, and Doya 2018) 作为计算查询、键和值的非线性激活，并使用 l_2 -范数对查询和键进行归一化。

卷积。遵循近期现代线性循环模型 (Gu and Dao 2024; S. Yang, Kautz, and Hatamizadeh 2024) 的思路，我们在查询、键和值投影之后各加入一个一维深度可分离卷积层。虽然这些一维卷积对性能影响不大，但已显示出性能提升，并且计算效率高。

门控机制。我们也遵循近期架构的做法，在最终输出投影之前使用归一化和带线性层的门控机制 (Mehta et al. 2023)。

定理 4.1。与变换器、对角线性循环模型和 DeltaNet 不同，它们都受限干 TC 的问题，这意味着在状态跟踪任务中，Titans 在理论上比变换器和大多数现代线性循环模型更具表达力。⁰ (Merrill, Petty, and S)

5 实验

接下来，我们评估 Titans 及其变体在语言建模、常识推理、大海捞针、DNA 建模和时间序列预测任务中的性能¹。更详细地，在本节中，我们回答以下实证问题：（1）与基线相比，Titans 在下游任务中的表现如何？（见 § 5.2，¹ 在本工作的第一版中，我们旨在提供关于 Titans 学习范式为何有效的见解/证据。我们正在完成更大模型的结果，并将在下一版本中报告。

§ 5.6 和 § 5.7)；(2) Titans 的实际上下文长度是多少？(见 § 5.3 和 § 5.4)；(3) Titans 在上下文长度方面如何扩展？(见 § 5.8)；(4) 记忆深度如何影响性能和效率？(见 § 5.5)；以及 (5) 每个 Titans 组件对其性能的贡献是什么？(见 § 5.9)。

5.1 实验设置

模型。在实验中，我们聚焦于泰坦 (Titans) 的三种变体，分别称为：(1) 记忆作为上下文 (Memory as a Context, MAC)，(2) 记忆作为门控 (Memory as a Gate, MAG)，(3) 记忆作为层 (Memory as a Layer, MAL)，以及 (4) 单独的神经记忆模块。将长期记忆作为独立模块的原因基于我们对学习的定义。如第 1 节所述，我们将学习定义为获取有效且有用记忆的过程。因此，我们期望长期记忆即使在没有注意力的情况下也能有效地从数据中学习。对于每个模型，我们考虑四种规模：(i) 170M，(ii) 340M，(iii) 400M，以及 (iv) 760M 参数。前三个模型在从 FineWeb-Edu 数据集 (Penedo 等人, 2024) 采样的 150 亿个标记上训练，最后一个模型在同一数据集的 300 亿个标记上训练。

基线。我们将所提模型与最先进的线性循环模型、变换器 (Transformer) 以及混合模型 (循环+注意力) 进行比较。具体而言，在语言任务中，我们与 Transformer++ (Touvron 等人, 2023 年)、RetNet (Yutao Sun 等人, 2023 年)、门控线性注意力 (Gated Linear Attention, GLA) (S. Yang, B. Wang, Shen 等人, 2024 年)、Mamba (Gu 和 Dao, 2024 年)、Mamba2 (Dao 和 Gu, 2024 年)、DeltaNet (S. Yang, B. Wang, Yu Zhang 等人, 2024 年)、TTT (Yu Sun 等人, 2024 年) 以及门控 DeltaNet (S. Yang, Kautz 和 Hatamizadeh, 2024 年) 进行比较。在“大海捞针”任务中，我们还与 GPT4 (Achiam 等人, 2023 年)、带 RAG 的 Llama3 (Touvron 等人, 2023 年)、RecurrentGemma2-9B (Botev 等人, 2024 年) 以及 Mistral (Jiang 等人, 2023 年) 模型进行比较，这些模型均由基准 (Yuri Kuratov 等人, 2024 年) 提供。在时间序列任务中，我们与基于 Mamba 的模型 (Behrouz, Santacatterina 和 Zabih, 2024 年)、基于 Transformer 的模型 (Y. Liu 等人, 2023 年; Nie 等人, 2022 年; Yunhao Zhang 和 Yan, 2023 年) 以及线性模型 (Das 等人, 2023 年; Z. Li 等人, 2023 年; H. Wu 等人, 2023 年; Zeng 等人, 2023 年) 进行比较。

训练。在训练中，我们遵循 S. Yang, Kautz 和 Hatamizadeh (2024) 的训练流程，使用词汇量为 32K 的 Llama 2 分词器，训练长度为 4K 个标记。我们采用 AdamW 优化器，学习率为 $4e-4$ ，采用余弦退火调度，批大小为 0.5M 个标记，权重衰减为 0.1。

5.2 语言建模

我们首先关注语言建模中的困惑度以及常识推理任务。表 1 报告了 Titans 变体以及三种不同规模 (340M、400M 和 760M) 基线的结果。在包括 Transformer++ 在内的非混合模型中，我们的神经记忆模块在困惑度和准确率度量上均达到了最佳性能。将我们的神经记忆模块与同样基于梯度的循环模型 TTT 进行比较，可以揭示权重衰减和动量的重要性。如前所述，权重衰减可解释为一种门控机制，在需要时遗忘过去的信息。同时，动量通过为意外度量提供额外记忆，帮助我们更好地管理记忆。虽然一些基线也利用了门控机制，例如 Mamba、Mamba2 和 Gated DeltaNet，但我们的神经记忆模块的卓越性能表明，我们的意外机制以及深层非线性记忆的重要性。我们将在第 5.5 节进一步讨论后者。比较混合模型，我们发现 Titans 的所有三种变体 (MAC、MAG 和 MAL) 均优于 Samba (Mamba + 注意力) 和 Gated DeltaNet-H2 (Gated DeltaNet + 注意力)。我们将 Titans 的卓越性能

(MAL) 归因于神经记忆模块的强大能力，因为架构设计和使用的注意力完全相同。比较 Titans (MAG) 和 (MAC)，我们发现虽然它们的性能接近，但 MAC 在处理数据中更长的依赖关系时表现更好。有趣的是，MAG 和 MAC 均优于 MAL 变体，由于使用了相同的模块，我们将此归因于这些模型的架构设计。这一发现尤为重要，因为文献中当前的混合模型 (除 Hymba (X. Dong 等人, 2024) 外) 均采用 MAL 风格的循环模型与注意力的组合。

5.3 大海捞针

将模型扩展到更长的上下文窗口并不总是等同于对非常长的序列有效 (Hsieh 等人, 2024)。大海捞针 (NIAH) 任务旨在衡量模型的实际有效上下文长度。在此任务中，我们评估模型从长干扰文本 (即“干草堆”) 中检索一条信息 (即“针”) 的能力。

表 1: 泰坦 (Titans) 及基于循环和变换器的基线模型在语言建模与常识推理任务上的性能。混合模型以 * 标记。简单模型与混合模型中的最佳结果已高亮显示。

Model	Wiki. ppl ↓	LMB. ppl ↓	LMB. acc ↑	PIQA acc ↑	Hella. acc_n ↑	Wino. acc ↑	ARC-e acc ↑	ARC-c acc_n ↑	SIQA acc ↑	BoolQ acc ↑	Avg. ↑
340M params / 15B tokens											
Transformer++	31.52	41.08	30.76	62.98	34.76	50.53	45.21	24.05	36.81	58.24	42.92
RetNet	32.50	49.73	28.24	62.61	34.15	50.91	44.27	23.62	36.79	59.72	42.54
GLA	28.51	43.02	28.73	64.05	35.96	50.00	54.19	24.29	37.13	58.39	44.09
Mamba	30.83	40.21	29.94	63.79	35.88	49.82	49.24	24.56	35.41	60.07	43.59
DeltaNet	28.65	47.30	28.43	63.52	35.95	49.63	52.68	25.37	37.96	58.79	44.04
TTT	27.44	34.19	30.06	63.97	35.71	50.08	53.01	26.11	37.32	59.83	44.51
Gated DeltaNet	27.01	30.94	34.11	63.08	38.12	51.60	55.28	26.77	34.89	59.54	45.42
Titans (LMM)	26.18	29.97	34.98	64.73	39.61	51.85	55.60	28.14	34.52	59.99	46.17
Titans (MAC)*	25.43	28.13	36.00	65.32	40.35	51.21	58.17	29.00	38.63	60.18	47.36
Titans (MAG)*	25.07	28.72	36.71	64.88	40.56	52.49	57.72	28.16	39.75	60.01	47.54
Titans (MAL)*	24.69	28.80	35.74	64.97	39.44	51.97	56.58	28.21	38.14	57.32	46.55
400M params / 15B tokens											
Transformer++	30.63	37.37	29.64	64.27	37.72	51.53	54.95	27.36	38.07	61.59	45.64
RetNet	29.92	46.83	29.16	65.23	36.97	51.85	56.01	27.55	37.30	59.66	45.47
HGRN2	32.33	47.14	26.12	64.52	35.45	52.24	55.97	25.51	37.35	59.02	44.52
GLA	27.96	36.66	27.86	65.94	37.41	49.56	56.01	26.36	38.94	59.84	45.24
Mamba	29.22	39.88	29.82	65.72	37.93	50.11	58.37	26.70	37.76	61.13	45.94
Mamba2	26.34	33.19	32.03	65.77	39.73	52.48	59.00	27.64	37.92	60.72	46.91
DeltaNet	27.69	44.04	29.96	64.52	37.03	50.82	56.77	27.13	38.22	60.09	45.57
TTT	26.11	31.52	33.25	65.70	39.11	51.68	58.04	28.99	38.26	59.87	46.86
Gated DeltaNet	25.47	29.24	34.40	65.94	40.46	51.46	59.80	28.58	37.43	60.03	47.26
Samba*	25.32	29.47	36.86	66.09	39.24	51.45	60.12	27.20	38.68	58.22	47.23
Gated DeltaNet-H2*	24.19	28.09	36.77	66.43	40.79	52.17	59.55	29.09	39.04	58.56	47.69
Titans (LMM)	25.03	28.99	35.21	65.85	40.91	52.19	59.97	29.20	38.74	60.85	47.83
Titans (MAC)*	25.61	27.73	36.92	66.39	41.18	52.80	60.24	29.69	40.07	61.93	48.65
Titans (MAG)*	23.59	27.81	37.24	66.80	40.92	53.21	60.01	29.45	39.91	61.28	48.60
Titans (MAL)*	23.93	27.89	36.84	66.29	40.74	52.26	59.85	29.71	38.92	58.40	47.87
760M params / 30B tokens											
Transformer++	25.21	27.64	35.78	66.92	42.19	51.95	60.38	32.46	39.51	60.37	48.69
RetNet	26.08	24.45	34.51	67.19	41.63	52.09	63.17	32.78	38.36	57.92	48.46
Mamba	28.12	23.96	32.80	66.04	39.15	52.38	61.49	30.34	37.96	57.62	47.22
Mamba2	22.94	28.37	33.54	67.90	42.71	49.77	63.48	31.09	40.06	58.15	48.34
DeltaNet	24.37	24.60	37.06	66.93	41.98	50.65	64.87	31.39	39.88	59.02	48.97
TTT	24.17	23.51	34.74	67.25	43.92	50.99	64.53	33.81	40.16	59.58	47.32
Gated DeltaNet	21.18	22.09	35.54	68.01	44.95	50.73	66.87	33.09	39.21	59.14	49.69
Samba*	20.63	22.71	39.72	69.19	47.35	52.01	66.92	33.20	38.98	61.24	51.08
Gated DeltaNet-H2*	19.88	20.83	39.18	68.95	48.22	52.57	67.01	35.49	39.39	61.11	51.49
Titans (LMM)	20.04	21.96	37.40	69.28	48.46	52.27	66.31	35.84	40.13	62.76	51.56
Titans (MAC)	19.93	20.12	39.62	70.46	49.01	53.18	67.86	36.01	41.87	62.05	52.51
Titans (MAG)	18.61	19.86	40.98	70.25	48.94	52.89	68.23	36.19	40.38	62.11	52.50
Titans (MAL)	19.07	20.33	40.05	69.99	48.82	53.02	67.54	35.65	30.98	61.72	50.97

“干草堆”)。本部分采用 RULER 基准 (Hsieh 等人, 2024) 中的单针尖检索 (S-NIAH) 任务, 在长度为 2K、4K、8K 和 16K 的序列上评估泰坦及基线模型。结果见表 2。神经记忆模块在所有三项任务中均取得优于基线的结果。我们将这一卓越性能归因于泰坦与现有序列模型的三个关键差异: (1) 与 TTT 相比, 神经记忆通过动量及遗忘机制 (即权重衰减) 更好地管理记忆容量。因此, 随着序列长度增加, 神经记忆的性能不会下降, 并呈现一致趋势; (2) 与具有门控 (遗忘) 机制的 Mamba2 相比, 泰坦拥有深度非线性记忆, 从而实现更优的记忆管理。此外, 与神经记忆和 DeltaNet 不同, Mamba2 无法移除记忆, 因此

表 2: 泰坦及基线模型在 RULER 基准 S-NIAH 任务上的性能。简单模型与混合模型中的最佳结果已高亮显示。

Model	S-NIAH-PK				S-NIAH-N				S-NIAH-W			
	2K	4K	8K	16K	2K	4K	8K	16K	2K	4K	8K	16K
TTT	98.4	98.8	98.0	88.4	60.2	36.6	10.2	4.4	78.8	28.0	4.4	0.0
Mamba2	98.6	61.4	31.0	5.4	98.4	55.8	14.2	0.0	42.2	4.2	0.0	0.0
DeltaNet	96.8	98.8	98.6	71.4	47.2	15.4	12.8	5.4	46.2	20.0	1.6	0.0
Titans (LMM)	99.8	98.4	98.2	96.2	100.0	99.8	93.4	80.2	90.4	89.4	85.8	80.6
Titans (MAC)	99.2	98.8	99.0	98.4	99.6	98.2	97.6	97.4	98.2	98.2	95.6	95.2
Titans (MAG)	99.4	98.0	97.4	97.4	99.2	98.8	97.2	98.6	98.0	98.0	90.2	88.2
Titans (MAL)	98.8	98.6	98.8	97.8	99.8	98.1	96.8	96.4	98.0	97.4	92.0	90.4




图 6: 泰坦及基线模型在 BABILong 基准上的性能。泰坦 (MAC) 超越所有基线, 包括 GPT4 等超大型模型。

当序列长度增加时, 性能显著下降; (3) 与 DeltaNet 相比, 尽管其能利用增量规则移除记忆, 但无法擦除记忆, 缺乏遗忘机制。最后, 如预期所示, 使用泰坦变体可获得相当或更优的结果, 其中最佳结果对应 MAC。

5.4 BABILong 基准

在上一节中, 我们讨论了简单针尖检索任务的结果, 该任务只需检索单个针尖。尽管泰坦相比基线表现出更好的性能, 但其在超长序列上的真正优势仍未显现。为此, 本节采用来自 BABILong 基准 (Yuri Kuratov 等, 2024) 的更难任务, 该任务要求模型对分布在极长文档中的事实进行推理。我们遵循该基准中的原始实验设置和训练流程。共有两种设置: (1) 少样本设置, 使用大型预训练模型; (2) 微调设置, 对泰坦的 MAC 变体进行微调, 以与其他微调基线进行比较。少样本设置的结果如图 6a 所示。在该设置下, 泰坦超越了所有基线——即 Mamba2.8B (Gu 和 Dao, 2024)、RWKV-6-7B (Peng、Goldstein 等, 2024)、RecurrentGemma-9B (Botev 等, 2024)、Gemma-9B (Team 等, 2024)、Llama3.1-8B (Touvron 等, 2023)、GPT-4 和 GPT4o-mini (Achiam 等, 2023)。这些结果是在泰坦 (MAC) 参数量远少于基线的情况下取得的。在微调设置中, 我们将泰坦 (MAC) 的小型微调版本与以下模型进行比较: (i) 小型模型的微调版本 (参数量与泰坦几乎相同), 如 Mamba (Gu 和 Dao, 2024)、RMT (Bulatov、Yury Kuratov 和 Burtsev, 2022); (ii) 采用检索增强生成 (RAG) (P. Lewis 等, 2020) 的大型模型, 如 Llama3.1-8B (Touvron 等, 2023); (iii) 超大型模型, 如 GPT-4 (Achiam 等, 2023)、GPT4o-mini、Qwen2.5-72B (A. Yang 等, 2024) 和 Llama3.1-70B (Touvron 等, 2023)。基线结果由 (Yuri Kuratov 等, 2024) 报告。泰坦和基线的结果如图 6b 所示。泰坦超越了所有模型, 甚至包括 GPT4 等超大型模型。此外, 与基于变换器并带记忆的模型 (如 RMT) 相比, 泰坦表现出更好的性能, 主要归功于其强大的记忆能力。也就是说, RMT 将历史数据压缩为 16 维向量值记忆, 而泰坦借助上下文在线记忆学习器能够将过去编码到模型参数中。有趣的是, 甚至




图 7: 记忆深度对困惑度的影响。更深的长期记忆在更长序列上带来更好的扩展性。

表 3: 长期预测性能。最佳结果以高亮显示。

	Neural Memory		Simba		iTransformer		RLinear		PatchTST		Crossformer		TiDE		TimesNet		DLinear	
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETIm1	0.358	0.387	0.383	0.396	0.407	0.410	0.414	0.407	0.387	0.400	0.513	0.496	0.419	0.419	0.400	0.406	0.403	0.407
ETIm2	0.261	0.309	0.271	0.327	0.288	0.332	0.286	0.327	0.281	0.326	0.757	0.610	0.358	0.404	0.291	0.333	0.350	0.401
ETTh1	0.420	0.421	0.441	0.432	0.454	0.447	0.446	0.434	0.469	0.454	0.529	0.522	0.541	0.507	0.458	0.450	0.456	0.452
ETTh2	0.336	0.382	0.361	0.391	0.383	0.407	0.374	0.398	0.387	0.407	0.942	0.684	0.611	0.550	0.414	0.427	0.559	0.515
ECL	0.162	0.261	0.169	0.274	0.178	0.270	0.219	0.298	0.205	0.290	0.244	0.334	0.251	0.344	0.192	0.295	0.212	0.300
Traffic	0.415	0.289	0.493	0.291	0.428	0.282	0.626	0.378	0.481	0.304	0.550	0.304	0.760	0.473	0.620	0.336	0.625	0.383
Weather	0.231	0.265	0.255	0.280	0.258	0.278	0.272	0.291	0.259	0.281	0.259	0.315	0.271	0.320	0.259	0.287	0.265	0.317

用 RAG 增强 Llama3.1-8B 模型的表现比 Titans 差，且参数少约 $\times 70$ 。

5.5 深度记忆的影响

本节评估深度记忆对墙钟训练时间和模型性能的影响²。为此，我们聚焦于神经记忆模块的不同变体，其中 $L_M = 1, 2, 3, 4$ 。同时使用 Mamba 作为模型性能的基线。为公平比较，所有模型采用相同的训练过程，并在 Pile 数据集的子集上训练 (L. Gao 等, 2020)。

我们在图 7 中报告了模型和基线的困惑度随序列长度变化的函数。有趣的是，随着记忆深度的增加 L_M ，模型在所有序列长度上都能获得更好的困惑度。此外，当模型参数较少时，更深的记忆模块对序列长度更鲁棒。随着参数数量的增加，所有模型在较长序列上表现出更好的性能。

我们还评估了记忆深度 ($L_M = 1, 2, 3, 4$) 对训练吞吐量的影响。我们在图 8 中报告了训练吞吐量（每秒处理的标记数）随序列长度变化的函数。所有模型相对于上下文长度呈线性扩展（即每秒标记数相对于序列长度保持恒定趋势）。此外，随着记忆深度的增加，正如预期，可以看到线性趋势：更深的记忆导致训练更慢。因此，使用更深的记忆模块并不总是高效的，这显示了有效性与效率之间的权衡。




图 8: 记忆深度对训练吞吐量的影响

5.6 时间序列预测

为了展示我们的记忆模块在更广泛任务中的有效性，我们还评估了其在时间序列预测任务中的性能。为此，我们使用 Simba 框架 (Patro 和 Agneeswaran, 2024) 进行时间序列预测，并且

注意，在本实验中，我们仅关注神经记忆模块，以评估记忆深度在记忆过程中的作用。将神经记忆与注意力结合，正如我们在 Titans 变体中所做的那样，可以进一步提升模型在长序列上的性能。

表 4: 预训练 DNA 模型在 GenomicsBenchmarks 上的下游评估 (Grešová 等人, 2023 年)。我们报告了 top-1 分类准确率 (%)。

Model	Enhancer Cohn	Enhancer Ens	Human Reg.	Non-TATA Promoters	Human OCR Ens.
CNN	69.5	68.9	93.3	84.6	68.0
DNABERT	74.0	85.7	88.1	85.6	75.1
GPT	70.5	83.5	91.5	87.7	73.0
HyenaDNA	74.2	89.2	93.8	96.6	80.9
Transformer++	73.4	89.5	89.9	94.4	79.5
Mamba	73.0	-	-	96.6	-
Based	74.6	89.5	89.5	96.8	79.0
Neural Memory Module	75.2	89.6	89.3	96.6	79.9

将其 Mamba 模块替换为我们的神经记忆。我们在常见的时间序列预测基准数据集——ETT、ECL、Traffic 和 Weather (H. Zhou 等人, 2021 年) 上报告了结果。结果见表 3。我们的神经记忆模块优于所有基线, 包括基于 Mamba、基于线性和基于 Transformer 的架构。

5.7 DNA 建模

为了解 Titans 在自然语言之外的能力, 我们进一步评估了神经记忆模块在 DNA 建模任务上的性能。为此, 我们在 GenomicsBenchmarks (Grešová 等人, 2023 年) 的下游任务上评估了预训练模型。我们遵循 Nguyen 等人 (2024 年) 的相同实验设置, 并复用了 Arora 等人 (2024 年) 报告的基线结果。Titans (LMM) 和基线的性能见表 4。我们发现 LMM 在不同的下游基因组学任务中与最先进的架构具有竞争力。

5.8 效率

在本部分中, 我们将神经记忆以及 Titans 与最先进的序列模型的效率进行了比较。不同序列长度 $\times$ 批大小下的模型训练吞吐量见图 9。比较包括我们神经记忆模块在内的循环模型, 我们可以看到我们的记忆模块比 Mamba2 和 Gated DeltaNet 稍慢, 主要原因是: (1) 具有深度记忆和更具表达力的转换过程 (记忆更新), 以及 (2) Mamba2 实现中高度优化的核函数。有趣的是, Titans (MAL) 比基线以及记忆模块更快。这种更高吞吐量的主要原因是 Flash-Attention (Dao 2024) 的高度优化核函数, 该核函数用于实现 Titans 中的 SWA 和全注意力模块。




图 9: Titans 与基线的训练吞吐量比较。

5.9 消融实验

最后, 我们对泰坦 (Titans) 中不同的架构选择进行了消融实验。我们将神经记忆模块作为基础模型, 然后每次改变一个组件: (1) 用线性记忆替换深度记忆, 移除 (2) 卷积, (3) 惊讶测度中的动量, (4) 权重衰减 (或遗忘机制), 以及 (5) 持久记忆。结果报告在表 5 中。神经记忆设计的所有组件都对其性能有积极贡献, 其中贡献最大的是权重衰减、动量、卷积和持久记忆。

架构设计的影响。为了评估架构设计的影响, 我们比较了泰坦的三种代表性变体在 (i) 语言建模, (ii) 常识推理, 以及 (iii) 长上下文 NIAH (BABILong) 任务三个方面的性能。结果报告在表 5 中。我们发现 MAC 和 MAG 在语言建模和常识推理任务中性能接近, 而 MAC 在长上下文 NIAH 中取得了显著更好的性能。这两种模型都比 MAL 取得了更好的性能。这些结果与图 9 一起, 展示了快速训练和更具表现力的设计之间的权衡。

表 5: 泰坦的消融实验。泰坦的所有组件都对其性能有积极贡献。

Model	Language Modeling ppl ↓	Reasoning acc ↑	Long Context acc ↑
LMM	27.01	47.83	92.68
+Attn (MAC)	26.67	48.65	97.95
+Attn (MAG)	25.70	48.60	96.70
+Attn (MAL)	25.91	47.87	96.91
Linear Memory	28.49	46.97	85.34
w/o Convolution	28.73	45.82	90.28
w/o Momentum	28.98	45.49	87.12
w/o Weight Decay	29.04	45.11	85.60
w/o Persistent Memory	27.63	46.35	92.49

6 结论

在本文中，我们提出了一种神经长期记忆，它作为一种元上下文学习者，在测试时学习记忆。神经记忆模块本质上是一个循环模型，并且自适应地记忆那些更令人惊讶或接近令人惊讶标记的标记。与现代循环模型相比，它具有更具表现力的记忆更新和存储机制。利用这种记忆，我们提出了泰坦架构及其三种变体，其中我们建议将记忆模块作为（1）上下文，（2）门控，以及（3）一个层来整合。我们在多种任务上的实验评估验证了泰坦比变换器和最近的现代线性循环模型更有效，特别是在长上下文方面。也就是说，泰坦可以扩展到超过 2M 上下文窗口大小，并且比基线具有更好的准确率。泰坦在 PyTorch 和 JAX 中实现，我们打算很快公开我们用于训练和评估模型的代码。

参考文献

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. “Gpt-4 technical report”. In: *arXiv preprint arXiv:2303.08774* (2023).
- [2] Yaroslav Aksenov, Nikita Balagansky, Sofia Maria Lo Cicero Vaina, Boris Shaposhnikov, Alexey Gorbatsovski, and Daniil Gavrillov. “Linear Transformers with Learnable Kernel Functions are Better In-Context Models”. In: *arXiv preprint arXiv:2402.10644* (2024).
- [3] Marcin Andrychowicz, Misha Denil, Sergio Gomez, Matthew W Hoffman, David Pfau, Tom Schaul, Brendan Shillingford, and Nando De Freitas. “Learning to learn by gradient descent by gradient descent”. In: *Advances in neural information processing systems* 29 (2016).
- [4] Cem Anil, Yuhuai Wu, Anders Andreassen, Aitor Lewkowycz, Vedant Misra, Vinay Ramasesh, Ambrose Slone, Guy Gur-Ari, Ethan Dyer, and Behnam Neyshabur. “Exploring length generalization in large language models”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 38546–38556.
- [5] Simran Arora, Sabri Eyuboglu, Michael Zhang, Aman Timalsina, Silas Alberti, James Zou, Atri Rudra, and Christopher Re. “Simple linear attention language models balance the recall-throughput tradeoff”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=e93ffDcpH3>.
- [6] Dzmitry Bahdanau. “Neural machine translation by jointly learning to align and translate”. In: *arXiv preprint arXiv:1409.0473* (2014).
- [7] Reza Bayat, Mohammad Pezeshki, Elvis Dohmatob, David Lopez-Paz, and Pascal Vincent. “The Pitfalls of Memorization: When Memorization Hurts Generalization”. In: *arXiv preprint arXiv:2412.07684* (2024).
- [8] Maximilian Beck, Korbinian Pöppel, Markus Spanring, Andreas Auer, Oleksandra Prudnikova, Michael Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. “xLSTM: Extended Long Short-Term Memory”. In: *arXiv preprint arXiv:2405.04517* (2024).
- [9] Ali Behrouz, Michele Santacatterina, and Ramin Zabih. “Mambamixer: Efficient selective state space models with dual token and channel selection”. In: *arXiv preprint arXiv:2403.19888* (2024).
- [10] Vincent-Pierre Berges, Barlas Öguz, Daniel Haziza, Wen-tau Yih, Luke Zettlemoyer, and Gargi Gosh. “Memory Layers at Scale”. In: *arXiv preprint arXiv:2412.09764* (2024).
- [11] Alberto Bietti, Vivien Cabannes, Diane Bouchacourt, Herve Jegou, and Leon Bottou. “Birth of a transformer: A memory viewpoint”. In: *Advances in Neural Information Processing Systems* 36 (2024).
- [12] Yonatan Bisk, Rowan Zellers, Jianfeng Gao, Yejin Choi, et al. “Piqa: Reasoning about physical commonsense in natural language”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 34. 05. 2020, pp. 7432–7439.
- [13] Aleksandar Botev, Soham De, Samuel L Smith, Anushan Fernando, George-Cristian Muraru, Ruba Haroun, Leonard Berrada, Razvan Pascanu, Pier Giuseppe Sessa, Robert Dadashi, et al. “RecurrentGemma: Moving Past Transformers for Efficient Open Language Models”. In: *arXiv preprint arXiv:2404.07839* (2024).
- [14] Léon Bottou and Vladimir Vapnik. “Local learning algorithms”. In: *Neural computation* 4.6 (1992), pp. 888–900.
- [15] Aydar Bulatov, Yuri Kuratov, Yermek Kapushev, and Mikhail S Burtsev. “Scaling transformer to 1m tokens and beyond with rmt”. In: *arXiv preprint arXiv:2304.11062* (2023).
- [16] Aydar Bulatov, Yuri Kuratov, and Mikhail Burtsev. “Recurrent memory transformer”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 11079–11091.
- [17] Edoardo Cetin, Qi Sun, Tianyu Zhao, and Yujin Tang. “An Evolved Universal Transformer Memory”. In: *arXiv preprint arXiv:2410.13166* (2024).
- [18] Beidi Chen, Tri Dao, Eric Winsor, Zhao Song, Atri Rudra, and Christopher Ré. “Scatterbrain: Unifying sparse and low-rank attention”. In: *Advances in Neural Information Processing Systems* 34 (2021), pp. 17413–17426.
- [19] Krzysztof Marcin Choromanski, Valerii Likhoshesterov, David Dohan, Xingyou Song, Andreea Gane, Tamas Sarlos, Peter Hawkins, Jared Quincy Davis, Afroz Mohiuddin, Lukasz Kaiser, David Benjamin Belanger, Lucy J Colwell, and Adrian Weller. “Rethinking Attention with Performers”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=Ua6zuk0WRH>.
- [20] Christopher Clark, Kenton Lee, Ming-Wei Chang, Tom Kwiatkowski, Michael Collins, and Kristina Toutanova. “BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Ed. by Jill Burstein, Christy Doran, and Thamar Solorio. Minneapolis, Minnesota: Association for Computational Linguistics, June 2019, pp. 2924–2936. DOI: 10.18653/v1/N19-1300. URL: <https://aclanthology.org/N19-1300/>.

- [21] Peter Clark, Isaac Cowhey, Oren Etzioni, Tushar Khot, Ashish Sabharwal, Carissa Schoenick, and Oyvind Tafjord. “Think you have solved question answering? try arc, the ai2 reasoning challenge”. In: *arXiv preprint arXiv:1803.05457* (2018).
- [22] Nelson Cowan. “What are the differences between long-term, short-term, and working memory?” In: *Progress in brain research* 169 (2008), pp. 323–338.
- [23] Zihang Dai, Zhilin Yang, Yiming Yang, Jaime G. Carbonell, Quoc Viet Le, and Ruslan Salakhutdinov. “Transformer-XL: Attentive Language Models beyond a Fixed-Length Context”. In: *ACL (1)*. Ed. by Anna Korhonen, David R. Traum, and Lluís Màrquez. Association for Computational Linguistics, 2019, pp. 2978–2988. ISBN: 978-1-950737-48-2.
- [24] Tri Dao. “FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=mZn2Xyh9Ec>.
- [25] Tri Dao, Dan Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. “FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness”. In: *Advances in Neural Information Processing Systems*. Ed. by S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh. Vol. 35. Curran Associates, Inc., 2022, pp. 16344–16359. URL: https://proceedings.neurips.cc/paper_files/paper/2022/file/67d57c32e20fd0a7a302cb81d36e40d5-Paper-Conference.pdf.
- [26] Tri Dao and Albert Gu. “Transformers are SSMS: Generalized models and efficient algorithms through structured state space duality”. In: *arXiv preprint arXiv:2405.21060* (2024).
- [27] Abhimanyu Das, Weihao Kong, Andrew Leach, Shaan K Mathur, Rajat Sen, and Rose Yu. “Long-term Forecasting with TiDE: Time-series Dense Encoder”. In: *Transactions on Machine Learning Research* (2023). ISSN: 2835-8856. URL: <https://openreview.net/forum?id=pCbC3aQB5W>.
- [28] Soham De, Samuel L Smith, Anushan Fernando, Aleksandar Botev, George Cristian-Muraru, Albert Gu, Ruba Haroun, Leonard Berrada, Yutian Chen, Srivatsan Srinivasan, et al. “Griffin: Mixing gated linear recurrences with local attention for efficient language models”. In: *arXiv preprint arXiv:2402.19427* (2024).
- [29] Juechu Dong, Boyuan Feng, Driss Guessous, Yanbo Liang, and Horace He. “Flex Attention: A Programming Model for Generating Optimized Attention Kernels”. In: *arXiv preprint arXiv:2412.05496* (2024).
- [30] Xin Dong, Yonggan Fu, Shizhe Diao, Wonmin Byeon, Zijia Chen, Ameya Sunil Mahabaleshwarkar, Shih-Yang Liu, Matthijs Van Keirsbilck, Min-Hung Chen, Yoshi Suhara, et al. “Hymba: A Hybrid-head Architecture for Small Language Models”. In: *arXiv preprint arXiv:2411.13676* (2024).
- [31] Stefan Elfving, Eiji Uchibe, and Kenji Doya. “Sigmoid-weighted linear units for neural network function approximation in reinforcement learning”. In: *Neural networks* 107 (2018), pp. 3–11.
- [32] Yukun Feng, Feng Li, Ziang Song, Boyuan Zheng, and Philipp Koehn. “Learn to remember: Transformer with recurrent memory for document-level machine translation”. In: *arXiv preprint arXiv:2205.01546* (2022).
- [33] Daniel Y Fu, Tri Dao, Khaled Kamal Saab, Armin W Thomas, Atri Rudra, and Christopher Re. “Hungry Hungry Hippos: Towards Language Modeling with State Space Models”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=COZDy0WYGg>.
- [34] Yossi Gandelsman, Yu Sun, Xinlei Chen, and Alexei Efros. “Test-time training with masked autoencoders”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 29374–29385.
- [35] Leo Gao, Stella Biderman, Sid Black, Laurence Golding, Travis Hoppe, Charles Foster, Jason Phang, Horace He, Anish Thite, Noa Nabeshima, et al. “The pile: An 800gb dataset of diverse text for language modeling”. In: *arXiv preprint arXiv:2101.00027* (2020).
- [36] Felix A Gers, Jürgen Schmidhuber, and Fred Cummins. “Learning to forget: Continual prediction with LSTM”. In: *Neural computation* 12.10 (2000), pp. 2451–2471.
- [37] Alex Graves, Greg Wayne, and Ivo Danihelka. *Neural Turing Machines*. 2014. arXiv: 1410.5401 [cs.NE]. URL: <https://arxiv.org/abs/1410.5401>.
- [38] Klaus Greff, Rupesh K Srivastava, Jan Koutník, Bas R Steunebrink, and Jürgen Schmidhuber. “LSTM: A search space odyssey”. In: *IEEE transactions on neural networks and learning systems* 28.10 (2016), pp. 2222–2232.
- [39] Katarína Grešová, Vlastimil Martinek, David Čechák, Petr Šimeček, and Panagiotis Alexiou. “Genomic benchmarks: a collection of datasets for genomic sequence classification”. In: *BMC Genomic Data* 24.1 (2023), p. 25.
- [40] Albert Gu and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces”. In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=tEYskw1VY2>.
- [41] Albert Gu, Karan Goel, and Christopher Re. “Efficiently Modeling Long Sequences with Structured State Spaces”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=uYLFoz1v1AC>.

- [42] Chi Han, Qifan Wang, Hao Peng, Wenhan Xiong, Yu Chen, Heng Ji, and Sinong Wang. “LM-Infinite: Zero-Shot Extreme Length Generalization for Large Language Models”. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Ed. by Kevin Duh, Helena Gomez, and Steven Bethard. Mexico City, Mexico: Association for Computational Linguistics, June 2024, pp. 3991–4008. doi: 10.18653/v1/2024.naacl-long.222. URL: <https://aclanthology.org/2024.naacl-long.222>.
- [43] Ramin Hasani, Mathias Lechner, Tsun-Hsuan Wang, Makram Chahine, Alexander Amini, and Daniela Rus. “Liquid Structural State-Space Models”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=g40TKRKfS7R>.
- [44] Zexue He, Leonid Karlinsky, Donghyun Kim, Julian McAuley, Dmitry Krotov, and Rogerio Feris. “CAMELoT: Towards Large Language Models with Training-Free Consolidated Associative Memory”. In: *arXiv preprint arXiv:2402.13449* (2024).
- [45] Donald Olding Hebb. *The organization of behavior: A neuropsychological theory*. Psychology press, 2005.
- [46] John J Hopfield. “Neural networks and physical systems with emergent collective computational abilities.” In: *Proceedings of the national academy of sciences* 79.8 (1982), pp. 2554–2558.
- [47] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. “Multilayer feedforward networks are universal approximators”. In: *Neural networks* 2.5 (1989), pp. 359–366.
- [48] Cheng-Ping Hsieh, Simeng Sun, Samuel Kriman, Shantanu Acharya, Dima Rekeshe, Fei Jia, and Boris Ginsburg. “RULER: What’s the Real Context Size of Your Long-Context Language Models?” In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=kIoBbc76Sy>.
- [49] DeLesley Hutchins, Imanol Schlag, Yuhuai Wu, Ethan Dyer, and Behnam Neyshabur. “Block-recurrent transformers”. In: *Advances in neural information processing systems* 35 (2022), pp. 33248–33261.
- [50] Kazuki Irie, Róbert Csordás, and Jürgen Schmidhuber. “The dual form of neural networks revisited: Connecting test time predictions to training patterns via spotlights of attention”. In: *International Conference on Machine Learning*. PMLR. 2022, pp. 9639–9659.
- [51] Kazuki Irie, Imanol Schlag, Róbert Csordás, and Jürgen Schmidhuber. “Going beyond linear transformers with recurrent fast weight programmers”. In: *Advances in neural information processing systems* 34 (2021), pp. 7703–7717.
- [52] Vidit Jain and Erik Learned-Miller. “Online domain adaptation of a pre-trained cascade of classifiers”. In: *CVPR 2011*. IEEE. 2011, pp. 577–584.
- [53] Albert Q Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, et al. “Mistral 7B”. In: *arXiv preprint arXiv:2310.06825* (2023).
- [54] Praneeth Kacham, Vahab Mirrokni, and Peilin Zhong. “PolySketchFormer: Fast Transformers via Sketching Polynomial Kernels”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=ghYrfdJfjK>.
- [55] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. “Scaling laws for neural language models”. In: *arXiv preprint arXiv:2001.08361* (2020).
- [56] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and François Fleuret. “Transformers are rnns: Fast autoregressive transformers with linear attention”. In: *International conference on machine learning*. PMLR. 2020, pp. 5156–5165.
- [57] Urvashi Khandelwal, Omer Levy, Dan Jurafsky, Luke Zettlemoyer, and Mike Lewis. “Generalization through Memorization: Nearest Neighbor Language Models”. In: *International Conference on Learning Representations*. 2020. URL: <https://openreview.net/forum?id=HklBjCEKvH>.
- [58] Yuri Kuratov, Aydar Bulatov, Petr Anokhin, Ivan Rodkin, Dmitry Igorevich Sorokin, Artyom Sorokin, and Mikhail Burtsev. “BABILong: Testing the Limits of LLMs with Long Context Reasoning-in-a-Haystack”. In: *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2024. URL: <https://openreview.net/forum?id=u7m2CG84BQ>.
- [59] Hung Le, Truyen Tran, and Svetha Venkatesh. “Self-attentive associative memory”. In: *International conference on machine learning*. PMLR. 2020, pp. 5682–5691.
- [60] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. “Retrieval-augmented generation for knowledge-intensive nlp tasks”. In: *Advances in Neural Information Processing Systems* 33 (2020), pp. 9459–9474.

- [61] Danny Leybzon and Corentin Kervadec. “Learning, Forgetting, Remembering: Insights From Tracking LLM Memorization During Training”. In: *Proceedings of the 7th BlackboxNLP Workshop: Analyzing and Interpreting Neural Networks for NLP*. 2024, pp. 43–57.
- [62] Zhe Li, Shiyi Qi, Yiduo Li, and Zenglin Xu. “Revisiting long-term time series forecasting: An investigation on linear mapping”. In: *arXiv preprint arXiv:2305.10721* (2023).
- [63] Bo Liu, Rui Wang, Lemeng Wu, Yihao Feng, Peter Stone, and Qiang Liu. “Longhorn: State space models are amortized online learners”. In: *arXiv preprint arXiv:2407.14207* (2024).
- [64] Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. “Lost in the middle: How language models use long contexts”. In: *Transactions of the Association for Computational Linguistics* 12 (2024), pp. 157–173.
- [65] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma, and Mingsheng Long. “itransformer: Inverted transformers are effective for time series forecasting”. In: *arXiv preprint arXiv:2310.06625* (2023).
- [66] George Mandler. “The structure of value: Accounting for taste”. In: *Affect and cognition*. Psychology Press, 2014, pp. 3–36.
- [67] Harsh Mehta, Ankit Gupta, Ashok Cutkosky, and Behnam Neyshabur. “Long Range Language Modeling via Gated State Spaces”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=5MkYIYCbva>.
- [68] Stephen Merity, Caiming Xiong, James Bradbury, and Richard Socher. “Pointer Sentinel Mixture Models”. In: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=Byj72udxe>.
- [69] William Merrill, Jackson Petty, and Ashish Sabharwal. “The Illusion of State in State-Space Models”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=QZgo9JZpLq>.
- [70] Ravi Teja Mullapudi, Steven Chen, Keyi Zhang, Deva Ramanan, and Kayvon Fatahalian. “Online model distillation for efficient video inference”. In: *Proceedings of the IEEE/CVF International conference on computer vision*. 2019, pp. 3573–3582.
- [71] Tsendsuren Munkhdalai, Manaal Faruqui, and Siddharth Gopal. “Leave no context behind: Efficient infinite context transformers with infini-attention”. In: *arXiv preprint arXiv:2404.07143* (2024).
- [72] Tsendsuren Munkhdalai, Alessandro Sordani, Tong Wang, and Adam Trischler. “Metalearned neural memory”. In: *Advances in Neural Information Processing Systems* 32 (2019).
- [73] Tsendsuren Munkhdalai and Hong Yu. “Neural semantic encoders”. In: *Proceedings of the conference. Association for Computational Linguistics. Meeting*. Vol. 1. NIH Public Access. 2017, p. 397.
- [74] Eric Nguyen, Michael Poli, Marjan Faizi, Armin Thomas, Michael Wornow, Callum Birch-Sykes, Stefano Massaro, Aman Patel, Clayton Rabideau, Yoshua Bengio, et al. “Hyenadna: Long-range genomic sequence modeling at single nucleotide resolution”. In: *Advances in neural information processing systems* 36 (2024).
- [75] A Nichol. “On first-order meta-learning algorithms”. In: *arXiv preprint arXiv:1803.02999* (2018).
- [76] Yuqi Nie, Nam H Nguyen, Phanwadee Sinthong, and Jayant Kalagnanam. “A time series is worth 64 words: Long-term forecasting with transformers”. In: *arXiv preprint arXiv:2211.14730* (2022).
- [77] Hideyuki Okano, Tomoo Hirano, and Evan Balaban. “Learning and memory”. In: *Proceedings of the National Academy of Sciences* 97.23 (2000), pp. 12403–12404.
- [78] Antonio Orvieto, Samuel L Smith, Albert Gu, Anushan Fernando, Caglar Gulcehre, Razvan Pascanu, and Soham De. “Resurrecting recurrent neural networks for long sequences”. In: *International Conference on Machine Learning*. PMLR. 2023, pp. 26670–26698.
- [79] Denis Paperno, Germán Kruszewski, Angeliki Lazaridou, Ngoc Quan Pham, Raffaella Bernardi, Sandro Pezzelle, Marco Baroni, Gemma Boleda, and Raquel Fernández. “The LAMBADA dataset: Word prediction requiring a broad discourse context”. In: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. by Katrin Erk and Noah A. Smith. Berlin, Germany: Association for Computational Linguistics, Aug. 2016, pp. 1525–1534. DOI: 10.18653/v1/P16-1144. URL: <https://aclanthology.org/P16-1144/>.
- [80] Badri N. Patro and Vijay S. Agneeswaran. *SiMBA: Simplified Mamba-Based Architecture for Vision and Multivariate Time series*. 2024. arXiv: 2403.15360 [cs.CV].
- [81] Guilherme Penedo, Hynek Kydlicek, Loubna Ben allal, Anton Lozhkov, Margaret Mitchell, Colin Raffel, Leandro Von Werra, and Thomas Wolf. “The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale”. In: *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*. 2024. URL: <https://openreview.net/forum?id=n6SCkn2QaG>.
- [82] Bo Peng. *RWKV-LM*. Version 1.0.0. Aug. 2021. DOI: 10.5281/zenodo.5196577. URL: <https://github.com/BlinkDL/RWKV-LM>.

- [83] Bo Peng, Eric Alcaide, Quentin Gregory Anthony, Alon Albalak, Samuel Arcadinho, Stella Biderman, Huanqi Cao, Xin Cheng, Michael Nguyen Chung, Leon Derczynski, Xingjian Du, Matteo Grella, Kranthi Kiran GV, Xuzheng He, Haowen Hou, Przemyslaw Kazienko, Jan Kocon, Jiaming Kong, Bartłomiej Koptyra, Hayden Lau, Jiaju Lin, Krishna Sri Ipsit Mantri, Ferdinand Mom, Atsushi Saito, Guangyu Song, Xiangru Tang, Johan S. Wind, Stanisław Woźniak, Zhenyuan Zhang, Qinghua Zhou, Jian Zhu, and Rui-Jie Zhu. “RWKV: Reinventing RNNs for the Transformer Era”. In: *The 2023 Conference on Empirical Methods in Natural Language Processing*. 2023. URL: <https://openreview.net/forum?id=7SaXczaBpG>.
- [84] Bo Peng, Daniel Goldstein, Quentin Anthony, Alon Albalak, Eric Alcaide, Stella Biderman, Eugene Cheah, Xingjian Du, Teddy Ferdinan, Haowen Hou, et al. “Eagle and finch: Rwkv with matrix-valued states and dynamic recurrence”. In: *arXiv preprint arXiv:2404.05892* (2024).
- [85] DL Prados and SC Kak. “Neural network capacity using delta rule”. In: *Electronics Letters* 25.3 (1989), pp. 197–199.
- [86] Zhen Qin, Yiran Zhong, and Hui Deng. “Exploring Transformer Extrapolation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 38. 17. 2024, pp. 18897–18905.
- [87] Liliang Ren, Yang Liu, Yadong Lu, Yelong Shen, Chen Liang, and Weizhu Chen. “Samba: Simple Hybrid State Space Models for Efficient Unlimited Context Language Modeling”. In: *arXiv preprint arXiv:2406.07522* (2024).
- [88] Ivan Rodkin, Yuri Kuratov, Aydar Bulatov, and Mikhail Burtsev. “Associative recurrent memory transformer”. In: *arXiv preprint arXiv:2407.04841* (2024).
- [89] Aurko Roy, Mohammad Saffar, Ashish Vaswani, and David Grangier. “Efficient content-based sparse attention with routing transformers”. In: *Transactions of the Association for Computational Linguistics* 9 (2021), pp. 53–68.
- [90] Keisuke Sakaguchi, Ronan Le Bras, Chandra Bhagavatula, and Yejin Choi. “Winogrande: An adversarial winograd schema challenge at scale”. In: *Communications of the ACM* 64.9 (2021), pp. 99–106.
- [91] Maarten Sap, Hannah Rashkin, Derek Chen, Ronan Le Bras, and Yejin Choi. “Social IQa: Commonsense Reasoning about Social Interactions”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Ed. by Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan. Hong Kong, China: Association for Computational Linguistics, Nov. 2019, pp. 4463–4473. DOI: 10.18653/v1/D19-1454. URL: <https://aclanthology.org/D19-1454/>.
- [92] Imanol Schlag, Kazuki Irie, and Jürgen Schmidhuber. “Linear transformers are secretly fast weight programmers”. In: *International Conference on Machine Learning*. PMLR. 2021, pp. 9355–9366.
- [93] JH Schmidhuber. “Learning to control fast-weight memories: An alternative to recurrent nets. Accepted for publication in”. In: *Neural Computation* (1992).
- [94] Jürgen Schmidhuber. “Reducing the ratio between learning complexity and number of time varying variables in fully recurrent nets”. In: *ICANN’93: Proceedings of the International Conference on Artificial Neural Networks Amsterdam, The Netherlands 13–16 September 1993* 3. Springer. 1993, pp. 460–463.
- [95] Jürgen Schmidhuber and Sepp Hochreiter. “Long Short-term Memory”. In: *Neural Computation MIT-Press* (1997).
- [96] Avi Schwarzschild, Zhili Feng, Pratyush Maini, Zachary C Lipton, and J Zico Kolter. “Rethinking llm memorization through the lens of adversarial compression”. In: *arXiv preprint arXiv:2404.15146* (2024).
- [97] Jimmy T.H. Smith, Andrew Warrington, and Scott Linderman. “Simplified State Space Layers for Sequence Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=Ai8Hw3AXqks>.
- [98] Robin Staab, Mark Vero, Mislav Balunovic, and Martin Vechev. “Beyond Memorization: Violating Privacy via Inference with Large Language Models”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=kmn0BhQk7p>.
- [99] Sainbayar Sukhbaatar, Edouard Grave, Guillaume Lample, Herve Jegou, and Armand Joulin. “Augmenting self-attention with persistent memory”. In: *arXiv preprint arXiv:1907.01470* (2019).
- [100] Sainbayar Sukhbaatar, Jason Weston, Rob Fergus, et al. “End-to-end memory networks”. In: *Advances in neural information processing systems* 28 (2015).
- [101] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. “Learning to (learn at test time): Rnns with expressive hidden states”. In: *arXiv preprint arXiv:2407.04620* (2024).
- [102] Yutao Sun, Li Dong, Shaohan Huang, Shuming Ma, Yuqing Xia, Jilong Xue, Jianyong Wang, and Furu Wei. “Retentive network: A successor to transformer for large language models”. In: *arXiv preprint arXiv:2307.08621* (2023).
- [103] Gemma Team, Thomas Mesnard, Cassidy Hardin, Robert Dadashi, Surya Bhupatiraju, Shreya Pathak, Laurent Sifre, Morgane Rivière, Mihir Sanjay Kale, Juliette Love, et al. “Gemma: Open models based on gemini research and technology”. In: *arXiv preprint arXiv:2403.08295* (2024).

- [104] W Scott Terry. *Learning and memory: Basic principles, processes, and procedures*. Routledge, 2017.
- [105] Matteo Tiezzi, Michele Casoni, Alessandro Betti, Tommaso Guidi, Marco Gori, and Stefano Melacci. “On the resurgence of recurrent models for long sequences: Survey and research opportunities in the transformer era”. In: *arXiv preprint arXiv:2402.08132* (2024).
- [106] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. “Llama: Open and efficient foundation language models”. In: *arXiv preprint arXiv:2302.13971* (2023).
- [107] Jos Van Der Westhuizen and Joan Lasenby. “The unreasonable effectiveness of the forget gate”. In: *arXiv preprint arXiv:1804.04849* (2018).
- [108] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. “Attention is All you Need”. In: *Advances in Neural Information Processing Systems*. Ed. by I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett. Vol. 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.
- [109] Shida Wang. “LongSSM: On the Length Extension of State-space Models in Language Modelling”. In: *arXiv preprint arXiv:2406.02080* (2024).
- [110] Yu Wang, Yifan Gao, Xiusi Chen, Haoming Jiang, Shiyang Li, Jingfeng Yang, Qingyu Yin, Zheng Li, Xian Li, Bing Yin, Jingbo Shang, and Julian McAuley. “MEMORYLLM: Towards Self-Updatable Large Language Models”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=p0lKWzdikQ>.
- [111] Yu Wang, Chi Han, Tongtong Wu, Xiaoxin He, Wangchunshu Zhou, Nafis Sadeq, Xiusi Chen, Zexue He, Wei Wang, Gholamreza Haffari, et al. “Towards LifeSpan Cognitive Systems”. In: *arXiv preprint arXiv:2409.13265* (2024).
- [112] Zhiwei Wang, Yao Ma, Zitao Liu, and Jiliang Tang. “R-transformer: Recurrent neural network enhanced transformer”. In: *arXiv preprint arXiv:1907.05572* (2019).
- [113] Jason Weston, Sumit Chopra, and Antoine Bordes. “Memory networks”. In: *arXiv preprint arXiv:1410.3916* (2014).
- [114] Bernard Widrow and Marcian E Hoff. “Adaptive switching circuits”. In: *Neurocomputing: foundations of research*. 1988, pp. 123–134.
- [115] Ronald J Williams and David Zipser. “A learning algorithm for continually running fully recurrent neural networks”. In: *Neural computation* 1.2 (1989), pp. 270–280.
- [116] Daniel B Willingham. “Systems of memory in the human brain”. In: *Neuron* 18.1 (1997), pp. 5–8.
- [117] Chao-Yuan Wu, Christoph Feichtenhofer, Haoqi Fan, Kaiming He, Philipp Krahenbuhl, and Ross Girshick. “Long-term feature banks for detailed video understanding”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2019, pp. 284–293.
- [118] Haixu Wu, Tengge Hu, Yong Liu, Hang Zhou, Jianmin Wang, and Mingsheng Long. “TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=ju_Uqw3840q.
- [119] Qingyang Wu, Zhenzhong Lan, Kun Qian, Jing Gu, Alborz Geramifard, and Zhou Yu. “Memformer: A memory-augmented transformer for sequence modeling”. In: *arXiv preprint arXiv:2010.06891* (2020).
- [120] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. “Efficient Streaming Language Models with Attention Sinks”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=NG7sS51zVF>.
- [121] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. “Qwen2. 5 Technical Report”. In: *arXiv preprint arXiv:2412.15115* (2024).
- [122] Songlin Yang, Jan Kautz, and Ali Hatamizadeh. “Gated Delta Networks: Improving Mamba2 with Delta Rule”. In: *arXiv preprint arXiv:2412.06464* (2024).
- [123] Songlin Yang, Bailin Wang, Yikang Shen, Rameswar Panda, and Yoon Kim. “Gated Linear Attention Transformers with Hardware-Efficient Training”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=ia5XvxFUJT>.
- [124] Songlin Yang, Bailin Wang, Yu Zhang, Yikang Shen, and Yoon Kim. “Parallelizing Linear Transformers with the Delta Rule over Sequence Length”. In: *The Thirty-eighth Annual Conference on Neural Information Processing Systems*. 2024. URL: <https://openreview.net/forum?id=y8Rm4VNRPH>.
- [125] Luca Zancato, Arjun Seshadri, Yonatan Dukler, Aditya Golatkar, Yantao Shen, Benjamin Bowman, Matthew Trager, Alessandro Achille, and Stefano Soatto. “B’MOJO: Hybrid State Space Realizations of Foundation Models with Eidetic and Fading Memory”. In: *The Thirty-eighth Annual Conference on Neural Information Processing Systems*. 2024. URL: <https://openreview.net/forum?id=RnQdRY1h5v>.

- [126] Rowan Zellers, Ari Holtzman, Yonatan Bisk, Ali Farhadi, and Yejin Choi. “HellaSwag: Can a Machine Really Finish Your Sentence?” In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Ed. by Anna Korhonen, David Traum, and Lluís Màrquez. Florence, Italy: Association for Computational Linguistics, July 2019, pp. 4791–4800. doi: 10.18653/v1/P19-1472. URL: <https://aclanthology.org/P19-1472/>.
- [127] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. “Are transformers effective for time series forecasting?” In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 37. 2023, pp. 11121–11128.
- [128] Hao Zhang, Alexander C Berg, Michael Maire, and Jitendra Malik. “SVM-KNN: Discriminative nearest neighbor classification for visual category recognition”. In: *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’06)*. Vol. 2. IEEE. 2006, pp. 2126–2136.
- [129] Jianyu Zhang, Niklas Nolte, Ranajoy Sadhukhan, Beidi Chen, and Léon Bottou. “Memory Mosaics”. In: *arXiv preprint arXiv:2405.06394* (2024).
- [130] Yunhao Zhang and Junchi Yan. “Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting”. In: *The eleventh international conference on learning representations*. 2023.
- [131] Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, and Wancai Zhang. “Informer: Beyond efficient transformer for long sequence time-series forecasting”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 35. 12. 2021, pp. 11106–11115.
- [132] Luisa Zintgraf, Kyriacos Shiarli, Vitaly Kurin, Katja Hofmann, and Shimon Whiteson. “Fast context adaptation via meta-learning”. In: *International Conference on Machine Learning*. PMLR. 2019, pp. 7693–7702.

A 相关工作

存在多种视角可以独立地促成泰坦（Titans）或其组件的设计。因此，为了进一步将我们的工作置于更广泛的背景中，我们回顾三类研究：

A.1 线性循环模型

近年来，为了解决变换器（Transformers）在训练和推理中的计算成本问题，线性循环模型因其快速的推理和训练而备受关注（Tiezzi 等人，2024）。第一代模型——如 RetNet（Yutao Sun 等人，2023）、LRU（Orvieto 等人，2023）、RWKV（Peng, Alcaide 等人，2023）、S5（J. T. Smith, Warrington 和 Linderman，2023）以及 S4（Gu, Goel 和 Re，2022）——使用数据无关的转移矩阵/衰减机制。第二代此类模型开始将门控机制——传统循环神经网络（RNN）中广泛使用的技术（Gers, Jürgen Schmidhuber 和 Cummins，2000；Greff 等人，2016；Van Der Westhuizen 和 Lasenby，2018）——引入到此类线性架构中，例如 Griffin（De 等人，2024）、SSMs（Behrouz, Santacatterina 和 Zabih，2024；Dao 和 Gu，2024；Gu 和 Dao，2024；Hasani 等人，2023）、RWKV6（Peng, Goldstein 等人，2024）。第三代线性循环模型基于更复杂的记忆更新规则，这些规则基于元学习、在线学习和/或 delta 规则，从而产生了更具表达力和有效性的模型，例如：Longhorn（B. Liu 等人，2024）、Gated DeltaNet（S. Yang, Kautz 和 Hatamizadeh，2024）、TTT（Yu Sun 等人，2024）以及 DeltaNet（S. Yang, B. Wang, Yu Zhang 等人，2024）。我们的 LMM 模型可视为此类模型的下一代，其中我们将令牌流纳入记忆更新机制，从而拥有更强大的记忆更新过程。有关不同循环模型和泰坦的详细讨论，请参见附录 C。

A.2 基于变换器的架构

变换器。变换器（Transformers）（Vaswani 等人，2017）作为众多深度学习模型的事实骨干，基于注意力机制（Bahdanau，2014）。然而，它们面临二次计算成本，限制了其扩展到长上下文窗口的能力。为了改善较长序列下 Softmax 注意力的内存消耗和吞吐量，各类研究聚焦于注意力的输入输出感知实现（Dao，2024；Dao, D. Fu 等人，2022），通过稀疏化注意力矩阵设计更高效的注意力机制（B. Chen 等人，2021；Choromanski 等人，2021；Dai 等人，2019；J. Dong 等人，2024；Roy 等人，2021），近似 Softmax（Arora 等人，2024），或开发基于核函数的（线性）注意力（Aksenov 等人，2024；Kacham, Mirrokni 和 P. Zhong，2024；Schlag, Irie 和 Jürgen Schmidhuber，2021；S. Yang, B. Wang, Shen 等人，2024）。

基于分段的变换器。提升变换器效率的另一研究方向是基于分段或分块的变换器（Dai 等人，2019）。分块变换器的主要缺点是各分段完全分离，因此上下文窗口受限于块的长度。为解决这一问题，多项研究讨论了记忆的重要性，以便帮助模型跨块传递信息（Bulatov, Yuri Kuratov 等人，2023；Bulatov, Yury Kuratov 和 Burtsev，2022；Feng 等人，2022；Hutchins 等人，2022；Rodkin 等人，2024；Z. Wang 等人，2019；Q. Wu 等人，2020；Zancato 等人，2024）。泰坦（Titans）与这些模型的关键区别在于：（1）此类模型中的记忆是简单的小尺寸向量，缺乏压缩复杂信息的表达能力；（2）记忆模块缺少遗忘机制，导致记忆快速溢出；（3）仅关注瞬时惊讶，忽略了信息流动。更具体地说，回顾循环记忆变换器（RMT）（Bulatov, Yuri Kuratov 等人，2023；Bulatov, Yury Kuratov 和 Burtsev，2022；Rodkin 等人，2024），可以将泰坦（MAC）视为 RMT 的泛化，其中我们使用神经记忆模块而非向量值的小尺寸记忆。

大语言模型的记忆。另一个有趣的研究方向是在训练后为大型语言模型（LLM）引入外部记忆模块（Z. He 等，2024；Khandelwal 等，2020；Y. Wang, Y. Gao 等，2024）。这类模型与本文方法不同，因为本文将记忆作为初始架构的一部分，并以端到端方式进行训练。此外，大多数此类显式记忆模块与基于分块的变换器（Transformer）存在相同的局限性（如前所述）。关于此类模型的详细讨论，可参考 Y. Wang, Han 等（2024）的最新研究。

A.3 测试时训练与快速权重程序

记忆设计与记忆增强。在文献中，大量研究工作致力于设计能够记忆知识抽象（例如持久记忆）的记忆模块（Sukhbaatar, Grave 等，2019），或通过循环（Bulatov, Yury Kuratov 和 Burtsev 2022; Rodkin 等，2024; Zancato 等，2024）、变换器（Berges 等，2024; Cetin 等，2024; Feng 等，2022; Le, Tran 和 Venkatesh 2020; Munkhdalai, Faruqui 和 Gopal 2024; J. Zhang 等，2024）、梯度（Irie, Csordás 和 Jürgen Schmidhuber 2022; Munkhdalai, Sordoni 等，2019）或其他学习范式（Sukhbaatar, Weston, Fergus 等，2015; Weston, Chopra 和 Bordes 2014）来记忆数据相关信息（也称为上下文记忆）。然而，这些记忆模型要么（1）基于瞬时惊讶，忽略了数据流和事件；（2）缺乏遗忘机制来移除记忆，导致记忆快速溢出；（3）是固定大小的浅层（矩阵值）记忆，在长上下文中性能较差；（4）在测试时基于固定参数，缺乏测试时自适应。

快速权重程序。将线性层视为键值（关联）记忆系统的思想可追溯至快速权重程序，其中动态快速程序被整合到循环神经网络中，充当可写记忆（Schlag, Irie 和 Jürgen Schmidhuber，2021 年; JH Schmidhuber，1992 年; Jürgen Schmidhuber，1993 年）。赫布（Hebb，2005 年）和德尔塔（Prados 和 Kak，1989 年）两种学习规则是快速权重程序最流行的学习规则，已在多项研究中得到广泛探索（Irie, Schlag 等人，2021 年; Munkhdalai, Sordoni 等人，2019 年; Munkhdalai 和 H. Yu，2017 年; Schlag, Irie 和 Jürgen Schmidhuber，2021 年; JH Schmidhuber，1992 年; S. Yang, Kautz 和 Hatamizadeh，2024 年; S. Yang, B. Wang, Yu Zhang 等人，2024 年）。然而，所有这些模型都基于瞬时惊讶，忽略了序列中的令牌流（见第 3.1 节），且大多数模型缺乏遗忘门，导致记忆管理不佳。

测试时训练。测试时学习或学会学习（即（Andrychowicz et al. 2016））的核心思想可追溯至关于局部学习的早期研究（Bottou and Vapnik 1992），其中每个测试数据样本在做出预测前会基于其邻居进行训练（Gandelsman et al. 2022; H. Zhang et al. 2006）。该方法进一步在视觉任务中展现出有前景的性能（Jain and Learned-Miller 2011; Mullapudi et al. 2019），主要归因于其缓解分布外样本的能力。在此方向上与本研究最相似的工作是 MNM（Munkhdalai, Sordoni, et al. 2019）和 TTT 层（Yu Sun et al. 2024），我们在附录 C 中讨论了关键差异。

B 语言建模与常识推理数据集

遵循近期关于线性循环模型的研究（Dao and Gu 2024; S. Yang, Kautz, and Hatamizadeh 2024; S. Yang, B. Wang, Yu Zhang, et al. 2024），我们使用 Wikitext（Merity et al. 2017）、LMB（Paperno et al. 2016）、PIQA（Bisk et al. 2020）、HellaSwag（Zellers et al. 2019）、WinoGrande（Sakaguchi et al. 2021）、ARC-easy（ARC-e）和 ARC-challenge（ARC-c）（P. Clark et al. 2018）、SIQA（Sap et al. 2019）以及 BoolQ（C. Clark et al. 2019）。此外，400M 模型的基线结果来自 S. Yang, Kautz, and Hatamizadeh（2024）报告的结果。

C 作为序列模型的长期记忆模块（LMM）

本节讨论作为序列模型的线性记忆模型（LMM）与现代线性循环模型的联系。为简化起见，从线性记忆开始，其中 $\mathcal{M}_t = W_t \in \mathbb{R}^{d_m \times d_m}$ 。此时目标函数变为 $\ell(\mathcal{M}; x_t) = \frac{1}{2} \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$ ，优化采用带动量和权重衰减的梯度下降。相应地，重新审视方程 13 中的循环公式：

$$\mathcal{M}_t = \text{diag}(1 - \alpha_t) \mathcal{M}_t + S_t \quad (32)$$

$$S_t = \text{diag}(\eta_t) S_{t-1} - \text{diag}(\theta_t) (\mathcal{M}_{t-1} \mathbf{k}_t^\top \mathbf{k}_t - \mathbf{v}_t^\top \mathbf{k}_t). \quad (33)$$

LMM 是广义门控 DeltaNet。如 S. Yang, Kautz 和 Hatamizadeh（2024）所述，DeltaNet（S. Yang, B. Wang, Yu Zhang 等，2024）可被解释为优化 $\mathcal{L} = \frac{1}{2} \|\mathbf{S}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$ 的在线学习问题，resulting in:

$$\mathbf{S}_{t+1} = \mathbf{S}_t - \theta_t \nabla \mathcal{L} = \mathbf{S}_t (\mathbf{I} - \theta_t \mathbf{k}_t \mathbf{k}_t^\top) + \theta_t \mathbf{v}_t \mathbf{k}_t^\top. \quad (34)$$

在此表述中，门控 DeltaNet 与上述相同，但增加了权重衰减项（S. Yang、Kautz 和 Hatamizadeh，2024）。比较方程 32 和方程 34，可见设置 $\eta_t = 0$ 时两种表述等价。因此，可以说 LMM 从三个方面推广了最新的门控 DeltaNet 研究（S. Yang、Kautz 和 Hatamizadeh，2024）：

- 基于动量的规则：Delta 规则基于瞬时惊讶，意味着令牌流不能影响记忆更新规则。而 LMM 基于动量规则，同时考虑过去和瞬时惊讶。

- 深度记忆：门控 DeltaNet 受限于线性（矩阵值）记忆，因为需要找到闭合循环形式；LMM 通过基于梯度的表述允许使用深度记忆模块，从而具有更高的表达能力。
- 非线性循环：DeltaNet 和门控 DeltaNet 基于线性循环，而 LMM 使用块间非线性循环和块内线性循环。这种设计使 LMM 具有更高的表达能力。

这里以门控 DeltaNet 作为新一代循环模型的示例进行了讨论。类似方法如 RWKV-7（Peng，2021）也采用相同的表述和损失函数，因此 LMM 推广了所有这些模型。

LMM 是广义 Longhorn。与 DeltaNet 类似，Longhorn（B. Liu 等人，2024）使用相同的损失函数，但通过隐式在线学习推导出闭式解：

$$\mathbf{S}_{t+1} = \mathbf{S}_t (\mathbf{I} - \delta_t \mathbf{k}_t \mathbf{k}_t^\top) + \delta_t \mathbf{v}_t \mathbf{k}_t^\top, \quad (35)$$

其中 $\delta_t = \theta_t \frac{1}{1 + \theta_t \mathbf{k}_t \mathbf{k}_t^\top}$ 。然而，它缺少遗忘门，导致记忆溢出更快。因此，除了上述（1）基于动量的规则、（2）深度记忆和（3）非线性递归之外，LMM 还具有使用额外（4）遗忘门的优势，从而实现更好的记忆管理。

LMM 是广义 TTT 层。据我们所知，TTT（Yu Sun 等人，2024）是唯一具有基于梯度的更新规则的现代线性递归模型。除了不同的架构设计和目标函数之外，我们的 LMM 与已提出的 TTT 层（Yu Sun 等人，2024）有三个关键区别：1. 遗忘机制：TTT 层在每个时间步更新记忆，没有机会遗忘过去的信息。因此，当固定记忆大小时，模型无法管理长序列的记忆。像 LMM 这样的遗忘机制允许在非常久远的信息不再需要时清除记忆。我们证明，在一般情况下，这种遗忘机制等价于权重衰减，并提供了一种快速方法将其融入并行训练。2. 基于动量的更新规则：TTT 层基于瞬时惊讶，这意味着令牌流不能影响记忆更新规则。然而，LMM 基于动量规则，同时考虑过去和瞬时的惊讶。该设计的动机见第 3.1 节。3. 深度记忆：虽然 TTT 层允许更深的记忆，但这种更深记忆模块的优势和劣势尚未经过实验评估。据我们所知，我们的神经长期记忆模块是第一个具有基于动量的更新规则的线性递归模型。最后，作为与上述所有模型以及其他近期线性递归研究的关键区别，请注意现代线性模型的混合变体——如 Griffin（De 等人，2024）、DeltaNet（S. Yang, B. Wang, Yu Zhang 等人，2024）、Gated DeltaNet（S. Yang, Kautz 和 Hatamizadeh，2024）、H3（D. Y. Fu 等人，2023）、Mamba2（Dao 和 Gu，2024）、Samba（Ren 等人，2024）等——都基于顺序的逐层设计。我们提出 Titans，以展示如何有效地将此记忆模块融入架构中。