

自动驾驶的测试时轨迹优化

Yihong Xu^{1,*} Éloi Zablocki^{1,*} Yuan Yin¹ Elias Ramzi¹ Ellington Kirby¹
Alexandre Boulch¹ Matthieu Cord^{1,2}

¹valeo.ai, Paris, France ²Sorbonne Université, CNRS, ISIR, F-75005 Paris, France

摘要：自动驾驶的端到端规划器通常生成一组候选轨迹，对每条轨迹进行评分，并返回评分最高的候选轨迹。然而，评分器仅在候选轨迹生成之后才被应用，无法影响轨迹集合：无论评分器的质量如何，较弱的候选集合都会限制规划性能。相反，我们将评分器视为学习到的轨迹级奖励函数，并搜索使其最大化的轨迹。我们的方法 TOAD 在测试时运行交叉熵方法，从规划器的候选轨迹热启动。它无需重新训练，并且对现有规划器即插即用。在六个基础规划器上，TOAD 在 NAVSIM-v1 (94.7 PDMS)、NAVSIM-v2 (56.3 EPDMS) 和闭环 HUGSIM 基准上均改善了结果。代码将通过项目页面公开提供。

关键词：自动驾驶，端到端规划，测试时优化

1 引言

端到端 (E2E) 规划已成为自动驾驶的主流方法 [1, 2, 3]。单个网络将传感器数据和自车状态直接映射为驾驶轨迹。几种最先进的方法共享一个通用流程。它们首先生成一组有限的候选轨迹，这些轨迹要么从大型预计算词汇表中抽取 [4, 5, 6, 7]，要么即时生成 [8, 9, 10]。然后，评分器从该集合中挑选最佳轨迹。

评分器是规划流程的核心。它经过训练以模仿驾驶质量的专家标准（安全性、进展、舒适性），因此可以被视为学习到的轨迹级奖励函数，一个可以被优化的目标。然而，当前的规划器仅使用它一次：生成是一次性的，评分器仅对固定的候选集合进行排序。如果每个候选轨迹都很差，规划器便无计可施，仍然返回较差集合中的最佳轨迹。我们认为这是一个错失的机会，并探讨评分器能否发挥更大作用：不仅仅是对固定集合进行一次排序，而是引导搜索以获得评分较高的轨迹。

我们提出 TOAD，一种测试时程序，将冻结的评分器转化为轨迹搜索的目标，且无需训练成本。具体而言，TOAD 将冻结的端到端规划器封装在基于交叉熵方法（Cross-Entropy Method, CEM）的推理时循环中 [11]。在每次迭代中，我们从高斯分布中采样轨迹，用冻结的评分器进行评分，将高斯分布重新拟合到前 k 个候选（“精英”），并重复此过程。搜索以规划器选择的轨迹作为热启动，并限制在其邻域内，从而限制搜索偏离评分器训练分布的程度。

一个关键发现是，并非所有训练好的评分器都能作为奖励。测试时搜索仅在评分器在其训练提议之外仍保持准确时才能成功，因为它探索了任何固定集合之外的轨迹。拟合到固定词汇表的评分器 [4, 5, 6, 7] 会失败：它们在自己的候选上准确，但在其他地方急剧退化，并且我们的循环使用它们时性能低于基线，尽管在标准排序评估下表现强劲。只有经过解耦训练的、能够评估自由解码轨迹。

Equal contribution

轨迹 [8] 的评分器才能在 TOAD 中工作。因此，测试时搜索暴露了标准评分器中排序评估无法揭示的隐藏弱点。

由于仅需要一个冻结的规划器和一个具有泛化能力的评分器，TOAD 是即插即用的。我们将一个冻结的评分器附加到六个基础规划器上，即 iPad [10]、Hydra-MDP [4]、GTRS [5]、ZTRS [6]、RAP [9] 和 DrivoR [8]，并在 NAVSIM-v1 [12] 上提高了所有六个规划器的 PDMS，在 NAVSIM-v2 [13] 上提高了 EPDMS。对于性能较低的规划器，增益最大，对于较强的规划器，增益最小（iPad 上+43.6%，DrivoR 上+3.1%），因为 TOAD 缩小了基础规划器与评分器最佳评分轨迹之间的差距。增益来自搜索本身，而非更强的评分器：仅用评分器对基础规划器的提议进行重新排序甚至可能损害性能，而 TOAD 则能提升性能。在 NAVSIM-v2 上，DrivoR + TOAD 达到了 56.3 EPDMS，这是一个新的最新技术水平，几乎与特权 PDM-Closed (56.6) [14] 持平。TOAD 还在逼真的闭环 HUGSIM 模拟器 [15] 上提高了 DrivoR 的零样本 HD-Score。代码将发布。

我们的贡献如下：

- 我们将端到端轨迹评分器重新定义为可优化的学习奖励函数，而不仅仅用于对一次性提议集进行排序。
- 我们提出 TOAD，一种测试时搜索方法，可插入任何基础规划器而无需重新训练。
- 本文表明，成功的优化需要一个能够超越其训练候选集进行泛化的评分器，这暴露了固定词汇表评分器的弱点。
- 在六个规划器上，TOAD 在 NAVSIM-v1 和 NAVSIM-v2 上均带来一致的提升，在 NAVSIM-v2 上达到新的最新技术水平，并在 HUGSIM 上改善了闭环性能，且成本可忽略不计。

2 相关工作

端到端驾驶与“评分-选择”方法。

端到端学习目前在自动驾驶领域占据主导地位。早期系统使用由手工设计模块组成的复杂流水线，用于检测、跟踪和建图 [16, 17]。近期方法则通过单一网络将传感器和自车状态映射为轨迹 [2, 18, 19]，通常舍弃三维监督和鸟瞰图表示 [20, 8]。进展通过开放环或伪闭环基准（如 NAVSIM-v1/v2 [12, 13]）以及模拟器（如 HUGSIM [15]）来衡量。

最强的端到端规划器共享一套方法：生成候选轨迹，对每条轨迹评分，并输出得分最高的轨迹 [4]。候选轨迹来自预计算轨迹的大型词汇表 [4, 5, 6]，或通过扩散或可学习查询等方式即时生成 [20, 21, 10, 9, 8]。无论哪种方式，评分器都经过训练以模仿驾驶质量预言机，并通过 argmax 选择轨迹。一个明显的趋势是通过不断加密的词汇表来扩大候选集 [22, 7]，这会增加运行时延迟 [8]，并常常使评分器过拟合于固定词汇表。此外，预言机研究表明，理想的选择可以超越人类驾驶员 [22]，这表明限制性能的往往是候选集而非评分器。一些评分器经过训练可以在词汇表之间迁移 [5]。然而，它们仍然对固定集合进行排序，这与在自由搜索的轨迹上保持准确性不同。本文转而探究训练后的评分器能否充当奖励函数，并在该集合之外搜索轨迹，从而进一步提升性能。

测试时优化与规划搜索。

基于采样的优化与模型预测控制在机器人与驾驶领域有着悠久的历史。无梯度采样器，如交叉熵方法 [11, 23, 24] 与模型预测路径积分控制 [25]，通常在模型预测控制框架内采样轨迹、评估代价，并重新拟合至低成本区域。经典的驾驶模型预测控制采用手工设计的代价函数；后续工作学习其中部分内容，例如从图像中学习代价图 [26]，或在可微规划器中学习代价权重 [27]。与我们工作相近的是，UniAD [2] 在推理阶段针对预测的占用图对其轨迹进行后优化。我们同样采用测试时搜索的思路，但优化的是完整的端到端学习评分器，且不预测任何中间表示，如未来占用图。




图 1: TOAD 概览。一个冻结的基础规划器输出轨迹提议和一个选定的锚点 τ_{base} (左)。轨迹通过逆自行车模型 (BM^{-1}) 映射为控制量。然后, 在控制空间中运行交叉熵方法 (CEM) 循环 K 步: 采样控制量, 用自行车模型 (BM) 展开它们, 在“评分器 + 正则”下评分 (学习到的奖励加上舒适性和锚点正则项), 将高斯分布重新拟合到得分最高的精英样本。评分器和 BM 保持冻结。

测试时训练调整模型本身而非轨迹。Centaur [28] 在测试时通过最小化其预测的不确定性度量来更新端到端规划器。我们是互补且更轻量的: 模型权重保持冻结, 我们仅搜索轨迹空间。

在固定模型上进行推理时搜索已在语言模型中带来巨大收益, 通过推理时推理 [29, 30] 和由验证器或奖励模型引导的搜索 [31]。这也出现在驾驶领域: 用视觉语言模型重新排序候选 [32] 或用学习到的世界模型在线评分 [33, 34]。我们同样在推理时搜索, 但在连续轨迹空间而非固定集合上, 使用单一学习评分器而非辅助模型。

学习到的评分器作为奖励将我们的设置与基于模型的强化学习联系起来, 其中学习到的奖励指导动作选择。几种驾驶方法在训练期间使用奖励: 规划器的强化学习微调 [35], 用于生成的强化扩散 [36], 以及用于驾驶风格的 RLHF [37]。我们则在推理时纯粹使用一个冻结的、已训练好的评分器作为搜索目标, 没有策略学习, 也不改变生成器。

3 方法

我们提出了 TOAD, 如图 1 所示, 这是一种基于评分器的方法, 在测试时增强由任意规划器生成的轨迹。我们在第 3.1 节介绍评分器, 然后在第 3.2 节详细说明优化算法及其设计选择。

3.1 评分器作为奖励函数

我们的方法使用评分器 S 作为轨迹上的奖励函数。轨迹 $\tau = (p_1, \dots, p_{n_p})$ 是 a 是自行车坐标系中未来位姿 $p_t = (x_t, y_t, \theta_t) \in \mathbb{R}^3$ 的序列 n_p 。以观测 o (传感器输入和自车状态) 和目标 g (目标点或路线) 为条件, 评分器将完整轨迹映射为标量, $S(\tau; o, g) \in \mathbb{R}$ 。 S 是与基础规划器联合训练的神经网络。我们将 S as a 视为轨迹空间上的奖励函数, 并将轨迹空间视为动作空间。这使得能够搜索奖励最大的轨迹, 而不是对固定候选集进行排序。

3.2 测试时轨迹搜索

我们使用交叉熵方法 (CEM) [11] 来实例化此搜索, 这是一种经典的基于采样的优化器。为了将搜索限制在评分器可靠的区域, 我们将其限制在基础规划器建议周围的信任区域内 (图 1, 左)。以下段落描述并论证了每个设计选择; 我们在第 5 节中分别对它们进行了消融研究。

在控制空间中优化。对于基于采样的搜索，搜索空间的选择并不明显。直接在位姿空间中采样会产生锯齿状、动态不可行的轨迹，因为它完全忽略了车辆动力学。我们改为通过运动学自行车模型 (BM) 注入此先验，并在控制序列上进行搜索，

$$u = (u_t)_{t=1}^{n_p}, \quad u_t = (a_t, \omega_t) \in \mathbb{R}^2, \quad (1)$$

其中 a_t 和 ω_t 是每步的纵向加速度和横摆角速度。我们的 BM 是可逆的，因此控制和轨迹是等价的表示。从控制序列 u 出发，我们在当前自行车速度 v_0 下展开轨迹为 $\tau = \text{BM}(u, v_0)$ ，并通过逆运动学恢复控制， $u = \text{BM}^{-1}(\tau, v_0)$ ，两者均在图 1 中说明。这种方法在基于采样的控制 [25, 23] 和轨迹优化 [38, 39] 中是标准的，并且免费获得两个特性：每个样本都是平滑且可行的，并且舒适性（定义在加速度（控制量）和加加速度（其导数）上）可以直接从 u 计算。

基于规划器的信任区域。原则上，交叉熵方法 (CEM) 可以从任意初始化运行（消融实验见图 4a）。我们反而刻意将搜索限制在围绕基础轨迹提议的小信任区域内，该提议以观测 o 和导航目标 g 为条件，因为第 3.1 节学习的评分器在附近更可靠。在此区域之外，搜索可能漂移到评分器给出高分但无法真正判断的轨迹，这可能导致奖励黑客行为。

形式上，我们假设可以访问一个训练好的基础规划器，它将观测 o 和目标 g 映射到一组 N 条候选轨迹以及一条选定的轨迹，

$$\text{BASEPLANNER}(o, g) = (\mathcal{T}, \tau_{\text{base}}), \quad \tau_{\text{base}} \in \mathcal{T} = \{\tau^{(i)}\}_{i=1}^N. \quad (2)$$

该表述涵盖了现有规划器，包括单候选规划器，其中 $\mathcal{T} = \{\tau_{\text{base}}\}$ 。给定自行车速度 v_0 ，这些轨迹等价地映射到控制序列， $\mathcal{U} = \{u^{(i)} = \text{BM}^{-1}(\tau^{(i)}, v_0)\}_{i=1}^N$ ，其中选定的一条为 u_{base} 。我们使用这些来定义信任区域，以 u_{base} 为锚点，而 $\mathcal{U}$ 的散布程度决定其范围。

TOAD：带信任区域先验的交叉熵方法。在 TOAD 中，信任区域先验同时塑造了交叉熵方法的代价函数及其初始化。交叉熵方法最大化 $J(u)$ ，该目标结合了 S 和两个闭式正则化项：

$$J(u) = S(\text{BM}(u, v_0); o, g) - \lambda_a C_{\text{anchor}}(u) - \lambda_c C_{\text{comf}}(u). \quad (3)$$

第一个正则化项 $C_{\text{anchor}}(u) = \|u - u_{\text{base}}\|^2$ 通过惩罚与锚点的偏差将搜索与信任区域联系起来。第二个正则化项 C_{comf} 累积标准运动学舒适性限制（纵向和横向加速度、加加速度、横摆角速度和横摆角加速度）的平方违反量；由于是精确且闭式的，它提供了学习评分器只能粗略估计的信号。我们在未来控制和最后执行的控制上评估 C_{comf} ，惩罚车辆近期运动中的不舒适过渡。

为了启动搜索，交叉熵方法的均值被设置为锚点 $\mu_0 = u_{\text{base}}$ ；标准差从基础规划器自身提议的散布程度开始， $\sigma_0 = \max(\beta \cdot \text{std}(\mathcal{U}), \epsilon)$ ，其中 $\beta < 1$ 和一个小的下限 ϵ 防止探索完全崩溃。因此，探索依赖于规划器自身的不确定性。我们在控制量上运行交叉熵方法，使用高斯分布 $\mathcal{N}(\mu_k, \text{diag}(\sigma_k^2))$ ，在 $\mathbb{R}^{2n_p}$ 中。在第 $k = 1, \dots, K$ 次迭代时，我们抽取 M 条控制序列，将其展开，评估 J ，并保留得分最高的 E 条序列作为精英集 $\mathcal{E}_k$ 。然后，我们根据精英集重新拟合高斯分布： $\mu_k = \text{均值}(\mathcal{E}_k)$ ， $\sigma_k = \text{std}(\mathcal{E}_k)$ 。

在最终迭代之后，我们按照交叉熵方法 (CEM) 标准展开由收敛均值所诱导的轨迹。我们返回该轨迹 $\tau_{\text{mean}} = \text{BM}(\mu_K, v_0)$ 迹与基础提案 τ_{base} 中使代价更大的那一个。

$$\tau^* = \arg \max_{\tau \in \{\tau_{\text{mean}}, \tau_{\text{base}}\}} S(\tau; o, g) - \lambda_c C_{\text{comf}}(\text{BM}^{-1}(\tau, v_0)). \quad (4)$$

此处排除 C_{anchor} ：交叉熵方法均值不应因偏离锚点而受到惩罚。

与 τ_{base} 进行比较可保证返回的轨迹代价不低于 τ_{base} 。

评分器选择。交叉熵方法要求评分器在基础规划器的提案分布之外仍保持准确，因此 TOAD 采用 DrivoR 的解耦评分器 [8]。我们强调本设置的一个特性：同一评分器服务于所有基础规划器，且无需是规划器自身的评分器。

表 1: NAVSIM-v1。与现有仅摄像头方法在 (navtest) 上的比较。分数越高越好。完整比较见表 5。

Method	PDMS (↑)
PDM-Closed [14]	89.1
Human driver [12]	94.8
ZTRS (V2-99) [6]	86.9
+ TOAD	89.0 (↑2.4%)
GTRS (V2-99) [5]	90.4
+ TOAD	90.9 (↑0.6%)
Hydra-MDP [4]	90.9
+ TOAD	91.4 (↑0.6%)
iPad [10]	91.7
+ TOAD	93.4 (↑1.9%)
RAP-DINO [9]	93.8
+ TOAD	93.9 (↑0.1%)
DrivoR [8]	94.6
+ TOAD	94.7 (↑0.1%)

表 2: NAVSIM-v2 navhard-two-stage。使用 EPDMS [13] 在 NAVSIM-v2 基准测试集上与现有方法的比较。完整比较见表 6。

Method	EPDMS (↑)
PDM-Closed [14]	56.6
iPad [10]	34.7
+ TOAD	49.8 (↑43.6%)
RAP-DINO [9]	39.6
+ TOAD	49.0 (↑23.9%)
Hydra-MDP [4]	40.9
+ TOAD	49.7 (↑21.6%)
GTRS [5]	45.4
+ TOAD	51.7 (↑13.8%)
ZTRS [6]	48.1
+ TOAD	49.2 (↑ 2.3%)
DrivoR [8]	54.6
+ TOAD	56.3 (↑ 3.1%)

表 3: 增益来源是什么？在 iPad [10] 和 Hydra-MDP [4] 之上，我们将 TOAD 与 (i) 轨迹平滑，(ii) 重新评分，以及 (iii) 使用不同评分器作为奖励进行比较。

Method	EPDMS (↑)
iPad [10]	34.7
+ Smoothing (BM)	35.0 (↑ 0.8%)
+ Re-scoring w/ DrivoR	45.6 (↑31.5%)
+ Re-scoring w/ GTRS	34.5 (↓ 0.6%)
+ Re-scoring w/ SparseDriveV2	30.3 (↓12.5%)
+ Search w/ GTRS scorer	23.9 (↓31.1%)
+ Search w/ SparseDriveV2 scorer	34.6 (↓ 0.4%)
+ TOAD (search w/ DrivoR scorer)	49.8 (↑43.6%)
Hydra-MDP [4]	40.9
+ Smoothing (BM)	38.8 (↓ 5.1%)
+ Re-scoring w/ DrivoR	37.3 (↓ 8.8%)
+ Re-scoring w/ GTRS	40.3 (↓ 1.5%)
+ Re-scoring w/ SparseDriveV2	9.5 (↓76.9%)
+ Search w/ GTRS scorer	38.1 (↓ 6.9%)
+ Search w/ SparseDriveV2 scorer	29.6 (↓27.7%)
+ TOAD (search w/ DrivoR scorer)	49.7 (↑21.6%)

4 实验结果

我们在标准驾驶基准上评估了测试时搜索方法。TOAD 在 NAVSIM-v1/2 上持续改进了多种基础规划器，并在 NAVSIM-v2 上达到了新的最新技术水平。它还在闭环 HUGSIM 基准上优于 DrivoR (第 4.2 节)。随后我们证明 TOAD 需要一个独立于轨迹头的评分器 (第 4.3 节)。最后，我们分离了性能提升的来源，并对设计选择进行了消融研究 (第 5 节)。我们的代码将开源。

4.1 实验设置

基准与度量。我们在 NAVSIM-v1 [12] (navtest 划分) 和 NAVSIM-v2 [13] (navhard-two-stage 划分) 上进行评估，这两个基准基于真实驾驶日志构建，属于伪闭环基准。我们还在 HUGSIM [15] 上进行评估，这是一个使用三维高斯泼溅 (3D Gaussian Splatting) [40] 构建的具有逼真场景的闭环评估基准。对于消融研究，我们使用 warmup-two-stage * 作为 NAVSIM-v2 的验证集，包含 7 个场景。度量详见附录 A。

基础规划器。我们通过六种基础规划器上评估 TOAD 来证明其即插即用特性，这些规划器涵盖了两种提议风格，即固定词汇评分器 (Hydra-MDP [4]、GTRS [5]、ZTRS [6]) 和即时生成器 (iPad [10]、RAP [9]、DrivoR [8])。对于每种规划器，我们使用公开检查点及其发布的轨迹提议；不更新任何模型。

超参数。除非另有说明，我们对具有即时生成器的规划器运行 $K = 5$ 次交叉熵方法 (CEM) 迭代，对具有固定词汇评分器的规划器运行 $K = 100$ 次迭代，因为其词汇量更大 ($> 8K$)，用于初始化搜索。考虑到搜索推理成本，每次迭代的候选数量 M 固定为 64，精英数量固定为 $E = M/8$ 。我们使用初始标准差尺度 $\beta = 0.5$ ，下限为 $\epsilon_a = 0.1 \text{ m/s}^2$ 和 $\epsilon_\omega = 0.025$ 弧度/s。目标函数使用舒适度权重 $\lambda_c = 0.05$ 和锚点权重 $\lambda_a = 0.5$ 。以上所有值在所有基础规划器和基准测试中保持不变；消融实验在第 5 节中进行。

4.2 主要结果

NAVSIM-v2 [13] 和 NAVSIM-v1 [12]。表 1 和表 2 报告了 NAVSIM-v1 导航测试和 NAVSIM-v2 导航困难两阶段结果。TOAD 在两个基准测试上均提升了每个基础规划器的性能。在 NAVSIM-v2 上，提升幅度从 +2.3% (ZTRS) 到 +43.6% (iPad) 不等，并且压缩了排名：六个规划器最初相差近 20 个 EPDMS 点 (34.7 到 54.6)，但搜索后均落在 49.0 * 预热两阶段与导航困难两阶段相交，经请求，基准测试作者验证了其作为验证集的使用。

表 4: HUGSIM [15] 零样本得分。TOAD 提升了安全性 (NC、DAC、TTC) 和舒适度, 提高了 HD-Score, 而路线完成率 (RC) 有时下降, 表明驾驶更加谨慎。

		KITTI360 [42]						nuScenes [43]						Pandaset [44]						Waymo [45]					
		NC	DAC	TTC	Conf.	RC	HDS	NC	DAC	TTC	Conf.	RC	HDS	NC	DAC	TTC	Conf.	RC	HDS	NC	DAC	TTC	Conf.	RC	HDS
LTF	[46]	32.4	86.4	25.1	97.3	19.4	8.0	56.1	99.7	49.8	95.4	50.1	35.1	44.7	100.0	36.2	92.1	51.3	28.2	49.1	93.9	42.1	95.4	38.3	23.8
UniAD	[2]	48.1	85.1	19.8	37.2	23.5	5.9	71.8	99.2	63.3	79.3	49.1	37.5	68.2	100.0	58.1	77.3	49.5	36.7	76.9	94.3	66.3	71.3	56.2	44.4
VAD	[18]	24.4	83.2	15.0	94.2	17.1	3.9	57.2	97.6	42.9	97.4	43.1	24.5	42.4	100.0	26.5	94.9	38.7	15.4	46.6	85.5	32.6	94.9	29.4	11.0
GTRS-D	[5]	47.9	90.4	43.1	94.4	29.5	19.5	71.3	99.8	64.8	96.0	59.3	47.4	55.7	99.9	48.0	91.6	56.0	37.2	65.5	96.4	61.0	95.1	52.5	41.0
DrivoR	[8]	44.0	89.9	40.8	93.6	28.8	17.7	57.0	100.0	51.3	93.0	54.2	39.7	50.8	99.9	44.0	89.8	58.3	35.1	64.0	96.8	58.6	94.1	56.5	44.2
DrivoR + TOAD		49.5	90.9	46.1	99.1	26.9	18.4	69.1	100.0	63.9	98.3	60.9	49.9	57.3	100.0	51.6	98.4	54.5	38.0	70.3	96.7	66.6	97.9	51.1	42.8

搜索后达到 56.3。最弱的规划器提升最大, 而 DrivoR 已经是最强的, 提升+3.1% 达到 56.3 EPDMS, 超过了最强的学习方法 (DriveFuture [41], 见表 6, 55.5), 仅比使用真实感知的特权 PDM-Closed (56.6) 低 0.3。完整的基准测试表见表 5 和表 6。

搜索使用任何有提升空间的子分数。在更困难的、分布外的 NAVSIM-v2 场景中, 它用少量进度换取无碰撞、可行驶区域和碰撞时间方面的大幅安全提升, 见表 6。在接近饱和的 NAVSIM-v1 上, 安全性已经很高, 它反而扩展了进度。同样, 最弱的规划器提升最大 (ZTRS +2.4%, iPad +1.9%), 最强的提升最小, DrivoR 达到 94.7 PDMS, 为最高条目, 比人类驾驶员低 0.1。

HUGSIM [15]。表 4 报告了零样本闭环评估结果, 将 TOAD 应用于 DrivoR 之上。安全性子度量 (无碰撞、可行驶区域、碰撞时间) 以及最为重要的舒适性在几乎所有四个数据集上均有所提升, 舒适性增益是控制空间搜索的直接效果。这些增益在有提升空间的地方提高了 HUGSIM 驾驶得分 (HDS), 在 nuScenes (DrivoR: 39.7 提升至 49.9) 和 KITTI360 上最为明显。路线完成率趋于下降, 表明搜索得到的策略驾驶更为谨慎, 而在 Waymo 上这种谨慎导致得分略低。改进无需调参即可迁移至闭环模拟器, 表明其反映了真正更安全的驾驶。

定性结果。图 2a 显示, 优化后的轨迹成功避免了与前方车辆的碰撞。利用 TOAD, 我们生成了原始轨迹集中不存在的一条更优轨迹。与图 4c 中的观察一致, 奖励并非总是精确, 偶尔会失效。此类失效可能发生在视觉线索因能见度有限而不可靠的情况下, 如图 2b 所示。




图 2: TOAD 在 DrivoR [8] 基础上发现的改进与失败的可视化示例。

4.3 收益需要搜索与具备泛化能力的评分器

两个因素解释了 TOAD 的增益: 它们来自搜索发现的新轨迹, 而非对现有轨迹的重新排序或平滑, 并且它们仅在评分器在分布外仍保持准确时出现

建议分布。我们在表 3 中验证了这两点，使用了两个基础规划器 iPad [10] 和 Hydra-MDP [4] 在 navhard-two-stage 上。详细的性能分解可见表 7。

搜索与重排序及平滑处理。 我们将 TOAD 与基础规划器的两种更简单修改进行了对比。平滑处理 (BM) 通过自行车模型映射所选轨迹以消除抖动，而不改变其路线；它几乎没有效果 (iPad +0.8%，Hydra-MDP -5.1%)，表明增益来自更好的轨迹，如图 2 所示。重新评分使用评分器对原始提议进行重新排序，而不生成新轨迹。当像 TOAD 中那样使用 DrivoR 的评分器时，重新排序表现不一致：它改善了 iPad (+31.5%)，但损害了 Hydra-MDP (-8.8%)。相比之下，TOAD 一致地提高了性能 (+43.6% 和 +21.6%)。因此，增益来自搜索在提议集之外发现更好的轨迹，而不是来自对现有轨迹的重新排序或平滑。

评分器必须具有泛化能力。 我们还使用不同的评分器作为奖励来运行搜索。只有 DrivoR 评分器 [8] 提高了性能；GTRS[5] 和 SparseDriveV2[7] 将其降低到基线以下（例如，使用 GTRS 时 iPad 降至 23.9）。我们将此归因于它们的训练设置。GTRS 和 SparseDriveV2 被训练来对预计算轨迹的固定词汇表进行评分，因此它们在该集合之外得不到监督，并且不需要在那里表现得合理。相比之下，DrivoR 与轨迹生成器联合训练，同时保持与其解耦，迫使它对自由解码的轨迹进行评分，而不是对固定网格进行评分。我们假设这就是为什么它在我们搜索探索的提议外轨迹上保持可靠，使其成为唯一适合作为奖励的评分器。

4.4 计算开销

图 3 报告了每个基础规划器+TOAD 的单样本 (batchsize=1) 推理成本，在单个 NVIDIA A100 上测量。我们将执行时间分为三部分：基础规划器、评分器骨干和搜索本身。评分器的感知骨干（一个 ViT-S 编码器，约 100 毫秒）每帧计算一次；然后搜索重用这些缓存的特征，并仅对每个采样轨迹重新运行轻量级评分头。搜索本身（蓝色）因此

仅增加 1.9 ($K = 5$) to 20.4 ms ($K = 100$)，相对于 100 到 780 毫秒的总推理时间。

搜索首先无法避免运行评分器的感知主干网络。

在 DrivoR 中，评分器是基础规划器的一部分，共享同一个主干网络：评分复用了规划器已经提取的特征，因此搜索几乎不增加额外开销（在 DrivoR 的前向传播之上仅需 1.9 毫秒）。当评分器是外部模块时，它需要自己的感知网络，与规划器的感知网络冗余，因此特征被提取了两次。这就是图 3 中其他规划器所承担的约 100 毫秒评分器主干网络开销。经验教训是：应将泛化能力强的评分器直接构建到规划器中，这样强大的测试时搜索几乎可以免费获得。

5 消融实验

TOAD 组件消融。 我们在 iPad 上对 TOAD 的不同组件进行消融实验 [10]. • 热启动。我们将热启动初始化与常规初始化进行比较，常规初始化的均值为零，标准差为一。 • 自行车模型。作为平滑控制空间的替代方案，TOAD 也可以直接在轨迹空间中运行。在这种设置（轨迹空间）下，我们直接采样由鸟瞰图坐标中的 8 个未来 (x, y) 位置组成的轨迹。 • 奖励项。我们研究不同奖励项的重要性：评分器奖励、舒适度奖励和锚点奖励，将它们与没有 TOAD 的原始基线和完整配置进行比较。




图 3: 各方法的单样本推理成本。条形长度是每个样本的总推理时间，分解为基础规划器（浅灰色）、评分器骨干（深灰色）和我们的测试时优化（TOAD，蓝色）。

(a) TOAD 组件消融

Method iPad	warm-start	bicycle	scorer	comfort	anchor	EPDMS $\uparrow$
Vanilla iPad						34.7
normal init.	✓	✓	✓	✓	✓	42.7
traj. space	✓	✓	✓	✓	✓	36.4
w/o scorer reward	✓	✓	✓	✓	✓	35.7
w/o comfort reward	✓	✓	✓	✓	✓	46.9
w/o anchor reward	✓	✓	✓	✓	✓	44.4
TOA	✓	✓	✓	✓	✓	48.5




(b) Per-iteration candidate M . $K = 5$, $E = \max(1, M/8)$.(c) CEM iterations K . $M = 64$, $E = 8$.(d) Number of elites E . $M = 64$ and $K = 5$.

图 4: 在 warmup-two-stage 上使用 iPad 对 TOAD 进行的消融实验。

在图 4a 中，第一个观察结果是，与原始规划器相比，使用 TOAD 后整体性能得到了提升。我们观察到，从标准正态分布初始化仍然能达到有竞争力的性能（42.7 对比 48.5），这表明 TOAD 可以推广到更广泛的端到端规划器类别，这些规划器仅输出单条轨迹而没有关联的分数。

另一个重要观察是，评分器奖励提供了主要的优化信号，带来了显著的性能提升（48.5 对比 35.7）。相比之下，舒适度和锚点奖励提供了补充性改进（48.5 对比 46.9、44.4）。最后，在控制空间中的优化始终优于在轨迹空间中的优化。我们推测这是因为控制空间（例如加速度和偏航率）天然有界，而轨迹坐标无界，因此更难有效优化。

候选数量 M 、迭代次数 K 和精英数量 E 。总体而言，TOAD 在不同超参数设置下始终优于普通基线，展示了其鲁棒性和对超参数选择的低敏感性。如图 4b 所示，性能通常随着采样候选数量的增加而提升。有趣的是，仅采样两个控制序列就已经比没有 TOAD 的普通基线有所改进。为了保持较低的推理开销，我们将候选数量上限设为 64，每次执行的运行时间不到 1.9 毫秒。

在图 4c 中，我们观察到热启动初始化能够实现快速收敛，iPad 在 5 次迭代后达到峰值性能。额外迭代导致的性能下降凸显了学习到的评分器与真实 EPDMS 目标之间不完全的相关性。例如，评分器没有显式建模需要跨相邻帧时序一致性的扩展舒适度指标。最后，图 4d 显示，在候选预算为 64 的情况下，经验上选择 8 个精英能够提供最佳性能，大约对应采样候选的八分之一。这一结果为选择 CEM 超参数提供了实用的指导。

6 结论

端到端规划中的轨迹评分器是学习到的奖励函数，但目前仅用于对固定候选集进行排序。我们表明，真正的瓶颈在于候选集，而非评分器。TOAD 是一个简单的 CEM 循环，针对冻结的评分器进行搜索，在 NAVSIM-v1、NAVSIM-v2 和 HUGSIM 上改进了六个基础规划器，成本可忽略不计且无需重新训练。CEM 只有在评分器在提议分布之外保持准确时才能成功，而目前大多数评分器做不到这一点。这指出了一个明确的方向：构建能够泛化的评分器，从而免费获得强大的测试时搜索能力。

局限性。TOAD 从基础规划器的提议中进行热启动，而一个足够准确的评分器和优化器原则上应允许从头开始搜索。这引出了一个问题：通过更多数据和容量来扩展评分器，是否最终能够完全消除对基础规划器的需求。第二个局限性是对 DrivoR 监督解耦评分器的依赖。未来工作的一个有前景的方向是减少训练此类评分器所需的昂贵轨迹级标注的依赖，例如通过自监督或基于世界模型的奖励。

致谢

我们感谢 Renaud Marlet 在整个项目期间给予的持续支持，以及 Marc Lafon 和 Andrei Bursuc 的有益讨论。本工作获得了 IDRIS 高性能计算资源的访问权限，分配编号为 A0201016239、A0181016239 和 A0181016203，由 GENCI 提供。我们感谢 VISA DEEP 讲席（ANR-20-CHIA-0022）、PostGenAI@Paris 集群（ANR-23-IACL-0007，法国 2030）以及 EuroHPC 联合体授予项目 ID EU2025R01-032 对捷克 Karolina 超级计算机的访问权限。

参考文献

- [1] M. Bojarski, D. Del Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, J. Zhang, et al. End to end learning for self-driving cars. *arXiv preprint arXiv:1604.07316*, 2016.
- [2] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang, L. Lu, X. Jia, Q. Liu, J. Dai, Y. Qiao, and H. Li. Planning-oriented autonomous driving. In *CVPR*, 2023.
- [3] K. Renz, L. Chen, E. Arani, and O. Sinavski. Simlingo: Vision-only closed-loop autonomous driving with language-action alignment. In *CVPR*, 2025.
- [4] Z. Li, K. Li, S. Wang, S. Lan, Z. Yu, Y. Ji, Z. Li, Z. Zhu, J. Kautz, Z. Wu, et al. Hydra-mdp: End-to-end multimodal planning with multi-target hydra-distillation. *arXiv preprint arXiv:2406.06978*, 2024.
- [5] Z. Li, W. Yao, Z. Wang, X. Sun, J. Chen, N. Chang, M. Shen, Z. Wu, S. Lan, and J. M. Alvarez. Generalized trajectory scoring for end-to-end multimodal planning. *arXiv preprint arXiv:2506.06664*, 2025.
- [6] Z. Li, W. Yao, Z. Wang, X. Sun, J. Chen, N. Chang, M. Shen, J. Song, Z. Wu, S. Lan, et al. Ztrs: Zero-imitation end-to-end autonomous driving with trajectory scoring. *arXiv preprint arXiv:2510.24108*, 2025.
- [7] W. Sun, X. Lin, K. Chen, Z. Pei, X. Li, Y. Shi, and S. Zheng. Sparsedrivev2: Scoring is all you need for end-to-end autonomous driving. *arXiv preprint arXiv:2603.29163*, 2026.
- [8] E. Kirby, A. Boulch, Y. Xu, Y. Yin, G. Puy, E. Zablocki, A. Bursuc, S. Gidaris, R. Marlet, F. Bartoccioni, A.-Q. Cao, N. Samet, T.-H. Vu, and M. Cord. Driving on registers. In *CVPR*, 2026.
- [9] L. Feng, Y. Gao, E. Zablocki, Q. Li, W. Li, S. Liu, M. Cord, and A. Alahi. Rap: 3d rasterization augmented end-to-end planning. In *ICLR*, 2026.
- [10] K. Guo, H. Liu, X. Wu, J. Pan, and C. Lv. ipad: Iterative proposal-centric end-to-end autonomous driving. *arXiv preprint arXiv:2505.15111*, 2025.
- [11] R. Y. Rubinstein and D. P. Kroese. *The cross-entropy method: a unified approach to combinatorial optimization, Monte-Carlo simulation, and machine learning*. Springer, 2004.
- [12] D. Dauner, M. Hallgarten, T. Li, X. Weng, Z. Huang, Z. Yang, H. Li, I. Gilitschenski, B. Ivanovic, M. Pavone, et al. Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking. In *NeurIPS*, 2024.
- [13] W. Cao, M. Hallgarten, T. Li, D. Dauner, X. Gu, C. Wang, Y. Miron, M. Aiello, H. Li, I. Gilitschenski, B. Ivanovic, M. Pavone, A. Geiger, and K. Chitta. Pseudo-simulation for autonomous driving. In *CoRL*, 2025.
- [14] D. Dauner, M. Hallgarten, A. Geiger, and K. Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *CoRL*, 2023.

- [15] H. Zhou, L. Lin, J. Wang, Y. Lu, D. Bai, B. Liu, Y. Wang, A. Geiger, and Y. Liao. HUGSIM: A real-time, photo-realistic and closed-loop simulator for autonomous driving. *IEEE Trans. Pattern Anal. Mach. Intell.*, 2026.
- [16] W. Zeng, W. Luo, S. Suo, A. Sadat, B. Yang, S. Casas, and R. Urtasun. End-to-end interpretable neural motion planner. In *CVPR*, 2019.
- [17] E. Yurtsever, J. Lambert, A. Carballo, and K. Takeda. A survey of autonomous driving: Common practices and emerging technologies. *IEEE Access*, 2020.
- [18] B. Jiang, S. Chen, Q. Xu, B. Liao, J. Chen, H. Zhou, Q. Zhang, W. Liu, C. Huang, and X. Wang. Vad: Vectorized scene representation for efficient autonomous driving. In *ICCV*, 2023.
- [19] X. Weng, B. Ivanovic, Y. Wang, Y. Wang, and M. Pavone. Para-drive: Parallelized architecture for real-time autonomous driving. In *CVPR*, 2024.
- [20] B. Liao, S. Chen, H. Yin, B. Jiang, C. Wang, S. Yan, X. Zhang, X. Li, Y. Zhang, Q. Zhang, et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *CVPR*, 2025.
- [21] Z. Xing, X. Zhang, Y. Hu, B. Jiang, T. He, Q. Zhang, X. Long, and W. Yin. Goalflow: Goal-driven flow matching for multimodal trajectories generation in end-to-end autonomous driving. In *CVPR*, 2025.
- [22] W. Yao, Z. Li, S. Lan, Z. Wang, X. Sun, J. M. Álvarez, and Z. Wu. Drivesuprim: Towards precise trajectory selection for end-to-end planning. In *AAAI*, 2026.
- [23] M. Kobilarov. Cross-entropy motion planning. *Int. J. Robotics Res.*, 2012.
- [24] C. Pinneri, S. Sawant, S. Blaes, J. Achterhold, J. Stueckler, M. Rolínek, and G. Martius. Sample-efficient cross-entropy method for real-time planning. In *CoRL*, 2020.
- [25] G. Williams, N. Wagener, B. Goldfain, P. Drews, J. M. Rehg, B. Boots, and E. A. Theodorou. Information theoretic MPC for model-based reinforcement learning. In *ICRA*, 2017.
- [26] P. Drews, G. Williams, B. Goldfain, E. A. Theodorou, and J. M. Rehg. Aggressive deep driving: Combining convolutional neural networks and model predictive control. In *CoRL*, 2017.
- [27] Z. Huang, H. Liu, J. Wu, and C. Lv. Differentiable integrated motion prediction and planning with learnable cost function for autonomous driving. *IEEE Trans. Neural Networks Learn. Syst.*, 2024.
- [28] C. Sima, K. Chitta, Z. Yu, S. Lan, P. Luo, A. Geiger, H. Li, and J. M. Alvarez. Centaur: Robust end-to-end autonomous driving with test-time training. *arXiv preprint arXiv:2503.11650*, 2025.
- [29] A. Jaech, A. Kalai, A. Lerer, A. Richardson, A. El-Kishky, A. Low, A. Helyar, A. Madry, A. Beutel, A. Carney, et al. Openai o1 system card. *arXiv preprint arXiv:2412.16720*, 2024.
- [30] D. Guo, D. Yang, H. Zhang, J. Song, P. Wang, Q. Zhu, R. Xu, R. Zhang, S. Ma, X. Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [31] B. Brown, J. Juravsky, R. Ehrlich, R. Clark, Q. V. Le, C. Ré, and A. Mirhoseini. Large language monkeys: Scaling inference compute with repeated sampling. *arXiv preprint arXiv:2407.21787*, 2024.
- [32] P. Zheng, Y. Zhao, Z. Gong, H. Zhu, and S. Wu. Simplevsf: Vlm-scoring fusion for trajectory prediction of end-to-end autonomous driving. *arXiv preprint arXiv:2510.17191*, 2025.
- [33] Y. Li, Y. Wang, Y. Liu, J. He, L. Fan, and Z. Zhang. End-to-end driving with online trajectory evaluation via BEV world model. In *ICCV*, 2025.

- [34] J. Sun, F. Xue, T. Long, C. Liu, J.-F. Hu, W.-S. Zheng, and N. Sebe. Risk-aware world model predictive control for generalizable end-to-end autonomous driving. *arXiv preprint arXiv:2602.23259*, 2026.
- [35] Y. Li, K. Xiong, X. Guo, F. Li, S. Yan, G. Xu, L. Zhou, L. Chen, H. Sun, B. Wang, et al. Recogdrive: A reinforced cognitive framework for end-to-end autonomous driving. In *ICLR*, 2026.
- [36] Z. Song, L. Liu, H. Pan, B. Liao, M. Guo, L. Yang, Y. Zhang, S. Xu, C. Jia, and Y. Luo. Diver: Reinforced diffusion breaks imitation bottlenecks in end-to-end autonomous driving. *arXiv preprint arXiv:2507.04049*, 2025.
- [37] D. Li, C. Li, Y. Wang, J. Ren, X. Wen, P. Li, L. Xu, K. Zhan, P. Jia, X. Lang, et al. Learning personalized driving styles via reinforcement learning from human feedback. *arXiv preprint arXiv:2503.10434*, 2025.
- [38] N. Hanselmann, K. Renz, K. Chitta, A. Bhattacharyya, and A. Geiger. KING: generating safety-critical driving scenarios for robust imitation via kinematics gradients. In *ECCV*, 2022.
- [39] Y. Yin, P. Khayatan, É. Zablocki, A. Boulch, and M. Cord. Regents: Real-world safety-critical driving scenario generation made stable. In *ECCV Workshops*, 2024.
- [40] B. Kerbl, G. Kopanas, T. Leimkühler, and G. Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 2023.
- [41] Y. Hong, X. Zhou, Y. Li, X. Zhou, L. Liu, Y. Luo, S. Xu, L. Yang, and Z. Song. Drivefuture: Future-aware latent world models for autonomous driving. *arXiv preprint arXiv:2605.09701*, 2026.
- [42] Y. Liao, J. Xie, and A. Geiger. KITTI-360: A novel dataset and benchmarks for urban scene understanding in 2d and 3d. *TPAMI*, 2023.
- [43] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *CVPR*, 2020.
- [44] P. Xiao, Z. Shao, S. Hao, Z. Zhang, X. Chai, J. Jiao, Z. Li, J. Wu, K. Sun, K. Jiang, Y. Wang, and D. Yang. Pandaset: Advanced sensor suite dataset for autonomous driving. In *ITSC*, 2021.
- [45] P. Sun, H. Kretzschmar, X. Dotiwalla, A. Chouard, V. Patnaik, P. Tsui, J. Guo, Y. Zhou, Y. Chai, B. Caine, V. Vasudevan, W. Han, J. Ngiam, H. Zhao, A. Timofeev, S. Ettinger, M. Krivokon, A. Gao, A. Joshi, Y. Zhang, J. Shlens, Z. Chen, and D. Anguelov. Scalability in perception for autonomous driving: Waymo open dataset. In *CVPR*, 2020.
- [46] K. Chitta, A. Prakash, B. Jaeger, Z. Yu, K. Renz, and A. Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *TPAMI*, 2022.
- [47] Y. Wang, X. Li, W. Wang, J. Zhang, Y. Li, Y. Chen, X. Wang, and Z. Zhang. Unified vision-language-action model. *arXiv preprint arXiv:2506.19850*, 2025.
- [48] Y. Chen, Y. Wang, and Z. Zhang. Drivinggpt: Unifying driving world modeling and planning with multi-modal autoregressive transformers. In *ICCV*, 2025.
- [49] C. Shi, S. Shi, K. Sheng, B. Zhang, and L. Jiang. Drivex: Omni scene modeling for learning generalizable world knowledge in autonomous driving. In *ICCV*, 2025.
- [50] Y. Zheng, P. Yang, Z. Xing, Q. Zhang, Y. Zheng, Y. Gao, P. Li, T. Zhang, Z. Xia, P. Jia, et al. World4drive: End-to-end autonomous driving via intention-aware physical latent world model. In *ICCV*, 2025.

- [51] C. Yuan, Z. Zhang, J. Sun, S. Sun, Z. Huang, C. D. W. Lee, D. Li, Y. Han, A. Wong, K. P. Tee, et al. Drama: An efficient end-to-end motion planner for autonomous driving with mamba. In *ISRR*, 2024.
- [52] S. Chen, B. Jiang, H. Gao, B. Liao, Q. Xu, Q. Zhang, C. Huang, W. Liu, and X. Wang. Vadv2: End-to-end vectorized autonomous driving via probabilistic planning. *arXiv preprint arXiv:2402.13243*, 2024.
- [53] M. Wozniak, L. Liu, Y. Cai, and P. Jensfelt. PRiX: learning to plan from raw pixels for end-to-end autonomous driving. *IEEE Robotics Autom. Lett.*, 2026.
- [54] Z. Zhou, T. Cai, S. Z. Zhao, Y. Zhang, Z. Huang, B. Zhou, and J. Ma. Autovla: A vision-language-action model for end-to-end autonomous driving with adaptive reasoning and reinforcement fine-tuning. *NeurIPS*, 2025.
- [55] Y. Li, S. Shang, W. Liu, B. Zhan, H. Wang, Y. Wang, Y. Chen, X. Wang, Y. An, C. Tang, et al. Drivevla-w0: World models amplify data scaling law in autonomous driving. *arXiv preprint arXiv:2510.12796*, 2025.
- [56] K. Li, Z. Li, S. Lan, Y. Xie, Z. Zhang, J. Liu, Z. Wu, Z. Yu, and J. M. Alvarez. Hydra-mdp++: Advancing end-to-end driving via expert-guided hydra-distillation. *arXiv e-prints*, pages arXiv–2503, 2025.
- [57] L. Liu, C. Jia, G. Yu, Z. Song, J. Li, F. Jia, P. Wu, X. Hao, and Y. Luo. Guideflow: Constraint-guided flow matching for planning in end-to-end autonomous driving. *arXiv preprint arXiv:2511.18729*, 2025.
- [58] B. Jiang, S. Chen, B. Liao, X. Zhang, W. Yin, Q. Zhang, C. Huang, W. Liu, and X. Wang. Senna: Bridging large vision-language models and end-to-end autonomous driving. *arXiv preprint arXiv:2410.22313*, 2024.
- [59] B. Sun, Y. Cao, Y. Wang, R. Wang, J. Shang, X. Feng, J. Lu, J. Shi, S. Yang, X. Yan, et al. Minddrive: An all-in-one framework bridging world models and vision-language model for end-to-end autonomous driving. *arXiv preprint arXiv:2512.04441*, 2025.
- [60] Z. Zhou, R. Yang, Y. Guo, S. X. Chen, T. Feng, K. Pistunova, Y. Shen, L. Su, J. Ma, et al. Spanvla: Efficient action bridging and learning from negative-recovery samples for vision-language-action model. *arXiv preprint arXiv:2604.19710*, 2026.
- [61] A. Jiang, Y. Gao, Z. Sun, Y. Wang, J. Wang, J. Chai, Q. Cao, Y. Heng, H. Jiang, Y. Dong, et al. Diffvla: Vision-language guided diffusion planning for autonomous driving. *arXiv preprint arXiv:2505.19381*, 2025.
- [62] H. Tian, T. Li, H. Liu, J. Yang, Y. Qiu, G. Li, J. Wang, Y. Gao, Z. Zhang, L. Wang, H. Ye, T. Tan, L. Chen, and H. Li. Simscale: Learning to drive via real-world simulation at scale. In *CVPR*, 2026.

A 驾驶度量

在本研究中，我们使用其原始基准所定义的官方度量。

NAVSIM-v1 [12]。我们使用预测驾驶员模型得分（PDMS），该得分聚合了以下子度量：无过错碰撞（NC）、可行驶区域合规性（DAC）、碰撞时间（TTC）、自行车进度（EP）、自行车舒适性（Comf.）。子得分描述和聚合策略的详细信息可在原始基准论文中找到。

NAVSIM-v2 [13]。我们使用扩展预测驾驶员模型得分（EPDMS），该得分在评估的两个阶段上计算。与 PDMS 相比，EPDMS 增加了驾驶方向合规性（DDC）、交通线合规性（TLC）和车道保持（LK），并将自行车舒适性度量替换为历史舒适性（HC）和扩展舒适性（EC）。

HUGSIM [15]。我们采用官方 HUGSIM 驾驶评分（HD-SCore 或 HDS），该评分模拟 NAVSIM-v1/2 度量。它使用五个子评分：无碰撞（NC）、可行驶区域合规性（DAC）、碰撞时间（TTC）、舒适性（COM）和路线完成度（RC），其中路线完成度以智能体在当前场景中覆盖路线的百分比替代自身进度。

B 交叉熵方法中轨迹的演化

在图 5 中，我们展示了优化过程中奖励的增加以及 EPDMS 评分的相应提升。我们还观察到平均精英轨迹分布逐步细化，向右车道偏移并表现出更好的前进进度。这种行为不同于普通轨迹和人类轨迹。




图 5：交叉熵方法迭代可视化。我们可视化 TOAD 中交叉熵方法的迭代过程，使用 Hydra-MDP [4]。

B.1 NAVSIM 基准的详细结果

NAVSIM-v1 详细结果。在表 5 中，我们报告了 navtest 上的 PDMS 及其组成子度量。表 5 显示，对于每个基础规划器，安全列（NC、DAC、TTC）已经饱和。因此，TOAD 通过提升自身进度子度量（EP）来提高不同基础规划器的 PDMS，同时在安全子度量上保持同等性能。这导致所有 6 个基础规划器的 PDMS 均有所增加。

表 5: NAVSIM-v1。在 NAVSIM-v1 基准测试集 (navtest) 上与现有一摄像头方法的比较。分数越高越好。

Method	NC	DAC	TTC	Comf.	EP	PDMS
PDM-Closed [14]	94.6	99.8	89.9	86.9	99.9	89.1
Human driver [12]	100	100	100	99.9	87.5	94.8
Ego-stat. MLP [12]	93.0	77.3	83.6	100	62.8	65.6
UniVLA [47]	96.9	91.1	91.7	96.7	76.8	81.7
DrivingGPT [48]	98.9	90.7	94.9	95.6	79.7	82.4
UniAD [2]	97.8	91.9	92.9	100	78.8	83.4
LTF [46]	97.4	92.8	92.4	100	79.0	83.8
PARA-Drive [19]	97.9	92.4	93.0	99.8	79.3	84.0
DriveX-S [49]	97.5	94.0	93.0	100	79.7	84.5
World4Drive [50]	97.4	94.3	92.8	100	79.9	85.1
DRAMA [51]	98.0	93.1	94.8	100	80.1	85.5
VAD-v2 [52]	98.1	94.8	94.3	100	80.6	86.2
PRIX [53]	98.1	96.3	94.1	100	82.3	87.8
DiffusionDrive [20]	98.2	96.2	94.7	100	82.2	88.1
DIVER [36]	98.5	96.5	94.9	100	82.6	88.3
AutoVLA [54]	98.4	95.6	98.0	99.9	81.9	89.1
DriveVLA-W0 [55]	98.7	99.1	95.3	99.3	83.3	90.2
ReCogDrive [35]	97.9	97.3	94.9	100	87.3	90.8
Hydra-MDP++ [56]	98.6	98.6	95.1	100	85.7	91.0
Centaur [28]	99.5	98.9	98.0	100	85.9	92.6
DriveSuprim [22]	98.6	98.6	95.5	100	91.3	93.5
ZTRS (V2-99) [6]	98.8	99.5	95.1	100	74.7	86.9
+ TOAD	98.4	98.6	94.3	100	82.1	89.0 (↑2.4%)
GTRS (V2-99) [5]	99.0	98.9	95.9	100	82.8	90.4
+ TOAD	98.9	98.1	96.3	100	84.8	90.9 (↑0.6%)
Hydra-MDP [4]	98.5	98.7	94.9	100	85.5	90.9
+ TOAD	98.7	98.0	95.4	100	87.2	91.4 (↑0.6%)
iPad [10]	98.6	98.3	94.9	100	88.0	91.7
+ TOAD	99.0	99.3	96.4	100	89.1	93.4 (↑1.9%)
RAP-DINO [9]	99.1	98.9	96.7	100	90.3	93.8
+ TOAD	99.0	99.2	96.6	100	90.1	93.9 (↑0.1%)
DrivoR [8]	99.1	99.2	96.9	100	91.6	94.6
+ TOAD	99.0	99.3	96.8	100	91.8	94.7 (↑0.1%)

NAVSIM-v2 详细结果。在表 6 中，我们报告了 EPDMS 及其在 navhard-two-stage 上的第一阶段和第二阶段子度量。表 6 显示，与 navtest 不同，在这些更难的分布外场景中，安全列（NC、DAC、

TTC）仍有提升空间。因此，TOAD 通过提高安全子度量来改善不同基础规划器的 EPDMS，同时以少量自车进度（EP）为代价，且这种变化集中在要求更高的第二阶段。这导致所有 6 个基础规划器的 EPDMS 均有所提升。

增益来源：详细结果。在表 7 中，我们报告了在 iPad 和 Hydra-MDP 之上，平滑、重打分以及使用不同打分器进行搜索的逐子度量分解。表 7 显示，平滑几乎使所有子度量保持不变，重打分在两个规划器上对各个子度量的影响不一致，而使用固定词汇打分器（GTRS、SparseDriveV2）的搜索会同时降低多个子度量。只有使用 DrivoR 打分器的 TOAD 能够在不破坏进度的前提下共同提升安全子度量。这证实了增益来源于 TOAD 中搜索与离策略准确打分器之间的协同作用，而非仅靠打分。

表 6: NAVSIM-v2 navhard-two-stage。在 NAVSIM-v2 基准测试集上使用 EPDMS [13] 与现有方法的比较。

Method		Stage 1									Stage 2									EPDMS
		NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	
PDM-Closed	[14]	94.4	98.8	100	99.5	100	93.5	99.3	87.7	36.0	90.5	90.6	95.4	98.4	100	86.6	74.2	91.9	29.7	56.6
TransFuser	[46]	96.2	79.5	99.1	99.5	84.1	95.1	94.2	97.5	79.1	77.7	70.2	84.2	98.0	85.1	75.6	45.4	95.7	75.9	23.1
DiffusionDrive	[20]	96.0	79.7	97.4	99.5	81.3	93.1	90.8	96.8	73.8	82.1	72.2	88.5	98.7	85.1	78.8	49.2	89.3	71.2	24.2
GuideFlow	[57]	96.6	80.5	96.3	99.3	82.3	94.9	91.5	97.7	67.8	87.3	76.7	88.8	99.2	84.3	85.1	49.7	93.1	44.5	27.1
Senna-E2E	[58]	95.6	86.0	98.9	99.6	83.9	95.1	95.3	97.6	75.6	78.6	74.8	84.8	98.2	88.2	75.7	46.9	96.0	65.8	27.2
MindDrive	[59]	96.1	86.0	98.8	99.3	83.3	95.6	94.4	97.6	74.7	82.6	79.1	86.4	98.0	85.3	79.4	49.2	96.5	71.0	30.9
World4Drive	[50]	97.3	89.1	97.6	99.7	60.5	96.8	87.7	93.1	60.0	91.4	82.0	91.0	98.5	53.1	90.6	52.3	93.3	62.8	34.9
SpanVLA	[60]	98.4	94.3	97.8	99.9	85.7	97.2	94.2	97.6	72.1	86.9	84.3	87.1	98.2	85.5	82.7	62.3	96.8	67.4	40.1
DriveSuprim	[22]	98.9	95.1	99.2	99.6	76.1	99.1	94.7	97.6	54.2	87.9	88.8	89.6	98.8	80.3	86.0	53.5	97.1	56.1	42.1
DiffVLA	[61]	95.7	99.2	100.0	100.0	85.9	96.4	97.1	95.0	84.2	81.2	88.8	94.6	99.0	86.0	76.4	59.8	98.6	80.4	45.0
GTRS-E	[5]	98.9	99.3	99.8	99.8	75.2	98.4	96.0	97.6	51.6	92.3	93.3	94.6	99.2	73.1	91.2	53.9	96.7	56.8	49.4
SimScale	[62]	99.6	99.1	99.9	100.0	69.6	99.6	95.8	95.6	28.4	94.5	94.2	95.8	99.2	75.8	92.8	60.1	96.1	43.2	53.2
DriveFuture	[41]	99.8	99.8	100.0	99.6	85.7	99.8	98.7	97.6	66.2	90.6	87.5	94.1	99.1	84.6	88.8	58.3	93.5	45.6	55.5
iPad	[10]	96.2	94.9	96.8	99.6	82.0	95.8	94.2	97.8	42.2	83.6	83.2	84.8	97.7	85.4	79.7	46.8	95.2	38.9	34.7
+ TOAD		97.7	97.1	99.6	99.8	75.6	98.4	93.6	97.6	43.1	93.0	91.0	93.1	98.8	78.4	91.2	54.8	97.6	41.1	49.8 (↑43.6%)
RAP-DINO (ViT-H)	[9]	97.1	94.4	98.8	99.8	83.9	96.9	94.7	96.4	66.2	83.2	83.9	87.4	98.0	86.9	80.4	52.3	95.2	52.4	39.6
+ TOAD		97.1	95.3	99.4	100.0	80.3	97.8	92.9	97.6	64.4	89.9	89.7	92.5	98.2	81.4	87.7	52.1	97.2	51.1	49.0 (↑23.9%)
Hydra-MDP	[4]	98.4	94.2	99.6	99.8	82.7	98.0	95.8	97.8	66.2	85.2	82.5	89.7	98.5	85.2	82.5	50.7	95.4	47.7	40.9
+ TOAD		98.1	95.1	99.3	100.0	78.0	98.2	89.1	97.8	55.1	91.4	90.1	94.3	98.5	80.1	88.9	55.7	97.6	45.2	49.7 (↑21.6%)
GTRS (v2-99)	[5]	98.9	95.1	99.1	99.6	76.2	99.1	94.9	97.6	54.2	88.1	88.8	89.3	98.9	98.9	85.9	53.7	96.8	56.9	45.4
+ TOAD		98.7	96.4	99.2	99.8	74.6	98.7	89.1	97.6	60.9	91.2	91.5	95.1	98.5	75.7	89.2	57.8	98.5	54.3	51.7 (↑13.8%)
ZTRS (v2-99)	[6]	98.9	97.6	100	100	66.7	98.9	96.2	96.7	44.0	91.1	90.4	95.8	99.0	63.6	89.8	60.4	97.6	66.1	48.1
+ TOAD		98.7	96.9	99.6	99.6	71.0	98.4	90.7	97.6	62.2	92.3	90.2	94.0	98.5	67.8	90.4	58.8	99.2	57.3	49.2 (↑ 2.3%)
DrivoR (ViT-S)	[8]	99.1	98.2	99.3	99.8	75.4	98.7	94.9	97.6	70.2	92.3	91.6	97.3	99.1	75.7	90.6	56.1	98.4	44.7	54.6
+ TOAD		98.9	98.2	99.4	100.0	74.6	98.9	94.0	97.6	66.7	93.6	94.0	97.5	98.8	74.1	92.0	57.1	98.0	47.3	56.3 (↑ 3.1%)

表 7: 增益来源是什么? (i) 轨迹平滑, (ii) 使用 DrivoR 打分器 [8]、GTRS 打分器 [5] 和 SparseDriveV2 [7] 对原始提议进行重打分, 以及 (iii) 使用不同打分器作为奖励进行搜索——基于 iPad [10] 和 Hydra-MDP [4]。在 NAVSIM-v2 上使用 EPDMS [13] 进行评估; 数值越大越好。

Method		Stage 1									Stage 2									EPDMS
		NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	NC	DAC	DDC	TLC	EP	TTC	LK	HC	EC	
iPad	[10]	96.2	94.9	96.8	99.6	82.0	95.8	94.2	97.8	42.2	83.6	83.2	84.8	97.7	85.4	79.7	46.8	95.2	38.9	34.7
+ Smoothing (BM)		96.0	94.0	96.6	99.3	82.4	95.6	94.4	97.8	60.9	81.6	80.2	85.6	97.9	85.7	78.3	46.7	97.2	56.8	35.0 (↑ 0.8%)
+ Re-scoring w/ DrivoR		98.7	97.8	99.9	99.6	75.2	98.7	94.4	88.9	44.0	90.2	87.4	92.8	98.7	74.0	88.1	53.2	91.9	43.6	45.6 (↑31.5%)
+ Re-scoring w/ GTRS		95.3	87.3	93.8	99.6	69.9	95.6	90.2	89.6	34.2	90.4	83.6	92.6	98.6	56.4	87.9	54.7	95.5	59.1	34.5 (↓ 0.6%)
+ Re-scoring w/ SparseDriveV2		96.7	85.1	98.7	100.0	79.4	96.4	95.6	92.0	36.9	85.0	76.1	87.1	98.5	77.2	84.1	51.9	87.5	37.3	30.3 (↓12.5%)
+ Search w/ GTRS-Scorer		93.3	77.8	89.8	99.8	59.9	94.0	79.1	94.2	15.6	88.1	75.6	91.2	98.2	64.3	87.0	57.0	96.4	30.6	23.9 (↓31.1%)
+ Search w/ SparseDriveV2 scorer		96.9	86.9	96.7	100.0	74.7	96.9	86.0	97.6	32.0	90.6	84.5	88.6	98.4	75.1	88.2	50.5	97.4	48.7	34.6 (↓ 0.4%)
+ TOAD (search w/ DrivoR scorer)		97.7	97.1	99.6	99.8	75.6	98.4	93.6	97.6	43.1	93.0	91.0	93.1	98.8	78.4	91.2	54.8	97.6	41.1	49.8 (↑43.6%)
Hydra-MDP	[4]	98.4	94.2	99.6	99.8	82.7	98.0	95.8	97.8	66.2	85.2	82.5	89.7	98.5	85.2	82.5	50.7	95.4	47.7	40.9
+ Smoothing (BM)		98.2	92.4	99.3	100.0	83.0	97.8	96.0	97.8	65.8	84.4	80.9	88.2	98.3	86.3	80.7	51.1	95.4	50.7	38.8 (↓ 5.1%)
+ Re-scoring w/ DrivoR		98.2	90.7	99.1	99.8	64.0	97.6	90.0	74.9	8.0	94.3	90.8	96.6	99.3	65.1	92.5	55.9	74.8	18.2	37.3 (↓ 8.8%)
+ Re-scoring w/ GTRS		97.3	98.7	99.9	99.6	63.5	97.1	92.7	85.1	15.1	91.9	92.8	95.1	98.8	65.1	90.8	58.1	79.5	18.4	40.3 (↓ 1.5%)
+ Re-scoring w/ SparseDriveV2		90.7	52.9	87.2	99.6	76.9	88.7	81.3	96.4	14.7	81.9	51.2	82.1	98.5	78.1	79.4	52.0	96.5	21.7	9.5 (↓76.9%)
+ Search w/ GTRS-Scorer		96.0	92.9	96.7	99.6	82.4	96.7	93.8	97.8	60.4	85.4	83.0	87.1	98.8	85.8	83.0	52.0	96.7	46.9	38.1 (↓ 6.9%)
+ Search w/ SparseDriveV2 scorer		95.9	78.7	95.0	100.0	78.9	95.1	85.8	97.6	52.4	87.6	77.3	85.6	98.9	83.0	84.0	47.8	96.9	51.8	29.6 (↓27.7%)
+ TOAD (search w/ DrivoR scorer)		98.1	95.1	99.3	100.0	78.0	98.2	89.1	97.8	55.1	91.4	90.1	94.3	98.5	80.1	88.9	55.7	97.6	45.2	49.7 (↑21.6%)