

TTRL: 测试时强化学习

Yuxin Zuo^{*1,2} Kaiyan Zhang^{*1} Li Sheng^{1,2} Shang Qu^{1,2} Ganqu Cui²
 Xuekai Zhu¹ Haozhan Li^{1,2} Yuchen Zhang² Xinwei Long¹
 Ermo Hua¹ Biqing Qi² Youbang Sun¹ Zhiyuan Ma¹ Lifan Yuan¹
 Ning Ding^{+1,2} Bowen Zhou^{+1,2}
¹Tsinghua University ²Shanghai AI Lab

<https://github.com/PRIME-RL/TTRL>

摘要

本文研究在大语言模型（Large Language Models）推理任务中，对无显式标签的数据进行强化学习（Reinforcement Learning）。该问题的核心挑战在于推理过程中无法获取真实信息时的奖励估计。尽管这一设定看似难以实现，我们发现测试时扩展（Test-Time Scaling）中的常见做法，如多数投票，能产生出人意料的的有效奖励，足以驱动强化学习训练。本文提出测试时强化学习（Test-Time Reinforcement Learning, TTRL），一种利用无标签数据训练大语言模型的新方法。TTRL 通过利用预训练模型中的先验知识，实现大语言模型的自我进化。实验表明，TTRL 在多种任务和模型上均能持续提升性能。值得注意的是，仅使用无标签测试数据，TTRL 将 Qwen-2.5-Math-7B 在 AIME 2024 上的 pass@1 性能提升了约 **211%**。此外，尽管 TTRL 仅由 maj@n 指标监督，其性能已持续超越初始模型 maj@n 的上限，并接近使用真实标签直接在测试数据上训练的模型性能。实验结果验证了 TTRL 在各类任务中的普遍有效性，并凸显了其在更广泛任务和领域中的潜力。




图 1: TTRL 的性能与定位。

* 同等贡献。张凯岩 (zhang-ky22@mails.tsinghua.edu.cn) 与崔淦渠主导本项目。†: 通讯作者。

目录

1 引言 3

2 测试时强化学习 (TTRL) 4

- 2.1 方法论 4
- 2.2 多数投票奖励函数 5

3 实验 5

- 3.1 实验设置 5
- 3.2 主要结果 7

4 分析与讨论 9

- 4.1 问题 1: 测试时强化学习能表现多好? 9
- 4.2 问题二: TTRL 为何有效? 10
- 4.3 问题三: TTRL 何时可能失效? 12

5 相关工作 13

- 5.1 测试时扩展 13
- 5.2 用于推理的强化学习 14

6 结论 14

7 局限性与未来工作 15

A 补充结果 20

B 训练度量 21

C 术语 21

- C.1 测试时训练 (Test-Time Training) 21
- C.2 测试时推理 (Test-Time Inference, TTI) 21

1 引言

大型推理模型（Large Reasoning Models, LRM）的最新进展，如 DeepSeek-R1（Guo 等，2025）和 OpenAI 的 o1（Jaech 等，2024），表明强化学习（Reinforcement Learning, RL）对于通过训练昂贵的人工标注数据来增强长思维链（chain-of-thought, CoT）推理（Wei 等，2022）至关重要。这些模型在一系列极具挑战性的任务上取得了显著性能。例如，OpenAI 的 o3 在 ARC-AGI-1 上达到了 75.7% 的成功率。然而，复杂且未标注的问题不断涌现，带来了重大挑战。例如，o3 在最近发布的 ARC-AGI-2 基准（2025）上仅解决了 4% 的问题¹。解决此类任务通常需要扩大训练规模，使用更多数据和计算资源，但仍可能无法在这些任务上取得强劲性能。Silver 与 Sutton（2025）最近倡导向“经验时代”过渡，强调现有 AI 系统严重依赖人类监督的局限性，以及使模型能够通过经验自我进化的重要性。

在大型推理模型取得重大进展的基础上，这自然催生了一个有前景的方向：人工智能系统通过直接参与自我体验与学习，在无标注数据上借助强化学习实现自主改进，从而拓展强化学习的边界，并进一步推动人工智能能力的前沿发展。这种自我进化可大致分为两种模式：对测试时数据的适应，使模型能够应对更难的基准，如 ARC-AGI-2；以及对外部无标注数据的训练，从而解锁超出标注语料库的更多训练数据。本文聚焦于测试时数据的适应，这一方向已在测试时训练范式下得到广泛研究。

（TTT）（Sun 等人，2019；2024；Behrouz 等人，2024；Akyürek 等人，2024）。TTT 近年来受到越来越多的关注。这些方法通过利用输入测试数据的结构和分布特性，在测试时自适应地调整模型参数。

因此，本文旨在通过在测试时利用强化学习更新模型，全面推动人工智能的进化，从而增强其对未见数据的泛化能力。然而，这引入了一个关键挑战：如何在测试时为强化学习获取奖励？这也凸显了当前强化学习方法的一个更广泛的局限性。尽管这些方法前景广阔，但大多数现有方法仍严重依赖标注数据，这极大地限制了其可扩展性。随着现实世界任务的复杂性和数量持续增长，为强化学习进行大规模标注变得越来越不切实际，对最先进模型的持续改进构成了重大障碍。

本文提出测试时强化学习（Test-Time Reinforcement Learning, TTRL），通过强化学习执行测试时训练。TTRL 在展开阶段采用重复采样策略，以准确估计标签并计算基于规则的奖励，从而在无标注数据上实现强化学习。通过引入有效的多数投票奖励，TTRL 在缺乏真实标签的情况下促进了高效且稳定的强化学习。如前所述，更具挑战性的任务的出现将不可避免地导致无标注数据比例增大。TTRL 直接解决了在没有显式监督的情况下通过强化学习训练模型的问题，探究了模型在这种具有挑战性但至关重要的环境中探索和学习的能力。本质上，TTRL 使模型能够生成自身经验、估计奖励并随时间提升性能。

在实验中，将 TTRL 应用于 Qwen2.5-Math-7B，在 AIME 2024 上性能提升了 **211%**（从 12.9 提升至 40.2），在 AIME 2024、AMC、MATH-500 和 GPQA 上平均增益达 **76%**。这些改进通过自我进化实现，无需任何标注训练数据，并进一步泛化到其他任务。TTRL 不仅提升了 pass@1 的性能，还通过多数投票改善了 TTS。此外，初步实验表明，TTRL 在不同规模和类型的模型上均有效，并且可以与现有强化学习算法集成。我们还发现 TTRL 表现出良好的特性，例如高性能上限。这些观察结果凸显了其大幅减少对人工标注依赖的潜力，从而支持持续学习并将强化学习扩展到大规模无监督训练。以下是几个关键点：

¹<https://arcprize.org/>

Takeaways

1. Majority voting provides effective reward estimation for TTRL (§ 3).
2. TTRL 能够超越其训练信号和上限 maj@n, 并紧密接近在带有真实标签的测试数据上直接训练的性能 (§ 4.1)。
3. It is possible to achieve efficient and stable RL in an unsupervised manner (§ 4.2).

2 测试时强化学习 (Test-Time Reinforcement Learning, TTRL)

与传统强化学习不同, 在传统强化学习中智能体从已知奖励信号中学习, 而 TTRL 在无标签的测试数据上运行。换句话说, 模型必须在没有显式监督的情况下学习和适应。我们的任务定义如下:

我们研究在测试时使用强化学习训练预训练模型的问题, 且没有真实标签。我们将这种设置称为测试时强化学习。

2.1 Methodology




图 2: TTRL 结合了测试时扩展 (Test-Time Scaling, TTS) 和测试时训练 (Test-Time Training, TTT)。

图 2 展示了我们的方法 TTRL 如何应对这一挑战。给定由提示 x 表示的状态, 模型通过从由 θ 参数化的策略 $\pi_\theta(y | x)$ 中采样产生输出 y 来采取行动。为了在没有真实标签的情况下构建奖励信号, 我们通过重复采样从模型生成多个候选输出 $\{y_1, y_2, \dots, y_N\}$ 。通过多数投票或其他聚合方法得出共识输出 y^* , 作为最优动作的代理。然后, 环境根据采样动作 y 与共识动作 y^* 之间的对齐程度提供奖励 $r(y, y^*)$ 。因此, 强化学习的目标是最大化期望奖励:

$$\max_{\theta} \mathbb{E}_{y \sim \pi_\theta(\cdot | x)} [r(y, y^*)], \quad (1)$$

参数 θ 通过梯度上升进行更新:

$$\theta \leftarrow \theta + \eta \nabla_{\theta} \mathbb{E}_{y \sim \pi_\theta(\cdot | x)} [r(y, y^*)], \quad (2)$$

其中 η 表示学习率。这种方法使模型能够在推理过程中进行适应, 从而在分布偏移的输入上有效提升性能, 而无需标注数据。

Listing 1: The pseudo-code of the majority voting reward function.

```

from collections import Counter

def majority_voting_reward_fn(outputs):
    """
    Assigns a reward of 1 to each output whose extracted answer matches
    the majority answer, otherwise 0.
    """
    # Extract answers from each output
    answers = [extract_answer(output) for output in outputs]

    # Find the majority answer
    counts = Counter(answers)
    majority_answer, _ = counts.most_common(1)[0]

    # Assign rewards: 1 if matches majority, else 0
    rewards = [1 if ans == majority_answer else 0 for ans in answers]
    return rewards

outputs = llm.generate(problem, n=N)
rewards = majority_voting_reward_fn(outputs)

```

2.2 多数投票奖励函数

多数投票奖励通过首先利用多数投票估计标签来确定。该估计标签随后用于计算基于规则的奖励，作为最终奖励。给定问题 x ，我们首先将 x 输入大语言模型以生成一组输出。答案提取器随后处理这些输出以获得相应的预测答案，记为 $P = \{\hat{y}_i\}_{i=1}^N$ 。我们首先对 P 按照方程 4 估计标签，以多数投票作为评分函数 $s(y, x)$ 得到 y ，即 P 中出现频率最高的预测。多数投票预测 y 随后用作估计标签，以计算基于规则的奖励（Guo 等，2025）。奖励函数为：

$$R(\hat{y}_i, y) = \begin{cases} 1, & \text{if } \hat{y}_i = y, \\ 0, & \text{otherwise.} \end{cases} \quad (3)$$

清单 1 展示了奖励函数的伪代码。

3 实验

3.1 实验设置

模型 为评估 TTRL 在不同骨干模型上的泛化性，我们使用不同规模的基础模型和指令模型进行实验。此外，我们在领先的长推理模型上开展实验，以证明 TTRL 即使在昂贵的后训练之后仍能提升模型性能。我们实验所用模型如下：

- **通义千问系列**：通义千问 2.5-数学-1.5B（杨等人，2024a）、通义千问 2.5-数学-7B（杨等人，2024a）、通义千问 2.5-7B（杨等人，2024b）、通义千问 2.5-32B（杨等人，2024b）、通义千问 3-8B（思考模式与非思考模式）（杨等人，2024b）；
- **羊驼家族**：羊驼-3.1-8B-指令（格拉塔菲奥里等人，2024）、羊驼-3.2-3B-指令（格拉塔菲奥里等人，2024）、羊驼-3.2-3B-燕麦-零（刘等人，2025b）；
- **米斯特拉尔家族**：米斯特拉尔-尼莫-指令-2407（米斯特拉尔 AI-尼莫，2024）、米尼斯特拉尔-8B-指令-2410（米尼斯特拉尔-8B-指令，2024）；
- **深度求索家族**：深度求索-数学-7B-指令（邵等人，2024）、深度求索-R1-羊驼-8B（郭等人，2025）；
- **其他**：Skywork-OR1-Math-7B（He 等人，2025）；

表 1: TTRL 在各任务上的主要结果。* 表示 Qwen3-8B 在 3k 上下文内以非思考模式评估。图 3 提供了 32k 上下文内的结果。

Name	AIME 2024	AMC	MATH-500	GPQA	Avg
Math Base Models					
Qwen2.5-Math-1.5B	7.7	28.6	32.7	24.9	23.5
w/ TTRL	15.8	48.9	73.0	26.1	41.0
Δ	+8.1	+20.3	+40.3	+1.2	+17.5
	↑ 105.2%	↑ 71.0%	↑ 123.2%	↑ 4.8%	↑ 74.4%
Qwen2.5-Math-7B	12.9	35.6	46.7	29.1	31.1
w/ TTRL	40.2	68.1	83.4	27.7	54.9
Δ	+27.3	+32.5	+36.7	-1.4	+23.8
	↑ 211.6%	↑ 91.3%	↑ 78.6%	↓ 4.8%	↑ 76.5%
Vanilla Base Models					
Qwen2.5-7B	7.9	34.8	60.5	31.8	33.8
w/ TTRL	23.3	56.6	80.5	33.6	48.5
Δ	+15.4	+21.8	+20.0	+1.8	+14.7
	↑ 194.9%	↑ 62.6%	↑ 33.1%	↑ 5.7%	↑ 43.7%
Qwen2.5-32B	7.9	32.6	55.8	33.2	32.4
w/ TTRL	24.0	59.3	83.2	37.7	51.1
Δ	+16.1	+26.7	+27.4	+4.5	+18.7
	↑ 203.8%	↑ 81.9%	↑ 49.1%	↑ 13.6%	↑ 57.7%
Instruct Models					
LLaMA3.1-8B	4.6	23.3	48.6	30.8	26.8
w/ TTRL	10.0	32.3	63.7	34.1	35.0
Δ	+5.4	+9.0	+15.1	+3.3	+8.2
	↑ 117.4%	↑ 38.6%	↑ 31.1%	↑ 10.7%	↑ 30.6%
Qwen3-8B*	26.9	57.8	82.3	48.1	53.8
w/ TTRL	46.7	69.1	89.3	53.0	64.5
Δ	+19.8	+11.3	+7.0	+4.9	+10.8
	↑ 73.6%	↑ 19.6%	↑ 8.5%	↑ 10.2%	↑ 20.0%

Benchmarks We evaluate **TTRL** on GPQA-Diamond (Rein et al., 2024), a challenging and high-quality subset of the Graduate-Level Google-Proof Question Answering benchmark, and 3 mathematical reasoning benchmarks: AIME 2024 (Li et al., 2024), AMC (Li et al., 2024), and MATH-500 (Hendrycks et al., 2021).

评估设置 我们将 TTRL 分别应用于每个基准，然后进行评估。除非另有说明，我们将最大生成长度设置为 3072 个标记。对于主要实验，遵循 DeepSeek-R1 (Guo 等人, 2025)，我们采用 pass@k 评估协议 (Chen 等人, 2021)，并使用非零温度采样报告 pass@1。具体来说，我们使用 0.6 的温度和 0.95 的 top-p 值，为每个问题生成 16 个响应 (32k 上下文为 4 个)。pass@1 分数计算如下：

$$\text{pass@1} = \frac{1}{k} \sum_{i=1}^k p_i,$$

其中 p_i 表示第 i 个响应是否正确。对于 **Qwen2.5-MATH** 上的分析和额外实验，我们使用贪婪解码进行评估以报告 pass@1，以确保与先前工作的公平比较。附录 B 展示了一组训练时度量，我们使用这些度量来监控 TTRL 的性能，并在缺乏真实标签的情况下分析其训练动态。

基线 由于使用 TTT 进行推理此前尚未被探索，我们主要将其与骨干模型进行比较，以验证 TTRL 能否通过自我进化实现有效改进。附录 A 展示了额外的实验结果，将 TTRL 与先前最先进的推理强化学习方法进行比较。

实现细节 我们在每个基准上独立应用 GRPO (Shao 等人, 2024) 来实现 TTRL。对于超参数, 我们使用峰值值为 5×10^{-7} 的余弦学习率调度, 并采用 AdamW 优化器来优化策略模型。对于采样, 我们使用 0.6 的温度 (Qwen2.5-Math 和 LRMs 为 1.0) 采样 64 个响应用于基于投票的标签估计, 并为训练下采样每个提示 32 个响应。证据表明, 我们的先投票后采样策略有效降低了计算成本, 同时仍能实现强大的性能。对于 LRMs, 最大生成长度设置为 32,768 个标记, 对于所有其他模型设置为 3,072 个标记。根据数据集大小, 我们将 MATH-500、AMC 和 AIME 2024 的回合数分别设置为 10、30 和 80。所有实验均在 8 * NVIDIA A100 80GB GPU 上进行。

3.2 主要结果

TTRL 在大多数任务上表现良好和模型上。

表 1 展示了主要结果。我们将 TTRL 应用于涵盖 4 个模型家族、2 种模型类型和 3 种模型规模的 6 个模型, 在 4 个极具挑战性的基准上一致地展示了显著的改进。在要求严格的数学推理基准 AIME 2024 上, TTRL 在所有 6 个模型上实现了至少 105% 的改进。此外, 将 TTRL 应用于 1.5B 模型在 MATH-500 上带来了高达

40.3 分的显著提升。最近,

Shao 等人 (2025) 证明了评估不同模型对于基于强化学习的方法以验证实验结论的重要性。因此, 我们额外报告了来自不同模型家族的更广泛模型的结果, 例如 DeepSeek-R1-LLaMA-8B, 这是一个在 LLaMA 模型上训练的来自 DeepSeek 的 LRM。表 2 展示了结果。如图所示, TTRL 继续表现出一致的有效性。此外, 如附录 A 所示, 尽管仅依赖于使用未标记测试数据的自我进化, TTRL 实现了与在大规模标记数据集上训练的现有基于强化学习的模型相当的性能。

表 2: TTRL 在各种模型上的性能。

Name	AIME	AMC	MATH-500
LLaMA Family			
LLaMA-3.2-3B-Oat-Zero	0.8	15.1	41.9
w/ TTRL	3.3	25.3	55.7
Δ	+2.5	+10.2	+13.8
LLaMA-3.2-3B-Instruct	6.0	19.4	43.9
w/ TTRL	13.3	31.3	61.6
Δ	+7.3	+11.9	+17.7
Mistral Family			
Mistral-Nemo-Instruct	0.8	15.4	40.8
w/ TTRL	0	24.8	51.0
Δ	-0.8	+9.4	+10.2
Ministral-8B-Instruct	1.3	19.7	52.4
w/ TTRL	3.3	28.9	57.8
Δ	+2.0	+9.2	+5.4
DeepSeek Family			
DeepSeek-Math-7B-Instruct	1.9	16.3	42.3
w/ TTRL	2.5	22.9	52.4
Δ	+0.6	+6.6	+10.1
DeepSeek-R1-LLaMA-8B	51.7	81.6	89.6
w/ TTRL	69.2	88.9	90.9
Δ	+17.5	+7.3	+1.3

测试时强化学习 (Test Time Reinforcement Learning, TTRL) 在大型推理模型上表现良好。随着强化学习与测试时缩放技术的快速进步, 大型推理模型正变得日益重要。为进一步检验测试时强化学习在已经过昂贵后训练的大型推理模型上是否依然有效, 尤其是在极具挑战性的任务上, 我们评估了另外两个强大的大型推理模型。图 3 展示了将测试时强化学习应用于其他推理模型的结果。Qwen3-8B 在思考模式下进行评估。尽管这些模型已经历了广泛的后训练, 测试时强化学习仍能带来显著的性能提升, 在两个骨干模型上均取得了约 10 个百分点的改进。




图 3: 测试时强化学习在大型推理模型上的表现。

测试时强化学习 (Test Time Reinforcement Learning, TTRL) 自然具备可扩展性。另一个值得注意的观察是，随着模型规模从 (1.5B $\rightarrow$ 7B 增加到 $\rightarrow$ 32B)，性能持续提升，这凸显了测试时强化学习的自然扩展行为：更大的模型在自我改进过程中能够产生更准确的多数投票奖励，从而在新数据上实现更有效的学习。

测试时强化学习 (Test Time Reinforcement Learning, TTRL) 在目标任务之外也具有良好的泛化能力。我们在每个基准上执行测试时强化学习，并以 Qwen2.5-Math-7B 为骨干模型，进一步使用贪心解码评估其他基准上的 pass@1 指标。图 4 展示了结果。尽管该设置具有分布外特性，测试时强化学习在所有基准上均取得了显著提升。这表明测试时强化学习并非依赖过拟合（过拟合会导致在其他任务上的性能权衡），而是在自我改进过程中获得了可泛化的增益。




图 4: 测试时强化学习前后的分布外性能。

测试时强化学习 (Test Time Reinforcement Learning, TTRL) 与不同的强化学习 (Reinforcement Learning, RL) 算法兼容。我们进一步在 MATH-500 上使用两种强化学习算法应用 TTRL 以评估其兼容性，这两种算法分别是 PPO (Schulman 等, 2017)，一种基于价值模式的方法，以及 PRIME (Cui 等, 2025)，一种过程级强化学习算法。图 5 展示了结果。GRPO、PPO 和 PRIME 的性能轨迹高度一致。




图 5: 使用 Qwen2.5-Math-1.5B 在 MATH-500 上比较不同强化学习算法 GRPO、PPO 和 PRIME 的步骤。

测试时强化学习 (TTRL) 通过“在线”和“强化学习 (RL)”实现可持续的自我进化。为了更深入地理解 TTRL 的底层机制，我们通过跟踪整个训练过程中的平均 (pass@1/avg@16) 和多数 (maj@16) 分数来分析模型的训练动态。鉴于多数投票是生成训练信号的基础，考察其性能轨迹对于理解其运作方式至关重要。此外，我们研究了 TTRL 是否以降低 maj@16 性能为代价来提高 pass@1。图 6 展示了 TTRL 的训练动态

在 AMC 上以 Qwen2.5-Math-1.5B 为基础模型。值得注意的是，随着训练的进行，**两个指标都呈现出一致的上升趋势**。这表明 TTRL 并非简单地接近初始模型的多数投票性能。由于其动态特性，TTRL 能够随着自身能力的提升生成更高质量的监督信号。此外，通过 TTRL 将强化学习用于测试时训练，将基于投票的伪标签转化为奖励信号，提升了有效监督质量（例如准确率；见 Q2 4.2），同时将学习与 maj@n 所施加的局限性解耦。




图 6：以 Qwen2.5-Math-1.5B 为基础模型，TTRL 在 AMC 上的训练动态。

4 分析与讨论

4.1 问题 1：TTRL 的性能表现如何？

Takeaways

1. TTRL 超越了传统自训练的上限，即初始模型的多数准确率。
2. TTRL 的经验上限是在带标签测试数据上直接进行强化学习（即在测试数据上训练）。TTRL 能够接近该上限的性能，凸显了其在效能上相对于标准训练-评估协议的潜在优势。
3. 对于具有挑战性的任务，TTRL 仅使用 1.5B 模型即可达到经验上限。这表明大语言模型现在能够通过 TTRL 高效地自我进化，从而在大规模数据集上实现无限终身学习。

我们利用两个上限来分析 TTRL 的潜在性能。第一个上限是初始模型的多数准确率（maj@n）。第二个上限是在基准数据上直接训练，这假设可以访问真实标签，从而向策略模型泄露标签信息。

测试时强化学习（TTRL）由多数准确率（maj@n）监督，却超越了它。由于 TTRL 利用模型自身多数投票输出进行强化学习，初始模型的这种基于投票的性能可直观地视为最终性能的上限。该上限也是传统自训练方法（Huang 等，2022）的性能极限，这些方法通过多数投票选择自生成的思维链用于监督微调（SFT）。然而，我们观察到一个令人惊讶的现象：训练后，模型不仅达到而且超越了预期的上限，表明其超过了原始模型的性能极限，而该原始模型也充当其初始监督信号。图 6 展示了这一显著结果，可以观察到最终 avg@16 分数超过初始 maj@16 分数 20 分以上。此外，我们在多个基准上对 **Qwen2.5-Math-7B** 进行了 TTRL 的额外评估，每个问题使用更多样本以实现更可靠的评估。图 7 显示了结果。可以观察到，TTRL avg@64 在所有基准上一致优于 **Qwen2.5-Math-7B** maj@64，且




图 7: 骨干模型与 TTRL 后多数投票性能比较。

差距相当大。通过自我强化循环，模型“依靠自身力量提升自己”，超越了预期的性能上限。此外，当应用多数投票时，TTRL 的性能进一步提升。

测试时强化学习（TTRL）的性能增益方法

在基准上训练。TTRL 的动机是利用多数投票估计标签以获得更准确的奖励，从而在没有真实标签的数据上通过强化学习实现有效的自我改进。因此，TTRL 的一个自然上限是直接测试数据上执行强化学习，记为 RL（泄漏）。尽管由于信息泄漏问题，这种设置很少被采用或研究，但它代表了在特定数据集上提升性能的最有效方式，其效率远超传统的训练-评估范式。我们使用 Qwen2.5-Math-7B 在 MATH-500 上执行 TTRL 和 RL（泄漏）并进行评估。图 8 显示了结果。令人惊讶的是，我们发现 TTRL 的性能曲线非常接近 RL（泄漏）的性能曲线。这表明：




图 8: RL（泄漏） vs TTRL 的比较。

1. TTRL 能够在无监督环境下通过强化学习达到与监督学习相当的自改进水平（即使在信息泄漏场景下也是如此），这表明其具有显著的效率和性能提升。
2. TTRL 提供了证据，表明即使是小型大语言模型现在也能通过强化学习在仅输入型挑战性任务上有效地进行自改进，从而实现持续学习。在 Qwen2.5-Math-1.5B 上的结果进一步支持了这一观察：从 MATH-500 上 32.7 的较差性能开始，该模型提升了 123.2%，达到 73.0，展示了通过 TTRL 实现的明显自改进。

4.2 问题二：TTRL 为何有效？

本节对使 TTRL 在无监督条件下实现稳定有效强化学习的因素进行了渐进式分析。我们的分析确定了三个关键因素：标签估计、奖励计算和在线学习。

标签估计。TTRL 与标准强化学习算法的一个直接区别在于 TTRL 涉及标签估计，这会引入奖励不准确。我们认为 TTRL 尽管存在这些不准确性仍能有效工作，原因如下两点。（一）现有研究




图 9: AIME 2024 上多数比例、标签准确率和奖励准确率随步骤变化的比较。即使标签准确率较低, 由于“幸运命中”, 奖励准确率仍然很高, 使 TTRL 能够提供可靠的训练信号。

表明强化学习能够容忍一定程度的奖励不准确。此外, 强化学习往往比监督微调具有更好的泛化能力, 后者通常依赖于记忆训练数据 (Chu 等人, 2025)。在强化学习中, 奖励通常是模糊的, 主要作为探索的方向性信号, 这导致了强化学习对奖励噪声的鲁棒性 (Razin 等人, 2025)。(二) 先前的工作还从优化角度研究了什么构成好的奖励模型, 揭示了更准确的奖励模型不一定是更好的教师 (Wang 等人, 2020)。因此, 由策略模型自身估计的奖励信号可能为学习提供更合适的指导。

奖励计算。当模型能够通过多数投票估计出准确标签时, 奖励及后续训练通常是可靠的。然而, 一个自然的问题是: 在诸如 AIME 2024 等具有挑战性的基准上, 即使模型无法通过多数投票估计出准确标签, TTRL 为何仍然有效? 最根本的原因在于验证器在强化学习中计算奖励的机制。对于数学等任务, 验证器基于“比较”来获得基于规则的奖励, 即检查预测答案是否与给定的“标签”匹配。这种机制可能导致“幸运命中”现象: 对于错误预测的答案, 即使估计的标签与真实标签不一致, 只要它与预测答案不同, 验证器仍会输出负奖励, 而这正是我们所期望的正确奖励, 如图 10 所示。换句话说, 只要估计的标签与预测答案不同, 就足以让验证器分配正确的负奖励。为了提供更详细的案例研究, 我们使用 Qwen2.5-Math-7B 考察了 TTRL 在 AIME 2024 上的表现。图 9 展示了附录 B 中所述的三个指标的变化曲线。我们确定了 TTRL 在 AIME 2024 上仍然有效的两个主要原因:




图 10: “幸运命中”的一个玩具案例。我们展示了一个基本的数值预测场景, 以比较两种条件下的奖励计算: 模型错误估计标签时与使用真实标签时。如左图所示, 尽管估计的标签不正确, 一些错误的预测仍然与错误标签不同, 因此获得了正确的奖励 (记为 0)。

1. 单次生成中多个输出带来的奖励鲁棒性。首先, 奖励比标签更密集, 即使在估计标签不准确的情况下, 也能有更多机会恢复有用的奖励信号。例如, 即使预测标签不正确, 同一次生成中的其他输出仍可能产生正确或高质量的奖励, 如图 10 所示; 而仅包含单个输出的生成则

输出无法提供这种灵活性。这使得整体奖励信号对伪标签估计中的错误更加鲁棒。2. 由于分散的错误预测导致高奖励准确率。其次，与直觉相反的是，当模型能力较弱时，TTRL 的多数投票奖励可能更加准确。如图 9 所示，尽管通过多数投票进行的初始标签估计准确率仅为 37%，但奖励准确率却达到了令人印象深刻的 92%。通过检查模型输出，我们发现这是因为模型的响应高度分散且持续错误，如图 10 所示。与这一观察结果一致的是，对于基础模型，最频繁预测的答案仅占有所有预测的 16.6%，表明输出高度分散。因此，即使标签未被准确估计，由于“幸运命中”，大多数输出仍能获得正确的奖励。此外，模型性能越差，它犯的错误就越多，这反而导致更准确的奖励估计。支持这一观点的实证观察是标签准确率与奖励准确率之间的比较，如图 9 所示。

尽管标签准确率很少超过 50%，但奖励准确率始终保持较高水平，稳定在 75% 以上。这种高奖励准确率为在测试数据上进行有效的自我改进提供了可靠的基础。

在线学习。 TTRL 而传统的

自训练和测试时训练方法以离线方式运行。TTRL 的在线特性使模型能够在应用过程中提升其能力，进而通过投票生成更准确的标签。因此，监督信号的质量得到改善，从而实现真正可持续的自我进化。如图 6 所示，这种动态学习过程导致 pass@1 和 maj@n 的性能互补提升。

4.3 问题 3: TTRL 何时可能失败?

在算法层面，测试时强化学习（TTRL）与现有强化学习算法并无本质区别，因此继承了其若干特性，例如对数据难度的敏感性、对先验知识的强依赖，以及在特定条件下崩溃的风险。在实现层面，这些问题因 TTRL 的约束而进一步加剧：TTRL 通过多数投票估计标签，并且仅在既稀疏又未曾见过的测试数据上运行，这可能导致在某些场景下失败。在我们的初步实验中，我们发现了两个潜在问题：

不恰当的强化学习超参数。超参数设置在强化学习训练中起着至关重要的作用，不同项目间差异很大²，并且常常导致训练失败。在 TTRL 中，由于奖励估计可能存在噪声以及测试数据的特性，超参数的影响被进一步放大。图 11 展示了在 AIME 2024 上几次不成功尝试的比较。这些失败的尝试均表现出持续的高熵，且在整个训练过程中没有降低，这与先前工作的发现一致（He 等人，2025）。在我们的初步实验中，我们确定了两个可能严重影响训练稳定性和成功的关键超参数：




图 11: 失败的尝试。我们比较了在参数设置合适与温度及训练批大小设置不佳情况下的曲线。

- **温度：**将温度设置为 1.0（而非 0.6）会增加模型的输出熵。这促进了更广泛的探索，并使模型能够² <https://github.com/TsinghuaC3I/Awesome-RL-Reasoning-Recipes>

表 3: TTRL 在 MATH-500 五个难度级别上的性能。

Metric	Name	MATH-500-L1	MATH-500-L2	MATH-500-L3	MATH-500-L4	MATH-500-L5
Accuracy	Backbone	25.9	33.0	36.3	32.5	22.3
	w/ TTRL	71.2	76.2	76.3	58.7	39.2
	Δ	+45.4	+43.2	+40.0	+26.2	+16.8
		$\uparrow 175.3\%$	$\uparrow 130.8\%$	$\uparrow 110.2\%$	$\uparrow 80.4\%$	$\uparrow 75.3\%$
Response Len.	Backbone	2,339.2	2,125.1	2,120.6	1,775.1	1,751.3
	w/ TTRL	624.3	614.4	672.3	783.5	985.3
	Δ	-1,715.0	-1,510.6	-1,448.3	-991.6	-766.0
		$\downarrow 73.3\%$	$\downarrow 71.1\%$	$\downarrow 68.3\%$	$\downarrow 55.9\%$	$\downarrow 43.7\%$

更好地利用其先验知识进行自我改进，这在应对具有挑战性的基准时尤为重要。

- **回合数：**鉴于各数据集在规模与难度上存在显著差异，规模较小且难度较高的数据集需要更多回合才能实现充分探索。

目标任务先验知识不足。先验知识在强化学习中起着至关重要的作用，往往决定测试时强化学习过程的成败³。这主要是因为测试数据通常难度更高且引入新特征，而测试时强化学习并未引入数据过滤等机制来支持课程学习。

因此，对于同一骨干模型，若模型的先验知识不足以应对数据复杂度，测试时强化学习便会失败。为进一步验证该假设，我们在数学 500 数据集上进行了消融实验。我们根据标注的难度等级（1 至 5 级）将数学 500 划分为五个子集，并分别对每个子集独立应用测试时强化学习，使用通义千问 2.5 数学 1.5B 模型。随后我们将结果与骨干模型进行对比，如表 3 所示。我们观察到，随着题目难度增加，性能提升幅度与长度缩减比例均呈下降趋势。这表明骨干模型可用的先验知识不足以支持在更具挑战性的题目上进行学习。

5 相关工作

5.1 测试时扩展

测试时扩展（Test-Time Scaling, TTS）旨在通过在测试时增加计算资源来增强大语言模型（Large Language Models, LLMs）处理复杂任务的能力。先前的研究（Snell 等，2024；Liu 等，2025a）表明，TTS 比预训练期间的扩展（Kaplan 等，2020）更高效。因此，将相同的计算资源从预训练重新分配到测试时，可能会带来更大的模型性能提升。当前关于 TTS 的研究分为两类（Welleck 等，2024）：并行生成和顺序生成。并行生成涉及 LLMs 在推理过程中产生多个候选响应（自洽性（Wang 等，2022；Chen 等，2023）、N 中选优（Stiennon 等，2020；Nakano 等，2021））、决策步骤（蒙特卡洛树搜索（Zhou 等，2023；Xie 等，2024））或标记（奖励引导搜索（Deng & Raffel，2023；Khanov 等，2024））。随后，应用聚合策略来整合这些候选，通常使用过程奖励模型（Lightman 等，2023；Wang 等，2023；Zhang 等，2025a）。同时，顺序生成侧重于扩展 LLMs 的输出，以包含具有反思和思维链（CoT）过程的更长响应（Wei 等，2022；Madaan 等，2023）。尽管提示技术被广泛采用，但它们往往受到底层模型能力的限制。值得注意的是，DeepSeek-R1（Guo 等，2025）是该领域的一项代表性进展，通过基于结果的强化学习（RL），更具体地说是群体相对策略优化（Shao

³<https://ysymyth.github.io/The-Second-Half/>

等, 2024), 在预训练语言模型中实现了扩展的推理能力。与需要密集过程级监督的第一种方法相比 (Yuan 等, 2024), 第二种方法由于依赖于基于规则的奖励而更具可扩展性。

除了上述专注于扩展测试时推理计算的方法之外, 另一种增加测试时计算的方法是测试时训练 (Test-Time Training, TTT)。我们在附录 C 中介绍了这些术语之间的关系。虽然先前的工作主要集中在视频生成和理解等应用上 (Hardt & Sun, 2024; Dalal 等, 2025), 并在一定程度上涉及大语言模型 (Wang 等, 2025a; Akyürek 等, 2024), 但测试时扩展与强化学习的整合在很大程度上仍未得到充分探索。

5.2 用于推理的强化学习

强化学习 (Reinforcement Learning, RL) (Sutton 等, 1998) 在提升大语言模型 (Large Language Models, LLMs) 的指令遵循能力方面发挥着关键作用, 尤其是通过基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF) 等方法 (Ouyang 等, 2022)。RLHF 利用近端策略优化 (Proximal Policy Optimization, PPO) 等算法 (Schulman 等, 2017) 使基础模型与人类偏好对齐, 其中偏好建模至关重要。近期, 大型推理模型 (Large Reasoning Models, LRM), 如 DeepSeek-R1 (Guo 等, 2025), 展示了强化学习在利用基于规则的奖励提升推理能力方面的显著性, GRPO (Shao 等, 2024) 即为典型例子。与针对开放域指令定制的 RLHF 不同, GRPO 专门设计用于在数学问题求解中引出长思维链 (Chain-of-Thought, CoT) (Wei 等, 2022) 推理。近期的研究主要聚焦于提升基于规则的强化学习方法 (如 GRPO 和 PPO) 的训练稳定性 (Cui 等, 2025; Yu 等, 2025; Liu 等, 2025b)。然而, 这些方法通常仅在监督训练数据上训练大语言模型, 而推理过程则涉及在未见过的测试问题上生成扩展的思维链推理。此外, 当前的强化学习方法 (Hu 等, 2025a; Wei 等, 2025) 依赖于可验证的输出——例如数学或代码中的解——以提供可靠的奖励信号。

以往研究探索了针对无标签数据的自我奖励 (Yuan et al., 2025; Prasad et al., 2024) 与自我博弈训练 (Chen et al., 2024)。然而, 这些工作主要聚焦于开放域指令遵循 (Yuan et al., 2025; Chen et al., 2024), 而非数学推理, 或采用基于偏好的优化策略 (Prasad et al., 2024), 如直接偏好优化 (DPO) (Rafailov et al., 2023), 而非在线强化学习算法。除上述研究外, 我们还识别出若干同期工作 (Xu et al., 2025; Zhang et al., 2025b; Zhao et al., 2025), 它们利用类强化学习方法探索自监督与半监督推理。关键区别在于奖励估计: 我们采用多数投票, 该投票源自模型自身, 可缓解奖励黑客行为。近期, Wang et al. (2025b) 证明, 使用单个训练样本来激励大语言模型的数学推理能力是有效的, 即使在最小监督下也能带来显著提升。我们认识到, 未来研究若能整合这些方法的洞见与优势, 有望在经验时代 (Silver & Sutton, 2025) 催生更稳健的推理模型。测试时强化学习 (TTRL) 为使用自标记奖励的强化学习提供了初步尝试, 朝着从经验流中学习迈进。

6 结论

本文提出测试时强化学习 (TTRL), 一种新颖的框架, 用于在测试数据上通过强化学习 (RL) 训练大语言模型, 而无需访问真实标签。TTRL 的关键组件是其多数投票奖励函数, 该函数基于模型预测间的共识生成基于规则的奖励。我们的实验证明了 TTRL 的强大潜力, 在多种模型与任务上取得了一致的改进。我们将 TTRL 视为迈向自标记奖励强化学习的初步步骤, 标志着从连续经验流中学习的重要方向。

7 局限性与未来工作

局限性 本文初步探索了利用自标记奖励的测试时强化学习。尽管实验结果令人鼓舞，但仍有若干方面需要进一步研究。特别是，我们计划更深入地分析先验知识与超参数配置的影响，这两者在强化学习动态中均扮演关键角色。我们将在本文的未来修订版中提供全面的讨论与消融研究。

未来工作 基于我们的发现，我们确定了未来研究的几个方向：

- **理论分析：** 建立测试时强化学习的形式化收敛分析，特别关注其向第 4.1 节中两个上界优化的能力。
- **基于流式数据的在线学习：** 将测试时强化学习扩展到实时学习场景，使模型能够与持续到达的数据交互并动态适应，即测试时自适应 (Liang 等人, 2025)。
- **大规模自监督强化学习训练：** 将 TTRL 扩展到大规模数据集和模型，以探索其在无人工标注数据的自监督机制中的潜力。
- **智能体任务与科学发现：** 将 TTRL 应用于更复杂、开放式的领域，如智能体任务和多步骤科学推理。

参考文献

- Ekin Akyürek, Mehul Damani, Linlu Qiu, Han Guo, Yoon Kim, and Jacob Andreas. The surprising effectiveness of test-time training for abstract reasoning. *arXiv preprint arXiv:2411.07279*, 2024.
- Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. Titans: Learning to memorize at test time. *arXiv preprint arXiv:2501.00663*, 2024.
- Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde De Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.
- Xinyun Chen, Renat Aksitov, Uri Alon, Jie Ren, Kefan Xiao, Pengcheng Yin, Sushant Prakash, Charles Sutton, Xuezhi Wang, and Denny Zhou. Universal self-consistency for large language model generation. *arXiv preprint arXiv:2311.17311*, 2023.
- Zixiang Chen, Yihe Deng, Huizhuo Yuan, Kaixuan Ji, and Quanquan Gu. Self-play fine-tuning converts weak language models to strong language models. *arXiv preprint arXiv:2401.01335*, 2024.
- Tianzhe Chu, Yuexiang Zhai, Jihan Yang, Shengbang Tong, Saining Xie, Dale Schuurmans, Quoc V Le, Sergey Levine, and Yi Ma. Sft memorizes, rl generalizes: A comparative study of foundation model post-training. *arXiv preprint arXiv:2501.17161*, 2025.
- Ganqu Cui, Lifan Yuan, Zefan Wang, Hanbin Wang, Wendi Li, Bingxiang He, Yuchen Fan, Tianyu Yu, Qixin Xu, Weize Chen, et al. Process reinforcement through implicit rewards. *arXiv preprint arXiv:2502.01456*, 2025.
- Karan Dalal, Daniel Kocaja, Gashon Hussein, Jiarui Xu, Yue Zhao, Youjin Song, Shihao Han, Ka Chun Cheung, Jan Kautz, Carlos Guestrin, et al. One-minute video generation with test-time training. *arXiv preprint arXiv:2504.05298*, 2025.
- Haikang Deng and Colin Raffel. Reward-augmented decoding: Efficient controlled text generation with a unidirectional reward model. *arXiv preprint arXiv:2310.09520*, 2023.
- Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Alex Vaughan, et al. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.
- Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- Moritz Hardt and Yu Sun. Test-time training on nearest neighbors for large language models, 2024. URL <https://arxiv.org/abs/2305.18466>.
- Jujie He, Jiacai Liu, Chris Yuhao Liu, Rui Yan, Chaojie Wang, Peng Cheng, Xiaoyu Zhang, Fuxiang Zhang, Jiacheng Xu, Wei Shen, Siyuan Li, Liang Zeng, Tianwen Wei, Cheng Cheng, Bo An, Yang Liu, and Yahui Zhou. Skywork open reasoner series. <https://capricious-hydrogen-41c.notion.site/Skywork-Open-Reasoner-Series-1d0bc9ae823a80459b46c149e4f51680>, 2025. Notion Blog.
- Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. *arXiv preprint arXiv:2103.03874*, 2021.
- Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, Xiangyu Zhang, and Heung-Yeung Shum. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. *arXiv preprint arXiv:2503.24290*, 2025a.
- Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, Xiangyu Zhang, and Heung-Yeung Shum. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model, 2025b. URL <https://arxiv.org/abs/2503.24290>.

- Jiaxin Huang, Shixiang Shane Gu, Le Hou, Yuexin Wu, Xuezhi Wang, Hongkun Yu, and Jiawei Han. Large language models can self-improve. *arXiv preprint arXiv:2210.11610*, 2022.
- Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. Openai o1 system card. *arXiv preprint arXiv:2412.16720*, 2024.
- Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- Maxim Khanov, Jirayu Burapachee, and Yixuan Li. Args: Alignment as reward-guided search. *arXiv preprint arXiv:2402.01694*, 2024.
- Jia Li, Edward Beeching, Lewis Tunstall, Ben Lipkin, Roman Soletskyi, Shengyi Huang, Kashif Rasul, Longhui Yu, Albert Q Jiang, Ziju Shen, et al. Numinamath: The largest public dataset in ai4maths with 860k pairs of competition math problems and solutions. *Hugging Face repository*, 13:9, 2024.
- Xuefeng Li, Haoyang Zou, and Pengfei Liu. Limr: Less is more for rl scaling. *arXiv preprint arXiv:2502.11886*, 2025.
- Jian Liang, Ran He, and Tieniu Tan. A comprehensive survey on test-time adaptation under distribution shifts. *International Journal of Computer Vision*, 133(1):31–64, 2025.
- Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. In *The Twelfth International Conference on Learning Representations*, 2023.
- Runze Liu, Junqi Gao, Jian Zhao, Kaiyan Zhang, Xiu Li, Biqing Qi, Wanli Ouyang, and Bowen Zhou. Can 1b llm surpass 405b llm? rethinking compute-optimal test-time scaling. *arXiv preprint arXiv:2502.06703*, 2025a.
- Zichen Liu, Changyu Chen, Wenjun Li, Penghui Qi, Tianyu Pang, Chao Du, Wee Sun Lee, and Min Lin. Understanding r1-zero-like training: A critical perspective. *arXiv preprint arXiv:2503.20783*, 2025b.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. Self-refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems*, 36: 46534–46594, 2023.
- Minstral-8B-Instruct. Minstral-8b-instruct, 2024. URL <https://mistral.ai/news/ministraux>.
- MistralAI-NeMo. Mistralai-nemo, 2024. URL <https://mistral.ai/news/mistral-nemo>.
- Reiichiro Nakano, Jacob Hilton, Suchir Balaji, Jeff Wu, Long Ouyang, Christina Kim, Christopher Hesse, Shantanu Jain, Vineet Kosaraju, William Saunders, et al. Webgpt: Browser-assisted question-answering with human feedback. *arXiv preprint arXiv:2112.09332*, 2021.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730–27744, 2022.
- Archiki Prasad, Weizhe Yuan, Richard Yuanzhe Pang, Jing Xu, Maryam Fazel-Zarandi, Mohit Bansal, Sainbayar Sukhbaatar, Jason Weston, and Jane Yu. Self-consistency preference optimization. *arXiv preprint arXiv:2411.04109*, 2024.
- Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36:53728–53741, 2023.

- Noam Razin, Zixuan Wang, Hubert Strauss, Stanley Wei, Jason D Lee, and Sanjeev Arora. What makes a reward model a good teacher? an optimization perspective. *arXiv preprint arXiv:2503.15477*, 2025.
- David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. Gpqa: A graduate-level google-proof q&a benchmark. In *First Conference on Language Modeling*, 2024.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Rulin Shao, Shuyue Stella Li, Rui Xin, Scott Geng, Yiping Wang, Sewoong Oh, Simon Shaolei Du, Nathan Lambert, Sewon Min, Ranjay Krishna, et al. Spurious rewards: Rethinking training signals in rlvr. *arXiv preprint arXiv:2506.10947*, 2025.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- David Silver and Richard S Sutton. Welcome to the era of experience. *Google AI*, 2025.
- Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*, 2024.
- Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. Learning to summarize with human feedback. *Advances in neural information processing systems*, 33:3008–3021, 2020.
- Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A Efros, and Moritz Hardt. Test-time training for out-of-distribution generalization. *Arxiv*, 2019.
- Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. Learning to (learn at test time): Rnns with expressive hidden states. *arXiv preprint arXiv:2407.04620*, 2024.
- Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.
- Jingkang Wang, Yang Liu, and Bo Li. Reinforcement learning with perturbed rewards. In *Proceedings of the AAAI conference on artificial intelligence*, volume 34, pp. 6202–6209, 2020.
- Peiyi Wang, Lei Li, Zhihong Shao, RX Xu, Damai Dai, Yifei Li, Deli Chen, Yu Wu, and Zhifang Sui. Math-shepherd: Verify and reinforce llms step-by-step without human annotations. *arXiv preprint arXiv:2312.08935*, 2023.
- Renhao Wang, Yu Sun, Arnub Tandon, Yossi Gandelsman, Xinlei Chen, Alexei A Efros, and Xiaolong Wang. Test-time training on video streams. *Journal of Machine Learning Research*, 26(9):1–29, 2025a.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*, 2022.
- Yiping Wang, Qing Yang, Zhiyuan Zeng, Liliang Ren, Liyuan Liu, Baolin Peng, Hao Cheng, Xuehai He, Kuan Wang, Jianfeng Gao, et al. Reinforcement learning for reasoning in large language models with one training example. *arXiv preprint arXiv:2504.20571*, 2025b.
- Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.

- Yuxiang Wei, Olivier Duchenne, Jade Copet, Quentin Carbonneaux, Lingming Zhang, Daniel Fried, Gabriel Synnaeve, Rishabh Singh, and Sida I Wang. Swe-rl: Advancing llm reasoning via reinforcement learning on open software evolution. *arXiv preprint arXiv:2502.18449*, 2025.
- Sean Welleck, Amanda Bertsch, Matthew Finlayson, Hailey Schoelkopf, Alex Xie, Graham Neubig, Ilia Kulikov, and Zaid Harchaoui. From decoding to meta-generation: Inference-time algorithms for large language models. *arXiv preprint arXiv:2406.16838*, 2024.
- Yuxi Xie, Anirudh Goyal, Wenyue Zheng, Min-Yen Kan, Timothy P Lillicrap, Kenji Kawaguchi, and Michael Shieh. Monte carlo tree search boosts reasoning via iterative preference learning. *arXiv preprint arXiv:2405.00451*, 2024.
- Fangzhi Xu, Hang Yan, Chang Ma, Haiteng Zhao, Qiushi Sun, Kanzhi Cheng, Junxian He, Jun Liu, and Zhiyong Wu. Genius: A generalizable and purely unsupervised self-training framework for advanced reasoning. *arXiv preprint arXiv:2504.08672*, 2025.
- An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, et al. Qwen2 technical report. *arXiv preprint arXiv:2407.10671*, 2024a.
- An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiayi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, and Zihan Qiu. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024b.
- Qiyang Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Tiantian Fan, Gaohong Liu, Lingjun Liu, Xin Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025.
- Lifan Yuan, Wendi Li, Huayu Chen, Ganqu Cui, Ning Ding, Kaiyan Zhang, Bowen Zhou, Zhiyuan Liu, and Hao Peng. Free process rewards without process labels. *arXiv preprint arXiv:2412.01981*, 2024.
- Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason Weston. Self-rewarding language models, 2025. URL <https://arxiv.org/abs/2401.10020>.
- Weihao Zeng, Yuzhen Huang, Qian Liu, Wei Liu, Keqing He, Zejun Ma, and Junxian He. Simplerl-zoo: Investigating and taming zero reinforcement learning for open base models in the wild, 2025. URL <https://arxiv.org/abs/2503.18892>.
- Kaiyan Zhang, Jiayuan Zhang, Haoxin Li, Xuekai Zhu, Ermo Hua, Xingtai Lv, Ning Ding, Binqing Qi, and Bowen Zhou. Openprm: Building open-domain process-based reward models with preference trees. In *The Thirteenth International Conference on Learning Representations*, 2025a.
- Qingyang Zhang, Haitao Wu, Changqing Zhang, Peilin Zhao, and Yatao Bian. 正确的问题已是答案的一半: 完全无监督的大语言模型推理激励. *arXiv 预印本 arXiv:2504.05812*, 2025b.
- Andrew Zhao, Yiran Wu, Yang Yue, Tong Wu, Quentin Xu, Yang Yue, Matthieu Lin, Shenzhi Wang, Qingyun Wu, Zilong Zheng, and Gao Huang. Absolute zero: Reinforced self-play reasoning with zero data, 2025. URL <https://arxiv.org/abs/2505.03335>.
- Andy Zhou, Kai Yan, Michal Shlapentokh-Rothman, Haohan Wang, and Yu-Xiong Wang. Language agent tree search unifies reasoning acting and planning in language models. *arXiv preprint arXiv:2310.04406*, 2023.


A 附加结果

表 4 展示了使用贪心解码的 pass@1 结果。对于两个基础模型，我们进一步与经过大规模后训练的指令版本进行了比较。此外，我们参考了当前领先的具有相似骨干的“R1-Zero-Like”模型，这些模型使用强化学习进行了广泛训练：DeepSeek-R1-Distill-1.5B&7B (Guo et al., 2025)、SimpleRL-Zero-7B (Zeng et al., 2025)、PRIME-Zero-7B (Cui et al., 2025)、OpenReasoner-Zero-7B (Hu et al., 2025b)、Oat-Zero-1.5B&7B (Liu et al., 2025b) 和 LIMR (Li et al., 2025)。请注意，TTRL 与之前的模型设置不同，这使得比较似乎不公平。


在极具挑战性的数学推理基准 AIME 2024 上，TTRL 实现了 159.3% 的显著提升，超越了所有在大规模数据集上训练的模型。此外，当应用于 Qwen2.5-Math-7B 时，TTRL 在三个基准上平均提升了 84.1%。图 12 以 Qwen2.5-Math-7B 为例，展示了 TTRL 在 AIME 2024 上的两条曲线。

表 4: TTRL 在每个任务上的额外结果。* 表示来自 Dr. GRPO (Liu 等人, 2025b) 的结果。我们的训练数据规模与对应的基准数据集规模一致。

Name	AIME 2024	AMC	MATH-500	Avg	Labeled Data
Qwen2.5-Math-1.5B*	20.0	32.5	33.0	28.5	-
w/ TTRL	20.0	53.0	80.0	51.0	✗
Δ	0	+20.5	+47.0	+22.5	✗
	0	↑ 63.1%	↑ 142.4%	↑ 79.0%	✗
Qwen2.5-Math-1.5B-Instruct*	10.0	48.2	74.2	44.1	3.1M
DeepSeek-R1-Distill-1.5B@3k*	2.5	21.7	52.2	25.5	800K
DeepSeek-R1-Distill-1.5B@8k*	20.0	49.4	77.4	48.9	800K
Oat-Zero-1.5B*	20.0	53.0	74.2	49.1	8.9K
Qwen2.5-Math-7B*	16.7	38.6	50.6	35.3	-
w/ TTRL	43.3	67.5	84.2	65.0	✗
Δ	+26.6	+28.9	+33.6	+29.7	✗
	↑ 159.3%	↑ 74.9%	↑ 66.4%	↑ 84.1%	✗
Qwen2.5-Math-7B-Instruct*	16.7	53.0	83.6	51.1	3.1M
DeepSeek-R1-Distill-7B@3k*	10.0	26.2	60.1	32.1	800K
SimpleRL-Zero-7B*	26.7	60.2	78.2	55.0	8.9K
PRIME-Zero-7B*	16.7	62.7	83.8	54.4	230K
OpenReasoner-Zero-7B@3k*	13.3	47.0	79.2	46.5	129K
Oat-Zero-7B*	43.3	62.7	80.0	62.0	8.9K
LIMR-7B	32.5	63.8	78.0	58.1	1.4K



(a) Accuracy Curve.



(b) Entropy Curve.

图 12: TTRL 在 AIME 2024 上使用 Qwen2.5-Math-7B 的熵和准确率曲线。

B 训练度量

鉴于测试数据中缺乏真实标签，评估 TTRL 在整个训练过程中的性能是一项挑战。为缓解这一局限性，本文引入一组专门设计的训练时度量，用于监控和评估 TTRL 的有效性。这些度量为选择最优检查点提供依据，并揭示训练动态的宝贵洞见。

- **熵**：衡量模型生成的不确定性。
- **多数投票奖励**：基于多数投票标签计算的规则奖励。
- **多数比例**：单次展开中最常见答案的出现频率。

此外，本文定义了若干依赖真实标签的度量指标，以便更深入地分析模型在训练过程中的行为：

- **标签准确率 (maj@n)**：表示估计标签是否与真实标签一致。
- **奖励准确率**：表示由估计标签计算得到的多数投票奖励中，与由真实标签计算得到的奖励相匹配的比例。
- **真实比例**：真实答案在单次生成中的出现频率。

C 术语

测试时扩展是指在测试阶段增加计算资源，可分为测试时训练与测试时推理两类。这两种方法互为补充，下文将分别介绍。

表 5: 术语对应关系。

名称	类别	方法	测试时扩展 (TTS)	测试时训练 (TTT)	测试时推理 (TTI)	测试时强化学习 (TTRL)	多数投票、最优 N 选一
----	----	----	-------------	-------------	-------------	----------------	--------------

C.1 测试时训练 (TTT)

测试时训练 (TTT) 是一种在推理阶段对预训练模型进行自适应调整的技术，旨在提升模型在分布偏移下的泛化能力。设 f_θ 表示在源域 $\mathcal{D}_s = \{(x_i, y_i)\}_{i=1}^N$ 上训练的模型，其中 $x_i \in \mathcal{X}, y_i \in \mathcal{Y}$ ， θ 为学习到的参数。在标准推理过程中，模型以固定参数 θ 对测试样本 $x_t \sim \mathcal{D}_t$ 进行评估，其中 $\mathcal{D}_t \neq \mathcal{D}_s$ 。

相比之下，测试时训练 (TTT) 允许模型通过最小化辅助自监督损失 $\mathcal{L}_{\text{aux}}$ 来适应每个测试样本 x_t ，而无需访问标签 y_t 。模型参数通过辅助任务在线更新，该任务通常设计为无标签且与主任务一致。

C.2 测试时推理 (TTI)

测试时推理 (TTI) 是指在推理过程中通过分配额外计算资源来提升大语言模型性能的策略。形式上，设 f_θ 表示参数为 θ 的语言模型， x 为输入提示。模型通过从条件分布 $p_\theta(y | x)$ 中采样生成输出 y 。TTI 技术旨在通过生成多个候选输出并基于评分函数选择最佳输出，或通过迭代过程优化输出，从而提高 y 的质量 (Welleck 等, 2024)。

一种常见方法是生成 N 个候选输出 $\{y_1, y_2, \dots, y_N\}$ ，并使用评分函数 $s(y, x)$ 选择最优输出 y^* ：

$$y^* = \arg \max_{y_i} s(y_i, x) \quad (4)$$

评分函数 $s(y, x)$ 可以通过多种方式实例化，例如：

1. 多数投票 (MV)：在候选中选择出现频率最高的输出。
2. 最优 N 选 (BoN)：使用奖励模型对每个候选进行评分，然后选择得分最高的输出。
3. 加权最优 N 选：结合多数投票和最优 N 选策略，以发挥各自优势。