

基于掩码自编码器的测试时训练

Yossi Gandelsman*
UC Berkeley

Yu Sun*
UC Berkeley

Xinlei Chen
Meta AI

Alexei A. Efros
UC Berkeley

摘要

测试时训练通过利用自监督为每个测试输入优化模型，从而即时适应新的测试分布。本文采用掩码自编码器解决这一单样本学习问题。实验表明，该简单方法在多种视觉基准上改善了分布偏移下的泛化性能。理论上，本文从偏差-方差权衡的角度刻画了这一改进。

1 引言

泛化是监督学习的核心主题，也是智能的标志。尽管多数研究关注训练与测试数据来自同一分布时的泛化，但在实际部署中这种情况很少见 [42]，在自然智能出现的环境中更是如此。

如今大多数模型在部署期间保持固定，即使测试分布发生变化。因此，训练好的模型需要对未来可能发生的所有分布偏移具有鲁棒性 [22, 14, 45, 33]。事实证明这相当困难，因为为所有可能的未来做好准备会限制模型在任一特定未来上表现优异的能力。但实际发生的未来只有一个。

这促使我们采用另一种泛化视角：与其为一切做好准备，不如在未来到来时简单地适应它。测试时训练 (TTT) 正是采用这一视角的一类工作 [41, 32, 18, 1]。其关键洞见在于，每个测试输入都提供了关于测试分布的线索。我们在测试时修改模型，通过设置单样本学习问题来利用这一线索。

唯一的问题是测试输入没有真实标签。但借助自监督学习，我们可以从输入本身生成标签。在训练时，TTT 同时优化主任务（如物体识别）和自监督任务。然后在测试时，对每个测试输入仅用自监督任务调整模型，再对主任务进行预测。

自监督任务的选择至关重要：它必须足够通用，以便在广泛的潜在测试分布上为主任务产生有用的特征。自监督任务不能太简单或太难，否则测试输入将无法提供有用的信号。什么是难度适中的通用任务？我们转向自然图像共享的一个基本属性——空间平滑性，即 xy 空间中信息的局部冗余。空间自编码——移除部分数据，然后预测被移除的内容——构成了一些最成功的自监督任务的基础 [46, 37, 19, 2, 48]。

本文表明，掩码自编码器 (MAE) [19] 非常适合测试时训练。我们的简单方法在四个目标识别数据集上带来了显著的改进。我们还利用线性模型对方法进行了理论分析。代码和模型可在 https://yossigandelsman.github.io/ttt_mae/index.html 获取。

* 同等贡献。

2 相关工作

本文研究分布偏移下的泛化问题。我们首先回顾该问题设置下的相关工作，以及相关的无监督领域自适应设置。然后讨论测试时训练和空间自编码，这是本文算法的两个组成部分。

2.1 问题设置

分布偏移下的泛化。当训练分布与测试分布不同时，若无法获取来自测试分布的训练数据，泛化本质上十分困难。通过在一种分布偏移（如高斯噪声）上训练或微调所获得的鲁棒性，往往无法迁移到另一种分布偏移（如椒盐噪声），即使二者在视觉上相似 [14, 45]。目前，常见做法是使用更宽的训练分布来完全避免分布偏移，希望该分布能包含测试分布——这需要更多的训练数据或数据增强 [22, 50, 10]。

无监督领域自适应。一种更简单但更具限制性的设置是，除了来自训练分布（源域）的数据外，还使用一些来自测试分布（目标域）的无标签训练数据 [29, 30, 7, 4, 39, 24, 5, 17]。之所以更简单，是因为直观上大部分分布偏移发生在输入而非标签上，因此测试分布的大部分信息在训练时已通过数据获知。之所以更具限制性，是因为训练出的模型仅对预先准备好数据的特定测试分布有效。

2.2 测试时训练

在无标签测试数据上进行训练的想法由来已久。其最早实现是直推学习，始于 20 世纪 90 年代 [13]。弗拉基米尔·瓦普尼克 [44] 将直推原理表述为：“尝试得到你真正需要答案，而不是一个更一般的答案。”这一原理最常应用于支持向量机 [43, 6, 26]，通过利用测试数据为决策边界的间隔添加额外约束。另一条早期研究路线是局部学习 [3, 49]：对于每个测试输入，在做出预测之前，基于最近邻训练一个“局部”模型。

在计算机视觉领域，[25] 通过利用测试图像中较易检测的人脸来引导同一图像中较难检测的人脸，从而改进人脸检测。[35] 通过在一个人的几张面部图像上进行微调，创建个性化生成模型。[38] 针对每张测试图像从头训练用于超分辨率的神经网络。[34] 通过使用学生模型在测试视频上从教师模型在线学习，使视频分割更加高效。这些只是视觉研究人员认为在部署期间继续训练很自然的几个例子。

测试时训练（Test-time Training, TTT）[41] 提出这一思想，作为监督学习在分布偏移下泛化问题的一种解决方案。该方法通过自监督为每个测试输入生成不同的模型。此方法也已应用于多个领域，并采用领域特定的自监督任务：基于视觉的强化学习 [18]、腿部运动 [40]、视频中的目标跟踪 [12]、自然语言问答 [1]，甚至医学影像 [27]。

[41] 采用的自监督前置任务是旋转预测 [15]：将每个输入在图像平面内旋转 90 度的倍数，并将角度预测视为四分类问题。该任务的通用性有限，因为它往往过于简单或过于困难。对于自然户外场景，仅通过检测地平线方向即可完成旋转预测，无需进一步的场景理解，因此可能过于简单。另一方面，对于俯视图，许多类别（如青蛙和蜥蜴）的旋转预测过于困难，因为每个方向看起来都同样合理。

TTT [41] 也可以被视为单样本无监督领域自适应（Unsupervised Domain Adaptation, UDA）——在第 2.1 小节中讨论。UDA 使用来自测试分布（目标域）的大量无标签样本；TTT 仅使用一个目标样本，并构成一种特殊情况——该样本可以是测试输入本身。我们发现这一思想在两个方面具有强大优势：1) 我们不再需要预先准备任何目标数据。

2) 学习到的模型不再需要对其他目标数据进行泛化——它只需要“过拟合”到单个训练样本，因为该样本就是测试样本。

继 [41] 之后的其他论文研究了相关但不同的问题设置，假设可以访问来自同一分布的整个测试输入数据集（如 TTT++ [28]）或批次（如 TENT [47]）。本文不做此类假设，而是独立评估每个单独的测试样本。




图 1: 我们在测试时训练一个掩码自编码器 (MAE) 来重建每张测试图像, 掩蔽 75% 的输入图像块。右侧的三张重建图像可视化了这个单样本学习问题的进展。主任务——目标识别——的损失 (绿色) 即使在 500 步梯度下降后仍在持续下降, 而网络继续优化重建损失 (红色)。未掩蔽的图像块未在右侧显示, 因为它们不属于重建损失的一部分。

2.3 通过空间自编码实现自监督

利用自编码器进行表示学习可追溯至 [46]。在计算机视觉领域, 最早的工作之一是上下文编码器 [37], 它根据上下文预测随机图像区域。近期工作 [19, 2, 48] 将空间自编码与视觉变换器 (ViT) [11] 相结合, 达到了最先进的性能。最成功的工作是掩码自编码器 (MAE) [19]: 它将每张图像分割成许多 (例如 196 个) 图像块, 随机掩蔽其中大部分 (例如 75%), 并通过优化原始像素与重建像素之间的均方误差来训练模型重建缺失的图像块。

MAE 预训练一个大型编码器和一个小型解码器, 两者均为视觉变换器 [11]。只有编码器用于下游任务, 例如目标识别。编码器特征成为任务特定线性投影头的输入。将预训练编码器与未训练头结合有两种常见方式。

- 1) 微调: 编码器和头一起端到端训练, 用于下游任务。
- 2) 线性探测: 编码器被冻结为固定特征提取器, 仅训练头。我们将在下一节回顾这些训练选项。

3 方法

从高层次来看, 我们的方法简单地将掩码自编码器 [19] 替换为测试时训练 (TTT) [41] 中的自监督部分。在实践中, 实现这一目标涉及许多设计选择。

架构。本文架构呈 Y 形 (如 [41] 所示): 一个特征提取器 f 同时后接自监督头 g 和主任务头 h 。此处, f 正是 MAE 的编码器, g 为解码器, 二者均为 ViT。我们有意不对其进行修改, 以便与 [19] 进行清晰比较。对于主任务 (例如目标识别) 头 h , [19] 采用从编码器特征维度到类别数的线性投影。作者讨论 h 为线性层, 认为这主要是历史工件。我们还尝试了更具表达力的主任务头——整个 ViT-Base——以增强基线。

训练设置。遵循标准做法, 我们从 [19] 作者提供的 MAE 模型开始, 该模型具有 ViT-Large 编码器, 在 ImageNet-1k[9] 上进行了重建预训练。将编码器与未训练的主任务头结合有三种方式: 微调、探测和联合训练。我们对这三种方式均进行了实验, 并基于以下考虑选择以 h 为 ViT-Base 的探测方式 (即 ViT 探测) 作为默认设置:

- 1) 微调: 端到端训练 $h \circ f$ 。这种方式在 TTT 下效果不佳, 因为它不鼓励两个任务之间的特征共享。微调使编码器在训练时专精于识别, 但随后 TTT 使编码器在测试时专精于重建, 从而丢失 h 所依赖的仅识别特征。出于同样原因, [41] 未使用微调。




图 2: 我们为 TTT 实验了两种优化器。MAE[19] 在预训练中使用 AdamW。但我们的结果（左）显示，TTT 使用 AdamW 需要早停，这在没有验证集的情况下对未知分布的泛化是不现实的。我们改用 SGD，即使在 20 步之后性能仍持续提升（右）。

2) ViT 探测: 仅训练 h ，冻结 f 。此处 h 为 ViT-Base，而非线性探测所用的线性层。ViT 探测比微调和联合训练都轻量得多，其训练参数量甚至比线性微调少 3.5 倍（86M 对 306M）。在 ImageNet 验证集上，无需激进的数据增强，其准确率也高于线性微调。

3) 联合训练: 同时训练 $h \circ f$ 和 $g \circ f$ ，将二者的损失相加。[41] 采用旋转预测的方式使用此方法。但就我们目前的能力而言，在 ImageNet 验证集上，使用 MAE 的联合训练表现不如线性/ViT 探测。若未来工作能为联合训练基线找到可靠的方案，我们的方法可轻松修改以适应。

训练时训练。 将 MAE 预训练产生的编码器记为 f_0 （解码器记为 g_0 ，后续用于 TTT）。我们的默认设置 ViT 探测产生一个训练好的主任务头 h_0 ：

$$h_0 = \arg \min_h \frac{1}{n} \sum_{i=1}^n l_m(h \circ f_0(x_i), y_i). \quad (1)$$

求和遍历包含 n 个样本的训练集，每个样本由输入 x_i 和标签 y_i 组成。在我们的案例中，主任务损失 l_m 为分类所用的交叉熵损失。注意，我们仅优化主任务头，而预训练编码器 f_0 保持冻结。

数据增强。 在训练时训练阶段，我们的默认设置仅使用图像裁剪和水平翻转作为数据增强，遵循 [19] 中预训练和线性探测的协议。然而，[19]（及 [2, 48]）中的微调在上述两种增强之外还添加了激进的数据增强，包括亮度、对比度、颜色和锐度的随机变化¹。其中许多实际上是我们评估基准中的分布偏移。为了研究对新测试分布的泛化能力，使用这些增强进行训练类似于在测试集上训练。因此，我们选择不使用这些增强，尽管它们表面上会改善我们的结果。

测试时训练。 在测试时，我们从视觉变换器（ViT）探测产生的主任务头 h_0 ，以及掩码自编码器（MAE）预训练的编码器 f_0 和解码器 g_0 开始。每当每个测试输入 x 到达时，我们为测试时训练（TTT）优化以下损失：

$$f_x, g_x = \arg \min_{f, g} l_s(g \circ f(\text{mask}(x)), x). \quad (2)$$

自监督重建损失 l_s 计算解码补丁相对于真实值的逐像素均方误差。在测试时训练之后，我们对 x 进行预测，结果为 $h \circ f_x(x)$ 。注意，方程 2 的基于梯度的优化总是从 f_0 和 g_0 开始。在测试集上评估时，[19] 中微调使用的其他增强方法有：插值、均衡化、反转、色调分离、日晒、旋转、剪切、随机擦除和平移。这些方法取自随机增强 [8]。




图 3: ImageNet-C 第 5 级的准确率 (%)。我们的方法 TTT-MAE 在基线之上显著提升, 而基线已经优于 [41] 的方法。详见第 4.2 小节。我们的基线和 TTT-MAE 的数值可在表 2 的最后两行找到。Sun 等人的数值取自 [41]。

在测试集上, 对每个测试输入 x 做出预测后, 我们总是丢弃 f_x 和 g_x , 并将权重重置为 f_0 和 g_0 , 用于下一个测试输入。通过对测试输入独立进行测试时训练, 我们不假设它们来自同一分布。

测试时训练的优化器。在 [41] 中, 测试时训练的优化器选择很直接: 它简单地采用自监督任务训练时训练最后一个轮次相同的优化器设置。然而, 这一选择对我们不可用, 因为 MAE 的学习率调度在预训练结束时降为零。我们尝试了 AdamW[31] 和带动量的随机梯度下降 (SGD) 的各种学习率。两者在各自最佳学习率下的性能如图 2 所示。

AdamW 在 [19] 中使用, 但对于测试时训练, 迭代次数过多会损害性能。另一方面, 使用 SGD 进行更多迭代在所有分布偏移上持续提升性能。即使经过 20 次迭代, 测试准确率仍在提高。这对于测试时训练非常理想: 单个测试图像是我们对测试分布的全部了解, 因此没有验证集来调整超参数或监控性能以进行早停。使用 SGD, 我们可以简单地继续训练。

4 实证结果

4.1 实现细节

在所有实验中, 我们使用基于 [19] 中 ViT-Large 编码器的 MAE, 该编码器在 ImageNet-1k[9] 上预训练了 800 个训练轮次。我们的 ViT-Base 头 h 以预训练 MAE 编码器输出的图像特征作为输入。中间有一个线性层将这些特征调整为适合头的输入尺寸, 就像 [19] 中编码器和解码器之间的做法一样。在头的最终类别标记之后还附加了一个线性层, 以产生分类 logits。

TTT 使用 SGD 进行, 如前所述, 共 20 步, 动量为 0.9, 权重衰减为 0.2, 批大小为 128, 固定学习率为 $5e-3$ 。选择 20 步纯粹是出于计算考虑; 从图 2 观察到的趋势来看, 更多步骤可能会略微提升性能。大多数实验在四块 NVIDIA A100 GPU 上进行; 超参数搜索在配备 V100 GPU 的工业集群上运行。

与预训练类似, 在 TTT 期间, 只有非掩码补丁的标记被送入编码器, 而解码器接收所有标记。TTT 批次中的每张图像都有不同的随机掩码。我们使用与 MAE[19] 相同的掩码比例: 75%。在 TTT 中, 除了随机掩码之外, 我们不使用任何数据增强。具体来说, TTT 的每次迭代都在图像的同一个 224×224 中心裁剪上执行, 该裁剪与我们稍后用于预测的裁剪相同; 唯一的区别是预测是在没有掩码的图像上进行的。

在 TTT 期间, 我们同时优化编码器和解码器的权重, 以及类别标记和掩码标记。我们尝试过冻结解码器, 发现即使经过多次 SGD 迭代, 差异也可以忽略不计; 详细比较见附录中的表 11。这与 [41] 中的观察结果一致。我们还尝试了带归一化像素和不带归一化像素的重建损失,

	<i>Frost</i>		<i>JPEG</i>		<i>Brightness</i>		<i>Elastic</i>	
	[41]	Ours	[41]	Ours	[41]	Ours	[41]	Ours
Jellyfish	-3	0	-6	5	2	-1	-2	3
Holster	-1	4	-2	6	1	0	-1	14
Chiton	-1	3	-3	8	-1	2	-3	8
Fire salamander	1	3	-1	3	2	5	2	2
Spaghetti squash	-3	4	-2	5	2	3	1	6

表 1: TTT 后 (-Rot 和 -MAE) 正确分类图像数量的变化, 每个类别共 50 张。在这些旋转不变类别上, TTT-Rot[41] 损害了性能, 而 TTT-MAE 仍然有帮助, 这得益于 MAE 作为自监督任务的通用性。四种损坏类型被选为 TTT-Rot 基线中最准确的类别。

如 [19] 中所做的那样。我们的方法在两种情况下都表现良好, 但在归一化像素上略好, 因为基线也略好。我们也在附录中包含了这些结果。

4.2 ImageNet-C

ImageNet-C [22] 是一个用于分布偏移下目标识别的基准。它包含 ImageNet [9] 验证集的副本, 带有 15 种损坏类型, 每种损坏有 5 个严重程度级别。由于篇幅限制, 正文中的结果除非另有说明, 均基于最严重的第 5 级。其他四个级别的结果见附录。该基准的示例图像也见附录中的图 4。

本着将这些分布偏移视为真正未知的精神, 我们不使用来自这些损坏的训练数据、先验知识或数据增强。这符合基准的既定规则, 即损坏应仅用于评估, 被评估的算法不应针对特定损坏 [22]。我们认为, 这一规则有助于社区进步: 研究评估之外的众多分布偏移无法预料, 如果算法依赖于特定于少数测试分布的信息, 则无法扩展。

主要结果。我们在 ImageNet-C 上的主要结果见图 3。按照 [41] 中的惯例, 我们仅绘制第 5 级损坏上的准确率。其他级别的结果见附录。这里的所有结果均使用第 3 节讨论的默认训练设置: 采用预训练的 MAE 编码器, 然后在原始 ImageNet 训练集上进行 ViT 探测以进行目标识别。我们的基线 (绿色) 将固定模型应用于损坏的测试集。TTT-MAE (红色) 在我们的基线上显著提升了性能。

比较重建与旋转预测。TTT-Rot 的基线取自 [41], 在图 3 中称为联合训练 (Joint Train)。这是一个 16 层的 ResNet [20], 经过旋转预测和目标识别的联合训练。由于我们的基线比 ResNet 基线先进得多, 前者在所有损坏类型上 (对比度除外) 已经优于 TTT-Rot 的报告结果。²因此, 与 [41] 的比较在相对意义上更有意义: TTT-MAE 在各自基线之上, 在所有损坏类型上的性能增益均高于 TTT-Rot。

旋转不变类别。如第 2 节所述, 旋转预测 [15] 往往过于困难而难以发挥作用, 这与空间自编码等更通用的任务形成对比。事实上, 我们发现整个类别

² 结果表明, 对于对比度损坏类型, TTT-Rot 的 ResNet 基线远优于我们的 ViT 基线, 尽管后者规模更大; 然而, TTT-MAE 仍然在 ViT 基线上有所改进。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Joint Train	62.3	4.5	26.7	39.9	25.7	30.0	5.8	16.3	5.8	45.3	30.9	45.9	7.1	25.1	31.8
Fine-Tune	67.5	7.8	33.9	32.4	36.4	38.2	22.0	15.7	23.9	51.2	37.4	51.9	23.7	37.6	37.1
ViT Probe	68.3	6.4	24.2	31.6	38.6	38.4	17.4	18.4	18.2	51.2	32.2	49.7	18.2	35.9	32.2
TTT-MAE	69.1	9.8	34.4	50.7	44.7	50.7	30.5	36.9	32.4	63.0	41.9	63.0	33.0	42.8	45.9

表 2: ImageNet-C 上的准确率 (%), 损坏级别 5。前三行是未进行测试时训练的固定模型, 比较了第 3 节讨论的三种设计选择。第三行 ViT 探测是本文默认基线, 其数值与图 3 中的基线相同。最后一行是我们的方法: ViT 探测后的 TTT-MAE。该方法在所有损坏类型上均达到最佳性能, 其数值与图 3 中的 TTT-MAE 相同。

这些类别具有旋转不变性, 表 1 展示了其中的随机示例。³ 不出所料, 这些图像通常采用俯视视角拍摄; 对它们进行旋转预测只能记忆辅助标签, 而无法按预期形成语义特征。这导致 [41] 的 TTT-Rot 在这些类别上损害性能, 如表 1 所示。同样不出所料的是, TTT-MAE 对旋转不变性不敏感, 在这些类别上仍然有所帮助。

训练时训练。在第 3 节中, 我们讨论了选择 ViT 探测而非微调或联合训练的原因。表 2 的前三行比较了这三种设计的准确率。如前所述, 联合训练在大多数损坏类型上未能达到令人满意的性能。虽然微调初始表现优于 ViT 探测, 但它不适合 TTT。前三行仅涉及训练时训练, 之后在测试期间应用固定模型。最后一行是 ViT 探测后的 TTT-MAE, 在所有损坏类型上表现最佳。最后两行的数值分别与图 3 中的基线 (ViT 探测) 和 TTT-MAE 相同。

4.3 其他 ImageNet 变体

我们在另外两个流行的分布偏移基准上评估 TTT-MAE。ImageNet-A[23] 包含真实世界、未经修改且自然出现的示例, 在这些示例上流行的 ImageNet 模型表现不佳。ImageNet-R[21] 包含 ImageNet 类别的艺术再现, 例如艺术、卡通和折纸。TTT-MAE 和基线使用相同的模型和算法, 超参数与 ImageNet-C (第 4.2 小节) 完全相同。我们的方法继续以较大优势超越基线: 见表 4.4。

4.4 肖像数据集

肖像数据集 (Portraits dataset) [16] 包含按性别标注的美国高中年鉴照片, 时间跨度超过一个世纪。它包含了多年来视觉外观上的真实世界分布偏移。我们将整个数据集按年份排序, 并均分为四部分, 每部分包含 5062 张图像。在四个划分之间, 存在可见的低层差异, 如模糊度和对比度, 以及高层变化, 如发型和微笑。⁴ 我们创建了三个实验: 对于每个实验, 我们在前三个划分之一上训练, 并在第四个划分上测试。性能通过二元性别分类的准确率来衡量。正如预期的那样, 随着训练划分在时间上更接近测试划分, 基线性能略有提升。

我们的模型是相同的 ImageNet 预训练 MAE + ViT-Base (使用 Sigmoid 函数进行二元分类), 并在训练划分上进行探测。我们使用与 TTT 完全相同的超参数。结果如表 4 所示。我们的方法在所有三个实验中都优于基线。

³ 我们通过以下步骤找到这 5 个类别: 1) 从 PyTorch 官方网站 [36] 获取 ImageNet 预训练的 ResNet-18。2) 在原始验证集和旋转 90 度的副本上运行它。3) 剔除原始准确率低于 60% 的类别。4) 对于每个剩余的类别, 比较原始图像与旋转图像上的准确率, 并选择归一化差异最小的 5 个类别。⁴ 肖像数据集仅由加州大学伯克利分校的作者访问。

<i>ImageNet-A</i>		<i>ImageNet-R</i>	
Baseline	TTT-MAE	Baseline	TTT-MAE
15.3	21.3	31.3	38.9

表 3: ImageNet-A [23] 和 ImageNet-R [21] 上的准确率 (%) ; 详见第 4.3 小节。基线是 ViT 探测——默认设置——在原始 ImageNet 训练集上训练; 实际上与 ImageNet-C 使用的模型相同。我们的方法在两个数据集上都优于基线, 使用与论文其余部分相同的超参数。

Train Split	1	2	3
Baseline	76.1	76.5	78.2
TTT-MAE	76.4	76.7	79.4

表 4: 肖像数据集上二元分类的准确率 (%) ; 详见第 4.4 小节。对于每一列, 我们在指定的划分上训练, 并在第四个划分上测试。基线仍然是 ViT 探测 (除了末尾使用 Sigmoid 函数)。我们的方法在所有三个训练划分上都优于基线。我们使用与论文其余部分相同的超参数进行常规训练和 TTT。

5 理论结果

为什么测试时训练 (TTT) 有帮助? [41] 的理论给出了一个直观但浅显的解释: 当自监督任务恰好传播与主任务梯度相关的梯度时。但这种回避性的理论只是将一个未知量——测试分布, 委托给另一个未知量——具有相关梯度的神奇自监督任务, 而没有真正回答问题, 也没有给出这种自监督任务的具体例子。

在本文中, 我们证明自编码, 即重构, 是一种使测试时训练 (TTT) 有帮助的自监督任务。为了以最小的数学开销做到这一点, 我们将自己限制在线性世界中, 其中我们的模型是线性的, 分布偏移由线性变换产生。我们分析使用降维而非掩码的自编码, 因为我们认为两者在本质上是密切相关的。

在我们看来, 最具启发性的洞见是, 在分布偏移下, 测试时训练 (TTT) 找到了比应用固定模型更好的偏差-方差权衡。固定模型是有偏差的, 因为它完全基于有偏差的训练数据, 这些数据不能代表新的测试分布。另一个极端是完全忘记训练数据, 在每个测试输入上从头训练一个新模型; 这也是不可取的, 因为单个测试输入虽然按定义是无偏的, 但方差很高。

偏差-方差权衡的一个最佳点是执行测试时训练 (TTT), 同时以某种方式记住训练数据。在深度学习中, 这通常通过使用训练好的模型初始化随机梯度下降 (SGD) 来实现, 就像我们的论文和 [41] 中那样。在本节中, 我们通过使用从训练数据导出的协方差矩阵的一部分来保留记忆。

众所周知, 线性自编码等价于主成分分析 (PCA)。这种等价性通过为训练和测试时训练期间的优化问题提供闭式解来简化数学。在本节的其余部分, 我们遵循理论界的惯例, 使用术语主成分分析 (PCA) 而不是线性自编码。

问题设置。 设 $x, y \sim P$ 为训练分布, 并假设总体协方差矩阵 $\Sigma = \text{Cov}(x)$ 是已知的。主成分分析 (PCA) 对 $\Sigma = UDU^\top$ 进行谱分解, 并取前 k 个特征向量 $u_1, \dots, u_k$ 将 $x \in \mathbb{R}^d$ 投影到 $\mathbb{R}^k$ 。在本节中, 我们将 u_i 表示为矩阵 U 的第 i 列, 其他矩阵同理。

假设对于每个 x , 真实值 y 是主成分分析 (PCA) 投影的线性函数, 其中 $k = 1$:

$$y = wu_1^\top x, \quad (3)$$

对于某个已知权重 $w \in \mathbb{R}$ 。为了数学上的便利，我们还对特征值（即 D 的对角元素）作如下假设：

$$\sigma_1 > \sigma_2 = \sigma_3 = \dots = \sigma_d = \sigma. \quad (4)$$

在测试时，自然抽取一个新的 $x, y \sim P$ ，但我们只能观察到 $\tilde{x}$ ，它是 x 的损坏版本。我们将损坏建模为未知的正交变换 R ，以及 $\tilde{x} = Rx$ 。

算法。 基线方法是直接应用固定模型并预测

$$\hat{y} = wu_1^\top \tilde{x}, \quad (5)$$

作为 y 的估计。直观上，如果损坏严重，即 R 远离 I ，这种预测将不准确。现在我们推导测试时训练的主成分分析版本。我们首先利用 $\tilde{x}$ （我们关于损坏的唯一信息）构造一个新的（且相当平凡的）协方差矩阵。设 $\alpha \in [0, 1]$ 为超参数。然后将 Σ 与新的协方差矩阵进行线性组合：

$$M(\alpha) = (1 - \alpha) \cdot \Sigma + \alpha \cdot \tilde{x}\tilde{x}^\top. \quad (6)$$

将其谱分解记为 $M(\alpha) = V(\alpha) \cdot S(\alpha) \cdot V^\top(\alpha)$ 。然后我们预测

$$\hat{y} = wv_1^\top \tilde{x}. \quad (7)$$

偏差-方差权衡。 $\alpha = 0$ 等价于基线，而 $\alpha = 1$ 意味着我们仅使用单个测试输入并完全忘记训练数据。从统计角度看， α 呈现出偏差-方差权衡： $\alpha \downarrow 0$ 意味着更大的偏差， $\alpha \uparrow 1$ 意味着更大的方差。

定理。 定义预测风险为 $\mathbb{E}[|\hat{y} - y|]$ ，其中期望取自被破坏的测试分布。当 $\alpha = 0$ 时，该风险被严格支配。也就是说，具有某些超参数选择 $\alpha > 0$ 的 TTT 平均而言严格优于基线。

证明见附录。

关于假设的说明。 方程 3 中的假设是温和的；它基本上只是说主成分分析在训练分布上至少是有帮助的。在此背景下假设 Σ 和 w 已知也是温和的，因为随着训练集的增大，估计的协方差矩阵和权重会渐近地接近总体真实值。方程 6 中关于特征值的假设极大地简化了数学推导，但我们的分析在缺少该假设时应该存在更复杂的版本。最后，我们相信我们的一般性陈述对于可逆线性变换而非正交变换仍然成立，因为它们具有相同的直觉。

6 局限性

我们的方法在测试时比应用固定模型的基线更慢。推理速度并非本文的重点。通过更好的超参数、优化器、训练技术和架构设计，速度可能会得到改善。由于深度学习工具箱的大部分已经针对大规模数据集上的常规训练进行了优化，因此在测试时训练方面仍有很大的改进空间。

虽然空间自编码是一种通用的自监督任务，但不能保证它能为每个主任务、在每个测试分布上都产生有用的特征。我们的工作仅涵盖一个主任务——物体识别，以及少数几个最流行的分布偏移基准。

从长远来看，我们认为类人的泛化能力最有可能在类人的环境中出现。我们当前评估机器学习模型的范式——将独立同分布的图像收集到测试集中——与人类的感知体验相去甚远。更接近人类体验的将是视频流，其中测试时训练自然具有更大的潜力，因为自监督学习不仅可以对当前帧进行，还可以对过去的帧进行。

致谢与资助披露

作者感谢 Yeshwanth Cherapanamjeri 在定理证明方面的帮助，以及 Assaf Shocher 的校对。Yu Sun 感谢其共同导师 Moritz Hardt 的持续支持。Yossi Gandelsman 由伯克利奖学金资助。伯克利作者部分由 DARPA MCS 和 ONR MURI 资助。

参考文献

- [1] Pratyay Banerjee, Tejas Gokhale, and Chitta Baral. Self-supervised test-time learning for reading comprehension. *arXiv preprint arXiv:2103.11263*, 2021.
- [2] Hangbo Bao, Li Dong, and Furu Wei. Beit: BERT pre-training of image transformers. *CoRR*, abs/2106.08254, 2021.
- [3] Léon Bottou and Vladimir Vapnik. Local learning algorithms. *Neural computation*, 4(6):888–900, 1992.
- [4] Minmin Chen, Kilian Q Weinberger, and John Blitzer. Co-training for domain adaptation. In *Advances in neural information processing systems*, pages 2456–2464, 2011.
- [5] Xilun Chen, Yu Sun, Ben Athiwaratkun, Claire Cardie, and Kilian Weinberger. Adversarial deep averaging networks for cross-lingual sentiment classification. *Transactions of the Association for Computational Linguistics*, 6:557–570, 2018.
- [6] Ronan Collobert, Fabian Sinz, Jason Weston, Léon Bottou, and Thorsten Joachims. Large scale transductive svms. *Journal of Machine Learning Research*, 7(8), 2006.
- [7] Gabriela Csurka. Domain adaptation for visual applications: A comprehensive survey. *arXiv preprint arXiv:1702.05374*, 2017.
- [8] Ekin D. Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V. Le. Randaugment: Practical data augmentation with no separate search. *CoRR*, abs/1909.13719, 2019.
- [9] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248–255. Ieee, 2009.
- [10] Samuel Dodge and Lina Karam. Quality resilient deep neural networks. *arXiv preprint arXiv:1703.08119*, 2017.
- [11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [12] Yang Fu, Sifei Liu, Umar Iqbal, Shalini De Mello, Humphrey Shi, and Jan Kautz. Learning to track instances without video annotations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8680–8689, 2021.
- [13] A. Gammerman, V. Vovk, and V. Vapnik. Learning by transduction. In *In Uncertainty in Artificial Intelligence*, pages 148–155. Morgan Kaufmann, 1998.
- [14] Robert Geirhos, Carlos RM Temme, Jonas Rauber, Heiko H Schütt, Matthias Bethge, and Felix A Wichmann. Generalisation in humans and deep neural networks. In *Advances in Neural Information Processing Systems*, pages 7538–7550, 2018.
- [15] Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations. *arXiv preprint arXiv:1803.07728*, 2018.
- [16] Shiry Ginosar, Kate Rakelly, Sarah Sachs, Brian Yin, and Alexei A. Efros. A century of portraits: A visual historical record of american high school yearbooks. *CoRR*, abs/1511.02575, 2015.
- [17] Boqing Gong, Yuan Shi, Fei Sha, and Kristen Grauman. Geodesic flow kernel for unsupervised domain adaptation. In *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pages 2066–2073. IEEE, 2012.
- [18] Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A Efros, Lerrel Pinto, and Xiaolong Wang. Self-supervised policy adaptation during deployment. *arXiv preprint arXiv:2007.04309*, 2020.
- [19] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross B. Girshick. Masked autoencoders are scalable vision learners. *CoRR*, abs/2111.06377, 2021.
- [20] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [21] Dan Hendrycks, Steven Basart, Norman Mu, Saurav Kadavath, Frank Wang, Evan Dorundo, Rahul Desai, Tyler Zhu, Samyak Parajuli, Mike Guo, Dawn Song, Jacob Steinhardt, and Justin Gilmer. The many faces of robustness: A critical analysis of out-of-distribution generalization. *ICCV*, 2021.
- [22] Dan Hendrycks and Thomas G. Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. *CoRR*, abs/1903.12261, 2019.
- [23] Dan Hendrycks, Kevin Zhao, Steven Basart, Jacob Steinhardt, and Dawn Song. Natural adversarial examples. *CVPR*, 2021.

- [24] Judy Hoffman, Eric Tzeng, Taesung Park, Jun-Yan Zhu, Phillip Isola, Kate Saenko, Alexei A Efros, and Trevor Darrell. Cycada: Cycle-consistent adversarial domain adaptation. *arXiv preprint arXiv:1711.03213*, 2017.
- [25] Vidit Jain and Erik Learned-Miller. Online domain adaptation of a pre-trained cascade of classifiers. In *CVPR 2011*, pages 577–584. IEEE, 2011.
- [26] Thorsten Joachims. *Learning to classify text using support vector machines*, volume 668. Springer Science & Business Media, 2002.
- [27] Neerav Karani, Ertunc Erdil, Krishna Chaitanya, and Ender Konukoglu. Test-time adaptable neural networks for robust medical image segmentation. *Medical Image Analysis*, 68:101907, 2021.
- [28] Yuejiang Liu, Parth Kothari, Bastien van Delft, Baptiste Bellot-Gurlet, Taylor Mordan, and Alexandre Alahi. Ttt++: When does self-supervised test-time training fail or thrive? *Advances in Neural Information Processing Systems*, 34, 2021.
- [29] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael I Jordan. Learning transferable features with deep adaptation networks. *arXiv preprint arXiv:1502.02791*, 2015.
- [30] Mingsheng Long, Han Zhu, Jianmin Wang, and Michael I Jordan. Unsupervised domain adaptation with residual transfer networks. In *Advances in Neural Information Processing Systems*, pages 136–144, 2016.
- [31] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- [32] Xuan Luo, Jia-Bin Huang, Richard Szeliski, Kevin Matzen, and Johannes Kopf. Consistent video depth estimation. *ACM Transactions on Graphics (ToG)*, 39(4):71–1, 2020.
- [33] Chengzhi Mao, Lu Jiang, Mostafa Dehghani, Carl Vondrick, Rahul Sukthankar, and Irfan Essa. Discrete representations strengthen vision transformer robustness. *arXiv preprint arXiv:2111.10493*, 2021.
- [34] Ravi Teja Mullapudi, Steven Chen, Keyi Zhang, Deva Ramanan, and Kayvon Fatahalian. Online model distillation for efficient video inference. *arXiv preprint arXiv:1812.02699*, 2018.
- [35] Yotam Nitzan, Kfir Aberman, Qiurui He, Orly Liba, Michal Yarom, Yossi Gandelsman, Inbar Mosseri, Yael Pritch, and Daniel Cohen-Or. Mystyle: A personalized generative prior. *arXiv preprint arXiv:2203.17272*, 2022.
- [36] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d’Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 8024–8035. Curran Associates, Inc., 2019.
- [37] Deepak Pathak, Philipp Krahenbuhl, Jeff Donahue, Trevor Darrell, and Alexei A Efros. Context encoders: Feature learning by inpainting. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2536–2544, 2016.
- [38] Assaf Shocher, Nadav Cohen, and Michal Irani. “zero-shot” super-resolution using deep internal learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3118–3126, 2018.
- [39] Yu Sun, Eric Tzeng, Trevor Darrell, and Alexei A Efros. Unsupervised domain adaptation through self-supervision. *arXiv preprint*, 2019.
- [40] Yu Sun, Wyatt L Ubellacker, Wen-Loong Ma, Xiang Zhang, Changhao Wang, Noel V Csomay-Shanklin, Masayoshi Tomizuka, Koushil Sreenath, and Aaron D Ames. Online learning of unknown dynamics for model-based controllers in legged locomotion. *IEEE Robotics and Automation Letters*, 6(4):8442–8449, 2021.
- [41] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *International Conference on Machine Learning*, pages 9229–9248. PMLR, 2020.
- [42] Antonio Torralba and Alexei A Efros. Unbiased look at dataset bias. In *CVPR 2011*, pages 1521–1528. IEEE, 2011.
- [43] Vladimir Vapnik. *The nature of statistical learning theory*. Springer science & business media, 2013.
- [44] Vladimir Vapnik and S. Kotz. *Estimation of Dependences Based on Empirical Data: Empirical Inference Science (Information Science and Statistics)*. Springer-Verlag, Berlin, Heidelberg, 2006.
- [45] Igor Vasiljevic, Ayan Chakrabarti, and Gregory Shakhnarovich. Examining the impact of blur on recognition by convolutional networks. *arXiv preprint arXiv:1611.05760*, 2016.

- [46] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. ICML '08, page 1096–1103, New York, NY, USA, 2008. Association for Computing Machinery.
- [47] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. *arXiv preprint arXiv:2006.10726*, 2020.
- [48] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim: A simple framework for masked image modeling. In *International Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [49] Hao Zhang, Alexander C Berg, Michael Maire, and Jitendra Malik. Svm-knn: Discriminative nearest neighbor classification for visual category recognition. In *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06)*, volume 2, pages 2126–2136. IEEE, 2006.
- [50] Stephan Zheng, Yang Song, Thomas Leung, and Ian Goodfellow. Improving the robustness of deep neural networks via stability training. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4480–4488, 2016.

检查清单

1. 对于所有作者...

(a) 摘要和引言中的主要声明是否准确反映了论文的贡献和范围? [是] (b) 您是否描述了工作的局限性? [是] (c) 您是否讨论了工作潜在的负面社会影响? [N/A] (d) 您是否阅读了伦理审查指南并确保论文符合要求? [是] 2. 如果您包含理论结果...

(a) 是否陈述了所有理论结果的全部假设? [是]

(b) 是否包含了所有理论结果的完整证明? [是] 3. 如果进行了实验……

(a) 是否提供了复现主要实验结果所需的代码、数据和说明（在补充材料中或以网址形式）? [是] 代码和数据将在录用后发布。

(b) 是否说明了所有训练细节（例如数据划分、超参数及其选择方式）? [是] (c) 是否报告了误差线（例如多次运行实验后关于随机种子的误差）? [N/A] 遵循 [19] 及许多其他大规模实验的惯例。

(d) 是否说明了所使用的总计算量和资源类型（例如 GPU 类型、内部集群或云服务商）? [是] 4. 如果使用了现有资产（例如代码、数据、模型）或整理/发布了新资产……

(a) 如果工作使用了现有资产，是否引用了创建者? [是]

(b) 是否提及了资产的许可证? [是] 在附录中

(c) 是否在补充材料中或以网址形式包含了任何新资产?
[N/A]

(d) 您是否讨论了在获取所使用或整理数据的人群的同意时，是否以及如何获得了同意?

[N/A] (e) 您是否讨论了所使用或整理的数据是否包含个人身份信息或冒犯性内容?

[N/A] 5. 如果您使用了众包或进行了涉及人类受试者的研究……

(a) 是否包含了提供给参与者的完整说明文本及截图（如有）
适用吗? [N/A]

(b) 您是否描述了任何潜在的参与者风险，并在适用的情况下附上机构审查委员会（IRB）的批准链接? [N/A] (c) 是否包含了支付给参与者的估计时薪以及用于参与者补偿的总金额? [N/A]

A 附录

A.1 定理 1 的证明

证明。由于旋转对称性，只需考虑 $U = I$ 的情况，因此 $\Sigma = D$ 。

我们首先计算相应分解的导数：

$$\tilde{x}\tilde{x}^\top - \Sigma =: \dot{M}(\alpha) = \dot{V}(\alpha) \cdot S(\alpha) \cdot V^\top(\alpha) + V(\alpha) \cdot \dot{S}(\alpha) \cdot V^\top(\alpha) + V(\alpha) \cdot S(\alpha) \cdot \dot{V}^\top(\alpha).$$

由 $V^\top(\alpha) \cdot V(\alpha) = I$ 及上述展示，我们得到：

$$\begin{aligned} \dot{V}^\top(\alpha)V(\alpha) + V^\top(\alpha)\dot{V}(\alpha) &= 0 \\ \dot{S}(\alpha) + V^\top(\alpha) \cdot \dot{V}(\alpha) \cdot S(\alpha) + S(\alpha) \cdot \dot{V}^\top(\alpha) \cdot V(\alpha) &= V^\top(\alpha) \cdot \dot{M}(\alpha) \cdot V(\alpha). \end{aligned}$$

上述展示现在表明 $V^\top(\alpha) \cdot \dot{V}(\alpha)$ 是斜对称的，因此我们得到：

$$\begin{aligned} \dot{S}(\alpha) &= I \odot (V^\top(\alpha) \cdot \dot{M}(\alpha) \cdot V(\alpha)) \\ \forall i \neq j : (V^\top(\alpha) \cdot \dot{V}(\alpha))_{ij} &= \frac{(V^\top(\alpha) \cdot \dot{M}(\alpha) \cdot V(\alpha))_{ij}}{\sigma_j(\alpha) - \sigma_i(\alpha)}. \end{aligned}$$

现在，我们限制在 $\alpha = 0$ 且 $V(\alpha) = I$ 的情形，并得到：

$$\dot{V}_{i1} = \frac{(\tilde{x}\tilde{x}^\top - \Sigma)_{i1}}{\sigma_1 - \sigma} = \begin{cases} 0 & \text{if } i = 1 \\ \frac{\tilde{x}_1 \cdot \tilde{x}_i}{\sigma_1 - \sigma} & \text{o.w} \end{cases}.$$

最后，我们计算：

$$\begin{aligned} \mathbb{E}[\langle \dot{V}(0), r_1 \rangle] &= \langle \mathbb{E}[\dot{V}(0)], r_1 \rangle = \frac{1}{\sigma_1 - \sigma} \cdot (r_1^\top \cdot R \cdot \Sigma \cdot R^\top \cdot e_1 - r_{11} \cdot e_1^\top \cdot R \cdot \Sigma \cdot R^\top \cdot e_1) \\ &= \frac{1}{\sigma_1 - \sigma} \cdot (\sigma_1 \cdot r_{11} - r_{11}(\sigma + (\sigma_1 - \sigma) \cdot r_{11}^2)) \\ &= r_{11} \cdot (1 - r_{11}^2). \end{aligned}$$

当 $0 < r_{11} < 1$ 时，上式大于 0。 $\square$

关于证明的注记。由于 $\|r_1\| = 1$ ，假设 $0 < r_{11} < 1$ 非常温和：当 r_1 中存在任何其他非零元素时，即当在 $\tilde{x}$ 与 x 之间的第一主成分上存在任何变换时，该假设成立。

A.2 ImageNet-C 上的附加实验

在所有实验中，除非另有说明，我们采用与主论文中描述相同的超参数进行 ViT 探测，并在 10 步 TTT 后报告 ImageNet-C 第 5 级损坏的准确率（%）（为了加快实验速度，而不是 20 步）。

所有级别上的结果。表 5-9 展示了在所有 5 个损坏级别上 TTT 前后的结果。

归一化像素。遵循 [19]，我们实验了两种重建损失：1) 重建像素与原始像素之间的均方误差 (MSE)；2) 目标为每个掩码块内归一化像素值的 MSE。如表 10 所示，使用归一化像素作为重建目标在大多数损坏类型上提高了表示质量。两种损失函数对应的两个预训练模型取自 [19] 的官方代码仓库。

仅训练编码器与训练编码器和解码器。我们实验了两种 TTT 优化过程：1) 同时优化编码器和解码器权重；2) 仅优化编码器，冻结解码器权重。在两种情况下，掩码标记和类别标记一起优化。如表 11 所示，差异可以忽略不计。

测试时训练 (TTT) 的掩码比例。表 12 展示了在测试图像上使用不同掩码比例进行训练的结果。对于预训练，所有结果均采用固定的 75% 掩码比例。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Baseline	78.5	74.5	68.1	73.9	70.5	70.6	74.8	68.6	72.3	73.0	75.2	75.9	73.6	69.3	63.7
TTT-MAE	78.9	74.7	72.5	74.7	72.9	72.2	76.8	72.2	75.5	74.5	75.8	77.0	75.9	71.9	69.3

表 5: 在 ImageNet-C (级别 1) 上经过 10 步测试时训练 (TTT) 后的准确率 (%)。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Baseline	77.4	71.2	62.3	51.0	66.3	58.4	68.6	59.2	64.9	70.4	70.6	74.7	66.2	54.2	55.2
TTT-MAE	77.8	71.5	69.4	49.7	69.8	62.7	72.5	66.4	70.0	72.7	72.3	76.2	70.6	58.7	63.6

表 6: 在 ImageNet-C (级别 2) 上经过 10 步测试时训练 (TTT) 后的准确率 (%)。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Baseline	75.8	62.7	49.5	67.1	59.8	47.6	57.1	35.0	57.4	68.6	60.2	70.1	54.3	54.7	48.0
TTT-MAE	75.8	64.4	59.4	71.2	64.0	54.0	63.6	50.7	64.2	71.3	64.2	73.1	61.8	58.0	57.4

表 7: 在 ImageNet-C (级别 3) 上经过 10 步测试时训练 (TTT) 后的准确率 (%)。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Baseline	73.1	33.1	35.8	56.9	54.2	45.2	39.6	26.0	38.2	62.0	43.2	60.3	32.2	44.2	40.7
TTT-MAE	72.7	39.6	45.7	64.9	58.3	52.6	48.5	42.8	47.6	67.0	50.5	66.6	42.4	45.7	51.5

表 8: 在 ImageNet-C (级别 4) 上经过 10 步测试时训练 (TTT) 后的准确率 (%)。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Baseline	68.3	6.4	24.2	31.6	38.6	38.4	17.4	18.4	18.2	51.2	32.2	49.7	18.2	35.9	32.2
TTT-MAE	67.7	9.2	31.7	45.5	42.8	46.3	25.1	31.8	27.0	59.9	39.5	59.9	27.0	37.9	42.9

表 9: 在 ImageNet-C (级别 5) 上经过 10 步测试时训练 (TTT) 后的准确率 (%)。

	亮度	对比度	散焦	弹性	雾	霜	高斯噪声	玻璃	脉冲	压缩	运动	像素化	散粒	雪	缩放
基线无归一化。	66.7	5.6	25.7	40.4	33.7	37.7	13.2	20.9	15.5	48.0	39.6	47.0	15.3	37.6	32.7
基线有归一化。	68.3	6.4	24.2	31.6	38.6	38.4	17.4	18.4	18.2	51.2	32.2	49.7	18.2	35.9	32.2
本文无归一化。	68.3	5.7	31.5	47.8	33.3	41.5	19.2	25.3	21.5	54.5	43.5	54.1	22.1	44.3	39.5
本文有归一化。	67.7	9.2	31.7	45.5	42.8	46.3	25.1	31.8	27.0	59.9	39.5	59.9	27.0	37.9	42.9

表 10: 像素归一化与未归一化的均方误差损失对比。基线: 基线模型。本文: TTT-MAE。

	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
Encoder	67.7	9.2	31.7	45.5	42.8	46.3	25.1	31.8	27.0	59.9	39.5	59.9	27.0	37.9	42.9
Both	67.8	9.1	31.6	45.4	43.3	46.4	25.1	31.8	27.0	59.9	39.7	59.9	27.0	38.3	43.0

表 11: 仅训练编码器与同时训练编码器和解码器的对比。

Mask ratio	brigh	cont	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
50%	68.3	11.4	29.0	39.7	44.4	46.3	27.1	25.1	29.3	59.6	34.9	57.8	29.5	40.3	36.8
75%	67.7	9.2	31.7	45.5	42.8	46.3	25.1	31.8	27.0	59.9	39.5	59.9	27.0	37.9	42.9
90%	62.7	6.2	24.2	43.0	38.3	40.2	21.4	28.3	23.3	54.0	35.6	54.7	22.5	27.2	40.8

表 12: TTT 过程中不同掩码比例的影响。

Dataset	License
ImageNet-C	Creative Commons Attribution 4.0 International
ImageNet-A	MIT License
ImageNet-R	MIT License
Yearbook Dataset	MIT License

表 13: 本文所用数据集的许可证。




图 4: ImageNet-C 基准中的样本图像，如原论文 [22] 所示。