

基于自监督的测试时训练用于分布偏移下的泛化

Yu Sun¹ Xiaolong Wang^{1,2} Zhuang Liu¹ John Miller¹ Alexei A. Efros¹ Moritz Hardt¹

摘要

本文提出测试时训练方法，这是一种通用方法，用于在训练数据与测试数据来自不同分布时提升预测模型的性能。我们将单个无标签测试样本转化为自监督学习问题，并在做出预测前更新模型参数。该方法也自然扩展到在线数据流。这一简单方法在多个旨在评估分布偏移鲁棒性的图像分类基准上取得了改进。

我们提出的测试时训练方法基于这一单个测试样本 x 创建自监督学习问题，在做出预测前更新 θ 。自监督学习使用辅助任务，自动从无标签输入中生成标签。在实验中，我们采用将每张输入图像旋转 90 度的倍数并预测其角度的任务（Gidaris 等人，2018）。

这种方法也可以很容易地修改，以在标准监督学习环境之外工作。如果多个测试样本成批到达，我们可以使用整个批次进行测试时训练。如果样本以在线流的形式到达，我们通过保持参数状态来获得进一步的改进。毕竟，预测很少是单一事件。在线版本可以在额外假设测试样本由相同或平滑变化的分布偏移产生的条件下的自然部署模式。

1. 引言

监督学习在分布偏移下的泛化能力仍然十分薄弱。除非训练数据和测试数据来自同一分布，否则即使看似微小的差异也会使最先进的模型失效（Recht 等人，2018）。对抗鲁棒性和领域自适应只是现有范式中的少数几种，它们试图通过拓扑结构或训练期间可用的测试分布数据来预判训练分布与测试分布之间的差异。我们探索一种新的泛化思路，不预判分布偏移，而是在测试时从中学学习。

我们从一个简单的观察出发。测试时呈现的无标签测试样本 x 为我们提供了其来源分布的线索。我们提出利用这一关于测试分布的线索，允许模型参数 θ 依赖于测试样本 x ，但不依赖于其未知标签 y 。可变决策边界 $\theta(x)$ 的概念在理论上具有强大能力，因为它突破了固定模型容量的限制（更多讨论见 A1 节），但从 x 到 $\theta(x)$ 的反馈机制设计在实践中带来了新的挑战，本文仅初步探讨。

我们在几个标准基准上以物体识别为背景实验验证了我们的方法。这些包括具有各种类型和不同程度损坏的图像（Hendrycks & Dietterich, 2019）、移动物体的视频帧（Shankar et al., 2019），以及由（Recht et al., 2018）收集的未知偏移的新测试集。我们的算法在分布偏移下取得了显著的改进，同时在原始分布上保持了相同的性能。

在我们的实验中，我们与一个强基线（标记联合训练）进行比较，该基线在训练时同时使用监督学习和自监督学习，但在测试时保持模型固定。最近的工作表明，训练时的自监督提高了鲁棒性（Hendrycks et al., 2019a）；我们的联合训练基线对应于这项工作的改进实现。相关工作的全面回顾见第 5 节。

我们在第 4 节中用理论分析补充了实证结果，并在凸模型上建立了一个直观的充分条件，说明测试时训练何时有帮助；粗略地说，这个条件是两个任务损失函数之间具有相关的梯度。

¹ 加州大学伯克利分校 ² 加州大学圣迭戈分校。通讯作者：Yu Sun <yusun@berkeley.edu>。

2. 方法

本节描述了我们方法的算法细节。为了建立符号，考虑一个标准的 K 层神经网络，其第 k 层的参数为 θ_k 。堆叠的参数向量 $\theta = (\theta_1, \dots, \theta_K)$ 指定了用于分类任务的整个模型，该任务在测试样本 (x, y) 上的损失函数为 $l_m(x, y; \theta)$ 。我们称之为主任务，如损失函数的下标所示。

我们假设有从分布 P 中独立同分布抽取的训练数据 $(x_1, y_1), \dots, (x_n, y_n)$ 。标准经验风险最小化解决以下优化问题：

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n l_m(x_i, y_i; \theta). \quad (1)$$

本文方法需要一个具有损失函数 $l_s(x)$ 的自监督辅助任务。本文选择旋转预测任务（Gidaris 等人，2018），该任务已被证明在卷积神经网络的特征学习方面简单且有效。该任务仅将 x 在图像平面内旋转 0、90、180 或 270 度之一，并让模型将旋转角度预测为一个四分类问题。第 5 节中的其他自监督任务也可用于本文方法。

辅助任务共享部分模型参数 $\kappa \in \{1, \dots, K\}$. We $\theta_e = (\theta_1, \dots, \theta_{\kappa})$ 直至某一指定层，将这些 κ 层作为共享特征提取器。辅助任务使用其自身的任务特定参数 $\theta_s = (\theta'_{\kappa+1}, \dots, \theta'_K)$ 。本文将未共享的参数 θ_s 称为自监督任务分支，将 $\theta_m = (\theta_{\kappa+1}, \dots, \theta_K)$ 称为主任务分支。从图示来看，联合架构是一个 Y 结构，具有共享的底部和两个分支。在本文实验中，自监督任务分支与主分支具有相同的架构，仅最后一层的输出维度因两个任务的类别数不同而有所差异。

训练采用多任务学习（Caruana, 1997）的方式进行；模型在从 P 中抽取的相同数据上同时针对两个任务进行训练。两个任务的损失相加，并对所有参数集计算梯度。因此，联合训练问题为

$$\min_{\theta_e, \theta_m, \theta_s} \frac{1}{n} \sum_{i=1}^n l_m(x_i, y_i; \theta_m, \theta_e) + l_s(x_i; \theta_s, \theta_e). \quad (2)$$

现在描述在单个测试样本 x 上标准版本的测试时训练。简而言之，测试时训练通过最小化 x 上的辅助任务损失来微调共享特征提取器 θ_e 。这可以表述为

$$\min_{\theta_e} l_s(x; \theta_s, \theta_e). \quad (3)$$

记 θ_e^* 为方程 3 的（近似）极小值点。然后模型使用更新后的参数 $\theta(x) = (\theta_e^*, \theta_m)$ 进行预测。经验上，在 θ_e 上最小化方程 3 与同时在 θ_e 和 θ_s 上最小化之间的差异可以忽略不计。理论上，仅当优化使用多于一个梯度步时，差异才存在。

测试时训练自然受益于标准的数据增强技术。在每个测试样本 x 上，我们执行与训练期间数据增强完全相同的随机变换集合，以形成一个仅包含 x 的增强副本的批次用于测试时训练。

在线测试时训练。在我们方法的标准版本中，方程 3 中的优化问题始终以通过最小化方程 2 获得的参数 $\theta = (\theta_e, \theta_s)$ 进行初始化。在对 x, θ^* 进行预测后， θ_e 被丢弃。在标准监督学习设置之外，当测试样本在线顺序到达时，在线版本解决与方程 3 相同的优化问题以更新共享特征提取器 θ_e 。然而，在测试样本 x_t, θ 上，则使用在前一个样本 x_{t-1} 上更新的 $\theta(x_{t-1})$ 进行初始化。这使得 $\theta(x_t)$ 能够利用 $x_1, \dots, x_{t-1}$ 以及 x_t 中可用的分布信息。

3. 实证结果

我们在三种分布偏移基准上实验了我们方法的两个版本（标准版和在线版），这里按视觉从低到高的顺序呈现。我们的代码可在项目网站上获取。

网络细节。我们的架构和超参数在所有实验中保持一致。我们使用 ResNets（He 等人，2016b），其针对 CIFAR-10（Krizhevsky & Hinton, 2009）（26 层）和 ImageNet（Russakovsky 等人，2015）（18 层）的构造有所不同。CIFAR-10 数据集包含 5 万张训练图像和 1 万张测试图像。ImageNet 包含 120 万张训练图像，5 万张验证图像用作测试集。CIFAR-10 上的 ResNets 有三个组，每组包含具有相同通道数和特征图尺寸的卷积层；我们的分割点是第二组的末尾。ImageNet 上的 ResNets 有四个组；我们的分割点是第三组的末尾。

我们在架构中使用组归一化（Group Normalization, GN）而非批归一化（Batch Normalization, BN），因为 BN 已被证明在小批量训练时效果不佳，此时估计的批统计量不准确（Ioffe & Szegedy, 2015）。这一技术细节对测试时训练不利，因为每个批次仅包含单张图像的（增强）副本。与 BN 不同，GN 不依赖于批大小，并在我们的基线上取得了相似的结果。




图 1. 在 CIFAR-10-C 上，5 级腐蚀下的测试误差 (%)。我们将本文方法——测试时训练 (TTT) 及其在线版本 (TTT-Online)——与两种基线进行比较：无自监督的目标识别，以及带自监督但在测试时保持模型固定的联合训练。TTT 优于基线，而 TTT-Online 进一步提升性能。

为完整性起见，我们在附录 A4 节报告了使用 BN 的结果。我们在 A4.5 小节中直接将本文架构与 Hendrycks 等人 (2018) 的架构进行了比较。

优化细节。对于联合训练 (方程 2)，我们使用随机梯度下降，并采用与 (Huang 等人, 2016; He 等人, 2016a) 相同的标准超参数。对于测试时训练 (方程 3)，我们使用随机梯度下降，学习率设为训练最后一个轮次的值，在本文所有实验中均为 0.001。受 (He 等人, 2018; Liu 等人, 2018) 实践的启发，我们在测试时训练期间将权重衰减和动量设为零。对于标准版测试时训练，我们执行十个梯度步，使用由同一图像独立生成的批次。对于在线版测试时训练，每张新图像仅执行一个梯度步。我们使用随机裁剪和随机水平翻转进行数据增强。关于本文方法的计算方面，请参见附录 A2 节。在所有表格和图中，目标识别任务仅指普通 ResNet 模型 (除非另有说明，使用 GN)；联合训练指在主任务和自监督任务上联合训练、测试时保持固定的模型；该方法由 Hendrycks 等人 (2019a) 提出；测试时训练 (TTT) 指第 2 节所述的标准版本；在线测试时训练 (TTT-Online) 指不丢弃 $\theta(x_t)$ 的在线版本，用于 x_t 从同一分布顺序到达的情况。TTT-Online 的性能按整个测试集的平均值计算；我们总是在 TTT-Online 之前打乱测试集，以避免顺序伪影。

3.1. 腐蚀图像上的目标识别

Hendrycks & Dietterich (2019) propose to benchmark robustness of object recognition with 15 types of corruptions from four broad categories: noise, blur, weather and digital. Each corruption type comes in five levels of severity, with

第 5 级为最严重级别 (详情及示例图像见附录)。这些损坏是在 CIFAR-10 和 ImageNet 测试集的副本上模拟的，以尽可能贴近真实世界的损坏。新的测试集分别命名为 CIFAR-10-C 和 ImageNet-C。在所提出的基准中，训练应在原始训练集上进行，损坏类型的多样性应使任何过度依赖损坏特定知识的方法难以全面表现良好。对于在线测试时训练，我们将整个测试集视为传入图像流，并在每张图像到达时以在线方式更新和测试。

CIFAR-10-C。我们在第 5 级损坏 (最严重) 上的结果如图 1 所示。第 1-4 级的结果见附录 A4 节。在所有五个级别和 15 种损坏类型中，测试时训练的标准版和在线版均大幅优于仅使用目标识别任务的基线。标准版始终优于联合训练，在线版通常显著优于联合训练 ($> 10\%$)，且从未造成超过 0.2% 的损失。具体而言，TTT-Online 在三种噪声类型上贡献了 $> 24\%$ ，在像素化上贡献了 38%。对于一个看似不稳定、滥用单张图像的学习问题，这种一致性相当令人惊讶。

仅使用目标识别任务的基线 ResNet-26 在 CIFAR-10 原始测试集上的错误率为 8.9%。联合训练基线实际上将原始性能提升至 8.1%。更令人惊讶的是，与许多以牺牲原始性能换取鲁棒性的方法不同，测试时训练在多次独立试验中始终将原始测试集性能提升 0.2%。这表明我们的方法无需在特异性和通用性之间做出选择。




图 2. 在第 5 级损坏的 ImageNet-C 上的测试准确率 (%)。上图：我们的方法 TTT 和 TTT-Online 在所有损坏类型上均显著优于两个基线。下图：我们展示了 TTT-Online 在 100 个样本滑动窗口上的平均准确率；随着评估样本增多 (x 轴)，TTT-Online 泛化能力更好，且不影响原始分布。此处使用准确率而非错误率，因为大多数损坏的基线性能非常低。

与本文方法无关，值得注意的是，联合训练始终优于单任务基线，这一发现由亨德里克斯等人 (Hendrycks et al., 2019a) 提出。亨德里克斯与迪特里希 (Hendrycks & Dietterich, 2019) 还在该基准上尝试了多种其他训练方法，并指出对抗性对数配对 (Adversarial Logit Pairing, ALP) (坎南等人, Kannan et al., 2018) 是最有效的方法。该额外基线在 CIFAR-10-C 所有级别上的结果及其实现细节见附录。尽管 ALP 在某些最严重的损坏 (尤其是三种噪声类型) 下表现出惊人的鲁棒性，但它在原始分布和某些损坏 (例如所有级别的对比度和雾) 上产生的误差要大得多 (高出两倍)，并且在损坏不那么严重时 (尤其是 1-3 级) 显著损害性能；这种权衡对于基于对抗训练的方法来说是意料之中的。

图像网腐蚀数据集 (ImageNet-C)。 图 2 展示了在 5 级损坏 (最严重) 情况下的结果。由于基线性能的原因，本数据集采用准确率而非错误率。

对于大多数损坏类型，错误率非常低。总体趋势与在 CIFAR-10-C 上的表现大致相同。标准版 TTT 始终优于基线和联合训练，而在线版仅在原始数据上比基线差 0.1%，但在许多损坏类型上显著改善 (提升超过三倍)。

在图 2 的下方面板中，我们可视化了在线版本在测试更多图像时准确率 (在滑动窗口上取平均) 的变化情况。由于篇幅限制，我们在原始测试集以及每第三种损坏类型上展示该图，顺序与原文相同。在原始测试集上，更新 50,000 个样本后性能变化没有明显趋势。对于损坏类型，准确率在 10,000 个样本后已显著上升，但在 50,000 个样本结束时仍在上升，表明如果有更多样本可用，仍有进一步改进的空间。在没有看到任何标签的情况下，TTT-Online 的表现从图上看就像是在测试集上进行训练一样。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
TTT-Online	8.2	25.8	22.6	30.6	14.6	34.4	18.3	17.1	20.0	18.0	16.9	11.2	15.6	21.6	18.1	21.2
UDA-SS	9.0	28.2	26.5	20.8	15.6	43.7	24.5	23.8	25.0	24.9	17.2	12.7	11.6	22.1	20.3	22.6

表 1. 在 CIFAR-10-C 数据集上, 5 级损坏下的测试误差 (%)。在线测试时训练 (TTT-Online) 与通过自监督进行的无监督领域自适应 (UDA-SS) (Sun 等人, 2019 年) 之间的比较, 后者在训练期间可以访问整个 (未标记的) 测试集。我们将较低的误差以粗体突出显示。我们按顺序缩写损坏类型: 原始测试集、高斯噪声、散粒噪声、脉冲噪声、散焦模糊、玻璃模糊、运动模糊、缩放模糊、雪、霜、雾、亮度、对比度、弹性变换、像素化和 JPEG 压缩。TTT-Online 报告的数字与图 1 相同。完整表格见表 A2。




图 3. 在 CIFAR-10-C 数据集上, 三种噪声类型下, 分布逐渐变化时的测试误差 (%)。分布偏移是通过将每种噪声类型的标准差从小到大增加来创建的, x 轴上越靠右, 偏移越大。随着样本噪声增大, 所有方法在测试集上评估得越深入, 误差就越大, 但在线测试时训练 (TTT-Online) 的斜率比联合训练更平缓。对于前两种噪声类型, TTT-Online 还取得了比通过自监督进行的无监督领域自适应 (UDA-SS) (Sun 等人, 2019 年) 更好的结果。

与无监督领域自适应的比较。

表 1 通过实验比较了在线测试时训练 (TTT-Online) 与通过自监督进行的无监督领域自适应 (UDA-SS) (Sun 等人, 2019 年), 后者在精神上与我们的方法相似, 但专为无监督领域自适应设置而设计 (第 5 节综述了该设置下的其他相关工作)。给定来自训练分布的标记数据和来自测试分布的未标记数据, UDA-SS 希望通过学习同时在两个分布的数据上执行自监督任务 (具体为旋转预测), 找到一个不变表示, 该表示能为两个分布提取有用特征。然后, 它使用标记数据在不变表示之上学习一个标记函数。在我们的实验中, 提供给 UDA-SS 的未标记数据是整个测试集本身, 但不包含标签。

由于在线测试时训练 (TTT-Online) 只能从已经评估过的无标签测试样本中学习, 它在任何时候获得的信息都少于无监督域自适应自监督 (UDA-SS)。从这个意义上说, UDA-SS 应被视为一种理想参照 (oracle) 而非基线。令人惊讶的是, TTT-Online 在 15 种损坏类型中的 13 种以及原始分布上均优于 UDA-SS。我们的解释是, UDA-SS 必须为两种分布找到一个不变表示, 而 TTT-Online 仅

调整表示使其对当前测试分布表现良好。也就是说, TTT-Online 具有灵活性, 可以遗忘不再相关的训练分布表示。这表明在我们的设定中, 遗忘并非有害, 甚至可能应当加以利用。

逐渐变化的分布偏移。在之前的实验中, 我们评估在线版本时假设测试输入 x_t 对于 $t = 1 \dots n$ 均采样自同一测试分布 Q , 该分布可能与训练分布 P 不同。这一假设对于打乱后的测试集的独立同分布样本确实成立。但此处我们表明, 该假设实际上可以放宽以允许 $x_t \sim Q_t$, 其中 Q_t 在分布距离意义上接近 Q_{t+1} 。我们称之为逐渐变化的分布偏移假设。我们通过在 CIFAR-10-C 的三种噪声类型上模拟此类分布偏移来进行实验。对于每种噪声类型, x_t 以标准差 σ_t 进行损坏, $\sigma_1, \dots, \sigma_n$ 在级别 1 和级别 5 的标准差之间进行插值。因此, 随着我们在测试集中进一步评估且 t 增大, x_t 的损坏程度更加严重。如图 3 所示, 在此放宽假设下, TTT-Online 仍然优于联合训练 (以及我们的标准版本), 甚至在前两种噪声类型上优于 UDA-SS。

Accuracy (%)	Airplane	Bird	Car	Dog	Cat	Horse	Ship	Average
Object recognition task only	67.9	35.8	42.6	14.7	52.0	42.0	66.7	41.4
Joint training (Hendrycks et al., 2019a)	70.2	36.7	42.6	15.5	52.0	44.0	66.7	42.4
TTT (standard version)	70.2	39.2	42.6	21.6	54.7	46.0	77.8	45.2
TTT-Online	70.2	39.2	42.6	22.4	54.7	46.0	77.8	45.4

表 2. VID-Robust 中 CIFAR 各类别的分类准确率 (%) 及平均准确率, 改编自 (Shankar 等, 2019)。测试时训练 (TTT) 和在线测试时训练 (TTT-Online) 在平均值上优于两个基线, 并且在“船”和“狗”类别上大幅领先, 这些类别中旋转任务比“飞机”等类别更有意义 (示例图像见图 A7)。

3.2. 视频帧上的物体识别

鲁棒视频分类 (VID-Robust) 数据集由尚卡尔等人 (2019) 基于视频检测数据集 (鲁萨科夫斯基等人, 2015) 构建, 旨在证明在静态图像数据集上训练的目标识别深度模型难以良好适应视频帧。该数据集包含 30 个类别的 1109 组视频帧; 每组是一个短视频片段, 其中的帧与锚定帧相似。本文结果在锚定帧上报告。为将 1000 个图像分类类别映射到 30 个鲁棒视频分类类别, 本文采用尚卡尔等人 (2019) 中的最大转换函数。在未对视频做任何修改的情况下, 本文将方法应用于鲁棒视频分类数据集, 并基于与前一小节相同的图像分类模型。分类准确率见表 3。

此外, 本文选取鲁棒视频分类数据集中与 CIFAR-10 重叠的七个类别, 将这些视频帧缩放至 CIFAR-10 图像的尺寸, 作为前一小节中在 CIFAR-10 上训练的模型的新测试集。同样, 本文在未做任何修改的情况下将方法应用于该数据集。结果见表 2, 并附有每个类别的细分。注意到测试时训练在飞机类别上未带来提升, 本文检查了一些飞机样本 (图 A7), 观察到大多数图像两侧存在黑色边距, 这为旋转预测提供了简单线索。此外, 对于天空中的飞机图像, 即使是人类也往往难以判断其是否旋转。这表明本文方法要求自监督任务既定义明确又非平凡。

3.3. CIFAR-10.1: 未知分布偏移

CIFAR-10.1 (雷希特等人, 2018) 是一个规模为 2000 的新测试集, 仿照 CIFAR-10 构建, 具有完全相同的类别和图像维度, 并尽可能严格遵循原始 CIFAR-10 论文所记录的数据集创建流程。其目的是研究两个测试集之间存在的分布偏移及其对目标识别的影响。作者测试的所有模型在 CIFAR-10.1 上的性能相比 CIFAR-10 均出现大幅下降, 尽管人类无法察觉明显差异, 并且

Method	Accuracy (%)
Object recognition task only	62.7
Joint training (Hendrycks et al., 2019a)	63.5
TTT (standard version)	63.8
TTT-Online	64.3

表 3. 鲁棒视频分类数据集 (尚卡尔等人, 2019) 上的测试准确率 (%)。测试时训练和在线测试时训练优于基线。

Method	Error (%)
Object recognition task only	17.4
Joint training (Hendrycks et al., 2019a)	16.7
TTT (standard version)	15.9

表 4. CIFAR-10.1 (雷希特等人, 2018) 上的测试错误率 (%)。测试时训练是首个在该新测试集上提升现有模型性能的方法。

两者具有相同的人类准确率。这表明分布偏移是多么隐蔽且普遍, 即使研究人员努力将其最小化。

从 CIFAR-10 到 CIFAR-10.1 的分布偏移构成了一个极其困难的问题, 此前没有任何工作能够提升现有模型在这个新测试集上的性能, 可能的原因包括: 1) 研究人员甚至无法识别这些分布偏移, 更不用说用数学方式描述它们; 2) CIFAR-10.1 中的样本仅在测试时才会出现; 即使它们在训练时被揭示, 分布偏移也过于细微, 且样本量过小, 难以进行领域自适应 (Recht 等人, 2018)。

在原始 CIFAR-10 测试集上, 仅使用目标识别的基线错误率为 8.9%, 联合训练的错误率为 8.1%; 与表 4 的前两行相比, 两者都遭受了典型的性能下降 (下降了一倍)。测试时训练 (TTT) 相比联合训练带来了 0.8% 的改进 (相对改进 4.8%)。我们认识到这一改进相对于性能下降而言较小, 但将其视为针对这一非常困难问题的令人鼓舞的第一步。




图 4. 主任务 l_m 与自监督任务 l_e 在共享特征提取器 θ_e 上的梯度之间的内积，与测试时训练带来的测试错误率改进 (%) 的散点图，分别对应标准（左）和在线（右）版本。每个点是一个测试集的平均值，每个散点图包含 75 个测试集，来自第 3.1 节所述的全部 15 种损坏类型在五个级别上的组合。蓝线和带状区域是最佳线性拟合及 99% 置信区间。线性相关系数分别为 0.93 和 0.89，表明两个量之间存在强正相关，正如定理 1 所暗示的。

4. 理论结果

本节包含我们对测试时训练何时以及为何有效的初步研究。对于凸模型，我们证明了损失函数之间的正梯度相关性会导致测试时训练后主任务性能的提升。基于这一洞见，我们随后通过实验证明，梯度相关性决定了第 3 节中讨论的深度学习模型上测试时训练的成功与否。

在陈述主要理论结果之前，我们首先通过一个玩具模型来阐述一般直觉。考虑一个回归问题，其中 $x \in \mathbb{R}^d$ 表示输入， $y_1 \in \mathbb{R}$ 表示标签，目标函数为平方损失（对于预测 $\hat{y}$ ，损失为 $(\hat{y} - y_1)^2/2$ ）。考虑一个由 $A \in \mathbb{R}^{h \times d}$ 和 $v \in \mathbb{R}^h$ 参数化的两层线性网络（其中 h 表示隐藏维度）。该模型的预测为 $\hat{y} = v^\top Ax$ ，主任务损失为

$$l_m(x, y_1; A, v) = \frac{1}{2} (y_1 - v^\top Ax)^2. \quad (4)$$

此外，考虑一个自监督回归任务，同样使用平方损失，并自动为 x 生成标签 y_s 。设自监督头由 $w \in \mathbb{R}^h$ 参数化。则自监督任务损失为

$$l_s(x, y_2; A, w) = \frac{1}{2} (y_2 - w^\top Ax)^2. \quad (5)$$

现在，我们对共享特征提取器 A 应用测试时训练，在已知 y_2 的情况下，对 l_s ，执行一步梯度下降。这给出

$$A' \leftarrow A - \eta (y_2 - w^\top Ax) (-wx^\top), \quad (6)$$

其中 A' 是更新后的矩阵， η 是学习率。如果我们设 $\eta = \eta^*$ ，其中

$$\eta^* = \frac{y_1 - v^\top Ax}{(y_2 - w^\top Ax) v^\top wx^\top}, \quad (7)$$

那么通过一些简单的代数运算，很容易看出主任务损失 $l_m(x, y_1; A', v) = 0$ 。具体而言，在精心选择的学习率下，测试时训练仅需一步梯度即可将主任务损失降至零。在实践中，该学习率是未知的，因为它依赖于未知的 y_1 。然而，由于我们的模型是凸的，只要 η^* 为正，将 η 设为一个小的正常数就足够了（详见附录）。如果 $x \neq 0$ ，则 η^* 为正（当两个损失均不为零时）的一个充分条件是

$$\text{sign}(y_1 - v^\top Ax) = \text{sign}(y_2 - w^\top Ax) \quad (8)$$

$$\text{and } v^\top w > 0. \quad (9)$$

对于我们的玩具模型，上述条件的两个部分都有直观解释。第一部分表示错误应当相关，即两个任务的预测在相同方向上出错。第二部分 $v^\top w > 0$ 表示特征空间上的决策边界应当相关。事实上，这两个部分成立当且仅当 $\langle \nabla l_m(A), \nabla l_s(A) \rangle > 0$ （该事实的简单证明见附录）。总结来说，如果梯度具有正相关性，测试时训练保证能降低主任务损失。我们的主要理论结果将此推广到一般光滑凸损失函数。

定理 1. 设 $l_m(x, y; \theta)$ 表示测试实例 x, y 上参数为 θ 的主任务损失, $l_s(x; \theta)$ 为仅依赖于 x 的自监督任务损失。假设对于所有 $x, y, l_m(x, y; \theta)$, 在 θ 上可微、凸且 β -光滑, 并且对于所有 θ , $\|\nabla l_m(x, y; \theta)\|, \|\nabla l_s(x; \theta)\| \leq G$ 均成立。在固定学习率 $\eta = \frac{\epsilon}{\beta G^2}$ 下, 对于每个满足以下条件的 x, y :

$$\langle \nabla l_m(x, y; \theta), \nabla l_s(x; \theta) \rangle > \epsilon, \quad (10)$$

我们有

$$l_m(x, y; \theta) > l_m(x, y; \theta(x)), \quad (11)$$

其中 $\theta(x) = \theta - \eta \nabla l_s(x; \theta)$, 即采用一步梯度下降的测试时训练。

证明采用优化中的标准技术, 留待附录给出。定理 1 揭示了梯度相关性是光滑凸情形下测试时训练成功与否的决定性因素。在图 4 中, 我们通过实验表明, 对于非凸损失函数、深度学习模型以及第 3 节所考虑的各种损坏类型, 这一洞见同样成立; 更强的梯度相关性明确预示着相对于基线的更大性能提升。

5. 相关工作

在测试实例上学习。Shocher 等人 (2018) 为我们的工作提供了关键启发, 他们表明图像超分辨率可以在测试时仅通过尝试对输入图像的下采样版本进行上采样来学习。最近, Bau 等人 (2019) 通过将预训练的生成对抗网络 (GAN) 适配到输入图像的统计特性来改进照片处理。这一思想的较早例子来自 Jain 与 Learned-Miller (2011), 他们通过从同一图像中较易检测的人脸引导较难检测的人脸, 改进了 Viola-Jones 人脸检测 (Viola 等人, 2001)。我们算法的在线版本受到 Mullapudi 等人 (2018) 工作的启发, 该工作通过使用一个从教师模型在线学习的学生模型来提高视频分割的效率。在线更新的思想也被用于 Kalal 等人 (2011) 的跟踪与检测中。最近一项超声心动图工作 (Zhu 等人, 2019) 通过顺序更新改进了跟踪心肌运动和心脏血液的深度学习模型。最后, 我们与直推式学习 (Vapnik, 2013; Gammernan 等人, 1998) 的理念相同, 但与其经典算法几乎没有共同之处; Tripuraneni 与 Mackey (2019) 最近的工作在去偏 LASSO 估计器的背景下, 从理论上探索了线性预测的这一思想。

自监督学习 研究如何通过设计各种代理任务从数据中创建标签, 这些任务能够

无需人工标注即可学习语义信息, 例如上下文预测 (Doersch 等, 2015)、拼图求解 (Noroozi 和 Favaro, 2016)、图像着色 (Larsson 等, 2017; Zhang 等, 2016)、噪声预测 (Bojanowski 和 Joulin, 2017)、特征聚类 (Caron 等, 2018)。本文采用旋转预测 (Gidaris 等, 2018)。Asano 等 (2019) 表明, 仅在单张图像上进行自监督学习, 竟能产生泛化良好的低级特征。与本文工作密切相关的是, Hendrycks 等 (2019a) 提出联合训练主任务和自监督任务 (即第 3 节中的联合训练基线) 可提升主任务的鲁棒性。相同的思想也被用于小样本学习 (Su 等, 2019)、领域泛化 (Carlucci 等, 2019) 以及无监督领域自适应 (Sun 等, 2019)。

对抗性鲁棒性 研究的是鲁棒风险 $R_P, \Delta(\theta) = \mathbb{E}_{x, y \sim P} \max_{\delta \in \Delta} l(x + \delta, y; \theta)$, 其中 l 是某个损失函数, Δ 是扰动集合; Δ 通常选为 L_p 球, 对于 $p \in \{1, 2, \infty\}$ 。许多流行算法将此问题形式化并求解为鲁棒优化问题 (Goodfellow et al., 2014; Madry et al., 2017; Sinha et al., 2017; Ragunathan et al., 2018; Wong & Kolter, 2017; Croce et al., 2018), 其中最著名的技术是對抗训练。另一类工作基于随机平滑 (Cohen et al., 2019; Salman et al., 2019), 而其他一些方法, 如输入变换 (Guo et al., 2017; Song et al., 2017), 被证明效果较差 (Athalye et al., 2018)。上述方法存在两个主要问题。首先, 它们都可以被视为对决策边界进行平滑。这在理论上建立了准确率与鲁棒性之间的权衡 (Tsipras et al., 2018; Zhang et al., 2019), 我们在第 3 节中通过对抗训练基线也实证观察到了这一点。直观上, Δ 越多样, 这种“一个边界适应所有”的方法对于 Δ 的特定元素就越无效。其次, 对抗方法严重依赖 Δ 的数学结构, 这可能无法准确模拟现实世界中的扰动。因此, 在 Δ_{we} 之外, 泛化仍然困难, 尤其是对于非对抗性分布偏移, 除非我们事先知道或能够数学建模。实证上, Kang et al. (2019) 表明, 针对一个 Δ_{might} 的鲁棒性不会迁移到另一个, 而在 L_∞ 球上训练实际上会损害在 L_1 球上的鲁棒性。

非对抗鲁棒性 研究由损坏、扰动、分布外样本以及真实世界分布偏移带来的影响 (Hendrycks 等, 2019b; a; 2018; Hendrycks 与 Gimpel, 2016)。Geirhos 等 (2018) 表明, 在受高斯噪声损坏的图像上训练可使深度学习模型对该特定噪声类型具有鲁棒性, 但并不能提升在受另一种噪声类型 (如椒盐噪声) 损坏的图像上的性能。

无监督领域自适应（又称迁移学习）研究分布偏移问题，即在训练时除了来自训练分布（源域）的带标签数据集外，还可获得来自测试分布（目标域）的无标签数据集（Chen 等，2011；Gong 等，2012；Long 等，2015；Ganin 等，2016；Long 等，2016；Tzeng 等，2017；Hoffman 等，2017；Csurka，2017；Chen 等，2018）。然而，该问题设定的局限性在于，泛化可能仅针对这一特定测试分布得到改善，而该分布往往难以提前预知。先前工作尝试通过使用多个且不断演化的领域来预测更广泛的分布（Hoffman 等，2018；2012；2014）。测试时训练不预测任何测试分布，而是通过改变无监督领域自适应的设定，同时借鉴其算法思想。本文是 Sun 等（2019）的后续工作，我们在第 3 节中对其进行了说明和实证比较。我们的更新规则可视为在运行中执行单样本无监督领域自适应，但需注意，当目标域只有一个样本时，标准领域自适应技术可能变得定义不清。

领域泛化

其中元

分布生成多个环境分布，其中一些在训练期间可用（源），而另一些用于测试（目标）（Li 等，2018；Shankar 等，2018；Muandet 等，2013；Balaji 等，2018；Ghifary 等，2015；Motiian 等，2017；Li 等，2017a；Gan 等，2016）。仅有少数环境时，关于元分布的信息往往过于稀缺而难以发挥作用；而环境众多时，我们又回到了独立同分布（i.i.d.）设定，每个环境可视为一个样本，一个强大的基线是简单地在所有环境上训练（Li 等，2019）。领域泛化的设定受限于固定决策边界在特定性与通用性之间的固有权衡，以及泛化在元分布之外再次难以捉摸的事实，即算法实际学习到的 F 。

单样本（少样本）学习 研究如何仅使用一个（或少数几个）样本，在已从多样样本中学习到的通用表示之上，学习新任务或新分类类别（Snell 等，2017；Vinyals 等，2016；Fei-Fei 等，2006；Ravi 和 Larochelle，2016；Li 等，2017b；Finn 等，2017；Gidaris 和 Komodakis，2018）。我们的更新规则可视为执行单样本自监督学习，并可能通过单样本学习的进展得到改进。

持续学习（又称无遗忘学习）研究模型学习一系列任务，并在训练后续任务时不遗忘先前任务的设定（Li 和 Hoiem，2017；Lopez-Paz 和 Ranzato，

2017；Kirkpatrick 等，2017；Santoro 等，2016）。相比之下，在测试时训练中，我们不担心遗忘过去的测试样本，因为它们已经被评估过；如果某个过去的样本偶然再次出现，它将再次经历测试时训练。此外，遗忘训练集的影响很小，因为两个任务已经联合训练过。

在线学习（又称在线优化）是学习理论中一个研究深入的领域（Shalev-Shwartz 等，2012；Hazan 等，2016）。其基本设定重复以下过程：接收 x_t ，预测 $\hat{y}_t$ ，从最坏情况预言机接收 y_t ，然后学习。最终性能通过遗憾来评估，通俗地说，遗憾表示在线学习算法与事后最佳固定模型相比表现差多少。相比之下，我们的设定即使在在线版本中，测试期间也从不揭示任何 y_t ，因此我们无需引入最坏情况预言机或遗憾的概念。此外，由于预测后缺乏来自环境的反馈，我们的算法被激励在预测 $\hat{y}_t$ 之前（通过自监督）学习，而不是之后。注意，之前涉及的一些论文（Hoffman 等，2014；Jain 和 Learned-Miller，2011；Mullapudi 等，2018）在学习理论设定之外使用了“在线学习”这一术语，因此该术语可能存在多重含义。

6. 讨论

测试时训练的思想也适用于其他任务，如分割和检测，以及其他领域，如语音识别和自然语言处理。对于在各自领域具有先验领域知识的机器学习从业者，可以利用他们的专业知识为测试时训练设计更好的专用自监督任务。通用自监督任务的研究人员也可以将测试时训练作为评估基准，除了目前流行的预训练和微调基准之外。

更广泛地说，我们希望本文能鼓励研究人员放弃测试时固定决策边界的自我限制，甚至完全放弃训练与测试之间的人为划分。我们的工作只是迈向新范式的一小步，在这种范式中，大部分学习发生在模型部署之后。

致谢。 本工作得到美国国家科学基金会（NSF）拨款 1764033、DARPA 和伯克利 DeepDrive 的支持。本文历经长时间发展，受益于与许多同事的交流，包括 Ben Recht 及其学生 Ludwig Schmidt、Vaishaal Shanker 和 Becca Roelofs；Ravi Teja Mullapudi、Achal Dave 和 Deva Ramanan；以及 Armin Askari、Allan Jabri、Ashish Kumar、Angjoo Kanazawa 和 Jitendra Malik。

参考文献

- Asano, Y. M., Rupprecht, C., and Vedaldi, A. Surprising effectiveness of few-image unsupervised feature learning. *arXiv preprint arXiv:1904.13132*, 2019.
- Athalye, A., Carlini, N., and Wagner, D. Obfuscated gradients give a false sense of security: Circumventing defenses to adversarial examples. *arXiv preprint arXiv:1802.00420*, 2018.
- Balaji, Y., Sankaranarayanan, S., and Chellappa, R. Metareg: Towards domain generalization using meta-regularization. In *Advances in Neural Information Processing Systems*, pp. 998–1008, 2018.
- Bau, D., Strobel, H., Peebles, W., Wulff, J., Zhou, B., Zhu, J.-Y., and Torralba, A. Semantic photo manipulation with a generative image prior. *ACM Transactions on Graphics (TOG)*, 38(4):59, 2019.
- Bojanowski, P. and Joulin, A. Unsupervised learning by predicting noise. In *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, pp. 517–526. JMLR. org, 2017.
- Carlucci, F. M., D’Innocente, A., Bucci, S., Caputo, B., and Tommasi, T. Domain generalization by solving jigsaw puzzles. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2229–2238, 2019.
- Caron, M., Bojanowski, P., Joulin, A., and Douze, M. Deep clustering for unsupervised learning of visual features. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 132–149, 2018.
- Caruana, R. Multitask learning. *Machine learning*, 28(1): 41–75, 1997.
- Chen, M., Weinberger, K. Q., and Blitzer, J. Co-training for domain adaptation. In *Advances in neural information processing systems*, pp. 2456–2464, 2011.
- Chen, X., Sun, Y., Athiwaratkun, B., Cardie, C., and Weinberger, K. Adversarial deep averaging networks for cross-lingual sentiment classification. *Transactions of the Association for Computational Linguistics*, 6:557–570, 2018.
- Cohen, J. M., Rosenfeld, E., and Kolter, J. Z. Certified adversarial robustness via randomized smoothing. *arXiv preprint arXiv:1902.02918*, 2019.
- Croce, F., Andriushchenko, M., and Hein, M. Provable robustness of relu networks via maximization of linear regions. *arXiv preprint arXiv:1810.07481*, 2018.
- Csurka, G. Domain adaptation for visual applications: A comprehensive survey. *arXiv preprint arXiv:1702.05374*, 2017.
- Ding, G. W., Wang, L., and Jin, X. AdverTorch v0.1: An adversarial robustness toolbox based on pytorch. *arXiv preprint arXiv:1902.07623*, 2019.
- Doersch, C., Gupta, A., and Efros, A. A. Unsupervised visual representation learning by context prediction. In *Proceedings of the IEEE International Conference on Computer Vision*, pp. 1422–1430, 2015.
- Fei-Fei, L., Fergus, R., and Perona, P. One-shot learning of object categories. *IEEE transactions on pattern analysis and machine intelligence*, 28(4):594–611, 2006.
- Finn, C., Abbeel, P., and Levine, S. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, pp. 1126–1135. JMLR. org, 2017.
- Gamerman, A., Vovk, V., and Vapnik, V. Learning by transduction. In *Proceedings of the Fourteenth conference on Uncertainty in artificial intelligence*, pp. 148–155. Morgan Kaufmann Publishers Inc., 1998.
- Gan, C., Yang, T., and Gong, B. Learning attributes equals multi-source domain generalization. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 87–97, 2016.
- Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., and Lempitsky, V. Domain-adversarial training of neural networks. *The Journal of Machine Learning Research*, 17(1):2096–2030, 2016.
- Geirhos, R., Temme, C. R., Rauber, J., Schütt, H. H., Bethge, M., and Wichmann, F. A. Generalisation in humans and deep neural networks. In *Advances in Neural Information Processing Systems*, pp. 7538–7550, 2018.
- Ghifary, M., Bastiaan Kleijn, W., Zhang, M., and Balduzzi, D. Domain generalization for object recognition with multi-task autoencoders. In *Proceedings of the IEEE international conference on computer vision*, pp. 2551–2559, 2015.
- Gidaris, S. and Komodakis, N. Dynamic few-shot visual learning without forgetting. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4367–4375, 2018.
- Gidaris, S., Singh, P., and Komodakis, N. Unsupervised representation learning by predicting image rotations. *arXiv preprint arXiv:1803.07728*, 2018.
- Gong, B., Shi, Y., Sha, F., and Grauman, K. Geodesic flow kernel for unsupervised domain adaptation. In *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2066–2073. IEEE, 2012.

- Goodfellow, I. J., Shlens, J., and Szegedy, C. Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*, 2014.
- Guo, C., Rana, M., Cisse, M., and van der Maaten, L. Countering adversarial images using input transformations. *arXiv preprint arXiv:1711.00117*, 2017.
- Hazan, E. et al. Introduction to online convex optimization. *Foundations and Trends® in Optimization*, 2(3-4):157–325, 2016.
- He, K., Zhang, X., Ren, S., and Sun, J. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016a.
- He, K., Zhang, X., Ren, S., and Sun, J. Identity mappings in deep residual networks. In *European conference on computer vision*, pp. 630–645. Springer, 2016b.
- He, K., Girshick, R., and Dollár, P. Rethinking imagenet pre-training. *arXiv preprint arXiv:1811.08883*, 2018.
- Hendrycks, D. and Dietterich, T. Benchmarking neural network robustness to common corruptions and perturbations. *arXiv preprint arXiv:1903.12261*, 2019.
- Hendrycks, D. and Gimpel, K. A baseline for detecting misclassified and out-of-distribution examples in neural networks. *arXiv preprint arXiv:1610.02136*, 2016.
- Hendrycks, D., Mazeika, M., Wilson, D., and Gimpel, K. Using trusted data to train deep networks on labels corrupted by severe noise. In *Advances in neural information processing systems*, pp. 10456–10465, 2018.
- Hendrycks, D., Lee, K., and Mazeika, M. Using pre-training can improve model robustness and uncertainty. *arXiv preprint arXiv:1901.09960*, 2019a.
- Hendrycks, D., Mazeika, M., Kadavath, S., and Song, D. Improving model robustness and uncertainty estimates with self-supervised learning. *arXiv preprint*, 2019b.
- Hoffman, J., Kulis, B., Darrell, T., and Saenko, K. Discovering latent domains for multisource domain adaptation. In *European Conference on Computer Vision*, pp. 702–715. Springer, 2012.
- Hoffman, J., Darrell, T., and Saenko, K. Continuous manifold based adaptation for evolving visual domains. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 867–874, 2014.
- Hoffman, J., Tzeng, E., Park, T., Zhu, J.-Y., Isola, P., Saenko, K., Efros, A. A., and Darrell, T. Cycada: Cycle-consistent adversarial domain adaptation. *arXiv preprint arXiv:1711.03213*, 2017.
- Hoffman, J., Mohri, M., and Zhang, N. Algorithms and theory for multiple-source adaptation. In *Advances in Neural Information Processing Systems*, pp. 8246–8256, 2018.
- Huang, G., Sun, Y., Liu, Z., Sedra, D., and Weinberger, K. Q. Deep networks with stochastic depth. In *European conference on computer vision*, pp. 646–661. Springer, 2016.
- Ioffe, S. and Szegedy, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *arXiv preprint arXiv:1502.03167*, 2015.
- Jain, V. and Learned-Miller, E. Online domain adaptation of a pre-trained cascade of classifiers. In *CVPR 2011*, pp. 577–584. IEEE, 2011.
- Kalal, Z., Mikolajczyk, K., and Matas, J. Tracking-learning-detection. *IEEE transactions on pattern analysis and machine intelligence*, 34(7):1409–1422, 2011.
- Kang, D., Sun, Y., Brown, T., Hendrycks, D., and Steinhardt, J. Transfer of adversarial robustness between perturbation types. *arXiv preprint arXiv:1905.01034*, 2019.
- Kannan, H., Kurakin, A., and Goodfellow, I. Adversarial logit pairing. *arXiv preprint arXiv:1803.06373*, 2018.
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, 114(13):3521–3526, 2017.
- Krizhevsky, A. and Hinton, G. Learning multiple layers of features from tiny images. Technical report, Citeseer, 2009.
- Larsson, G., Maire, M., and Shakhnarovich, G. Colorization as a proxy task for visual understanding. In *CVPR*, 2017.
- Li, D., Yang, Y., Song, Y.-Z., and Hospedales, T. M. Deeper, broader and artier domain generalization. In *Proceedings of the IEEE International Conference on Computer Vision*, pp. 5542–5550, 2017a.
- Li, D., Zhang, J., Yang, Y., Liu, C., Song, Y.-Z., and Hospedales, T. M. Episodic training for domain generalization. *arXiv preprint arXiv:1902.00113*, 2019.
- Li, Y., Tian, X., Gong, M., Liu, Y., Liu, T., Zhang, K., and Tao, D. Deep domain generalization via conditional invariant adversarial networks. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 624–639, 2018.

- Li, Z. and Hoiem, D. Learning without forgetting. *IEEE transactions on pattern analysis and machine intelligence*, 40(12):2935–2947, 2017.
- Li, Z., Zhou, F., Chen, F., and Li, H. Meta-sgd: Learning to learn quickly for few-shot learning. *arXiv preprint arXiv:1707.09835*, 2017b.
- Liu, Z., Sun, M., Zhou, T., Huang, G., and Darrell, T. Re-thinking the value of network pruning. *arXiv preprint arXiv:1810.05270*, 2018.
- Long, M., Cao, Y., Wang, J., and Jordan, M. I. Learning transferable features with deep adaptation networks. *arXiv preprint arXiv:1502.02791*, 2015.
- Long, M., Zhu, H., Wang, J., and Jordan, M. I. Unsupervised domain adaptation with residual transfer networks. In *Advances in Neural Information Processing Systems*, pp. 136–144, 2016.
- Lopez-Paz, D. and Ranzato, M. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, pp. 6467–6476, 2017.
- Madry, A., Makelov, A., Schmidt, L., Tsipras, D., and Vladu, A. Towards deep learning models resistant to adversarial attacks. *arXiv preprint arXiv:1706.06083*, 2017.
- Motiian, S., Piccirilli, M., Adjeroh, D. A., and Doretto, G. Unified deep supervised domain adaptation and generalization. In *Proceedings of the IEEE International Conference on Computer Vision*, pp. 5715–5725, 2017.
- Muandet, K., Balduzzi, D., and Schölkopf, B. Domain generalization via invariant feature representation. In *International Conference on Machine Learning*, pp. 10–18, 2013.
- Mullapudi, R. T., Chen, S., Zhang, K., Ramanan, D., and Fatahalian, K. Online model distillation for efficient video inference. *arXiv preprint arXiv:1812.02699*, 2018.
- Noroozi, M. and Favaro, P. Unsupervised learning of visual representations by solving jigsaw puzzles. In *European Conference on Computer Vision*, pp. 69–84. Springer, 2016.
- Raghunathan, A., Steinhardt, J., and Liang, P. Certified defenses against adversarial examples. *arXiv preprint arXiv:1801.09344*, 2018.
- Ravi, S. and Larochelle, H. Optimization as a model for few-shot learning. *IEEE transactions on pattern analysis and machine intelligence*, 2016.
- Recht, B., Roelofs, R., Schmidt, L., and Shankar, V. Do cifar-10 classifiers generalize to cifar-10? *arXiv preprint arXiv:1806.00451*, 2018.
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., and Fei-Fei, L. ImageNet Large Scale Visual Recognition Challenge. *International Journal of Computer Vision (IJCV)*, 115(3):211–252, 2015. doi: 10.1007/s11263-015-0816-y.
- Salman, H., Yang, G., Li, J., Zhang, P., Zhang, H., Razenshteyn, I., and Bubeck, S. Provably robust deep learning via adversarially trained smoothed classifiers. *arXiv preprint arXiv:1906.04584*, 2019.
- Santoro, A., Bartunov, S., Botvinick, M., Wierstra, D., and Lillicrap, T. Meta-learning with memory-augmented neural networks. In *International conference on machine learning*, pp. 1842–1850, 2016.
- Shalev-Shwartz, S. et al. Online learning and online convex optimization. *Foundations and Trends® in Machine Learning*, 4(2):107–194, 2012.
- Shankar, S., Piratla, V., Chakrabarti, S., Chaudhuri, S., Jyothi, P., and Sarawagi, S. Generalizing across domains via cross-gradient training. *arXiv preprint arXiv:1804.10745*, 2018.
- Shankar, V., Dave, A., Roelofs, R., Ramanan, D., Recht, B., and Schmidt, L. Do image classifiers generalize across time? *arXiv*, 2019.
- Shocher, A., Cohen, N., and Irani, M. zero-shot super-resolution using deep internal learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3118–3126, 2018.
- Sinha, A., Namkoong, H., and Duchi, J. Certifying some distributional robustness with principled adversarial training. *arXiv preprint arXiv:1710.10571*, 2017.
- Snell, J., Swersky, K., and Zemel, R. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, pp. 4077–4087, 2017.
- Song, Y., Kim, T., Nowozin, S., Ermon, S., and Kushman, N. Pixeldefend: Leveraging generative models to understand and defend against adversarial examples. *arXiv preprint arXiv:1710.10766*, 2017.
- Su, J.-C., Maji, S., and Hariharan, B. Boosting supervision with self-supervision for few-shot learning. *arXiv preprint arXiv:1906.07079*, 2019.
- Sun, Y., Tzeng, E., Darrell, T., and Efros, A. A. Unsupervised domain adaptation through self-supervision. *arXiv preprint*, 2019.

- Tripuraneni, N. and Mackey, L. Debiasing linear prediction. *arXiv preprint arXiv:1908.02341*, 2019.
- Tsipras, D., Santurkar, S., Engstrom, L., Turner, A., and Madry, A. Robustness may be at odds with accuracy. *arXiv preprint arXiv:1805.12152*, 2018.
- Tzeng, E., Hoffman, J., Saenko, K., and Darrell, T. Adversarial discriminative domain adaptation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 7167–7176, 2017.
- Vapnik, V. *The nature of statistical learning theory*. Springer science & business media, 2013.
- Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., et al. Matching networks for one shot learning. In *Advances in neural information processing systems*, pp. 3630–3638, 2016.
- Viola, P., Jones, M., et al. Rapid object detection using a boosted cascade of simple features. *CVPR (1)*, 1(511–518):3, 2001.
- Wong, E. and Kolter, J. Z. Provable defenses against adversarial examples via the convex outer adversarial polytope. *arXiv preprint arXiv:1711.00851*, 2017.
- Zhang, H., Yu, Y., Jiao, J., Xing, E. P., Ghaoui, L. E., and Jordan, M. I. Theoretically principled trade-off between robustness and accuracy. *arXiv preprint arXiv:1901.08573*, 2019.
- Zhang, R., Isola, P., and Efros, A. A. Colorful image colorization. In *European conference on computer vision*, pp. 649–666. Springer, 2016.
- Zhu, W., Huang, Y., Vannan, M. A., Liu, S., Xu, D., Fan, W., Qian, Z., and Xie, X. Neural multi-scale self-supervised registration for echocardiogram dense tracking. *arXiv preprint arXiv:1906.07357*, 2019.

附录：分布偏移下泛化的自监督测试时训练

A1. 关于可变决策边界的非正式讨论 在引言中，我们声称传统监督学习 θ 给出固定决策边界，而我们的 θ 给出可变决策边界。这里我们非正式地讨论这一主张。

记输入空间为 $\mathcal{X}$ ，输出空间为 $\mathcal{Y}$ 。决策边界就是一个映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 。设 Θ 为一个模型类，例如 $\mathbb{R}^d$ 。现在考虑一族参数化函数 $g_\theta: \mathcal{X} \rightarrow \mathcal{Y}$ ，其中 $\theta \in \Theta$ 。在深度学习的语境下， g 是神经网络架构， θ 包含参数。我们说 f 是一个固定决策边界 w.r.t. g 和 Θ ，如果存在 $\theta \in \Theta$ s.t. $f(x) = g_\theta(x)$ 对每个 $x \in \mathcal{X}$ 成立；而是一个可变决策边界，如果对每个 $x \in \mathcal{X}$ ，存在 $\theta \in \Theta$ s.t. $f(x) = g_\theta(x)$ 。注意对于可变决策边界， θ 的选择可以依赖于 x ，而对于固定决策边界则不能。在这些定义下，很容易验证我们的主张成立。

一位挑剔的读者可能会说，如果模型类任意大，难道不是每个决策边界都可以是固定的吗？是的，但事情并未就此结束。设 $d = \dim(\mathcal{X}) \times \dim(\mathcal{Y})$ ，并考虑巨大的模型类 $\Theta' = \mathbb{R}^d$ ，它能够表示 $\mathcal{X}$ 和 $\mathcal{Y}$ 之间的所有可能映射。设 $g'_{\theta'}$ 就是由 $\theta' \in \Theta'$ 表示的映射。那么相对于 g 和 Θ 的可变决策边界，相对于 g' 和 Θ' 确实必须是固定决策边界，但我们想指出两点。第一，在没有任何先验知识的情况下，用任何有限训练数据在 Θ' 中进行泛化是不可能的；从算法角度看，对 g' 和 Θ' 进行推理很可能没有成效，而可变决策边界的概念正是为了避免这种推理。第二，对于可变决策边界，基于 x 选择 θ 可以看作是在所有点 $x \in \mathbb{R}^d$ 上进行“训练”；然而，“训练”只在必要时发生，即针对它实际遇到的 x 。

总而言之，可变决策边界的概念不同于传统学习理论所能描述的内容。正式讨论超出了本文范围，可能成为未来工作的兴趣点。

A2. 我们方法的计算方面

在测试阶段，我们的方法比常规测试慢 $2 \times \text{批大小} \times \text{迭代次数}$ 倍，而常规测试仅对每个样本执行一次前向传播。作为测试时训练（Test-Time Training）的首项工作，本文更关注提升鲁棒性而非计算效率，但在此提供两种可能有用但尚未充分验证的潜在解决方案。第一种是对 l_s 使用阈值技巧，该方法在方法部分作为小批量问题的解决方案被引入。对于实验中考量的模型，约 80% 的测试实例低于阈值，因此测试时训练只需在其余 20% 上执行，对性能影响甚微，因为这 20% 包含了大多数预测错误的样本。第二种是减少测试时更新的迭代次数。对于在线版本，迭代次数已为 1，无需进一步处理。对于标准版本，我们进行了初步实验，将迭代次数设为 1（而非 10），学习率设为 0.01（而非 0.001），观察到结果几乎与标准超参数设置一样好。关于效率的更深入讨论留待未来工作，未来工作可能在训练期间显式地使模型易于快速更新。

A3. 证明

此处证明主论文中的理论结果。

A3.1. 玩具问题

以下设定适用于两个引理；这即玩具问题的设定，为便于参考在此重现。

考虑一个两层线性网络，其参数分别为 $\mathbf{A} \in \mathbb{R}^{h \times d}$ （共享）和 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^h$ （固定），对应两个头。记 $x \in \mathbb{R}^d$ 为输入， $y_1, y_2 \in \mathbb{R}$ 为两个任务的标签。对于主任务损失

$$l_m(\mathbf{A}; \mathbf{v}) = \frac{1}{2} (y_1 - \mathbf{v}^\top \mathbf{A}x)^2, \quad (12)$$

and the self-supervised task loss

$$l_s(\mathbf{A}; \mathbf{w}) = \frac{1}{2} (y_2 - \mathbf{w}^\top \mathbf{A}x)^2, \quad (13)$$

测试时训练得到更新后的矩阵

$$\mathbf{A}' \leftarrow \mathbf{A} - \eta (y_2 - \mathbf{w}^\top \mathbf{A}x) (-\mathbf{w}x^\top), \quad (14)$$

其中 η 为学习率。

引理 1。 遵循主论文的阐述，设

$$\eta^* = \frac{(y_1 - \mathbf{v}^\top \mathbf{A}x)}{(y_2 - \mathbf{w}^\top \mathbf{A}x)\mathbf{v}^\top \mathbf{w}x^\top x}. \quad (15)$$

假设 $\eta^* \in [\epsilon, \infty)$ 对某个 $\epsilon > 0$ 成立。那么对于任意 $\eta \in (0, \epsilon]$ ，我们保证主损失有所改进，即 $l_m(\mathbf{A}') < l_m(\mathbf{A})$ 。

证明。根据主论文的阐述，我们知道

$$l_m(\mathbf{A} - \eta^* \nabla l_s(\mathbf{A})) = 0,$$

这也可以通过简单的代数推导得出。然后由凸性，我们有

$$l_m(\mathbf{A} - \eta \nabla l_s(\mathbf{A})) \quad (16)$$

$$= l_m\left(\left(1 - \frac{\eta}{\eta^*}\right)\mathbf{A} + \frac{\eta}{\eta^*}(\mathbf{A} - \eta^* \nabla l_s(\mathbf{A}))\right) \quad (17)$$

$$\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(\mathbf{A}) + 0 \quad (18)$$

$$\leq \left(1 - \frac{\eta}{\epsilon}\right) l_m(\mathbf{A}) \quad (19)$$

$$< l_m(\mathbf{A}), \quad (20)$$

其中最后一个不等式利用了假设 $l_m(\mathbf{A}) > 0$ ，该假设成立是因为 $\eta^* > 0$ 。

引理 2。 定义 $\langle \mathbf{U}, \mathbf{V} \rangle = \text{vec}(\mathbf{U})^\top \text{vec}(\mathbf{V})$ i.e. the 弗罗贝尼乌斯内积，则

$$\text{sign}(\eta^*) = \text{sign}(\langle \nabla l_m(\mathbf{A}), \nabla l_s(\mathbf{A}) \rangle). \quad (21)$$

证明。通过简单的代数运算，

$$\begin{aligned} & \langle \nabla l_m(\mathbf{A}), \nabla l_s(\mathbf{A}) \rangle \\ &= \langle (y_1 - \mathbf{v}^\top \mathbf{A}x) (-\mathbf{v}x^\top), (y_2 - \mathbf{w}^\top \mathbf{A}x) (-\mathbf{w}x^\top) \rangle \\ &= (y_1 - \mathbf{v}^\top \mathbf{A}x) (y_2 - \mathbf{w}^\top \mathbf{A}x) \text{Tr}(x\mathbf{v}^\top \mathbf{w}x^\top) \\ &= (y_1 - \mathbf{v}^\top \mathbf{A}x) (y_2 - \mathbf{w}^\top \mathbf{A}x) \mathbf{v}^\top \mathbf{w}x^\top x, \end{aligned}$$

其符号与 η^* 相同。

A3.2. 定理 1 的证明

对于任意 η ，由光滑性和凸性，

$$\begin{aligned} l_m(x, y; \boldsymbol{\theta}(x)) &= l_m(x, y; \boldsymbol{\theta} - \eta \nabla l_s(x; \boldsymbol{\theta})) \\ &\leq l_m(x, y; \boldsymbol{\theta}) + \eta \langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle \\ &\quad + \frac{\eta^2 \beta}{2} \|\nabla l_s(x; \boldsymbol{\theta})\|^2. \end{aligned}$$

Denote

$$\eta^* = \frac{\langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle}{\beta \|\nabla l_s(x; \boldsymbol{\theta})\|^2}.$$

则方程 22 变为

$$l_m(x, y; \boldsymbol{\theta} - \eta^* \nabla l_s(x; \boldsymbol{\theta})) \quad (22)$$

$$\leq l_m(x, y; \boldsymbol{\theta}) - \frac{\langle \nabla l_m(x, y; \boldsymbol{\theta}), \nabla l_s(x, \boldsymbol{\theta}) \rangle^2}{2\beta \|\nabla l_s(x; \boldsymbol{\theta})\|^2}. \quad (23)$$

并且根据我们对梯度范数和梯度内积的假设，

$$l_m(x, y; \boldsymbol{\theta}) - l_m(x, y; \boldsymbol{\theta} - \eta^* \nabla l_s(x; \boldsymbol{\theta})) \geq \frac{\epsilon^2}{2\beta G^2}. \quad (24)$$

由于在实践中无法观测到 η^* ，我们改用固定学习率 $\eta = \frac{\epsilon}{\beta G^2}$ ，如定理 1 所述。现在论证该固定学习率仍能提升主任务的性能。

根据我们的假设， $\eta^* \geq \frac{\epsilon}{\beta G^2}$ ，so $\eta \in (0, \eta^*]$ 。记，则由 $\mathbf{g} = \nabla l_s(x; \boldsymbol{\theta})$ 的凸性，

$$l_m(x, y; \boldsymbol{\theta}(x)) = l_m(x, y; \boldsymbol{\theta} - \eta \mathbf{g}) \quad (25)$$

$$= l_m\left(x, y; \left(1 - \frac{\eta}{\eta^*}\right)\boldsymbol{\theta} + \frac{\eta}{\eta^*}(\boldsymbol{\theta} - \eta^* \mathbf{g})\right) \quad (26)$$

$$\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(x, y; \boldsymbol{\theta}) + \frac{\eta}{\eta^*} l_m(x, y; \boldsymbol{\theta} - \eta^* \mathbf{g}) \quad (27)$$

结合方程 24，我们得到

$$\begin{aligned} l_m(x, y; \boldsymbol{\theta}(x)) &\leq \left(1 - \frac{\eta}{\eta^*}\right) l_m(x, y; \boldsymbol{\theta}) \\ &\quad + \frac{\eta}{\eta^*} \left(l_m(x, y; \boldsymbol{\theta}) - \frac{\epsilon^2}{2\beta G^2}\right) \\ &= l_m(x, y; \boldsymbol{\theta}) - \frac{\eta}{\eta^*} \frac{\epsilon^2}{2\beta G^2} \end{aligned}$$

由于 $\eta/\eta^* > 0$ ，我们已经证明了

$$l_m(x, y; \boldsymbol{\theta}) - l_m(x, y; \boldsymbol{\theta}(x)) > 0. \quad (28)$$

A4. 常见损坏数据集上的额外结果

为了表格美观，我们使用以下缩写：B 代表基线，JT 代表联合训练，TTT 代表测试时训练标准版本，TTT-Online 代表在线测试时训练，即在线版本。

我们按顺序缩写损坏名称：原始测试集、高斯噪声、散粒噪声、脉冲噪声、散焦模糊、玻璃模糊、运动模糊、缩放模糊、雪、霜、雾、亮度、对比度、弹性变换、像素化和 JPEG 压缩。

A4.1. 使用批归一化的结果

如结果部分所讨论的，批归一化

批归一化 (Batch Normalization, BN) 对于小批量数据无效，而测试时训练 (标准版和在线版) 的输入正是小批量数据，因为每个批次形成时只有一个样本可用；因此，本文的主要结果基于使用组归一化 (Group Normalization, GN) 的残差网络 (ResNet)。图 A2 和表 A1 展示了本文方法在 CIFAR-10-C 第 5 级损坏上的结果，使用的是采用批归一化的残差网络。这些结果仅供感兴趣的读者参考。

在本项目早期阶段，我们尝试了两种潜在方案来解决批归一化在小批量数据上的问题。朴素方案是在测试时训练期间固定批归一化层，但这会减少共享参数的数量，从而降低性能提升。更好的方案是困难样本挖掘：不对所有输入进行更新，而是仅对导致较大自监督任务损失的输入进行更新 l_s ，其中较大的改进可能抵消不准确统计量的负面影响。

测试时训练 (标准版) 在批归一化下仍然非常有效。事实上，某些改进相当显著，例如在对比度 (34%)、蓝色散焦 (18%) 和高斯噪声 (与联合训练相比 22%，与基线相比 16%) 上。原始分布上的性能几乎保持不变，且使用批归一化的原始误差实际上略低于组归一化，并且收敛所需的训练轮次减少一半。

我们没有进一步使用批归一化进行实验，原因有二：1) 在线版不适用于批归一化，因为在线训练许多步 (例如 10000 步) 时，不准确批次统计量的问题会加剧。2) 几乎所有损坏类型的基线误差在使用批归一化时都显著高于组归一化。尽管与本文的主要思想无关，我们注意到一个有趣的现象：组归一化显著提高了模型的鲁棒性。

A4.2. 附加基线：对抗性对数配对

如结果部分所述，亨德里克斯与迪特里希 (2019) 指出，对抗性对数配对 (ALP) (坎南等人, 2018) 是提升模型对损坏与扰动鲁棒性的有效方法，尽管其最初设计用于防御对抗性攻击。我们将 ALP 作为所有基于 CIFAR-10 (使用组归一化) 基准的额外基线，遵循坎南等人 (2018) 的训练流程及其推荐的超参数。对抗性攻击的实现来自丁等人 (2019) 的代码库。我们未在 ImageNet 上运行 ALP，因为我们引用的两篇关于该方法的论文，坎南等人 (2018) 与亨德里克斯和迪特里希 (2019)，均未在 ImageNet 上运行或提出任何主张或建议。

A4.3. CIFAR-10-C 与 ImageNet-C 第 5 级的结果

表 A2 与表 A3 对应结果部分中的条形图。表 A2 的两行已在正文中作为表 1 呈现。

A4.4. CIFAR-10-C 第 1 至 4 级的结果

以下条形图与表格展示 CIFAR-10-C 第 1 至 4 级的结果。原始分布在所有级别上相同，因此我们在原始分布上的结果也相同。

A4.5. 与亨德里克斯等人 (2019a) 的直接比较

以下比较由一位匿名审稿人为我们的最终版本提出。我们的联合训练基线基于亨德里克斯等人 (2019a)，但也包含一些架构改动 (见下文)。我们发现这些改动提升了我们方法的鲁棒性，并认为给予基线同样的优势是重要的。请注意，我们的联合训练基线整体表现优于亨德里克斯：将表 S2 与亨德里克斯等人 (2019a) 的图 3 (由作者提供) 进行比较，我们的基线在所有损坏与级别上的平均误差为 22.8%，而他们的平均误差为 28.6%。

架构改动总结：1) 使用组归一化 (GN) 代替批归一化 (BN)。为完整性起见，使用 BN 的结果见表 S1；对比表 S2 中的 GN 结果，无论是否使用自监督，鲁棒性均显著提升。2) 我们在第二个残差组之后进行分割，而他们在第三个残差组之后、线性层之前进行分割。这一改动持续带来约 0.5% 至 1% 的改进。3) 我们使用 ResNet-26，而他们使用 40-2 宽残差网络。但即使我们的网络小 4 倍，由于上述两个技巧，我们的基线仍优于他们的方法。




图 A1. 来自常见损坏基准的样本图像，取自亨德里克斯与迪特里希（2019）的原始论文。




图 A2. 在 CIFAR-10-C、第 5 级、带批归一化的 ResNet-26 上的测试误差（%）。

原始	高斯	散粒	脉冲	散焦	玻璃	运动	缩放	雪	霜	雾	亮度	对比度	弹性	像素化	压缩	基线	7.9	63.9	58.8	64.3	46.3	54.6	41.6	
45.9	31.9	44.0	37.5	13.0	69.2	33.8	61.4	31.7	联合训练	7.5	70.7	65.6	67.2	43.1	55.4	40.9	42.7	30.3	44.5	42.5	12.7	58.6	30.7	62.6
31.9	测试时训练	7.9	47.9	45.2	54.8	27.6	50.4	31.5	30.9	28.7	34.3	26.9	12.6	35.2	30.6	51.2	31.3							

表 A1. 在 CIFAR-10-C、第 5 级、带批归一化的 ResNet-26 上的测试误差（%）。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	8.9	50.5	47.2	56.1	23.7	51.7	24.3	26.3	25.6	34.4	28.1	13.5	25.0	27.4	55.8	29.8
JT	8.1	49.4	45.3	53.4	24.2	48.5	24.8	26.4	25.0	32.5	27.5	12.6	25.3	24.0	51.6	28.7
TTT	7.9	45.6	41.8	50.0	21.8	46.1	23.0	23.9	23.9	30.0	25.1	12.2	23.9	22.6	47.2	27.2
TTT-Online	8.2	25.8	22.6	30.6	14.6	34.4	18.3	17.1	20.0	18.0	16.9	11.2	15.6	21.6	18.1	21.2
UDA-SS	9.0	28.2	26.5	20.8	15.6	43.7	24.5	23.8	25.0	24.9	17.2	12.7	11.6	22.1	20.3	22.6
ALP	16.5	22.7	22.9	28.3	25.0	25.6	27.4	23.1	25.2	27.2	64.8	21.7	73.6	23.0	20.2	18.9

Table A2. Test error (%) on CIFAR-10-C, level 5, ResNet-26.

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	68.9	1.3	2.0	1.3	7.5	6.6	11.8	16.2	15.7	14.9	15.3	43.9	9.7	16.5	15.3	23.4
JT	69.1	2.1	3.1	2.1	8.7	6.7	12.3	16.0	15.3	15.8	17.0	45.3	11.0	18.4	19.7	22.9
TTT	69.0	3.1	4.5	3.5	10.1	6.8	13.5	18.5	17.1	17.9	20.0	47.0	14.4	20.9	22.8	25.3
TTT-Online	68.8	26.3	28.6	26.9	23.7	6.6	28.7	33.4	35.6	18.7	47.6	58.3	35.3	44.3	47.8	44.3

表 A3. 在 ImageNet-C、第 5 级、ResNet-18 上的测试准确率（%）。




图 A3. 在 CIFAR-10-C、第 4 级上的测试误差 (%)。详见结果部分。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	8.9	46.4	39.2	44.8	15.3	52.5	19.1	20.5	21.3	26.9	13.3	10.5	13.7	20.8	35.3	26.9
JT	8.1	45.0	38.3	42.2	16.4	50.2	20.7	20.5	21.1	25.4	14.1	10.0	14.7	19.0	33.2	25.1
TTT	7.9	41.5	35.4	39.8	15.0	47.8	19.1	18.4	20.1	24.0	13.5	10.0	14.1	17.7	29.4	24.5
TTT-Online	8.2	22.9	20.0	23.9	11.2	35.1	15.6	13.8	18.6	15.9	12.3	9.7	11.9	16.7	13.6	19.8
ALP	16.5	21.3	20.5	24.5	20.7	25.9	23.7	21.4	24.2	23.9	42.2	17.5	53.7	22.1	19.1	18.5

表 A4. 在 CIFAR-10-C、第 4 级、ResNet-26 上的测试误差 (%)。




图 A4. 在 CIFAR-10-C、第 3 级上的测试误差 (%)。详见结果部分。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	8.9	42.2	35.1	30.7	12.2	41.7	18.6	17.5	19.0	25.3	10.8	9.7	11.6	15.3	21.7	24.6
JT	8.1	40.2	34.4	29.9	12.2	37.9	20.8	17.3	18.4	25.0	11.4	9.2	12.0	15.2	20.8	22.8
TTT	7.9	37.2	31.6	28.6	11.5	35.8	19.1	15.8	17.8	23.3	11.0	9.1	11.6	14.3	18.9	22.3
TTT-Online	8.2	21.3	17.7	17.9	9.0	23.4	15.3	12.5	16.4	15.8	10.9	9.0	10.7	12.8	12.2	18.7
ALP	16.5	20.0	19.3	20.5	19.2	21.2	24.0	20.5	20.9	24.2	30.1	16.6	39.6	20.9	17.8	18.0

表 A5. CIFAR-10-C 第 3 级上的测试误差 (%)，ResNet-26。




图 A5. CIFAR-10-C 第 2 级上的测试误差 (%)。详见结果部分。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	8.9	31.7	22.6	24.3	9.9	42.6	14.9	14.7	21.7	18.4	9.8	9.1	10.0	13.1	17.1	22.4
JT	8.1	31.0	22.6	23.4	9.1	39.2	16.4	14.2	21.2	17.5	9.4	8.3	10.6	12.8	15.9	20.5
TTT	7.9	28.8	20.7	23.0	9.0	36.6	15.4	13.1	20.2	16.9	9.2	8.3	10.2	12.5	14.8	19.7
TTT-Online	8.2	16.8	13.8	15.5	8.5	23.4	13.3	11.5	16.8	12.7	9.4	8.4	9.7	12.4	11.5	17.0
ALP	16.5	18.0	17.2	19.0	17.8	20.7	21.2	19.3	19.0	20.1	22.4	16.3	29.2	20.3	17.4	17.8

表 A6. CIFAR-10-C 第 2 级上的测试误差 (%)，ResNet-26。




图 A6. CIFAR-10-C 第 1 级上的测试误差 (%)。详见结果部分。

	orig	gauss	shot	impul	defoc	glass	motn	zoom	snow	frost	fog	brit	contr	elast	pixel	jpeg
B	8.9	21.7	17.1	17.0	9.0	44.0	12.1	13.9	14.3	13.4	9.2	8.9	9.0	13.2	12.0	17.3
JT	8.1	20.4	16.6	16.9	8.2	40.5	12.2	13.0	13.1	12.3	8.4	8.1	8.5	12.9	11.3	15.9
TTT	7.9	19.1	15.8	16.5	8.0	37.9	11.7	12.2	12.8	11.9	8.2	8.0	8.3	12.6	11.1	15.5
TTT-Online	8.2	13.8	11.9	12.2	8.5	24.4	10.5	11.5	12.4	10.7	8.5	8.3	8.6	12.4	10.7	14.4
ALP	17.0	16.8	17.6	16.8	20.9	18.7	19.0	17.3	17.5	17.4	16.1	18.4	20.4	17.0	17.2	17.5

表 A7. CIFAR-10-C 第 1 级上的测试误差 (%)，ResNet-26。




图 A7. 结果部分中适用于 CIFAR-10 的 VID-Robust 数据集 (Shankar 等人, 2019) 的样本图像。每行显示一个类别的八张样本图像。按顺序显示的七个类别为: 飞机、鸟、汽车、狗、猫、马、船。