

TTT-Parkour: 面向感知型机器人跑酷的快速测试时训练

Shaoting Zhu^{12*}, Baijun Ye^{12*}, Jiaxuan Wang^{1†}, Jiakang Chen^{1†}, Ziwen Zhuang¹²,
Linzhan Mou³, Runhan Huang¹, Hang Zhao^{12‡}

¹Tsinghua University, ²Shanghai Qi Zhi Institute, ³Princeton University

*Equal contribution †Equal contribution ‡Corresponding author

摘要——在未知复杂地形上实现高动态人形机器人跑酷仍是机器人领域的一项挑战。尽管通用运动策略在广泛地形分布中展现出一定能力，但它们往往难以应对任意且极具挑战性的环境。为克服这一局限性，本文提出一种真实到仿真再到真实（real-to-sim-to-real）框架，利用在未知地形上的快速测试时训练（Test-Time Training, TTT），显著增强机器人穿越极端困难几何体的能力。本文采用两阶段端到端学习范式：策略首先在多样化的程序生成地形上进行预训练，随后在由真实世界捕获重建的高保真网格上进行快速微调。具体而言，本文开发了一种基于 RGB-D 输入的前馈式、高效且高保真的几何重建流程，确保测试时训练的速度与质量。实验证明，TTT-Parkour 使人形机器人能够掌握复杂障碍物，包括楔形、桩柱、箱体、梯形及窄梁。在大多数测试地形上，捕获、重建与测试时训练的完整流程耗时不足 10 分钟。大量实验表明，经过测试时训练的策略展现出鲁棒的零样本仿真到现实迁移能力。项目页面：<https://tttparkour.github.io>。




图 1: 在未见地形上的快速测试时训练。通过重建场景并在仿真中微调，我们的框架使机器人能够在 10 分钟内掌握具有挑战性的障碍，将失败（左）转变为成功（右）。

I. 引言

深度强化学习的最新进展从根本上革新了人形机器人运动控制，使机器人能够在多样化的真实环境中展示稳健的移动能力 [15, 35, 55]。通过利用大规模并行仿真和仿真到现实迁移技术 [32, 31]，人形机器人现在能够穿越非结构化地形。尽管一些通用策略在广泛的地形分布上展示了能力，但它们难以穿越未见过的复杂障碍。弥合这一差距以实现真正的运动智能对于人形机器人在挑战性环境中的部署至关重要。尽管大规模仿真训练提升了人形机器人的能力，但仅依赖程序化生成来创建地形存在固有的局限性。由简单几何基元组成的合成地形往往无法捕捉现实世界中地形类型的广泛谱系及其复杂的空间配置。在预训练期间不可能穷尽覆盖每一个潜在环境。在如此受限的数据分布上训练的策略不可避免地会在真实世界部署时遭遇分布外问题。因此，迫切需要一种能够在测试时实现快速适应的范式。此外，在仿真中手动复现逼真的几何特征非常耗费人力。虽然逐场景优化

诸如神经辐射场（Neural Radiance Fields, NeRF）[22, 53, 47, 5] 与三维高斯泼溅（3D Gaussian Splatting, 3DGS）[29, 34, 48, 24] 等方法在视图综合方面表现卓越，并可扩展至物理交互 [10, 54, 14]，然而其整体工作流程通常计算密集且耗时，难以满足测试时训练的快速适应需求。相反，前馈式 [42, 43, 44, 21] 与生成式 [7] 方法速度更快，但在某些地形上常产生尺度模糊或几何失真的结果，因而无法用于本文跑酷场景中的物理仿真。因此，在快速适应所需的紧迫时间窗口内生成碰撞精确、可直接用于仿真的网格，仍是一个关键瓶颈。为应对这些挑战，本文提出 TTT-Parkour，一个面向挑战性地形（包括楔形、桩柱、箱体、梯形与窄梁）的快速人形机器人适应的真实到仿真再到真实框架。本文方法建立在一个两阶段端到端感知运动学习范式之上。首先，本文在程序化生成的多样化地形集上预训练一个通用策略。随后，本文在由真实地形重建的网格上对该策略进行微调。本文开发了一套基于 RGB-D 输入的高效高保真几何重建流程。本文采用一种具有自动尺度恢复与帧对齐功能的前馈方法，直接重建可直接用于仿真的网格。该流程使策略能够在精确几何约束下进行测试时训练，显著加速适应过程并缩小仿真到真实的差距。值得注意的是，本文的高效自动化流程

框架支持快速适应。对于大多数测试地形，它能在 10 分钟内完成捕获、重建和测试时训练阶段。这使得机器人能够快速更新其策略，即使在遇到预训练期间从未见过的几何不规则性时，也能确保稳健而敏捷的跑酷性能。大量实验表明，采用课程学习的预训练阶段和针对特定地形的测试时训练阶段，对于在极具挑战性的地形上实现稳健性能都是必不可少的。总之，我们的主要贡献如下：

- 我们引入了一个两阶段的端到端感知运动学习范式，包括预训练和快速测试时训练，这两者对于穿越极具挑战性的地形都是必不可少的。
- 我们开发了一种快速、前馈且高保真的几何重建流程，从 RGB-D 输入生成可直接用于仿真的网格，从而实现高效的从真实到仿真再到真实的跑酷工作流程。
- 实验表明，在极具挑战性的地形上，敏捷而稳健的人形机器人跑酷能力能够迅速涌现，显著超越了基线。

II. 相关工作

A. 感知运动

整合外部感知对于敏捷运动至关重要，它使机器人能够从盲目的、反应式的恢复 [23, 18, 13] 过渡到主动的障碍物穿越。传统的基于地图的方法通常利用激光雷达结合精确定位来构建高程图 [15, 28, 41, 35] 或体素网格 [4]。然而，这些方法在高动态跑酷过程中容易受到状态估计漂移和运动失真的影响，使得全局地图在极具挑战性的地形上变得不可靠。另外，最近的工作探索了利用深度图像作为策略输入 [37, 38, 9]，保留中间的高度图表示。遵循 [56, 8, 55] 的范式，我们采用前向深度相机来端到端地训练策略。这种方法在高速穿越过程中具有鲁棒性。此外，与激光雷达相比，深度相机具有更高的频率，这使其本质上更适合需要精确选择落脚点的任务。然而，大多数基于学习的方法，包括基于高度图的方法和端到端方法，仍然局限于结构化地形，并且通常无法泛化到落脚点极其稀疏的非结构化复杂环境。

B. 快速适应

测试时自适应 (Test-Time Adaptation) [45, 39, 3, 2] 起源于经典机器学习，作为一种轻量级在线微调范式，用于在推理过程中缓解分布外偏移，并已在基础模型中通过梯度更新 [3, 1] 得到扩展。在机器人学习中，测试时的快速自适应近年来得到了广泛探索：基于扩散的控制器 [19, 27, 17] 在测试时引入显式奖励和代价函数的梯度作为引导，以优化期望的行为结果。虽然这类方法提供了灵活性，但生成的轨迹可能会被梯度更新拉离

分布内数据流形，导致性能崩溃。其他方法使用生成模型对新颖环境和形态进行测试时自适应 [6]。据我们所知，我们是首个利用快速测试时训练范式使人形机器人能够掌握未见过的复杂地形的工作。

C. 场景重建

高保真重建对于增强仿真真实感和弥合仿真到现实的差距至关重要。虽然逐场景优化方法如神经辐射场 (NeRF) [22, 53, 47, 5] 和三维高斯泼溅 (3DGS) [29, 48, 34, 46, 49, 52, 24, 25, 26] 在视觉综合方面表现出色，且近期扩展能够提取用于物理交互的网格 [10, 54, 14, 40]，但它们无法满足测试时训练 (TTT) 的自动化和效率要求。它们依赖离线、多阶段流程（例如 COLMAP 或迭代优化）[54, 29]，阻碍了快速在线自适应。相反，近期前馈技术 [42, 43, 21] 绕过了优化，但存在尺度模糊或显著的度量差异。虽然 RoLA [51] 能够从单张图像进行操作学习，但它仅限于桌面场景中的小物体。相比之下，跑酷环境涉及长跨度地形，具有复杂布局和遮挡。因此，单图像生成 [7] 得到的空间布局往往包含严重的几何失真。这种几何不保真使得生成的网格不适合跑酷任务。为了解决这个问题，我们引入了一条高效流水线，将前馈重建与自动尺度和帧对齐相结合，生成具有测试时跑酷训练所需速度和保真度的仿真就绪网格。

III. 方法

A. 问题定义

我们将任务定义为穿越一系列高于地面的离散平台 $\mathcal{P} = \{p_{\text{start}}, p_1, \dots, p_n, p_{\text{end}}\}$ 。机器人旨在从 p_{start} 移动到 p_{end} ，遵循固定的前进速度指令，没有显式的角速度指令。为确保有效穿越，与地面平面 $\mathcal{G}_{\text{ground}}$ 的接触被视为失败状态，防止机器人通过在地面移动来绕过障碍物。地形由接触面积有限的几何基元组成（例如楔形、桩、盒子、梯形和窄梁），要求策略通过精确的落脚点选择来保持稳定。

B. 策略预训练

我们将感知运动任务表述为强化学习 (Reinforcement Learning, RL) 问题，并使用近端策略优化 (Proximal Policy Optimization, PPO) [36] 优化策略。该策略采用基于卷积神经网络 (CNN) 的深度编码器提取潜在特征，然后将这些特征与本体感觉信息拼接，并输入多层感知机 (MLP) 以预测最终动作。

观测：策略的观测空间旨在为稳定运动提供全面的状态信息。执行器的观测 $\mathbf{o}_t^a$ 结合了本体感觉数据和视觉感知。具体而言，本体感觉




图 2: TTT-Parkour。 我们的框架包含三个阶段：（1）预训练：在多样化的程序生成地形上预训练通用策略，以学习鲁棒的运动基元。（2）测试时训练（Test-time Training, TTT）：我们使用前馈重建，结合自动尺度恢复和帧对齐，从真实世界捕获中重建高保真且可仿真的网格。然后在仿真中针对这些特定地形快速微调策略。（3）仿真到真实部署：将适应后的策略直接部署到真实人形机器人上，实现对复杂未见障碍物的零样本穿越。

包括基础角速度 ω_t 、投影重力向量 $\mathbf{g}_t$ 、速度指令 $\mathbf{c}_t$ 、关节位置 $\mathbf{q}_t$ 、关节速度 $\dot{\mathbf{q}}_t$ 以及上一动作 $\mathbf{a}_{t-1}$ 。为处理部分可观测性并捕捉运动动态，我们采用长度为 h 的历史滑动窗口。最终观测是本体感觉历史与深度图像序列的拼接

$$\mathbf{I}_t \in \mathbb{R}^{W \times H};$$

$$\mathbf{o}_t^a = [\mathbf{p}_{t-h+1:t}, \mathbf{H}_t], \quad (1)$$

其中 $\mathbf{p}_t = (\omega_t, \mathbf{g}_t, \mathbf{c}_t, \mathbf{q}_t, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1})$ 表示时间 t 处的本体感觉向量。我们对深度图像使用跨步窗口以获得较长历史。

$$\mathbf{H}_t = \{\mathbf{I}_{t-k:\ell} \mid k = 0, 1, \dots, m-1\}, \quad (2)$$

在训练过程中，我们向演员的输入注入随机噪声，以增强鲁棒性并弥合仿真到现实的差距。我们采用非对称的演员-评论家架构。评论家可以访问特权信息，包括无噪声状态和基座线速度 $\mathbf{v}_t \in \mathbb{R}^3$ ，以指导学习过程。

动作： 策略输出目标关节位置 $\mathbf{a}_t \in \mathbb{R}^{29}$ 。这些位置通过 PD 控制器转换为关节力矩 $\boldsymbol{\tau}_t$ ：

$$\boldsymbol{\tau}_t = k_p(\mathbf{a}_t - \mathbf{q}_t) - k_d\dot{\mathbf{q}}_t. \quad (3)$$

其中增益 k_p 和 k_d 取自 [27]。

终止条件： 如果满足以下任一条件，训练回合终止：（1）机器人在起始位置卡住超过 4 秒；（2）任何身体连杆接触地面；（3）基座姿态超过允许阈值。

奖励： 奖励函数包括任务 r_{task} 、正则化 r_{reg} 、安全 r_{safe} 和 AMP r_{AMP} 项。我们将任务表述为目标位置跟踪，其中目标速度由目标向量导出并裁剪到最大值，以防止奖励黑客行为（例如，在起点处掉头）。值得注意的是，我们不提供角速度指令；机器人必须自主决定转向。我们利用密集的速度跟踪奖励来调节速度，而不是稀疏的目标奖励。正则化项惩罚地形边缘的落脚点、能量消耗和动作速率以防止振荡，而安全项则强制执行关节限制。此外，我们利用在 MPC 生成的数据集 [12] 上训练的对抗性运动先验（AMP）[33] 来鼓励自然且鲁棒的运动风格。详情见附录。

C. 高效几何重建

为便于对未见地形进行快速测试时训练，本文提出一种高效、自动化且高保真的重建流程，该流程将前馈重建与自动尺度恢复及帧对齐相结合，如图 3 所示。形式上，本文将重建问题定义为将真实世界采集数据 $\mathcal{P}_{1:n}$ 转换为仿真就绪网格 $\mathcal{M}$ ，该网格严格对齐于重力轴 $\mathbf{g}$ 和起点到终点的遍历方向 $\mathbf{d}$ 。

前馈地形重建： 本文首先采用前馈模型 [43]，以 RGB 序列为输入重建尺度模糊的点云。随后，应用筛选泊松曲面重建 [20] 恢复网格。

尺度恢复： 现有的仅 RGB 和度量前馈




图 3：高效几何重建。本文流程包含四个阶段：（1）真实世界采集。（2）前馈重建从 RGB 序列提供初始场景几何。（3）尺度恢复通过将推断深度与传感器深度对齐来修正度量尺度差异。（4）物理一致的帧对齐利用三维语义分割将地形配准到仿真坐标系，使 z 轴与重力方向对齐， x 轴与遍历方向对齐。

如表 IV 所示，方法 [43, 21] 在部分地形上预测精确绝对尺度不可靠。这种不确定性至关重要，因为标准尺度随机化 (e.g., $s \in [0.9, 1.1]$) 不足以补偿未见地形上的任意尺度偏差。例如，若在木桩或窄梁等几何受限地形上尺度被显著低估，仿真器中的有效接触面积将变得不可行地小，导致任务在物理上不可解，阻碍策略收敛。

为确保精确对齐，本文通过将前馈模型预测的深度与 RGB-D 相机的度量深度对齐来计算缩放因子。具体而言，计算深度图像下半部分导出的中值深度之比。该感兴趣区域选择有效聚焦于地形，同时减轻远处背景离群点的干扰。此对齐步骤至关重要，因为它最小化了仿真到现实的差距，并确保任何残余尺度偏差落在标准领域随机化的可处理范围内。

坐标系对齐：给定缩放后的点云与重建网格，本文的目标是将地形配准至物理一致的世界坐标系中。在该坐标系中，原点锚定于起始平台 p_{start} 的质心，而 z 轴与 x 轴分别与重力方向和预期遍历方向对齐。本文假设物理地平面与重力向量正交。为稳健估计该平面，首先利用三维分割模型 [50] 提取语义标记为地面的点。随后应用随机抽样一致算法 (RANSAC) [11] 稳健滤除分割地面点中的离群点，再通过主成分分析 (PCA) 精确估计表面法线 $\mathbf{n}$ 。接着旋转整个场景，使 $\mathbf{n}$ 与仿真中的 z 轴对齐。为对齐遍历方向，识别由语义分割得到的起始平台 (p_{start}) 与终止平台 (p_{end}) 的质心。然后绕 z 轴旋转场景，使连接两质心的向量与仿真中的 x 轴对齐。该对齐确保机器人在仿真中的前进速度指令与物理地形布局在几何上一致。

D. 策略快速测试时训练

在预训练之后，本文对特定目标地形执行快速测试时训练，利用重建流程生成的仿真就绪网格。关键的是，保持与预训练期间相同的马尔可夫决策过程 (MDP) 公式，保留相同的观测空间、动作空间、终止条件与奖励函数。基于预训练策略，本文研究四种不同的微调策略。

(1) 全量微调：从预训练检查点直接开始，端到端更新策略网络的所有参数。

(2) 适配器模块：在深度编码器与多层感知机 (MLP) 的每一层之后插入轻量级适配器。冻结原始权重，仅优化适配器模块。关键的是，适配器输出采用零初始化，以在开始时保持原始特征调制不变。

(3) 残差学习：添加一个并行网络来学习加性动作修正 ($\mathbf{a}_{\text{total}} = \mathbf{a}_{\text{base}} + \mathbf{a}_{\text{res}}$)。基础策略被冻结，残差输出层初始化为零，使得初始时为零，从而在初始阶段有效保持原始策略行为。

(4) 最后一层微调：冻结深度编码器和中间多层感知机层，将更新严格限制在演员策略的最终线性层。

四、实验

在本节中，我们在仿真和真实场景中对 TTT-Parkour 框架进行全面评估。我们将策略部署到一系列极具挑战性的地形上，旨在突破人形机器人运动的极限，包括楔形、桩、箱子、梯形和窄梁。我们尝试回答以下关键问题：

问题 1. 必要性与效率：预训练和快速测试时训练对于在未见过的、极具挑战性的地形上实现敏捷运动是否都是必不可少的，并且该过程是否足够高效以用于实际部署？

问题 2. 策略消融：不同的微调策略在性能和稳定性方面如何比较？




图 4：真实世界实验。机器人成功穿越了极具挑战性的地形，包括：(a) 楔形物，(b) 桩，(c) 箱子，(d) 梯形物，(e) 窄梁，以及 (f) 混合地形。更多内容请参见视频。

问题 3：重建质量与速度：不同数据源下的重建保真度和速度有何差异？与仅使用 RGB 的方法相比，RGB-D 是否必要？

问题 4：收敛性分析：哪些因素影响测试时训练过程的样本效率和所需迭代次数？

A. 实验配置

1) 训练设置：我们利用由 IsaacSim 驱动的 IsaacLab [32] 进行高保真物理仿真和策略训练。所有实验均在一台配备 NVIDIA RTX 5090 GPU 的工作站上运行，并行运行 4096 个人形机器人智能体，每次迭代耗时不到 4 秒。我们利用 NVIDIA Warp 框架 [30] 实现 GPU 加速的光线投射深度仿真。

所采用的机器人 为宇树 G1 29 自由度 (Unitree G1 29Dof)。本文对策略进行 100,000 次迭代的预训练，利用长度为 $h = 8$ 的历史记录来捕捉时序观测。随后，本文捕获并重建场景以进行测试时训练。

2) 策略在真实机器人上的部署：本文将仿真中训练的策略零样本迁移至真实机器人。该策略通过 ROS2 部署在机器人机载的英伟达 (NVIDIA)

Jetson Orin NX 计算机上，推理循环以 50 赫兹运行。在感知方面，本文利用机载的英特尔实感 D435i (Intel RealSense D435i) 相机，其工作频率为 60 赫兹。原始深度图像以 480×270 的分辨率捕获，下采样至 64×36 ，随后裁剪为 32×18 的块，覆盖中心底部区域，以聚焦于近处地形几何。

3) 测试地形：本文实验聚焦于五类地形：楔形、桩、箱体、梯形和窄梁。在所有实验设置中，起始和终止平台均构建为大型箱体，尺寸约为长 90 厘米、宽 80 厘米、高 35 厘米。

所有中间障碍物的布置均要求机器人穿越它们而不接触地面。在预训练阶段，本文采用程序化生成在仿真中创建这五类地形的多样化变体。为确保鲁棒性，本文对每个障碍物的位置、尺寸和形状进行随机化。仿真环境组织为 $a 20 \times 10$ 网格，包含 5 个不同的地形类别，每个类别占据 4 列。在每列中，10 行遵循课程训练策略 [16]，难度从第一行到最后一行逐步增加。

表一：13 种地形上的仿真成功率。本文比较了预训练策略（在程序化地形上训练）、从零开始策略（在单一目标地形上从头训练）、TTT-13 策略（在所有 13 种地形上同时微调）以及 TTT-1 策略（仅在单一目标地形上微调）。

Methods / Terrains	Boxes	Wedges	Nar.1	Nar.2	Nar.3	Trap.1	Trap.2	Boston	Stake1	Stake2	Stake3	Mix1	Mix2
Pre-train	98.6%	0.1%	81.2%	88.4%	65.6%	0.0%	7.4%	0.0%	4.4%	0.0%	9.9%	0.0%	0.1%
Scratch-1 (25k iters)	0.0%	0.0%	100.0%	100.0%	0.0%	0.0%	0.0%	0.0%	0.0%	0.0%	0.0%	0.0%	0.0%
TTT-13 (1k iters)	98.7%	100.0%	99.9%	100.0%	99.6%	100.0%	99.6%	73.6%	100.0%	100.0%	100.0%	99.9%	99.5%
TTT-1 (Converged)	100.0%	100.0%	100.0%	100.0%	99.4%	100.0%	100.0%	99.9%	100.0%	100.0%	100.0%	99.9%	100.0%




图 5：测试时训练（TTT-1）迭代过程中的成功率进展。该策略在先前未见过的地形上迅速收敛至高性能。




图 6：预训练策略与 TTT-1 策略在真实世界中的成功率。

具体而言，难度通过改变几何参数来调节：难度越高，间隙越大，平台尺寸越小。代表性示例见图 2 左侧。在真实世界的测试时训练与部署阶段，我们实际构建了 13 种不同的测试地形，涵盖上述各类别。每种地形均采用随机化的空间布局与朝向，以严格考验机器人在未知几何结构上的适应能力。详细规格见附录。

4) 评估指标：我们采用成功率作为实验的主要度量。每次试验中，机器人从起始平台出发，被赋予恒定的前向线速度与零角速度。若机器人成功穿越地形并抵达终点平台，且未接触地面或跌落，则记为一次成功。为确保统计可靠性，每个真实世界实验进行 5 次试验，每个仿真实验进行 1000 次试验。

B. 可通过性分析

为确定测试时训练的必要性及效率，我们在仿真环境中与四种基线方法进行了对比分析。各方法定义如下：

(1) **预训练**：基础策略在大规模程序化生成的地形上训练，并直接部署，未进行

adaptation.

(2) **从零开始-1**：一种策略，从随机初始化开始，直接在单个特定的重建真实世界地形上进行训练。

(3) **TTT-13**：一种在所有 13 个可用的重建真实世界地形上同时进行微调的策略。

(4) **TTT-1 (本文方法)**：本文提出的框架，在真实世界环境中单个特定的重建网络上执行快速测试时微调。

我们首先在仿真中进行实验。如图 5 所示，与预训练基线（第 0 次迭代）相比，成功率迅速提升。测试时训练在大多数地形上于 120 次迭代内收敛至高成功率，这对应的总适应时间约为 10 分钟（包括捕捉与重建阶段）。值得注意的是，波士顿地形具有楔形物的环形排列，需要复杂的转向行为，不同于其他地形的线性遍历。因此，它需要更多迭代才能有效适应。此外，我们在表 1 中比较了不同策略的成功率，揭示了有趣的洞见：

(1) 预训练策略在大多数测试地形上失败，尽管它们与程序化训练集相似。这表明该策略在极具挑战性的场景中，对于精确的几何差异具有有限的零样本泛化能力。

经过测试时训练后，微调策略在所有地形上均达到高成功率，凸显了测试时自适应的必要性。

(2) 从头训练在大多数地形上均告失败，即便在单一地形上进行了大量训练（2.5 万次迭代）也是如此。成功仅限于两种没有宽间隙的狭窄地形。这表明大规模预训练中固有的课程策略至关重要。

(3) **TTT-13** 略逊于 TTT-1。我们将其归因于多任务优化固有的挑战，其中梯度干扰和每任务采样密度降低阻碍了收敛。

表二：不同重建来源的比较。时间表示从数据采集到最终网格的持续时间。

Methods	RGB-D	LiDAR Scanner	iPhone	Hand-crafted
Pros	Balanced quality and efficiency	Professional, best scale accuracy	Most accessible, fast acquisition	No artifacts
Cons	Scale precision slightly lower than LiDAR	Terrain junction artifacts, tedious post-processing	Unstable reconstruction results, flying point artifacts	High manual effort, over-perfect geometry causes sim-to-real gap
Time	2min 10s	20min	4min	1h




图 7：几何对比。我们采用 RGB-D 输入的流程在质量和效率之间取得平衡，以重建可用于仿真的网格。与激光雷达和 iPhone 扫描相比，它保持了逼真的几何保真度，且工件明显更少，主要工件用红色圆圈标出。上行：Stake1，下行：Narrow1。

表三：使用不同重建来源在真实世界中的成功率。

Terrains / Methods	RGB-D (Ours)	LiDAR	iPhone	Hand-crafted
Stake1	80%	80%	0%	40%
Narrow1	80%	100%	80%	20%

表四：绝对相对尺度误差比较。我们的尺度保真度可与工业级激光雷达相媲美。

Terrains / Methods	RGB-D (Ours)	LiDAR	iPhone	MapAnything	Pi3
Stake1	0.002	<u>0.016</u>	0.074	0.383	0.863
Narrow1	<u>0.028</u>	0.005	0.056	0.720	1.172

C. 网格重建分析

在真实世界实验中，我们在各自地形上部署了预训练策略和通过测试时训练（TTT-1）获得的地形特定策略。成功率如图 6 所示。如图所示，预训练的通用策略在未见过的几何形状上表现明显不佳，在大多数具有挑战性的障碍物（如楔形、梯形和桩）上完全失败（成功率为 0%）。相比之下，TTT-Parkour 展示了强大的适应能力，在大多数复杂地形上将成功率从接近零提高到 60% 以上，并在箱体和楔形上达到 100%。这一显著改进验证了我们的测试时训练流程有效地增强了机器人在多样化未知环境中的能力。一些快照如图 4 所示。真实世界的成功率略低于仿真中的成功率。我们将这种仿真到真实的差距归因于硬件不稳定性（例如相机噪声、执行器动力学）和环境不匹配。与静态、刚性的仿真不同，物理地形元素在机器人交互过程中经常晃动或移动。这些未建模的动力学可能导致真实世界测试中的失败。此外，重建几何与物理地形之间的差异仍然存在，进一步加剧了性能差距。

如图 7 和表二所示，我们的几何重建流程支持多种输入模式。在实验中，我们使用 Realsense D435i 进行 RGB-D 感知，使用 Lixel K1 进行激光雷达扫描，使用 iPhone 16 Pro（通过 3D Scanner App）进行移动扫描，以及使用 Python 脚本通过 Trimesh 库生成的手工网格，这些网格由物理地形的实际测量参数化。在这些采集方法中，RGB-D 相机利用深度信息恢复准确的物理尺度，有效缩小了仿真到现实的差距，同时比消费级替代方案产生更少的伪影。它在重建质量和效率之间提供了最佳权衡。虽然激光雷达扫描仪提供专业级的尺度精度，但它们价格昂贵，并且容易在地形交界处和精细细节处产生伪影。此外，激光雷达工作流程劳动密集且耗时，需要多遍扫描、基于 SLAM 的建图和大量的后处理（例如去噪、平滑）。像 iPhone 这样的消费级设备虽然易于获取且速度快，但结果不一致，往往容易产生显著噪声，如飞点伪影。手工重建被证明对迁移效果最差。尽管这些手工

表五：收敛效率比较：达到 97% 成功率所需的迭代次数。

Methods / Terrains	Boxes	Wedges	Nar.1	Nar.2	Nar.3	Trap.1	Trap.2	Boston	Stake1	Stake2	Stake3	Mix1	Mix2
Scratch-1	> 25k	> 25k	17k	17k	> 25k	> 25k	> 25k	> 25k	> 25k	> 25k	> 25k	> 25k	> 25k
TTT-13	0	250	70	70	70	230	170	> 1000	350	400	260	160	270
TTT-1 (Ours)	0	100	20	20	40	70	240	560	100	200	100	60	120

表六：不同测试时训练策略比较：达到 97% 成功率所需的迭代次数。

Methods / Terrains	Narrow1	Trapezoid1	Mix2
Last Layer	120	60	<u>200</u>
Residual	<u>40</u>	<u>70</u>	> 1000
Adapter	40	60	260
Full Fine-tuning (Ours)	20	<u>70</u>	120

设计网格在人眼看来是理想的，但它们缺乏物理世界中存在的表面不规则性和几何噪声。这种过度的几何完美造成了严重的域不匹配，导致仿真到现实迁移性能不佳。为了评估重建质量对仿真到现实迁移的影响，我们将在不同来源网格上测试时训练的策略部署到现实世界中，如表三所示。虽然所有策略在仿真中都在各自的 terrain 源上收敛到高成功率，但它们在现实世界中的性能差异显著。手工制作的地形由于上述域不匹配而始终失败。基于 iPhone 的重建在较简单的 Narrow1 地形上成功，但在 Stake1 上完全失败，原因是复杂的多桩环境中存在过多的工件。RGB-D 和 LiDAR 达到了相当的高成功率。尽管 LiDAR 在 Narrow1 上由于更优的尺度精度略优于 RGB-D，但其对昂贵硬件和高时间成本的依赖使其不适合测试时跑酷训练。我们通过将点云配准到具有实际尺度的手工制作点云来计算绝对相对尺度误差，从而评估度量精度。在表四中，我们的方法达到了工业级 LiDAR 的精度，同时保持最快速度。它显著优于仅 RGB 的基线，如 Pi3（尺度模糊）和 MapAnything（推断的度量尺度不准确），验证了 RGB-D 输入对于最小化仿真到现实差距的必要性。

D. 测试时训练策略分析

我们通过测量在仿真中达到 97% 成功率所需的迭代次数来评估第三-D 小节中提到的各种测试时训练策略。如表六所示，全量微调在三个测试地形上实现了最稳健的性能。相比之下，残差和适配器方法需要随机初始化新的网络参数，这引入了敏感性并需要额外的步骤进行初始收敛。最后一层方法限制了可训练参数空间，从而限制了策略的适应性。虽然参数高效微调（PEFT）方法（包括最后一层、残差和适配器）通常旨在以轻微的性能下降换取降低的计算成本，但这种权衡在此处被证明是不利的。

我们的设定。实验上，我们观察到参数高效微调方法始终不如全量微调。我们将这一性能差距归因于预训练与测试地形之间存在显著的领域偏移。参数高效微调有限的参数空间限制了模型适应如此剧烈环境变化的能力，而全量微调保留了这种适应所需的完整表达能力。此外，由于我们强化学习流程中的主要计算瓶颈是物理仿真而非梯度计算，参数高效微调在每次迭代的墙钟时间或资源上节省甚微。因此，鉴于参数高效微调在未带来有意义的效率提升的情况下降低了性能，我们采用全量微调作为标准方法。

E. 收敛性分析

我们在仿真中评估了三种训练策略在 13 种地形上的收敛效率：从头训练、多地形测试时训练（TTT-13）和地形特定测试时训练（TTT-1）。效率通过达到 97% 成功率所需的迭代次数来量化。如表 V 所示，从头训练在所有地形上均未能合理时间内收敛（超过 25k 次迭代）。总体而言，TTT-13 的收敛速度比 TTT-1 慢。我们将此归因于样本稀释：同时针对 13 种地形进行优化会减少训练批次中任何特定地形可用的有效样本数量，从而减缓不同几何形状的梯度更新。然而，Trapezoid2 是一个显著例外，TTT-13 的收敛速度比 TTT-1 快（170 次迭代对 240 次迭代）。我们假设该地形与窄梁具有几何相似性。因此，多地形测试时训练可能受益于正迁移，利用从窄梁学到的特征来加速在 Trapezoid2 上的适应。

V. 结论

本文提出 TTT-Parkour 框架，显著提升机器人在复杂地形中的通行能力。我们建立了两阶段预训练与测试时训练范式，并构建了快速高保真几何重建流程。实验表明，在精确重建的地形上进行测试时训练，人形机器人可在数分钟内掌握在极难地形上的敏捷稳健跑酷，包括楔形、桩、箱、梯形和窄梁。尽管取得这些进展，部署效率和任务多样性方面仍存在局限。首先，当前 10 分钟的适应过程仅作为概念验证，对工业应用而言仍过长，且依赖人工地形采集。未来工作将探索

直接从机器人中心视角的单张图像生成本地地形网格，同时利用改进的计算硬件和物理仿真器将训练时间缩短至秒级。其次，我们的框架依赖静态几何重建，忽略了摩擦、质量和柔顺性等物理属性。未来工作将探索推断这些动态参数以建模地形不稳定性，创建交互式仿真，进一步缩小仿真与现实的差距。

参考文献

- [1] Ekin Akyürek, Mehul Damani, Adam Zweiger, Linlu Qiu, Han Guo, Jyothish Pari, Yoon Kim, and Jacob Andreas. The surprising effectiveness of test-time training for few-shot learning. *arXiv preprint arXiv:2411.07279*, 2024.
- [2] Marco Bagatella, Mert Albaba, Jonas Hübner, Georg Martius, and Andreas Krause. Test-time offline reinforcement learning on goal-related experience. *arXiv preprint arXiv:2507.18809*, 2025.
- [3] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. Titans: Learning to memorize at test time. *arXiv preprint arXiv:2501.00663*, 2024.
- [4] Qingwei Ben, Botian Xu, Kailin Li, Feiyu Jia, Wentao Zhang, Jingping Wang, Jingbo Wang, Dahua Lin, and Jiangmiao Pang. Gallant: Voxel grid-based humanoid locomotion and local-navigation across 3d constrained terrains. *arXiv preprint arXiv:2511.14625*, 2025.
- [5] Arunkumar Byravan, Jan Humplik, Leonard Hasenclever, Arthur Brussee, Francesco Nori, Tuomas Haarnoja, Ben Moran, Steven Bohez, Fereshteh Sadeghi, Bojan Vujatovic, et al. Nerf2real: Sim2real transfer of vision-guided bipedal motion skills using neural radiance fields. *arXiv preprint arXiv:2210.04932*, 2022.
- [6] Lawrence Yunliang Chen, Kush Hari, Karthik Dharmarajan, Chenfeng Xu, Quan Vuong, and Ken Goldberg. Mirage: Cross-embodiment zero-shot policy transfer with cross-painting. *arXiv preprint arXiv:2402.19249*, 2024.
- [7] Xingyu Chen, Fu-Jen Chu, Pierre Gleize, Kevin J Liang, Alexander Sax, Hao Tang, Weiyao Wang, Michelle Guo, Thibaut Hardin, Xiang Li, et al. Sam 3d: 3dfy anything in images. *arXiv preprint arXiv:2511.16624*, 2025.
- [8] Xuxin Cheng, Kexin Shi, Ananye Agarwal, and Deepak Pathak. Extreme parkour with legged robots. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 11443–11450. IEEE, 2024.
- [9] Helei Duan, Bikram Pandit, Mohitvishnu S Gadde, Bart Van Marum, Jeremy Dao, Chanh Kim, and Alan Fern. Learning vision-based bipedal locomotion for challenging terrain. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 56–62. IEEE, 2024.
- [10] Alejandro Escontrela, Justin Kerr, Arthur Allshire, Jonas Frey, Rocky Duan, Carmelo Sferrazza, and Pieter Abbeel. Gaussgym: An open-source real-to-sim framework for learning locomotion from pixels. *arXiv preprint arXiv:2510.15352*, 2025.
- [11] Martin A Fischler and Robert C Bolles. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography. *Communications of the ACM*, 24(6):381–395, 1981.
- [12] Manuel Yves Galliker. Whole-body humanoid mpc: Realtime physics-based procedural loco-manipulation planning and control. https://github.com/1x-technologies/wb_humanoid_mpc, 2024.
- [13] Xinyang Gu, Yen-Jen Wang, Xiang Zhu, Chengming Shi, Yanjiang Guo, Yichen Liu, and Jianyu Chen. Advancing humanoid locomotion: Mastering challenging terrains with denoising world model learning. *arXiv preprint arXiv:2408.14472*, 2024.
- [14] Xiaoshen Han, Minghuan Liu, Yilun Chen, Junqiu Yu, Xiaoyang Lyu, Yang Tian, Bolun Wang, Weinan Zhang, and Jiangmiao Pang. Re³ sim: Generating high-fidelity simulation data via 3d-photorealistic real-to-sim for robotic manipulation. *arXiv preprint arXiv:2502.08645*, 2025.
- [15] Junzhe He, Chong Zhang, Fabian Jenelten, Ruben Grandia, Moritz Bäcker, and Marco Hutter. Attention-based map encoding for learning generalized legged locomotion. *Science Robotics*, 10(105):eadv3604, 2025.
- [16] Nicolas Heess, Dhruva Tb, Srinivasan Sriram, Jay Lemmon, Josh Merel, Greg Wayne, Yuval Tassa, Tom Erez, Ziyu Wang, SM Eslami, et al. Emergence of locomotion behaviours in rich environments. *arXiv preprint arXiv:1707.02286*, 2017.
- [17] Runhan Huang, Haldun Balim, Heng Yang, and Yilun Du. Flexible locomotion learning with diffusion model predictive control. *arXiv preprint arXiv:2510.04234*, 2025.
- [18] Runhan Huang, Shaoting Zhu, Yilun Du, and Hang Zhao. Moe-loco: Mixture of experts for multitask locomotion. *arXiv preprint arXiv:2503.08564*, 2025.
- [19] Michael Janner, Yilun Du, Joshua B Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. *arXiv preprint arXiv:2205.09991*, 2022.
- [20] Michael Kazhdan and Hugues Hoppe. Screened poisson surface reconstruction. *ACM Transactions on Graphics (ToG)*, 32(3):1–13, 2013.
- [21] Nikhil Keetha, Norman Müller, Johannes Schönberger, Lorenzo Porzi, Yuchen Zhang, Tobias Fischer, Arno Knapitsch, Duncan Zaus, Ethan Weber, Nelson Antunes, et al. Mapanything: Universal feed-forward metric 3d reconstruction. *arXiv preprint arXiv:2509.13414*, 2025.
- [22] Justin Kerr, Letian Fu, Huang Huang, Yahav Avigal, Matthew Tancik, Jeffrey Ichnowski, Angjoo Kanazawa, and Ken Goldberg. Evo-nerf: Evolving nerf for sequential robot grasping of transparent objects. In *6th annual conference on robot learning*, 2022.
- [23] Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. Rma: Rapid motor adaptation for legged robots. *arXiv preprint arXiv:2107.04034*, 2021.
- [24] Xinhai Li, Jialin Li, Ziheng Zhang, Rui Zhang, Fan Jia,

- Tiancai Wang, Haoqiang Fan, Kuo-Kun Tseng, and Ruiping Wang. Robogsim: A real2sim2real robotic gaussian splatting simulator. *arXiv preprint arXiv:2411.11839*, 2024.
- [25] Yue Li, Qi Ma, Runyi Yang, Huapeng Li, Mengjiao Ma, Bin Ren, Nikola Popovic, Nicu Sebe, Ender Konukoglu, Theo Gevers, et al. Scenesplat: Gaussian splatting-based scene understanding with vision-language pretraining. *arXiv preprint arXiv:2503.18052*, 2025.
- [26] Yue Li, Qi Ma, Runyi Yang, Mengjiao Ma, Bin Ren, Nikola Popovic, Nicu Sebe, Theo Gevers, Luc Van Gool, Danda Pani Paudel, et al. Chorus: Multi-teacher pre-training for holistic 3d gaussian scene encoding. *arXiv preprint arXiv:2512.17817*, 2025.
- [27] Qiayuan Liao, Takara E Truong, Xiaoyu Huang, Yuman Gao, Guy Tevet, Koushil Sreenath, and C Karen Liu. Beyondmimic: From motion tracking to versatile humanoid control via guided diffusion. *arXiv preprint arXiv:2508.08241*, 2025.
- [28] Junfeng Long, Junli Ren, Moji Shi, Zirui Wang, Tao Huang, Ping Luo, and Jiangmiao Pang. Learning humanoid locomotion with perceptive internal model. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9997–10003. IEEE, 2025.
- [29] Haozhe Lou, Yurong Liu, Yike Pan, Yiran Geng, Jianteng Chen, Wenlong Ma, Chenglong Li, Lin Wang, Hengzhen Feng, Lu Shi, et al. Robo-gs: A physics consistent spatial-temporal model for robotic arm with hybrid representation. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 15379–15386. IEEE, 2025.
- [30] Miles Macklin. Warp: A high-performance python framework for gpu simulation and graphics. <https://github.com/nvidia/warp>, March 2022. NVIDIA GPU Technology Conference (GTC).
- [31] Viktor Makoviychuk, Lukasz Wawrzyniak, Yunrong Guo, Michelle Lu, Kier Storey, Miles Macklin, David Hoeller, Nikita Rudin, Arthur Allshire, Ankur Handa, et al. Isaac gym: High performance gpu-based physics simulation for robot learning. *arXiv preprint arXiv:2108.10470*, 2021.
- [32] Mayank Mittal, Pascal Roth, James Tigue, Antoine Richard, Octi Zhang, Peter Du, Antonio Serrano-Muñoz, Xinjie Yao, René Zurbrugg, Nikita Rudin, et al. Isaac lab: A gpu-accelerated simulation framework for multi-modal robot learning. *arXiv preprint arXiv:2511.04831*, 2025.
- [33] Xue Bin Peng, Ze Ma, Pieter Abbeel, Sergey Levine, and Angjoo Kanazawa. Amp: Adversarial motion priors for stylized physics-based character control. *ACM Transactions on Graphics (ToG)*, 40(4):1–20, 2021.
- [34] M Nomaan Qureshi, Sparsh Garg, Francisco Yandun, David Held, George Kantor, and Abhisesh Silwal. Splat-sim: Zero-shot sim2real transfer of rgb manipulation policies using gaussian splatting. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6502–6509. IEEE, 2025.
- [35] Nikita Rudin, Junzhe He, Joshua Aurand, and Marco Hutter. Parkour in the wild: Learning a general and extensible agile locomotion policy using multi-expert distillation and rl fine-tuning. *arXiv preprint arXiv:2505.11164*, 2025.
- [36] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [37] Haolin Song, Hongbo Zhu, Tao Yu, Yan Liu, Mingqi Yuan, Wengang Zhou, Hua Chen, and Houqiang Li. Gait-adaptive perceptive humanoid locomotion with real-time under-base terrain reconstruction. *arXiv preprint arXiv:2512.07464*, 2025.
- [38] Jingkai Sun, Gang Han, Pihai Sun, Wen Zhao, Jiahang Cao, Jiaxu Wang, Yijie Guo, and Qiang Zhang. Dpl: Depth-only perceptive humanoid locomotion via realistic depth synthesis and cross-attention terrain reconstruction. *arXiv preprint arXiv:2510.07152*, 2025.
- [39] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *International conference on machine learning*, pages 9229–9248. PMLR, 2020.
- [40] Marcel Torne, Anthony Simeonov, Zechu Li, April Chan, Tao Chen, Abhishek Gupta, and Pulkit Agrawal. Reconciling reality through simulation: A real-to-sim-to-real approach for robust manipulation. *arXiv preprint arXiv:2403.03949*, 2024.
- [41] Huayi Wang, Zirui Wang, Junli Ren, Qingwei Ben, Tao Huang, Weinan Zhang, and Jiangmiao Pang. Beamdojo: Learning agile humanoid locomotion on sparse footholds. *arXiv preprint arXiv:2502.10363*, 2025.
- [42] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. Vggt: Visual geometry grounded transformer. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 5294–5306, 2025.
- [43] Yifan Wang, Jianjun Zhou, Haoyi Zhu, Wenzheng Chang, Yang Zhou, Zizun Li, Junyi Chen, Jiangmiao Pang, Chunhua Shen, and Tong He. π^3 : Permutation-equivariant visual geometry learning. *arXiv preprint arXiv:2507.13347*, 2025.
- [44] Zirui Wu, Zeren Jiang, Martin R Oswald, and Jie Song. From rays to projections: Better inputs for feed-forward view synthesis. *arXiv preprint arXiv:2601.05116*, 2026.
- [45] Zehao Xiao and Cees GM Snoek. Beyond model adaptation at test time: A survey. *arXiv preprint arXiv:2411.03687*, 2024.
- [46] Runyi Yang, Zhenxin Zhu, Zhou Jiang, Baijun Ye, Xiaoxue Chen, Yifei Zhang, Yuantao Chen, Jian Zhao, and Hao Zhao. Spectrally pruned gaussian fields with neural compensation. *arXiv preprint arXiv:2405.00676*, 2024.
- [47] Baijun Ye, Caiyun Liu, Xiaoyu Ye, Yuantao Chen, Yuhai Wang, Zike Yan, Yongliang Shi, Hao Zhao, and Guyue Zhou. Blending distributed nerfs with tri-stage robust

- pose optimization. *arXiv preprint arXiv:2405.02880*, 2024.
- [48] Baijun Ye, Minghui Qin, Saining Zhang, Moonjun Gong, Shaoting Zhu, Zebang Shen, Luan Zhang, Lu Zhang, Hao Zhao, and Hang Zhao. Gs-occ3d: Scaling vision-only occupancy reconstruction with gaussian splatting. *arXiv preprint arXiv:2507.19451*, 2025.
 - [49] Saining Zhang, Baijun Ye, Xiaoxue Chen, Yuantao Chen, Zongzheng Zhang, Cheng Peng, Yongliang Shi, and Hao Zhao. Drone-assisted road gaussian splatting with cross-view uncertainty. *arXiv preprint arXiv:2408.15242*, 2024.
 - [50] Yujia Zhang, Xiaoyang Wu, Yixing Lao, Chengyao Wang, Zhuotao Tian, Naiyan Wang, and Hengshuang Zhao. Concerto: Joint 2d-3d self-supervised learning emerges spatial representations. *arXiv preprint arXiv:2510.23607*, 2025.
 - [51] Siheng Zhao, Jiageng Mao, Wei Chow, Zeyu Shangguan, Tianheng Shi, Rong Xue, Yuxi Zheng, Yijia Weng, Yang You, Daniel Seita, et al. Robot learning from any images. In *Conference on Robot Learning*, pages 4226–4245. PMLR, 2025.
 - [52] Yuhang Zheng, Xiangyu Chen, Yupeng Zheng, Songen Gu, Runyi Yang, Bu Jin, Pengfei Li, Chengliang Zhong, Zengmao Wang, Lina Liu, et al. Gaussiangrasper: 3d language gaussian splatting for open-vocabulary robotic grasping. *IEEE Robotics and Automation Letters*, 2024.
 - [53] Allan Zhou, Moo Jin Kim, Lirui Wang, Pete Florence, and Chelsea Finn. Nerf in the palm of your hand: Corrective augmentation for robotics via novel-view synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 17907–17917, 2023.
 - [54] Shaoting Zhu, Linzhan Mou, Derun Li, Baijun Ye, Runhan Huang, and Hang Zhao. Vr-robo: A real-to-sim-to-real framework for visual robot navigation and locomotion. *IEEE Robotics and Automation Letters*, 2025.
 - [55] Shaoting Zhu, Ziwen Zhuang, Mengjie Zhao, Kun-Ying Lee, and Hang Zhao. Hiking in the wild: A scalable perceptive parkour framework for humanoids. *arXiv preprint arXiv:2601.07718*, 2026.
 - [56] Ziwen Zhuang, Shenzhe Yao, and Hang Zhao. Humanoid parkour learning. *arXiv preprint arXiv:2406.10759*, 2024.

附录

A. 奖励公式

我们在预训练和测试时训练中使用相同的奖励。奖励函数旨在鼓励速度跟踪，同时确保物理安全。它由四个部分组成：任务奖励、正则化奖励、安全奖励和 AMP 风格奖励。每个项的详细定义及其对应权重和关键参数见表 VII。

平台 p_{start} ，蓝点表示目标平台。若干地形具有极其稀疏 p_{end} 或狭窄的几何结构，对机器人获取稳定立足点构成显著挑战。

B. 真实世界地形的几何规格

我们给出了真实世界实验中所用地形的关键尺寸，如图 8、图 9 和图 10。图中，红点表示起点

表 7: 奖励项、权重及数学公式的详细说明。

Reward Term	Weight	Mathematical Formulation
Task Reward		
Linear Vel Tracking (v_{xy})	2.0	$\exp(-\ \mathbf{v}_{xy}^* - \mathbf{v}_{xy}\ ^2/0.5^2)$
Angular Vel Tracking (ω_z)	0.1	$\exp(-(\omega_z^* - \omega_z)^2/0.5^2)$
Heading Error	-1.0	$ \omega_z^* $
Don't Wait	-0.5	$\mathbb{I}(v_x^* > 0.3) \cdot (\mathbb{I}(v_x < 0.15) + \mathbb{I}(v_x < 0) + \mathbb{I}(v_x < -0.15))$
Is Alive	3.0	+1
Stand Still	-0.3	$(\ \mathbf{q} - \mathbf{q}_{default}\ _1 - 4.0) \cdot \mathbb{I}(\ \mathbf{v}^*\ < 0.15) \cdot \mathbb{I}(\omega_z^* < 0.15)$
Regularization Reward		
Edge Penetration	-1.0	$\sum_{i=1}^{ \mathcal{P} } \ \mathbf{d}_i\ \cdot (\ \mathbf{v}_i\ + \epsilon)$
Feet Air Time	0.5	$\min_f(t_{phase,f}) \cdot \mathbb{I}(\sum c_f = 1) \cdot \mathbb{I}(\ \mathbf{v}^*\ > 0.15)$
Feet Slide	-0.4	$\sum_f \ \mathbf{v}_{xy,f}\ \cdot \mathbb{I}(c_f)$
Joint Deviation (Hip)	-0.5	$\sum_{j \in \text{hips}} (q_j - q_{j,default})^2$
Base Ang Vel (XY) (L_2)	-0.05	$\ \omega_{xy}\ ^2$
Joint Torques (L_2)	-1.5e-7	$\ \boldsymbol{\tau}_{legs}\ ^2$
Joint Acc (L_2)	-1.25e-7	$\ \ddot{\mathbf{q}}\ ^2$
Joint Vel (L_2)	-1.0e-4	$\ \dot{\mathbf{q}}\ ^2$
Action Rate (L_2)	-0.005	$\ \mathbf{a}_t - \mathbf{a}_{t-1}\ ^2$
Flat Orientation	-3.0	$\ \mathbf{g}_{xy}^{proj}\ ^2$
Pelvis Orientation	-3.0	$\ \mathbf{g}_{xy}^{proj,pelvis}\ ^2$
Feet Orientation	-0.4	$\sum_f \ \mathbf{g}_{xy,f}^{proj}\ \cdot \mathbb{I}(c_f)$
Feet Height Error	-0.1	$\sum_f \sum_p \text{clip}(h_f - h_{terr,p} - 0.035, 0, 0.3) \cdot \mathbb{I}(c_f)$
Feet Distance	1.0	$\exp(-\max(0, 0.12 - y_L^R - y_R^R)/0.05) - 1$
Energy Consumption	-5.0e-5	$\sum_j (\tau_j \dot{q}_j / k_j)^2$
Freeze Upper Body	-0.004	$\ \mathbf{q}_{upper} - \mathbf{q}_{upper}^{default}\ _1$
Safety Reward		
Joint Pos Limits	-1.0	$\sum_j (\max(0, q_j - q_{j,max}) + \max(0, q_{j,min} - q_j))$
Joint Vel Limits	-1.0	$\sum_j \max(0, \dot{q}_j - 0.9\dot{q}_{j,max})$
Torque Limits	-0.01	$\sum_j \max(0, \tau_j - 0.8\tau_{j,max})^2$
Undesired Contacts	-1.0	$\mathbb{I}(\text{count}(\text{collision}_{body \setminus feet}) > 0)$
AMP Reward		
AMP Style	0.25	$\max[0, 1 - 0.25(D(\mathbf{S}_t) - 1)^2]$




图 8: 真实世界地形的详细尺寸。









图 9: 真实世界地形的详细尺寸。




图 10: 真实世界地形的详细尺寸。