
TTT++: 自监督测试时 训练何时失效或成功?

Yuejiang Liu Parth Kothari Bastien van Delft

Baptiste Bellot-Gurlet Taylor Mordan Alexandre Alahi

洛桑联邦理工学院 (EPFL) {名.姓}@epfl.ch

摘要

测试时训练 (TTT) 通过自监督学习 (SSL) 成为应对分布偏移的新兴范式。尽管结果令人鼓舞，但该方法何时成功或失效仍不明确。本文首先深入剖析其局限性，并表明在严重分布偏移下，TTT 可能恶化而非提升测试时性能。为解决此问题，我们提出一种测试时特征对齐策略，利用离线特征摘要与在线矩匹配，在不重新访问训练数据的情况下正则化自适应。进一步地，我们通过批队列解耦将该策略扩展至在线设置，即使在有限批大小下也能获得稳健的矩估计。在特征分布对齐的基础上，我们通过理论分析自适应后的性能，揭示了 TTT 的巨大潜力。该分析促使我们在视觉识别问题中采用更具信息量的对比学习形式作为自监督信号。我们通过实验证明，我们改进的测试时训练方法 TTT++ 在多个基准上以显著优势超越最先进方法。结果表明，除模型参数外，存储并利用额外信息是迈向稳健测试时自适应的有前景方向。代码见 <https://github.com/vita-epfl/ttt-plus-plus>。

1 引言

机器学习模型在分布偏移下往往难以泛化。即使训练与测试数据间存在感知上轻微的偏移（如 JPEG 压缩），也可能导致严重预测错误 [1]。应对该挑战的一类流行方法是同时利用带标签训练数据与无标签测试数据，学习跨域不变表示 [2–5]。然而，在测试时重新访问训练数据可能因日益增长的隐私担忧、数据集规模膨胀及诸多现实约束而不切实际。这一不足催生了更具挑战性但更具吸引力的测试时自适应范式：给定已训练模型，如何在访问训练数据与人工标注的情况下，即时地将其从一个域自适应到另一个域？

实现这一目标的一个有前景的方法是测试时训练 (Test-Time Training, TTT)，通过自监督学习 [6]。TTT 的核心思想简单直接：在两项任务上训练模型，即主任务和自监督学习 (Self-Supervised Learning, SSL) 任务，并在测试时仅基于 SSL 任务更新模型。该技术通过自监督旋转预测实现，在多种分布偏移下提升图像分类器的鲁棒性方面已显示出令人鼓舞的结果。然而，其经验性能仍逊于其他测试时算法家族 [7, 8]。

本文首先深入审视 TTT，重点关注其局限性。我们的分析从一个基本问题开始：TTT 能否始终缓解分布偏移的影响？通过一个说明性问题，我们表明 TTT 框架可能导致意外的失败，使测试准确率恶化而非提升。该问题主要归因于 SSL 任务的无约束更新干扰了主任务。为解决这一问题，我们引入一种测试时特征对齐策略，通过离线特征汇总和在线矩匹配实现：训练完成后，计算训练特征的均值和协方差矩阵，并将其作为模型的一部分存储，称为离线特征汇总；在测试时，通过将在线估计的矩与离线预计算的矩进行匹配，促使测试特征分布接近训练分布，这一过程称为在线矩匹配。

在线特征对齐的一个实际挑战在于将该策略扩展到类别数量众多的问题，因为获得稳健的矩估计通常需要每个类别至少少量样本。为缓解这一问题，我们借鉴近期文献 [9] 的启发，将矩估计的样本量与批大小解耦。具体而言，我们维护一个大型动态编码特征队列，并以小批量方式逐步更新。这一修改使得即使在有限批大小下也能实现有效的特征对齐，极大提升了其在在线测试时设置中的可行性。

最后，本文通过对自适应后测试准确率的理论分析，揭示了测试时训练（Test-Time Training）的巨大潜力。特别地，本文推导了主任务测试准确率的下界，并证明当自监督学习任务与主任务越接近时，该下界预期会迅速增长。这些发现促使本文将对表示学习 [9–12] 作为自监督学习的一个强有力实例，集成到视觉识别问题中的测试时训练框架中。

通过结合所提出的三个组件，本文设计了一种改进的测试时训练版本，称为 TTT++。实验结果表明，TTT++ 在各种鲁棒性基准上以显著优势大幅超越其他近期方法。本文的结果表明，利用额外信息，包括以强自监督形式存在的任务特定信息和以特征汇总形式存在的领域特定信息，是提升测试时自适应有效性的一个有前景的方向。

2 背景

2.1 相关工作

测试时自适应。基于测试样本的自适应机器学习模型在生成式问题（如超分辨率 [13]、图像综合 [14] 和图像处理 [15]）以及判别式问题（如图像分类 [16]）中引起了越来越多的关注。本文的工作聚焦于存在分布偏移情况下的后者。近期若干工作 [16, 17] 展示了在不重新访问源数据的情况下，以无监督方式将学习到的分类器自适应到新测试领域的优势。一种最简单的形式是用测试样本上的批量归一化统计量替换训练集上估计的统计量 [17]。另一类工作提出通过利用测试样本上的预测标签来调整模型参数，例如熵最小化 [8] 和伪标签 [7]。虽然这些方法在某些基准上取得了有前景的结果，但它们本质上局限于分类问题，并且在较大的分布偏移下往往较为脆弱 [18]。

与本文工作更为接近的是，[6] 提出了通过自监督学习进行测试时训练，例如预测图像旋转类型。该方法不涉及对主任务输出的任何假设，因此更具通用性。它已成功应用于多种问题，如实例跟踪 [19] 和强化学习 [20]。然而，实证表明其性能不如其他测试时算法 [8]。本文深入分析了其局限性，提出了简单而有效的改进措施，并夯实了理论基础。

特征对齐。在特征空间中对齐训练样本和测试样本的分布是领域自适应的常用方法。以往的特征对齐方法主要分为两类：最小化散度测度，如最大均值差异（MMD）[21]、深度相关对齐（Coral）[22] 和中心矩差异（CMD）[23]，或通过对抗训练促进领域混淆 [5, 24]。然而，这些方法大多依赖于源数据和目标数据的同时存在，因此无法直接应用于源数据不可用的测试时场景。本文重新审视了特征




图 1: 展示测试时训练在分布偏移下损害鲁棒性的失败案例。(a) 预测模型在训练域中主分类任务（区分红蓝数据点）和辅助自监督任务（区分圆形和叉形）上均达到高准确率。(b) 在较大分布偏移下，测试样本被编码到新的子空间，导致两个任务的准确率均受限。(c) 在特征分布无任何约束的情况下，测试时训练可能导致更新后的编码器严重过拟合自监督学习任务，从而降低主任务准确率，而非提升。

对齐在测试时训练中的关键作用，并提出一种简单实用的策略，即使在批大小有限的情况下也能实现在线特征对齐。

自监督学习。自监督学习是从无标签样本中学习丰富表示的强大范式。近年来，通过设计信息丰富的自监督任务 [11, 12, 25 – 28] 和稳定训练过程 [9, 29]，该领域取得了显著进展。以往工作主要关注无监督预训练，而本文则探讨将强自监督学习方法融入测试时自适应的重要性。

2.2 预备知识：测试时训练

测试时训练（Test-Time Training, TTT）[6] 是一种基于无标签样本使神经网络模型适应新测试分布的通用框架。与传统仅针对目标任务训练模型的方法不同，TTT 考虑两个任务：一个主任务和一个辅助自监督学习任务。模型通过多任务架构同时在这两个任务上进行训练，该架构由一个共享编码器 g 和两个独立头部分别为 π_m 和 π_s 组成。给定带标签的训练数据集 $D = \{(x_i, y_i)\}_{i \in \{1, \dots, N\}}$ ，模型被训练以联合最小化两个损失：

$$\mathcal{L}_{train}(D; g, \pi_m, \pi_s) = \frac{1}{N} \sum_{i=1}^N \mathcal{L}_m(x_i, y_i; g, \pi_m) + \lambda \mathcal{L}_s(x_i; g, \pi_s), \quad (1)$$

其中 λ 是用于平衡两个任务的超参数。

在存在分布偏移的情况下，学习到的模型往往难以直接泛化到新的测试集 $D' = \{x'_i\}_{i \in \{1, \dots, N'\}}$ 。TTT 的核心思想是利用测试样本基于自监督任务微调编码器 g ，

$$\mathcal{L}_{TTT}(D'; g') = \frac{1}{N'} \sum_{i=1}^{N'} \mathcal{L}_s(x'_i; g'), \quad (2)$$

期望更新后的模型 $\pi_m \circ g'$ 在主任务上取得更好的结果。

以自监督旋转预测任务实例化的 TTT 已被证明能有效提升图像分类器在常见分布偏移下的鲁棒性 [6]。然而，研究表明其性能不如其他测试时自适应方法家族 [7, 8]。接下来，我们将深入分析其优势与局限性，并提出改进版本以获得更好的自适应性能。

3 测试时训练何时失效？

在本节中，我们首先阐明在大分布偏移下测试时训练的一个注意事项，随后介绍针对测试时场景量身定制的实用解决方案。




图 2: 我们改进的测试时训练版本 (TTT++)。我们的方法包含三个阶段: 模型训练、离线特征汇总和在线测试时自适应。(i) 在训练期间, 模型同时针对主任务和辅助对比自监督任务进行优化。(ii) 训练完成后, 我们以一二阶矩的形式汇总编码器和自监督头之后的特征分布。(iii) 在测试时, 我们通过在在线特征对齐 (第 3.2 节) 和自监督学习 (第 4.2 节) 来适应编码器。在批大小有限的情况下, 我们维护一个大型动态特征向量队列以获得稳健的矩估计 (第 3.3 节)。

3.1 失效的示例说明

测试时自适应 (Test-Time Adaptation) 背后的一个隐含假设是, 基于自监督学习 (Self-Supervised Learning) 的编码器更新能够抵消底层分布偏移对主任务的影响。然而, 在较大偏移下, 这一假设很可能被打破, 并导致意外的自适应失效。为了说明这一局限性, 我们在图 1 中引入一个简单的玩具问题, 其中主任务和自监督学习任务分别定义为对二维潜空间中编码特征的颜色和符号进行分类。我们考虑一个理想场景, 即两个任务高度相关, 使得训练良好的模型在训练域中能够在两个任务上都达到较高的准确率。然而, 在存在显著分布偏移的情况下, 模型在测试域中仍可能遭受严重的预测误差。

在此场景下, 虽然测试时自适应可能在一定程度上恢复所学表示对主任务的判别能力, 但无约束的自监督自适应可能导致对辅助自监督学习任务的严重过拟合。因此, 主任务上的性能甚至可能恶化, 而非改善。这一现象不仅限于我们的示例, 在实际中也同样出现, 如第 5.1 节所示。

3.2 在线特征对齐

如上述玩具示例所示, 仅在测试时应用自监督自适应可能导致任意差的结果。为解决这一问题, 我们引入一种在线特征对齐策略, 以确保测试时自适应的鲁棒性。该策略的核心思想是在测试时自适应过程中对特征空间施加约束, 使测试样本的特征分布保持接近训练域中的特征分布。虽然一些特征对齐技术, 如最大均值差异 (Maximum Mean Discrepancy) [2] 和对抗训练 (Adversarial Training) [24], 已被广泛用于领域自适应, 但它们通常依赖于同时从训练域和测试域采样, 这在测试时设置中是不切实际的。因此, 我们转向可以独立估计每个分布的经典散度测度。更具体地说, 受深度域混淆 (Deep Domain Confusion) [30] 和相关性对齐 (Correlation Alignment) [22] 的启发, 我们使用两个特征分布之间一阶矩和二阶矩的平方距离来近似域差异。这一设计选择使我们能够以紧凑格式总结训练特征的分布, 并将其作为模型的一部分存储, 从而在测试时自适应过程中无需重新访问训练数据。

具体而言, 训练完成后, 我们执行一个离线特征汇总步骤, 通过经验均值 $\mu_Z = \frac{1}{N} \sum_{i=1}^N z_i$ 和协方差矩阵 $\Sigma_Z = \frac{1}{N-1} (Z^T Z - (I^T Z)^T (I^T Z))$ 来刻画训练域中特征向量的分布 $Z = \{z_1^T, \dots, z_N^T\}$ 。前者本质上等价于逐通道的批归一化统计量, 而后者信息更丰富且计算和存储开销较小。在测试时, 我们正则化

通过最小化从测试样本小批量估计的特征统计量之间的距离进行自监督适应，*i.e.*, μ'_z 以及 Σ_z ，以及关于训练域的预存量：

$$\mathcal{L}_{f,z} = \|\mu_z - \mu'_z\|_2^2 + \|\Sigma_z - \Sigma'_z\|_F^2, \quad (3)$$

其中 $\|\cdot\|_2$ 为欧几里得范数， $\|\cdot\|_F$ 为弗罗贝尼乌斯范数。在线矩匹配的基本形式存在局限性，因为低阶统计量可能不足以充分捕捉高维复杂分布，例如标准 ResNet-50 的 2048 维。为缓解这一问题，本文在编码器输出端和自监督头输出端对齐特征分布，这两处维度较低，例如第 4.2 节所述对比学习中的 128 维。测试阶段的最终目标为自监督损失 $\mathcal{L}_s$ 、编码器特征对齐损失 $\mathcal{L}_{f,z}$ 与自监督头特征对齐损失 $\mathcal{L}_{f,s}$ 的加权组合，

$$\mathcal{L}_{TTT++} = \mathcal{L}_s + \lambda_z \mathcal{L}_{f,z} + \lambda_s \mathcal{L}_{f,s}, \quad (4)$$

其中 λ_z 和 λ_s 是控制各项权重的超参数。

3.3 在线动态队列

在线特征对齐的一个实际挑战在于将该策略扩展到具有大量类别的问题上。直观地说，对整个分布矩的良好估计至少需要每个类别有少量样本。因此，样本量的需求随类别数量线性增长，例如，在 CIFAR-100 的情况下需要超过 ~ 1000 个样本。然而，部署期间的计算资源通常有限，难以在测试时设置中容纳如此大的批大小。

为克服这一挑战，本文从近期文献 [9] 中获得启发，并维护一个编码特征的动态队列，以将批大小与用于矩估计的样本大小解耦。更具体地说，本文构建了一个动态队列，其中包含在测试时编码的几批特征向量。本文通过追加最新小批量并弹出最旧小批量来逐步更新队列，如图 2 所示。这种批队列解耦使本文能够收集大量且一致的样本用于在线矩匹配，即使在批大小非常有限的情况下也是如此。

通过整合在线矩匹配和批队列解耦，本文的测试时算法同时考虑了更新表示的判别能力和边际分布，从而在各种设置下实现更稳健的适应。值得注意的是，当前的矩匹配策略只是在线特征对齐方案的一个特定实例。它可以自然地扩展以纳入高阶统计量 [23, 31]，以在更大空间和计算复杂度的代价下带来进一步的性能提升。

4 测试时训练何时能蓬勃发展？

在特征分布得到适当对齐的前提下，本文接下来探讨在强自监督学习任务下测试时训练的潜力。本文首先推导出一般场景下测试准确率的下界，然后在主任务性能可以直接估计的特定设置中分析该下界。这些分析促使本文在测试时训练中使用更具信息量的自监督学习。

4.1 理论结果

本文考虑一个训练集，其样本来自联合分布 $\mathbb{P}_{X,Y_m,Y_s}$ ，其中 X, Y_m 和 Y_s 分别是与训练样本、主任务标签和自监督标签相对应的随机变量。类似地，测试集由来自联合分布 $\mathbb{P}_{X',Y'_m,Y'_s}$ 的样本组成。在存在分布偏移的情况下， $\mathbb{P}_{X,Y_m,Y_s}$ 和 $\mathbb{P}_{X',Y'_m,Y'_s}$ 并不相同。然而，本文在分析中对标签分布做出以下假设。

假设 1. 训练标签和测试标签在分布上相等， $Y_m \stackrel{d}{=} Y'_m, Y_s \stackrel{d}{=} Y'_s$ 及 $(Y_m, Y_s) \stackrel{d}{=} (Y'_m, Y'_s)$ 。

此外，本文将分析范围限定于训练期间两个任务均可被完美解决的场景。

假设 2。 存在一个编码器 g 以及分类器 π_m 和 π_s ，使得 $\mathbb{P}(\pi_m(g(X)) = Y_m) = 1$ 且 $\mathbb{P}(\pi_s(g(X)) = Y_s) = 1$ 。

在测试时训练 (TTT) 过程中，共享编码器 g 被更新为 g' ，以使自监督头 π_s 拟合测试数据。鉴于本文在方程 4 中提出的在线特征对齐方法，假设训练域和测试域中的编码特征 *i.e.*, Z 和 Z' 具有以下性质。假设 3。测试时的边缘特征分布和条件特征分布与训练时的对应分布对齐，即 Z 且 $Y'_s = k$ 对于自监督学习任务中的所有类别 k 。

$$\stackrel{d}{=} Z' \quad (Z \mid Y_s = k) \stackrel{d}{=} (Z' \mid$$

在这些假设下，本文考虑最坏情况下测试时训练的结果。

定理 1。 主任务上的预测准确率下界为：

$$\mathbb{P}(\pi_m(Z') = Y'_m) \geq \sum_{y_s} \mathbb{P}(Y_s = y_s) \max \left\{ 0, 2 \left(\max_{y_m} \mathbb{P}(Y_m = y_m \mid Y_s = y_s) - 0.5 \right) \right\}. \quad (5)$$

证明：请参见补充材料第 A.1 节。 □

定理 1 强调了主任务与自监督学习任务之间的关系对适应后测试准确率的重要性。更具体地说，自监督学习任务需要相对于主任务具有信息量以保证性能，即知道自监督学习类别

高度可能，或等价地 $\mathbb{P}(Y_m = y_m \mid Y_s = y_s)$ 较大，从而得到更大的下界。 y_m 使得主类别

为了进一步理解任务关系对测试时训练的影响，我们接下来考虑一种特定设置，其中编码特征完全过拟合于自监督学习任务（例如，长时间的测试时训练），并在给定自监督学习标签的情况下变得与主任务标签独立。在此条件下，主任务上的预测准确率可以直接估计如下。

定理 2。 如果 $Z' \perp\!\!\!\perp Y'_m \mid Y'_s$ ，则主任务上的预测准确率由下式给出

$$\mathbb{P}(\pi_m(Z') = Y'_m) = \sum_{y_s} \left[\mathbb{P}(Y_s = y_s) \sum_{y_m} \mathbb{P}(Y_m = y_m \mid Y_s = y_s)^2 \right]. \quad (6)$$

证明：请参见补充材料第 A.2 节。 □

直观上，如果编码特征关于主任务所包含的信息不超过自监督学习标签，则主分类器 π_m 的准确率仅取决于自监督学习任务的性质。特别地，方程 6 右侧的平方项强调了设计紧密相关的自监督学习任务的至关重要性。当两个任务偏离时，测试准确率以二次方速度下降，导致适应无效。

4.2 通过对比学习进行测试时训练

上述理论分析揭示了在测试时训练中纳入与主任务高度相关的自监督任务的重要性。量化两个任务之间关系的一种实用方法是测度从一个任务学习到的表示向另一个任务的可迁移性 [32]。鉴于对比方法在视觉表示预训练中取得的显著成果 [9, 12, 33, 34]，我们假设它们也将是测试时训练的合适选择。因此，在视觉识别背景下，我们用 SimCLR[12] 替换旋转预测任务。给定一个包含 B 张图像的小批量，我们将每张图像增强为两个视图。我们将来自同一原始实例的两个增强视图视为正对，并将其他对视为负对。每张图像 x_i 的特征向量 $z_i = g(x_i)$ 通过我们的自监督头投影到低维空间 $h_i = \pi_s(z_i)$ 。通过以下损失函数，鼓励来自正对 $\langle h_i, h_j \rangle$ 的投影隐藏嵌入比来自负对的更接近，

$$\mathcal{L}_s = -\log \frac{\exp(\text{sim}(h_i, h_j)/\tau)}{\sum_{k=1}^{2B} \mathbb{1}_{k \neq i} \exp(\text{sim}(h_i, h_k)/\tau)}, \quad (7)$$

其中 τ 是温度缩放参数。投影嵌入之间的距离通过余弦相似度 $\text{sim}(u, v) = u^T v / (\|u\| \|v\|)$ 来测度。




图 3: 在存在较大平移和旋转偏移的情况下, TTT[6] 与我们的 TTT++ 在交织双月问题上的定性比较。由于严重的特征错位 (在特征主成分分析可视化中用虚线箭头标出), 原始 TTT 使决策边界进一步偏离期望边界。相比之下, 我们的方法能更有效地将决策边界适配到测试域。




图 4: 在 150 种不同设置下, TTT[6] 与我们的 TTT++ 在交织双月问题上的定量比较。标准差以阴影区域可视化。我们的方法 (左) 在较大偏移 (即自适应前测试准确率较低) 下尤其具有优势, 并且 (右) 在主任务与自监督任务之间相关性更高 (即标签一致性更大) 时获益显著。

5 实验

我们在四种场景中实证验证了所提出的方法: 合成玩具问题、常见图像损坏、自然域偏移以及仿真到现实迁移。

在整个实验过程中, 我们考虑以下基线:

- **测试:** 训练域中的模型直接在测试数据上进行评估, 不进行任何自适应;
- 测试时归一化 (**BN**) [35] 根据测试数据更新已训练网络的批归一化统计量;
- 测试时熵最小化 (**TENT**) [8] 通过最小化模型在测试数据上预测的熵来更新已训练网络的批归一化统计量;
- 源假设迁移 (**SHOT**) [36] 冻结分类器模块, 仅更新特征提取模块, 利用测试期间的信息最大化来自监督伪标签概念;
- 测试时训练 (**TTT-R**) [6] 在源域中联合训练网络的主任务和基于旋转的自监督学习任务; 在测试期间, **TTT-R** 继续在目标域中训练基于旋转的任务。

我们还评估了以下我们方法的消融版本:

- 测试时特征对齐 (**TFA**) 在测试期间对齐源分布和目标分布的一阶和二阶统计量 (第 3.2 节和第 3.3 节);
- 测试时对比学习 (**TTT-C**) 在源域中联合训练网络的主任务和对比学习 (自监督学习) 任务; 在测试期间, **TTT-C** 继续基于目标域中的对比学习更新编码器 (第 4.2 节)。

我们方法的完整版本, 改进的测试时训练 (**TTT++**), 结合了 TFA 和 TTT-C。

5.1 合成玩具问题

我们首先在交错双月问题 [4, 37] 上评估我们的方法, 其中主任务是预测给定数据点的月亮类别, 自监督学习任务是预测数据点位于超平面 (即两个月亮之间的线性分隔符) 的哪一侧。两个任务之间的关系 (标签一致性) 取决于两个月亮之间的分离距离。为了同时解决这两个任务, 我们构建了一个小型神经网络, 由一个两层多层感知机作为共享编码器和两个两层多层感知机作为独立任务头组成。每个隐藏层包含 8 个神经元。学习到的模型在训练域中主任务和自监督学习任务上均达到超过 99% 的准确率。我们通过对所有数据点进行平移和旋转来模拟各种分布偏移。

图 3 展示了在特定的大分布偏移测试案例中, 普通测试时训练 (TTT) 和我们提出的 TTT++ 的决策边界和编码特征。TTT 不仅未能提高分类准确率, 反而由于严重的特征分布不匹配, 将决策边界推离了期望的位置, 这一点在 PCA 可视化中得到了证实。相比之下, 我们的 TTT++ 通过所提出的在线矩匹配减少了特征分布偏移, 从而带来了显著的性能提升, 将测试准确率从 50% 提高到 93%。




图 5: CIFAR10-C [1] 上的分类错误率 (%)。

表 1: CIFAR10-C/100-C [1] 和 CIFAR10.1 [40] 上的平均分类错误率 (%)

Method	C10-C	C100-C	C10.1
Test	29.1	61.2	12.1
BN [41]	15.7	43.3	14.1
TTT-R [6]	14.3	40.4	11.0
SHOT [36]	14.7	38.1	11.1
TENT [8]	12.6	36.3	13.4
TFA (Ours)	11.9	35.8	12.1
TTT-C (Ours)	10.7	36.9	9.7
TTT++ (Ours)	9.8	34.1	9.5

严重的特征分布不匹配，如 PCA 可视化所示。相比之下，我们的 TTT++ 通过所提出的在线矩匹配减少了特征分布偏移，从而带来了显著的性能提升，将测试准确率从 50% 提高到 93%。

图 4 总结了我们的方法以及普通对应方法在 150 种不同模拟设置下的定量结果。如左图所示，当域偏移仅导致主任务上的轻微测试误差时，原始 TTT 和我们的 TTT++ 都表现出强大的适应结果。然而，随着域偏移的增长，TTT 的有效性迅速下降，反映在较低的测试准确率上。相比之下，我们提出的 TTT++ 在大偏移下表现出明显的优势，例如，当适应前的测试准确率约为 0.5 时。我们进一步通过改变两个月亮之间的分离距离来研究主任务和自监督学习任务之间的关系对适应性能的影响。仿真结果证实了在改进的自监督学习任务下测试时训练的巨大潜力，正如第 4.1 节所分析的那样。

5.2 常见图像损坏

我们进一步评估了所提方法对常见图像损坏的鲁棒性。遵循先前工作的评估协议 [8]，我们在 CIFAR10/CIFAR100[39] 上训练 ResNet-50[38]，并在 CIFAR10-C/CIFAR100-C[1] 数据集上进行测试，这些数据集包含 15 种算法生成的损坏类型，如噪声、模糊和雪效应。测试时自适应使用批大小为 256。此外，在 CIFAR100-C 上，我们使用一个包含 16 批特征向量的动态队列进行在线特征对齐。

图 5 展示了每种图像损坏类型下的定量结果。CIFAR10-C 和 CIFAR100-C 上的平均结果报告在表 1 中。我们的 TTT++ 在 CIFAR10-C 和 CIFAR100-C 上明显优于先前最先进的测试时方法。特别是，结合强自监督任务 (TTT-C) 已经足以达到与 TENT 相当或更好的性能。在此基础上加入测试时特征对齐 (TFA) 可进一步使测试误差相对降低 $\sim 8\%$ 。

5.3 自然分布偏移

接下来我们展示所提方法 TTT++ 应对自然分布偏移的有效性。我们再次使用预训练的 ResNet-50，并在 CIFAR10.1[40] 上进行测试，这是一个最近收集的、受自然分布偏移影响的测试集。尽管与 CIFAR10 数据集在感知上高度相似，CIFAR10.1 通常会导致各种深度模型的准确率下降 (4% 至 10%) [40]。

表 1 总结了各种测试时算法在 CIFAR10.1 上的结果。先前基于批归一化的方法表现不佳，甚至降低了模型准确率。这一现象与其隐含假设有关，即不同样本和空间位置以相似方式偏移 [18]，该假设对算法生成的图像损坏成立，但在 CIFAR-10.1 上不成立。相比之下，TTT++ 更具通用性，在自然分布偏移下表现出更强的性能。

5.4 仿真到现实迁移

我们最后在 VisDA-C 数据集 [42] 上验证所提方法的有效性，这是一个具有挑战性的大规模合成到真实物体分类基准。如表 2 所示，先前的方法

表 2: 大规模 VisDA-C 数据集 [42] 上的分类错误率 (%)。

Method	plane	beycl	bus	car	horse	knife	mcycl	person	plant	sktbrd	train	truck	Per-class
Test	56.52	88.71	62.77	30.56	81.88	99.03	17.53	95.85	51.66	77.86	20.44	99.51	58.72
BN [41]	44.38	56.98	33.24	55.28	37.45	66.60	16.55	59.02	43.55	60.72	31.07	82.98	48.12
TENT [8]	13.43	77.98	20.17	48.15	21.72	82.45	12.37	35.78	21.06	76.41	34.11	98.93	42.73
SHOT [36]	5.73	13.64	23.33	42.69	7.93	86.99	19.17	19.97	11.63	11.09	15.06	43.26	25.04
TFA (Ours)	28.25	32.03	33.67	64.77	20.49	56.63	22.52	36.30	24.84	35.20	25.31	64.24	39.58
TTT-C (Ours)	5.46	32.23	25.42	37.03	7.84	85.20	9.14	23.80	11.72	11.00	7.74	56.87	25.72
TTT++ (Ours)	4.13	26.20	21.60	31.70	7.43	83.30	7.83	21.10	7.03	7.73	6.91	51.40	22.46

表 3: 在 CIFAR100-C 上, 在 5 级雾腐蚀下, 使用或不使用特征向量动态队列的在线特征对齐的分类错误率 (%) 结果。样本大小= 批大小 $\times$ 批数。给定固定的批大小, 增大队列大小会得到与使用更大批大小相似的结果。

Sample Size	w/o queue			w/ queue			
	64	128	256	64 $\times$ 2	64 $\times$ 4	64 $\times$ 8	64 $\times$ 16
Test Error	40.31	38.67	37.01	39.84	37.37	36.18	36.02

在图像腐蚀下相当有竞争力的方法, 如 BN[41] 和 TENT[8], 在 VisDA-C 上并不有效。我们推测这归因于它们在测试时对可调参数施加了严格的限制。相比之下, 本文提出的方法更加灵活, 允许模型更新整个编码器, 从而在 VisDA-C 上取得了令人瞩目的结果。此外, 测试时特征对齐在这个合成到真实的领域自适应问题中起着关键作用, 在 TTT-C 的基础上提供了 $\sim 13\%$ 的性能提升。

5.5 批队列解耦的效果

为了验证批队列解耦的效果, 我们比较了不同样本大小下在线特征对齐的结果。表 3 总结了在 5 级雾腐蚀下 CIFAR100 上的测试误差。正如预期的那样, 较大的样本大小通常会导致较低的分类错误率。有趣的是, 虽然使用动态队列的性能略逊于来自单个大批次的相同样本大小的对应方法, 但增大队列大小总是能产生更强的结果。例如, 给定 64 的小批大小, 使用动态队列分别从 8 个或 16 个连续批次中维护 512 或 1024 个特征向量, 比基于 256 个样本批大小的普通矩匹配更有优势。这一结果证实了将动态队列集成到本文提出的特征对齐框架中的好处, 以增强在线设置中的可扩展性。

5.6 矩匹配的设计选择

如第 3 节所述, 本文提出的在线特征对齐可通过不同阶矩进行实例化, 并应用于不同层。为理解具体设计选择的影响, 我们在表 4 中经验性地将所提版本与若干消融变体进行比较。无论选择哪一层, 本文提出的在线特征对齐均一致地降低了分类误差。然而, 在 15 种图像损坏类型中的 11 种上, 仅对自监督头应用矩匹配相比将其应用于特征提取器输出可获得更低的测试误差。我们推测前者的优异性能归因于特征向量的维度更低, 从而能够更准确地估计特征统计量。最佳结果来自在编码器和投影头输出处同时进行在线特征对齐, 这验证了我们在第 3.2 节中的设计选择。

我们进一步通过消融实验验证了发散测度的选择。使用二阶矩 (协方差) 的在线特征对齐明显优于使用一阶矩 (均值) 的方法。同样明显的是, 当同时考虑均值和协方差时, 在线特征对齐最为有效。

表 4: CIFAR10-C [1] 上不同在线特征对齐版本的分类误差 (%)。在两层同时考虑一阶和二阶矩, 在抵御大多数图像损坏类型方面优于其他对应方法。

TFA	brit	contr	defoc	elast	fog	frost	gauss	glass	impul	jpeg	motn	pixel	shot	snow	zoom
w/o $\mathcal{L}_{f,s}$	7.96	7.57	9.4	17.24	14.38	12.54	14.62	21.05	21.4	12.68	11.92	10.7	13.7	12.74	7.32
w/o $\mathcal{L}_{f,z}$	7.85	7.84	9.18	16.51	14.33	11.99	13.79	20.08	20.17	12.42	12.02	10.5	12.78	13.28	7.44
w/o Σ	7.49	7.56	9.62	18.62	19.22	12.72	16.02	25.07	25.17	13.43	13.63	11.22	15.04	15.11	7.77
w/o μ	7.43	7.37	8.90	15.92	12.98	11.57	13.46	19.27	18.95	11.87	11.11	9.97	12.81	11.76	7.04
Full	7.44	7.40	8.89	15.73	12.82	11.49	12.94	18.46	19.13	11.66	10.77	9.93	12.67	11.73	7.03

6 结论与讨论

本文深入分析了自监督测试时训练的局限性与潜力。我们提请注意特征分布不匹配的风险, 该风险在近期的测试时算法中至关重要却大多被忽视。通过分析在改进的自监督学习任务下测试准确率的增长, 我们揭示了该方法的巨大潜力。这些分析启发了三项改进方案, 即在线特征对齐、批队列解耦和对比测试时训练, 在多个鲁棒性基准上取得了最先进的结果。我们的结果表明, 以紧凑格式引入额外的任务特定和领域特定信息用于测试时自适应具有优势。我们希望这些发现能激励研究人员和实践者重新思考, 除了权重参数之外, 还应存储哪些内容以实现机器学习模型的鲁棒部署。

局限性。本文中, 我们将特征汇总限制在一阶和二阶矩。然而, 低阶统计量可能不足以刻画高维特征的复杂分布。开发针对测试时自适应的更高级汇总方法是未来工作的一个有趣方向。此外, 当所述假设不成立时, 我们的理论分析与实证结果之间可能存在较大差距。例如, 分类头或特征对齐在实践中均非完美。对于安全关键场景中测试时自适应的实际应用, 更多的理论保证将具有价值。

开放问题。在我们的实验中, 仅考虑标准 ResNet-50 作为骨干架构, 并在主任务与自监督任务之间共享整个特征提取器。然而, 近期文献 [30, 43] 表明, 不同层捕获不同层次的语义粒度。架构设计对测试时训练的影响仍是一个开放问题。此外, 虽然我们经验性地将所提方法与其他测试时自适应算法族进行了比较, 但这些技术利用从无标签数据中提取的不同监督信号, 彼此可以互补。将这些技术融合到统一框架中是未来探索的另一个有趣方向。

社会影响。本文旨在拓展当前测试时自适应机器学习算法的研究视野。对于涉及人类生命安全的应用场景, 如自动驾驶, 信任、安全与鲁棒性均为不可或缺的关键要素。当训练与测试环境高度相似时, 该领域已取得显著进展。然而, 当机器部署于全新环境时, 情况又将如何? 人类天生具备应对此类环境变化的能力。本文认为, 机器亦应具备与人类同等的适应能力。诚然, 前路漫漫, 但本文期望此项工作能推动更多研究, 致力于分析并设计在测试阶段实现鲁棒且高效自适应的算法。

致谢

本研究由瑞士国家科学基金会 (项目号 200021-L92326)、本田研发有限公司、洛桑联邦理工学院开放科学基金及法雷奥集团共同资助。感谢 Sudeep Salgia、Tao Lin、Lingjun Meng、Yifan Sun 对初稿提出的宝贵意见, 以及匿名审稿人的建设性评论。

参考文献

- [1] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. *Proceedings of the International Conference on Learning Representations*, 2019.
- [2] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael Jordan. Learning Transferable Features with Deep Adaptation Networks. In *International Conference on Machine Learning*, pages 97–105. PMLR, June 2015. ISSN: 1938-7228.
- [3] Mingsheng Long, Han Zhu, Jianmin Wang, and Michael I. Jordan. Deep Transfer Learning with Joint Adaptation Networks. In *Proceedings of the 34th International Conference on Machine Learning*, pages 2208–2217. PMLR, July 2017. ISSN: 2640-3498.
- [4] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lempitsky. Domain-adversarial training of neural networks. *The Journal of Machine Learning Research*, 17(1):2096–2030, January 2016.
- [5] Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial Discriminative Domain Adaptation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 7167–7176, 2017.
- [6] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei Efros, and Moritz Hardt. Test-Time Training with Self-Supervision for Generalization under Distribution Shifts. In *Proceedings of the 37th International Conference on Machine Learning*, pages 9229–9248. PMLR, November 2020. ISSN: 2640-3498.
- [7] Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data? source hypothesis transfer for unsupervised domain adaptation. In *International Conference on Machine Learning (ICML)*, pages 6028–6039, July 13–18 2020.
- [8] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully Test-Time Adaptation by Entropy Minimization. In *International Conference on Learning Representations*, September 2020.
- [9] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum Contrast for Unsupervised Visual Representation Learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9729–9738, 2020.
- [10] Raia Hadsell, Sumit Chopra, and Yann LeCun. Dimensionality Reduction by Learning an Invariant Mapping. In *2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition - Volume 2 (CVPR'06)*, volume 2, pages 1735–1742, New York, NY, USA, 2006. IEEE.
- [11] Zhirong Wu, Yuanjun Xiong, Stella Yu, and Dahua Lin. Unsupervised Feature Learning via Non-parametric Instance Discrimination. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3733–3742, June 2018. ISSN: 2575-7075.
- [12] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A Simple Framework for Contrastive Learning of Visual Representations. In *Proceedings of the 37th International Conference on Machine Learning*, pages 1597–1607. PMLR, November 2020. ISSN: 2640-3498.
- [13] Assaf Shocher, Nadav Cohen, and Michal Irani. Zero-Shot Super-Resolution Using Deep Internal Learning. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3118–3126, June 2018. ISSN: 2575-7075.
- [14] Yuejiang Liu, Parth Kothari, and Alexandre Alahi. Collaborative Sampling in Generative Adversarial Networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(04):4948–4956, April 2020. Number: 04.
- [15] David Bau, Hendrik Strobelt, William Peebles, Jonas Wulff, Bolei Zhou, Jun-Yan Zhu, and Antonio Torralba. Semantic photo manipulation with a generative image prior. *ACM Transactions on Graphics*, 38(4):59:1–59:11, July 2019.

- [16] Jogendra Nath Kundu, Naveen Venkat, Rahul M. V, and R. Venkatesh Babu. Universal Source-Free Domain Adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4544–4553, 2020.
- [17] Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Improving robustness against common corruptions by covariate shift adaptation. *Advances in Neural Information Processing Systems*, 33, 2020.
- [18] Collin Burns and Jacob Steinhardt. Limitations of Post-Hoc Feature Alignment for Robustness. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2525–2533, 2021.
- [19] Yang Fu, Sifei Liu, Umar Iqbal, Shalini De Mello, Humphrey Shi, and Jan Kautz. Learning to Track Instances without Video Annotations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8680–8689, 2021.
- [20] Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A. Efros, Lerrel Pinto, and Xiaolong Wang. Self-Supervised Policy Adaptation during Deployment. In *International Conference on Learning Representations*, September 2020.
- [21] Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A Kernel Two-Sample Test. *Journal of Machine Learning Research*, 13(25):723–773, 2012.
- [22] Baochen Sun, Jiashi Feng, and Kate Saenko. Correlation Alignment for Unsupervised Domain Adaptation. In Gabriela Csurka, editor, *Domain Adaptation in Computer Vision Applications*, Advances in Computer Vision and Pattern Recognition, pages 153–171. Springer International Publishing, Cham, 2017.
- [23] Werner Zellinger, Thomas Grubinger, Edwin Lughofer, Thomas Natschläger, and Susanne Saminger-Platz. Central Moment Discrepancy (CMD) for Domain-Invariant Representation Learning. *International Conference on Learning Representations*, International Conference on Learning Representations, November 2016. 00283.
- [24] Yaroslav Ganin and Victor Lempitsky. Unsupervised Domain Adaptation by Backpropagation. In *Proceedings of the 32nd International Conference on Machine Learning*, pages 1180–1189. PMLR, June 2015. ISSN: 1938-7228.
- [25] Mehdi Noroozi and Paolo Favaro. Unsupervised Learning of Visual Representations by Solving Jigsaw Puzzles. In Bastian Leibe, Jiri Matas, Nicu Sebe, and Max Welling, editors, *European Conference on Computer Vision*, pages 69–84, Cham, 2016. Springer International Publishing.
- [26] Mathilde Caron, Piotr Bojanowski, Armand Joulin, and Matthijs Douze. Deep Clustering for Unsupervised Learning of Visual Features. In Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu, and Yair Weiss, editors, *Computer Vision – ECCV 2018*, Lecture Notes in Computer Science, pages 139–156, Cham, 2018. Springer International Publishing.
- [27] Yuejiang Liu, Qi Yan, and Alexandre Alahi. Social NCE: Contrastive Learning of Socially-Aware Motion Representations. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 15118–15129, 2021.
- [28] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging Properties in Self-Supervised Vision Transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 9650–9660, 2021.
- [29] Xinlei Chen and Kaiming He. Exploring Simple Siamese Representation Learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15750–15758, 2021.
- [30] Eric Tzeng, Judy Hoffman, Ning Zhang, Kate Saenko, and Trevor Darrell. Deep Domain Confusion: Maximizing for Domain Invariance. *arXiv:1412.3474 [cs]*, December 2014. arXiv: 1412.3474.

- [31] Chao Chen, Zhihang Fu, Zhihong Chen, Sheng Jin, Zhaowei Cheng, Xinyu Jin, and Xian-sheng Hua. HoMM: Higher-Order Moment Matching for Unsupervised Domain Adaptation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(04):3422–3429, April 2020. Number: 04.
- [32] Amir R. Zamir, Alexander Sax, William Shen, Leonidas J. Guibas, Jitendra Malik, and Silvio Savarese. Taskonomy: Disentangling Task Transfer Learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3712–3722, 2018.
- [33] Jean-Bastien Grill, Florian Strub, Florent Altché, Corentin Tallec, Pierre H. Richemond, Elena Buchatskaya, Carl Doersch, Bernardo Avila Pires, Zhaohan Daniel Guo, Mohammad Gheshlaghi Azar, Bilal Piot, Koray Kavukcuoglu, Rémi Munos, and Michal Valko. Bootstrap your own latent: A new approach to self-supervised Learning. *arXiv:2006.07733 [cs, stat]*, September 2020. 00623 arXiv: 2006.07733.
- [34] Mathilde Caron, Ishan Misra, Julien Mairal, Priya Goyal, Piotr Bojanowski, and Armand Joulin. Unsupervised Learning of Visual Features by Contrasting Cluster Assignments. *arXiv:2006.09882 [cs]*, January 2021. 00403 arXiv: 2006.09882.
- [35] Steffen Schneider, Evgenia Rusak, Luisa Eck, Oliver Bringmann, Wieland Brendel, and Matthias Bethge. Removing covariate shift improves robustness against common corruptions. *CoRR*, abs/2006.16971, 2020.
- [36] Jian Liang, Dapeng Hu, and Jiashi Feng. Do We Really Need to Access the Source Data? Source Hypothesis Transfer for Unsupervised Domain Adaptation. In *International Conference on Machine Learning*, pages 6028–6039. PMLR, November 2020. ISSN: 2640-3498.
- [37] Pascal Germain, Amaury Habrard, François Laviolette, and Emilie Morvant. A PAC-Bayesian Approach for Domain Adaptation with Specialization to Linear Classifiers. In *Proceedings of the 30th International Conference on Machine Learning*, pages 738–746. PMLR, May 2013. ISSN: 1938-7228.
- [38] Kaiming He, X. Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [39] A. Krizhevsky. Learning multiple layers of features from tiny images, 2009.
- [40] Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, and Vaishaal Shankar. Do ImageNet Classifiers Generalize to ImageNet? In *Proceedings of the 36th International Conference on Machine Learning*, pages 5389–5400. PMLR, May 2019. ISSN: 2640-3498.
- [41] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In Francis R. Bach and David M. Blei, editors, *Proceedings of the 32nd International Conference on Machine Learning, ICML 2015, Lille, France, 6-11 July 2015*, volume 37 of *JMLR Workshop and Conference Proceedings*, pages 448–456. JMLR.org, 2015.
- [42] Xingchao Peng, Ben Usman, Neela Kaushik, Judy Hoffman, Dequan Wang, and Kate Saenko. Visda: The visual domain adaptation challenge. *ArXiv*, abs/1710.06924, 2017.
- [43] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How Transferable Are Features in Deep Neural Networks? In *Proceedings of the 27th International Conference on Neural Information Processing Systems - Volume 2, NIPS’14*, pages 3320–3328, Cambridge, MA, USA, 2014. MIT Press.
- [44] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised Contrastive Learning. *arXiv:2004.11362 [cs, stat]*, April 2020. arXiv: 2004.11362.