

TTT-VLA: 面向视觉-语言-动作模型的测试时潜在提示优化

Wenbo Zhang^{1,2,*}, Jianxiong Li^{1,3}, Shuai Yang⁴, Sijin Chen^{1,5}, Jiajun Liu⁶,
Lingqiao Liu^{2,†}, Xiao Ma^{1,†}

¹ByteDance Seed, ²The University of Adelaide, ³Tsinghua University, ⁴Zhejiang University,
⁵The University of Hong Kong, ⁶CSIRO Data61

*Work done at ByteDance Seed, †Corresponding authors

Abstract

基于大规模数据训练的视觉-语言-动作（VLA）模型已取得显著进展，但在部署时仍易受分布偏移的影响。近期 VLA 模型表明，提示可作为引导策略行为的高效接口，但现有基于提示的引导通常依赖外部指导。这引出一个自然的问题：能否通过优化提示来实现 VLA 的测试时训练（TTT），从而使引导接口本身能够从交互中学习和适应？本文通过 TTT-VLA 来回答这一问题，这是一个基于潜在提示优化（LPO）的测试时训练框架。在训练阶段，潜在提示通过一个额外的代理任务进行学习，为策略学习提供额外的学习条件信号。在测试阶段，通过从当前环境收集交互数据，并仅利用代理任务的自监督信号在这些数据上优化潜在提示来执行 TTT，而不修改策略本身。在 SimplerEnv 上的实验表明，所提方法在单一和多种具身设置下均能持续提升任务成功率。进一步分析显示，性能提升主要源于纠正少量关键决策，而非全局改变策略行为。这些结果表明，LPO 为基础操作策略的部署时改进提供了一条有效且实用的途径。

Date: June 1, 2026

Correspondence: xiao.ma@bytedance.com, lingqiao.liu@adelaide.edu.au

1 引言

视觉-语言-动作（VLA）模型是通用机器人控制的一个有前景的框架，因为它们将视觉感知、语言条件和动作生成统一在单一策略中。对 VLA 更好泛化性的追求推动了多种技术方向，包括大规模预训练 [1–3, 12, 21]、潜在动作模型 [5, 38] 以及基于世界模型的方法 [13, 39]。实现这一目标的另一条实用途径是在部署时改进策略，尤其是当模型必须在视觉条件、环境或具身发生变化的情况下行动时。然而，部署时改进的主流方法仍然是强化学习（RL），它可以通过交互改进策略，但通常成本高昂且依赖奖励 [22, 25]。

与此同时，近期工作表明，基于提示的引导正成为

部署时改进视觉-语言-动作模型（VLA）[14, 26, 40, 41]。特别是，借助人类辅助（如分解指令），现成的策略能够取得更优性能。尽管该方法有效，但这一范式无法从部署经验中学习。另一方面，正如 $\pi_{0.7}$ 所强调的，任务成功与熟练程度还可能取决于难以仅用文本表达的细粒度上下文，例如回合质量、执行速度或视觉线索 [26]。这些因素反映了与控制相关的时空上下文，表明在 VLA 控制中表示此类上下文仍有很大改进空间。

受此观察启发，我们探索了部署时改进的新方向：在训练期间学习潜在提示 z 以条件化策略，然后在测试时仅通过调整 z 来改进策略。我们通过基于潜在提示优化的框架 TTT-VLA 解决这一问题。如图 1 所示，核心思想是从与测试环境的交互中获取改进信号，并利用该信号优化潜在提示。由于 VLA 被训练为以该提示为条件，测试时知识可以通过轻量级接口被吸收，而无需修改策略主干。在我们当前的实现中，改进信号来自一个名为状态接地的代理任务，该任务利用观测-状态监督来塑造潜在提示。该代理任务促使潜在提示捕获空间相关信息 [35]，我们进一步设计了训练策略以强化这一效果。由此产生的潜在提示具有双重作用：在训练期间，它为策略学习提供额外的学习条件信号；在测试时，从当前环境收集交互数据，并仅用于更新冻结策略的潜在提示。




图 1 TTT-VLA 与潜在提示优化的概览。

我们在简化环境（SimplerEnv）[15] 中，分别在单一具身和多具身设置下评估了这一想法。我们的评估遵循官方协议，即策略在真实机器人数据上训练并在仿真中测试，这自然引入了部署时的领域差距。在单一具身设置中，我们在 WidowX 和 Google Robot 任务上进行评估。在多具身设置中，我们在 OXE-Aug [10] 的 BridgeData V2 [30] 上训练，包含九种具身，然后在 WidowX 上进行评估。在这些设置中，我们通过 TTT-VLA 在保持主策略冻结的情况下实现了持续改进。分析进一步表明，大部分增益来自我们称之为关键决策引导的现象，其中测试时训练

表 1 视觉-语言-动作（VLA）部署时改进策略的比较。这些策略在部署时如何干预策略、更新什么内容以及驱动改进的信号方面有所不同。TTT-VLA 属于自监督测试时训练范畴：它仅优化潜在提示，同时保持策略主干冻结。更多比较参见第 5 节。

	Human-Assisted Steering	RL Post-Training	Test-Time Training
Intervention interface	Prompts, e.g., task-factorized instruction, metadata, trace	Typically policy itself	Typically parts of the parameters. In this paper, we only use latent prompts.
Improvement signal	Human guidance / external signal	Reward	Self-supervised loss
Policy backbone status	Frozen	Generally updated	Frozen

纠正少量关键动作，而不是全局重写完整轨迹。我们的贡献总结如下：

- TTT-VLA，一种基于潜在提示优化的 VLA 部署时改进框架，在训练期间学习潜在提示，并在部署时对冻结策略执行仅提示的测试时训练。
- 在单一具身和多具身设置中均实现一致的部署时改进，表明潜在提示可以作为从交互中学习的有效接口。
- 对潜在提示的有效训练和更新策略进行了研究，揭示增益主要来自我们称之为关键决策引导的现象。

2 相关工作

2.1 操作策略的部署时改进

针对操作策略的部署时改进已通过强化学习后训练、人类辅助提示引导以及近期的测试时训练等方法进行了研究。其中一条成熟的研究路线是通过从部署经验中进行强化学习来改进视觉-语言-动作策略。代表性工作包括 $\pi_{0.6}^*$ ，该工作研究了基于异构经验和人类纠正的强化学习自改进方法；以及 GR-RL，它通过多阶段强化学习将通用型视觉-语言-动作模型转变为灵巧的专用模型 [22, 25]。

另一条研究路线将视觉-语言-动作模型的条件接口本身作为部署时人类辅助的通道。Yell At Your Robot 在执行过程中使用实时语言纠正，而 MolmoAct 和 TraceVLA 则暴露可编辑的迹作为时空引导的结构化转向信号 [14, 28, 41]。 $\pi_{0.7}$ 进一步扩展了该接口，引入元数据、语言引导和图像目标上下文，表明人类或外部指定的上下文能够提升轨迹质量和对未见任务的泛化能力 [26]。

关于操作策略测试时训练的早期工作包括 PAD[7]，该工作在小规模策略上表明自监督信号能够帮助操作策略适应环境变化。然而，PAD 并未在基础模型框架下进行研究。因此，其设计思路和结论均无法直接迁移至现代视觉-语言-动作模型。近期，测试时训练开始出现在视觉-语言-动作模型文献中。一项同期工作是 WorldAgen[31]，它联合学习动作预测和世界建模，并在部署时利用新收集的转移数据对其世界模型分支进行适应。然而，其测试时训练方案是围绕一个随方法一同提出的定制架构构建的，而非基于强大的最先进视觉-语言-动作模型。相比之下，本文将提示作为一种轻量级适应接口，用于预训练视觉-语言-动作模型，从而在已经具备竞争力的强大基础策略之上执行测试时训练。

2.2 提示条件视觉-语言-动作模型

近期的视觉-语言-动作（VLA）模型日益围绕超越纯语言的提示条件化接口进行组织。早期系统如 RT-2、OpenVLA 和 Octo 确立了语言条件化的机器人控制，Octo 进一步表明子目标图像可作为额外的任务指定通道 [3, 11, 20, 37]。近期工作通过使用结构化轨迹或迹输入作为提示进一步拓宽了提示的概念，如 MolmoAct 和 TraceVLA[14, 41]。 π 系列进一步扩展了这一方向： π_0 提升了语言条件化控制的广度和灵巧性， $\pi_{0.5}$ 通过分层子任务指令增强提示， $\pi_{0.7}$ 则利用源自世界模型的元数据和图像目标上下文进一步拓宽条件化空间 [1, 24, 26]。这些工作共同表明，更丰富的提示接口是现代 VLA 性能的核心。本文方法与该方向互补：我们并非添加另一个由人类指定的提示通道，而是学习一个潜在提示，该提示捕获 VLA 策略的控制相关上下文，并可通过测试时训练进行更新。




图 2 TTT-VLA 概览。策略以当前观测、显式提示和潜在提示为条件。训练期间，潜在提示与策略及状态接地代理任务联合优化。部署期间，测试时训练仅通过与环境的交互更新潜在提示，而不修改策略本身。

3 方法：潜在提示优化

一般而言，VLA 策略可写为条件策略，其接收当前观测 o 及条件化上下文 c ，并预测动作块 a ，通过

$$a \sim \pi_{\theta}(a \mid o, c), \quad (1)$$

其中 c 是一个统一的条件变量。它可以包含具有可读语义的显式条件，例如语言、状态、图像或其他结构化上下文，以及以可学习潜在提示 z 形式存在的隐式条件。在我们当前的实现中， $z \in \mathbb{R}^{n \times d}$ 被实例化为一个可学习的 n 个提示标记块，其中 d 是策略骨干的隐藏维度， n 是控制提示长度的超参数。遵循基于流的视觉-语言-动作（VLA）公式，我们将动作生成建模为动作块上的条件流匹配。设 $a_0 \sim p_0$ 表示动作空间中的噪声样本，设 $a_1 = a$ 表示目标动作块。对于插值时间 $t \sim \mathcal{U}(0, 1)$ ，我们将加噪动作轨迹定义为 $a_t = (1 - t)a_1 + ta_0$ ，并将对应的目标向量场定义为 $u_t = a_0 - a_1$ 。策略根据当前输入和完整条件上下文预测向量场：

$$\mathcal{L}_{\text{act}}(\theta, z) = \mathbb{E}_{(o, c, a), a_0, t} \left[\|v_{\theta}(a_t, t; o, c) - u_t\|_2^2 \right]. \quad (2)$$

该目标定义了本文框架中的基础策略学习问题。潜在提示优化并不取代动作目标，而是增加了一个可学习的条件变量，该变量可在训练期间优化，并在部署时进行适配。下一小节将介绍该潜在提示在部署时如何通过抽象代理目标进行更新，后续实现小节将具体说明当前系统所使用的代理目标。

3.1 通过潜在提示优化的测试时训练

受先前测试时训练与部署时自监督适应工作的启发 [6, 7, 29]，本文引入一个代理任务，以实现潜在提示优化的测试时训练。由于在部署时仅对提示进行适应无法直接获得动作目标，该代理任务提供了执行测试时训练过程所需的辅助学习目标。同时，它在训练期间将潜在提示与控制相关上下文耦合，使得同一目标之后可复用于部署时适应。在训练过程中，本文同时利用动作目标和代理目标优化策略，使潜在提示既有助于动作预测，又保持可适应性。

the same proxy signal:

$$\mathcal{L}_{\text{train}}(\theta, z) = \mathcal{L}_{\text{act}}(\theta, z) + \mathcal{L}_{\text{proxy}}(\theta, z). \quad (3)$$

在测试阶段，我们的主要流程是基于当前环境交互缓冲区的仅提示词自适应。我们首先从当前环境收集交互数据，将得到的样本组织成缓冲区，然后仅更新潜在提示词，同时保持策略主干网络冻结。由此得到的测试时训练规则可以写为

$$z \leftarrow z - \eta \nabla_z \mathcal{L}_{\text{proxy}}, \quad (4)$$

使用来自当前环境的交互数据。这里， $\mathcal{L}_{\text{proxy}}$ 表示训练中引入的同一代理目标，其具体实例化在 3.2 节中作为状态接地任务给出。这保持了清晰的分工：动作专家仍然负责动作生成，而潜在提示词是部署期间唯一被调整的变量。我们还探索了在线提示词更新作为消融实验，但在当前实验中这种模式不稳定，提示词表示容易崩溃，因此主要方法采用上述离线缓冲区公式。

3.2 架构与训练策略

网络结构。如图 2 所示，我们当前的实现将 TTT-VLA 实例化为混合变换器（Mixture-of-Transformers, MoT）架构 [1]，由两个流匹配专家组成：一个动作专家预测动作空间中的流场，一个状态接地专家预测状态空间中的流目标，用于机器人状态接地。我们考虑使用硬路由器进行潜在提示词选择。如果训练数据包含多个实施例，则随机初始化多个潜在提示词。在单一实施例设置中，该设计自然退化为单个潜在提示词。

详细的注意力掩码如图 3 所示。潜在提示词能否被动作专家关注取决于具体的训练策略，这些策略将在后文描述。在训练期间，参数从预训练的 $\pi_{0.5}$ 检查点初始化。注意状态输入有细微差别：它从语言形式的条件输入移入动作专家，遵循 $\pi_{0.}$ 的实现。这一变化主要是为了避免与我们的代理任务冲突。我们的主要比较集中在两个变体上。




图 3 MoT 网络中使用的注意力掩码。

状态接地作为代理任务。在当前实现中，潜在提示优化通过一个名为状态接地的代理任务实例化，其中专用专家根据当前观测、显式提示和潜在提示预测机器人末端执行器位置和夹爪状态。设 $s_1 = s$ 表示目标机器人状态，包括末端执行器位置和夹爪状态，设 $s_0 \sim p_0^s$ 表示状态空间中的噪声样本。

对于插值时间 $t \sim \mathcal{U}(0, 1)$ ，定义加噪状态轨迹为 $s_t = (1 - t)s_1 + ts_0$ ，对应的目标向量为

$u_t^s = s_0 - s_1$ 。状态接地专家以当前输入和完整条件上下文

为条件预测该向量场：

$$\mathcal{L}_{\text{proxy}}(\theta, z) = \mathcal{L}_{\text{sg}}(\theta, z) = \mathbb{E}_{(o, c, s), s_0, t} \left[\|v_\theta^s(s_t, t; o, c) - u_t^s\|_2^2 \right]. \quad (5)$$

本文采用该任务作为代理目标，原因有二。首先，这些状态目标在训练和部署阶段均可获得，无需额外标注成本，使其成为实用的自监督信号。其次，

准确的状态预测需要对场景的空间理解以及对机器人本体的具体理解，因此提供了丰富的控制相关线索 [31, 35]。剩余问题是如何确保这些线索更有效地被吸收到潜在提示中，而非其他参数中，这促使了下述训练策略。

单一体与多体设置下的训练策略。在多体设置中，本体为异构机器人数据提供了自然划分，形成不同的控制相关上下文。因此，本文将不同的状态接地潜在提示与不同本体相关联，并同时使用动作目标和状态接地目标进行联合优化。该设计鼓励跨本体控制差异被吸收到潜在提示中，而非完全纠缠在共享模型参数中。

单一实体设置的数据更为有限，因此这种自然划分会变得弱得多，必须更明确地强制提示学习。为解决这一问题，本文采用两阶段训练策略。如图 3 所示，从潜在提示到动作专家的连接是可选的：在第一阶段，它以概率 1 被阻断；在第二阶段，它以概率 0.5 被阻断。该随机丢弃设计的消融实验见附录图 8。若不采用随机丢弃，仅添加潜在提示便可能降低基础策略的性能，这表明在单一实体机制中更强的解耦至关重要。相关的提示丢弃或条件丢弃策略在先前工作中也有使用 [9]。此外，本文将状态接地目标的梯度流限制在状态专家和潜在提示上，而动作目标的梯度流则限制在视觉语言模型骨干和动作专家上。这些约束共同促使潜在提示在更紧密地耦合到动作预测之前，从代理任务中吸收与控制相关的上下文。

表 2 在 SimplerEnv WidowX 基准上与最先进策略的性能比较。对于最后三行，均从预训练的 $\pi_{0.5}$ 检查点初始化。此处，‘ $\pi_{0.5}$ ’表示本文内部基线，‘ $\pi_{0.5} + \text{SG-LP}$ ’添加了带潜在提示训练的状态接地，‘ $\pi_{0.5} + \text{SG-LP} + \text{TTT}$ ’进一步对学习到的潜在提示应用测试时训练。

WidowX Benchmark	Carrot	Eggplant	Spoon	Cube	Overall
RT-1-X [4]	4.2%	0%	0%	0%	1.1%
OpenVLA [12]	0%	4.1%	0%	0%	1.0%
SpatialVLA [27]	20.8%	70.8%	20.8%	25.0%	34.4%
Magma [36]	29.2%	91.7%	37.5%	20.8%	44.8%
Octo-Base [20]	8.3%	43.1%	12.5%	0%	16.0%
Octo-Small [20]	9.7%	56.9%	47.2%	4.2%	29.5%
RoboVLM [18]	20.8%	79.2%	45.8%	4.2%	37.5%
InstructVLA [37]	40.3%	94.4%	43.1%	9.7%	46.9%
π_0 [1]	36.1%	81.9%	45.8%	26.4%	47.6%
CogACT [16]	37.5%	91.7%	58.3%	20.8%	52.1%
ThinkAct [8]	37.5%	70.8%	58.3%	8.7%	43.8%
$\pi_{0.5}$	79.2%	75.0%	33.3%	16.7%	51.1%
$\pi_{0.5} + \text{SG-LP}$	69.5%	70.5%	72.5%	41.5%	63.5%
$\pi_{0.5} + \text{SG-LP} + \text{TTT}$	74.5%	76.0%	71.0%	48.0%	67.4%

4 实验

基准。本文在本节中始终使用 SimplerEnv[15] 作为评估基准。在该基准内，本文研究了单一具身和多具身两种设置：前者涵盖固定具身的 WidowX 和 Google Robot 任务，后者研究在 OXE-Aug（增强的 Open X-Embodiment (OXE) 训练集）上进行训练，并在 WidowX 上进行评估。为便于阅读，WidowX 任务在表 2、表 4、表 7 和图 6 中分别缩写为 Spoon、Carrot、Cube 和 Eggplant，对应将勺子放在毛巾上、将胡萝卜放在盘子上、堆叠积木和将茄子放入篮子中。

基线。为进行比较，本文报告了 SimplerEnv 上多种先前方法的公开最先进结果。

表 3 在 SimplierEnv Google Robot 任务上的性能比较。结果按视觉匹配和变体聚合两种协议报告。

Visual Matching				
Model	Pick Coke Can	Move Near	Open/Close Drawer	Avg
HPT [33]	56.0%	60.0%	24.0%	46.0%
TraceVLA [41]	28.0%	53.7%	57.0%	42.0%
RT-1-X [2]	56.7%	31.7%	59.7%	53.4%
Octo-Base [20]	17.0%	4.2%	22.7%	16.8%
OpenVLA [12]	16.3%	46.2%	35.6%	27.7%
RoboVLM [18] (zero-shot)	72.7%	66.3%	26.8%	56.3%
RoboVLM [18] (fine-tuned)	77.3%	61.7%	43.5%	63.4%
Emma-X [17]	2.3%	3.3%	18.3%	8.0%
π_0 [1] (fine-tuned)	72.7%	65.3%	38.3%	58.7%
π_0 -Fast [23] (fine-tuned)	75.3%	67.5%	42.9%	61.9%
GR00T [19] (fine-tuned)	69.3%	68.7%	35.8%	52.4%
$\pi_{0.5}$	84.0%	59.2%	59.3%	67.5%
$\pi_{0.5}$ + SG-LP	85.0%	66.2%	55.6%	68.9%
$\pi_{0.5}$ + SG-LP + TTT	85.0%	71.7%	60.6%	72.4%

Variant Aggregation				
Model	Pick Coke Can	Move Near	Open/Close Drawer	Avg
TraceVLA [41]	60.0%	56.4%	31.0%	45.0%
RT-1-X [2]	49.0%	32.3%	29.4%	39.6%
Octo-Base [20]	0.6%	3.1%	1.1%	1.1%
OpenVLA [12]	54.5%	47.7%	17.7%	39.8%
RoboVLM [18] (zero-shot)	68.3%	56.0%	8.5%	46.3%
RoboVLM [18] (fine-tuned)	75.6%	60.0%	10.6%	51.3%
Emma-X [17]	5.3%	7.3%	20.5%	11.0%
π_0 [1] (fine-tuned)	75.2%	63.7%	25.6%	54.8%
π_0 -Fast [23] (fine-tuned)	77.6%	68.2%	31.3%	59.0%
GR00T [19] (fine-tuned)	46.7%	62.9%	17.5%	43.7%
$\pi_{0.5}$	82.0%	47.7%	44.7%	58.1%
$\pi_{0.5}$ + SG-LP	81.7%	51.2%	42.9%	58.6%
$\pi_{0.5}$ + SG-LP + TTT	79.3%	55.2%	45.8%	60.1%

作为我们方法的严格对照，我们引入了一个不包含状态专家或潜在提示的基线，该基线是直接从原始 $\pi_{0.5}$ 微调得到的版本。第二个记法是‘ $\pi_{0.5}$ + SG-LP’（状态接地潜在提示），它在基线上扩展了 SG-LP 训练。第三个是‘ $\pi_{0.5}$ + SG-LP + 测试时训练（TTT）’，它进一步将测试时训练应用于学习到的潜在提示。后一种变体是我们的完整方法，TTT-VLA。

训练。 所有模型都从预训练的 $\pi_{0.5}$ 检查点初始化。我们将状态输入从语言形式的条件转移到动作专家中，遵循 π_0 的实现，以避免与代理任务冲突。在单一具身设置中，模型训练 20,000 步；在多具身设置中，训练 40,000 步。我们使用 AdamW 优化器，学习率为 1×10^{-4} ，批大小为 1024。所有训练运行在 32 块 NVIDIA H100 GPU 上进行，每次运行的墙钟时间约为 20 小时。

测试时训练。 在测试时，我们仅更新潜在提示，将其初始化为训练期间学到的预训练提示。我们使用学习率 1×10^{-5} 和批大小 128。除非另有说明，WidowX 任务运行 500 个优化步骤，Google Robot 任务运行 1000 个优化步骤。我们不根据评估性能选择最佳检查点；相反，我们为每个基准预先固定优化范围，以便在每个设置内保持程序一致，并在代理损失基本趋于平稳后停止。

表 4 SimplerEnv WidowX 任务上的多具身评估。该策略在 OXE-Aug Bridge V2 上训练，共包含九个具身，并在四个 Bridge V2 WidowX 任务上进行评估。

Method	Carrot	Eggplant	Spoon	Cube	Mean
$\pi_{0.5}$	28.0%	17.5%	43.0%	2.5%	22.8%
$\pi_{0.5} + \text{SG-LP}$	41.0%	29.5%	43.0%	0.5%	28.5%
$\pi_{0.5} + \text{SG-LP} + \text{TTT}$	43.0%	34.0%	48.5%	1.0%	31.6%

代理损失基本趋于平稳。测试时训练在 8 块 NVIDIA H100 GPU 上进行，通常需要 15 – 30 分钟的墙钟时间。更多细节见附录 6。

评估协议。在 SimplerEnv 中的评估具有随机性，原因在于：（1）动作通过流匹配采样生成；（2）WidowX 基准在四个任务中仅有 24 种配置，且物体位置和朝向各不相同。因此，单次扫描噪声过大，难以进行可靠比较。遵循 GR00T [19] 的做法，我们对每个 WidowX 任务评估 200 个回合，循环遍历 24 种配置，同时允许采样噪声在不同试验中产生不同动作。在模型变体之间，我们仅固定初始种子，而不固定完整的下游随机流，因此采样噪声和由此产生的动作仍然不同。这降低了评估方差，有助于进行更可靠的比较。对于 Google Robot 视觉匹配和变体聚合，我们使用官方默认评估次数。在优化评估流程后，一次完整评估的墙钟时间约为：Bridge 40 分钟，Fractal 视觉匹配 50 分钟，Fractal 变体聚合 3 小时。




图 4 九个训练具身中的 OXE-Aug Bridge V2 示例。

4.1 单一具身设置

我们首先研究单一具身设置，其中主要问题是：即使具身身份本身固定，学习到的潜在提示是否仍然有用。表 2 展示了在 SimplerEnv WidowX 基准上的结果。在 $\pi_{0.5}$ 上加入潜在提示优化后，平均成功率从 51.1% 提升至 63.5%，测试时训练进一步将其提升至 67.4%。我们在表 3 的 Google Robot 任务中观察到相同的趋势。在视觉匹配划分上，平均成功率从 $\pi_{0.5}$ 的 67.5% 提升至使用潜在提示优化后的 68.9%，再经测试时训练后达到 72.4%。在变体聚合划分上，同一序列从 58.1% 提升至 58.6%，再提升至 60.1%。

4.2 多具身设置

我们接下来研究多具身设置。在此设置中，训练数据来自 OXE-Aug Bridge V2，共包含九种具身：原始的 WidowX 以及八种额外具身，即 Panda、UR5e、Xarm7、Google Robot、Sawyer、Kinova3、IIWA 和 Jaco，如图 4 所示。在评估过程中，路由器在推理前为 WidowX 选择相应的提示。结果如表 4 所示。与 $\pi_{0.5}$ 基线相比，潜在提示优化将平均成功率从 22.8% 提升至 28.5%，测试时训练进一步将其提升至 31.6%。提升主要集中在 Carrot 和 Eggplant 任务上，而 Cube 对所有变体而言仍然困难。经验上，我们发现 Cube 特别困难，因为它相比其他任务需要更精确的抓取和放置对齐，而在异构多具身数据上训练时这一挑战更加严峻。




图 5 测试时训练效果的定性可视化。顶行比较了有无 TTT 的动作轨迹，底行展示了一个具有代表性的操作序列，其中 TTT 将关键决策从向下运动引导为向上纠正运动，从而成功完成任务。

4.3 消融与分析

在线与离线 TTT 在此，在线 TTT 指随着交互样本到达持续更新潜在提示，使用批大小 1 和学习率 1×10^{-7} 。该设置在 [32, 34] 中被概念性引入，其目标是适应当地流式数据分布。相比之下，离线 TTT 将交互样本存储在缓冲区中，随后进行批量优化。在离线 TTT 中，我们进一步区分逐任务优化和所有任务上的联合优化。如图 6 所示，我们发现完全在线的提示更新较为敏感，导致性能大幅下降。因此，我们以离线 TTT 作为主要设置，并将在线 TTT 视为稳定性分析而非主要部署协议。同时，逐任务与联合离线优化之间的差异可以忽略不计。这些结果表明，批大小而非任务分组是关键因素，并且对于在测试时训练期间保持有意义的潜在表征可能很重要。稳定真正即时的提示更新仍是一个重要的未来方向。

学习率敏感性 我们还研究了离线联合测试时训练的学习率敏感性，因为这一基本超参数对性能有很大影响。适中的学习率 10^{-5} 表现最佳，优于较大的更新尺度 10^{-4} 和较小的更新尺度 10^{-6} 。这一结果表明，仅提示词的适应并非任意脆弱，但它仍然受益于使用一个足够大的更新尺度，以




图 6 单一实体设置下测试时训练配置的分析。左图：在线与离线测试时训练策略的任务级比较，包括离线逐任务和离线联合变体。右图：离线联合测试时训练的学习率敏感性，其中适中的学习率 10^{-5} 给出了最佳平均成功率。

纠正部署特定的不匹配，同时不破坏已学习的提示词。

增益来源。为了获得有效的比较，我们在完全固定种子的情况下重新运行实验¹。这使我们能够仔细检查测试时训练改善行为的案例。我们发现大多数这些改进遵循一个共同的模式，我们称之为“关键决策引导”。图 5 展示了一个代表性示例。在夹爪抓住胡萝卜之前，有和没有测试时训练的动作输出在所有维度上几乎相同。分歧在抓取后立即出现：没有测试时训练的模型继续向下移动，仿佛未能识别胡萝卜已被固定且手臂被桌子阻挡，而有测试时训练的模型则适当地抬起手臂。从这个决策点开始，两条轨迹分离且不再重叠。我们在各任务中观察到类似行为。许多操作任务由多个阶段组成，阶段之间的过渡通常对应关键决策点。一个常见的例子是判断抓取是否成功。在立方体任务中，放置阶段出现了一个不同的关键点：在抓住立方体后，策略必须决定物体是否在释放前已充分对齐。附录图 7 展示了另一个示例，其中测试时训练通过减少过冲和产生更好的块对齐来改善这一放置决策。

5 结论

我们研究了是否可以通过更新学习到的潜在提示来实现视觉-语言-动作模型在部署时的改进。为此，我们提出了 TTT-VLA，这是一个基于潜在提示优化的框架，在训练期间学习潜在提示，并在部署时对冻结策略进行仅提示的测试时训练。在 SimplerEnv 上的实验表明，这种设计在单一具身和多具身设置下均能提升性能，包括在 WidowX 和 Google Robot 任务上测试时训练带来的一致增益。

实证分析进一步表明，测试时训练的益处通常来自于在少数关键决策点纠正行为，而非全局改变完整动作轨迹。当前的局限性在于，在现有代理任务下，这些改进主要表现为对关键点附近错误动作的局部修正，而非在更长时域上更复杂的纠正行为。这可能限制了仅提示测试时训练所能达到的改进上限。重要的下一步是开发更有效的提示优化程序，并研究该接口如何随更强的 VLA 骨干网络扩展。更多局限性和开放问题在附录.1 中讨论。

¹ 这对于标准评估不可行，因为流匹配需要随机采样

参考文献

- [1] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. A vision-language-action flow model for general robot control. [arXiv preprint arXiv:2410.24164](#), 2024.
- [2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. [arXiv preprint arXiv:2212.06817](#), 2022.
- [3] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. [arXiv preprint arXiv:2307.15818](#), 2023.
- [4] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. RT-1: Robotics Transformer for Real-World Control at Scale. In *Robotics: Science and Systems XIX*. Robotics: Science and Systems Foundation, July 2023. ISBN 978-0-9923747-9-2. doi: 10.15607/RSS.2023.XIX.025.
- [5] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions, 2025.
- [6] Yossi Gandelsman, Yu Sun, Xinlei Chen, and Alexei A. Efros. Test-time training with masked autoencoders. In *Advances in Neural Information Processing Systems*, 2022.
- [7] Nicklas Hansen, Rishabh Jangir, Yu Sun, Guillem Alenyà, Pieter Abbeel, Alexei A. Efros, Lerrel Pinto, and Xiaolong Wang. Self-supervised policy adaptation during deployment. [arXiv preprint arXiv:2007.04309](#), 2020.
- [8] Chi-Pin Huang, Yueh-Hua Wu, Min-Hung Chen, Yu-Chiang Frank Wang, and Fu-En Yang. Thinkact: Vision-language-action reasoning via reinforced visual latent planning. [arXiv preprint arXiv:2507.16815](#), 2025.
- [9] Physical Intelligence, Bo Ai, Ali Amin, Raichelle Aniceto, Ashwin Balakrishna, Greg Balke, Kevin Black, George Bokinsky, Shihao Cao, Thomas Charbonnier, et al. $\pi_{0.7}$: a steerable generalist robotic foundation model with emergent capabilities. [arXiv preprint arXiv:2604.15483](#), 2026.
- [10] Guanhua Ji, Harsha Polavaram, Lawrence Yunliang Chen, Sandeep Bajamahal, Zehan Ma, Simeon Adebola, Chenfeng Xu, and Ken Goldberg. Oxe-aug: A large-scale robot augmentation of oxe for scaling cross-embodiment policy learning, 2025.
- [11] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. OpenVLA: An Open-Source Vision-Language-Action Model, June 2024.
- [12] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Paul Foster, Pannag R. Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. Openvla: An open-source vision-language-action model. In *Conference on Robot Learning*, volume 270, pages 2679–2713. PMLR, 2024.
- [13] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, and Jinwei Gu. Cosmos policy: Fine-tuning video models for visuomotor control and planning, 2026.
- [14] Jason Lee, Jiafei Duan, Haoquan Fang, Yuquan Deng, Shuo Liu, Boyang Li, Bohan Fang, Jieyu Zhang, Yi Ru Wang, Sangho Lee, Winson Han, Wilbert Pumacay, Angelica Wu, Rose Hendrix, Karen Farley, Eli VanderBilt, Ali Farhadi, Dieter Fox, and Ranjay Krishna. Molmoact: Action reasoning models that can reason in space, 2025.
- [15] Pannag R. Sanketi Li, Hao Wang, Ajay Mandlekar, Sichen M. Yang, Haoran Geng, Yizhou Duan, Ruslan Li, Vincent Vanhoucke, Chelsea Finn, Julian Ibarz, Fei Xia, and Tianhe Yu. Evaluating real-world robot manipulation policies in simulation. In *Proceedings of the 8th Conference on Robot Learning*, 2025.

- [16] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, Xiaofan Wang, Bei Liu, Jianlong Fu, Jianmin Bao, Dong Chen, Yuanchun Shi, Jiaolong Yang, and Baining Guo. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. [arXiv preprint arXiv:2411.19650](#), 2024.
- [17] Shijie Li, Weixian Li, Tianle Zhou, Abul Kalam Azad, Jiankai Liu, Yeyun Gong, Liangming Pan, Chao Li, Zhangyang Wang, Bo An, and Li Dong. Emma-x: An embodied multimodal action model with grounded chain of thought and look-ahead spatial reasoning. [arXiv preprint arXiv:2412.11974](#), 2024.
- [18] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. [arXiv preprint arXiv:2412.14058](#), 2024.
- [19] NVIDIA GEAR Team, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, et al. Gr00t n1: An open foundation model for generalist humanoid robots, 2025.
- [20] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. <https://octo-models.github.io>, 2023.
- [21] Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, et al. Open x-embodiment: Robotic learning datasets and rt-x models. [arXiv preprint arXiv:2310.08864](#), 2023.
- [22] Kaustubh Pathak, Lawrence Yunliang Chen, Yiming Gao, Somil Kent, Long Ma, Anca Dragan, Dorsa Sadigh, and Chelsea Finn. Gr-rl: Going dexterous and precise for long-horizon robotic manipulation, 2025.
- [23] Karl Pertsch, Quan Vuong, Kevin Black, You Liang Tan, Adnan Esmail, Isabel Leal, Homer Walke, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. [arXiv preprint arXiv:2501.09747](#), 2025.
- [24] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Alex Irpan, Julian Jones, Nikhil Joshi, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Sergey Levine, Yao Lu, Corey Lynch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Dorsa Sadigh, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Anikait Singh, Jost Tobias Springenberg, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization, 2025.
- [25] Physical Intelligence, Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. $\pi_{0.6}^*$: a vla that learns from experience, 2025.
- [26] Physical Intelligence, Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. $\pi_{0.7}$: a steerable generalist robotic foundation model with emergent behaviors, 2026.
- [27] Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, JiaYuan Gu, Bin Zhao, Dong Wang, and Xuelong Li. Spatialvla: Exploring spatial representations for visual-language-action model. [arXiv preprint arXiv:2501.15830](#), 2025.
- [28] Lucy Xiaoyang Shi, Zheyuan Hu, Tony Z. Zhao, Archit Sharma, Karl Pertsch, Jianlan Luo, Sergey Levine, and Chelsea Finn. Yell at your robot: Improving on-the-fly from language corrections. In [Robotics: Science and Systems](#), 2024.
- [29] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A. Efros, and Moritz Hardt. Test-time training with self-supervision for generalization under distribution shifts. In [Proceedings of the 37th International Conference on Machine Learning](#), pages 9229–9248, 2020.
- [30] Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn, and Sergey Levine. Bridgedata v2: A dataset for robot learning at scale. In [Conference on Robot Learning \(CoRL\)](#), 2023.
- [31] Chi Wan, Kangrui Wang, Yuan Si, Pingyue Zhang, and Manling Li. Worldagen: Unified state-action prediction with test-time world model training. In [Proceedings of the AAAI Conference on Artificial Intelligence](#), 2026.

- [32] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In International Conference on Learning Representations, 2021.
- [33] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. In Advances in Neural Information Processing Systems, 2024.
- [34] Qin Wang, Olga Fink, Luc Van Gool, and Dengxin Dai. Continual test-time domain adaptation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 7201–7211, 2022.
- [35] Yuqing Wen, Kefan Gu, Haoxuan Liu, Yucheng Zhao, Tiancai Wang, Haoqiang Fan, and Xiaoyan Sun. Rosa: Harnessing robot states for vision-language and action alignment, 2025.
- [36] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, Yuquan Deng, Lars Liden, and Jianfeng Gao. Magma: A foundation model for multimodal ai agents. arXiv preprint arXiv:2502.13130, 2025.
- [37] Shuai Yang, Hao Li, Bin Wang, Yilun Chen, Yang Tian, Tai Wang, Hanqing Wang, Feng Zhao, Yiyi Liao, and Jiangmiao Pang. Instructvla: Vision-language-action instruction tuning from understanding to manipulation. arXiv preprint arXiv:2507.17520, 2025.
- [38] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejun Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent action pretraining from videos, 2025.
- [39] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chunling Zhu, Jiannan Xiang, Ayaan Malik, Kyungmin Lee, William Liang, Nadun Ranawaka, Jiasheng Gu, Yinzheng Xu, Guanzhi Wang, Fengyuan Hu, Avnish Narayan, Johan Bjorck, Jing Wang, Gwanghyun Kim, Dantong Niu, Ruijie Zheng, Yuqi Xie, Jimmy Wu, Qi Wang, Ryan Julian, Danfei Xu, Yilun Du, Yevgen Chebotar, Scott Reed, Jan Kautz, Yuke Zhu, Linxi "Jim" Fan, and Joel Jang. World action models are zero-shot policies, 2026.
- [40] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. arXiv preprint arXiv:2503.22020, 2025.
- [41] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. arXiv preprint arXiv:2412.10345, 2024.

附录

表 5 VLA 部署时改进策略的扩展比较。此附录版本扩展了主表比较，增加了额外的实用考量，包括各策略族的典型优势与局限性。TTT-VLA 属于自监督测试时训练范畴：它仅优化潜在提示，同时保持策略骨干网络冻结。

	Human-Assisted Steering	RL Post-Training	Test-time Training
Intervention interface	Prompts, e.g., task-factorized instruction, metadata, trace	Typically policy itself	Typically parts of the parameters. In this paper, we only use latent prompts.
Improvement signal	Human guidance / external signal	Reward	Self-supervised loss
Policy backbone status	Frozen	Generally updated	Frozen
Typical strength	Simple and controllable at deployment time	Can improve beyond the pre-trained policy through continued interaction	Lightweight self-supervised improvement without updating the backbone
Typical limitation	Depends on human or externally specified guidance and is often bounded by the pre-trained policy	Usually costly, reward-dependent, and optimization-heavy	Depends on the quality of the proxy objective, and gains may remain local or bounded by the adaptation interface
Expected improvement pattern	Mostly steers behavior within the capability envelope of the pretrained policy	Can reshape policy behavior more substantially through optimization	Often corrects deployment-specific mistakes while preserving most pretrained behavior

.1 系统性局限性 无真实世界部署评估。本文尚未在完全真实世界的部署环境中评估 TTT-VLA。这一局限性应在问题设定的背景下理解：与标准的模仿学习评估不同，真实世界的测试时训练需要在适应之前于目标环境中收集全新的交互数据。从这个意义上说，该挑战更接近真实世界的强化学习部署，其中交互成本、系统稳定性和协议设计本身即成为问题的一部分。由于面向 VLA 的测试时训练仍处于早期阶段，许多实用问题仍然悬而未决，包括如何组织数据收集、如何在部署期间控制适应风险，以及如何定义稳定的真实世界评估流程。因此，本文将严格的真实世界 TTT 评估视为一项重要但独立于当前基于模拟器研究的挑战。

代理任务比较有限。在当前研究中，本文仅以状态接地代理任务实例化了潜在提示优化。其他代理任务也可能具有前景，包括未来状态预测、未来图像预测、未来表征预测或逆动力学预测。这些替代方案中的每一种都可能引入不同的优化挑战。例如，未来状态预测可能需要谨慎处理，以避免与主要的动作预测目标混淆。未来图像预测可能是一项具有挑战性的任务，并且需要一个预训练的世界模型作为预测头。未来表征预测需要在 DINO、SigLIP 等编码器中寻找有效的编码器。本文首先专注于为 VLA 建立一个稳定且可观测的 TTT 设置，包括基本的超参数选择、自定义模拟器评估规则以及个性化的部署时优化协议。这一稳定化工作消耗了大量实验时间，因此更广泛的代理任务比较仍有待未来工作。

与先前 TTT 方法无直接比较。本文未提供与先前用于操作策略的 TTT 方法的直接实验比较。对于 VLA 而言，最接近的同期工作是 WorldAgen [31]，

表 6 本文实验中使用的默认测试时训练配置。除非另有说明，TTT-VLA 在部署时提示优化中使用以下设置。

Item	Value
TTT mode	Offline by default; online TTT is only used as an ablation
Interaction buffer	800 / ~ 800 / ~ 2000 for WidowX/GR VM/ GR VA
Trajectory source	Rollouts collected from the pretrained policy
Success / failure composition	Includes both successful and failed rollouts
Optimization target	State grounding loss only
Updated parameters	Latent prompt only
Frozen parameters	Vision-language backbone, action expert, and state expert
TTT steps	500 for WidowX; 1000 for Google Robot
Batch size	128
Learning rate	1×10^{-5}
Wall-clock cost	Approximately 15/30 minutes for WidowX/GR optimization
Checkpoint selection	Fixed optimization horizon for each benchmark; no best-step selection on evaluation performance

表 7 单实施例 WidowX 设置下 TTT 前后的按回合对齐结果比较。我们按回合身份对齐基线和 TTT 后的展开，并比较二元任务结果。结果表明，TTT 并非简单地修复固定的一小部分案例；相反，它在成对展开中产生了净正向转变，既有恢复的失败案例，也有偶尔的退化。

Task	Total	Base Succ.	Post Succ.	Δ	Succ. $\rightarrow$ Fail.	Fail. $\rightarrow$ Succ.	Always Succ.	Always Fail.
Carrot	200	139	149	+10	28	38	111	23
Eggplant	200	141	152	+11	29	40	112	19
Spoon	200	145	142	-3	28	25	117	30
Cube	200	83	96	+13	29	42	54	75
Overall	800	508	539	+31	114	145	394	147

但其代码未公开，且未报告 SimplerEnv 结果，因此难以进行受控比较。早期工作如部署期间的自监督策略适应 (Self-Supervised Policy Adaptation during Deployment) [7] 研究了部署时的自监督适应，但该工作早于现代视觉-语言-动作 (VLA) 模型，因此在模型类别和评估设置上无法直接比较。

在线 TTT 的稳定性。我们观察到，当优化批次较小时，完全在线的提示更新可能不稳定，有时会导致提示崩溃。因此，本文采用离线 TTT 作为主要部署协议。通过近端约束、信赖域目标、提示范数正则化或微批量累积来稳定在线更新，是未来工作的重要方向。

部署成本。TTT-VLA 需要在目标环境中收集交互轨迹，并在评估前执行提示优化。尽管仅更新少量参数且策略主干保持冻结，但交互和优化成本并非为零。因此，我们明确报告轨迹数量、优化步骤和实际时间开销，以便在最终性能增益之外，这一权衡也清晰可见。



图 7 立方体任务中关键决策引导的额外示例。本附录图补充了图 5 的另一个定性案例。在关键放置决策之前，有测试时训练和无测试时训练的轨迹相似。在释放附近，测试时训练减少了向右的过冲，改善了块对齐，并实现了成功堆叠。




图 8 单实施例设置下随机丢弃训练对潜在提示优化的消融。我们比较了原始基线、随机丢弃变体以及无随机丢弃的对应变体在胡萝卜、茄子、勺子、立方体和总体均值上的表现。随机丢弃训练一致地改善了对应变体，尤其是在测试时训练之后。