

VANE: 通过未来视觉表征预测实现可靠的视觉-语言-动作模型测试时训练

Hongjin Ji^{1,5,*} Guoyang Xia^{2,5,*} Luoyang Sun^{3,4,5,*} Fangxiang Feng² Lei Ren^{5,†,‡}

¹The Chinese University of Hong Kong, Shenzhen ²Beijing University of Posts and Telecommunications

³Institute of Automation, Chinese Academy of Sciences

⁴University of Chinese Academy of Sciences

⁵Li Auto Inc.

摘要

测试时训练 (Test-Time Training, TTT) 为从无标签部署流中轻量级适配视觉-语言-动作 (Vision-Language-Action, VLA) 策略提供了一种途径, 但在闭环操作中仍难以可靠使用。共享的适配空间可能混合不兼容的任务修正, 而在线更新可能在后果未知之前就改变后续动作。我们提出了一种面向 VLA 策略的可靠 TTT 框架 (VANE)。VANE 以当前视觉-语言上下文为条件进行提示适配, 并从已执行动作的未来视觉后果中学习。候选更新与在线策略隔离, 在后续观测上评估, 仅当有未来证据支持时才提交, 从而使适配具有选择性和可逆性。在 SimplerEnv WidowX 上, VANE 相较于对应的 TTT 基线平均成功率提高了 3.2 个百分点。在 Google Robot 上的结果进一步表明, 部署时的增益仍依赖于任务和具体机器人形态。这些结果共同展示了一种在交互过程中适配 VLA 策略的受限且基于证据的方法。

1 引言

不断扩展的视觉-语言-动作 (VLA) 模型家族为机器人操作提供了强大的策略骨干 [1–4]。然而, 即使机器人形态固定, 将这些骨干适配到新任务或新视觉环境仍然代价高昂。传统适配通常需要额外的带动作标签的任务特定演示, 随后进行反复微调和超参数选择。随着下游任务数量的增加, 这一过程反复消耗数据和工程精力, 并且往往产生一组分别调优的策略, 而非一个可维护的部署系统。相比之下, 机器人部署自然会产生无标签的视觉观测流。实用的适配机制应当利用这种现成的监督信号, 保留共享的 VLA 骨干, 表示任务相关的修正, 并防止有害更新直接进入闭环控制器。

测试时训练 (Test-time Training, TTT) 通过在未标注的测试观测上优化自监督目标, 同时仅更新一小部分参数子集 [5], 提供了一种有前景的替代方案。TTT-VLA [6] 进一步证明, 潜在提示可以将自监督代理任务与冻结的 VLA 策略连接起来, 从而在部署期间避免全模型微调。这确立了轻量级 VLA TTT 的可行性, 但尚未回答由此产生的更新在异构任务和闭环交互中是否保持可靠。在我们对 QwenPi [4] 的受控研究中, 潜在提示 TTT 在不同任务和视觉条件下产生不一致的结果: 有利于一种设置的更新可能会损害另一种设置, 而未经验证的在线更新可能会降低已部署策略的性能。在本文中, 当候选更新被有选择地引入, 并且由任务干扰或错误的在线优化引起的回归被抑制时, 我们称 TTT 是可靠的。我们确定了实现这一行为所面临的三个设计挑战。

首先, 提示适应强烈依赖于任务。在固定检查点处, 未适应的策略获得 64.1% 的成功率。在所有四个任务上联合优化一个提示会使结果降低到 63.3%, 而独立

* 同等贡献。 † 项目负责人。 ‡ 通讯作者。

邮箱: hongjinji@link.cuhk.edu.cn

适应特定任务的提示达到 66.1%。这一差距表明，单一共享提示纠缠了异构的、有时相互冲突的校正方向。同时，完全独立的提示丢弃了相关任务之间潜在可重用的结构。因此，我们寻求一个适应空间，在保留共享的同时允许当前的视觉-语言上下文组合不同的校正。这促使我们提出上下文路由的潜在提示混合（Mixture of Latent Prompts, MoLP），它从共享的潜在提示库中构建有效提示，而无需外部提供的任务标识符。我们在第 4.1.1 节分析了潜在的任务共享干扰，并在第 4.2.3 节评估了由此产生的提示结构。

其次，仅提示的测试时训练（prompt-only TTT）的有效性关键取决于其代理目标。合适的部署代理应满足两个要求。第一，其目标必须能够在训练和部署期间从普通机器人交互中获取，无需专家动作、奖励、成功标签或特权评估信号。第二，优化该目标应提供与策略相关的适应信号：目标应保留可跨任务和视觉条件泛化的语义结构，同时暴露交互依赖的变化，而非仅仅重建已可见的内容。状态接地满足可用性要求，因为当前机器人状态可直接观测，但其目标维度低、依赖具体本体，并与当前图像同步。因此，可以在不明确解释交互后视觉场景如何演变的情况下对其进行优化。延迟的 RGB 观测同样无需标签，而冻结的视频表示编码器将其转换为语义结构化的未来视觉目标，无需像素级生成。从当前观测、可适应提示和动作上下文中预测此类目标，可产生时间预测性和动作条件化的代理。我们将此监督分支称为世界预测接口（World-Predictive Interface, WPI）。

我们在 QwenPi 上实例化此代理设计，QwenPi 是基于 Qwen 的流匹配视觉语言动作模型（VLA），构建于 StarVLA- α 框架内，而非 TTT-VLA 所使用的原生 $\pi_{0.5}$ 策略。我们保留 QwenPi 的动作策略主干，并将其状态接地代理分支替换为 WPI；所得变体称为 QwenWPI。此处，世界预测表示一种类似世界模型的监督接口，用于预测未来视觉表示。QwenWPI 并非独立的世界模型，也不替代动作策略。状态接地与 WPI 的匹配比较见第 4.2.3 节。

第三，用未来表征预测替代同时刻状态代理改变了在线优化问题本身。在状态锚定的 QwenPi 中，当前步骤即可获得低维代理目标，并能立即形成提示更新。而在 QwenWPI 中，有效的目标只有在延迟观测 o_{t+k} 到达后才可用，且每对样本都需要编码并比较词元级视觉表征。更重要的是，立即部署候选提示会改变生成其后续监督的动作：更新可能改变其之后将被评估的未来观测本身。因此，可靠的预测性测试时训练不仅需要决定何时更新是有信息量的，还需要决定如何在不允许候选提示控制用于验证的轨迹的情况下对其进行评估。

我们通过注意力门控与验证驱动的测试时训练（AGV-TTT）来解决这一难题。跨层注意力重分配提供了一种策略内部信号，用于在交互转换附近提出稀疏更新。更新被应用于潜在提示库的影子副本，而活跃提示继续控制机器人。随着后续观测的到来，旧提示和候选提示在匹配的未来预测对上被评估。只有当聚焦目标改善且没有全局回归时，候选提示及其优化器状态才会被原子地提交；否则，候选提示被丢弃。因此，注意力决定何时提出自适应，而延迟观测决定该提议是否应被部署。激发提议线索的注意力模式在第 4.1.2 节中考察，未来验证的贡献在第 4.2.4 节中单独分析。

这些考虑引出了 VANE，它结合了上下文路由的潜在提示自适应空间、未来预测代理以及选择性提议-验证-提交协议。VANE 这个名字让人联想到风向标，它在保持锚定于稳定结构的同时响应周围环境的变化，反映了我们有选择地使共享策略适应不断变化的部署条件的目标。MoLP 表示任务相关的修正，QwenWPI 提供可观测且与策略相关的自监督，而 AGV-TTT 处理预测性测试时训练的延迟和闭环特性。在部署时，所有策略、路由和预测模块保持冻结；只有潜在提示库有资格进行经过验证的更新。

本文的贡献总结如下：

- 本文在 QwenPi 上系统诊断了潜在提示测试时训练（TTT），表明异构操作任务需要上下文相关的修正。我们提出了一种上下文路由的潜在提示混合模型（MoLP），在紧凑的适应空间内平衡跨任务共享与专业化。
- 我们为部署时代理制定了两项要求——目标可观测性与策略相关性——并将未来视觉表示预测实例化为世界预测接口（World-Predictive Interface）。取代状态接地

QwenPi 的分支结合 WPI 得到 QwenWPI，该方法利用延迟观测作为时间预测性的、无标签的目标，用于仅提示的测试时训练 (TTT)。

• 本文揭示了预测性测试时训练 (TTT) 引入的两大挑战——延迟目标与闭环耦合——并开发了 AGV-TTT 以应对这些挑战。AGV-TTT 将策略内部的注意力转移转换为孤立的影子提议，然后在原子提交或回滚之前，在匹配的未来观测上验证每个候选。




图 1: VANE 概览。(a) MoLP 从共享提示库中组合出上下文相关的潜在提示，无需任务标识符。(b) 上方对比展示了两种部署可观测的代理：状态接地提供即时可用但同时间的目标，而 WPI 利用延迟观测为交互结果提供跨时间、动作条件的监督。下方示意图将 WPI 实例化为仅提示 TTT 的未来视觉表示预测。(c) AGV-TTT 利用跨层注意力重分配提出影子更新，并仅在成对未来验证后提交。

2 相关工作

2.1 视觉语言动作策略与预测接口

通用视觉-语言-动作策略从大规模机器人数据和视觉-语言预训练中学习可迁移的操作技能 [1,2,7–9]。近期策略如 π_0 和 StarVLA- α 通过流匹配 (flow matching) [3,4] 来形式化连续动作块生成。我们的实验使用 QwenPi，一个基于 Qwen 的流匹配 VLA 实例，按照 StarVLA- α 实现，作为受控的动作策略骨干。QwenWPI 保留相同的 VLM 和动作策略模块，仅改变代理接口，从而隔离未来视觉潜变量预测的影响。

预测性表示学习通过建模视觉观测如何演化来提供监督。V-JEPA 2 在潜空间中预测未来视频表示，而预测性 VLA 将未来动态纳入策略预训练或联合动作学习 [10–12]。QwenWPI 则保持视觉目标编码器和策略骨干冻结，并将未来视觉表示作为部署时的目标，用于仅提示的优化。

2.2 大语言模型、视觉语言模型和 VLA 策略的测试时训练

测试时学习始于视觉领域，通过对未标记测试样本进行自监督训练或基于熵的自适应 [5,13–15]。这一思想后来扩展到基础模型：大语言模型可以在推理前对检索到的邻近文本进行训练 [16]，而视觉语言模型可以针对每张图像，利用增强视图间一致且置信的预测来调整提示 [17]。这些研究建立了基于测试输入的无标签自适应，但侧重于静态预测，其中更新不会决定下一个观测。

VLA 增加了闭环挑战：更新会改变后续动作，从而改变可用于进一步自适应的数据。TTT-VLA 联合训练动作预测和状态接地，然后在部署时仅自适应潜提示 [6]。同时， T^3 VF 使用预测-实际未来图像对和动作方差过滤来适应视觉预见策略 [18]，而基于奖励的方法需要显式的测试时奖励信号 [19]。VANE 保留潜提示自适应，但增加了上下文路由、未来潜变量监督以及在闭环部署前对影子更新进行未来验证。

3 方法

3.1 概述

给定 RGB 观测 o_t 和语言指令 ℓ ，QwenPi 策略预测动作块 $A_t \in \mathbb{R}^{16 \times 7}$ ，同时以有效潜提示 p_t ： $A_t = \pi \ominus (o_t, \ell; p_t)$ 为条件。

(1)

图 1 将 VANE 呈现为一个顺序自适应流水线，而非三个独立模块：MoLP 决定自适应什么，WPI 提供自适应信号，AGV-TTT 决定何时提出更新以及是否部署更新。

首先，MoLP 在共享提示库上稀疏路由当前的视觉-语言上下文以形成 p_t ，无需任务标识符。这减轻了跨任务干扰，并将自适应限制在结构化提示空间中。随后，WPI 以 p_t 、当前视觉潜变量和动作标记为条件，预测未来视觉潜变量，并使用后续观测作为无标签目标。与当前状态代理不同，它在没有奖励、专家动作或成功标签的情况下，对动作引起的未来变化进行建模。

AGV-TTT 管理由此产生的在线更新。已部署的提示 P_{old} 持续生效，直到注意力转移触发对影子副本执行一步仅提示更新，生成 P_{cand} ，而 P_{old} 保持在线。后续观测通过匹配的未来对和受控输入评估两个提示。仅当候选提示的聚焦损失改善、全局损失不退化且大多数未来对支持它时，才提交候选提示；否则，更新被回滚。因此，注意力决定何时提出更新，而未来证据决定是否提交。

在机器人数据训练期间，策略、潜提示库和路由器通过以下方式联合学习：

$$\mathcal{L}_{\text{train}} = \mathcal{L}_{\text{act}} + \lambda_{\text{wpi}} \mathcal{L}_{\text{wpi}} + \lambda_{\text{lb}} \mathcal{L}_{\text{lb}}, \quad (2)$$

其中 $\mathcal{L}_{\text{act}}$ 是原始流匹配动作损失， $\mathcal{L}_{\text{wpi}}$ 是未来视觉表示损失， $\mathcal{L}_{\text{lb}}$ 正则化路由利用率。在部署时，除潜提示库外的所有模块均被冻结，从而产生一个受约束、可验证且可逆的自适应过程。为便于参考，方法中使用的符号总结在附录 A 中，实现细节在附录 B 中提供。

3.2 上下文路由的潜提示混合

单一潜提示将异构任务修正强制纳入一个共享参数块，而完全独立的提示则丢弃了有用的跨任务结构。我们改为维护一个全局潜提示库 $\mathcal{P} = \{P_i\}_{i=1}^E$ ，并学习一种稀疏的、上下文相关的组合。设 c_t 为最终投影 VLM 表示的最后一个有效标记，它共同总结了当前图像和指令。线性路由器生成提示选择概率和有效提示：

$$\begin{aligned} q_t &= \text{softmax}(W_r c_t + b_r), \\ \mathcal{S}_t &= \text{TopK}(q_t, K), \\ p_t &= \sum_{i \in \mathcal{S}_t} \frac{q_{t,i}}{\sum_{j \in \mathcal{S}_t} q_{t,j}} P_i. \end{aligned} \quad (3)$$

我们使用一个包含 8 个潜在提示的共享库，并采用前 2 路由。该库不按任务或具身划分，允许相关任务复用提示组件，同时不同的视觉-语言上下文组合出不同的提示混合。路由权重针对每个新的控制观测重新计算，然后在用于生成相应动作块的流匹配迭代过程中保持不变。

路由器与潜在提示库与动作目标和代理目标联合训练，并加入标准的负载均衡损失。在测试时训练期间，路由器被冻结，仅优化潜在提示库 $\mathcal{P}$ 。这定义了一个紧凑的适应空间，其行为以当前视觉-语言上下文为条件，无需外部提供的任务标识符。初始化、负载均衡和优化器细节见附录 B。

3.3 世界预测接口

部署时的代理目标必须在目标可观测性与策略相关性之间取得平衡。状态接地提供了即时可用的当前状态目标，但提供的是同时刻的、具身特定的监督，并且可以在不建模交互结果的情况下进行优化。世界预测接口通过使用后续观测来保持无标签目标的可用性，并要求可适应提示根据当前观测和动作上下文预测其冻结的视觉表示。因此，它用跨时间的、以动作为条件的监督取代了时间上局部的状态监督，同时保留了原始的 QwenPi 动作策略主干。

一个冻结的 V-JEPA 2 编码器 f_ω 提取当前和延迟的未来视觉标记， $Z_t = f_\omega(o_t)$ 和 $Z_{t+k} = f_\omega(o_{t+k})$ 。当前标记、路由提示和加噪动作标记构成潜在动作 DiT 查询。

$$Q_\tau^{(0)} = [p_t \mid E_z(Z_t) \mid E_a(A_\tau, \tau)]. \quad (4)$$

视觉潜在标记和动作标记通过共享自注意力交换信息，因此预测以策略的动作相关上下文为条件，而不仅仅依赖于当前图像。从 Z_t 初始化的槽位直接解码为延迟表示 Z_{t+k} ，并使用以下损失进行训练：

$$\mathcal{L}_{\text{wpi}} = \frac{1}{NC} \left\| \hat{Z}_{t+k} - \text{sg}(Z_{t+k}) \right\|_F^2, \quad (5)$$

其中 N 和 C 分别是视觉标记的数量和宽度。在训练期间，该目标与动作生成联合优化。在部署期间，延迟观测提供目标，无需奖励、成功标签或专家动作，梯度仅应用于潜在提示库。具体的流匹配目标、预测时域和注意力掩码实现细节见附录 B。

3.4 注意力门控与验证驱动的训练时训练

在线测试时训练将每个有效代理对视为同等适合更新。我们的注意力可视化揭示了清晰的时间结构：常规运动占据相对稳定的注意力状态，而接触、抓取闭合和抬升则引起显著的跨层重分布。注意力门控与验证驱动的训练时训练利用这一策略内部转换信号来决定何时值得尝试更新，同时保留未来观测以决定是否部署所尝试的更新。

内生事件检测。实时提示首先在正常策略推理下生成 a_t 。在该前向传播过程中，我们收集 (i) 动作到视觉语言模型的交叉注意力以及 (ii) 动作到预测潜在变量的注意力。对于通道 c 、去噪步骤 u 和扩散变换器层 l ，令 $a_{t,u,l}^c$ 为归一化注意力分布。我们将其时间变化聚合为

$$\Delta_t^c = \frac{1}{|\mathcal{U}||\mathcal{L}|} \sum_{u,l} \frac{1}{2} \|a_{t,u,l}^c - a_{t-1,u,l}^c\|_1. \quad (6)$$

当任一通道相对于其近期稳健基线出现异常时，即触发事件。由于检测发生在 a_t 生成之后，由该事件创建的提议无法追溯影响触发它的动作。稳健归一化和阈值在附录 C 中说明。

注意力聚焦的影子提议。在事件发生时，预测潜在变量注意力选择一组高注意力视觉标记 $\mathcal{K}_t$ 并分配归一化权重 $F_{t,n}$ 。利用逐标记未来预测误差 $e_{t,n}$ ，提议损失为

$$\begin{aligned} \mathcal{L}_{\text{focus},t} &= \sum_{n \in \mathcal{K}_t} F_{t,n} e_{t,n}, \\ \mathcal{P}^{\text{cand}} &= \text{Update}(\mathcal{P}^{\text{old}}; \mathcal{L}_{\text{focus},t}). \end{aligned} \quad (7)$$

所选标记和权重在整个提议验证周期中被分离并冻结。更新在影子副本上执行；实时提示和优化器状态立即恢复，因此候选更新在验证之前无法影响控制。

未来验证与原子化部署。在接下来的 H_v 个有效工作进程信息对中，旧提示与候选提示使用相同的输入、焦点权重和流匹配随机性进行评估。令 R_{focus} 和 R_{global} 分别表示它们在聚焦预测损失和全词元预测损失上的相对改进。仅当 $R_{\text{focus}} > 0$ ， $R_{\text{global}} \geq 0$ 时，候选提示才会被接受。

$$\sum_{j=1}^{H_v} \mathbb{I} \left[R_{\text{focus}}^{(j)} > 0 \right] > \frac{H_v}{2}. \quad (8)$$

因此，一次更新必须改善事件聚焦表示、避免全局回归，并在后续工作进程信息对的时间多数上保持有益。若被接受，完整的提示库及其优化器状态将被原子化提交；否则，两者均被丢弃。前 $H_v - 1$ 个验证帧动作始终使用旧提示，而最终验证在该帧动作生成之前完成。这保持了提案数据、验证证据与部署之间的因果分离。附录 C 给出了配对随机性构造、状态接地自动驾驶车实例以及算法 1 中总结的完整部署流程。

4 分析与实验

我们将证据分为两类。诊断与机制分析小节考察了激发或为 VANE 提供背景的现象——共享提示下的任务依赖迁移、策略内部注意力重分配以及跨评估套件的视觉表示偏移。这些观察结果不被视为方法有效性的直接证明。实验评估小节随后通过基准比较、受控组件比较、验证消融和优化成本测量来评估所得到的设计。

4.1 诊断与机制分析

4.1.1 任务依赖的提示干扰

我们使用状态接地策略的固定检查点重新审视单提示假设。表 1 报告了当提示在不同任务子集上自适应并在所有四个任务上评估时，相对于无测试时训练的成功率变化。任务特定行对每个评估任务使用单独自适应的提示；其他每一行使用在指定子集上联合优化的一个提示。黄色和蓝色单元格分别标记每列中最大的增益和退化。

表 1: 固定检查点下 WidowX 上基于状态的单提示离线测试时训练的任务共享诊断。

Adaptation subset	Stack	Carrot	Spoon	Eggplant	Avg.
<i>One-task adaptation</i>					
Task-specific prompts	+2.5	+3.1	0.0	+2.6	+2.0
<i>Two-task shared prompt</i>					
Carrot + Eggplant	+5.2	+10.4	+1.1	0.0	+4.1
Carrot + Spoon	-1.1	+4.2	+2.1	+1.0	+1.5
Spoon + Eggplant	+4.1	+4.2	-2.1	-1.1	+1.3
Stack + Carrot	-2.1	+1.0	+1.1	+1.0	+0.2
Stack + Eggplant	+4.1	+11.5	-6.2	+1.0	+2.6
Stack + Spoon	+4.1	+8.3	0.0	+3.1	+3.9
<i>Three-task shared prompt</i>					
Carrot + Spoon + Eggplant	-2.1	+16.7	-2.1	+3.1	+4.1
Stack + Carrot + Eggplant	+2.0	+5.2	0.0	+3.1	+2.6
Stack + Carrot + Spoon	+3.1	+2.1	+4.2	+2.1	+2.8
Stack + Spoon + Eggplant	+2.0	-1.1	0.0	+1.0	+0.5
<i>All-task shared prompt</i>					
Stack + Carrot + Spoon + Eggplant	-0.6	+2.1	-5.7	+1.0	-0.8

观察。提示适应在不同任务间的迁移不均衡，且单一的全任务提示可能表现不佳，既不如未适应的提示，也不如任务特定的提示。 为每个评估任务分别适应提示，可将四项任务的平均得分从 64.1% 提升至 66.1%，而在所有四项任务上联合适应一个共享提示则将其降低至 63.3%。中间子集显示出强烈的非均匀迁移：胡萝卜+茄子和胡萝卜+勺子+茄子并列获得最大平均增益 4.1 分，而其他几个子集在提升某些评估任务的同时却降低了其他任务的表现。特别是，全任务适应使勺子的性能降低了 5.7 分。这些结果层面的迁移模式与异构上下文共享一个适应提示时的任务相关干扰一致。这促使我们采用上下文路由的潜在提示库，而 MoLP 本身的有效性将在第 4.2.3 节中单独评估。

4.1.2 交互转换时动作到 VLM 注意力的变化

我们分析动作到 VLM 的交叉注意力，该注意力捕捉了在展开过程中动作查询如何关注 VLM 图像块标记。我们跟踪该注意力分布在 DiT 层间及随时间的变化。在 QwenWPI 中，AGV 在部署期间还监控动作到预测潜在变量的注意力，但该额外通道对于以下诊断并非必需。




图 2: 交互转换附近策略内部的跨层注意力变化。(a) 固定检查点下 Stack Blocks 展开中的 RGB 观测（上行）和代表性的动作查询到 VLM 图像块注意力图（下行）；所有注意力图共享一个回合级别的尺度。(b) 动作到 VLM 注意力分布在所有 36 个 DiT 层上的时间重分配。(c) 相应的层平均注意力变化迹。在接触/闭合及随后的抓取后转换附近出现显著的重分配。

观察。在所示展开中，交互转换与显著的跨层注意力重分配同时发生

重新分配。在图 2 中，面板 (a) 将来自代表性堆叠积木 (Stack Blocks) 推演过程的观测与相应的动作到视觉语言模型 (VLM) 注意力图配对，而面板 (b) 和 (c) 分别展示了逐层的时间重分配及其层平均值。注意力在整个推演过程中不断变化，但在标注的交互转换附近出现了显著的跨层重分配：夹爪与物体的接触和抓取闭合伴随着多个扩散变换器 (DiT) 层的明显变化，随后在抓取之后又发生了一次重组。事件分数衡量的是完整注意力分布的重分配，而非其最大空间响应的语义位置。这一单次推演的可视化仅用于说明，并非定量的事件检测基准；它不能确定检测器的精确率或召回率。因此，我们仅将注意力变化用作无标签的、策略内部的提示，以决定何时考虑影子更新。这种提议是否有益是另一个问题，由第 4.2.4 节中的未来验证消融实验来检验。

4.1.3 评估套件间视觉表征分布偏移

流程。我们利用此分析来比较 WidowX 和 Google Robot 评估套件相对于机器人数据训练参考的视觉表征偏移幅度。我们首先构建一个包含 1,000 帧的参考集，这些帧从 RT-1 [7] 和 Bridge [20] 中等量采样；每个评估套件再贡献 1,000 帧。每一帧都

通过未适应的 QwenPi 策略的固定检查点，并将最后一层 Qwen3-VL 图像标记平均池化为一个 2,560 维的特征向量。

接下来，我们仅在参考集上拟合所有预处理变换，并比较两个特征空间：原始标准化特征（2,560 维），以及一个主成分分析（PCA）空间，其成分保留参考方差的 95%（681 维，记为 PCA-95）。对于每个测试套件，我们计算其特征分布与参考分布之间的有偏径向基函数最大均值差异（RBF-MMD）。MMD 是一种核双样本距离：值越小表示测试特征越接近训练参考。RBF 带宽从参考集内的成对距离中位数中选取，并对两个测试套件保持不变。

最后，本文通过重采样完整片段 500 次并重新计算每个最大均值差异（MMD）值来量化不确定性，而非重采样单个帧。表 2 中的括号表示由此得到的 95% 自助置信区间。在两种特征空间中重复比较，以检验排序并非仅由降维所致。

表 2: 来自 RT-1/Bridge 训练混合数据的视觉表征分布偏移。

Test suite	PCA-95 (681-D)	Raw standardized (2560-D)
WidowX	0.330 [0.326, 0.338]	0.348 [0.343, 0.358]
Google Robot	0.262 [0.259, 0.269]	0.262 [0.260, 0.271]

观察。WidowX 与 RT-1/Bridge 视觉表示参考的距离比 Google Robot 更远

两种评估的特征空间。在这种共同的特征提取和核函数设定下，WidowX 在两个空间中都比 Google Robot 更远离 RT-1/Bridge 参考分布：在 PCA-95 之后为 0.330 对 0.262，在原始标准化空间中为 0.348 对 0.262。我们仅将此排序作为分布背景。MMD 不度量动作语义、具身动力学或闭环难度，也不用于预测测试时训练增益。

4.2 实验评估

4.2.1 实验设置

模型与检查点。所有变体均采用第 3 节介绍的相同 QwenPi 主干网络和机器人数据训练方案。我们在 Bridge [20] 和 RT-1 [7] 上以相等采样概率联合训练，并比较状态接地或 WPI 与单一潜在提示或上下文路由的潜在提示混合（MoLP）的效果。除非诊断明确使用固定检查点，否则结果取连续 50K、60K、70K 和 80K 检查点的平均值；评估成功率从不用检查点选择。

基准与闭环评估。我们在 SimplerEnv [21] 的 WidowX 和 Google Robot 套件上进行评估。WidowX 包括将绿色方块堆叠在黄色方块上、将胡萝卜放在盘子上、将勺子放在桌布上以及将茄子放入篮子中。Google Robot 包括在视觉匹配（VM）和变体聚合（VA）下拾取可乐罐、靠近移动、开关抽屉以及放入抽屉。在每个控制步骤中，重叠的动作块使用基准的自适应时间集成进行组合，并且仅执行结果中的第一个动作，然后进行下一次观察。比较的变体枚举相同的显式初始条件规格，但我们不在方法之间强制使用公共随机数滚动协议。WidowX 总体得分是四个任务的未加权平均值；Google 总体得分直接从报告的任务族-设置得分重新计算。

适应协议与符号。无 TTT 保持训练后的提示不变。离线 TTT 在先前收集的无标签套件缓冲区上调整提示，然后评估固定的调整后提示。在线 TTT 每当有效的自监督对可用时立即部署每个提示更新。AGV-TTT 仅在注意力事件时提出更新，并且仅在经过未来验证后部署候选更新。在比较表中，SG-LP 表示 QwenPi 使用的状态接地单一潜在提示，而 FP-LP 表示 QwenWPI 使用的未来预测单一潜在提示；FP-LP 不包含状态专家。除非另有说明，公开比较表中的 TTT 遵循 TTT-VLA [6] 的离线 TTT 协议。优化设置详见附录 B，门控和验证设置详见附录 C。

4.2.2 与先前策略的比较

表 3: 在 SimplerEnv WidowX 基准上与先前策略的比较。

Method	Carrot	Eggplant	Spoon	Cube	Overall
RT-1-X [8]	4.2	0.0	0.0	0.0	1.1
OpenVLA [2]	0.0	4.1	0.0	0.0	1.0
SpatialVLA [22]	20.8	70.8	20.8	25.0	34.4
Magma [23]	29.2	91.7	37.5	20.8	44.8
Octo-Base [9]	8.3	43.1	12.5	0.0	16.0
Octo-Small [9]	9.7	56.9	47.2	4.2	29.5
RoboVLMs [24]	20.8	79.2	45.8	4.2	37.5
InstructVLA [25]	40.3	94.4	43.1	9.7	46.9
π_0 [3]	36.1	81.9	45.8	26.4	47.6
CogACT [26]	37.5	91.7	58.3	20.8	52.1
ThinkAct [27]	37.5	70.8	58.3	8.7	43.8
TTT-VLA ($\pi_{0.5}$ + SG-LP + TTT) [6]	74.5	76.0	71.0	48.0	67.4
QwenPi + SG-LP + TTT	58.0	95.6	83.9	18.2	63.9
QwenPi + MoLP + AGV-TTT	64.6	97.1	84.9	28.4	68.8
QwenWPI + FP-LP + TTT	63.1	90.2	73.9	44.9	68.0
QwenWPI + MoLP + AGV-TTT	68.8	94.5	77.3	44.3	71.2

WidowX. 表 3 报告了任务级成功率及四项任务未加权平均值。先前策略的数值遵循 TTT-VLA 中的公开比较 [6]；我们的行取四个连续检查点的平均值。在 QwenPi 系列中，将 SG-LP + TTT 替换为 MoLP + AGV-TTT 使总体从 63.9% 提升至 68.8%；在 QwenWPI 中，相应的端到端比较从 68.0% 提升至 71.2%。后者还比已发表的 TTT-VLA 结果 67.4% 高出 3.8 个百分点。这些比较展示了完整 VANE 配置相对于相应 TTT 基线的性能。由于每对比较同时改变了提示结构和更新协议，且跨系统比较还改变了骨干网络和训练数据，我们将组件归因分析推迟到第 4.2.3 节。

表 4: 在三个常见 Google Robot 任务族上与先前策略的比较。

Method	Pick Coke Can		Move Near		Open/Close Drawer		Overall
	VM	VA	VM	VA	VM	VA	
TraceVLA [28]	28.0	60.0	53.7	56.4	57.0	31.0	47.7
RT-1-X [8]	56.7	49.0	31.7	32.3	59.7	29.4	43.1
Octo-Base [9]	17.0	0.0	4.2	3.1	22.7	1.1	8.0
OpenVLA [2]	16.3	54.5	46.2	47.7	35.6	17.7	36.3
RoboVLMs (zero-shot) [24]	72.7	68.3	66.3	56.0	26.8	8.5	49.8
RoboVLMs (fine-tuned) [24]	77.3	75.6	61.7	60.0	43.5	10.6	54.8
Emma-X [29]	2.3	5.3	3.3	7.3	18.3	20.5	9.5
π_0 (fine-tuned) [3]	72.7	75.2	65.3	63.7	38.3	25.6	56.8
π_0 -FAST (fine-tuned) [30]	75.3	77.6	67.5	68.2	42.9	31.3	60.5
GR00T (fine-tuned) [31]	69.3	46.7	68.7	62.9	35.8	17.5	50.1
TTT-VLA ($\pi_{0.5}$ + SG-LP + TTT) [6]	85.0	79.3	71.7	55.2	60.6	45.8	66.3
QwenPi + SG-LP + TTT	87.6	78.7	79.3	66.9	68.2	49.3	71.7
QwenPi + MoLP + AGV-TTT	94.8	85.8	87.5	71.9	65.3	55.1	76.7
QwenWPI + FP-LP + TTT	84.3	82.4	81.6	68.8	64.8	59.8	73.6
QwenWPI + MoLP + AGV-TTT	89.1	83.7	83.3	67.5	55.2	55.4	72.4

Google Robot. TTT-VLA 中的公开比较报告了拾取可乐罐、移近和开关抽屉，但未报告放入抽屉。因此表 4 采用相同的三项任务范围，并取六个 VM/VA 条目的平均值作为总体。在 QwenPi 系列中，完整 VANE 配置将总体从 SG-LP + TTT 的 71.7% 提升至 MoLP + AGV-TTT 的 76.7%。这是端到端比较，而非对任一组件单独增益的估计。在 QwenWPI 中，相应结果从 73.6% 下降至 72.4%，表明未来预测提示在此受限任务聚合上并非一致优越。最强的 VANE 变体，QwenPi + MoLP + AGV-TTT，

比已发表的 TTT-VLA 结果 66.3% 高出 10.4 个百分点，但此跨系统差异并未隔离骨干网络、训练数据或自适应效应。因此我们将 Google 比较视为边界与范围测试，而非跨实施例一致优越性的证据。

表 5: 我们的变体在 Google Robot 上的完整四项任务分解。

Method	Pick Coke Can		Move Near		Open/Close Drawer		Put in Drawer		Overall
	VM	VA	VM	VA	VM	VA	VM	VA	
QwenPi + SG-LP + TTT	87.6	78.7	79.3	66.9	68.2	49.3	72.0	63.4	70.7
QwenPi + MoLP + AGV-TTT	94.8	85.8	87.5	71.9	65.3	55.1	60.2	52.9	71.7
QwenWPI + FP-LP + TTT	84.3	82.4	81.6	68.8	64.8	59.8	19.0	56.0	64.6
QwenWPI + MoLP + AGV-TTT	89.1	83.7	83.3	67.5	55.2	55.4	58.8	70.4	70.4

完整四项任务分解。表 5 增加了“放入抽屉”任务，并对所有八个 VM/VA 任务设置条目取平均。在 QwenPi 中，相对于 SG-LP + TTT，MoLP + AGV-TTT 将总体从 70.7% 提升至 71.7%。在 QwenWPI 中，加入“放入抽屉”后，完整的 VANE 配置从 64.6% 显著提升至 70.4%。两个 QwenWPI 行之间最大的任务族差异出现在“放入抽屉”上，其中 VM/VA 从 19.0%/56.0% 增加到 58.8%/70.4%。结合受限的三任务结果，这表明 MoLP 和 AGV-TTT 的端到端收益取决于任务组成。由于在该比较中 WPI 保持不变，结果并未将组成效应归因于预测代理。因此，我们将 Google Robot 视为范围测试，而非证明某一种代理或适应协议在所有任务族中均占优的证据。

4.2.3 VANE 组件的受控评估

表 6: 在 WidowX 上四个检查点的受控比较。

Proxy	Prompt	No TTT	Offline	Online	AGV
State	Single	64.3	63.9	64.7	65.9
State	MoLP	67.5	68.1	67.8	68.8
WPI	Single	67.5	68.0	67.5	69.0
WPI	MoLP	70.7	69.4	70.3	71.2

WidowX。表 6 提供了用于组件归因的因子比较。最强值为 WPI – MoLP 配合 AGV-TTT 时的 71.2%，但重要证据是每次仅沿一个因子进行的匹配比较，总结如下。

表 7: 在四任务 Google Robot 套件上的受控比较。

Proxy	Prompt	No TTT	Offline	Online	AGV
State	Single	73.6	70.7	74.0	74.0
State	MoLP	72.3	71.7	71.6	71.7
WPI	Single	64.2	64.6	64.7	65.3
WPI	MoLP	70.1	70.2	70.5	70.4

Google Robot。表 7 在完整的 Google 套件上提供了相同的因子比较，其中组件排名发生变化，收益也较不均匀。特别是，最强配置仍然是状态接地的单提示策略，而两个 WPI 行相对于无 TTT 获得了正向但较小的 AGV 增益。因此，受控组件收益在 WidowX 上比在 Google Robot 上更为一致。这些结果应与第 4.1.3 节中的描述性表示偏移分析一同解读，而非由其解释。

提示结构。在 WidowX 上，当代理和适应协议保持不变时，MoLP 改善了每一个匹配的单提示配置。对于状态接地，在无 TTT、离线、在线和 AGV 下，增益范围从 +2.9 到 +4.2 点；对于 WPI，相应增益范围从 +1.4 到 +3.2 点。无 TTT 的正向比较表明，路由提示结构在部署时优化之前已经改变了训练策略，而

其余列显示，在评估的 TTT 协议下，该优势持续存在。谷歌机器人（Google Robot）的表现则不那么一致：MoLP 持续改善 WPI 变体，但未改善状态锚定变体。结合第 4.1.1 节中的诊断性任务共享分析，这些比较将路由提示的动机与其实际效果区分开来。

预测性代理。在 WidowX 上，WPI 在所有八个匹配的提示-协议比较中均超过状态锚定。无 TTT 的差距在 Single 和 MoLP 上已经达到 +3.2 分，表明绝对 WPI 优势的相当一部分在部署时优化之前就已存在。在离线、在线和 AGV 下，相应的绝对差距保持在 1.3 - 4.1 分。因此，这些比较支持 WPI 作为 WidowX 上更强的代理条件策略接口，但它们本身并不能证明 WPI 增加了 TTT 的增量收益：相对于各自无 TTT 基线的改进仍然依赖于协议。在谷歌机器人上，WPI 在八个匹配比较中均未超过状态锚定，进一步将代理声明限制在所评估的任务和实体分布范围内。

部署协议。在 WidowX 上，AGV-TTT 是每个代理-提示行中评估的最佳协议，也是唯一一个在所有四行上均优于其对应无 TTT 基线的协议。相对于无 TTT，State - Single、State - MoLP、WPI - Single 和 WPI - MoLP 的增益分别为 +1.6, +1.3, +1.5 和 +0.5 分；相对于密集在线 TTT，AGV 将相同的四行分别提高了 +1.2, +1.0, +1.5 和 +0.9 分。在谷歌机器人上，顺序并不一致：AGV 相对于无 TTT 改善了两个 WPI 行，略微改善了 State - Single，但降低了 State - MoLP。这促使在第 4.2.4 节中将验证步骤与事件触发稀疏性分离。

4.2.4 未来验证是否必要？

表 8：单提示 QwenWPI 上事件触发与未来验证的消融。

Online protocol	Event gate	Future validation	Success
Online TTT	–	–	67.5
Event + Accept-All	✓	–	67.3
AGV-TTT	✓	✓	69.0

结果。为了将未来验证与事件触发分离，全盘接受策略（Accept-All）保留了与 AGV-TTT 相同的注意力检测器和影子提议，但对每个已完成的候选对象直接提交，而不在后续观测中对其进行评估。如表 8 所示，事件+全盘接受策略达到 67.3%，略低于在线 TTT 的 67.5%。未来验证将成功率提升至较“全盘接受”高出 69.0%，a 1.7 个点。因此，仅靠事件触发的稀疏性无法解释这一增益。1.7 个点的差距隔离出了在同一事件门控提案流程中未来验证的可量化收益，这与在部署前通过验证过滤不利候选方案的做法一致。

4.2.5 优化效率

表 9：单提示 QwenWPI 的每个检查点优化与验证成本，在四个检查点上取平均。

Protocol	Backward	Validation forward	Success
Online TTT	45,824	–	67.5
AGV-TTT	612	4,831	69.0

结果。在线 TTT 在有效的 WPI 对可用时执行反向更新，而 AGV-TTT 仅在注意力事件时提出影子更新。对于相同的单提示 QwenWPI 策略在四个检查点上，表 9 显示 AGV-TTT 平均每个检查点评估执行 612 次候选反向传播，而在线 TTT 为 45,824 次。它仅在 1.3% 的合格帧上触发反向优化，并将反向调用减少了 98.7%（约 75×），同时将平均成功率从 67.5% 提高到 69.0%。

AGV-TTT 还执行 4,831 次仅前向的代理评估以进行未来验证。只有 19.4% 的提案被接受，因此大多数影子提案从未进入部署策略。这种选择性在功能上很重要：事件+接受全部获得 67.3%，而经过验证的 AGV-TTT 达到 69.0%。因此，增益来自事件触发的提案以及随后的验证，而不仅仅是降低更新频率。我们报告优化次数，而不是将其转换为缺乏依据的墙钟加速比。

5 结论

我们提出了 VANE，一个用于视觉语言动作模型的测试时训练框架，它结合了上下文路由的专家混合低秩适配、未来视觉表示预测以及注意力门控、验证驱动的更新。注意力重分配识别信息丰富的交互转换以提出影子更新，而后续观测决定每个候选是被提交还是回滚。

在更简单的环境（SimplerEnv）WidowX 上，学习到的 WPI – MoLP 接口将未适配策略从 64.3% 提升至 70.7%，而 AGV-TTT 进一步将成功率提高到 71.2%。AGV-TTT 是唯一在所有四种代理 – 提示配置下均能改善检查点平均性能的评估协议。在单提示 QwenWPI 效率研究中，与在线 TTT 相比，它将反向更新减少了 98.7%。谷歌机器人（Google Robot）的结果进一步表明，适配增益仍取决于任务和具体形态，同时视觉表征偏移存在可测量的差异。这些发现支持在 WidowX 上采用上下文路由、时间预测的适配接口，并为在线更新引入显式的提议 – 验证机制，而谷歌的结果则限定了这些增益的普适性。

参考文献

- [1] A. Brohan *et al.*, “RT-2: Vision-language-action models transfer web knowledge to robotic control,” *arXiv preprint arXiv:2307.15818*, 2023.
- [2] M. J. Kim *et al.*, “OpenVLA: An open-source vision-language-action model,” *arXiv preprint arXiv:2406.09246*, 2024.
- [3] K. Black *et al.*, “ π_0 : A vision-language-action flow model for general robot control,” *arXiv preprint arXiv:2410.24164*, 2024.
- [4] J. Ye, N. Gao, S. Yang, J. Zheng, Z. Wang, Y. Chen, P. Chen, Y. Chen, S. Liu, and J. Jia, “StarVLA- α : Reducing complexity in vision-language-action systems,” *arXiv preprint arXiv:2604.11757*, 2026.
- [5] Y. Sun, X. Wang, Z. Liu, J. Miller, A. A. Efros, and M. Hardt, “Test-time training with self-supervision for generalization under distribution shifts,” in *Proceedings of the 37th International Conference on Machine Learning*, 2020, pp. 9229–9248.
- [6] W. Zhang, J. Li, S. Yang, S. Chen, J. Liu, L. Liu, and X. Ma, “TTT-VLA: Test-time latent prompt optimization for vision-language-action models,” *arXiv preprint arXiv:2606.03127*, 2026.
- [7] A. Brohan *et al.*, “RT-1: Robotics transformer for real-world control at scale,” *arXiv preprint arXiv:2212.06817*, 2022.
- [8] Open X-Embodiment Collaboration, A. O’Neill *et al.*, “Open X-Embodiment: Robotic learning datasets and RT-X models,” *arXiv preprint arXiv:2310.08864*, 2023.
- [9] Octo Model Team, D. Ghosh *et al.*, “Octo: An open-source generalist robot policy,” *arXiv preprint arXiv:2405.12213*, 2024.
- [10] M. Assran *et al.*, “V-JEPA 2: Self-supervised video models enable understanding, prediction and planning,” *arXiv preprint arXiv:2506.09985*, 2025.
- [11] X. Xu, H. Li, J. Ye, Y. Chen, J. Zeng, X. Chen, L. Xu, D. Lin, W. Li, and J. Pang, “FutureVLA: Joint visuomotor prediction for vision-language-action model,” *arXiv preprint arXiv:2603.10712*, 2026.
- [12] L. Li, Q. Zhang, Y. Luo, S. Yang, R. Wang, F. Han, M. Yu, Z. Gao, N. Xue, X. Zhu, Y. Shen, and Y. Xu, “Causal world modeling for robot control,” *arXiv preprint arXiv:2601.21998*, 2026.
- [13] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell, “Tent: Fully test-time adaptation by entropy minimization,” *arXiv preprint arXiv:2006.10726*, 2020.
- [14] Q. Wang, O. Fink, L. Van Gool, and D. Dai, “Continual test-time domain adaptation,” *arXiv preprint arXiv:2203.13591*, 2022.
- [15] S. Niu, J. Wu, Y. Zhang, Y. Chen, S. Zheng, P. Zhao, and M. Tan, “Efficient test-time model adaptation without forgetting,” *arXiv preprint arXiv:2204.02610*, 2022.
- [16] M. Hardt and Y. Sun, “Test-time training on nearest neighbors for large language models,” in *International Conference on Learning Representations*, 2024.
- [17] M. Shu, W. Nie, D.-A. Huang, Z. Yu, T. Goldstein, A. Anandkumar, and C. Xiao, “Test-time prompt tuning for zero-shot generalization in vision-language models,” in *Advances in Neural Information Processing Systems*, 2022.

- [18] S. Park, W. Kim, Y. In, S. Kim, H. Kang, and C. Park, “Test-time training for visual foresight vision-language-action models,” *arXiv preprint arXiv:2605.08215*, 2026.
- [19] C. Liu, Y. Liu, T. Wang, Q. Zhuang, J. C. Liang, W. Yang, R. Xu, Q. Wang, D. Liu, and C. Han, “On-the-fly VLA adaptation via test-time reinforcement learning,” *arXiv preprint arXiv:2601.06748*, 2026.
- [20] H. Walke, K. Black, A. Lee, M. J. Kim, M. Du, C. Zheng, T. Zhao, P. Hansen-Estruch, Q. Vuong, A. He, V. Myers, K. Fang, C. Finn, and S. Levine, “BridgeData V2: A dataset for robot learning at scale,” *arXiv preprint arXiv:2308.12952*, 2023.
- [21] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, S. Levine, J. Wu, C. Finn, H. Su, Q. Vuong, and T. Xiao, “Evaluating real-world robot manipulation policies in simulation,” *arXiv preprint arXiv:2405.05941*, 2024.
- [22] D. Qu, H. Song, Q. Chen, Y. Yao, X. Ye, Y. Ding, Z. Wang, J. Gu, B. Zhao, D. Wang, and X. Li, “SpatialVLA: Exploring spatial representations for vision-language-action model,” *arXiv preprint arXiv:2501.15830*, 2025.
- [23] J. Yang, R. Tan, Q. Wu, R. Zheng, B. Peng, Y. Liang, Y. Gu, M. Cai, S. Ye, J. Jang, Y. Deng, and J. Gao, “Magma: A foundation model for multimodal AI agents,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025, pp. 14 203–14 214.
- [24] X. Li, P. Li, M. Liu, D. Wang, J. Liu, B. Kang, X. Ma, T. Kong, H. Zhang, and H. Liu, “Towards generalist robot policies: What matters in building vision-language-action models,” *arXiv preprint arXiv:2412.14058*, 2024.
- [25] S. Yang, H. Li, B. Wang, Y. Chen, Y. Tian, T. Wang, H. Wang, F. Zhao, Y. Liao, and J. Pang, “InstructVLA: Vision-language-action instruction tuning from understanding to manipulation,” *arXiv preprint arXiv:2507.17520*, 2025.
- [26] Q. Li, Y. Liang, Z. Wang, L. Luo, X. Chen, M. Liao, F. Wei, Y. Deng, S. Xu, Y. Zhang, X. Wang, B. Liu, J. Fu, J. Bao, D. Chen, Y. Shi, J. Yang, and B. Guo, “CogACT: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation,” *arXiv preprint arXiv:2411.19650*, 2024.
- [27] C.-P. Huang, Y.-H. Wu, M.-H. Chen, Y.-C. F. Wang, and F.-E. Yang, “ThinkAct: Vision-language-action reasoning via reinforced visual latent planning,” in *Advances in Neural Information Processing Systems*, 2025.
- [28] R. Zheng, Y. Liang, S. Huang, J. Gao, H. Daumé III, A. Kolobov, F. Huang, and J. Yang, “TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies,” in *International Conference on Learning Representations*, 2025.
- [29] Q. Sun, P. Hong, T. D. Pala, V. Toh, U.-X. Tan, D. Ghosal, and S. Poria, “Emma-X: An embodied multimodal action model with grounded chain of thought and look-ahead spatial reasoning,” *arXiv preprint arXiv:2412.11974*, 2024.
- [30] K. Pertsch, K. Stachowicz, B. Ichter, D. Driess, S. Nair, Q. Vuong, O. Mees, C. Finn, and S. Levine, “FAST: Efficient action tokenization for vision-language-action models,” in *Proceedings of Robotics: Science and Systems*, 2025.
- [31] NVIDIA, J. Bjorck, F. Castaneda, N. Cherniadev, X. Da, R. Ding, L. Fan, Y. Fang, D. Fox *et al.*, “GR00T N1: An open foundation model for generalist humanoid robots,” *arXiv preprint arXiv:2503.14734*, 2025.

附录

A. 符号说明

该表总结了方法和部署过程中重复使用的符号；仅在单个推导中出现的量在其引入处定义。

Symbol	Definition
o_t, ℓ	RGB observation and language instruction at control step t .
$\hat{A}_t, a_t$	Policy-predicted action chunk and executed action at control step t .
Θ	Policy parameters, frozen during deployment-time adaptation.
$\mathcal{P}, P_i, p_t$	Latent-prompt bank, prompt component i , and effective routed prompt.
$c_t, q_t, \mathcal{S}_t$	Router context, prompt-selection probabilities, and selected set.
E, K	Number of banked latent prompts and selected prompts.
f_ω, Z_t, Z_{t+k}	Frozen visual encoder and its present and delayed future visual tokens.
$\mathcal{L}_{\text{act}}, \mathcal{L}_{\text{wpi}}, \mathcal{L}_{\text{lb}}$	Action, future-prediction, and router load-balancing losses.
$a_{t,u,l}^c, \Delta_t^c$	Channel- c attention at step t , flow step u , and layer l , and its aggregated temporal change.
$\mathcal{K}_t, F_{t,n}, e_{t,n}$	Focused token set, normalized weight, and token-wise prediction error.
$\mathcal{L}_{\text{focus}}$	Attention-weighted prediction loss over focused tokens.
$\mathcal{P}^{\text{old}}, \mathcal{P}^{\text{cand}}$	Live and shadow candidate prompt banks.
H_v, R_x	Validation horizon and relative improvement for loss x .

B. 训练与架构细节

流匹配动作目标。对于干净的动作块 $A_1 \in \mathbb{R}^{16 \times 7}$ ，我们采样 $A_0 \sim \mathcal{N}(0, I)$ 和 $u \sim \text{Beta}(1.5, 1.0)$ ，然后设置

$$\tau = \frac{\eta - u}{\eta}, \quad \eta = 0.999, \quad A_\tau = (1 - \tau)A_0 + \tau A_1. \quad (9)$$

设 H_a 和 d_a 分别表示动作块时域和每步动作维度。动作分支输出 $\hat{v} \ominus$ 预测恒定目标速度 $A_1 - A_0$ ：

$$\mathcal{L}_{\text{act}} = \mathbb{E} \left[\frac{1}{H_a d_a} \|\hat{v}_\Theta(A_\tau, \tau) - (A_1 - A_0)\|_F^2 \right]. \quad (10)$$

所有动作步和维度均被同等加权。重复的噪声时间样本提供了同一目标的蒙特卡洛估计。

路由器正则化与初始化。对于一批样本，设 f_i 为路由到潜在提示 i 的比例及其平均路由器概率。本文使用 $\bar{q}_i$

$$\mathcal{L}_{\text{lb}} = E \sum_{i=1}^E f_i \bar{q}_i, \quad \mathcal{L}_{\text{train}} = \mathcal{L}_{\text{act}} + 0.1 \mathcal{L}_{\text{wpi}} + 0.01 \mathcal{L}_{\text{lb}}. \quad (11)$$

潜在提示库的形状为 $[8, 16, 1024]$ ；其八个提示分量独立地从初始化。线性路由器使用 PyTorch 默认初始化，且单阶段模型不从先前的提示或路由器检查点恢复。

潜在动作 DiT 可见性。WPI 查询的顺序为 [提示 | 当前视觉潜在 | 动作]，当前潜在与动作标记之间存在双向交互。遵循 TTT-VLA[6] 的潜在提示可见性策略，在提示学习期间屏蔽动作查询到提示键的直接连接，并在策略推理和仅提示 TTT 期间恢复。这种继承的设计防止动作分支在训练期间过早依赖潜在提示，同时允许自适应提示在部署时调节冻结的动作分支。QwenWPI 通过引入预测性视觉潜在在标记改变了代理接口，但不改变这种提示到动作的可见性策略。提示/视觉和动作标记使用独立的前馈分支，同时共享注意力。V-JEPA 2 保持冻结，未来偏移为 $k = 8$ ，WPI 损失对所有视觉标记和通道取普通平方误差的平均值。

仅提示优化。在测试时，完整的 $[8, 16, 1024]$ 提示库被注册为一个 AdamW 参数，而路由器和策略保持冻结。当前代理梯度在选中的提示切片中是稀疏的，但衰减和历史矩为完整的提示库维护。因此，AGV 对完整的提示库和优化器状态进行快照、提交和回滚。

测试时优化设置。离线 TTT 在 WidowX 上执行套件范围的仅提示 AdamW 优化，学习率为 10^{-5} ，批大小为 64，共 500 步；在 Google Robot 上为 1000 步，之后在评估期间固定适应后的提示。稠密在线 TTT 使用批大小为 1，每当有效的 WPI 对到达时，以学习率 10^{-7} 执行一步 AdamW。每个 AGV 提议包含一步影子 AdamW，学习率为 10^{-7} ， $\beta = (0.9, 0.999)$ ，权重衰减为 0.01；候选提示和优化器状态仅在通过未来验证后才提交。这些设置仅更新潜在提示；路由器和策略骨干保持冻结。

C. AGV-TTT 实现细节

鲁棒事件门控。公式 (6) 中的变化分数相对于滚动历史 $\mathcal{H}_t^c$ 进行归一化：

$$r_t^c = \frac{\Delta_t^c - \text{median}(\mathcal{H}_t^c)}{\max(1.4826 \text{MAD}(\mathcal{H}_t^c), \epsilon)}. \quad (12)$$

这里 MAD 表示中位数绝对偏差， $\epsilon > 0$ 是数值稳定性常数。事件需要在任一通道中同时满足绝对阈值和鲁棒阈值。预热、冷却和单一待处理候选保护抑制启动噪声和重叠提议。

聚焦令牌构建。预测性潜在注意力按层和流步骤进行归一化，然后在选定的后期 DiT 层上进行聚合。设 S 表示选定的流步骤-层对， $a_{t,u,l,n}^{\text{jepa}}$ 为视觉标记 n 在 N 个视觉标记中的预测性潜在注意力权重：

$$A_n = \frac{1}{|S|} \sum_{(u,l) \in S} \frac{a_{t,u,l,n}^{\text{jepa}}}{\sum_{j=1}^N a_{t,u,l,j}^{\text{jepa}}}, \quad (13)$$

$$F_n = \frac{A_n}{\sum_{j \in \mathcal{K}_t} A_j}, \quad n \in \mathcal{K}_t.$$

这里 A_n 是聚合的事件帧注意力， F_n 是其在 $\mathcal{K}_t$ 上的归一化权重，对应于正文中的 $F_{t,n}$ 。主要实验使用前 32 个标记。单提示 WPI 和 WPI + MoLP 分别聚合最后四层和八层。索引和权重由实时事件帧注意力创建，分离后用于提案训练和所有验证对。

成对未来验证。对于每个验证对，旧提示和候选提示接收相同的当前和未来潜在变量、焦点权重、高斯动作噪声和流时间。CPU 和 CUDA 随机状态在每个分支前重置，并在之后恢复。由于没有专家动作可用，两个分支使用相同的零动作锚点；仅比较未来潜在预测误差。对于 $x \in \{\text{焦点}, \text{全局}\}$ ，

$$R_x = \frac{\bar{\mathcal{L}}_x^{\text{old}} - \bar{\mathcal{L}}_x^{\text{cand}}}{\max(|\bar{\mathcal{L}}_x^{\text{old}}|, \epsilon)}. \quad (14)$$

上划线表示所收集验证对的均值，分母中使用相同的数值稳定性常数 ϵ 。WPI 设置使用 $H_v = 4$ 、焦点权重 $\lambda_f = 1$ 、零改进裕度和零全局退化容差。提交前应用有限损失、参数和步骤检查。无法在一个回合内完成验证的候选将被丢弃。

Algorithm 1: WPI-AGV-TTT at deployment time

```

1: Initialize live prompt/optimizer  $(\mathcal{P}, m)$  and no candidate
2: for each control step  $t$  do
3:   if a candidate is pending and a new WPI pair is available then
4:     Evaluate old and candidate with paired randomness
5:     if  $H_v$  validation pairs have been collected then
6:       Commit iff Eq. (8) holds; otherwise retain live state
7:       Clear the candidate
8:     end if
9:   end if
10:  Generate  $a_t$  with the live prompt and capture attention
11:  if an event is detected and no candidate is pending then
12:    Freeze the attention-derived focus specification
13:    Take one shadow AdamW step on  $\mathcal{L}_{\text{focus}}$ 
14:    Restore live state and mark the candidate as pending
15:  end if
16:  Execute the already generated action  $a_t$ 
17: end for

```

状态接地 AGV。对于状态接地基线，AGV 仅使用动作到 VLM 的注意力、状态接地代理和三对多数验证。其接受裕度为 10^{-6} ，而 WPI 使用零。该变体测试提案-验证-提交抽象是否可迁移到另一个代理；完整的 VANE 方法是双注意力 WPI 实例。