

VLA-ATTTC: 面向 VLA 模型的自适应测试时计算与相对动作批评模型

Wenhao Li¹ Xiu Su² Yichao Cao² Hongyan Xu² Xiaobo Xia³ Shan You⁴ Yi Chen⁵ Chang Xu¹

摘要

视觉-语言-动作 (VLA) 模型在具身操作中展现出卓越的能力与泛化性。然而，其决策依赖快速、本能的过程，缺乏深思熟虑。面对需要更多考量的复杂或模糊场景时，这种策略往往导致次优甚至灾难性的动作。本文提出 **VLA-ATTTC** 框架，赋予 VLA 模型自适应测试时计算 (TTC) 能力。**VLA-ATTTC** 采用基于不确定性的“认知离合器”，在必要时从反射式执行动态切换至 TTC 深思阶段。在 TTC 阶段，新颖的相对动作评价 (RAC) 模型通过成对比较从生成的候选中识别最优动作。这种相对机制取代了不稳定的绝对值估计，显著简化了学习目标。此外，本文引入高效采样策略以分摊计算成本，并构建自动化数据流水线，无需人工标注即可整理偏好对。在 LIBERO-LONG 基准上，**VLA-ATTTC** 将最先进模型 PI0.5 的失败率降低超过 50%。

1 引言

VLA 模型 (Team 等, 2024; Black 等, 2024; Kim 等, 2024; Shukor 等, 2025; Kim 等, 2025; Li 等, 2024; Xu 等, 2025c; b; Yang 等, 2026; Li 等, 2026a; b) 的出现标志着具身智能 (Embodied AI) 的重要里程碑 (Liu 等, 2025; Paolo 等, 2024; Memarian 和 Doleck, 2024; Duan 等, 2022; Fung 等, 2025; Feng 等, 2025; Li 等, 2025c; d; Chen 等, 2026; Li 等, 1 悉尼大学 2 中南大学 3 中国科学技术大学 4 商汤科技研究院 5 香港科技大学。通讯作者: 苏修, 徐畅 <xiusu1994@csu.edu.cn, c.xu@sydney.edu.au>。

Proceedings of the 43rd International Conference on Machine Learning, Seoul, South Korea. PMLR 306, 2026. Copyright 2026 by the author(s).




图 1. 性能概览与效率比较。

2021; 2023; Tan 等, 2025)。通过利用预训练骨干网络中嵌入的丰富世界知识 (Wang 等, 2025a; Zeng 等, 2026; Li 等, 2025b)，这些模型在多样化的复杂操作任务中展现出令人印象深刻的泛化能力。然而，它们的决策由快速、直觉式的推理过程主导 (Xu 等, 2025a)。这种快速、直觉式的策略对于简单场景足够，但在面对需要更深思熟虑的复杂或模糊情境时，往往导致次优甚至灾难性的失败。这种能力差距引出一个根本性问题：如何赋予视觉-语言-动作模型强大的深思熟虑过程，使其从快速、直觉式的系统 1 推理进化为更审慎的系统 2 推理？从概念上讲，深思熟虑可分为顺序范式和并行范式 (Muennighoff 等, 2025; Zhang 等, 2025; Li 等, 2025a; Huang 等, 2025; Zeng 等, 2025)。顺序方法 (Miao 等, 2024; Wang 等, 2025c)，如思维链 (Chain-of-Thought, CoT) (Wang 和 Zhou, 2024; Xia 等, 2024; Chen 等, 2025; Yeo 等, 2025)，已在视觉-语言-动作模型中得到一些探索 (Zhao 等, 2025; Liu 等, 2024; Black 等, 2025; Zhou 等, 2025b; a; Song 等, 2025; Lin 等, 2025)。然而，这些方法带来显著开销，需要昂贵的微调、费力的思维链数据标注，并且常常因迫使以动作为中心的模型生成文本推理而降低动作性能。相比之下，并行深思熟虑策略 (Sessa 等, 2024; Zhang 等, 2024; Wang 等, 2025d; 2024b; a) ——模型生成一组候选方案并深思熟虑以选择价值最高的一个——更符合具身决策的本质。

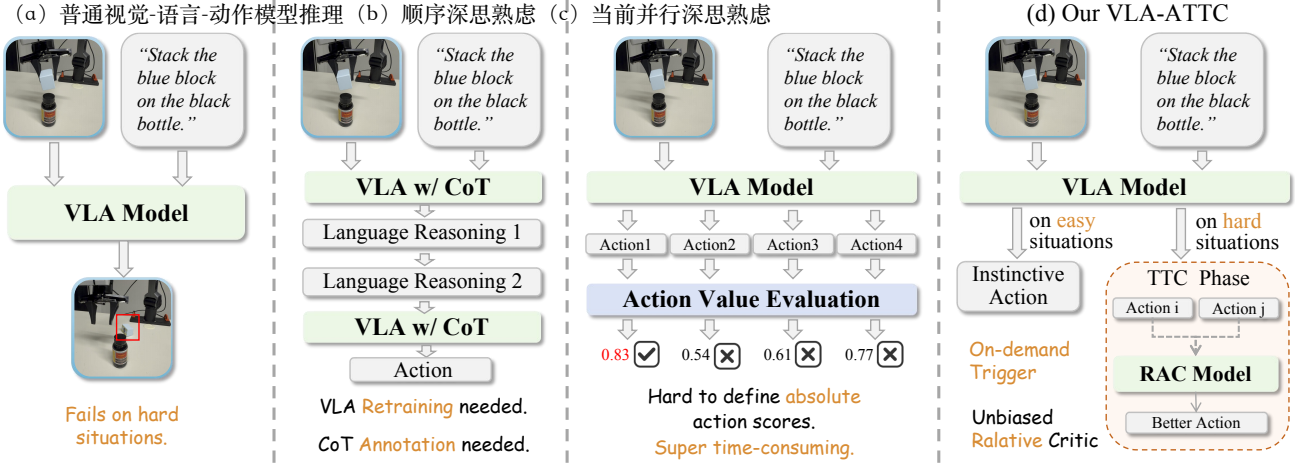


图 2. 视觉-语言-动作模型推理范式比较。(a) 标准推理速度快,但在复杂场景中容易失败。(b) 顺序深思熟虑需要昂贵的重新训练和数据标注。(c) 现有并行深思熟虑成本高,且依赖不稳定的绝对评分。(d) 视觉-语言-动作模型自适应触发深思熟虑仅在困难情境下触发,采用相对优势比较模型进行稳健的候选选择。

然而,其在视觉-语言-动作模型中的探索仍处于起步阶段。一些研究尝试 (Kwok 等, 2025; Nakamoto 等, 2024) 采用大规模外部评论家模型从大量候选中选择最佳动作,而另一些研究 (Guo 等, 2025) 则利用世界模型以类似蒙特卡洛树搜索的模式引导探索。尽管这些方法具有开创性,但它们对所有场景不加区分地应用深思熟虑,且其深思熟虑过程成本高昂,使其难以在实际应用中落地。这凸显了面向视觉-语言-动作模型的实用并行深思熟虑方法必须应对三个关键挑战:一是量化情境难度以实现自适应深思熟虑;二是最小化多动作采样的计算开销;三是设计轻量级且高保真的动作评论家模型。为应对这些挑战,本文提出 VLA-ATTC,一个在不修改基础模型的前提下为视觉-语言-动作模型赋予自适应测试时深思熟虑能力的框架。VLA-ATTC 引入了一个“认知离合器”,用于监测基础视觉-语言-动作模型生成过程中的不确定性,仅在必要时触发测试时计算深思熟虑阶段。在测试时计算阶段,我们通过一种高效的并行策略来摊销视觉-语言计算,从而降低候选采样成本。为解决评估瓶颈,本文提出一种轻量级且高精度的相对评论家模型。该模型从预测绝对分数转变为进行相对比较——即询问“动作 A 是否优于动作 B?”——大幅降低了训练难度和评估模型所需的容量。最后,为确保可扩展性,本文引入一条自动化流程,从现有操作数据集中筛选高质量偏好对,从而消除人工标注的需求。综上所述,本文的贡献如下:

- 本文提出 VLA-ATTC,一个即插即用的框架,使视觉-语言-动作模型能够在不确定场景中自适应地触发高效的测试时深思熟虑阶段。

ios, requiring no fine-tuning of the base model.

- 本文设计了一种轻量级且稳健的相对动作评论家模型,通过迭代成对比较识别最优动作,克服了先前并行深思熟虑方法在准确率和效率方面的瓶颈。
- 本文开发了一条全自动数据流程,直接从现有数据集中筛选高质量偏好对,避免了繁重的人工数据收集。
- 大量实验表明, VLA-ATTC 将 LIBERO-LONG 的最先失败率降低了 50% 以上,并将真实世界成功率提升了 17.3%,同时保持了实用的 20.8 Hz 控制频率。

利益冲突披露: 无。

2 相关工作

视觉语言动作 (VLA) 模型中的顺序推理。早期方法如 ECoT (Zawalski 等, 2024)、CoT-VLA (Zhao 等, 2025)、RoboMamba (Liu 等, 2024) 和 PI0.5 (Black 等, 2025) 在动作之前输出预定义的结构化信息,例如子任务分解。后续工作如 ChatVLA (Zhou 等, 2025b)、ChatVLA2 (Zhou 等, 2025a)、Hume (Song 等, 2025) 和 OneTwoVLA (Lin 等, 2025) 转向生成更具适应性的自由形式自然语言思维。然而,所有方法都需要昂贵的微调来使 VLA 适应推理的辅助任务。此外,它们在文本和动作的优化之间存在冲突。

视觉语言动作 (VLA) 模型中的并行推理。并行推理通常采用 Best-of-N 采样 (Sessa 等, 2024; Zhang 等, 2024; Wang 等, 2025d; Verdun 等, 2025; Toshniwal 等, 2025; Nguyen 等, 2025) 或自一致性 (Wang 等, 2024b; a; Prasad 等, 2024; Wang 等, 2025b)。对于 VLA,一个方向 (Guo 等, 2025) 使用世界模型来指导蒙特卡洛树搜索,但受到巨大计算成本和限制的阻碍。

世界模型在真实场景中的保真度有限。其他方法 (Kwok 等, 2025; Nakamoto 等, 2024) 采样大量动作候选, 并使用大型外部评论模型进行选择。然而, 它们不加区分的推敲代价高昂, 且绝对动作评分不稳定。

3 预备知识: 视觉-语言-动作推理范式

当代视觉-语言-动作模型, 如 PI0 (Black 等, 2025), 通常采用两阶段推理过程。给定时间步 t 的多模态观测, 包含图像 I_t 和语言指令 T , 过程如下: 视觉-语言编码: 高容量预训练视觉-语言模型骨干 Φ_{VLM} 处理输入, 生成丰富的多模态上下文嵌入或内部特征, C_t :

$$C_t = \Phi_{VLM}(I_t, T) \in \mathbb{R}^{L \times D_{emb}} \quad (1)$$

该上下文 C_t 封装了对场景和任务目标的语义理解。该操作通常涉及大型变换器 (Transformer) 的前向传播, 计算密集。

动作解码: A specialized action head, Ψ_{Action} , then conditions on this context C_t to generate an action chunk a_t :

$$a_t = \Psi_{Action}(C_t, z), \quad \text{where } z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (2)$$

其中 z 表示随机生成过程所需的初始噪声向量或随机种子。现代视觉-语言-动作模型在此阶段主要采用扩散或流匹配等生成模型。

关键的是, 计算成本高度不对称。视觉-语言模型编码占延迟的绝大部分, 我们称该过程为“预填充”。相比之下, 动作解码即使包含多个采样步骤, 也显著更快。例如, 在 PI0 策略中, 动作解码在 RTX4090 上仅占总推理时间 86 毫秒中的 27 毫秒。我们的 VLA-ATTC 框架设计为每个时间步仅执行一次昂贵的预填充操作, 将其成本分摊到所有生成的动作上, 从而高效采样多个动作候选。

4 VLA-ATTC

4.1 不确定性量化作为离合器

一种实用的测试时深思方法应仅在必要时激活, 以确保可控的推理开销。为评估深思的必要性, 首先需量化模型的不确定性。不确定性越低, 表明模型置信度越高, 因此所需深思越少。本文认为, 置信度高的模型尽管随机种子 z 变化, 仍会产生一致的动作; 而不确定的模型将表现出高方差。在每个时间步 t , 生成两个动作块, a_1

Algorithm 1 VLA-ATTC Inference

Require: VLM Backbone Φ_{VLM} , Action Head Ψ_{Action} , Relative Action Critic $\mathcal{R}$, Image I_t , Instruction T , State s_t , Uncertainty threshold τ , Candidate count N

- 1: $C_t \leftarrow \Phi_{VLM}(I_t, T)$ ▷ Prefill VLM once
- 2: $a_1, a_2 \leftarrow \Psi_{Action}(C_t)$ ▷ Generate two actions
- 3: $U_t \leftarrow \text{DTW}(a_1, a_2)$ ▷ Calculate DTW as uncertainty
- 4: **if** $U_t < \tau$ **then** ▷ High confidence
- 5: $a_{final} \leftarrow a_1$
- 6: **else** ▷ Low confidence: trigger deliberation
- 7: $\mathcal{A} \leftarrow \{a_i\}_{i=1}^N \leftarrow \Psi_{Action}(C_t)$ ▷ Batch Generation
- 8: **while** $\text{LEN}(\mathcal{A}) > 1$ **do**
- 9: $\mathcal{A}_{next} \leftarrow \emptyset$ ▷ Initialize next round's winners
- 10: **for** (a_i, a_j) in $\text{PAIRWISE}(\mathcal{A})$ **do**
- 11: $p_{ij} \leftarrow \mathcal{R}(a_i, a_j, C_t, s_t)$ ▷ RAC predicts
- 12: **if** $p_{ij} \geq 0.5$ **then**
- 13: $\text{ADD}(\mathcal{A}_{next}, a_i)$
- 14: **else**
- 15: $\text{ADD}(\mathcal{A}_{next}, a_j)$
- 16: **end if**
- 17: **end for**
- 18: $\mathcal{A} \leftarrow \mathcal{A}_{next}$ ▷ Update candidate set
- 19: **end while**
- 20: $a_{final} \leftarrow \mathcal{A}[0]$ ▷ Single best action remains
- 21: **end if**
- 22: **EXECUTE**(a_{final})

和 a_2 , 通过共享视觉语言模型上下文 C_t 但使用不同种子:

$$\{\mathbf{a}_k\}_{k=1}^2 = \{\Psi_{Action}(\mathbf{C}_t, \mathbf{z}_k) \mid \mathbf{z}_k \stackrel{\text{iid}}{\sim} \mathcal{N}(\mathbf{0}, \mathbf{I})\} \quad (3)$$

在共享预填充的情况下, 第二个动作带来的额外开销可以忽略不计。设每个动作块为 H 个姿态的序列 $a = (p^1, \dots, p^H)$, 其中每个姿态 $p^k \in \mathbb{R}^D$ 且 D 为动作维度。为了度量这两个动作块之间的一致性, 我们采用动态时间规整 (Dynamic Time Warping, DTW) 距离。为了计算 DTW 距离, 我们构建一个 $H \times H$ 的累积代价矩阵 Γ 。矩阵中的每个元素 $\Gamma(i, j)$ 存储将 a_1 的前 i 个姿态与 a_2 的前 j 个姿态对齐所需的最小累积代价。该矩阵通过以下递推关系迭代计算:

$$\Gamma(i, j) = d(p_1^i, p_2^j) + \min \begin{cases} \Gamma(i-1, j) \\ \Gamma(i, j-1) \\ \Gamma(i-1, j-1) \end{cases} \quad (4)$$

其中 $d(p_1^i, p_2^j)$ 是一种局部代价测度, 本文将其定义为两个位姿之间的欧氏距离 $\|p_1^i - p_2^j\|_2$ 。该矩阵初始化为 $\Gamma(0, 0) = 0$ 和 $\Gamma(i, 0) = \Gamma(0, j) = \infty$ 对于 $i, j > 0$ 。

最终标量不确定性分数 U_t 为矩阵右上角所示的总累计代价, 表示




图 3. VLA-ATTC 框架的整体架构。流程始于“认知离合器”（第 4.1 节），该模块量化 VLA 动作生成的不确定性。若不确定性较低，模型则反射性地执行初始动作。若不确定性超过阈值，则激活深思阶段（第 4.2 节）。该阶段 1) 通过分摊昂贵的 VLM 骨干计算，高效并行生成 N 个动作候选；2) 采用锦标赛选择机制。随后，本文轻量级的相对动作评论家模型执行迭代式成对比较，以确定最终最优动作。

两条完整序列之间的最优对齐代价：

$$U_t = \Gamma(H, H) \quad (5)$$

不确定性得分 U_t 作为“认知离合器”的信号。我们通过取离线数据集上计算的不确定性得分的第 K 百分位数来建立阈值 τ 。在测试时，最终策略 π_{deploy} 在反射执行和 TTC 深思之间自适应切换：

$$\pi_{\text{deploy}}(s_t) = \begin{cases} a_1 & \text{if } U_t \leq \tau \quad (\text{Fast}) \\ \text{Deliberate}(C_t, s_t) & \text{if } U_t > \tau \quad (\text{Slow}) \end{cases} \quad (6)$$

4.2 TTC 深思阶段

当触发 TTC 深思时，我们首先并行生成 N 个候选动作块 $\{a_1, \dots, a_N\}$ ，使用动作头 Ψ_{Action} 和预填充上下文 C_t ：

$$\{a_1, \dots, a_N\} = \Psi_{\text{Action}}(C_t, \{z_1, \dots, z_N\}) \quad (7)$$

并行批量采样使得生成多个候选动作的边际成本很小。

然后我们需要从这些候选中选择最佳动作。此过程中的一个重大挑战是动作质量评估的固有困难。为复杂动作块分配绝对标量质量分数通常是定义不清且模糊的。为规避此问题，我们的框架将评估从绝对评分重构为相对成对比较。我们假设，在当前上下文下判断动作 a_i 是否优于 a_j （记作 $a_i \succ a_j$ ）是一个定义更明确且偏差更小的任务。我们通过实现锦标赛式选择过程来利用这一原则。该机制通过进行一系列成对比较来迭代筛选候选。设 $\mathcal{R}$ 为我们的 RAC 模型，其细节将在下一节中介绍。RAC 模型可以在给定两个动作、本体感受状态 s_t 和共享上下文 C_t 的情况下估计偏好概率 p_{ij} ：

$$p_{ij} = \mathcal{R}(a_i, a_j, C_t, s_t) \quad (8)$$

在锦标赛的每一轮中，候选集合被组织成对。对于每一对 (a_i, a_j) ，根据评论家输出选择首选动作晋级下一轮：

$$a_{\text{winner}} = \begin{cases} a_i & \text{if } p_{ij} \geq 0.5 \\ a_j & \text{otherwise} \end{cases} \quad (9)$$

这种单淘汰过程每轮淘汰一半候选。它重复进行，直到仅剩一个最优动作 a_* 。

4.3 相对动作评论家 (RAC) 模型

我们 TTC 审议阶段的基石是 RAC，一个训练用于充当成对偏好评判器的模型。它根据上下文判断动作 a_i 是否优于 a_j 。该模型轻量但功能强大，因为它可以利用 VLM 的内部特征来减少计算量。

4.3.1 输入表示

RAC 接收四个不同的输入：两个待比较的动作块 a_i 和 a_j ；它们的差值 $a_i - a_j$ ；以及当前的本体感受状态 s_t 。每个输入都由一个专用的多层感知机独立映射到模型的嵌入维度 d_{model} ：

$$e_i = \text{MLP}_i(a_i), \quad e_j = \text{MLP}_j(a_j) \quad (10)$$

$$e_{\text{diff}} = \text{MLP}_{\text{diff}}(a_i - a_j), \quad e_s = \text{MLP}_s(s_t) \quad (11)$$

这四个嵌入向量随后被拼接起来，形成 RAC 变换器塔的初始隐藏状态：

$$X^0 = \text{Concat}[e_i; e_j; e_{\text{diff}}; e_s].$$

4.3.2 分层上下文条件

为了使 RAC 具备任务相关的上下文，我们引入了一组 N_q 个随机初始化、可学习的查询令牌 $q_{\text{rac}} \in \mathbb{R}^{N_q \times d_{\text{model}}}$ 。这些令牌被附加到 VLM 的输入序列中。在 VLM 的预填充计算过程中，这些查询从 VLM 的原始特征 F_{vlm} 中提炼出高层语义信息，有效地创建了




图 4. 相对动作评判器 (RAC) 模型的详细架构 (第 4.3 节)。(左) VLM 骨干网络增加了 N_q 个可学习查询。在单次预填充过程中, 这些查询从图像和指令中提炼出高层语义上下文查询特征, 同时保留标准原始特征。(中) RAC 模型本身是一个与 VLM 深度一致的变换器。它接收四个由专用多层感知机处理的输入: 动作 i 、动作 j 、它们的差值 (动作 i - 动作 j) 以及当前的本体感受状态。(右) 核心组件是多分支 RAC 注意力块。在每一层, 该块分层融合来自三个来源的信息: (1) 对 RAC 自身特征的自注意力, (2) 对同一层 VLM 原始特征的原始交叉注意力, 以及 (3) 对提炼查询特征的查询交叉注意力。这种架构使 RAC 既轻量又具有高度上下文感知能力。

对 VLM 理解的压缩、面向任务的总结。这些查询令牌的最终隐藏状态 F_{query} 为 RAC 提供了丰富的上下文来源。

$$C_t = [F_{vlm}, F_{query}] = \Phi_{VLM}(I_t, T, q_{rac}) \quad (12)$$

4.3.3 多分支注意力架构

RAC 是一个深度为 L 的变换器, 与视觉语言模型骨干网络的深度相匹配。RAC 的每一层 $l \in [1, L]$ 通过一个复杂的三分支注意力模块更新其输入 X^{l-1} , 如图 4 所示。1. 自注意力: 第一个分支在 RAC 自身的表示上计算自注意力:

$$O_{sa}^l = \text{Attention}(Q(X^{l-1}), K(X^{l-1}), V(X^{l-1})) \quad (13)$$

2. 原始交叉注意力: 第二个分支通过关注视觉语言模型骨干网络中对应层 l 的原始特征来注入广泛的上下文信息, F_{vlm}^l :

$$O_{raw}^l = \text{Attention}(Q(X^{l-1}), K(F_{vlm}^l), V(F_{vlm}^l)) \quad (14)$$

3. 查询交叉注意力: 第三个分支关注来自同一层 l , F_{query}^l 的视觉语言模型可学习查询令牌中经过提炼的专门上下文特征:

$$O_{query}^l = \text{注意力} (Q(X^{l-1}), K(F_{query}^l), V(F_{query}^l)) \quad (15)$$

这三个输出随后被融合。查询交叉注意力分支由一个可学习的标量门控参数 g^l 调制, 使模型能够动态控制提炼上下文的影响。融合表示 O_{fused}^l 通过拼接创建:

$$O_{fused}^l = \text{Concat}[O_{sa}^l, O_{raw}^l, g^l \times O_{query}^l] \quad (16)$$

该融合向量随后通过标准的变换器层组件: 前馈网络和层归一化, 并带有来自输入 X^{l-1} 的残差连接:

$$X^{l'} = \text{LN}(O_{fused}^l + X^{l-1}) \quad (17)$$

$$X^l = \text{LN}(\text{FFN}(X^{l'}) + X^{l'}) \quad (18)$$

在最后一层 L 之后, 输出表示 X^L 由分类头 (多层感知机) 处理以产生单个逻辑值。该逻辑值通过 Sigmoid 函数以预测 a_i 优于 a_j 的概率, 并使用焦点损失进行训练。

4.4 自动化动作偏好对筛选

为训练 RAC, 本文需要大规模偏好数据集。因此, 本文提出一种全自动流程, 通过操纵基于流匹配的动作头的生成过程来生成该数据集。

条件流匹配原理。流匹配动作头学习一个以上下文为条件的向量场, 将简单先验分布 $p_{prior}(a)$ (例如高斯噪声) 变换为专家动作的复杂数据分布 $p_{data}(a|C_t)$ 。生成过程通过数值求解相应常微分方程实现, 流时间步从 τ 降至 $\tau = 1$, 最终到 $\tau = 0$:

$$\frac{da_\tau}{d\tau} = v(a_\tau, \tau, C_t) \quad (19)$$

最终样本的质量高度依赖于求解器使用的积分步数 (N_{steps})。更高的 N_{steps} 能更精确地逼近

表 1. LIBERO-LONG 上的平均任务成功率 (%)。Ours (Full) 表示不含认知离合器的 VLA-ATTC。

Task	Robomonkey	PI0	+Ours (Full)	+Ours	PI0.5	+Ours (Full)	+Ours
Soup and sauce in basket	59%	86%	94% (+8%)	92% (+6%)	92%	96% (+4%)	96% (+4%)
Box and butter in basket	79%	98%	100% (+2%)	100% (+2%)	96%	100% (+4%)	100% (+4%)
Turn on stove and put pot	58%	90%	96% (+6%)	94% (+4%)	92%	98% (+6%)	96% (+4%)
Bowl in drawer and close	37%	96%	100% (+4%)	98% (+2%)	98%	98% (=)	98% (=)
Two mugs on two plates	55%	90%	98% (+8%)	96% (+6%)	94%	100% (+6%)	100% (+6%)
Book in compartment	86%	86%	96% (+10%)	94% (+8%)	96%	100% (+4%)	98% (+2%)
Mug and pudding on plate	59%	84%	94% (+10%)	90% (+6%)	90%	98% (+8%)	92% (+2%)
Soup and box in Basket	62%	96%	98% (+2%)	98% (+2%)	98%	98% (=)	98% (=)
Both pots on stove	26%	40%	58% (+18%)	56% (+16%)	54%	68% (+14%)	66% (+12%)
Mug in microwave and close	44%	62%	88% (+26%)	88% (+26%)	92%	98% (+6%)	96% (+4%)
Average	56.5%	82.8%	92.2% (+9.4%)	90.6% (+7.8%)	90.6%	95.4% (+4.8%)	94% (+3.4%)

表 2. 使用 Agilex Piper 机械臂的真实世界任务成功率 (%)。VLA-ATTC 始终优于基线。

Task	Robomonkey	PI0	+Ours (Full)	+Ours	PI0.5	+Ours (Full)	+Ours
Stack cubes	18%	46%	62% (+16%)	58% (12%)	50%	60% (+10%)	60% (+10%)
Pour water	24%	50%	66% (+16%)	64% (+14%)	54%	68% (+14%)	66% (+12%)
Sweep rubbish	36%	42%	62% (+20%)	56% (14%)	52%	60% (+8%)	60% (+8%)
Average	26%	46%	63.3% (+17.3%)	58.7% (+12.7%)	52%	62.7% (+10.7%)	62% (+10%)

沿向量场的真实轨迹，从而生成更忠实于所学专家分布的样本。

数据策展流程。本文利用这一原理，从单个预训练的视觉-语言-动作模型 (VLA) 中生成不同质量的动作。对于专家数据集中的每个状态-动作对 (o_t, a_t^{expert}) ，本文生成：• 高质量动作 (a_t^{good})：通过以大量步数求解常微分方程 (ODE)， N_{high} 。• 低质量动作 (a_t^{bad})：通过以少量步数求解常微分方程 (ODE)， N_{low} 。

This establishes clear preference orderings: $a_t^{expert} \succ a_t^{bad}$ and $a_t^{good} \succ a_t^{bad}$, where $\succ$ denotes superiority. We then form a dataset of preference pairs with clear quality distinction, primarily using $\langle a_t^{expert}, a_t^{bad} \rangle$ and $\langle a_t^{good}, a_t^{bad} \rangle$. To ensure the model learns the relative quality rather than positional cues, we augment the dataset with the symmetric versions of each pair (e.g., also including $\langle a_t^{bad}, a_t^{expert} \rangle$ with the inverse label). This scalable, automated process allows us to generate a massive, high-quality preference dataset without any human intervention.

5 实验

在本节中，本文进行了大量实验以回答以下研究问题 (RQ)：

- **RQ1 (有效性)**：VLA-ATTC 能否显著提升复杂任务上的性能？
- **RQ2 (消融)**：核心组件的贡献是什么？候选规模与不确定性阈值的影响如何？
- **研究问题三 (机制)**：所提出的不确定性度量与自动化数据策展流程在科学上是否有效且必要？

- **研究问题四 (效率)**：在带来性能提升的同时，VLA-ATTC 是否保持了实际应用所需的高控制频率？

环境与任务 我们的实验在具有挑战性的仿真平台 LIBERO-LONG (Liu 等, 2023) 以及基于 Agilex Piper 机械臂的真实机器人系统上进行。

基础模型与实现细节 我们选择 PI0 (Black 等, 2024) 和 PI0.5 (Black 等, 2025) 这两个最先进的视觉-语言-动作模型作为基础模型。除非在消融研究中另有说明，不确定性阈值 τ 设为第 80 百分位，可学习查询数量 N_q 设为 8，候选数量为 16。所有实验中 RAC 模型的训练步数为 30000。对于自动化数据策展，我们使用了两对混合集用于 (N_{high}, N_{low}) ，具体为 $\langle 10, 3 \rangle$ 和 $\langle 9, 2 \rangle$ 。“Ours (Full)”表示我们不使用“认知离合器”，在所有时间步激活 TTC。每个任务执行 50 次以计算成功率。

5.1 VLA-ATTC 的有效性 (研究问题一)

观察 1：视觉语言动作 (VLA) -ATTC 提升了最先进 VLA 的性能 模型显著。我们首先在 LIBERO-LONG 基准和真实世界环境中，比较原始基础 VLA 模型与其 VLA-ATTC 增强版本的性能。如表 1 和表 2 所示，VLA-ATTC 带来了显著的性能提升。在极具挑战性的“两个锅都在炉子上”任务中，VLA-ATTC 将 PI0 的平均成功率从 40% 提高到 58%，表明在关键时刻的深思熟虑决策能有效防止灾难性失败。值得注意的是，VLA-ATTC 在真实机器人任务上将 PI0 的平均成功率提高了 17.3%，证明了其

表 3. 不确定性阈值 (τ , 按第 K 百分位设定) 对 PI0-ATTC 和 PI0.5-ATTC 的成功率与延迟的影响。

K-th percentile	PI0-0%	PI0-40%	PI0-60%	PI0-80%	PI0.5-0%	PI0.5-40%	PI0.5-60%	PI0.5-80%
Soup and sauce in basket	94%	92%	92%	92%	96%	96%	96%	96%
Box and butter in basket	100%	100%	100%	100%	100%	100%	100%	100%
Turn on stove and put pot	96%	96%	94%	94%	98%	98%	96%	96%
Bowl in drawer and close	100%	98%	98%	98%	98%	98%	98%	98%
Two mugs on two plates	98%	98%	98%	96%	100%	100%	100%	100%
Book in compartment	96%	96%	94%	94%	100%	98%	98%	98%
Mug and pudding on plate	94%	94%	92%	90%	98%	96%	96%	92%
Soup and box in Basket	98%	98%	98%	98%	98%	98%	98%	98%
Both pots on stove	58%	58%	58%	56%	68%	66%	66%	66%
Mug in microwave and close	88%	88%	88%	88%	98%	96%	96%	96%
Average	92.2%	91.8%	91.2%	90.6%	95.4%	94.6%	94.4%	94%

表 4. 深思过程中候选动作数量 (N) 对 LIBERO-LONG 成功率的影响。

Number of candidate actions	4 (PI0)	8 (PI0)	16 (PI0)	32 (PI0)	4 (PI0.5)	8 (PI0.5)	16 (PI0.5)	32 (PI0.5)
Soup and sauce in basket	90%	90%	92%	92%	94%	96%	96%	96%
Box and butter in basket	100%	100%	100%	100%	100%	100%	100%	100%
Turn on stove and put pot	92%	94%	94%	94%	94%	96%	96%	98%
Bowl in drawer and close	98%	98%	98%	98%	94%	98%	98%	100%
Two mugs on two plates	94%	94%	96%	98%	100%	100%	100%	100%
Book in compartment	90%	94%	94%	96%	98%	100%	98%	100%
Mug and pudding on plate	86%	88%	90%	94%	92%	94%	92%	96%
Soup and box in Basket	96%	96%	98%	98%	96%	98%	98%	100%
Both pots on stove	48%	52%	56%	60%	56%	60%	66%	66%
Mug in microwave and close	76%	82%	88%	88%	96%	96%	96%	96%
Average	87%	88.8%	90.6%	91.8%	92.0%	93.8%	94%	95.2%

excellent performance on physical hardware. VLA-ATTC consistently surpasses previous representative deliberation method Robomonkey (Kwok et al., 2025).

5.2 Ablation Studies and Analysis (RQ2)

Obs2: Cognitive Clutch is accurate, with difficult states being sparse. The sensitivity of the “Cognitive Clutch” is governed by the uncertainty threshold τ , set as the K-th percentile. We study the effect of varying τ on task success rate. As shown in Table 3, although lower τ triggers more deliberation, the performance does not improve significantly. This suggests that only a few scenarios during the operation are difficult, which also proves that our cognitive clutch can effectively identify these few critical, difficult scenarios.

观察 3: 更多候选动作带来更高性能收益。在测试时计算 (TTC) 的审议阶段, 我们通过并行采样 N 个候选动作来探索更优解。我们研究了 N 的选择如何影响最终成功率。如表 4 所示, 即使候选数量较少 (例如 $N = 4$), 性能也有显著提升。虽然随着候选动作数量的增加, 性能稳步提升, 但考虑到计算成本的增加, 我们认为 $N = 16$ 是一个高效且有效的选择。

观察 4: RAC 的所有专用组件均为 es-对于准确预测偏好至关重要。图 5 所示的消融研究表明, 移除关键架构元素——特别是可学习权重、激活函数——




图 5. 不同 RAC 模型变体在 LIBERO-LONG 上的成功率比较。

差异输入或可学习查询的移除均会持续降低在 LIBERO-LONG 基准上的性能。完整的 RAC 模型达到了最高的成功率 (PI0.5+ATTC 为 94%, PI0+ATTC 为 90.8%), 而移除“可学习查询”组件会导致性能下降最为显著, 成功率分别降至 92.4% 和 88%。这些发现证实了 RAC 框架中的每一项设计选择对于有效评估和选择最优动作都是必要的。

5.3 机制分析 (RQ3)

为验证核心设计选择的科学有效性——具体而言, 即不确定性度量与自动化数据策展流程——本文开展了针对性的对照实验。

表 5. 平均控制频率（赫兹）的比较。VLA-ATTC 保持了较高的控制率。

Model	PI0/0.5 (Baseline)	Robomoney	VLA-ATTC (Full)	VLA-ATTC
Avg. Control Frequency (Hz)	23.3Hz	1.5Hz	12.1Hz	20.8Hz




图 6. PI0.5-ATTC 的两个代表性案例。它在面对困难情况时自适应地触发 TTC。

表 6. 不确定性估计策略与人类专家排名的验证对比。在 1,000 对观测数据上进行测试。

Method	Metric	Human Agree. (%)	Cost (Rel.)
Ours ($N = 2$)	Pairwise DTW	89.2	1.0×
Baseline ($N = 4$)	Mean Pairwise Dist.	90.1	2.0×
Baseline ($N = 8$)	Mean Pairwise Dist.	90.4	4.0×

表 7. 常微分方程积分步数对动作质量的影响。“倒水”任务中的真实世界成功率（各 50 次试验）。

ODE Steps (N_{steps})	Success Rate (%)	Behavior Description
10 (High Quality)	54	Precise execution
5 (Mid Quality)	42	Coherent, misaligned
1 (Low Quality)	18	Rough, frequent failure

观察 5：最小采样（ $N = 2$ ）足以进行有效的

不确定性估计。 关于我们的“认知离合器”，一个潜在的担忧是：仅比较两个动作候选是否足够稳健以准确衡量情境不确定性。为探究此问题，我们构建了一个包含 1000 对观测场景的专用评估数据集。四位人类专家对这些场景对进行标注，以识别每对中哪个场景呈现更高的难度级别（即更高的失败可能性），作为真实标签。我们将所提出的策略（2 个动作，使用动态时间规整，DTW）与使用更多样本（ $N = 4$ 和 $N = 8$ ）并采用平均成对距离（MPD）作为不确定性度量的基线进行比较。如表 6 所示，我们的方法与人类专家的一致性准确率达到 89.2%。关键的是，将样本规模扩展到 4 或 8 仅带来边际改进（ $< 1.5\%$ ），同时线性增加了动作头的计算开销。

观察 6：减少常微分方程步数产生有效的偏好梯度，而非随机噪声。

我们的自动化数据策展流程基于以下前提：减少常微分方程积分步数（ N_{steps} ）会优雅地降低动作质量，而不会退化为随机噪声，从而创建有效的“专家与次优”偏好对。为实证验证这一点，我们在 Agilex Piper 机械臂上使用“倒水”任务进行了真实世界实验，将 N_{steps} 分别设为 10、5 和 1。

表 7 中呈现的结果证实了我们的假设。高质量设置（ $N_{steps} = 10$ ）实现了 54% 的成功率，而将步数减少到 5 和 1 导致性能逐步下降（分别为 42% 和 18%）。这表明，以较低步数生成的动作在语义上保持连贯（例如，大致朝杯子移动），但存在精度误差（例如，溢出或未对准），而非表现出随机抖动。

5.4 效率分析（RQ4）

观察 7：视觉语言动作（VLA）-ATTC 保持高控制频率 适用于实时机器人。VLA-ATTC 的核心优势在于能够在提升决策质量的同时，对控制频率的影响降至最低。由于“认知离合器”的存在，昂贵的深思过程仅在必要时被调用。如表 5 所示，基线模型运行频率约为 23.3 Hz。集成 VLA-ATTC 后，平均控制频率仅略微下降至 20.8 Hz，因为深思仅在少数时间步内激活。这一速度显著高于其他依赖重型评论家模型或蒙特卡洛树搜索（MCTS）的无差别并行深思方法，例如 RoboMonkey (Kwok 等, 2025) 的 1.5 Hz。这证明了我们框架巨大的实用优势，使其适用于要求实时响应的机器人任务。

6 结论

本文提出了 VLA-ATTC，一个从根本上挑战 VLA 模型静态、“一刀切”推理范式的框架。通过基于不确定性的“认知离合器”动态触发测试时深思阶段，并采用高效、轻量级的相对动作评论家模型进行成对选择，我们的方法在复杂场景中显著增强了决策鲁棒性，同时不牺牲机器人所需的高控制频率。这项工作展示了自适应计算的关键价值，并为开发更高效、更具深思能力且能战略性地分配资源的智能体开辟了一个有前景的新方向。

资源以应对当前问题。

影响声明

本文旨在推动机器学习领域的发展，特别是在具身智能和机器人操作方面。我们的工作可能产生许多潜在的社会影响，但我们认为无需在此特别强调任何一项。

参考文献

- Black, K., Brown, N., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., Groom, L., Hausman, K., Ichter, B., et al. pi0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- Black, K., Brown, N., Darpinian, J., Dhabalia, K., Driess, D., Esmail, A., Equi, M., Finn, C., Fusai, N., Galliker, M. Y., et al. pi0.5: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- Chen, Q., Qin, L., Liu, J., Peng, D., Guan, J., Wang, P., Hu, M., Zhou, Y., Gao, T., and Che, W. Towards reasoning era: A survey of long chain-of-thought for reasoning large language models. *arXiv preprint arXiv:2503.09567*, 2025.
- Chen, Y., Cao, Z., Ren, H., Yang, C., Li, W., Wang, S., Wang, Y., Zhang, L., Shao, Y., Zhao, Z., et al. Roborouter: Training-free policy routing for robotic manipulation. *arXiv preprint arXiv:2603.07892*, 2026.
- Duan, J., Yu, S., Tan, H. L., Zhu, H., and Tan, C. A survey of embodied ai: From simulators to research tasks. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 6(2):230–244, 2022.
- Feng, Z., Xue, R., Yuan, L., Yu, Y., Ding, N., Liu, M., Gao, B., Sun, J., Zheng, X., and Wang, G. Multi-agent embodied ai: Advances and future directions. *arXiv preprint arXiv:2505.05108*, 2025.
- Fung, P., Bachrach, Y., Celikyilmaz, A., Chaudhuri, K., Chen, D., Chung, W., Dupoux, E., Gong, H., Jégou, H., Lazaric, A., et al. Embodied ai agents: Modeling the world. *arXiv preprint arXiv:2506.22355*, 2025.
- Guo, W., Lu, G., Deng, H., Wu, Z., Tang, Y., and Wang, Z. Vla-reasoner: Empowering vision-language-action models with reasoning via online monte carlo tree search. *arXiv preprint arXiv:2509.22643*, 2025.
- Huang, C., Huang, L., Leng, J., Liu, J., and Huang, J. Efficient test-time scaling via self-calibration. *arXiv preprint arXiv:2503.00031*, 2025.
- Kim, M. J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E., Lam, G., Sanke, P., et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- Kim, M. J., Finn, C., and Liang, P. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- Kwok, J., Agia, C., Sinha, R., Foutter, M., Li, S., Stoica, I., Mirhoseini, A., and Pavone, M. Robomodel: Scaling test-time sampling and verification for vision-language-action models. *arXiv preprint arXiv:2506.17811*, 2025.
- Li, D., Cao, S., Cao, C., Li, X., Tan, S., Keutzer, K., Xing, J., Gonzalez, J. E., and Stoica, I. S*: Test time scaling for code generation. *arXiv preprint arXiv:2502.14382*, 2025a.
- Li, M., Huang, X., and Zhang, Z. Self-supervised geometric features discovery via interpretable attention for vehicle re-identification and beyond. In *ICCV*, 2021.
- Li, M., Liu, J., Zheng, C., Huang, X., and Zhang, Z. Exploiting multi-view part-wise correlation via an efficient transformer for vehicle re-identification. *IEEE Transactions on Multimedia*, 25:919–929, 2023. doi: 10.1109/TMM.2021.3134839.
- Li, Q., Liang, Y., Wang, Z., Luo, L., Chen, X., Liao, M., Wei, F., Deng, Y., Xu, S., Zhang, Y., et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- Li, W., Su, X., Wu, J., Yang, F., Liu, Y., Chen, Y., You, S., and Xu, C. Identify, isolate, and purge: Mitigating hallucinations in llms via self-evolving distillation. In *Proceedings of the 33rd ACM International Conference on Multimedia*, pp. 6791–6800, 2025b.
- Li, W., Su, X., Cao, Y., Xu, H., Xia, X., You, S., Chen, Y., and Xu, C. Sentinel-vla: A metacognitive vla model with active status monitoring for dynamic reasoning and error recovery, 2026a. URL <https://arxiv.org/abs/2605.01191>.
- Li, W., Su, X., Niu, D., Cao, Y., Xu, H., Qu, Z., Fan, L., You, S., and Xu, C. Vla-attc: Adaptive test-time compute for vla models with relative action critic model, 2026b. URL <https://arxiv.org/abs/2605.01194>.
- Li, Z., Chi, C., Wei, Y., Zhu, B., Huang, T., Sun, Z., Peng, Y., Wang, P., Wang, Z., Liu, F., et al. Do you have freestyle? expressive humanoid locomotion via audio control. *arXiv preprint arXiv:2512.23650*, 2025c.

- Li, Z., Chi, C., Zhu, B., Wei, Y., Bai, S., Ji, Y., Peng, Y., Huang, T., Wang, P., Wang, Z., et al. Robomirror: Understand before you imitate for video to humanoid locomotion. *arXiv preprint arXiv:2512.23649*, 2025d.
- Lin, F., Nai, R., Hu, Y., You, J., Zhao, J., and Gao, Y. Onetwovla: A unified vision-language-action model with adaptive reasoning. *arXiv preprint arXiv:2505.11917*, 2025.
- Liu, B., Zhu, Y., Gao, C., Feng, Y., Liu, Q., Zhu, Y., and Stone, P. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023.
- Liu, J., Liu, M., Wang, Z., Lee, L., Zhou, K., An, P., Yang, S., Zhang, R., Guo, Y., and Zhang, S. Robomamba: Multimodal state space model for efficient robot reasoning and manipulation. *arXiv e-prints*, pp. arXiv–2406, 2024.
- Liu, Y., Chen, W., Bai, Y., Liang, X., Li, G., Gao, W., and Lin, L. Aligning cyber space with physical world: A comprehensive survey on embodied ai. *IEEE/ASME Transactions on Mechatronics*, 2025.
- Memarian, B. and Doleck, T. Embodied ai in education: A review on the body, environment, and mind. *Education and Information Technologies*, 29(1):895–916, 2024.
- Miao, J., Thongprayoon, C., Suppadungsuk, S., Krisanapan, P., Radhakrishnan, Y., and Cheungpasitporn, W. Chain of thought utilization in large language models and application in nephrology. *Medicina*, 60(1):148, 2024.
- Muennighoff, N., Yang, Z., Shi, W., Li, X. L., Fei-Fei, L., Hajishirzi, H., Zettlemoyer, L., Liang, P., Candès, E., and Hashimoto, T. s1: Simple test-time scaling. *arXiv preprint arXiv:2501.19393*, 2025.
- Nakamoto, M., Mees, O., Kumar, A., and Levine, S. Steering your generalists: Improving robotic foundation models via value guidance. *arXiv preprint arXiv:2410.13816*, 2024.
- Nguyen, H. T., Nguyen, B., and Nguyen, V. A. Structured pruning for diverse best-of-n reasoning optimization. *arXiv preprint arXiv:2506.03978*, 2025.
- Paolo, G., Gonzalez-Billandon, J., and Kégl, B. Position: a call for embodied ai. In *Forty-first International Conference on Machine Learning*, 2024.
- Prasad, A., Yuan, W., Pang, R. Y., Xu, J., Fazel-Zarandi, M., Bansal, M., Sukhbaatar, S., Weston, J., and Yu, J. Self-consistency preference optimization. *arXiv preprint arXiv:2411.04109*, 2024.
- Sessa, P. G., Dadashi, R., Hussenot, L., Ferret, J., Vieillard, N., Ramé, A., Shariari, B., Perrin, S., Friesen, A., Cideron, G., et al. Bond: Aligning llms with best-of-n distillation. *arXiv preprint arXiv:2407.14622*, 2024.
- Shukor, M., Aubakirova, D., Capuano, F., Kooijmans, P., Palma, S., Zouitine, A., Aractingi, M., Pascal, C., Russi, M., Marafioti, A., et al. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- Song, H., Qu, D., Yao, Y., Chen, Q., Lv, Q., Tang, Y., Shi, M., Ren, G., Yao, M., Zhao, B., et al. Hume: Introducing system-2 thinking in visual-language-action model. *arXiv preprint arXiv:2505.21432*, 2025.
- Tan, S., Qiu, X., Shu, Y., Xu, G., Xu, L., Xu, X., Zhuang, H., Li, M., and Yu, F. WMarkGPT: Watermarked image understanding via multimodal large language models. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pp. 58621–58636. PMLR, 13–19 Jul 2025.
- Team, O. M., Ghosh, D., Walke, H., Pertsch, K., Black, K., Mees, O., Dasari, S., Hejna, J., Kreiman, T., Xu, C., et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- Toshniwal, S., Sorokin, I., Ficek, A., Moshkov, I., and Gitman, I. Genselect: A generative approach to best-of-n. *arXiv preprint arXiv:2507.17797*, 2025.
- Verdun, C. M., Oesterling, A., Lakkaraju, H., and Calmon, F. P. Soft best-of-n sampling for model alignment. *arXiv preprint arXiv:2505.03156*, 2025.
- Wang, C., Guo, J., Li, H., Tian, Y., Nie, Y., Xu, C., and Han, K. Circle-rope: Cone-like decoupled rotary positional embedding for large vision-language models. *arXiv preprint arXiv:2505.16416*, 2025a.
- Wang, H., Prasad, A., Stengel-Eskin, E., and Bansal, M. Soft self-consistency improves language model agents. *arXiv preprint arXiv:2402.13212*, 2024a.
- Wang, X. and Zhou, D. Chain-of-thought reasoning without prompting. *Advances in Neural Information Processing Systems*, 37:66383–66409, 2024.
- Wang, X., Feng, S., Li, Y., Yuan, P., Zhang, Y., Tan, C., Pan, B., Hu, Y., and Li, K. Make every penny count: Difficulty-adaptive self-consistency for cost-efficient reasoning. *arXiv preprint arXiv:2408.13457*, 2024b.
- Wang, X., Feng, S., Li, Y., Yuan, P., Zhang, Y., Tan, C., Pan, B., Hu, Y., and Li, K. Make every penny count:

- Difficulty-adaptive self-consistency for cost-efficient reasoning. In *Findings of the Association for Computational Linguistics: NAACL 2025*, pp. 6904–6917, 2025b.
- Wang, Y., Wu, S., Zhang, Y., Yan, S., Liu, Z., Luo, J., and Fei, H. Multimodal chain-of-thought reasoning: A comprehensive survey. *arXiv preprint arXiv:2503.12605*, 2025c.
- Wang, Y., Zhang, P., Huang, S., Yang, B., Zhang, Z., Huang, F., and Wang, R. Sampling-efficient test-time scaling: Self-estimating the best-of-n sampling in early decoding. *arXiv preprint arXiv:2503.01422*, 2025d.
- Xia, Y., Wang, R., Liu, X., Li, M., Yu, T., Chen, X., McAuley, J., and Li, S. Beyond chain-of-thought: A survey of chain-of-x paradigms for llms. *arXiv preprint arXiv:2404.15676*, 2024.
- Xu, S., Wang, Y., Xia, C., Zhu, D., Huang, T., and Xu, C. Vla-cache: Towards efficient vision-language-action model via adaptive token caching in robotic manipulation. *arXiv preprint arXiv:2502.02175*, 2025a.
- Xu, S., Wang, Y., Xia, C., Zhu, D., Huang, T., and Xu, C. Vla-cache: Efficient vision-language-action manipulation via adaptive token caching. *arXiv preprint arXiv:2502.02175*, 2025b.
- Xu, S., Wang, Z., Wang, Y., Xia, C., Huang, T., and Xu, C. Affordance field intervention: Enabling vlases to escape memory traps in robotic manipulation. *arXiv preprint arXiv:2512.07472*, 2025c.
- Yang, Y., Zeng, S., Lin, T., Chang, X., Qi, D., Xiao, J., Liu, H., Chen, R., Chen, Y., Huo, D., et al. Abot-m0: Vla foundation model for robotic manipulation with action manifold learning. *arXiv preprint arXiv:2602.11236*, 2026.
- Yeo, E., Tong, Y., Niu, M., Neubig, G., and Yue, X. Demystifying long chain-of-thought reasoning in llms. *arXiv preprint arXiv:2502.03373*, 2025.
- Zawalski, M., Chen, W., Pertsch, K., Mees, O., Finn, C., and Levine, S. Robotic control via embodied chain-of-thought reasoning. *arXiv preprint arXiv:2407.08693*, 2024.
- Zeng, X., Xu, Q., Wang, Y., and Xu, C. Hici: Hierarchical construction-integration for long-context attention. *arXiv preprint arXiv:2603.20843*, 2026.
- Zeng, Z., Cheng, Q., Yin, Z., Zhou, Y., and Qiu, X. Revisiting the test-time scaling of o1-like models: Do they truly possess test-time scaling capabilities? *arXiv preprint arXiv:2502.12215*, 2025.
- Zhang, Q., Lyu, F., Sun, Z., Wang, L., Zhang, W., Hua, W., Wu, H., Guo, Z., Wang, Y., Muennighoff, N., et al. A survey on test-time scaling in large language models: What, how, where, and how well? *arXiv preprint arXiv:2503.24235*, 2025.
- Zhang, R., Haider, M., Yin, M., Qiu, J., Wang, M., Bartlett, P., and Zanette, A. Accelerating best-of-n via speculative rejection. In *ICML 2024 Workshop on Structured Probabilistic Inference Generative Modeling*, 2024.
- Zhao, Q., Lu, Y., Kim, M. J., Fu, Z., Zhang, Z., Wu, Y., Li, Z., Ma, Q., Han, S., Finn, C., et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pp. 1702–1713, 2025.
- Zhou, Z., Zhu, Y., Wen, J., Shen, C., and Xu, Y. Chatvla-2: Vision-language-action model with open-world embodied reasoning from pretrained knowledge. *arXiv preprint arXiv:2505.21906*, 2025a.
- Zhou, Z., Zhu, Y., Zhu, M., Wen, J., Liu, N., Xu, Z., Meng, W., Cheng, R., Peng, Y., Shen, C., et al. Chatvla: Unified multimodal understanding and robot control with vision-language-action model. *arXiv preprint arXiv:2502.14420*, 2025b.

A Verification of Semantic Preference Learning in RAC

A potential concern regarding our automated data curation pipeline (Sec. 3.4) is that the RAC model might solely rely on distinguishing low-level generation artifacts (e.g., trajectory smoothness or noise levels) resulting from different ODE integration steps (N_{high} vs. N_{low}), rather than acquiring a semantic understanding of task fulfillment.

To rule out this possibility and verify that the RAC genuinely aligns actions with visual context and language instructions, we conducted a controlled "Cross-Task" experiment.

Experimental Setup. We utilized the real-world "Stack Cubes" task for this validation. We collected a dataset of 1,000 observations from successful execution trajectories. For each observation, we generated a pair of action candidates to be evaluated by the RAC model trained on the "Stack Cubes" task:

- **Positive Sample (Task-Aligned):** Actions generated by the "Stack Cubes" expert policy.
- **Negative Sample (Task-Misaligned):** Actions generated by a policy trained on a completely different task ("Pour Water"), applied to the "Stack Cubes" observations.

Crucially, **both policies generated actions using a high number of ODE integration steps** ($N_{steps} = 10$). This setup ensures that both candidates possess high trajectory quality and smoothness, eliminating low-level generation artifacts as a discriminative feature. The only distinguishing factor is the semantic alignment with the "Stack Cubes" task.

Results. The RAC model demonstrated a high accuracy of **97.3%** in identifying the actions from the "Stack Cubes" policy as the preferred candidates. This result strongly evidences that the RAC goes beyond detecting generation quality; it successfully learns to evaluate the semantic compatibility between the proposed action, the visual observation, and the task instruction.